图卷积网络的公式、直观含义与卷积来源

摘要

图卷积网络的核心操作是：每个节点收集自己和邻居的特征，按照图结构加权汇总，再通过所有节点共享的参数变换，得到新的特征。本文以经典的 Kipf–Welling 图卷积网络（Graph Convolutional Network，GCN）为例，从矩阵维度、节点计算、归一化设计与数值示例出发，解释其层更新公式；随后通过图傅里叶变换与一阶谱滤波近似，说明它为什么可以被称为卷积。文中另设带权图专节，详细讨论加权度数、节点聚合、手算示例、两类归一化、自环尺度，以及有向边与负边权的适用边界，并讨论 GCN 与图像卷积的联系、区别和适用条件。

目录

1 从普通卷积出发：为什么图上需要新的公式？ 3

2 GCN 的完整公式与各个符号 3

2.1 节点特征矩阵 3

2.2 邻接矩阵、自环和度数 3

2.3 可训练参数和非线性 4

3 把矩阵公式展开：每个节点究竟在做什么？ 4

4 为什么需要自环、归一化、参数矩阵和非线性？ 5

4.1 加自环：让节点也使用自己的信息 5

4.2 对称归一化：调整传播尺度 5

4.3 参数矩阵：学习任务需要的特征组合 5

4.4 非线性：增加表达能力 5

5 一个可以手算的例子 6

6 为什么可以称为卷积：频率域的数学联系 6

6.1 图拉普拉斯与图频率 7

6.2 谱图卷积的定义 7

7 谱图卷积如何变成经典 GCN 公式？ 7

7.1 多项式近似带来局部性 7
7.2 一阶近似与参数约束 8
7.3 重归一化是设计上的替换 8

8 带权邻接矩阵：卷积如何进行？ 8
8.1 边权的含义：强连接还是大距离? 9
8.2 度数必须改为边权之和 9
8.3 矩阵形式与节点形式 9
8.4 完整的带权手算例子 10
8.5 若希望严格做加权平均 10
8.6 带权后为什么仍然是图卷积? 11
8.7 边权尺度与自环权重的关系 11
8.8 有向边与负边权不能直接套用无向非负推导 11

9 它与图像卷积的相似之处和区别 12

10 为什么这种操作有用，什么时候会受限制？ 12
10.1 层数不是越多越好：过平滑 12

11 如何记住这条公式 13

1 从普通卷积出发：为什么图上需要新的公式？

对于一维信号，深度学习中通常称为卷积的运算可以写成

$$y_i = \sum_{r=-R}^{R} w_r x_{i+r}. \tag{1}$$

它表示：计算位置 i 的输出时，取附近位置的输入，用同一组权重加权求和。图像中的二维卷积也是如此，只是邻域变成一个小窗口。严格来说，上式采用互相关的索引写法；数学卷积常写成 $\sum_r w_r x_{i-r}$。对于可训练核，两种约定可通过翻转核的索引互相对应，不影响这里对局部滤波的解释。

普通卷积包含三个关键特点：

- **局部性**：只看附近的位置。
- **权重共享**：不同位置使用同一个卷积核。
- **根据相对位置组合信息**：左边、右边、上边等位置各有对应的权重。

图数据也有“附近”的概念，即节点的邻居。但一个节点可能有两个邻居，另一个有十个邻居，而且一般没有统一的“左边第一个邻居”或“右边第二个邻居”。因此，要把局部滤波推广到图上，需要**用边定义邻域，并用不依赖邻居排列顺序的方式组合信息**。

2 GCN 的完整公式与各个符号

经典 GCN 的一层写成

$$\boxed{H^{(\ell+1)} = \sigma\Big(\widetilde{D}^{-1/2}\widetilde{A}\widetilde{D}^{-1/2}H^{(\ell)}W^{(\ell)}\Big).} \tag{2}$$

本文假设图具有 n 个节点，是非负边权的无向图。其他图神经网络可能使用不同的聚合公式。

2.1 节点特征矩阵

$H^{(\ell)} \in \mathbb{R}^{n\times d_\ell}$ 是第 ℓ 层的节点特征矩阵：**一行对应一个节点，一列对应一种特征**。初始输入为 $H^{(0)} = X$，例如论文节点的词语特征或用户节点的属性。示意写法为

$$H^{(\ell)} = \begin{bmatrix} h_1^{(\ell)} \\ h_2^{(\ell)} \\ \vdots \\ h_n^{(\ell)} \end{bmatrix}, \tag{3}$$

其中 $h_i^{(\ell)}$ 是节点 i 的行向量表示。

2.2 邻接矩阵、自环和度数

$A \in \mathbb{R}^{n\times n}$ 是邻接矩阵。对于无权图，节点 i, j 相连时 $A_{ij} = 1$，否则为 0。定义

$$\widetilde{A} = A + I_n, \tag{4}$$

即为每个节点添加一条连接到自己的边，称为**自环**。定义加自环后的度数及其对角矩阵：

$$\widetilde{d}_i = \sum_j \widetilde{A}_{ij}, \qquad \widetilde{D} = \mathrm{diag}(\widetilde{d}_1, \ldots, \widetilde{d}_n). \tag{5}$$

对于原本没有自环的无权图，$\widetilde{d}_i = d_i + 1$。

2.3 可训练参数和非线性

$W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell+1}}$ 是可训练参数，负责把输入特征转换为输出特征。σ 是逐元素非线性函数，例如 $\mathrm{ReLU}(z) = \max(0, z)$。

定义传播矩阵

$$S = \widetilde{D}^{-1/2} \widetilde{A} \widetilde{D}^{-1/2}, \tag{6}$$

则式 (2) 可简写为

$$H^{(\ell+1)} = \sigma\Big(S H^{(\ell)} W^{(\ell)}\Big). \tag{7}$$

维度关系为

$$\underbrace{S}_{n\times n}\ \underbrace{H^{(\ell)}}_{n\times d_\ell}\ \underbrace{W^{(\ell)}}_{d_\ell \times d_{\ell+1}} \quad \in \mathbb{R}^{n \times d_{\ell+1}}. \tag{8}$$

S 负责**在节点之间混合信息**，$W^{(\ell)}$ 负责**在特征维度之间转换信息**。

3 把矩阵公式展开：每个节点究竟在做什么？

对于无权图，节点更新可以写成

$$\boxed{h_i^{(\ell+1)} = \sigma\left(\sum_{j \in \mathcal{N}(i)\cup\{i\}} \frac{h_j^{(\ell)} W^{(\ell)}}{\sqrt{\widetilde{d}_i \widetilde{d}_j}} \right).} \tag{9}$$

若有边权，则求和系数还要乘以 $\widetilde{A}_{ij}$。

通俗地说，节点 i 更新自己的表示时：

1. 收集自己和邻居的特征。
2. 用共享的 $W^{(\ell)}$ 转换这些特征。
3. 按图结构确定的系数加权求和。
4. 通过非线性函数生成新表示。

例如，判断一篇论文属于什么领域，可以参考它自己的内容，也参考与它相连的论文的内容。GCN 将这种利用关联信息的过程变成可训练的计算。若原始引用关系是有向的，而使用本文公式，需要先明确如何构造无向图。

最基本的 GCN 并不学习每条边的聚合权重。系数 $1/\sqrt{\widetilde{d}_i \widetilde{d}_j}$ 由图结构决定，学习的主要是 $W^{(\ell)}$。此外，由矩阵乘法结合律，

$$S(HW) = (SH)W. \tag{10}$$

所以可以先变换特征再聚合，也可以先聚合再变换；当中间没有插入非线性等额外操作时，两种顺序等价。

4 为什么需要自环、归一化、参数矩阵和非线性？

4.1 加自环：让节点也使用自己的信息

如果只使用 AH，节点的新表示只来自邻居。加入 I_n 后，它自己的特征也进入求和。孤立节点也能正常更新，因为其加自环后的度数为 1，逆平方根有定义。

不过，自环不保证原始特征完整保留：自己的信息仍会被缩放、变换并与邻居混合。自环与直接相加的残差连接是不同的操作。

4.2 对称归一化：调整传播尺度

直接相加时，拥有一百个邻居的节点通常比拥有两个邻居的节点累加更多信息。结果的大小可能主要反映邻居数量。GCN 使用

$$S_{ij} = \frac{\widetilde{A}_{ij}}{\sqrt{\widetilde{d}_i \widetilde{d}_j}} \tag{11}$$

调整传播强度。这个系数同时考虑接收节点 i 和发送节点 j 的连接数量；固定边权时，两端度数越大，单条边的系数越小。

两侧各使用一个逆平方根，使无向图的传播矩阵保持对称，并与对称归一化图拉普拉斯相对应。这是经典 GCN 的设计选择，不是唯一可能的归一化。

对称归一化一般不是普通的邻居平均。按行归一化的矩阵是

$$P_{\mathrm{rw}} = \widetilde{D}^{-1}\widetilde{A}, \tag{12}$$

其每行之和为 1，可以解释为邻居平均或随机游走的一步转移概率。式 (6) 的 S 一般不具有行和为 1 的性质。因此，说 GCN 做邻域平滑是合理的，说它严格做邻居算术平均则不准确。度数均相同等特殊情况下，两种归一化可以一致。

4.3 参数矩阵：学习任务需要的特征组合

图结构告诉网络哪些节点可以交换信息，却不能直接告诉它哪些信息有用。W 学习输入特征到输出特征的转换，并在所有节点上共享。例如，若输入是多个词语的频次，W 可以学习有助于辨别论文领域的词语组合。

4.4 非线性：增加表达能力

没有非线性时，两层计算变成

$$S(SXW^{(0)})W^{(1)} = S^2X\big(W^{(0)}W^{(1)}\big), \tag{13}$$

整体仍是线性变换。加入非线性后，网络可以表达更复杂的特征关系。不同图神经网络还可以使用注意力权重、不同聚合函数或其他自环处理方式。

5 一个可以手算的例子

考虑三个节点构成的路径 $1-2-3$，每个节点只有一个特征：

$$H = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}. \tag{14}$$

原始邻接矩阵与加自环后的邻接矩阵分别为

$$A = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}, \qquad \widetilde{A} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 1 \end{bmatrix}. \tag{15}$$

加自环后的度数为 $(2, 3, 2)$，所以

$$S = \begin{bmatrix} \frac{1}{2} & \frac{1}{\sqrt{6}} & 0 \\ \frac{1}{\sqrt{6}} & \frac{1}{3} & \frac{1}{\sqrt{6}} \\ 0 & \frac{1}{\sqrt{6}} & \frac{1}{2} \end{bmatrix}. \tag{16}$$

暂时取 $W = 1$，并令 $\sigma(z) = z$，只观察传播：

$$H' = SH = \begin{bmatrix} \frac{1}{2} + \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} + \frac{2}{3} + \frac{3}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} + \frac{3}{2} \end{bmatrix} \approx \begin{bmatrix} 1.3165 \\ 2.2997 \\ 2.3165 \end{bmatrix}. \tag{17}$$

例如，节点 1 的更新为

$$h_1' = \frac{1}{2} \times 1 + \frac{1}{\sqrt{6}} \times 2 \approx 1.3165. \tag{18}$$

它只使用自身和节点 2。节点 3 的特征要在下一层经由节点 2 才能影响节点 1。这说明**一层 GCN 使用一跳邻域，两层可以使用两跳邻域，更多层扩大可利用的图上范围**。

第一行的系数和为 $1/2 + 1/\sqrt{6} \approx 0.9082$，第二行的系数和为 $1/3 + 2/\sqrt{6} \approx 1.1498$，再次说明对称归一化不是严格的平均。

6 为什么可以称为卷积：频率域的数学联系

仅说“聚合邻居”，不足以解释卷积这个名称。更严格的联系来自普通卷积的**卷积定理**。先明确式中的两个对象：x 是待处理的输入信号，k 是卷积核（kernel），也称滤波器。若 $x = (x_0, \ldots, x_{n-1})$，则 x_i 是位置 i 上的信号值；$k = (k_0, \ldots, k_{m-1})$ 则规定输入信号在局部范围内如何加权组合。符号 $k * x$ 表示用卷积核 k 处理信号 x 后得到的输出信号，符号 $*$ 表示卷积运算，不表示普通乘法。例如，在一维离散情形下，忽略边界处理时，某个位置的输出可写成

$$(k * x)_i = \sum_r k_r x_{i-r}. \tag{19}$$

其中 k_r 是相对位置 r 的权重，x_{i-r} 是输入信号在对应位置的值。因此，k 决定“如何组合邻近信号”，x 是“被组合的信号”。在深度学习的互相关写法中常见 x_{i+r}；两者只差卷积核索引是否翻转。

对有限信号采用循环卷积时，卷积定理写为

$$\mathcal{F}(k * x) = \mathcal{F}(k)\,\mathcal{F}(x). \tag{20}$$

这里 $\mathcal{F}(x)$ 和 $\mathcal{F}(k)$ 分别是输入信号与卷积核的傅里叶变换；右侧的乘法是对应频率分量之间的逐元素乘法。也就是说，空间域中的卷积等价于：把信号 x 和卷积核 k 变换到频率域，用 $\mathcal{F}(k)$ 给 $\mathcal{F}(x)$ 的每个频率分量加权，再变换回来。$\mathcal{F}(k)$ 因而描述了卷积核对不同频率的响应。离散有限信号采用循环卷积时，可直接用离散傅里叶变换表达这一关系。

图没有普通坐标系，但可以通过**图拉普拉斯矩阵的特征向量**建立图上的频率表示。

6.1 图拉普拉斯与图频率

定义对称归一化拉普拉斯矩阵

$$L = I_n - D^{-1/2} A D^{-1/2}. \tag{21}$$

这里暂时使用加自环前的 A, D，并假设节点度数为正；孤立节点可以另行处理，最终 GCN 传播公式因加自环而不存在逆度数问题。由于 L 是实对称矩阵，它可分解为

$$L = U \Lambda U^{\top}, \qquad U^{\top} U = I_n. \tag{22}$$

U 的列是正交特征向量，Λ 的对角元素是特征值。这些特征向量构成图傅里叶基。

为什么它们可以表示频率？对于标量节点信号 x，

$$x^{\top} L x = \frac{1}{2} \sum_{i,j} A_{ij} \left(\frac{x_i}{\sqrt{d_i}} - \frac{x_j}{\sqrt{d_j}} \right)^2. \tag{23}$$

这个量衡量相连节点之间经过度数调整后的差异。对单位特征向量 u_k，有

$$u_k^{\top} L u_k = \lambda_k. \tag{24}$$

因此，小特征值对应沿边变化较缓的模式，大特征值对应变化较剧烈的模式，分别类似普通信号中的低频与高频。这里的平滑针对度数调整后的信号，并不总意味着原始数值处处相同。

6.2 谱图卷积的定义

图傅里叶变换及逆变换为

$$\widehat{x} = U^{\top} x, \qquad x = U \widehat{x}. \tag{25}$$

谱图卷积定义为

$$\boxed{g_\theta *_G x = U g_\theta(\Lambda) U^{\top} x,} \tag{26}$$

其中

$$g_\theta(\Lambda) = \operatorname{diag}\big(g_\theta(\lambda_1), \ldots, g_\theta(\lambda_n)\big). \tag{27}$$

该运算对第 k 个图频率乘以响应 $g_\theta(\lambda_k)$。它与普通卷积的频率域运算具有同样的结构：**变换、逐频率相乘、逆变换**。这是图卷积名称的数学基础。

不过，这是把经典频率滤波推广到图上的定义，并不要求一般图具有普通的平移操作。任意谱滤波器也不一定局部；局部性需要进一步限制滤波器形式。

7 谱图卷积如何变成经典 GCN 公式？

7.1 多项式近似带来局部性

直接计算整张图的特征分解通常代价较大。一种方法是用拉普拉斯矩阵的多项式近似滤波器，例如切比雪夫多项式：

$$g_\theta *_G x \approx \sum_{k=0}^{K} \theta_k T_k(\overline{L})x, \qquad \overline{L} = \frac{2}{\lambda_{\max}} L - I_n. \tag{28}$$

其中 $\lambda_{\max}$ 为 L 的最大特征值，缩放将其谱映射到 $[-1,1]$。前两项为 $T_0(z)=1$、$T_1(z)=z$。

多项式计算不需要显式求出 U。由于矩阵乘法沿边传播，K 次矩阵多项式最多涉及 K 跳范围的节点，因此可以实现局部滤波。

7.2 一阶近似与参数约束

取 $K=1$，得到

$$g_\theta *_G x \approx \theta_0 x + \theta_1 \overline{L} x. \tag{29}$$

归一化拉普拉斯的特征值位于 $[0,2]$。采用 $\lambda_{\max} \approx 2$ 的简化后，

$$\overline{L} \approx L - I_n = -D^{-1/2} A D^{-1/2}. \tag{30}$$

注意，最大特征值并不总恰好为 2，这里是简化而非一般恒等式。于是

$$g_\theta *_G x \approx \theta_0 x - \theta_1 D^{-1/2} A D^{-1/2} x. \tag{31}$$

进一步约束 $\theta_0 = \theta$、$\theta_1 = -\theta$，得到

$$g_\theta *_G x \approx \theta \left(I_n + D^{-1/2} A D^{-1/2} \right) x. \tag{32}$$

这里出现了自身信息加上一跳邻居信息。这些近似和参数约束减少了计算与参数，同时限制了可以表达的滤波器类型。所谓一阶近似，并不保证精确表示任意谱滤波器。

7.3 重归一化是设计上的替换

经典 GCN 使用重归一化技巧，将传播矩阵替换为

$$I_n + D^{-1/2} A D^{-1/2} \quad \longrightarrow \quad \widetilde{D}^{-1/2} (A + I_n) \widetilde{D}^{-1/2}. \tag{33}$$

这里是设计上的替换，不是恒等变形。加自环后重新计算了度数，因此两边通常不相等，自身信息的系数也改变了。

这样做有助于控制反复传播的尺度。$D^{-1/2}AD^{-1/2}$ 的特征值位于 $[-1,1]$，所以式 (31) 中的传播矩阵特征值可达到 2，反复应用可能放大某些方向。对于本文假设的非负边权无向图，重归一化后的对称矩阵 S 的特征值绝对值不超过 1，欧氏算子范数为 1。

这控制了图传播本身的放大效应，但不能保证包含可训练 W 的整个网络始终稳定。最后，将标量信号推广到多维节点特征，加入通道变换 W 与非线性 σ，就得到式 (2)。

因此，经典 GCN 同时具有两种解释：**在节点域，它是局部邻居聚合；从谱域来源看，它是经过简化和重归一化的图滤波**。对最终的 S，也可以定义加自环图的归一化拉普拉斯 $\widetilde{L} = I_n - S$，于是 $S = I_n - \widetilde{L}$ 是该图拉普拉斯的一阶多项式滤波器。

8 带权邻接矩阵：卷积如何进行？

前文的矩阵公式已经允许非负边权。本节将带权情形单独展开，说明边权如何进入聚合、度数如何计算，以及权重尺度对结果的影响。首先假设图是无向图，原图没有自环，且 $a_{ij} = A_{ij} \geq 0$、$a_{ij} = a_{ji}$。

8.1 边权的含义：强连接还是大距离？

无权图的邻接矩阵只表示两个节点是否相连；带权图还表示连接强度。若 a_{ij} 表示相似度，较大的数值通常意味着应加强这条边上的信息传播。但若原始数值表示距离或成本，越大反而可能意味着关系越弱，不能直接将其当作相似度使用。例如，可以将距离转为

$$a_{ij} = \exp\left(-\frac{\mathrm{dist}(i,j)^2}{2s^2}\right), \qquad s > 0. \tag{34}$$

s 控制距离衰减尺度；是否进一步截断为稀疏邻域，取决于建图方式。关键是先明确权重的语义：经典加权 GCN 使用非负权重来表示传播强度。

8.2 度数必须改为边权之和

允许自环权重为 $\alpha > 0$，定义

$$\widetilde{A} = A + \alpha I_n, \qquad \widetilde{d}_i = \sum_j \widetilde{A}_{ij} = \alpha + \sum_{j \in \mathcal{N}(i)} a_{ij}. \tag{35}$$

标准选择是 $\alpha = 1$。这里 $\widetilde{d}_i$ 是加权度数，也称节点强度。**它是边权之和，不是邻居数量**。原始邻居数为

$$|\mathcal{N}(i)| = \sum_{j \neq i} \mathbf{1}\{a_{ij} > 0\}, \tag{36}$$

只有边权都等于 1 时，边权之和才等于邻居数。

若原图已有自环，$A + \alpha I_n$ 表示在已有自环上额外增加 α，自身系数应按实际的 $\widetilde{A}_{ii}$ 计算，不能重复把已有自环忽略。

8.3 矩阵形式与节点形式

定义 $\widetilde{D}=\mathrm{diag}(\widetilde{d}_1,\dots,\widetilde{d}_n)$，加权 GCN 为

$$\boxed{H^{(\ell+1)}=\sigma\Big(\widetilde{D}^{-1/2}\widetilde{A}\widetilde{D}^{-1/2}H^{(\ell)}W^{(\ell)}\Big).} \tag{37}$$

它的外观与无权公式相同，但邻接矩阵的数值和度矩阵的数值都已改变。节点形式为

$$h_i^{(\ell+1)}=\sigma\Bigg(\frac{\alpha}{\widetilde{d}_i}h_i^{(\ell)}W^{(\ell)} + \sum_{j\in\mathcal{N}(i)}\frac{a_{ij}}{\sqrt{\widetilde{d}_i\widetilde{d}_j}}h_j^{(\ell)}W^{(\ell)}\Bigg). \tag{38}$$

通俗理解是：a_{ij} 表示连接强度；两端的加权度数调整传播尺度；W 学习特征如何转换。真正用于邻居聚合的系数为

$$c_{ij}=\frac{a_{ij}}{\sqrt{\widetilde{d}_i\widetilde{d}_j}}, \tag{39}$$

而不是原始边权 a_{ij}。修改一条边的权重还会改变两端的度数，因此会影响与两端相连的其他传播系数。最终的信息贡献则是 $c_{ij}h_jW$，还取决于节点特征和可训练变换。

边权与参数矩阵是两类不同的权重。边权 a_{ij} 控制节点之间的联系，W 控制特征通道之间的变换。基本 GCN 中，给定的边权通常是固定输入，不会自动因训练 W 而改变；若要学习边权，需要另行设计可训练建图或注意力机制。

8.4 完整的带权手算例子

三个节点构成路径 $1-2-3$，两条边的权重分别为 2 和 1：

$$A=\begin{bmatrix}0&2&0\\2&0&1\\0&1&0\end{bmatrix}. \tag{40}$$

取 $\alpha=1$，则

$$\widetilde{A}=\begin{bmatrix}1&2&0\\2&1&1\\0&1&1\end{bmatrix},\qquad \widetilde{D}=\mathrm{diag}(3,4,2). \tag{41}$$

例如，节点 2 的加权度数为 $2+1+1=4$，并非加自环后的邻居数量 3。归一化后，

$$S=\begin{bmatrix}\frac{1}{3}&\frac{2}{\sqrt{12}}&0\\ \frac{2}{\sqrt{12}}&\frac{1}{4}&\frac{1}{\sqrt{8}}\\ 0&\frac{1}{\sqrt{8}}&\frac{1}{2}\end{bmatrix}. \tag{42}$$

仍取 $H=[1,2,3]^\top$、$W=1$ 和 $\sigma(z)=z$，得到

$$H'=SH=\begin{bmatrix}\frac{1}{3}+\frac{4}{\sqrt{12}}\\ \frac{2}{\sqrt{12}}+\frac{1}{2}+\frac{3}{\sqrt{8}}\\ \frac{2}{\sqrt{8}}+\frac{3}{2}\end{bmatrix}\approx\begin{bmatrix}1.4880\\2.1380\\2.2071\end{bmatrix}. \tag{43}$$

对节点 2，

$$h_2' = \underbrace{\frac{2}{\sqrt{12}} \times 1}_{\text{节点 1 的信息}} + \underbrace{\frac{1}{4} \times 2}_{\text{自己的信息}} + \underbrace{\frac{1}{\sqrt{8}} \times 3}_{\text{节点 3 的信息}} . \tag{44}$$

节点 1 的系数约为 0.5774，节点 3 的系数约为 0.3536。前者的系数更大，但后者的特征值更大，所以节点 3 的数值贡献反而更大。**不能只看边权大小判断最终贡献**。

8.5 若希望严格做加权平均

可以采用按行归一化，而不是对称归一化：

$$P_{\text{rw}} = \widetilde{D}^{-1}\widetilde{A}, \qquad H' = \sigma(P_{\text{rw}}HW). \tag{45}$$

此时

$$h_i' = \sigma\left(\sum_j \frac{\widetilde{A}_{ij}}{\sum_k \widetilde{A}_{ik}} h_j W\right). \tag{46}$$

每行系数之和为 1，因此非线性之前是变换后特征的加权平均。上述例子中，节点 2 对三个节点的权重分别为 $2/4, 1/4, 1/4$，故

$$h_2' = \frac{2}{4} \times 1 + \frac{1}{4} \times 2 + \frac{1}{4} \times 3 = 1.75. \tag{47}$$

它与对称归一化的 2.1380 不同。两种都是图传播设计，但计算结果和解释不同，不能混用。

8.6 带权后为什么仍然是图卷积？

对于非负边权无向图，式 (20) 中的 A 可以直接使用带权邻接矩阵，$D_{ii} = \sum_j a_{ij}$。在度数为正的节点上，加权归一化拉普拉斯仍是实对称矩阵，仍可定义图傅里叶变换和谱滤波。其平滑性表达式为

$$x^\top Lx = \frac{1}{2}\sum_{i,j} a_{ij}\left(\frac{x_i}{\sqrt{d_i}} - \frac{x_j}{\sqrt{d_j}}\right)^2. \tag{48}$$

每条边上的差异项由 a_{ij} 加权。给定这些度数调整后的差异，较强的边在平滑性度量中占更大权重；实际修改边权时，度数也会同时变化。

谱图卷积 $Ug_\theta(\Lambda)U^\top x$、多项式近似和一阶近似仍然适用。加入自环并重新归一化后，式 (36) 就是加权图上的局部滤波。边权改变的是图上的传播强度和频率基，并没有使运算脱离图滤波框架。

8.7 边权尺度与自环权重的关系

若边权普遍很大，固定自环权重 $\alpha = 1$ 时，自身系数 $\alpha/\widetilde{d}_i$ 可能很小；若边权普遍很小，自身信息则可能占主导。因此，应关注边权与自环权重的相对尺度。

这个问题可以用整体缩放说明。若把包括自环在内的全部权重乘以 $c > 0$，则

$$(c\widetilde{D})^{-1/2}(c\widetilde{A})(c\widetilde{D})^{-1/2} = \widetilde{D}^{-1/2}\widetilde{A}\widetilde{D}^{-1/2}. \tag{49}$$

归一化传播不变。但若只将原始边权变成 cA，自环仍为 αI_n，通常会改变传播，因为邻居与自身的相对权重改变了。α 可作为超参数选择；它不是对所有数据都必须固定为 1 的数学要求。

8.8 有向边与负边权不能直接套用无向非负推导

有向图：若 $A_{ij} \neq A_{ji}$，矩阵乘法仍可执行，但必须明确传播方向。本文按 A_{ij} 表示节点 j 向节点 i 提供信息来解释 $(AH)_i = \sum_j A_{ij} h_j$。若数据将 A_{ij} 定义为从 i 到 j 的边，要聚合入边信息，通常需要使用转置或另行定义传播矩阵。入边、出边或双向聚合可采用不同设计；无向图的实对称特征分解和谱稳定性结论不能原样照搬。

负边权：若直接用带符号边权之和作为度数，可能出现零或负数，使实数逆平方根无定义；即使度数为正，非负图的谱界与加权平均解释也不再自动成立。正负关系通常需要符号图模型，例如分别构造正边、负边传播通道，或使用专门的符号拉普拉斯，不能简单视为本节非负边权公式的常规情形。

实现要点：先确认边权语义，再添加自环，用边权之和计算度数，完成归一化，最后进行特征聚合与变换。将二值邻接矩阵换成带权矩阵却继续使用邻居数量归一化，不是这里定义的标准加权 GCN。

9 它与图像卷积的相似之处和区别

二者都在局部范围组合信息、共享参数，并通过叠加层扩大感受野。但普通图像卷积可以分别学习左边和右边的权重；经典 GCN 中，所有邻居使用同一个特征变换 W，差异主要来自边权与度数归一化。它通常不学习方向相关的卷积核，因此在网格图上也不自动等同于任意二维 CNN 卷积。

图上没有一般意义的平移，但节点编号不应影响结果。GCN 满足**节点置换等变性**。若用置换矩阵 P 重新排列节点，则

$$H \mapsto PH, \qquad S \mapsto PSP^{\top}, \tag{50}$$

且

$$\sigma\Big((PSP^{\top})(PH)W\Big) = P\,\sigma(SHW). \tag{51}$$

即节点重新编号后，输出仅按相同方式重新排列。这保证网络依赖图结构和节点特征，而不是任意编号顺序。

局部性、权重共享与置换等变性解释了它与普通卷积在结构上的联系；谱滤波推导进一步解释了名称的数学来源。不过，仅具备邻居聚合的任意图算子，不一定都等价于拉普拉斯谱卷积。

10 为什么这种操作有用，什么时候会受限制？

许多任务中，相连节点的属性具有相关性。例如，同一研究领域的论文往往互相引用。图传播可以帮助节点借助邻居的信息进行判断，这也是经典 GCN 的平滑倾向常常有效的原因。

如果相邻节点经常属于不同类别，简单混合邻居特征则可能损害判别信息，需要更合适的传播或聚合设计。经典 GCN 对邻居采取共享变换，也限制了它对邻居角色、方向和差异的刻画能力。

10.1 层数不是越多越好：过平滑

忽略参数和非线性时，反复传播近似为

$$H^{(L)} = S^L X. \tag{52}$$

对于连通、带正自环的图，反复传播会抑制许多变化模式，使表示趋向主特征向量控制的形式。定义

$$q_i = \frac{\sqrt{\widetilde{d}_i}}{\sqrt{\sum_j \widetilde{d}_j}}, \tag{53}$$

则 $Sq = q$，并在上述条件下有

$$\lim_{L\to\infty} S^L = qq^\top. \tag{54}$$

因此，传播后的每个特征通道最终趋向同一个图结构方向。对于对称归一化，这个方向与 $\sqrt{\widetilde{d}_i}$ 有关，不一定是所有节点数值完全相等，但节点之间的可区分信息会明显减少。这是**过平滑**的基本机制。非连通图可在各连通分量内分别理解；实际网络的程度还受参数、非线性与残差连接等因素影响。

11 如何记住这条公式

可以抓住三个部分的分工：

$$\underbrace{\widetilde{D}^{-1/2}\widetilde{A}\widetilde{D}^{-1/2}}_{\text{决定节点之间如何传播}} \qquad \underbrace{H}_{\text{提供节点特征}} \qquad \underbrace{W}_{\text{学习特征如何转换}} . \tag{55}$$

图卷积利用图结构定义局部信息交换，利用共享参数学习特征变换。经典 GCN 的“卷积”名称，既体现局部滤波与参数共享，也具有从图傅里叶域滤波出发的数学来源。