工业数据智能入门指南

Introduction to Industrial Data Intelligence

张恺

2026 年 10 月 21 日

目录

第一部分　机器学习的基本语言与完整流程　1

第一章　数学与概率预备知识　3

1.1　向量、矩阵与基本运算 3
1.2　线性空间、秩、迹、逆与伪逆 5
1.3　正交投影与正定性 7
1.4　矩阵分解 9
1.5　微积分工具 13
1.6　概率空间、随机变量与分布 15
1.7　期望、方差与协方差 17
1.8　常用概率分布 19
1.9　全概率与贝叶斯公式 22
1.10　信息量与分布差异 23
1.11　期望与参数微分 24
1.12　指数族分布 25

第二章　机器学习究竟在学习什么　28

2.1　学习对象：数据、任务与模型 28
2.2　损失函数怎样规定训练目标 30
2.3　归纳偏置 33
2.4　任务的可学习性 36
2.5　从问题定义到模型计算 38

第三章 从一个简单模型开始：线性回归 40
3.1 先固定数据和任务 40
3.2 第一种视角：确定性判别模型 42
3.3 第二种视角：输出有分布，参数取一个确定值 51
3.4 第三种视角：参数也用分布表示 55
3.5 第四种视角：从核贝叶斯线性回归到高斯过程 59
3.6 把上一章的概念逐项放回例子 63

第四章 模型的求解 66
4.1 确定性参数模型：从目标到参数值 67
4.2 随机参数模型的求解 82
4.3 选择求解方法时应问的问题 92
4.4 本章小结 93

第五章 统计学习理论与模型选择 94
5.1 假设空间与泛化约束 94
5.2 模型选择、校准与不平衡 98
5.3 从统计结论到实验设置 102
5.4 从统计量到决策 104
5.5 本章小结 106

第二部分 贝叶斯机器学习：用概率表达知识与不确定性 107

第六章 概率图模型 109
6.1 从朴素贝叶斯理解有向图 110
6.2 从已知类别到单个隐变量：高斯混合模型 114
6.3 从单个隐变量到状态序列 116
6.4 从生成模型到局部条件模型：MEMM 125

6.5 无向图：分离、团分解与条件随机场 127
6.6 无向图中的隐变量：玻尔兹曼机与 RBM 136
6.7 用五个方面比较概率图模型 142

第七章 参数化与非参数化模型 151
7.1 两个概念 151
7.2 核方法、函数空间与计算边界 156

第三部分 深度学习模型 165

第八章 序列建模模型 167
8.1 先固定任务与可用的历史 168
8.2 RNN 与 LSTM：把历史逐步写入记忆 169
8.3 时间卷积网络：在固定范围内组合历史 173
8.4 Transformer：按内容重新读取历史 175
8.5 状态空间与 Mamba：选择性地保留长历史 182
8.6 把历史表示接到预测与异常任务 189
8.7 时序基础模型：先在大量序列上预训练 192
8.8 回到设备监测：怎样验证历史表示有用 195

第九章 视觉模型 198
9.1 先确定任务：类别、位置还是边界 198
9.2 图像分类：从局部卷积到 ResNet 200
9.3 ViT：用注意力联系不同图像区域 205
9.4 目标检测：以 Faster R-CNN 解释框级定位 209
9.5 图像分割：以 U-Net 解释像素级预测 215
9.6 少样本异常检测：用 DINOv2 特征比较正常图像块 220
9.7 回到质检任务：模型能解决什么，怎样验证 223

第十章 语言大模型 **226**
10.1 Token、表示与语言建模 227
10.2 预训练、对齐与推理 230
10.3 检索、工具与安全边界 238

第十一章 多模态模型 **244**
11.1 先确定任务：寻找匹配还是生成回答 244
11.2 CLIP：把图像和文本变成可比较的表示 246
11.3 BLIP-2：用少量查询连接视觉与语言 250
11.4 LLaVA：让视觉表示参与指令回答 255
11.5 典型应用怎样验证 259

第十二章 深度生成模型 **263**
12.1 生成任务与概率建模目标 263
12.2 VAE：用潜变量获得稳定采样 264
12.3 GAN：追求逼真样本的对抗训练 267
12.4 扩散模型：逐步去噪成为当前主线 268
12.5 任务选择与验证边界 270

第十三章 物理信息神经网络与风场重建 **272**
13.1 先用一个小例子理解 PINN 273
13.2 激光雷达给了我们什么数据 276
13.3 用流体方程描述风速怎样变化 278
13.4 把数据和方程放进同一次训练 281
13.5 论文案例：两束激光雷达怎样重建风机前方的风场 284
13.6 PINN 的优化方向 291

第四部分　从学习方式看数据智能场景 **301**

第十四章　预训练：构建可复用的数据表示 **303**

14.1 预训练学到了什么 304
14.2 监督预训练与重建式目标 306
14.3 对比学习：哪些样本应当接近 309
14.4 无负样本学习与表示坍缩 311
14.5 数据组织与领域继续预训练 314
14.6 工业振动信号的完整学习任务设置 315

第十五章　迁移学习 **318**

15.1 源域知识与目标域风险 319
15.2 实例重加权与分布对齐 320
15.3 预训练、微调与参数高效适配 325
15.4 测试时适配与负迁移 327

第十六章　持续学习 **330**

16.1 数据流、任务边界与遗忘 331
16.2 经验回放与梯度约束 332
16.3 参数重要性与知识蒸馏 336
16.4 参数隔离、扩展与混合策略 339
16.5 评价矩阵与工业更新规则 340

第十七章　主动学习 **343**

17.1 查询规则与标注预算 344
17.2 不确定性、委员会与贝叶斯查询 345
17.3 预期风险、梯度变化与多样性 348
17.4 成本、噪声与工业流式变体 352
17.5 算法流程与验收 354

第十八章　联邦学习 **356**

18.1 问题定义 356

18.2 联邦优化、隐私与系统约束 359

18.3 联邦诊断案例与验收 363

第十九章　流形学习 **371**

19.1 几何假设与邻域构造 371

19.2 线性基线与测地距离 373

19.3 局部重构与谱嵌入 376

19.4 概率邻域可视化 379

19.5 流形正则与工业验证 382

第二十章　元学习 **386**

20.1 任务分布与双层目标 386

20.2 度量与关系方法 389

20.3 梯度初始化与一阶变体 391

20.4 学习更新规则与概率适应 395

20.5 跨设备快速适应的完整设置 399

写在前面

本指南面向刚开始接触数据智能、机器学习或深度学习的读者。工业数据智能包括多类任务：预测设备故障或风功率，根据有限观测重建风场，通过缺失值填充恢复不完整数据，定位图像中的缺陷，以及根据手册和工单回答问题。本书以设备维护作为贯穿案例之一，同时结合这些任务介绍数据、模型、优化、推理和不确定性。公式用来说明计算怎样成立，例子用来说明结果会怎样影响现场判断。

先从一个不需要算法名称的问题开始

假设每台设备每小时记录一次温度和振动。现在是周一上午八点，值班人员想知道：从此刻起的二十四小时内，这台设备是否可能发生故障，以便决定是否安排复检。这里已经有三个不同的对象：温度和振动是**输入**，未来二十四小时内是否故障是**预测目标**，是否复检是人员或系统需要作出的**决策**。目标与决策有关，却不是同一件事：同样的故障概率，在复检便宜和复检昂贵时，可能对应不同的行动。

过去的记录可以帮助建立输入与目标之间的关系。例如，把每个历史预测时刻之前已经收到的温度和振动作为输入，等该时刻之后的二十四小时结束、故障记录确认后，再补上实际结果。这样一对输入和实际结果称为一个**带标签样本**。利用许多历史样本调整计算规则的过程叫**训练**；把调整好的规则用于当前输入、估计尚未知晓的目标，叫**预测**。实际运行模型得到输出，通常叫**推理**；不过在概率章节中，“推断”还可能指根据已知观测计算未知量的条件分布，需要按上下文区分。模型算出的是估计，不是提前观察到了未来事实。训练时可以使用后来确认的结果来学习，但当前

预测不能偷看未来。

本书中的**模型**就是这样一条可以计算的规则。例如，“温度超过某个值就告警”是一条规则；把温度和振动分别乘以一个系数、相加后再输出风险，也是一条规则。规则中需要从数据确定的系数叫**参数**。机器学习研究怎样根据数据选择或调整这些规则，并检验它们对没见过的数据是否仍然有效。深度学习是机器学习的一类方法，它用多层可调整的计算来形成表示，并不意味着可以跳过数据检查和结果验证。

当模型不仅给出一个数，还描述不同结果出现的可能性时，需要用到**概率分布**。例如，预测故障概率为 0.2，并不是说这台设备会发生“五分之一次故障”，也不是保证五台这样的设备恰好坏一台；它是一种需要用后续数据检验的风险表达。如何计算、解释和检验这样的概率，是本书第二部分的主题。

公式怎样读，读到什么程度再往下走

不要求读者在开篇就认识全部数学符号。第一章会逐一建立它们的含义；以后遇到公式，可以按“对象是什么、输入是什么、要计算什么、结果怎样使用”的顺序阅读。例如，$\hat{y} = f_\theta(x)$ 只是在压缩一句话：把输入 x 交给参数为 θ 的规则 f，得到预测 $\hat{y}$。字母上方的小帽子用来提醒我们，这是预测值，不是后来观测到的真实结果 y。参数下标 θ 说明规则可以随训练而改变，不表示再乘一次 θ。

除特别说明外，向量默认为列向量，即把几个数竖着排成一列；$\|\cdot\|_2$ 表示欧氏范数，可先理解为由勾股定理推广得到的长度；$\mathbb{E}$ 表示期望，即按照各结果的概率加权平均。它们的计算方法、适用条件和例子都在数学预备知识章中展开。第一次读到较长推导时，可以先保留“这段在解决什么问题”的主线，再回头逐步计算，不必把暂时不会推导误认为完全不懂这个任务。

设备维护案例联系了其中几类学习任务：根据运行记录预测未来二十

四小时内的故障，利用巡检图像定位缺陷，再结合有效手册和历史工单组织复检依据。这些任务共享设备、时间和证据来源，但并不共享同一种标签。预测未来二十四小时内是否故障，也不等于保证提前二十四小时告警。各章中的数值设置是教学设置，不代表已经完成的工业实验。阅读时应追问：观测在何时可用，目标如何定义，模型保留了什么结构，损失优化了什么，错误如何影响决策，以及系统需要采取什么动作。

因此，本书的章节不是按模型名称组成的目录。前两部分先说明学习什么、可以用哪些数据、错误有什么代价，以及结果有多不确定；第三部分分别处理按时间排列的读数、图像、文本、不同类型观测之间的联系，以及新数据的生成，再以风场重建说明物理方程如何参与学习；第四部分讨论旧设备上的经验怎样用于新设备、不同机构怎样共同训练，以及新任务只有少量样本时怎样适应。每次引入新模型时，都应把它放回明确的案例设定中，并与简单方法比较。“基线”就是这种用于比较的参考方法，例如始终预测历史平均值；它并不是故意设置的弱对手，而是检查复杂方法是否值得使用的起点。

贯穿全书的核心观点是：先把现场能看到的东西和要做的决定说清楚，再谈模型。传感器晚到五分钟，不能当成实时输入；拆机后才拍到的裂纹照片，不能拿来证明拆机前预警有效；一次误报会占用检修人员的时间，一次漏报可能损坏设备。数据、假设、损失、优化和验证，最终都要对这些具体后果负责。它们不是彼此独立的技术清单。例如，为什么常把“预测值减去真实值”之后的差再平方？这既与如何衡量偏差有关，也与我们怎样描述观测误差有关。又如，为什么训练时有时要惩罚过大的参数？这既可以限制规则对训练数据的过度迎合，也可以表达训练之前对参数的偏好。后文会把这些做法分别命名为平方损失、正则化和先验，并解释它们在什么条件下能够联系起来。这里先记住问题，不必提前记住术语。

阅读每章时，可以先沿着开篇的几个问题建立方向：上一章已经解决了什么，仍留下什么困难，本章通过增加哪一种假设或结构处理这个困难。进入推导后，应先确认随机变量与具体观测、待学习参数与已知常量的区

别，再检查矩阵维度和概率分布的条件。等式说明在给定假设下严格成立的关系，近似式通常意味着舍弃了某些项、引入了采样或限制了函数族；二者不能混为一谈。遇到较长推导，不必先记结论，可以用一个标量、两个样本或一维高斯分布重算一遍，再回到一般形式。

本书中的数学展开承担三项任务：从问题假设推出目标，从目标推出求解步骤，再从求解结果返回实际含义。因此，得到梯度或闭式解不是讨论的终点，还要追问解是否存在、是否唯一、算法是否能到达它，以及所需假设在工业数据中是否成立。章末的总结段落把这些结论重新放回相应的工业任务，并指出下一章需要改变的条件。读者可以据此区分已经得到证明的结论、依赖模型的解释和仍须通过实验检验的判断。

贯穿全书的参考书

除了各章末的辅助学习材料，下面三本书可以作为阅读整本指南时的常备参考。遇到推导看不懂、概念分不清的地方，可按问题查阅对应章节，不必先从头读完这些书再开始本指南。

- Marc Peter Deisenroth、A. Aldo Faisal、Cheng Soon Ong：*Mathematics for Machine Learning*。这本书适合补齐线性代数、解析几何、矩阵分解、向量微积分、概率与连续优化基础，并通过线性回归、主成分分析等方法说明这些数学工具如何使用。阅读本指南的数学基础和模型推导时，可用它核对矩阵运算、求导步骤及概率计算。作者维护的书籍网站提供公开电子版。

- Sergios Theodoridis：*Machine Learning: A Bayesian and Optimization Perspective*。这本书从贝叶斯推断和优化两个角度组织机器学习方法，适合进一步理解概率模型、参数估计、正则化、核方法与学习算法之间的联系。阅读本指南中的统计学习、贝叶斯建模和优化推导时，可对照查阅，重点看模型假设如何导出目标函数，以及目标函数如何决定求解方法。

- Ian Goodfellow、Yoshua Bengio、Aaron Courville：*Deep Learning*，即常说的“花书”。这本书系统介绍深度前馈网络、正则化、优化、卷积网络、序列模型以及概率与生成建模。阅读本指南的深度学习部分时，可用它补充基础原理和推导。官方书籍网站提供免费在线阅读。它适合打基础，但不涵盖后来的 Transformer、Mamba 和当前大语言模型训练方法；这些内容需结合相应章节的补充材料学习。

三本书的用途各有侧重：数学运算不熟时查第一本，想理清概率假设与优化目标的关系时查第二本，想系统学习神经网络原理时查第三本。本指南中的工业例子用于连接这些原理与具体任务，不替代对数据条件和模型假设的检查。

第一部分

机器学习的基本语言与完整流程

本部分先补齐后文要用的数学语言，再依次回答八个问题：公式里的向量和概率怎样读；机器学习究竟学什么；简单模型怎样计算；一次学习实验怎样组织；参数怎样一步步更新；为什么训练成绩不能代表新数据上的成绩；有限数据能支持多强的结论；原始记录怎样变成预测时刻确实可用的输入。这里的“泛化”指模型在未见数据上的表现，“优化”指按目标调整参数，“部署”指把训练好的系统放到实际流程中使用。读者应看到，机器学习不是一条训练命令，而是一个完整的流程：先明确问题，再选择模型，最后验证结果。

第一章　数学与概率预备知识

本章摘要。本章按知识依赖顺序建立数学与概率工具。先介绍向量、矩阵及其运算，再讨论秩、迹、逆、伪逆、正定性和矩阵分解。随后介绍微积分、概率空间、随机变量、条件分布、矩和常用分布，最后给出全概率公式、贝叶斯公式及指数族的性质。各项结论均注明所需条件。

1.1　向量、矩阵与基本运算

1.1.1　对象与记号

标量是单个数。本章除特别说明外使用实数，实数集合记为 $\mathbb{R}$。向量默认为列向量，写作 $\boldsymbol{x} = (x_1, \dots, x_d)^{\mathsf{T}} \in \mathbb{R}^d$。矩阵 $A = (A_{ij}) \in \mathbb{R}^{m \times d}$ 有 m 行、d 列，A_{ij} 是第 i 行第 j 列的元素。上标 T 表示转置，即 $(A^{\mathsf{T}})_{ji} = A_{ij}$，转置后矩阵的维度为 $d \times m$。

零向量与零矩阵分别记为 $\mathbf{0}$ 与 0，维度由上下文确定。$I_d \in \mathbb{R}^{d \times d}$ 表示单位矩阵。$\mathrm{diag}(a_1, \dots, a_d)$ 表示对角元素为 $a_1, \dots, a_d$、其余元素为零的对角矩阵。$\mathbb{1}\{B\}$ 是指示函数，命题 B 成立时为 1，否则为 0。本章的 $\log$ 均表示自然对数。

向量或矩阵只有在维度相同时才能逐元素相加。数乘将每个元素乘以同一个标量。若 $\boldsymbol{v}_j \in \mathbb{R}^d$、$a_j \in \mathbb{R}$，则 $\sum_{j=1}^{k} a_j \boldsymbol{v}_j \in \mathbb{R}^d$ 称为线性组合。

1.1.2　内积、范数与距离

实向量的欧氏内积与欧氏范数定义为

$$\langle \boldsymbol{x}, \boldsymbol{y} \rangle = \boldsymbol{x}^{\mathsf{T}} \boldsymbol{y} = \sum_{j=1}^{d} x_j y_j, \qquad \|\boldsymbol{x}\|_2 = \sqrt{\boldsymbol{x}^{\mathsf{T}} \boldsymbol{x}}. \tag{1.1}$$

这里 $\boldsymbol{x},\boldsymbol{y}\in\mathbb{R}^d$，内积是标量。内积为零称为正交。范数满足非负性、绝对齐次性和三角不等式，且仅零向量的范数为零。柯西–施瓦茨不等式（Cauchy–Schwarz inequality）为 $|\boldsymbol{x}^{\mathsf{T}}\boldsymbol{y}|\le\|\boldsymbol{x}\|_2\|\boldsymbol{y}\|_2$，等号成立当且仅当两向量线性相关。

对 $1\le p<\infty$ 定义 $\|\boldsymbol{x}\|_p=(\sum_j|x_j|^p)^{1/p}$，另定义 $\|\boldsymbol{x}\|_\infty=\max_j|x_j|$。相应距离为

$$d_1(x,y)=\|x-y\|_1=\sum_{j=1}^{d}|x_j-y_j|, \tag{1.2}$$

$$d_2(x,y)=\|x-y\|_2=\sqrt{\sum_{j=1}^{d}(x_j-y_j)^2}, \tag{1.3}$$

$$d_p(x,y)=\|x-y\|_p=\left(\sum_{j=1}^{d}|x_j-y_j|^p\right)^{1/p},\quad p\ge1, \tag{1.4}$$

$$d_\infty(x,y)=\|x-y\|_\infty=\max_j|x_j-y_j|. \tag{1.5}$$

这里沿用 $x,y\in\mathbb{R}^d$ 表示两个向量。四式分别称为曼哈顿距离（Manhattan distance）、欧氏距离（Euclidean distance）、闵可夫斯基距离（Minkowski distance）和切比雪夫距离（Chebyshev distance）。度量要求非负、对称、满足三角不等式，且距离为零当且仅当两对象相同。上述距离均为度量。$0<p<1$ 时同一幂和表达式一般不满足范数的三角不等式。

非零向量的余弦相似度（cosine similarity）与余弦距离（cosine distance）为

$$s_{\cos}(x,y)=\frac{x^{\mathsf{T}}y}{\|x\|_2\|y\|_2},\qquad d_{\cos}(x,y)=1-s_{\cos}(x,y),\quad x\neq0,\ y\neq0. \tag{1.6}$$

相似度等于夹角余弦，范围为 $[-1,1]$。余弦距离的范围为 $[0,2]$，但一般不是度量，正比例向量可有零距离，三角不等式也未必成立。对等长离散符号序列，汉明距离（Hamming distance）为

$$d_{\mathrm{H}}(x,y)=\sum_{j=1}^{d}\mathbb{1}\{x_j\neq y_j\}. \tag{1.7}$$

它计数不同坐标的位置，在固定长度的同一符号集合上满足度量条件。

1.1.3 矩阵乘法与线性变换

若 $A \in \mathbb{R}^{m\times d}$、$B \in \mathbb{R}^{d\times k}$，则

$$(AB)_{i\ell} = \sum_{j=1}^{d} A_{ij}B_{j\ell}, \qquad AB \in \mathbb{R}^{m\times k}. \tag{1.8}$$

相邻的两个维度必须相等。特别地，$A\boldsymbol{x} \in \mathbb{R}^m$ 且 $(A\boldsymbol{x})_i = \sum_j A_{ij}x_j$。映射 $\boldsymbol{x} \mapsto A\boldsymbol{x}$ 保持加法与数乘，称为线性变换。矩阵乘法满足结合律和分配律，一般不满足交换律。转置满足 $(AB)^{\mathsf{T}} = B^{\mathsf{T}}A^{\mathsf{T}}$。对 $\boldsymbol{x} \in \mathbb{R}^m$、$\boldsymbol{y} \in \mathbb{R}^d$，外积 $\boldsymbol{x}\boldsymbol{y}^{\mathsf{T}} \in \mathbb{R}^{m\times d}$ 的元素为 $x_i y_j$。

弗罗贝尼乌斯范数（Frobenius norm）与谱范数（spectral norm）定义为

$$\|A\|_{\mathrm{F}} = \left(\sum_{i,j} A_{ij}^2\right)^{1/2}, \qquad \|A\|_2 = \sup_{\|\boldsymbol{x}\|_2=1} \|A\boldsymbol{x}\|_2. \tag{1.9}$$

前者计入全部元素，后者度量单位输入向量的最大输出长度。维度相容时 $\|AB\|_2 \le \|A\|_2\|B\|_2$。

1.2 线性空间、秩、迹、逆与伪逆

1.2.1 线性无关与秩

向量组 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_k$ 线性无关，是指 $\sum_j a_j\boldsymbol{v}_j = \boldsymbol{0}$ 仅在全部 $a_j = 0$ 时成立。全部线性组合构成它们张成的空间。子空间的一组线性无关生成向量称为基，基中向量的个数称为维数。

对 $A \in \mathbb{R}^{m\times d}$，列空间与零空间为

$$\mathcal{C}(A) = \{A\boldsymbol{x} : \boldsymbol{x} \in \mathbb{R}^d\} \subseteq \mathbb{R}^m, \qquad \mathcal{N}(A) = \{\boldsymbol{x} \in \mathbb{R}^d : A\boldsymbol{x} = \boldsymbol{0}\} \subseteq \mathbb{R}^d. \tag{1.10}$$

列空间包含全部可能输出，零空间包含映射为零的输入。行空间为 $\mathcal{C}(A^{\mathsf{T}})$。秩（rank）定义为列空间的维数，满足

$$\operatorname{rank}(A) = \operatorname{rank}(A^{\mathsf{T}}), \qquad \operatorname{rank}(A) + \dim \mathcal{N}(A) = d. \tag{1.11}$$

第二式称为秩–零度定理。正交直和分解为 $\mathbb{R}^d = \mathcal{C}(A^{\mathsf{T}}) \oplus \mathcal{N}(A)$、$\mathbb{R}^m = \mathcal{C}(A) \oplus \mathcal{N}(A^{\mathsf{T}})$，其中 $\oplus$ 表示两子空间正交，且每个向量有唯一的分解。

秩不超过 $\min(m, d)$。秩为 d 称为满列秩，要求 $m \geq d$。秩为 m 称为满行秩，要求 $m \leq d$。维度相容时，

$$\operatorname{rank}(AB) \leq \min\{\operatorname{rank}(A), \operatorname{rank}(B)\}, \qquad \operatorname{rank}(A^{\mathsf{T}}A) = \operatorname{rank}(A). \tag{1.12}$$

后一结论来自 $\mathcal{N}(A^{\mathsf{T}}A) = \mathcal{N}(A)$：$A^{\mathsf{T}}A\boldsymbol{x} = \mathbf{0}$ 蕴含 $\|A\boldsymbol{x}\|_2^2 = 0$，反向蕴含直接成立。

1.2.2 迹与行列式

方阵 $A \in \mathbb{R}^{d\times d}$ 的迹（trace）为 $\operatorname{tr}(A) = \sum_j A_{jj}$。迹是标量，具有线性性质，且 $\operatorname{tr}(A^{\mathsf{T}}) = \operatorname{tr}(A)$。若 $A \in \mathbb{R}^{m\times d}$、$B \in \mathbb{R}^{d\times m}$，则

$$\operatorname{tr}(AB) = \sum_{i=1}^{m}\sum_{j=1}^{d} A_{ij}B_{ji} = \operatorname{tr}(BA). \tag{1.13}$$

循环移动可推广到多个因子，只要各乘积有定义且是方阵。一般不能任意交换因子。另有 $\|A\|_{\mathrm{F}}^2 = \operatorname{tr}(A^{\mathsf{T}}A)$。若 $B \in \mathbb{R}^{d\times d}$，则 $\boldsymbol{x}^{\mathsf{T}}B\boldsymbol{x} = \operatorname{tr}(B\boldsymbol{x}\boldsymbol{x}^{\mathsf{T}})$。

行列式（determinant）是关于方阵各列交替多线性的标量函数，由 $\det I_d = 1$ 确定。绝对值表示体积缩放因子，符号表示定向。同阶方阵满足 $\det(AB) = \det A \det B$、$\det(A^{\mathsf{T}}) = \det A$。三角矩阵的行列式为对角元素之积。$|A|$ 也表示行列式。

1.2.3 逆与线性方程组

若方阵 $A \in \mathbb{R}^{d\times d}$ 存在 A^{-1} 满足 $AA^{-1} = A^{-1}A = I_d$，则称为可逆，A^{-1} 是唯一的逆矩阵（inverse matrix）。可逆等价于 $\operatorname{rank}(A) = d$、$\mathcal{N}(A) = \{\mathbf{0}\}$、

$\det A \neq 0$，也等价于对每个 $\boldsymbol{b} \in \mathbb{R}^d$，$A\boldsymbol{x} = \boldsymbol{b}$ 恰有一个解。可逆同阶方阵满足

$$(AB)^{-1} = B^{-1}A^{-1}, \qquad (A^{\mathsf{T}})^{-1} = (A^{-1})^{\mathsf{T}}. \tag{1.14}$$

对一般 $A \in \mathbb{R}^{m\times d}$，方程有解当且仅当 $\boldsymbol{b} \in \mathcal{C}(A)$。若 $\boldsymbol{x}_0$ 为一个解，则全部解为 $\boldsymbol{x}_0 + \mathcal{N}(A)$。解存在时，唯一性等价于满列秩。矩形矩阵没有上述双侧逆，但满列秩矩阵有左逆，满行秩矩阵有右逆。

1.2.4 穆尔–彭罗斯伪逆

每个 $A \in \mathbb{R}^{m\times d}$ 均有唯一的穆尔–彭罗斯伪逆（Moore–Penrose pseudoinverse）$A^{+} \in \mathbb{R}^{d\times m}$，定义条件为

$$AA^{+}A = A, \qquad A^{+}AA^{+} = A^{+}, \tag{1.15}$$

$$(AA^{+})^{\mathsf{T}} = AA^{+}, \qquad (A^{+}A)^{\mathsf{T}} = A^{+}A. \tag{1.16}$$

可逆方阵的伪逆等于逆。满列秩时 $A^{+} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$，满行秩时 $A^{+} = A^{\mathsf{T}}(AA^{\mathsf{T}})^{-1}$。一般构造将在奇异值分解中给出。

AA^{+} 是到列空间的正交投影，$A^{+}A$ 是到行空间的正交投影。对任意 $\boldsymbol{b} \in \mathbb{R}^m$，$A^{+}\boldsymbol{b}$ 是使 $\|A\boldsymbol{x} - \boldsymbol{b}\|_2$ 最小的全部解中范数最小的唯一解。全部最小平方残差解为

$$\boldsymbol{x} = A^{+}\boldsymbol{b} + (I_d - A^{+}A)\boldsymbol{z}, \qquad \boldsymbol{z} \in \mathbb{R}^d. \tag{1.17}$$

其输出均为 $\boldsymbol{b}$ 到列空间的投影。第二项属于零空间，与行空间中的 $A^{+}\boldsymbol{b}$ 正交，加入非零第二项会增大解的范数。

1.3 正交投影与正定性

1.3.1 正交矩阵与投影

方阵 $U \in \mathbb{R}^{d\times d}$ 满足 $U^{\mathsf{T}}U = I_d$ 时称为正交矩阵（orthogonal matrix）。它也满足 $UU^{\mathsf{T}} = I_d$，故 $U^{-1} = U^{\mathsf{T}}$。正交变换保持内积与欧氏范数。

若 $U_r \in \mathbb{R}^{d\times r}$ 满足 $U_r^{\mathsf{T}}U_r = I_r$，其列为一个 r 维子空间的标准正交基。令 $P = U_rU_r^{\mathsf{T}}$，则

$$\boldsymbol{x} = P\boldsymbol{x} + (I_d - P)\boldsymbol{x}, \qquad \|\boldsymbol{x}\|_2^2 = \|P\boldsymbol{x}\|_2^2 + \|(I_d - P)\boldsymbol{x}\|_2^2. \tag{1.18}$$

两项分别位于该子空间及其正交补。$P = P^{\mathsf{T}}$、$P^2 = P$ 分别表达正交性与重复投影不改变结果。对称且幂等的实矩阵均为正交投影矩阵。

单位向量 $\boldsymbol{u}$ 张成的直线具有投影 $\boldsymbol{u}\boldsymbol{u}^{\mathsf{T}}\boldsymbol{x}$。其系数由

$$\frac{d}{da}\|\boldsymbol{x} - a\boldsymbol{u}\|_2^2 = -2\boldsymbol{u}^{\mathsf{T}}\boldsymbol{x} + 2a = 0 \tag{1.19}$$

确定。这里 $\|\boldsymbol{u}\|_2 = 1$、$a \in \mathbb{R}$，二阶导数为 2，故 $a = \boldsymbol{u}^{\mathsf{T}}\boldsymbol{x}$ 是唯一最小点。非单位的非零向量具有系数 $\boldsymbol{u}^{\mathsf{T}}\boldsymbol{x}/(\boldsymbol{u}^{\mathsf{T}}\boldsymbol{u})$。

1.3.2 二次型与正定矩阵

实方阵 $A \in \mathbb{R}^{d\times d}$ 满足 $A = A^{\mathsf{T}}$ 时称为对称矩阵（symmetric matrix）。本章对实对称矩阵定义正定性：

$$A \succeq 0 \iff \boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v} \geq 0 \quad \text{对所有}\boldsymbol{v} \in \mathbb{R}^d, \tag{1.20}$$

$$A \succ 0 \iff \boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v} > 0 \quad \text{对所有非零}\boldsymbol{v} \in \mathbb{R}^d. \tag{1.21}$$

第一种性质称为半正定（positive semidefinite，PSD），第二种称为正定（positive definite，PD）。标量 $\boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v}$ 称为二次型。负定与半负定分别由 $-A \succ 0$ 与 $-A \succeq 0$ 定义。二次型既取正值又取负值时称为不定。任意实方阵的二次型只取决于对称部分 $(A + A^{\mathsf{T}})/2$。

对称矩阵之间记 $A \succeq B$ 表示 $A - B \succeq 0$。半正定矩阵的非负系数线性组合仍半正定。若 $A \succeq 0$、$C \in \mathbb{R}^{d\times k}$，则 $C^{\mathsf{T}}AC \succeq 0$，因为对 $\boldsymbol{z} \in \mathbb{R}^k$ 有

$$\boldsymbol{z}^{\mathsf{T}}C^{\mathsf{T}}AC\boldsymbol{z} = (C\boldsymbol{z})^{\mathsf{T}}A(C\boldsymbol{z}) \geq 0. \tag{1.22}$$

若 $A \succ 0$，则 $C^{\mathsf{T}}AC$ 正定当且仅当 C 满列秩。任意 $B \in \mathbb{R}^{m\times d}$ 都有 $B^{\mathsf{T}}B \succeq 0$，且正定当且仅当 B 满列秩。

正定矩阵必可逆，逆矩阵也正定。半正定矩阵可能奇异，但任意 $\epsilon > 0$ 均使 $A + \epsilon I_d \succ 0$。西尔维斯特判据（Sylvester criterion）指出，对称矩阵正定等价于全部顺序主子式为正。顺序主子式是前 k 行、前 k 列形成方阵的行列式。半正定等价于全部主子式非负，主子式允许选取任意相同的行列指标，仅检查顺序主子式不足以判定半正定。

1.3.3 分块矩阵与舒尔补

设对称分块矩阵为

$$M = \begin{pmatrix} A & B \\ B^{\mathsf{T}} & C \end{pmatrix}, \qquad A \in \mathbb{R}^{d\times d},\ B \in \mathbb{R}^{d\times k},\ C \in \mathbb{R}^{k\times k}. \tag{1.23}$$

若 $A \succ 0$，则 $S = C - B^{\mathsf{T}} A^{-1} B$ 称为关于 A 的舒尔补（Schur complement）。配方给出

$$\begin{pmatrix} \boldsymbol{x} \\ \boldsymbol{y} \end{pmatrix}^{\mathsf{T}} M \begin{pmatrix} \boldsymbol{x} \\ \boldsymbol{y} \end{pmatrix} = (\boldsymbol{x} + A^{-1}B\boldsymbol{y})^{\mathsf{T}} A (\boldsymbol{x} + A^{-1}B\boldsymbol{y}) + \boldsymbol{y}^{\mathsf{T}} S \boldsymbol{y}. \tag{1.24}$$

这里 $\boldsymbol{x} \in \mathbb{R}^d$、$\boldsymbol{y} \in \mathbb{R}^k$。在 $A \succ 0$ 的前提下，$M \succ 0$ 等价于 $S \succ 0$，$M \succeq 0$ 等价于 $S \succeq 0$。

1.4 矩阵分解

矩阵分解将一个矩阵表示为结构较简单的矩阵的乘积。三角矩阵便于逐项解方程，正交矩阵保持欧氏长度，对角矩阵使各坐标的作用分离。各分解的存在条件不同。

1.4.1 LU 分解

下三角–上三角分解（Lower–Upper decomposition，LU 分解）写为 $A = LU$，其中 L 为单位下三角矩阵，U 为上三角矩阵。非奇异方阵 $A \in \mathbb{R}^{d\times d}$ 的全部顺序主子式非零时，这样的分解存在且唯一。

一般非奇异方阵需要允许交换行，形式为

$$PA = LU, \qquad P, L, U \in \mathbb{R}^{d\times d}. \tag{1.25}$$

P 为置换矩阵，满足 $P^{-1} = P^{\mathsf{T}}$。通过选择非零主元，任意非奇异方阵均有这一分解。求解 $A\boldsymbol{x} = \boldsymbol{b}$ 可依次解 $L\boldsymbol{z} = P\boldsymbol{b}$、$U\boldsymbol{x} = \boldsymbol{z}$，分别从首行向末行、从末行向首行代入。选主元有助于控制舍入误差，但不能消除方程对扰动的敏感性。

1.4.2 QR 分解

正交–三角分解（Orthogonal–Triangular decomposition，QR 分解）对任意 $A \in \mathbb{R}^{m\times d}$ 存在：

$$A = QR, \qquad Q \in \mathbb{R}^{m\times m}, \quad Q^{\mathsf{T}}Q = I_m, \quad R \in \mathbb{R}^{m\times d}. \tag{1.26}$$

R 为上梯形矩阵，即 $i > j$ 时 $R_{ij} = 0$。当 $m \geq d$ 时，可取简化形式 $A = Q_1 R_1$，其中 $Q_1 \in \mathbb{R}^{m\times d}$、$Q_1^{\mathsf{T}}Q_1 = I_d$、$R_1 \in \mathbb{R}^{d\times d}$ 为上三角矩阵。A 满列秩且规定 R_1 对角元素为正时，简化分解唯一。

正交分解给出

$$\|A\boldsymbol{x} - \boldsymbol{b}\|_2^2 = \|R_1\boldsymbol{x} - Q_1^{\mathsf{T}}\boldsymbol{b}\|_2^2 + \|(I_m - Q_1Q_1^{\mathsf{T}})\boldsymbol{b}\|_2^2. \tag{1.27}$$

这里 $\boldsymbol{x} \in \mathbb{R}^d$、$\boldsymbol{b} \in \mathbb{R}^m$。满列秩时，最小平方残差解由 $R_1\boldsymbol{x} = Q_1^{\mathsf{T}}\boldsymbol{b}$ 唯一确定。秩不足时 R_1 奇异，不能使用唯一解结论。豪斯霍尔德反射（Householder reflection）和吉文斯旋转（Givens rotation）可通过正交变换构造 QR 分解。

1.4.3 特征分解

若 $A \in \mathbb{R}^{d\times d}$ 与非零向量 $\boldsymbol{u}$ 满足 $A\boldsymbol{u} = \lambda\boldsymbol{u}$，则 λ 称为特征值（eigenvalue），$\boldsymbol{u}$ 称为特征向量（eigenvector）。特征值是 $\det(A - \lambda I_d) = 0$ 的根，一般实矩阵可能有复特征值。

在所讨论数域上，A 有 d 个线性无关的特征向量时称为可对角化，此时

$$A = V\Lambda V^{-1}, \qquad \Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_d). \tag{1.28}$$

V 的列为特征向量。一般方阵未必可对角化。不同特征值的特征向量线性无关，因此 d 个互异特征值足以保证可对角化。

实对称矩阵的谱定理（spectral theorem）保证特征值为实数，且

$$A = U\Lambda U^{\mathsf{T}}, \qquad U^{\mathsf{T}}U = I_d. \tag{1.29}$$

由 $\boldsymbol{v} = U\boldsymbol{z}$ 得到 $\boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v} = \sum_j \lambda_j z_j^2$。所以半正定等价于全部特征值非负，正定等价于全部特征值为正。另有

$$\operatorname{tr}(A) = \sum_j \lambda_j, \qquad \det A = \prod_j \lambda_j, \qquad \lambda_{\min} \le \frac{\boldsymbol{v}^{\mathsf{T}}A\boldsymbol{v}}{\boldsymbol{v}^{\mathsf{T}}\boldsymbol{v}} \le \lambda_{\max}. \tag{1.30}$$

最后一式要求 $\boldsymbol{v} \neq \mathbf{0}$，比值称为瑞利商（Rayleigh quotient），端点由对应特征向量达到。一般方阵的迹与行列式仍等于特征值之和与之积，按代数重数计入。

半正定矩阵有唯一的对称半正定平方根 $A^{1/2} = U\operatorname{diag}(\sqrt{\lambda_j})U^{\mathsf{T}}$。正定时还可定义 $A^{-1/2} = U\operatorname{diag}(\lambda_j^{-1/2})U^{\mathsf{T}}$。重特征值空间内的标准正交基不唯一，但这些矩阵函数不依赖基的选择。

1.4.4 奇异值分解

奇异值分解（Singular Value Decomposition，SVD）对任意 $A \in \mathbb{R}^{m\times d}$ 存在：

$$A = U\Sigma V^{\mathsf{T}}, \qquad U \in \mathbb{R}^{m\times m}, \quad V \in \mathbb{R}^{d\times d}, \quad \Sigma \in \mathbb{R}^{m\times d}. \tag{1.31}$$

U, V 均正交。令 $q = \min(m, d)$，Σ 只在 (j, j) 位置可能非零，且 $\sigma_1 \ge \cdots \ge \sigma_q \ge 0$，称为奇异值（singular values）。此处 Σ 为奇异值矩阵，概率部分的同一字母表示协方差矩阵，须按所在公式区分。

若 $r = \operatorname{rank}(A)$，则恰有 r 个正奇异值。取相应列组成 $U_r \in \mathbb{R}^{m\times r}$、$V_r \in \mathbb{R}^{d\times r}$，得到

$$A = U_r \operatorname{diag}(\sigma_1, \dots, \sigma_r) V_r^{\mathsf{T}}, \tag{1.32}$$

$$A^{+} = V_r \operatorname{diag}(\sigma_1^{-1}, \dots, \sigma_r^{-1}) U_r^{\mathsf{T}}. \tag{1.33}$$

零矩阵的伪逆为零。也可写 $A^{+} = V\Sigma^{+}U^{\mathsf{T}}$，$\Sigma^{+} \in \mathbb{R}^{d\times m}$ 将正奇异值取倒数，将零奇异值保持为零。

因为 $A^{\mathsf{T}}A = V\Sigma^{\mathsf{T}}\Sigma V^{\mathsf{T}}$，其非零特征值为 σ_j^2，且 $\|A\|_2 = \sigma_1$、$\|A\|_{\mathrm{F}}^2 = \sum_j \sigma_j^2$。对 $0 \le k < r$，截断矩阵 $A_k = \sum_{j=1}^{k} \sigma_j \boldsymbol{u}_j \boldsymbol{v}_j^{\mathsf{T}}$ 的秩至多为 k，满足低秩近似定理：

$$\min_{\operatorname{rank}(B)\le k} \|A - B\|_2 = \sigma_{k+1}, \qquad \min_{\operatorname{rank}(B)\le k} \|A - B\|_{\mathrm{F}}^2 = \sum_{j=k+1}^{q} \sigma_j^2. \tag{1.34}$$

A_k 达到这两个最小值。把正的小奇异值置零会改变矩阵及其伪逆，所得矩阵一般不是原矩阵的精确伪逆。

1.4.5 Cholesky 与对称分解

实对称正定矩阵 $A \in \mathbb{R}^{d\times d}$ 具有唯一的乔列斯基分解（Cholesky decomposition）$A = LL^{\mathsf{T}}$，其中 L 是对角元素严格为正的下三角矩阵。反过来，可逆下三角矩阵 L 使 LL^{T} 正定。解方程可依次解 $L\boldsymbol{z} = \boldsymbol{b}$ 与 $L^{\mathsf{T}}\boldsymbol{x} = \boldsymbol{z}$。同时 $\det A = \prod_j L_{jj}^2$，故 $\log\det A = 2\sum_j \log L_{jj}$。

半正定矩阵可写为 BB^{T}，但 B 可能秩不足，不能要求严格正对角元素的 Cholesky 因子。对称不定矩阵可使用带对称置换的 $PAP^{\mathsf{T}} = LDL^{\mathsf{T}}$，其中 L 为单位下三角矩阵，D 为具有 1×1 或 2×2 对角块的对称分块对角矩阵。允许 2×2 块可处理无法使用标量主元的情形。

1.4.6 条件数与投影恒等式

可逆方阵的二范数条件数（condition number）为

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)} \geq 1. \tag{1.35}$$

若 $A\boldsymbol{x} = \boldsymbol{b}$ 且只扰动右端，$\delta\boldsymbol{x} = A^{-1}\delta\boldsymbol{b}$。当 $\boldsymbol{b} \neq \boldsymbol{0}$ 时，

$$\frac{\|\delta\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2} \leq \kappa_2(A) \frac{\|\delta\boldsymbol{b}\|_2}{\|\boldsymbol{b}\|_2}. \tag{1.36}$$

可逆性保证解唯一，条件数描述对扰动的敏感性。条件数很大时称为病态。满列秩矩形矩阵也可定义 $\kappa_2(A) = \sigma_1/\sigma_d$，此时 $\kappa_2(A^{\mathsf{T}}A) = \kappa_2(A)^2$。数学秩以严格为零为准，数值秩还需给定尺度和容差。

设 $\boldsymbol{z}_i \in \mathbb{R}^d$、$S = n^{-1}\sum_{i=1}^{n} \boldsymbol{z}_i \boldsymbol{z}_i^{\mathsf{T}}$、$n \geq 1$，且 $U_r^{\mathsf{T}} U_r = I_r$。由正交分解与迹的性质，

$$\frac{1}{n}\sum_{i} \|\boldsymbol{z}_i - U_r U_r^{\mathsf{T}} \boldsymbol{z}_i\|_2^2 = \frac{1}{n}\sum_{i} (\|\boldsymbol{z}_i\|_2^2 - \|U_r^{\mathsf{T}}\boldsymbol{z}_i\|_2^2) \tag{1.37}$$

$$= \operatorname{tr}(S) - \operatorname{tr}(U_r^{\mathsf{T}} S U_r). \tag{1.38}$$

这里 $S \in \mathbb{R}^{d\times d}$ 半正定，不要求 $\boldsymbol{z}_i$ 来自随机抽样。若 S 的特征值按 $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$ 排列，则在全部 r 维子空间上，右端最小值为 $\sum_{j>r}\lambda_j$。在特征基中，保留的迹为 $\sum_j \lambda_j w_j$，其中 $0 \leq w_j \leq 1$、$\sum_j w_j = r$，将权重配置给最大的 r 个特征值即可达到最大值。重根可能使最优子空间不唯一。

1.5 微积分工具

1.5.1 导数、全微分与链式法则

函数 f 在 x 的导数为 $f'(x) = \lim_{h\to 0}[f(x+h) - f(x)]/h$，前提是极限存在。对 $f : \mathbb{R}^d \to \mathbb{R}$，偏导数只沿一个坐标方向取极限。各偏导数存在并不自动保证全微分存在。若存在 $\boldsymbol{g} \in \mathbb{R}^d$ 使

$$f(\boldsymbol{x} + \boldsymbol{h}) = f(\boldsymbol{x}) + \boldsymbol{g}^{\mathsf{T}}\boldsymbol{h} + o(\|\boldsymbol{h}\|_2), \tag{1.39}$$

则 f 在 $\boldsymbol{x}$ 可微。$\boldsymbol{g}=\nabla f(\boldsymbol{x})$ 称为梯度（gradient），分量为各偏导数。小量 $o(\|\boldsymbol{h}\|_2)$ 除以 $\|\boldsymbol{h}\|_2$ 后趋于零。偏导数在邻域内连续是可微的充分条件。

对 $\boldsymbol{f}:\mathbb{R}^d\to\mathbb{R}^m$，雅可比矩阵（Jacobian matrix）为 $D\boldsymbol{f}=(\partial f_i/\partial x_j)_{i,j}\in\mathbb{R}^{m\times d}$。可微时，$\boldsymbol{f}(\boldsymbol{x}+\boldsymbol{h})=\boldsymbol{f}(\boldsymbol{x})+D\boldsymbol{f}(\boldsymbol{x})\boldsymbol{h}+o(\|\boldsymbol{h}\|_2)$。若 $\boldsymbol{g}:\mathbb{R}^m\to\mathbb{R}^k$ 也可微，链式法则（chain rule）给出

$$D(\boldsymbol{g}\circ\boldsymbol{f})(\boldsymbol{x})=D\boldsymbol{g}(\boldsymbol{f}(\boldsymbol{x}))D\boldsymbol{f}(\boldsymbol{x})\in\mathbb{R}^{k\times d}. \tag{1.40}$$

当 g 为标量函数时，$\nabla(g\circ\boldsymbol{f})=(D\boldsymbol{f})^{\mathsf{T}}\nabla g\in\mathbb{R}^d$。

1.5.2 二阶导数与泰勒展开

海森矩阵（Hessian matrix）为 $H_f=(\partial^2 f/\partial x_i\partial x_j)_{i,j}\in\mathbb{R}^{d\times d}$。若二阶偏导数在邻域内连续，混合偏导数可交换，$H_f$ 对称，且二阶泰勒展开（Taylor expansion）为

$$f(\boldsymbol{x}+\boldsymbol{h})=f(\boldsymbol{x})+\nabla f(\boldsymbol{x})^{\mathsf{T}}\boldsymbol{h}+\frac{1}{2}\boldsymbol{h}^{\mathsf{T}}H_f(\boldsymbol{x})\boldsymbol{h}+o(\|\boldsymbol{h}\|_2^2). \tag{1.41}$$

可微函数沿方向 $\boldsymbol{v}$ 的方向导数为 $\nabla f^{\mathsf{T}}\boldsymbol{v}$。梯度非零时，柯西–施瓦茨不等式说明单位方向中的最小方向导数为 $-\|\nabla f\|_2$，由负梯度的单位方向取得。这保证足够小的正位移使函数下降。

定义域内部的可微局部极小点必须满足 $\nabla f=\boldsymbol{0}$。二阶连续可微时，该点还必须满足 $H_f\succeq 0$。若驻点满足 $H_f\succ 0$，则为严格局部极小点。仅半正定不足以判定极小点。

1.5.3 矩阵微分

对固定 $A\in\mathbb{R}^{d\times d}$、$\boldsymbol{b}\in\mathbb{R}^d$，

$$\nabla_{\boldsymbol{x}}(\boldsymbol{b}^{\mathsf{T}}\boldsymbol{x})=\boldsymbol{b},\qquad \nabla_{\boldsymbol{x}}(\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x})=(A+A^{\mathsf{T}})\boldsymbol{x}. \tag{1.42}$$

第二式由 $d(\boldsymbol{x}^{\mathsf{T}}A\boldsymbol{x})=(d\boldsymbol{x})^{\mathsf{T}}A\boldsymbol{x}+\boldsymbol{x}^{\mathsf{T}}A\,d\boldsymbol{x}$ 得到。A 对称时梯度为 $2A\boldsymbol{x}$。

对固定 $A\in\mathbb{R}^{m\times d}$、$\boldsymbol{b}\in\mathbb{R}^m$，$F(\boldsymbol{x})=\tfrac12\|A\boldsymbol{x}-\boldsymbol{b}\|_2^2$ 满足

$$dF=(A\boldsymbol{x}-\boldsymbol{b})^{\mathsf T}A\,d\boldsymbol{x},\quad \nabla F=A^{\mathsf T}(A\boldsymbol{x}-\boldsymbol{b}),\quad H_F=A^{\mathsf T}A. \tag{1.43}$$

梯度为 d 维，海森矩阵为 $d\times d$ 且半正定。

对可微变化的可逆方阵，

$$d(A^{-1})=-A^{-1}(dA)A^{-1},\qquad d\log|\det A|=\operatorname{tr}(A^{-1}dA). \tag{1.44}$$

第一式由 $d(AA^{-1})=0$ 推得，第二式在可逆矩阵邻域内成立。正定时可写 $\log\det A$。对矩阵函数 $F(A)$，可由 $dF=\operatorname{tr}((\nabla_A F)^{\mathsf T}dA)$ 定义同维度的矩阵梯度。

1.5.4 积分与变量替换

若 f 连续且 $F'=f$，微积分基本定理给出 $\int_a^b f(x)\,dx=F(b)-F(a)$。若 u,v 连续可微，分部积分为 $\int_a^b uv'\,dx=[uv]_a^b-\int_a^b u'v\,dx$。

若 $\boldsymbol{x}=\boldsymbol{g}(\boldsymbol{z})$ 为开集之间一一、连续可微且逆也连续可微的变换，则

$$\int_{\mathcal{X}} f(\boldsymbol{x})\,d\boldsymbol{x}=\int_{\mathcal{Z}} f(\boldsymbol{g}(\boldsymbol{z}))\,|\det D\boldsymbol{g}(\boldsymbol{z})|\,d\boldsymbol{z}. \tag{1.45}$$

这里 $\mathcal{X},\mathcal{Z}\subseteq\mathbb{R}^d$，雅可比矩阵为 $d\times d$，要求 f 非负或绝对可积。行列式绝对值是体积因子。非负函数可交换积分次序，这是托内利定理（Tonelli theorem）。绝对可积函数也可交换次序，这是富比尼定理（Fubini theorem）。缺少这些条件时，不能任意交换积分或求和次序。

1.6 概率空间、随机变量与分布

1.6.1 事件与概率

概率空间（probability space）是三元组 $(\Omega,\mathcal{F},P)$。Ω 为所有可能结果组成的样本空间。$\mathcal{F}$ 为事件组成的 σ 代数，包含 Ω，对补集与可数并封闭。

概率测度 P 定义在 $\mathcal{F}$ 上，满足

$$P(A)\ge 0,\qquad P(\Omega)=1,\qquad P\left(\bigcup_{i=1}^{\infty}A_i\right)=\sum_{i=1}^{\infty}P(A_i) \tag{1.46}$$

最后一式要求 A_i 两两不交。公理蕴含 $P(\varnothing)=0$、$P(A^{\mathrm{c}})=1-P(A)$ 及 $P(A\cup B)=P(A)+P(B)-P(A\cap B)$。

若 $P(B)>0$，条件概率（conditional probability）定义为 $P(A\mid B)=P(A\cap B)/P(B)$。它在 B 内重新归一化。事件 A,B 独立（independent）是指 $P(A\cap B)=P(A)P(B)$。相互独立要求任意有限子集的交事件概率等于相应概率之积，比两两独立更强。

1.6.2 随机变量与分布函数

随机变量（random variable）是可测映射 $X:\Omega\to\mathbb{R}$，即对每个实数 t 都有 $\{X\le t\}\in\mathcal{F}$。分布由 $P_X(B)=P(X\in B)$ 确定，B 为实数上的可测集合。大写 X 表示随机变量，小写 x 表示可能取值。分布函数（cumulative distribution function，CDF）为 $F_X(t)=P(X\le t)$，它单调不减、右连续，在 $t\to-\infty$ 与 $t\to+\infty$ 时分别趋于 0 与 1。区间概率为 $P(a<X\le b)=F_X(b)-F_X(a)$。

离散随机变量的取值至多可数，概率质量函数（probability mass function，PMF）为 $p_X(x)=P(X=x)$，满足 $p_X(x)\ge 0$ 与 $\sum_x p_X(x)=1$。分布相对于勒贝格测度绝对连续时，存在概率密度函数（probability density function，PDF），满足

$$P(X\in B)=\int_B p_X(x)\,dx,\qquad p_X(x)\ge 0,\qquad \int_{\mathbb{R}}p_X(x)\,dx=1. \tag{1.47}$$

这时 $F_X(t)=\int_{-\infty}^{t}p_X(x)\,dx$，几乎处处有 $F_X'=p_X$。密度可大于 1，但单点概率为零。密度量纲是变量量纲的倒数，积分后概率无量纲。一般分布可能有离散或奇异连续部分，不能假定每个分布都有普通密度。

随机向量 $\boldsymbol{X}=(X_1,\dots,X_d)^{\mathsf{T}}$ 是到 $\mathbb{R}^d$ 的可测映射。多维密度相对于 d 维勒贝格测度定义，积分覆盖全部坐标。

1.6.3 联合、边缘、条件与独立

联合分布（joint distribution）描述共同取值。有联合密度 $p(x,y)$ 时，边缘密度（marginal density）为 $p_X(x)=\int p(x,y)\,dy$。离散变量使用求和。无歧义时用 $p(x)$ 代替 $p_X(x)$。

在 $p(x)>0$ 处，条件密度或条件质量函数满足

$$p(x,y)=p(y\mid x)p(x),\qquad p(y\mid x)=\frac{p(x,y)}{p(x)}. \tag{1.48}$$

条件分布在 y 上归一化。连续情形不能将其写成两个单点概率相除。条件分布仅需在 X 的分布下几乎处处定义，$p(x)=0$ 处不由比值确定。多变量链式法则为 $p(x_1,\dots,x_d)=p(x_1)\prod_{j=2}^{d}p(x_j\mid x_1,\dots,x_{j-1})$，在条件分布有定义处使用。

X,Y 独立，是指任意可测集合 B,C 满足 $P(X\in B,Y\in C)=P(X\in B)P(Y\in C)$。有联合密度时，等价于 $p(x,y)=p(x)p(y)$ 几乎处处成立。给定 Z 时条件独立（conditional independence）记为 $X\perp Y\mid Z$，密度形式为

$$p(x,y\mid z)=p(x\mid z)p(y\mid z) \tag{1.49}$$

对 Z 的分布下几乎所有 z 成立。独立与条件独立一般不能互相推出。

1.7 期望、方差与协方差

1.7.1 期望与矩

若 $\mathbb{E}|g(X)|<\infty$，期望（expectation）为

$$\mathbb{E}[g(X)]=\sum_{x}g(x)p_X(x)\quad\text{或}\quad\mathbb{E}[g(X)]=\int g(x)p_X(x)\,dx. \tag{1.50}$$

前式针对离散分布，后式针对有密度的分布。一般定义是对分布测度积分。非负函数允许期望为 $+\infty$，但正负部分均为无穷时不能定义为它们的差。均

值为 $\mu=\mathbb{E}X$，k 阶原点矩为 $\mathbb{E}[X^k]$，中心矩为 $\mathbb{E}[(X-\mu)^k]$，均需检查存在条件。

期望具有线性性质，不要求变量独立。若 X,Y 独立且绝对可积，则 $\mathbb{E}[XY]=\mathbb{E}X\mathbb{E}Y$。对凸函数 ϕ，若 X 与 $\phi(X)$ 可积，詹森不等式（Jensen inequality）为 $\phi(\mathbb{E}X)\le\mathbb{E}[\phi(X)]$。

1.7.2 方差与协方差

若 $\mathbb{E}[X^2]<\infty$，方差（variance）与标准差（standard deviation）为

$$\operatorname{Var}(X)=\mathbb{E}[(X-\mu)^2]=\mathbb{E}[X^2]-\mu^2,\qquad \operatorname{sd}(X)=\sqrt{\operatorname{Var}(X)}. \tag{1.51}$$

方差非负，且为零当且仅当 $X=\mu$ 几乎必然成立。方差量纲为 X 量纲的平方，标准差与 X 同量纲。常数 a,b 满足 $\operatorname{Var}(aX+b)=a^2\operatorname{Var}(X)$。

若 X,Y 有有限二阶矩，协方差（covariance）为

$$\operatorname{Cov}(X,Y)=\mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)], \tag{1.52}$$

$$\operatorname{Var}(X+Y)=\operatorname{Var}(X)+\operatorname{Var}(Y)+2\operatorname{Cov}(X,Y). \tag{1.53}$$

独立蕴含协方差为零，反向结论一般不成立。两方差均为正时，相关系数（correlation coefficient）为 $\rho_{XY}=\operatorname{Cov}(X,Y)/(\operatorname{sd}(X)\operatorname{sd}(Y))\in[-1,1]$，它无量纲。任一方差为零时，相关系数无定义。

有有限二阶矩的 $\boldsymbol{X}\in\mathbb{R}^d$ 具有均值 $\boldsymbol{\mu}=\mathbb{E}\boldsymbol{X}$ 及协方差矩阵 $\Sigma=\mathbb{E}[(\boldsymbol{X}-\boldsymbol{\mu})(\boldsymbol{X}-\boldsymbol{\mu})^{\mathsf{T}}]\in\mathbb{R}^{d\times d}$。第 (i,j) 个元素为 $\operatorname{Cov}(X_i,X_j)$，且

$$\boldsymbol{v}^{\mathsf{T}}\Sigma\boldsymbol{v}=\mathbb{E}[(\boldsymbol{v}^{\mathsf{T}}(\boldsymbol{X}-\boldsymbol{\mu}))^2]=\operatorname{Var}(\boldsymbol{v}^{\mathsf{T}}\boldsymbol{X})\ge 0. \tag{1.54}$$

此式对任意 $\boldsymbol{v}\in\mathbb{R}^d$ 成立，证明 Σ 对称半正定。它正定当且仅当每个非零线性组合均有正方差。固定 $B\in\mathbb{R}^{m\times d}$、$\boldsymbol{b}\in\mathbb{R}^m$ 时，$\mathbb{E}[B\boldsymbol{X}+\boldsymbol{b}]=B\boldsymbol{\mu}+\boldsymbol{b}$，$\operatorname{Cov}(B\boldsymbol{X}+\boldsymbol{b})=B\Sigma B^{\mathsf{T}}$。

1.7.3 条件期望与全方差

对可积 Y，条件期望 $\mathbb{E}[Y \mid X]$ 是 X 的可积函数，满足对任意有界可测 g 都有 $\mathbb{E}[g(X)\mathbb{E}[Y \mid X]] = \mathbb{E}[g(X)Y]$。它几乎处处唯一。存在条件密度时，$\mu(x) = \mathbb{E}[Y \mid X = x] = \int y p(y \mid x)\, dy$，离散时使用求和。

条件期望具有线性性质，满足塔式法则 $\mathbb{E}[\mathbb{E}[Y \mid X]] = \mathbb{E}Y$。有界可测 g 还满足 $\mathbb{E}[g(X)Y \mid X] = g(X)\mathbb{E}[Y \mid X]$。

若 $\mathbb{E}[Y^2] < \infty$，定义 $\operatorname{Var}(Y \mid X) = \mathbb{E}[(Y - \mathbb{E}[Y \mid X])^2 \mid X]$。对任意常数 $a \in \mathbb{R}$，在条件二阶矩有限处展开平方：

$$\mathbb{E}[(Y-a)^2 \mid X = x] = \mathbb{E}[(Y-\mu(x))^2 \mid X = x] + 2(\mu(x)-a)\mathbb{E}[Y-\mu(x) \mid X = x] + (\mu \tag{1.55}$$

$$= \operatorname{Var}(Y \mid X = x) + (\mu(x) - a)^2. \tag{1.56}$$

交叉项由条件均值为零而消失，所以条件平方偏差在 $a = \mu(x)$ 处取得唯一最小值，不需要分布形状假设。

将 $Y - \mathbb{E}Y = (Y - \mathbb{E}[Y \mid X]) + (\mathbb{E}[Y \mid X] - \mathbb{E}Y)$ 平方并取期望。交叉项先对 X 条件化后为零，故

$$\operatorname{Var}(Y) = \mathbb{E}[\operatorname{Var}(Y \mid X)] + \operatorname{Var}(\mathbb{E}[Y \mid X]). \tag{1.57}$$

这称为全方差公式（law of total variance），要求有限二阶矩。

1.8 常用概率分布

本节给出分布的定义、参数范围与基本性质。质量函数与密度在指定支撑集之外均取零。$X \sim \mathcal{D}$ 表示 X 服从分布 $\mathcal{D}$。

1.8.1 离散分布

伯努利分布（Bernoulli distribution）$X \sim \operatorname{Bernoulli}(\pi)$ 定义在 $\{0,1\}$ 上，$0 \le \pi \le 1$，满足 $P(X=1) = \pi$、$P(X=0) = 1-\pi$。均值为 π，方差为 $\pi(1-\pi)$。

二项分布（binomial distribution）$X \sim \mathrm{Binomial}(n, \pi)$ 的质量函数为

$$P(X = k) = \binom{n}{k} \pi^k (1-\pi)^{n-k}, \qquad k = 0, \dots, n. \tag{1.58}$$

n 为非负整数，$0 \le \pi \le 1$，端点参数按退化分布理解。均值为 $n\pi$，方差为 $n\pi(1-\pi)$。n 个独立同参数伯努利变量之和服从该分布。

类别分布（categorical distribution）定义在 $\{1, \dots, K\}$ 上，$P(X = j) = \pi_j$，$\pi_j \ge 0$ 且 $\sum_j \pi_j = 1$。多项分布（multinomial distribution）$\boldsymbol{N} \sim \mathrm{Multinomial}(n, \boldsymbol{\pi})$ 定义在非负整数向量 $\boldsymbol{k}$ 且 $\sum_j k_j = n$ 上：

$$P(\boldsymbol{N} = \boldsymbol{k}) = \frac{n!}{\prod_{j=1}^{K} k_j!} \prod_{j=1}^{K} \pi_j^{k_j}. \tag{1.59}$$

n 为非负整数，$\boldsymbol{\pi}$ 为类别概率向量，0^0 按 1 处理。均值为 $\mathbb{E}N_j = n\pi_j$，方差为 $n\pi_j(1-\pi_j)$，$i \ne j$ 时协方差为 $-n\pi_i\pi_j$。

泊松分布（Poisson distribution）$X \sim \mathrm{Poisson}(\lambda)$ 为

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \qquad k = 0, 1, \dots, \quad \lambda > 0. \tag{1.60}$$

均值与方差均为 λ。相互独立的泊松变量之和仍为泊松变量，参数为各参数之和。

1.8.2 连续分布

均匀分布（uniform distribution）$X \sim \mathrm{Uniform}(a, b)$ 要求 $a < b$，在 $[a, b]$ 上的密度为 $1/(b-a)$，均值为 $(a+b)/2$，方差为 $(b-a)^2/12$。

指数分布（exponential distribution）$X \sim \mathrm{Exponential}(\lambda)$ 的密度为 $\lambda e^{-\lambda x}$，$x \ge 0$、$\lambda > 0$。均值为 $1/\lambda$，方差为 $1/\lambda^2$。无记忆性质为 $P(X > s + t \mid X > s) = P(X > t)$，$s, t \ge 0$。

伽马分布（gamma distribution）采用形状–率参数化：

$$p(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \qquad x > 0, \quad \alpha, \beta > 0. \tag{1.61}$$

$\Gamma(\alpha)=\int_0^\infty t^{\alpha-1}e^{-t}\,dt$ 为伽马函数。均值为 α/β，方差为 α/β^2。若使用尺度参数，尺度为 $1/\beta$，须相应改写公式。

贝塔分布（beta distribution）$X\sim\mathrm{Beta}(\alpha,\beta)$ 的密度为

$$p(x)=\frac{x^{\alpha-1}(1-x)^{\beta-1}}{\mathrm{B}(\alpha,\beta)},\qquad 0<x<1,\quad \alpha,\beta>0. \tag{1.62}$$

$\mathrm{B}(\alpha,\beta)=\Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha+\beta)$ 为贝塔函数。均值为 $\alpha/(\alpha+\beta)$，方差为 $\alpha\beta/[(\alpha+\beta)^2(\alpha+\beta+1)]$。

狄利克雷分布（Dirichlet distribution）$\boldsymbol{X}\sim\mathrm{Dirichlet}(\alpha_1,\dots,\alpha_K)$ 要求 $K\geq 2$、$\alpha_j>0$。在 $x_j>0$、$\sum_j x_j=1$ 的单纯形上，以 $x_1,\dots,x_{K-1}$ 为自由坐标，其密度为

$$p(\boldsymbol{x})=\frac{\Gamma(\alpha_0)}{\prod_j\Gamma(\alpha_j)}\prod_{j=1}^{K}x_j^{\alpha_j-1},\qquad \alpha_0=\sum_{j=1}^{K}\alpha_j. \tag{1.63}$$

密度相对于自由坐标的 $(K-1)$ 维勒贝格测度定义。均值为 α_j/α_0，方差为 $\alpha_j(\alpha_0-\alpha_j)/[\alpha_0^2(\alpha_0+1)]$，$i\neq j$ 时协方差为 $-\alpha_i\alpha_j/[\alpha_0^2(\alpha_0+1)]$。

1.8.3 正态分布

正态分布（normal distribution），又称高斯分布（Gaussian distribution），$X\sim\mathcal{N}(\mu,\sigma^2)$ 的密度为

$$p(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right],\qquad x\in\mathbb{R},\quad \mu\in\mathbb{R},\quad \sigma>0. \tag{1.64}$$

均值为 μ，方差为 σ^2。标准正态分布的均值为零、方差为一。

多元正态分布 $\boldsymbol{X}\sim\mathcal{N}(\boldsymbol{\mu},\Sigma)$ 在 $\Sigma\succ 0$ 时具有密度

$$p(\boldsymbol{x})=\frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}}\exp\left[-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathsf{T}}\Sigma^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right]. \tag{1.65}$$

$\boldsymbol{x},\boldsymbol{\mu}\in\mathbb{R}^d$，$\Sigma\in\mathbb{R}^{d\times d}$ 为协方差矩阵，$|\Sigma|=\det\Sigma>0$。若 $\boldsymbol{Z}$ 的分量为相互独立的标准正态变量，则 $\boldsymbol{\mu}+\Sigma^{1/2}\boldsymbol{Z}$ 具有该分布。固定 $B\in\mathbb{R}^{m\times d}$、$\boldsymbol{b}\in\mathbb{R}^m$ 时，$B\boldsymbol{X}+\boldsymbol{b}\sim\mathcal{N}(B\boldsymbol{\mu}+\boldsymbol{b},B\Sigma B^{\mathsf{T}})$。

允许 $\Sigma \succeq 0$ 时仍可通过线性变换定义退化正态分布，但奇异 Σ 没有 $\mathbb{R}^d$ 上的普通密度，不能使用式(1.65)。联合正态变量的零协方差等价于独立，该等价性不适用于任意分布。

设分块联合正态向量为

$$\begin{pmatrix} \boldsymbol{X} \\ \boldsymbol{Y} \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \boldsymbol{\mu}_X \\ \boldsymbol{\mu}_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \right). \tag{1.66}$$

$\boldsymbol{X} \in \mathbb{R}^d$、$\boldsymbol{Y} \in \mathbb{R}^k$，交叉协方差 $\Sigma_{XY} \in \mathbb{R}^{d\times k}$ 且 $\Sigma_{YX} = \Sigma_{XY}^{\mathsf{T}}$。当 $\Sigma_{XX} \succ 0$ 时，

$$\boldsymbol{Y} \mid \boldsymbol{X} = \boldsymbol{x} \sim \mathcal{N}(\boldsymbol{\mu}_{Y|x}, \Sigma_{Y|X}), \tag{1.67}$$

$$\boldsymbol{\mu}_{Y|x} = \boldsymbol{\mu}_Y + \Sigma_{YX}\Sigma_{XX}^{-1}(\boldsymbol{x} - \boldsymbol{\mu}_X), \tag{1.68}$$

$$\Sigma_{Y|X} = \Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY}. \tag{1.69}$$

条件协方差是舒尔补，不依赖 $\boldsymbol{x}$。令 $\boldsymbol{R} = \boldsymbol{Y} - \boldsymbol{\mu}_Y - \Sigma_{YX}\Sigma_{XX}^{-1}(\boldsymbol{X} - \boldsymbol{\mu}_X)$，计算可得 $\operatorname{Cov}(\boldsymbol{R}, \boldsymbol{X}) = 0$。联合正态性使 $\boldsymbol{R}$ 与 $\boldsymbol{X}$ 独立，从而得到上述条件均值与协方差。

1.9 全概率与贝叶斯公式

1.9.1 事件形式

若 B_i 为两两不交、并集为 Ω 的有限或可数事件，且各 $P(B_i) > 0$，全概率公式（law of total probability）为

$$P(A) = \sum_i P(A \mid B_i)P(B_i). \tag{1.70}$$

它由 $A = \bigcup_i (A \cap B_i)$ 及可数可加性推出。零概率的 B_i 可直接按 $P(A\cap B_i) = 0$ 处理，避免定义零概率事件上的条件概率。当 $P(A) > 0$ 时，贝叶斯公式（Bayes' theorem）为

$$P(B_j \mid A) = \frac{P(A \mid B_j)P(B_j)}{\sum_i P(A \mid B_i)P(B_i)}. \tag{1.71}$$

分子是交事件的概率，分母是 $P(A)$，保证结果归一化。

1.9.2 密度形式

设 Θ 与 X 具有联合密度，则

$$p(x)=\int p(x\mid\theta)p(\theta)\,d\theta,\qquad p(\theta\mid x)=\frac{p(x\mid\theta)p(\theta)}{p(x)}. \tag{1.72}$$

离散 Θ 时使用求和。第二式要求 $0<p(x)<\infty$，以几乎处处意义理解。$p(\theta)$ 称为先验分布（prior distribution），$p(\theta\mid x)$ 称为后验分布（posterior distribution）。固定 x 后，将 $p(x\mid\theta)$ 视为 θ 的函数称为似然函数（likelihood function），它不要求在 θ 上积分为一。$p(x)$ 称为边缘似然（marginal likelihood），也称证据（evidence）。先验归一化且分母为正、有限时，公式给出归一化的后验。

1.10 信息量与分布差异

1.10.1 熵、交叉熵与相对熵

离散分布的熵（entropy）为 $H(p)=-\sum_x p(x)\log p(x)$，交叉熵（cross entropy）为 $H(p,q)=-\sum_x p(x)\log q(x)$。约定 $0\log 0=0$。若 $p(x)>0$ 且 $q(x)=0$，交叉熵为 $+\infty$。自然对数对应的信息单位为奈特（nat）。

库尔贝克–莱布勒散度（Kullback–Leibler divergence，KL 散度），又称相对熵，为

$$\mathrm{KL}(p\|q)=\sum_x p(x)\log\frac{p(x)}{q(x)}. \tag{1.73}$$

采用同样的零值约定。共同基准测度下的密度使用积分。若 p 不相对于 q 绝对连续，散度为 $+\infty$。散度非负，为零当且仅当两分布相同。离散情形由 $-\log u\ge 1-u$ 得到

$$\mathrm{KL}(p\|q)\ge\sum_{p(x)>0}\bigl(p(x)-q(x)\bigr)\ge 0. \tag{1.74}$$

连续情形有相应积分证明。KL 散度一般不对称，不满足度量的全部条件。熵与交叉熵均有限时，展开对数比得到

$$H(p,q) = H(p) + \mathrm{KL}(p\|q), \qquad \mathrm{KL}(p\|q) \geq 0. \tag{1.75}$$

有限性避免 $\infty - \infty$。连续分布的微分熵（differential entropy）为 $h(p) = -\int p(x)\log p(x)\,dx$，要求积分有定义。它可为负，并随坐标尺度改变。

多元正态分布在 $\Sigma \succ 0$ 时的微分熵为 $\frac{1}{2}\log((2\pi e)^d|\Sigma|)$。在具有相同均值与正定协方差、相关积分有限的密度中，它具有最大微分熵。令 q 为该正态密度，因 $\log q$ 为常数加二次型，相同矩意味着 $\mathbb{E}_p \log q = \mathbb{E}_q \log q$。于是 $\mathrm{KL}(p\|q) = h(q) - h(p) \geq 0$。

1.10.2 Wasserstein 距离

对有限共同支撑集上的分布 p, q，令 $c(a,b)$ 为支撑集上的度量，$\Gamma(p,q)$ 为边缘分别是 p, q 的联合质量函数集合。一阶瓦瑟斯坦距离（Wasserstein distance）定义为

$$W_1(p,q) = \min_{\gamma \in \Gamma(p,q)} \sum_{a,b} \gamma(a,b)c(a,b). \tag{1.76}$$

约束为 $\gamma(a,b) \geq 0$、$\sum_b \gamma(a,b) = p(a)$、$\sum_a \gamma(a,b) = q(b)$。$\gamma$ 也称为耦合（coupling），规定两个边缘取值之间的共同质量。有限支撑使最小值存在，底层 c 为度量时 W_1 也为度量。一般度量空间上将求和改为对耦合测度积分，将最小值改为下确界，并要求有限一阶矩以保证距离有限。

1.11 期望与参数微分

参数变化时，函数值与分布都可能变化。对 $\theta \in \mathbb{R}^k$，仅对函数求导一般不能给出完整的期望导数：

$$\nabla_\theta \mathbb{E}_{X\sim p_\theta}[f_\theta(X)] \quad \text{一般不能直接写为} \quad \mathbb{E}_{X\sim p_\theta}[\nabla_\theta f_\theta(X)]. \tag{1.77}$$

特殊条件下两者可以相等，该式说明不能无条件交换运算。

设 p_θ 相对于固定测度 ν 具有共同的参数无关支撑集，且 f_θ, p_θ 关于 θ 可微。若在参数的邻域内，$f_\theta p_\theta$ 及其各参数偏导具有可积控制函数，则可由支配收敛定理交换微分与积分：

$$\nabla_\theta \int f_\theta(x) p_\theta(x)\, d\nu(x) = \int [p_\theta(x)\nabla_\theta f_\theta(x) + f_\theta(x)\nabla_\theta p_\theta(x)]\, d\nu(x) \tag{1.78}$$

$$= \mathbb{E}_{p_\theta}[\nabla_\theta f_\theta(X)] + \mathbb{E}_{p_\theta}[f_\theta(X)\nabla_\theta \log p_\theta(X)]. \tag{1.79}$$

第二步另要求共同支撑上密度为正，且各项可积。向量 $\nabla_\theta \log p_\theta(x) \in \mathbb{R}^k$ 称为得分函数（score function）。同样的交换条件应用于 $\int p_\theta\, d\nu = 1$，给出 $\mathbb{E}_{p_\theta}[\nabla_\theta \log p_\theta(X)] = \mathbf{0}$。支撑集随参数变化时需要处理移动边界，不能直接套用式(1.79)。

1.12 指数族分布

1.12.1 基准测度、自然参数与归一化

指数族（exponential family）通过固定统计量与参数的内积表达密度。设 ν 为固定的 σ 有限基准测度（base measure），$h(x) \geq 0$ 为参数无关的基准项，$T(x) \in \mathbb{R}^k$ 为固定可测函数。σ 有限表示空间可被可数个具有有限测度的集合覆盖。分布写作

$$p_\theta(x) = h(x)\exp\{\theta^{\mathsf{T}} T(x) - A(\theta)\}, \qquad A(\theta) = \log \int h(x) e^{\theta^{\mathsf{T}} T(x)}\, d\nu(x). \tag{1.80}$$

p_θ 为相对于 ν 的密度，$\theta \in \mathbb{R}^k$ 称为自然参数（natural parameter），T 称为充分统计量（sufficient statistic），A 称为对数配分函数（log-partition function）。h 不必积分为一。离散变量可使用计数测度，普通连续密度使用勒贝格测度。也可将 h 吸收到测度 $h\, d\nu$ 中。

自然参数空间为

$$\mathcal{H} = \left\{ \theta \in \mathbb{R}^k : 0 < \int h(x) e^{\theta^{\mathsf{T}} T(x)}\, d\nu(x) < \infty \right\}. \tag{1.81}$$

只有 $\theta \in \mathcal{H}$ 时，密度才可归一化。A 使 $\int p_\theta \, d\nu = 1$，同时描述参数改变时归一化量的变化。共同支撑由 $h(x) > 0$ 确定，要求不随参数变化。

参数集合取为全部 $\mathcal{H}$ 时称为满指数族（full exponential family）。自然参数集合为 $\mathbb{R}^k$ 中的开集时称为正则指数族（regular exponential family）。使用受限参数映射 $\theta = \theta(\eta)$ 时，关于 θ 的导数不能直接当作关于 η 的导数。

1.12.2 充分性与最小表示

统计量的充分性是指给定该统计量后，随机对象的条件分布不再依赖参数。对具有共同支配测度的分布族，因子分解判据将充分性写为 $p_\theta(x) = g_\theta(S(x))b(x)$。式(1.80)具有这一形式，所以 $T(X)$ 对 θ 充分。

若 $X_1, \dots, X_n$ 相互独立且同分布，其联合密度为

$$\prod_{i=1}^{n} p_\theta(x_i) = \left(\prod_{i=1}^{n} h(x_i) \right) \exp\left\{ \theta^{\mathsf{T}} \sum_{i=1}^{n} T(x_i) - nA(\theta) \right\}. \tag{1.82}$$

因此 $\sum_i T(X_i)$ 是联合分布的充分统计量。充分性不保证维度最小，也不保证不同参数对应不同分布。

若不存在非零 $\boldsymbol{a} \in \mathbb{R}^k$ 和常数 b 使 $\boldsymbol{a}^{\mathsf{T}} T(x) = b$ 在测度 $h\,d\nu$ 下几乎处处成立，则称为最小表示（minimal representation）。存在这样的仿射关系时，统计量含有冗余分量，自然参数可沿相应方向改变而不改变分布。

1.12.3 对数配分函数的导数

在自然参数空间内部，要求一阶、二阶微分可移入积分，且相关矩有限。一个足够的局部条件是：在参数的某个邻域内，$h(x)e^{\theta^{\mathsf{T}} T(x)}$ 及其一阶、二阶偏导具有共同的可积控制函数。令 $Z(\theta) = e^{A(\theta)}$，则

$$\frac{\partial A}{\partial \theta_j} = \frac{1}{Z(\theta)} \int T_j(x) h(x) e^{\theta^{\mathsf{T}} T(x)} \, d\nu(x) = \mathbb{E}_\theta[T_j(X)], \tag{1.83}$$

$$\frac{\partial^2 A}{\partial \theta_i \partial \theta_j} = \mathbb{E}_\theta[T_i(X) T_j(X)] - \mathbb{E}_\theta[T_i(X)] \mathbb{E}_\theta[T_j(X)]. \tag{1.84}$$

因此

$$\nabla A(\theta) = \mathbb{E}_\theta[T(X)] \in \mathbb{R}^k, \qquad \nabla^2 A(\theta) = \mathrm{Cov}_\theta(T(X)) \in \mathbb{R}^{k\times k}. \tag{1.85}$$

这些公式将归一化函数的导数与统计量的矩联系起来。海森矩阵半正定，因为 $\boldsymbol{a}^{\mathsf{T}}\nabla^2 A\boldsymbol{a} = \mathrm{Var}_\theta(\boldsymbol{a}^{\mathsf{T}}T(X)) \geq 0$。最小表示下，非零线性组合不能几乎必然为常数，所以在满足上述条件的内部点，海森矩阵正定。

自然参数空间是凸集。对 $\theta_1, \theta_2 \in \mathcal{H}$ 与 $0 < t < 1$，赫尔德不等式（Hölder inequality）给出 $Z(t\theta_1 + (1-t)\theta_2) \leq Z(\theta_1)^t Z(\theta_2)^{1-t}$。取对数可得 A 为凸函数。在最小正则表示下，A 在自然参数空间内部严格凸。边界处导数或矩可能不存在，不能无条件延伸内部结论。

1.12.4 得分与信息矩阵

在上述正则条件下，得分函数为

$$\nabla_\theta \log p_\theta(x) = T(x) - \nabla A(\theta), \tag{1.86}$$

其期望为零。费舍尔信息矩阵（Fisher information matrix）定义为得分的二阶矩：

$$\mathcal{I}(\theta) = \mathbb{E}_\theta\left[(\nabla_\theta \log p_\theta(X))(\nabla_\theta \log p_\theta(X))^{\mathsf{T}}\right] = \nabla^2 A(\theta). \tag{1.87}$$

它为 $k \times k$ 半正定矩阵，最小正则表示下正定。它描述分布相对于自然参数的局部变化。若 $\theta = \theta(\eta)$ 可微，则信息矩阵按 $\mathcal{I}_\eta = (D\theta)^{\mathsf{T}}\mathcal{I}_\theta D\theta$ 变换，矩阵元素依赖参数坐标。

第二章　机器学习究竟在学习什么

本章摘要。本章定义样本、任务、模型、损失和风险，说明不同损失对应不同预测对象，并讨论正则化、可识别性及预测到决策的边界。

同一段振动记录，可以用来判断轴承是否故障，也可以用来预测下一时刻的振幅。这两个问题需要不同的标签，预测错误的后果也不同。上一章介绍了计算所需的数学工具；本章先确定要学习的对象，再说明怎样用目标函数比较模型。

输入决定模型能够使用哪些信息，标签规定需要预测什么，损失衡量预测错误的代价。如果三者与实际任务不一致，即使训练目标已经达到最小值，预测结果也可能无法支持维护决策。本章由数据和任务引出模型、损失与风险，再讨论归纳偏置、正则化和任务的可学习性。后续各章将把这些概念用于具体计算。

2.1　学习对象：数据、任务与模型

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

从数据到任务。　数据（data）是对对象、过程或环境的观测记录。一个样本（sample）是一次相对完整的观测，通常记为 $\boldsymbol{x} \in \mathbb{R}^d$；监督学习中还伴随标签 y，于是样本写为 $(\boldsymbol{x}, y)$。这里的“样本”不是数据表的一行这么简单：一次设备运行周期、一张图像、一个句子或一段传感器窗口都可以成为样本，关键在于它是否对应一个明确的可学习单位。

“任务”由输入空间 $\mathcal{X}$、输出空间 $\mathcal{Y}$ 以及评价准则共同决定。输入空

间是模型允许接收的对象集合（例如时序数据、图像、文本等），输出空间是允许回答的结果集合，这两个集合先于可学习参数的确定。分类的输出是离散类别，回归的输出是连续数值，预测性维护可能输出剩余寿命，异常检测则可能没有逐样本标签。相同的数据可以支持不同任务。例如，振动信号既可以用于故障分类，也可以用于生成未来波形或估计设备状态。

把一个任务写成可核查的样本。 假设每小时读一次温度和振动，把这两项读数排成输入向量：

$$\boldsymbol{x} = (\text{温度}, \text{振动})^{\mathsf{T}} \in \mathbb{R}^2.$$

标签为下一小时温度 $y \in \mathbb{R}$ 时，这就是回归任务；改成“未来一天是否故障”的 $y \in \{0, 1\}$ 时，就成为二分类。

监督学习用已知输入和标签学习对应关系，无监督学习则在没有这些目标标签时寻找输入结构，即发现样本之间的相似性、变量之间的关联等规律。例如，不提供故障标签，仅根据温度和振动把相似的设备记录分组，但这些分组不自动代表正常或故障。

同一数据记录能面向不同任务，不同任务同样需要不同的标签或指标。训练是利用已有样本调整参数；推理是在参数训练固定后处理一个新输入，得到对新样本标签或指标的预测。

模型、参数与预测。 模型规定了允许采用的预测关系。直接给出一个预测值时，可以用确定性模型（deterministic model）表示：

$$f_{\boldsymbol{\theta}} : \mathcal{X} \to \mathcal{Y}, \qquad \boldsymbol{\theta} \in \Theta. \tag{2.1}$$

这里 Θ 是允许的参数取值集合。给定输入 $\boldsymbol{x}$ 和参数 $\boldsymbol{\theta}$，输出为 $\hat{y} = f_{\boldsymbol{\theta}}(\boldsymbol{x})$。模型结构规定函数的形式，参数从这些函数中确定一个具体函数。例如，$f_{w,b}(x) = wx + b$ 规定了直线形式，w 和 b 分别决定斜率和截距。训练利用数据和目标函数选择参数，求解算法决定怎样完成这一选择。

如果还需要描述不同标签的可能性，可以建立概率模型（probabilistic model），输出条件分布 $p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})$。在 K 类分类中，输出是 K 个非负且总和为一的概率。在高斯回归中，模型可以给出条件均值和方差。概率分布随后可以转成一个预测值，例如取回归分布的均值，或取概率最大的类别；这种转换会舍去部分不确定性信息。确定性预测也可以表示为集中在单点 $f_{\boldsymbol{\theta}}(\boldsymbol{x})$ 上的退化分布，但它没有表达该点以外的观测波动。

上述两类表述都直接描述给定输入后的输出，属于判别建模（discriminative modeling）。选择函数形式时，需要考虑输入结构、任务和计算资源。例如，处理图像时可以利用邻近像素的局部关系，处理时间序列时可以利用观测的先后顺序。具体网络结构将在相应章节介绍。

概率建模还可以作用于未观测的状态或未知参数。用潜变量 z 表示设备状态时，可通过 $p_{\boldsymbol{\theta}}(z \mid \boldsymbol{x})$ 和 $p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x}, z)$ 描述预测，再对 z 求和或积分。贝叶斯模型则用后验分布 $p(\boldsymbol{\theta} \mid \mathcal{D})$ 表达观测训练数据后对参数的不确定性。因此，输出是否为概率分布，与参数是否用分布表示，是两个需要分别确定的问题。

生成模型（generative model）描述观测数据的分布。在带标签任务中，它可以建立联合分布 $p_{\boldsymbol{\theta}}(\boldsymbol{x}, y)$；没有标签时，也可以直接建立 $p_{\boldsymbol{\theta}}(\boldsymbol{x})$。联合模型能够通过条件概率得到 $p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})$，也可能用于生成新样本。相比直接建立条件分布，它增加了关于输入如何产生的假设，这些假设同样需要检验。

2.2 损失函数怎样规定训练目标

从一次预测的误差到整个训练集的目标。 损失函数（loss function）把模型输出与观测标签之间的差异转成一个数。数值越大，表示该预测按所选规则付出的代价越高。例如，回归任务可以使用平方损失：

$$\ell_{\mathrm{sq}}\big(f_{\boldsymbol{\theta}}(\boldsymbol{x}), y\big) = \frac{1}{2}\big(f_{\boldsymbol{\theta}}(\boldsymbol{x}) - y\big)^2. \tag{2.2}$$

这里 $f_{\boldsymbol{\theta}}(\boldsymbol{x})$ 是预测值，y 是观测标签，系数 1/2 使求导更简洁。平方损失会放大较大的误差。如果任务对高估和低估的代价不同，还需要改变损失形式，第四章将讨论这种选择。

对训练集 $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}$，单样本损失的平均值称为经验风险（empirical risk）：

$$\hat{R}(f_{\boldsymbol{\theta}}) = \frac{1}{n}\sum_{i=1}^{n} \ell(f_{\boldsymbol{\theta}}(\boldsymbol{x}_i), y_i). \tag{2.3}$$

训练目标函数（objective function）规定需要最小化或最大化的量。它可以是经验风险，也可以包含正则项。单样本损失、经验风险和完整训练目标描述不同层次的量，需要分别说明。

概率模型可以通过似然构造目标。把参数视为固定未知量时，极大似然估计（Maximum Likelihood Estimation，ML）选择使观测数据似然最大的参数。在给定参数后样本相互独立的联合模型中，有

$$\hat{\boldsymbol{\theta}}_{\mathrm{ML}} = \arg\max_{\boldsymbol{\theta}} \log p_{\boldsymbol{\theta}}(\mathcal{D}) = \arg\max_{\boldsymbol{\theta}} \sum_{i=1}^{n} \log p_{\boldsymbol{\theta}}(\boldsymbol{x}_i, y_i). \tag{2.4}$$

条件模型则使用 $\sum_i \log p_{\boldsymbol{\theta}}(y_i \mid \boldsymbol{x}_i)$。最大化对数似然等价于最小化其负值，称为负对数似然（Negative Log-Likelihood，NLL）。第三章将说明高斯回归的 NLL 为何对应平方误差。

如果为参数指定先验 $p(\boldsymbol{\theta})$，还可以选择后验密度最大的参数，称为最大后验估计（Maximum A Posteriori estimation，MAP）：

$$\hat{\boldsymbol{\theta}}_{\mathrm{MAP}} = \arg\max_{\boldsymbol{\theta}} p(\boldsymbol{\theta} \mid \mathcal{D}) = \arg\max_{\boldsymbol{\theta}} \big[\log p(\mathcal{D} \mid \boldsymbol{\theta}) + \log p(\boldsymbol{\theta})\big]. \tag{2.5}$$

该等式要求后验可归一化；其归一化常数与待比较的参数无关。MAP 使用先验，但结果仍是一个参数点。保留完整后验分布还需要进一步计算。极大似然和 MAP 都可以用于条件模型或联合模型，采用哪一种估计方法与是否建立输入的分布是两个不同的选择。

经验风险与总体风险. 有限样本上的拟合与总体上的预测能力需要分开讨论，经验分布到真实分布的一致收敛是统计学习理论的基础问题之一 [88]。设 $(X,Y)\sim P$ 描述部署环境中的输入与标签，$X\in\mathbb{R}^d$，Y 可为实数或类别。总体风险定义为

$$R(f)=\mathbb{E}_{(X,Y)\sim P}[\ell(f(X),Y)]. \tag{2.6}$$

这里的期望包含尚未观察到的未来样本，因此通常不能直接计算。若训练样本独立同分布于 P（independent and identically distributed，彼此独立且共享同一个分布），对一个事先固定且损失可积的 f，有 $\mathbb{E}[\hat{R}(f)]=R(f)$。训练前允许选择的模型参数属于参数空间 Θ；“事先固定”强调不能先看测试结果再挑选 f 而仍使用这条无偏性解释。若损失方差有限，独立性进一步给出

$$\mathrm{Var}(\hat{R}(f))=\frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(\ell(f(X_i),Y_i))=\frac{\mathrm{Var}(\ell(f(X),Y))}{n}. \tag{2.7}$$

这解释了平均损失为什么可用于估计风险，也暴露了限制：相邻设备窗口相关时有额外协方差项；f 由同一训练集选择后，上述固定模型的无偏论证不能直接用于其训练误差。验证与测试的必要性由此产生，而不是来自惯例。

训练时通常最小化经验风险，真正希望最小化的却是部署分布上的总体风险。**“过拟合”**的核心表现，是模型在训练集上的经验风险很小，但在未参与训练的新样本上的总体风险仍然较大，因而出现较大的泛化差距。模型容量过大时，它不仅可以学习输入与标签之间可迁移的规律，也可能记住训练样本中的噪声、偶然相关性甚至标签错误；但模型容量过大并不是过拟合的必要条件，训练样本过少、标签噪声较强或反复利用验证集也可能造成过拟合。当训练集有限或含有噪声时，模型记住的细节可能无法在同一分布的新样本中重复出现。若训练集与部署分布不同，则还存在分布偏移问题，不能仅把性能下降归因于过拟合。典型地，训练早期经验风险和总体风险可能同时下降；训练后期经验风险继续下降，而总体风险可能转而上升，因为模型开始更多地拟合训练数据中的偶然性。

2.3 归纳偏置

前文提到了过拟合，通俗来讲指的是训练误差很低而新样本误差较高。与之对应的一个概念叫做“**泛化性**”，指模型在“未参与训练和选择的数据”上的有效程度。使用损失函数或目标函数进行训练，直接下降的是经验风险；但我们真正关心的是部署分布上的总体风险。经验风险最小化并不自动意味着总体风险最小化，因此需要在模型构造和训练目标中加入能够约束学习过程的偏好。下面从模型角度和训练目标角度分别说明这种约束如何发挥作用。

模型结构、参数化方式和训练算法会限制能够采用的预测关系，也会使某些解更容易被找到。这些预先引入的限制和偏好称为归纳偏置（inductive bias）。当训练样本不足以唯一确定预测关系时，归纳偏置提供选择候选解的依据。它能否改善新样本上的表现，取决于这些假设是否适合任务。

例如，对同一图像分类任务，卷积神经网络把局部连接和参数共享写进了模型结构，因此偏好局部模式以及对平移具有一定稳定性的函数；全连接网络则没有这种结构性限制。若图像任务确实具有这些性质，卷积网络就能把有限样本用于学习更有用的变化，而不必分别记住每个像素位置的完全独立关系，因此通常更容易获得较好的泛化性能。这里的“更适合”是统计意义上的，不是保证在任何数据集上都更好。

归纳偏置与可解释性有关，但二者不是同一个概念。可解释性讨论人能否理解模型的预测依据；归纳偏置讨论模型在学习时预先接受了哪些结构假设。一个模型可以具有明确的归纳偏置，却仍然难以解释；也可以相对容易解释，但其归纳偏置并不适合当前任务。判断归纳偏置是否良好，关键在于它是否与数据生成过程和任务目标相匹配，并能否在有限样本下缩小训练风险与总体风险之间的差距。

正则化（regularization）提供了加入这种偏好的另一条途径：不一定更换模型结构，而是在训练目标中明确惩罚某些不希望出现的解。其基本形式是

$$\min_{\boldsymbol{\theta}} \ \hat{R}(\boldsymbol{\theta}) + \lambda \Omega(\boldsymbol{\theta}), \qquad \Omega(\boldsymbol{\theta}) = \frac{1}{2}\|\boldsymbol{\theta}\|_2^2. \tag{2.8}$$

这里第一项 $\hat{R}(\boldsymbol{\theta})$ 要求模型解释训练数据，第二项 $\Omega(\boldsymbol{\theta})$ 表达我们对模型复杂度的偏好。选择 $\Omega(\boldsymbol{\theta}) = \frac{1}{2}\|\boldsymbol{\theta}\|_2^2$，表示在其他条件相近时偏好范数较小的参数；它并不声称真实参数一定接近零，而是把“大权重可能对应不稳定拟合”作为一种可调的建模偏好。系数 $\lambda \geq 0$ 决定这种偏好有多强：$\lambda = 0$ 时只拟合训练数据；λ 增大时，模型愿意牺牲一部分训练集拟合精度，以换取更小的参数和可能更好的泛化。正则化的目的不是让训练误差尽可能低，而是在经验风险和对复杂度的约束之间寻找适合部署的平衡。

例 2.1. 根据温度记录预测下一时刻温度时，若已知相邻时刻通常连续变化，可以采用平滑性假设；若设备存在周期，可以把相应周期特征加入输入。这些选择限制了候选预测关系。只有假设与设备运行条件相符时，这种限制才可能帮助有限样本下的学习。

惩罚形式与约束形式如何联系。 为什么可以把正则化理解成“控制复杂度”？一种直接的写法是先规定允许的复杂度上限：

$$\min_{\theta} \hat{R}(\theta) \quad \text{subject to} \quad \Omega(\theta) \leq c. \tag{2.9}$$

这句话的意思是：在所有不超过复杂度预算 c 的模型中，选择训练风险最小的模型。它明确表达了两件事：训练数据需要拟合，但模型不能为了拟合少量样本而无限增加复杂度。

约束问题也可以通过拉格朗日乘子写成

$$L(\theta, \lambda) = \hat{R}(\theta) + \lambda\big(\Omega(\theta) - c\big), \qquad \lambda \geq 0. \tag{2.10}$$

固定 λ 后，$-\lambda c$ 与 θ 无关，不会改变参数最优解，于是得到惩罚形式 $\hat{R}(\theta) + \lambda\Omega(\theta)$。因此，$c$ 和 λ 分别是两种不同的控制方式：前者规定复杂度上限，后者规定超出较简单解的代价。在线性凸问题并满足适当严格可行性条件时，二者可以通过拉格朗日最优性条件联系起来；对非凸网络，不能据此声称任意约束问题都与某个惩罚问题全局等价，也不能认为 λ 与 c 必然一一对应。

在约束问题的最优点 $\hat{\theta}$ 处，若目标与约束满足相应的凸性条件，可以写出

$$0 \in \partial \hat{R}(\hat{\theta}) + \lambda \partial \Omega(\hat{\theta}), \qquad \Omega(\hat{\theta}) \le c, \qquad \lambda(\Omega(\hat{\theta}) - c) = 0. \tag{2.11}$$

∂ 是允许不可微凸函数的次梯度集合。最后一个等式是互补条件。若 $\Omega(\hat{\theta}) < c$，说明复杂度预算没有用完，限制没有起作用，此时可以有 $\lambda = 0$；若 $\Omega(\hat{\theta}) = c$，说明模型已经碰到复杂度边界，进一步降低训练风险通常需要增加复杂度，约束因此会通过正的 λ 影响最优解。这里的“补偿”不是说两个数必须相等，而是说训练风险的改善必须值得为增加复杂度所付出的代价。

最后用一维例子看清“收缩”究竟发生了什么。设无正则化时的训练风险为

$$\hat{R}(w) = \frac{1}{2}(w - a)^2, \tag{2.12}$$

其中 a 是只根据训练数据得到的最优估计。它的最小值在 $w = a$ 处，因为此时 w 与 a 完全一致。现在加入平方惩罚，训练目标变为

$$J(w) = \frac{1}{2}(w - a)^2 + \frac{\lambda}{2} w^2. \tag{2.13}$$

第一项希望 w 接近数据给出的估计 a，第二项希望 w 接近零。对 w 求导得到

$$J'(w) = (w - a) + \lambda w. \tag{2.14}$$

令导数为零，得到 $(1 + \lambda)w = a$，因此

$$\hat{w} = \frac{a}{1 + \lambda}. \tag{2.15}$$

由于 $\lambda \ge 0$，有 $|\hat{w}| \le |a|$；当 $\lambda = 0$ 时不收缩，随着 λ 增大，$\hat{w}$ 逐渐靠近零。这就是“收缩”的含义：正则化不会自动判断某个变量是噪声，也不会直接把所有不重要的系数删掉，而是把参数估计向预先选定的中心（这里是零）拉近。

收缩为什么可能改善总体风险？训练数据中的偶然波动会使无正则化估计 a 在不同训练集之间变化很大，这种变化称为估计的不稳定性或方差。平方惩罚牺牲了一部分对当前训练集的贴合，使估计更稳定；但如果真实系数确实远离零，收缩会带来偏差。因此，正则化是在偏差与方差之间作权衡：只有方差的降低足以抵消偏差增加，使用验证数据选择的 λ 才可能降低总体预测风险。它不是“惩罚越强越好”，也不是“参数越小越接近真实机制”。

模型选择至少同时受四类约束：数据规模与标注质量、任务中的依赖结构、训练与推理资源、错误的业务代价。复杂模型并不自动优于简单模型；它只有在表示了简单模型无法表示的结构时才有必要。后文讨论的序列、视觉和语言模型，实际上是在不同结构约束下对这四个问题的回答。

2.4 任务的可学习性

在选择模型之前，还应先问一个更根本的问题：给定的输入中，是否含有足以预测目标的稳定信息？例如，设输入是风电机组叶片的图像，标签是同一时刻的发电功率。凭借领域知识可以预期，功率还强烈依赖风速、风向、空气密度、机组运行状态和控制策略；一张只反映叶片外观的图像，通常不足以充分决定功率。图像中也许包含结冰、污损或损伤等与功率有关的间接线索，但这种联系必须由数据和机理共同证实，不能因为两个变量出现在同一张数据表中，就假定二者必然存在可用于预测的关系。

训练集上的拟合能力不能单独回答“任务是否可以被学习”这个问题。只要模型足够灵活，它就可以把输入空间划分为许多很小的区域，并为每个训练样本建立对应映射。以决策树回归为例，当训练输入彼此可区分，且树的深度、叶节点样本数等不受限制时，树可以把训练样本逐个分到不同叶节点，从而达到零训练误差；分类树也可以达到百分之百训练准确率。这说明模型有能力记住训练样本，却不说明图像中存在对未来功率稳定有效的预测线索。若新图像落入训练时未被充分覆盖的区域，模型只能依赖未

经验证的划分和映射，训练集上的完美表现便可能无法迁移到新样本。这正是过拟合的一种典型表现。

从统计角度看，需要检查给定输入 X 后的条件分布 $P(Y \mid X)$ 是否具有可利用的结构，以及这种结构在训练和部署环境之间是否足够稳定。相近输入对应相近的标签分布，是一种可能的结构；连续性、平滑性和低维结构也可以支持对未见样本的预测。但这些条件并不适用于所有任务，判断时还要结合样本覆盖、噪声水平和模型假设。即使存在稳定关系，有限训练数据也未必足以学到它。

现实中的困难在于，输入空间往往高维，且样本真实分布不均匀；有限样本更不可能把整个空间都覆盖。因此，数据中是否存在规律通常不能仅靠观察几个样本来断言。一个有用的直觉是：若相同或非常相近的输入在输入空间的一个小邻域内反复对应差异很大的标签，那么只使用这些输入时就存在不可消除的不确定性；即使知道真实条件分布，也不可能准确预测每一个样本。相反，若 X 能够稳定地缩小 Y 的不确定性，使合适的预测函数在独立新样本上显著优于“不看输入、只预测平均值或多数类”的基线，则该任务具有可学习的信号。这里的“规律”不要求是线性的、显式的，或容易写成公式；它可以是高度非线性的统计关系，但必须能够在新的数据中重复出现。

有限数据无法从逻辑上证明这种规律一定存在，只能不断积累证据。实践中应结合四类检查：首先用领域机理审查输入到标签的路径，确认不是把结果发生之后的信息误当作输入；其次检查标签的测量质量、时间对齐和样本覆盖，避免真实信号被噪声或错误配对淹没；再次在严格隔离的验证集或测试集上，与不使用输入的简单基线比较；最后检验结果是否能跨时间、机组或运行条件复现。若模型只在训练集上优于基线，或一旦按时间、设备划分测试集就失效，更合理的结论通常是现有输入不足、分布发生了变化，或模型只记住了偶然性，而不是急于增加模型复杂度。

从训练到部署及反馈。 沿图2.1从采集到上线的路径，可以依次看四个阶段。先把设备记录整理成输入和标签，再选择能处理这些输入的模型，通过训练求出参数，最后用这些参数预测新记录。上线后的错误又会提示我们补数据、改标签或重新训练。评价时除了训练损失，还要检查新工况下的表现、概率是否校准、计算是否及时，以及误报和漏报的后果。

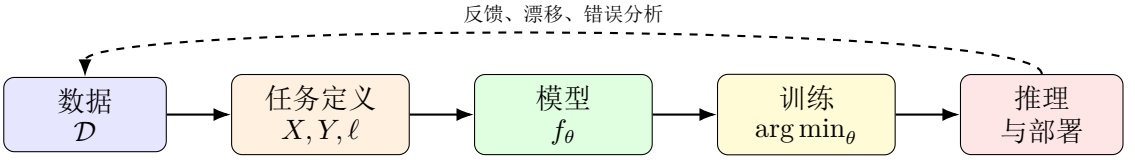


图 2.1: 工业数据智能的训练、部署与反馈：部署反馈会重新影响数据和任务定义。

2.5 从问题定义到模型计算

本章确定了输入、标签、模型和训练目标之间的关系。经验风险描述训练数据上的平均损失，总体风险描述目标分布上的预测代价。归纳偏置和正则化能够约束学习，但其效果仍需要独立数据检验。

接下来需要把这些定义用于计算。第三章以线性回归说明怎样组织数据、求出参数，以及怎样用后验分布表达参数不确定性。第四章进一步比较不同任务的损失和评价指标，第五章讨论目标没有直接解或后验难以计算时的求解方法。

辅助学习材料

- **Linear Models**；作者/平台：scikit-learn Developers；英文；官方文档。重点阅读 Ordinary Least Squares、Ridge、Lasso 与 Logistic Regression 小节，配合本章的线性预测、正则化和分类损失理解参数约束与风险最小化。在线阅读。

- **Cross-validation: evaluating estimator performance**；作者/平

台：scikit-learn Developers；英文；官方文档。重点阅读训练/验证/测试划分、交叉验证和数据泄漏说明，帮助把本章的经验风险、部署风险与可复现实验边界落实为流程。在线阅读。

- **损失函数（Loss Function）**；知乎；中文解说。比较平方损失与交叉熵，核对本章预测对象；标题与主题据必应索引，原页受限。在线阅读。

- **损失函数（lossfunction）的全面介绍（简单易懂版）**；CSDN；中文博客。阅读 L1、MSE 与交叉熵说明，比较不同误差的代价；已核对公开页面标题与索引摘要。在线阅读。

- **2021 - 类神经网络训练不起来怎么办 (四) 损失函数 (Loss) 也可能有影响**；李宏毅；bilibili；中文课程。选看第 22 集，对照本章损失与学习目标。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量；已核对目录与计数，未逐帧观看。观看分集。

第三章　从一个简单模型开始：线性回归

本章摘要。本章用线性回归，把上一章的数据、任务、模型、目标函数与正则化落实为可以计算的例子。我们从四个角度看同一个回归问题：直接预测数值；在固定参数下预测标签的条件分布；用参数分布表达有限数据带来的不确定性；用高斯过程在函数空间中直接表达函数的不确定性。平方损失、高斯似然、岭惩罚、高斯先验与核函数由此联系起来，同时区分最大后验点估计、贝叶斯线性回归和高斯过程的预测分布。

上一章介绍了许多概念，但只知道名称还不足以建立一个模型。例如，输入和标签究竟怎样排成数据？参数怎样从目标函数中求出来？输出一个概率，是否就意味着参数也是随机的？本章沿着“问题形式化、参数估计、贝叶斯线性回归、投影解释”的线索组织推导 [18]，但用本书的工业预测任务重新表述这些关系。

我们始终围绕同一个回归问题展开。先把预测写成输入与权重的加权和，再把它看作条件分布的均值，随后用权重的后验分布表达有限数据带来的不确定性，最后不再显式保存有限维权重，而是在函数空间中用协方差函数描述任意输入处的联合不确定性。这样既能看清四种视角之间的联系，也能看清它们对模型结构和计算方式作出的不同选择。

3.1　先固定数据和任务

一个带标签样本由输入 $\boldsymbol{x}_i$ 和对应的标签 y_i 组成，其中 i 是样本编号。输入是预测时可用的信息，用 d 个数值特征组成的列向量表示；标签是希

望根据这些信息预测的目标量。本章讨论实数值的回归任务，因此

$$\boldsymbol{x}_i = (x_{i1}, \dots, x_{id})^{\mathsf{T}} \in \mathbb{R}^d, \qquad y_i \in \mathbb{R}. \tag{3.1}$$

这里 x_{ij} 表示第 i 个样本的第 j 个特征。标签 y_i 是训练时已经观测到的目标值，模型给出的预测值则记为 $\hat{y}_i$，两者需要区分。标签也可能含有观测噪声，并不一定是完全精确的真值。

将 n 个输入与各自的标签配对，得到训练集

$$\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}. \tag{3.2}$$

训练的目的是根据这些已知配对学习从输入到目标的关系，再对新输入预测尚未知的标签。这属于监督学习。对未来量的预测，输入只能包含预测时刻已经可用的信息，未来的目标观测只能作为历史样本的标签，不能提前放入输入。

例：根据当前读数预测下一小时温度。 在每个历史预测时刻，记录设备当前的温度和振动，并将下一小时实际测得的温度作为标签：

$$\boldsymbol{x}_i = (\text{当前温度}_i, \text{当前振动}_i)^{\mathsf{T}} \in \mathbb{R}^2, \qquad y_i = \text{下一小时温度}_i. \tag{3.3}$$

这个例子中 $d = 2$，每一对 $(\boldsymbol{x}_i, y_i)$ 对应一次历史预测及其后续观测。训练完成后，给出新的当前温度和振动读数，模型便输出对下一小时温度的预测。

模型结构与参数各是什么。 回归模型先写成

$$f_{\boldsymbol{w},b}(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b. \tag{3.4}$$

“加权求和再加截距”构成模型结构，$\boldsymbol{w}$ 和 b 是要从数据中学习的参数。输入 $\boldsymbol{x}$ 与历史标签 y 属于数据。例如，两个权重为 $0.8, 0.2$、截距为 1 时，预测就是 $0.8x_1 + 0.2x_2 + 1$；训练过程确定这些参数，已经观测到的读数则保持不变。

基函数：先表示输入，再在线性空间中学习。 更一般地，可先将原始输入映射为 M 个预先规定的特征（basis functions，基函数）

$$\boldsymbol{\phi}(\boldsymbol{x}) = (\phi_1(\boldsymbol{x}), \dots, \phi_M(\boldsymbol{x}))^{\mathsf{T}}, \qquad f_{\boldsymbol{w}}(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{\phi}(\boldsymbol{x}). \tag{3.5}$$

这时“线性”始终是指 $f_{\boldsymbol{w}}$ 对参数 $\boldsymbol{w}$ 线性，并不要求 ϕ_j 对原始输入线性。对一维温度读数 x，可取 $\boldsymbol{\phi}(x) = (1, x, x^2)^{\mathsf{T}}$，得到二次曲线；对振动窗口，可将均方根、峭度、频带能量或某个频率分量作为不同的 ϕ_j。基函数负责规定模型能够看见和组合什么模式，权重负责根据标签决定这些模式各占多大作用。若基函数由训练数据本身估计，例如标准化均值、PCA 投影或特征选择规则，则它们也必须只在训练部分拟合，再应用于验证和测试数据。

给定 n 个输入后，式(3.5)形成的设计矩阵为 $\Phi \in \mathbb{R}^{n\times M}$，其中 $\Phi_{ij} = \phi_j(\boldsymbol{x}_i)$。为避免符号重复，后续仍用 X 表示这个已经形成的设计矩阵。因此，改变原始特征或加入非线性基函数，改变的是 X 的列；最小二乘、岭回归和贝叶斯线性回归的参数推导仍沿用同一套形式。线性模型也因此能够成为许多复杂表示的基础层。

以下推导都可以自然包含截距。令增广特征为 $\tilde{\boldsymbol{x}}_i = (\boldsymbol{x}_i^{\mathsf{T}}, 1)^{\mathsf{T}}$、增广参数为 $\tilde{\boldsymbol{w}} = (\boldsymbol{w}^{\mathsf{T}}, b)^{\mathsf{T}}$，则 $\tilde{\boldsymbol{w}}^{\mathsf{T}}\tilde{\boldsymbol{x}}_i = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i + b$。也就是说，只需在设计矩阵 X 中增加一列全为 1 的固定特征，后续的最小二乘、似然和后验推导无需改变。为使符号简洁，后文仍用 $X, \boldsymbol{w}$ 表示已经增广后的矩阵和参数向量；若加入岭惩罚或高斯先验，通常将截距对应坐标排除在惩罚或收缩之外。

3.2 第一种视角：确定性判别模型

3.2.1 线性回归：直接输出一个数

给定一组参数，模型直接输出 $\hat{y}_i = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i$。这里的“确定性”只描述输入和参数固定时输出的状态；真实观测仍可能含有噪声，训练数据改变后参数也会随之改变。

模型已经规定了允许怎样预测，还需要目标函数规定怎样比较预测。选择平方损失

$$\ell_i = \frac{1}{2}(\boldsymbol{w}^\top \boldsymbol{x}_i - y_i)^2, \qquad \hat{R}(\boldsymbol{w}) = \frac{1}{n}\sum_{i=1}^{n} \ell_i. \tag{3.6}$$

单个样本的损失衡量一次预测偏差，经验风险是训练样本损失的平均值。平方让正负偏差不会抵消，也使较大的偏差受到更强惩罚。平方损失体现了我们对错误代价的选择，并非线性模型结构唯一规定的损失。

一个简单的手算例子。 为便于手算，暂时只保留一个输入，取 $(x_1, y_1) = (1, 2)$、$(x_2, y_2) = (2, 3)$，模型为 $\hat{y} = wx$。本章用损失之和写训练目标：

$$J(w) = \frac{1}{2}[(w-2)^2 + (2w-3)^2]. \tag{3.7}$$

求导得到 $J'(w) = (w-2) + 2(2w-3) = 5w - 8$。令导数为零，得到 $\hat{w} = 8/5$，两个预测分别为 1.6 和 3.2。它没有逐点穿过观测，却使总平方误差最小。这就是从数据、模型和损失走到参数估计的完整过程。

线性回归最小二乘的矩阵表示——正规方程。 把每个 $\boldsymbol{x}_i^\top$ 排成设计矩阵 $X \in \mathbb{R}^{n\times d}$ 的一行，将标签排成 $\boldsymbol{y} \in \mathbb{R}^n$，则

$$J(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2. \tag{3.8}$$

梯度为 $X^\top(X\boldsymbol{w} - \boldsymbol{y})$，令它为零得到**正规方程** (normal equations)

$$X^\top X \hat{\boldsymbol{w}} = X^\top \boldsymbol{y}. \tag{3.9}$$

当 X 的列线性无关时，$X^\top X$ 可逆，解唯一。若两个特征列完全相同，数据只能确定它们系数的和，不能区分各自的系数，这称为参数不可识别：不同参数取值产生相同的观测预测关系。公式可以写成逆矩阵形式，但实际计算通常用矩阵分解求解，而不显式求逆。

这个条件也把样本数与特征数的关系说清楚了。对 $X \in \mathbb{R}^{n\times d}$，$X^\top X$ 可逆当且仅当 X 有满列秩，即 $\operatorname{rank}(X) = d$。因此 $n \geq d$ 只是可逆的必要

条件，并非充分条件：即使样本数不少于特征数，重复或线性相关的特征列仍会使矩阵不可逆。反过来，若 $n < d$，则

$$\operatorname{rank}(X) \le n < d. \tag{3.10}$$

于是 X 不可能满列秩，必存在非零向量 $\boldsymbol{v}$ 满足 $X\boldsymbol{v} = \mathbf{0}$，从而 $X^{\mathsf{T}}X\boldsymbol{v} = \mathbf{0}$；所以 $X^{\mathsf{T}}X$ 必定不可逆。直观地说，参数个数多于训练样本时，仅凭这些样本无法唯一确定每个权重。

不可逆与病态：解是否唯一，与解是否稳定。 正规方程的矩阵不可逆，意味着参数不能由数据唯一确定，并不意味着最小二乘问题无解。若特征列完全共线，或样本数不足以约束所有参数，X 就不满列秩。此时若 $\hat{\boldsymbol{w}}$ 是一个最小二乘解，则对任意满足 $X\boldsymbol{v} = \mathbf{0}$ 的向量 $\boldsymbol{v}$，$\hat{\boldsymbol{w}} + \boldsymbol{v}$ 也给出相同的训练集预测。问题在于数据不能唯一识别参数，而非最小二乘目标没有最优解。可以删除冗余特征、重新参数化，或用 Moore–Penrose 伪逆选取最小范数解 $X^{+}\boldsymbol{y}$.

与此同时，更容易被忽略的是：X 满列秩，解在数学上唯一，但特征近似共线，使某些参数方向只受到数据很弱的约束。令 $A = X^{\mathsf{T}}X$，其特征分解为

$$A = Q\,\operatorname{diag}(\mu_1, \dots, \mu_d)Q^{\mathsf{T}}, \qquad \mu_j > 0, \qquad Q^{\mathsf{T}}Q = I. \tag{3.11}$$

记 Q 的第 j 列为 $\boldsymbol{q}_j$，则

$$A^{-1} = \sum_{j=1}^{d} \frac{1}{\mu_j}\boldsymbol{q}_j\boldsymbol{q}_j^{\mathsf{T}}. \tag{3.12}$$

固定 X，若正规方程的右端 $\boldsymbol{b} = X^{\mathsf{T}}\boldsymbol{y}$ 受到扰动 $\delta\boldsymbol{b}$，参数变化恰好为

$$\delta\boldsymbol{w} = A^{-1}\delta\boldsymbol{b} = \sum_{j=1}^{d} \frac{\boldsymbol{q}_j^{\mathsf{T}}\delta\boldsymbol{b}}{\mu_j}\boldsymbol{q}_j. \tag{3.13}$$

因此，小特征值方向上的右端扰动会被放大 $1/\mu_j$ 倍。标签若发生小扰动 $\delta\boldsymbol{y}$，右端就相应变化为 $\delta\boldsymbol{b} = X^{\mathsf{T}}\delta\boldsymbol{y}$。当矩阵病态时，标签中的小扰动也可能使求出的权重发生很大变化。实际标签通常含有测量误差、记录误差或其他观测噪声，不能把它们当作完全精确的数值。因此，矩阵可逆只保证解唯一，不保证解可靠；病态矩阵会使参数估计对标签噪声敏感。

为什么正规方程也是正交投影条件。 所有可由该模型给出的训练集预测向量构成 X 的列空间

$$\mathcal{C}(X) = \{X\boldsymbol{w} : \boldsymbol{w} \in \mathbb{R}^d\} \subseteq \mathbb{R}^n. \tag{3.14}$$

最小二乘的搜索范围限定在 $\mathcal{C}(X)$：预测向量必须来自这个列空间，而不能在 $\mathbb{R}^n$ 中任意选取一个接近 $\boldsymbol{y}$ 的向量。令残差为 $\boldsymbol{r} = \boldsymbol{y} - X\hat{\boldsymbol{w}}$。从预测向量 $X\hat{\boldsymbol{w}}$ 沿列空间中的任意方向 $X\boldsymbol{v}$ 作一个微小移动，平方残差不能在一阶继续下降，因此

$$0 = \frac{\mathrm{d}}{\mathrm{d}\epsilon}\frac{1}{2}\|\boldsymbol{r} - \epsilon X\boldsymbol{v}\|_2^2\Big|_{\epsilon=0} = -\boldsymbol{v}^{\mathsf{T}}X^{\mathsf{T}}\boldsymbol{r} \quad \text{对任意}\boldsymbol{v}. \tag{3.15}$$

故 $X^{\mathsf{T}}\boldsymbol{r} = 0$，这就是式(3.9)。从几何上看，拟合向量 $X\hat{\boldsymbol{w}}$ 是 $\boldsymbol{y}$ 到列空间的正交投影，残差垂直于每一列特征。若 X 秩不足，不同权重可生成同一个投影向量；因此训练集上的最佳预测唯一，但参数表示未必唯一。选择最小范数解 $X^{+}\boldsymbol{y}$，是在这些同样拟合训练数据的参数中选取一个代表，不改变最优的训练拟合。这里有两个需要分别观察的问题：数据能否唯一确定参数，以及求出的参数对扰动是否稳定。下面先说明实际软件怎样求解这个线性最小二乘问题，再在拟合要求之外加入对参数的偏好，看看它怎样缓解病态情况下参数对标签噪声的敏感性。

3.2.2 实际计算：用矩阵分解解方程，而不是求逆

正规方程给出了一个清晰的数学条件，但它不是计算机实现线性回归时的首选操作流程。若直接写成

$$\hat{\boldsymbol{w}} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}\boldsymbol{y}, \tag{3.16}$$

就需要显式构造逆矩阵。实际数值线性代数中通常只需解线性方程组：给定矩阵 A 和右端 $\boldsymbol{b}$，求满足 $A\boldsymbol{w} = \boldsymbol{b}$ 的 $\boldsymbol{w}$，而不计算 A^{-1}。原因有三点：求逆通常需要更多运算和内存；数值误差会被不必要地放大；得到逆矩阵也没有为后续预测提供额外好处。

Cholesky：适合已经形成的正规方程。 当 X 满列秩时，$A = X^{\mathsf{T}}X$ 是对称正定矩阵，可以分解为

$$A = LL^{\mathsf{T}}, \tag{3.17}$$

其中 L 是对角线为正的下三角矩阵。求解正规方程只需依次解两个三角方程：

$$L\boldsymbol{z} = X^{\mathsf{T}}\boldsymbol{y}, \qquad L^{\mathsf{T}}\hat{\boldsymbol{w}} = \boldsymbol{z}. \tag{3.18}$$

三角方程可以从前往后、再从后往前代入，整个过程不需要求逆。不过，形成 $X^{\mathsf{T}}X$ 会使条件数大致平方：$\kappa(X^{\mathsf{T}}X) = \kappa(X)^2$。因此，Cholesky 适合规模较小且已经确认数值条件良好的问题，不是普通最小二乘的默认首选。

QR：通常的最小二乘默认方法。 对 X 直接作 QR 分解

$$X = QR, \qquad Q^{\mathsf{T}}Q = I, \tag{3.19}$$

其中 Q 的列正交，R 是上三角矩阵。由最小二乘的正交投影条件，先计算

$$Q^{\mathsf{T}}\boldsymbol{y}, \tag{3.20}$$

再解三角方程

$$R\hat{\boldsymbol{w}} = Q^{\mathsf{T}}\boldsymbol{y}. \tag{3.21}$$

QR 不必显式形成 $X^{\mathsf{T}}X$，所以通常比“先构造正规方程再求解”更稳定。实际库一般使用 Householder 变换，而不是逐列手工构造 Q，因为 Householder 变换能在保持正交性的同时减少舍入误差。

SVD：处理病态或秩不足问题。 若特征高度相关、列不满秩，或者需要判断哪些方向实际上由数据支持，可使用奇异值分解

$$X = U\Sigma V^{\mathsf{T}}. \tag{3.22}$$

若奇异值为 σ_j，最小二乘解可写为

$$\hat{\boldsymbol{w}} = V\Sigma^{+}U^{\mathsf{T}}\boldsymbol{y}, \qquad \Sigma^{+}_{jj} = \begin{cases} 1/\sigma_j, & \sigma_j > \text{容差}, \\ 0, & \sigma_j \le \text{容差}. \end{cases} \tag{3.23}$$

若只将零奇异值对应的项置零，该表达式给出原问题的最小范数解。若还截断非零的小奇异值，就改变了估计规则，得到的是截断 SVD 解，未必是原问题的最小二乘解。SVD 的计算成本通常高于 QR，但能直接显示各方向的奇异值，适合诊断病态性和处理秩不足。这里的“容差”是数值判据，不是把小奇异值方向无条件当成真实无关；阈值仍应结合尺度、噪声和验证结果选择。

大规模问题：迭代法。 当 X 稀疏、样本或特征数量很大时，软件可能不显式存储分解，而使用 LSQR（Least Squares QR，最小二乘 QR）和 LSMR（Least Squares Minimal Residual，最小残差最小二乘）等迭代方法，通过计算 $X\boldsymbol{v}$ 和 $X^{\mathsf{T}}\boldsymbol{u}$ 逐步逼近最小二乘解。若求解对称正定的岭回归系统，也可使用共轭梯度法。迭代法需要设置停止条件，并监控残差、迭代次数和验证集表现；它不是因为“不能求逆”才使用，而是为了避免大规模矩阵分解的时间和内存成本。

岭回归的数值实现。 岭回归的方程为

$$(X^{\mathsf{T}}X + \lambda I)\hat{\boldsymbol{w}}_{\lambda} = X^{\mathsf{T}}\boldsymbol{y}. \tag{3.24}$$

它可以用 Cholesky 求解，但同样不必显式构造逆矩阵。更稳定的做法是把问题改写为增广最小二乘：

$$\min_{\boldsymbol{w}} \left\| \begin{bmatrix} X \\ \sqrt{\lambda} I \end{bmatrix} \boldsymbol{w} - \begin{bmatrix} \boldsymbol{y} \\ \boldsymbol{0} \end{bmatrix} \right\|_2^2, \tag{3.25}$$

然后直接对增广矩阵使用 QR 或 SVD。若截距不应正则化，只需将对应的 $\sqrt{\lambda}$ 行删除或置为零。

这些方法对应不同的计算条件。普通最小二乘可优先考虑 QR，需要诊断数值秩或处理秩不足时可使用 SVD。已经形成且条件良好的对称正定系统适合 Cholesky，超大规模或稀疏问题则适合相应的迭代法。实现时应调用最小二乘或线性方程求解接口，以避免不必要的显式求逆。求解后还应检查残差 $\|X\hat{\boldsymbol{w}}-\boldsymbol{y}\|_2$、数值秩和验证集误差，不能只因为程序返回了一个向量就认为结果可靠。

3.2.3 正则化：在拟合之外加入偏好

只追求训练误差小，可能得到对数据扰动敏感的权重。岭回归在平方损失之外加入二次惩罚 [32]：

$$J_\lambda(\boldsymbol{w})=\frac{1}{2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2+\frac{\lambda}{2}\|\boldsymbol{w}\|_2^2,\qquad \lambda\ge 0. \tag{3.26}$$

第一项要求解释数据，第二项在拟合效果相近时偏好较小的权重。与前面用伪逆从原有最小二乘解中选取最小范数代表不同，有限强度的岭惩罚改变了优化目标，通常也改变最优的训练拟合。因此，岭惩罚是为了控制参数而引入的建模选择；矩阵不可逆时，可以根据问题目标决定是否采用它。对参数求导，得到

$$(X^{\mathsf{T}}X+\lambda I)\hat{\boldsymbol{w}}_\lambda=X^{\mathsf{T}}\boldsymbol{y}, \tag{3.27}$$

其中 I 是 $d\times d$ 单位矩阵。$\lambda>0$ 时，无截距模型的这个解唯一，即使特征列相关也可以求出。

岭回归的作用不仅是让矩阵可逆，更是在数据约束薄弱的方向上抑制过大的权重。若所有坐标均受惩罚，$X^{\mathsf{T}}X+\lambda I$ 的特征值为 $\mu_j+\lambda$，求解时相应的放大因子从 $1/\mu_j$ 变为 $1/(\mu_j+\lambda)$，从而减弱小特征值方向上的噪声放大。但它通过改变估计目标换取稳定性，会引入收缩偏差。若截距不受惩罚，上述统一平移所有特征值的结论不直接适用，可先中心化数据，再对特征权重讨论这一结论。

Lasso：用 ℓ_1 惩罚实现变量选择。 Lasso（Least Absolute Shrinkage and Selection Operator，最小绝对收缩与选择算子）使用绝对值惩罚：

$$J_{\text{lasso}}(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda\|\boldsymbol{w}\|_1, \qquad \|\boldsymbol{w}\|_1 = \sum_{j=1}^{d} |w_j|. \tag{3.28}$$

ℓ_1 惩罚在零点不可微，其次梯度条件允许某些 w_j 恰好等于零，因此 Lasso 不仅收缩系数，还能产生稀疏模型。它适合特征很多、希望进行变量筛选的场景，但当特征高度相关时，可能任意保留其中一列而丢弃其他列，选择结果会对数据扰动敏感。Lasso 通常不能像岭回归那样通过一个线性方程组直接求解，而使用坐标下降、近端梯度或其他凸优化方法。

Elastic Net：在稀疏与稳定之间折中。 Elastic Net（弹性网络）同时加入 ℓ_1 和 ℓ_2 惩罚：

$$J_{\text{EN}}(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda_1\|\boldsymbol{w}\|_1 + \frac{\lambda_2}{2}\|\boldsymbol{w}\|_2^2, \qquad \lambda_1, \lambda_2 \geq 0. \tag{3.29}$$

ℓ_1 项鼓励零系数，ℓ_2 项缓解共线特征之间的不稳定性，并倾向于让相关特征成组保留。$\lambda_1 = 0$ 时退化为岭回归，$\lambda_2 = 0$ 时退化为 Lasso。两个超参数必须在验证数据上选择，不能只根据训练误差决定。

Group Lasso：按组进行结构化选择。 当特征天然分成组，例如一个类别变量展开出的哑变量、同一传感器产生的一组频域特征，可以使用 Group Lasso：

$$J_{\text{group}}(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda \sum_{g=1}^{G} \alpha_g \|\boldsymbol{w}_g\|_2. \tag{3.30}$$

其中 $\boldsymbol{w}_g$ 是第 g 组系数，α_g 用于校正不同组的大小。该惩罚倾向于让整组系数同时为零，因此比普通 Lasso 更符合“选择或删除一个特征组”的先验结构。组内若还需要进一步稀疏，可以使用稀疏组 Lasso，同时加入组级 ℓ_2 范数和元素级 ℓ_1 范数。

非凸惩罚：减少过度收缩。 Lasso 对较大的系数仍施加线性增长的惩罚，可能把真正重要的系数收缩得过小。SCAD（Smoothly Clipped Absolute Deviation，平滑截断绝对偏差）和 MCP（Minimax Concave Penalty，极小最大凹惩罚）等非凸惩罚会让惩罚在系数较大时逐渐减弱，从而减少收缩偏差：

$$J(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \sum_{j=1}^{d} p_\lambda(|w_j|). \tag{3.31}$$

它们可能比 Lasso 更接近变量选择的目标，但优化问题通常不再是凸的，容易依赖初始化并陷入局部最优。因此，较小的偏差要以更复杂、更不稳定的优化过程为代价。

约束式正则化与早停。 惩罚形式也可以改写为约束形式，例如 Lasso 等价于在适当的 λ 下求解

$$\min_{\boldsymbol{w}} \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2 \quad \text{subject to} \quad \|\boldsymbol{w}\|_1 \le t. \tag{3.32}$$

在神经网络等迭代优化模型中，限制训练轮数的早停也可产生正则化效果：参数尚未完全拟合训练噪声时停止，相当于限制了模型有效复杂度，但它不是显式的参数范数惩罚，必须通过验证集选择停止时刻。

这些方法的侧重点可以概括为：岭回归主要降低方差并稳定共线特征，Lasso 主要产生元素级稀疏性，Elastic Net 兼顾稀疏与相关特征稳定性，Group Lasso 利用已知的分组结构，SCAD 和 MCP 减少大系数的收缩偏差。正则化并非越强越好；增大惩罚通常降低方差，却会增加偏差，最终取值应依据独立验证结果和实际错误代价确定。

处理这类问题时，应区分三个目的：完全共线时，删除冗余列、重新参数化或选取伪逆解，可以处理参数表示不唯一；计算普通最小二乘时，QR 或 SVD 分解可以避免显式求逆及构造正规方程造成的额外数值误差，但无法消除数据本身的敏感性；若希望降低噪声引起的参数波动，则可依据验证结果选择岭惩罚、截断小奇异值，或补充能区分相关特征的数据。后两类收缩处理改变了估计规则，需要评估稳定性与偏差的取舍。因此，“不可

逆”并不自动意味着必须使用岭回归，“已经求出唯一解”也不足以保证估计结果可靠。

在刚才的例子中，$X^{\mathsf{T}}X=5$、$X^{\mathsf{T}}\boldsymbol{y}=8$，因此 $\hat{w}_\lambda=8/(5+\lambda)$。取 $\lambda=3$，权重从 1.6 缩为 1，预测变成 $1,2$。训练误差变大了，但权重也更小了；是否因此更适合新数据，要用未参与拟合的数据检验，不能只凭惩罚项判断。

λ 是控制学习偏好的超参数，而 $\boldsymbol{w}$ 是给定这个偏好后学出的参数。选择 λ 通常需要验证数据。惩罚还受特征单位影响，因此一般先按训练数据的统计量调整特征尺度。若改用平均损失，目标中的相同数值 λ 不再代表同样的惩罚强度：$\hat{R}+\lambda\|\boldsymbol{w}\|^2/2$ 乘以 n 后，对应的求解矩阵是 $X^{\mathsf{T}}X+n\lambda I$。以下推导都沿用损失求和的约定。

3.3 第二种视角：输出有分布，参数取一个确定值

3.3.1 概率回归：把线性输出作为均值

现在不只说“预测为 $\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}$”，还假设给定输入后，观测在这个均值附近波动：

$$Y=\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}+\varepsilon,\qquad \varepsilon\sim\mathcal{N}(0,\sigma^2),\qquad Y\mid\boldsymbol{x},\boldsymbol{w}\sim\mathcal{N}(\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x},\sigma^2). \tag{3.33}$$

这里 $\mathcal{N}$ 表示高斯分布，$\sigma^2>0$ 是噪声方差。随机性放在标签 Y 上；参数 $\boldsymbol{w}$ 和噪声方差 σ^2 都是模型中需要确定的量。为了先看清权重的求解过程，下面先暂时固定 σ^2，随后再对它进行最大似然估计。训练后，点估计模型保存的是确定的 $\hat{\boldsymbol{w}}$ 和 $\hat{\sigma}^2$。

假设给定输入和参数后，各样本的观测噪声相互独立。对第 i 个样本，前面的高斯观测模型给出条件密度

$$p(y_i\mid\boldsymbol{x}_i,\boldsymbol{w})=\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left[-\frac{(y_i-\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2}{2\sigma^2}\right]. \tag{3.34}$$

其中 y_i 是已经观测到的数值，$\boldsymbol{x}_i$ 是已知输入，$\boldsymbol{w}$ 是待比较的参数。指数中的平方项衡量模型均值 $\boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i$ 与标签 y_i 之间的差异；差异越大，该参数对这条观测分配的密度越小。

独立性使得 n 条观测的联合条件密度等于各项密度的乘积。把式(3.34)代入，得到条件似然

$$L(\boldsymbol{w}) = \prod_{i=1}^{n} p(y_i \mid \boldsymbol{x}_i, \boldsymbol{w}) \tag{3.35}$$

$$= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(y_i - \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2}{2\sigma^2}\right] \tag{3.36}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2\right]. \tag{3.37}$$

最后一行用了两个基本运算规则：相同的常数相乘得到 $(2\pi\sigma^2)^{-n/2}$，指数函数的乘积等于指数中各项之和。把各样本残差排成向量，注意

$$\sum_{i=1}^{n}(y_i - \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x}_i)^2 = \|X\boldsymbol{w} - \boldsymbol{y}\|_2^2, \tag{3.38}$$

因此也可以写成

$$L(\boldsymbol{w}) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2\right]. \tag{3.39}$$

这里需要区分联合概率密度与似然函数。若把参数 $\boldsymbol{w}$ 固定，把可能出现的标签 $(y_1, \ldots, y_n)$ 看作变量，则

$$p(\boldsymbol{y} \mid X, \boldsymbol{w}) = \prod_{i=1}^{n} p(y_i \mid \boldsymbol{x}_i, \boldsymbol{w}) \tag{3.40}$$

是给定模型参数后，观测数据的联合条件密度；对所有可能的 $\boldsymbol{y}$ 积分，它的总量为 1。而训练时，标签 $\boldsymbol{y}$ 已经观测到，变化的是待估计的参数，于是把同一个表达式看作参数 $\boldsymbol{w}$ 的函数：

$$L(\boldsymbol{w}; \boldsymbol{y}, X) = p(\boldsymbol{y} \mid X, \boldsymbol{w}). \tag{3.41}$$

这就是**“似然函数”**(likelihood function)。它用来比较不同参数对当前数据的解释程度，但不把 $\boldsymbol{w}$ 本身看作随机变量，也不要求似然对 $\boldsymbol{w}$ 积分为 1。因此，联合概率密度和似然函数可以写成同一个数学表达式，区别在于哪一个量被视为变量，以及概率归一化针对哪个对象。为避免直接处理很小的乘积，通常取对数：

$$\log L(\boldsymbol{w}) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2, \tag{3.42}$$

$$-\log L(\boldsymbol{w}) = \frac{n}{2}\log(2\pi\sigma^2) + \frac{1}{2\sigma^2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.43}$$

取负号后，最大化似然就等价于最小化**“负对数似然”**（Negative Log-Likelihood）。先固定 σ^2，由于第一项与 $\boldsymbol{w}$ 无关，且 $1/(2\sigma^2)$ 是正常数，关于 $\boldsymbol{w}$ 的最大似然估计等价于最小化平方误差 $\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2$。因此

$$\hat{\boldsymbol{w}}_{\mathrm{ML}} = \arg\min_{\boldsymbol{w}} \|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.44}$$

当 X 满列秩时，它就是正规方程的唯一解；若 X 秩不足，则可用伪逆选取一个最小二乘解。

现在同时估计噪声方差。令

$$\mathrm{SSE}(\boldsymbol{w}) = \|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.45}$$

将 $\boldsymbol{w}$ 固定为某个值，把负对数似然看作 σ^2 的函数：

$$\mathcal{L}(\sigma^2) = \frac{n}{2}\log(2\pi\sigma^2) + \frac{\mathrm{SSE}(\boldsymbol{w})}{2\sigma^2}. \tag{3.46}$$

令 $v=\sigma^2$，对 v 求导得到

$$\frac{\mathrm{d}\mathcal{L}}{\mathrm{d}v} = \frac{n}{2v} - \frac{\mathrm{SSE}(\boldsymbol{w})}{2v^2}. \tag{3.47}$$

令导数为零，并利用 $v>0$，有

$$\hat{v} = \frac{\mathrm{SSE}(\boldsymbol{w})}{n}, \qquad \hat{\sigma}^2(\boldsymbol{w}) = \frac{1}{n}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2. \tag{3.48}$$

二阶导数为

$$\frac{\mathrm{d}^2\mathcal{L}}{\mathrm{d}v^2} = -\frac{n}{2v^2} + \frac{\mathrm{SSE}(\boldsymbol{w})}{v^3}. \tag{3.49}$$

当 $\mathrm{SSE}(\boldsymbol{w}) > 0$ 时，驻点 $\hat{v} = \mathrm{SSE}(\boldsymbol{w})/n$ 位于允许的参数范围内，二阶导数为 $n/(2\hat{v}^2) > 0$。一阶导数在该点左侧为负、右侧为正，因此它是负对数似然的全局最小点，也是似然的全局最大点。残差为零的边界情形将在下文单独讨论。

将权重取为最小二乘解 $\hat{\boldsymbol{w}}_{\mathrm{ML}}$，得到联合最大似然估计

$$\boxed{\hat{\sigma}^2_{\mathrm{ML}} = \frac{1}{n}\|X\hat{\boldsymbol{w}}_{\mathrm{ML}} - \boldsymbol{y}\|_2^2}, \qquad \hat{\sigma}_{\mathrm{ML}} = \sqrt{\hat{\sigma}^2_{\mathrm{ML}}}. \tag{3.50}$$

它是训练样本残差平方和的平均值，也就是残差均方。

噪声方差的无偏估计。 最大似然方差估计一般会低估噪声方差。无偏估计（unbiased estimation）要求在相同模型下反复抽取数据时，估计量的期望等于待估计的固定参数。例如，对噪声方差 σ^2，无偏性是 $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$。这里随机变化的是训练数据及由它计算的估计量。

下面在 X 固定、满列秩且 $n > d$ 的条件下，说明为什么无偏方差估计的分母为 $n - d$。d 表示实际估计的系数总数；若包含截距，也要计入。在模型

$$\boldsymbol{y} = X\boldsymbol{w}_0 + \boldsymbol{\varepsilon}, \qquad \mathbb{E}[\boldsymbol{\varepsilon}] = \boldsymbol{0}, \qquad \mathrm{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 I_n \tag{3.51}$$

下，$\boldsymbol{w}_0$ 表示真实的线性系数。X 满列秩时，最小二乘拟合向量是

$$X\hat{\boldsymbol{w}}_{\mathrm{ML}} = P_X\boldsymbol{y}, \qquad P_X = X(X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}, \tag{3.52}$$

其中 P_X 是投影到 X 的列空间的矩阵。因此残差为

$$\boldsymbol{e} = \boldsymbol{y} - X\hat{\boldsymbol{w}}_{\mathrm{ML}} = (I_n - P_X)\boldsymbol{y} = (I_n - P_X)\boldsymbol{\varepsilon}. \tag{3.53}$$

这里 $(I_n - P_X)$ 也是投影矩阵，且它的秩为 $n - d$：拟合过程已经用 X 的 d 个独立列方向解释了 d 个自由度，残差只保留其余 $n - d$ 个方向。利用

$\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^{\mathsf{T}}] = \sigma^2 I_n$，有

$$\begin{aligned}\mathbb{E}[\|\boldsymbol{e}\|_2^2] &= \mathbb{E}[\boldsymbol{\varepsilon}^{\mathsf{T}}(I_n - P_X)\boldsymbol{\varepsilon}] && (3.54)\\ &= \operatorname{tr}\left((I_n - P_X)\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^{\mathsf{T}}]\right) && (3.55)\\ &= \sigma^2 \operatorname{tr}(I_n - P_X) && (3.56)\\ &= (n-d)\sigma^2. && (3.57)\end{aligned}$$

因此，将残差平方和除以 $n-d$ 后，其期望正好等于真实噪声方差：

$$\hat{\sigma}^2_{\text{unbiased}} = \frac{\|X\hat{\boldsymbol{w}}_{\text{ML}} - \boldsymbol{y}\|_2^2}{n-d}, \qquad \mathbb{E}[\hat{\sigma}^2_{\text{unbiased}}] = \sigma^2. \tag{3.58}$$

这就是它被称为无偏估计的原因。两种估计的用途不同：$\hat{\sigma}^2_{\text{ML}}$ 用于最大化当前高斯似然，分母为 n；$\hat{\sigma}^2_{\text{unbiased}}$ 用于无偏估计真实噪声方差，分母为剩余自由度 $n-d$。若最小二乘残差为零，例如 $n = d$ 且 X 可逆，似然会随 $\sigma^2 \to 0$ 而无界增大。在本章 $\sigma^2 > 0$ 的参数空间内，此时不存在有限的方差最大似然解，不能把零残差解释为未来观测没有噪声。$n = d$ 时，无偏方差公式的分母也为零，无法使用。实际应用中还需要独立数据或交叉验证检查误差与噪声假设。

平方损失既可以直接作为错误度量，也可以从高斯观测假设推导出来；概率解释还补充了关于观测噪声的具体假设。

训练完成后，模型输出 $\mathcal{N}(\hat{\boldsymbol{w}}^{\mathsf{T}}\boldsymbol{x}_*, \sigma^2)$。星号表示新输入。需要一个数值时可取其均值；需要描述观测波动时则保留分布。这里尚未将有限数据导致的参数不确定性纳入预测。

3.4 第三种视角：参数也用分布表示

3.4.1 先验与后验：不再只选一组权重

前面两种方法训练后都保存一组参数。只有少量数据时，可能仍有其他权重能够合理解释观测。贝叶斯回归用参数分布保留这种不确定性 [7, 61]。

这里把参数写成随机量，是为了表达我们对未知系数的认识；设备的真实系数并不会因此在每次预测时改变。

仍采用高斯观测模型，并为权重指定零均值高斯先验：

$$\boldsymbol{w} \sim \mathcal{N}(\mathbf{0}, \tau^2 I), \qquad \boldsymbol{y} \mid X, \boldsymbol{w} \sim \mathcal{N}(X\boldsymbol{w}, \sigma^2 I_n), \tag{3.59}$$

其中 $\tau^2 > 0$ 描述先验允许权重偏离零的程度，I_n 是 $n \times n$ 单位矩阵。本章把 τ^2 和 σ^2 都作为给定的超参数，先看清参数分布怎样更新。训练输入 X 作为已知条件，不对输入的产生过程建模，因此这里仍属于条件判别建模；使用贝叶斯公式本身不会改变这一点。

若权重维数为 d，上述两个高斯分布写成密度分别为

$$p(\boldsymbol{y} \mid X, \boldsymbol{w}) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\|\boldsymbol{y} - X\boldsymbol{w}\|_2^2\right], \tag{3.60}$$

$$p(\boldsymbol{w}) = \frac{1}{(2\pi\tau^2)^{d/2}} \exp\left[-\frac{1}{2\tau^2}\|\boldsymbol{w}\|_2^2\right]. \tag{3.61}$$

似然的指数项衡量参数给出的均值与观测标签相差多远；先验的指数项衡量权重离零多远。两个前面的系数保证各自对相应变量积分为一。它们在比较不同 $\boldsymbol{w}$ 时看似只是常数，但在写出完整后验或计算模型证据时不能随意丢弃。

将 X 视为已知条件，贝叶斯公式写成

$$p(\boldsymbol{w} \mid \mathcal{D}) = \frac{p(\boldsymbol{y} \mid X, \boldsymbol{w}) p(\boldsymbol{w})}{\int p(\boldsymbol{y} \mid X, \boldsymbol{u}) p(\boldsymbol{u}) \, \mathrm{d}\boldsymbol{u}}. \tag{3.62}$$

分子把数据证据与原有偏好结合，分母保证后验积分为一。先验是看见本次训练标签之前的参数分布，后验是结合这些标签之后的参数分布。后验用概率密度描述许多可能的权重，并为它们赋予不同的可信程度。

3.4.2 最大后验估计：从后验中选一个点

若仍希望最终只保存一组权重，可以选择后验密度最大的点，称为最大后验估计（Maximum A Posteriori, MAP）。取负对数并舍去与权重无关

的常数，得到

$$\hat{\boldsymbol{w}}_{\mathrm{MAP}} = \arg\min_{\boldsymbol{w}} \left\{ \frac{1}{2\sigma^2}\|X\boldsymbol{w}-\boldsymbol{y}\|_2^2 + \frac{1}{2\tau^2}\|\boldsymbol{w}\|_2^2 \right\}. \tag{3.63}$$

目标乘以 σ^2 不改变最优点。因此，在本章损失求和的约定下，它就是岭回归，且

$$\lambda = \frac{\sigma^2}{\tau^2}. \tag{3.64}$$

观测噪声越大，数据的相对作用越弱；先验越集中于零，收缩越强。这给出了正则化的一种概率解释：二次惩罚可以来自零均值高斯先验的负对数。仅凭某个惩罚项本身，还不能把模型称为贝叶斯模型。

MAP 使用了先验和后验，但最终仍是点估计；它不等于保留了完整的参数分布。若直接把 MAP 权重代入概率模型，仍会省略参数不确定性对预测的影响。

3.4.3 完整后验：均值与方差都保留

在线性高斯模型中，式(3.60)与式(3.61)的乘积仍可写成高斯形式。为看清这个结论，先把后验中依赖 $\boldsymbol{w}$ 的指数项展开。忽略暂时与 $\boldsymbol{w}$ 无关的因子，有

$$p(\boldsymbol{w}\mid\mathcal{D}) \propto \exp\left\{ -\frac{1}{2}\left[\boldsymbol{w}^{\mathsf{T}}(\sigma^{-2}X^{\mathsf{T}}X+\tau^{-2}I)\boldsymbol{w} - 2\boldsymbol{w}^{\mathsf{T}}\sigma^{-2}X^{\mathsf{T}}\boldsymbol{y} \right] \right\}. \tag{3.65}$$

定义后验精度矩阵和信息向量

$$\Lambda = \sigma^{-2}X^{\mathsf{T}}X + \tau^{-2}I, \qquad \boldsymbol{h} = \sigma^{-2}X^{\mathsf{T}}\boldsymbol{y}, \tag{3.66}$$

$$S = \Lambda^{-1}, \qquad \boldsymbol{m} = S\boldsymbol{h}. \tag{3.67}$$

由于 $\Lambda\boldsymbol{m} = \boldsymbol{h}$，二次项可完成平方：

$$\boldsymbol{w}^{\mathsf{T}}\Lambda\boldsymbol{w} - 2\boldsymbol{w}^{\mathsf{T}}\boldsymbol{h} = (\boldsymbol{w}-\boldsymbol{m})^{\mathsf{T}}\Lambda(\boldsymbol{w}-\boldsymbol{m}) - \boldsymbol{m}^{\mathsf{T}}\Lambda\boldsymbol{m}. \tag{3.68}$$

最后一项不依赖 $\boldsymbol{w}$，会被贝叶斯公式分母中的证据吸收。于是归一化后的完整后验密度为

$$p(\boldsymbol{w} \mid \mathcal{D}) = \frac{1}{(2\pi)^{d/2}|S|^{1/2}} \exp\left[-\frac{1}{2}(\boldsymbol{w}-\boldsymbol{m})^{\mathsf{T}} S^{-1}(\boldsymbol{w}-\boldsymbol{m})\right], \tag{3.69}$$

即 $\boldsymbol{w} \mid \mathcal{D} \sim \mathcal{N}(\boldsymbol{m}, S)$。其中 $\boldsymbol{m}$ 是后验均值，S 是后验协方差，描述权重的不确定性及其相互关联；$|S|$ 是协方差矩阵的行列式，归一化系数保证式(3.69)对所有 $\boldsymbol{w}$ 的积分为一。高斯分布的均值恰好也是密度最高点，因此这里 $\boldsymbol{m} = \hat{\boldsymbol{w}}_{\mathrm{MAP}}$；这不表示任意后验的均值与 MAP 都相等。

新数据怎样更新已有后验。 后验也可作为下一批独立数据到来之前的先验。设已有后验为 $\mathcal{N}(\boldsymbol{m}_0, S_0)$，新到一批设计矩阵为 X_1、标签为 $\boldsymbol{y}_1$，且噪声仍为 $\mathcal{N}(\boldsymbol{0}, \sigma^2 I)$，则更新后

$$S_1^{-1} = S_0^{-1} + \sigma^{-2} X_1^{\mathsf{T}} X_1, \tag{3.70}$$

$$\boldsymbol{m}_1 = S_1\left(S_0^{-1}\boldsymbol{m}_0 + \sigma^{-2} X_1^{\mathsf{T}} \boldsymbol{y}_1\right). \tag{3.71}$$

式(3.70)揭示了独立观测的累积方式：增加的是精度（协方差的逆），方差并不会直接相加。新数据在某个权重方向上的信息由 $X_1^{\mathsf{T}} X_1$ 决定：若新记录在该方向没有变化，就无法显著降低该方向的不确定性。将全部训练数据一次代入，或将它们分批按式(3.70)–(3.71)更新，在模型假设相同且不重复计数的条件下都会得到同一个后验。这个顺序视角也提醒我们，重复复制同一条记录并不能制造独立证据。

仍用两个样本 $(1,2),(2,3)$，取 $\sigma^2 = 1$、$\tau^2 = 1/3$。此时 $\lambda = 3$，并且

$$S = (5+3)^{-1} = \frac{1}{8}, \qquad m = \frac{1}{8} \times 8 = 1, \qquad w \mid \mathcal{D} \sim \mathcal{N}(1, 1/8). \tag{3.72}$$

岭回归与 MAP 只留下 $w = 1$；完整后验还留下方差 $1/8$。三者在这个例子中可以给出相同的中心预测，但保存的信息并不相同。

3.4.4 后验预测：把参数不确定性带到新样本

对新输入 $\boldsymbol{x}_*$，贝叶斯预测要把后验中的各种权重都纳入计算，具体表现为积分：

$$p(y_* \mid \boldsymbol{x}_*, \mathcal{D}) = \int p(y_* \mid \boldsymbol{x}_*, \boldsymbol{w}) p(\boldsymbol{w} \mid \mathcal{D}) \, \mathrm{d}\boldsymbol{w}. \tag{3.73}$$

在线性高斯模型中，这个结果可以直接算出：

$$Y_* \mid \boldsymbol{x}_*, \mathcal{D} \sim \mathcal{N}(\boldsymbol{x}_*^{\mathsf{T}} \boldsymbol{m}, \underbrace{\sigma^2}_{\text{观测噪声}} + \underbrace{\boldsymbol{x}_*^{\mathsf{T}} S \boldsymbol{x}_*}_{\text{参数不确定性}}). \tag{3.74}$$

第一项是在给定权重后仍存在的观测波动，第二项是不同合理权重在新输入处产生的预测差异。也可以先看没有观测噪声的线性函数值：它的后验方差只有第二项。前者描述下一次观测本身的不确定性，后者描述我们对均值函数的不确定性，使用时需要区分。

在上述一维例子中，取 $x_* = 2$，后验预测的均值为 2，方差为 $1 + 2^2/8 = 3/2$。若只代入 MAP 权重，则得到 $\mathcal{N}(2, 1)$，省略了额外的 $1/2$。这个数值例子把“输出是概率分布”和“参数也是分布”的差别直接呈现在预测结果中。

本章的线性高斯假设使后验和预测分布都能写成闭式形式，便于看清参数不确定性怎样传递到预测中。更一般的模型可能需要近似推断，后面的贝叶斯章节再讨论这些方法。

3.5 第四种视角：从核贝叶斯线性回归到高斯过程

前面的贝叶斯线性回归把不确定性放在有限维权重 $\boldsymbol{w}$ 上。现在仍然使用同一个模型思路，只改变输入表示：先用特征函数把原始输入映射到特征空间，再对特征空间中的权重使用高斯先验。特征空间可以取任意有限维，也可以形式上扩展到无穷维。后一个变化会使我们从显式计算权重，转

向计算输入之间的核函数，最后引出高斯过程的函数空间视角。经典教材对这条联系有系统介绍 [71]。

3.5.1 先在特征空间中做贝叶斯线性回归

令 $\phi(\boldsymbol{x})$ 表示输入 $\boldsymbol{x}$ 的特征向量。与本章前面式(3.5)相同，函数写成

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathsf{T}}\phi(\boldsymbol{x}), \qquad \boldsymbol{w} \sim \mathcal{N}(\mathbf{0}, \Sigma_p). \tag{3.75}$$

如果 $\phi(\boldsymbol{x})$ 有 M 个分量，$\boldsymbol{w}$ 和 Σ_p 的维度分别是 M 和 $M \times M$。给定训练输入后形成特征矩阵 $\Phi \in \mathbb{R}^{n\times M}$，其中第 i 行是 $\phi(\boldsymbol{x}_i)^{\mathsf{T}}$。观测模型仍为

$$\boldsymbol{y} \mid \Phi, \boldsymbol{w} \sim \mathcal{N}(\Phi\boldsymbol{w}, \sigma^2 I_n). \tag{3.76}$$

因此，前面贝叶斯线性回归的后验推导完全保留，只需将 X 换成 Φ：

$$S = \left(\sigma^{-2}\Phi^{\mathsf{T}}\Phi + \Sigma_p^{-1}\right)^{-1}, \tag{3.77}$$

$$\boldsymbol{m} = S\sigma^{-2}\Phi^{\mathsf{T}}\boldsymbol{y}, \tag{3.78}$$

$$\boldsymbol{w} \mid \mathcal{D} \sim \mathcal{N}(\boldsymbol{m}, S). \tag{3.79}$$

对新输入 $\boldsymbol{x}_*$，潜在函数值的后验预测为

$$f(\boldsymbol{x}_*) \mid \boldsymbol{x}_*, \mathcal{D} \sim \mathcal{N}\left(\phi(\boldsymbol{x}_*)^{\mathsf{T}}\boldsymbol{m}, \phi(\boldsymbol{x}_*)^{\mathsf{T}}S\phi(\boldsymbol{x}_*)\right). \tag{3.80}$$

到这里，它仍然只是把原始输入换成了特征表示后的贝叶斯线性回归。

3.5.2 特征函数映射为何引出核函数

当 M 很大，直接形成 Φ 并求解 $M \times M$ 的后验系统会变得困难。更重要的是，很多有用的特征映射并没有方便写出的有限维表达式。此时可以观察预测公式中实际出现的量。定义

$$k(\boldsymbol{x}, \boldsymbol{x}') = \phi(\boldsymbol{x})^{\mathsf{T}}\Sigma_p\phi(\boldsymbol{x}'), \qquad K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j). \tag{3.81}$$

k 称为核函数。它把两个输入先映射到特征空间，再计算带有先验协方差 Σ_p 的内积。训练数据与新输入之间的核向量为 $\boldsymbol{k}_{*X} = [k(\boldsymbol{x}_*, \boldsymbol{x}_1), \ldots, k(\boldsymbol{x}_*, \boldsymbol{x}_n)]$。利用矩阵恒等式，可以将式(3.80)改写为

$$\mathbb{E}[f(\boldsymbol{x}_*) \mid \mathcal{D}] = \boldsymbol{k}_{*X}(K + \sigma^2 I_n)^{-1}\boldsymbol{y}, \tag{3.82}$$

$$\mathrm{Var}(f(\boldsymbol{x}_*) \mid \mathcal{D}) = k(\boldsymbol{x}_*, \boldsymbol{x}_*) - \boldsymbol{k}_{*X}(K + \sigma^2 I_n)^{-1}\boldsymbol{k}_{X*}. \tag{3.83}$$

这里不再需要显式构造 $\phi(\boldsymbol{x})$ 或保存 $\boldsymbol{w}$。计算从特征空间的 M 个权重转到了训练样本决定的 $n \times n$ 核矩阵。若 $M > n$，这个转换尤其有用。它也说明了“核技巧”不是凭空增加一个非线性步骤，而是利用特征空间内积的等价表达避免显式进入高维空间。

以 RBF 核为例，取

$$k(\boldsymbol{x}, \boldsymbol{x}') = \alpha^2 \exp\left(-\frac{\|\boldsymbol{x} - \boldsymbol{x}'\|_2^2}{2\ell^2}\right). \tag{3.84}$$

其中 α^2 控制函数值的变化幅度，$\ell > 0$ 是长度尺度。两个输入距离越远，核值越小，模型就越少把一个位置的观测变化传递到另一个位置。长度尺度小的模型允许函数快速变化，长度尺度大的模型偏好更平滑的函数。这个核具有一个无穷维的特征表示，但实际计算只需要核函数值。核函数必须使任意输入集合形成的矩阵半正定，即对任意向量 $\boldsymbol{a}$ 都有 $\boldsymbol{a}^{\mathsf{T}} K \boldsymbol{a} \geq 0$。

3.5.3 从核贝叶斯线性回归引出高斯过程

前面的推导已经在使用一个事实：对任意输入集合，函数值向量的协方差都由同一个核函数给出。现在把这一事实单独作为模型定义。高斯过程（Gaussian Process，GP）是定义在输入空间上的随机函数。若任取有限个输入 $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n$，函数值向量都服从多元高斯分布：

$$\begin{bmatrix} f(\boldsymbol{x}_1) \\ \vdots \\ f(\boldsymbol{x}_n) \end{bmatrix} \sim \mathcal{N}\left(\boldsymbol{m}(X), K(X, X)\right), \qquad K_{ij} = k(\boldsymbol{x}_i, \boldsymbol{x}_j). \tag{3.85}$$

由有限维高斯权重模型诱导出的核正是式(3.81)。高斯过程把这个关系推广到不必显式给出有限维特征映射的情形。此后讨论的对象从权重 $\boldsymbol{w}$ 变为函数值 $f(\boldsymbol{x})$，但高斯条件分布的计算形式仍然来自前面已经学过的贝叶斯线性回归。

3.5.4 观测数据怎样更新函数

仍以回归数据 $\mathcal{D}=\{(\boldsymbol{x}_i,y_i)\}_{i=1}^n$ 为例，假设观测包含独立高斯噪声：

$$f\sim\mathcal{GP}(m,k),\qquad y_i=f(\boldsymbol{x}_i)+\varepsilon_i,\qquad \varepsilon_i\overset{\text{i.i.d.}}{\sim}\mathcal{N}(0,\sigma^2). \tag{3.86}$$

令 $\boldsymbol{m}_X=[m(\boldsymbol{x}_1),\dots,m(\boldsymbol{x}_n)]^{\mathsf{T}}$，$K_{XX}=K(X,X)$。由于高斯分布对条件化封闭，训练标签的分布为

$$\boldsymbol{y}\mid X\sim\mathcal{N}\left(\boldsymbol{m}_X,K_{XX}+\sigma^2I_n\right). \tag{3.87}$$

这里的 σ^2I_n 只加在观测协方差上，表示每次测量的独立噪声；它不改变潜在函数 f 本身的协方差。与贝叶斯线性回归保存权重后验不同，高斯过程直接对函数值的联合分布进行更新。

对新输入集合 X_*，记 $K_{*X}=K(X_*,X)$、$K_{**}=K(X_*,X_*)$。训练数据与新位置的联合高斯分布为

$$\begin{bmatrix}\boldsymbol{y}\\ f_*\end{bmatrix}\sim\mathcal{N}\left(\begin{bmatrix}\boldsymbol{m}_X\\ \boldsymbol{m}_*\end{bmatrix},\begin{bmatrix}K_{XX}+\sigma^2I_n & K_{X*}\\ K_{*X} & K_{**}\end{bmatrix}\right). \tag{3.88}$$

对这个联合分布作条件化，得到潜在函数值的后验预测：

$$\boldsymbol{\mu}_*=\boldsymbol{m}_*+K_{*X}(K_{XX}+\sigma^2I_n)^{-1}(\boldsymbol{y}-\boldsymbol{m}_X), \tag{3.89}$$

$$\Sigma_*=K_{**}-K_{*X}(K_{XX}+\sigma^2I_n)^{-1}K_{X*}. \tag{3.90}$$

$\boldsymbol{\mu}_*$ 是新位置的函数均值，Σ_* 是对潜在函数值的不确定性。若要预测下一次带噪观测 $\boldsymbol{y}_*$，还要加入观测噪声：

$$\boldsymbol{y}_*\mid X_*,\mathcal{D}\sim\mathcal{N}(\boldsymbol{\mu}_*,\Sigma_*+\sigma^2I). \tag{3.91}$$

观测点附近通常有更多信息，后验方差会降低，但带噪观测的预测方差仍包含 σ^2。因此，训练点处的函数不确定性和下一次测量的不确定性不能混为一谈。

这些公式也说明了高斯过程回归（Gaussian Process Regression，GPR）的计算代价。训练时需要分解 $n \times n$ 矩阵 $K_{XX} + \sigma^2 I_n$，直接方法的时间复杂度通常为 $O(n^3)$，存储复杂度为 $O(n^2)$。实现时应使用 Cholesky 分解求解线性方程，不显式计算逆矩阵。样本很多时，常用诱导点或其他稀疏高斯过程近似降低代价，但近似会改变计算结果，需要用验证数据检查。

3.5.5 高斯过程回归何时适合

GPR 适合样本量中小、希望获得平滑函数预测和不确定性估计的回归任务。例如，温度传感器的历史记录不多时，可以用长度尺度表达相近工况下的温度关系，并用后验方差标出数据稀疏区域。核函数的选择、输入尺度和噪声方差仍需通过训练集以外的数据确定。高斯过程的方差只反映所选核和噪声模型下的统计不确定性，不能自动发现传感器漂移、分布变化或核函数选错等模型错误。高维、大样本任务通常需要特征降维、结构化核或稀疏近似，否则矩阵计算会成为主要限制。

3.6 把上一章的概念逐项放回例子

回顾这条线性模型主线，首先要区分几组容易混淆的对象。

- **数据与任务**：输入 $\boldsymbol{x}_i$ 是预测时可用的特征，标签 y_i 是对应的实数目标。在设备温度例子中，当前温度和振动是输入，下一小时温度是标签，任务是回归。

- **结构与参数**：加权求和是结构，权重和截距是参数。线性结构本身就是一种归纳偏置：不允许模型任意改变输入与输出的关系。

- **损失与目标**：平方损失衡量单样本的预测误差；求和后形成训练目标，

加入惩罚后则同时考虑拟合和参数偏好。

- **训练与预测：**训练用历史标签求权重或后验；预测将结果用于新输入。点估计下代入固定参数，完整贝叶斯预测则对参数后验积分。高斯过程回归直接利用核矩阵对函数值进行条件化。

- **正则化与先验：**岭惩罚可以在给定高斯似然和高斯先验时解释为 MAP。惩罚强度、先验方差和噪声方差之间的对应依赖目标的尺度约定。

- **经验风险与泛化：**这些计算决定怎样拟合已有样本，不保证新设备、新时段上的表现。验证仍然需要独立于参数拟合的数据。

四种视角可以服务于同一个回归任务：确定性函数给出一个数，固定参数的高斯模型给出条件分布，参数后验把有限维权重的不确定性带到预测中，高斯过程则直接在函数空间中表达这种不确定性。具体采用哪一种，取决于问题需要表达什么信息，也取决于可用的数据规模和建模假设。

本章只把上一章的判别模型分支具体算了一遍，并没有试图用线性回归代替所有模型类型。生成建模、隐藏变量和无监督学习改变了要描述的对象，需要另作假设。即使使用参数后验，模型结构和噪声假设也仍可能不适合数据；后验不确定性并不能自动覆盖所有建模错误。

辅助学习材料

- **Linear Models**；scikit-learn Developers；英文官方文档。阅读 Ordinary Least Squares、Ridge 与 Bayesian Regression 小节，对照本章的点预测、惩罚目标与参数不确定性。软件中损失的归一化和超参数记法可能不同，需要先核对定义。在线阅读。

- **Mathematics for Machine Learning**；Deisenroth、Faisal、Ong；英文教材。阅读线性回归相关章节，对照设计矩阵、最大似然估计与贝叶斯回归。书籍网站。

- **Gaussian Processes for Machine Learning**；Rasmussen、Williams；英文教材。阅读协方差函数、后验预测与超参数学习，对照本章的函数空间视角。在线阅读。

第四章　模型的求解

本章摘要。给定数据、任务和模型以后，还需要计算模型中的未知量。对于确定性参数模型，求解通常得到一个参数值，可以使用闭式计算、梯度方法或启发式搜索。对于随机参数模型，求解需要计算参数的后验分布。本章还讨论含隐变量的极大似然估计：此时参数仍是固定未知量，但参数更新需要隐变量的条件分布。期望最大化算法和变分推断分别说明怎样利用条件分布求参数，以及怎样用可计算的分布近似后验。

上一章讨论了训练目标和评价指标。本章接着回答：数据、任务和模型已经给定，怎样计算模型中的未知量？最小二乘回归可以通过解线性方程确定权重。含隐变量的极大似然估计需要处理未观测变量。贝叶斯学习则需要计算参数后验分布。这些问题都属于模型求解，其中一部分可以转化为优化问题。

设训练数据为 $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}$。确定性参数模型把 θ 视为固定未知量，求解通常得到点估计

$$\hat{\theta} = \arg\min_{\theta} J(\theta). \tag{4.1}$$

这里 J 是由损失和可能的正则项构成的训练目标。随机参数模型给 θ 指定先验分布，求解对象是 $p(\theta \mid \mathcal{D})$。需要注意，模型中同时存在随机参数和确定性参数是完全可能的。这一区分取决于怎样处理参数，与算法是否使用随机抽样无关；随机梯度下降仍可以用于确定性参数模型。

隐变量 $\boldsymbol{z}$ 是没有被观测、但参与数据生成的随机量。含隐变量的模型既可以用固定参数进行极大似然估计，也可以进行贝叶斯学习。因此，本章先讨论固定参数的直接计算与搜索，再讨论隐变量怎样影响极大似然求解，最后讨论随机参数的后验近似。

4.1 确定性参数模型：从目标到参数值

4.1.1 先判断是否存在直接解

第三章的线性回归采用平方损失：

$$J(\boldsymbol{w}) = \frac{1}{2}\|X\boldsymbol{w} - \boldsymbol{y}\|_2^2, \qquad \nabla J(\boldsymbol{w}) = X^{\mathsf{T}}(X\boldsymbol{w} - \boldsymbol{y}). \tag{4.2}$$

其中 $X \in \mathbb{R}^{n\times d}$ 是设计矩阵，$\boldsymbol{y} \in \mathbb{R}^n$ 是标签向量，$\boldsymbol{w} \in \mathbb{R}^d$ 是待定参数。令梯度为零，得到正规方程

$$X^{\mathsf{T}}X\hat{\boldsymbol{w}} = X^{\mathsf{T}}\boldsymbol{y}. \tag{4.3}$$

由于平方损失是凸函数，正规方程的解是全局最小点。当 X 列满秩时，解唯一，可以写为 $\hat{\boldsymbol{w}} = (X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}\boldsymbol{y}$。

这个表达式说明解的数学形式。实际计算通常对 X 进行 QR 分解或奇异值分解（Singular Value Decomposition，SVD），直接求解最小二乘问题，避免显式求逆和形成 $X^{\mathsf{T}}X$ 造成的数值误差放大。列线性相关时解不唯一，可用 SVD 求最小范数解；列接近相关时，即使解唯一，也可能对数据扰动敏感。正则化改变目标，可以改善稳定性，但其强度仍需验证。

许多非线性模型没有可用的闭式解。有闭式表达式的问题在规模很大时，也可能更适合迭代计算。接下来讨论怎样从一个初始参数出发，逐步降低目标。

4.1.2 梯度怎样给出局部改进方向

若 J 可微，小位移 Δ 引起的目标变化近似为

$$J(\theta + \Delta) - J(\theta) \approx \nabla J(\theta)^{\mathsf{T}}\Delta. \tag{4.4}$$

在欧氏长度固定的位移中，与梯度反向的位移使这个一阶变化最小。因此，梯度下降采用

$$\theta_{t+1} = \theta_t - \eta_t \nabla J(\theta_t). \tag{4.5}$$

这里 t 是更新次数，$\eta_t > 0$ 是学习率。梯度给出当前位置的局部信息，学习率决定沿该方向走多远。

对 $J(\theta) = \theta^2/2$，更新为 $\theta_{t+1} = (1 - \eta_t)\theta_t$。固定学习率满足 $0 < \eta < 2$ 时，非零参数的绝对值逐步减小；$\eta = 2$ 时参数在正负之间交替，损失不变；$\eta > 2$ 时，从非零初值出发会发散。选择下降方向以后，还需要控制步长。

更一般地，假设 J 的梯度满足 Lipschitz 连续条件：存在 $L > 0$，使

$$\|\nabla J(\boldsymbol{u}) - \nabla J(\boldsymbol{v})\|_2 \le L\|\boldsymbol{u} - \boldsymbol{v}\|_2. \tag{4.6}$$

常数 L 限制梯度随位置变化的速度。令 $\Delta = \boldsymbol{v} - \boldsymbol{u}$，沿线段积分可得

$$J(\boldsymbol{u} + \Delta) - J(\boldsymbol{u}) = \int_0^1 \nabla J(\boldsymbol{u} + s\Delta)^{\mathsf{T}}\Delta \, ds \tag{4.7}$$

$$\le \nabla J(\boldsymbol{u})^{\mathsf{T}}\Delta + \frac{L}{2}\|\Delta\|_2^2. \tag{4.8}$$

第二步把梯度拆成 $\nabla J(\boldsymbol{u})$ 与梯度差，再用柯西不等式将梯度差的内积上界为 $Ls\|\Delta\|_2^2$。代入 $\Delta = -\eta\nabla J(\boldsymbol{u})$，得到

$$J(\theta_t - \eta\nabla J(\theta_t)) \le J(\theta_t) - \eta\left(1 - \frac{L\eta}{2}\right)\|\nabla J(\theta_t)\|_2^2. \tag{4.9}$$

当 $0 < \eta < 2/L$ 且 $\nabla J(\theta_t) \neq \mathbf{0}$ 时，上式右端减去的量严格为正。因此，更新后的训练目标值严格小于更新前的目标值，即 $J(\theta_{t+1}) < J(\theta_t)$。这个结论依赖梯度的光滑性和步长范围，只保证当前更新降低目标。对于非凸目标，它不保证达到全局最优，梯度为零的点也可能是局部极小点或鞍点。

实际计算中，可以从一个试探步长开始；如果更新没有满足预定的下降条件，就缩小步长后重新计算，这称为回溯线搜索。达到步数上限、目标变化很小或梯度很小时可以停止，但需要记录具体条件。停止只表示触发了计算规则，不能单独证明已经找到最优解。

4.1.3 链式法则与神经网络的梯度计算

梯度更新要求知道每个参数对目标函数的影响。在线性回归中，这种关系可以直接写出。神经网络的参数先影响某一层的输出，再通过后续各

层影响预测值，最后影响损失。要计算较早层的参数梯度，需要把这些连续的影响连接起来。链式法则提供了计算复合函数导数的方法，反向传播则按网络的依赖顺序组织这些计算。

4.1.3.1 从一条计算链理解链式法则

设一个参数 w 先决定中间量 $a = g(w)$，再由 a 决定损失 $\ell = h(a)$。当两个函数在相应位置可微时，链式法则为

$$\frac{d\ell}{dw} = \frac{d\ell}{da}\frac{da}{dw}. \tag{4.10}$$

其中 da/dw 描述参数变化怎样影响中间量，$d\ell/da$ 描述中间量变化怎样影响损失。对足够小的变化 Δw，先有 $\Delta a \approx (da/dw)\Delta w$，再有 $\Delta \ell \approx (d\ell/da)\Delta a$。将两步连接，便得到式(4.10)中的导数乘积。

例如，固定输入 x 和标签 y，令 $a = wx + b$、$\hat{y} = \phi(a)$、$\ell = (\hat{y} - y)^2/2$。函数 ϕ 称为激活函数，用来对加权和进行非线性变换。沿 $w \to a \to \hat{y} \to \ell$ 这条计算链，有

$$\frac{\partial \ell}{\partial w} = \frac{\partial \ell}{\partial \hat{y}}\frac{\partial \hat{y}}{\partial a}\frac{\partial a}{\partial w} = (\hat{y} - y)\phi'(a)x. \tag{4.11}$$

三个因子分别来自损失函数、激活函数和加权和。偏置 b 的局部导数为 $\partial a/\partial b = 1$，所以 $\partial \ell/\partial b = (\hat{y} - y)\phi'(a)$。

网络中一个量可能影响多个后续量。若 $\ell = h(u, v)$，而 u 和 v 都依赖 w，则

$$\frac{d\ell}{dw} = \frac{\partial \ell}{\partial u}\frac{du}{dw} + \frac{\partial \ell}{\partial v}\frac{dv}{dw}. \tag{4.12}$$

因此，沿同一条路径的导数相乘，不同路径对同一变量的贡献相加。多层网络和参数共享都需要遵循这条规则。

4.1.3.2 一个两层网络的完整计算

取单个样本 $\boldsymbol{x} \in \mathbb{R}^d$ 和标量标签 y。考虑一个隐藏层和一个线性输出层：

$$\boldsymbol{a} = W_1\boldsymbol{x} + \boldsymbol{b}_1, \qquad \boldsymbol{h} = \phi(\boldsymbol{a}), \tag{4.13}$$

$$\hat{y} = \boldsymbol{w}_2^{\top}\boldsymbol{h} + b_2, \qquad \ell = \frac{1}{2}(\hat{y} - y)^2. \tag{4.14}$$

这里 $W_1 \in \mathbb{R}^{m\times d}$ 是第一层权重矩阵，$\boldsymbol{b}_1 \in \mathbb{R}^m$ 是偏置，$\boldsymbol{a} \in \mathbb{R}^m$ 是加权和，$\boldsymbol{h} \in \mathbb{R}^m$ 是隐藏层输出。激活函数 ϕ 逐坐标作用，$\boldsymbol{w}_2 \in \mathbb{R}^m$ 和 $b_2 \in \mathbb{R}$ 是输出层参数。将这些参数放在一起就得到前文的 θ。按式(4.14)从输入计算到损失，称为前向传播。

求导从损失开始。先计算损失对预测值的导数：

$$\delta_2 = \frac{\partial \ell}{\partial \hat{y}} = \hat{y} - y. \tag{4.15}$$

δ_2 表示预测值发生微小变化时，损失的一阶变化率。由于 $\partial\hat{y}/\partial w_{2j} = h_j$ 和 $\partial\hat{y}/\partial b_2 = 1$，输出层梯度为

$$\nabla_{\boldsymbol{w}_2}\ell = \delta_2\boldsymbol{h}, \qquad \frac{\partial \ell}{\partial b_2} = \delta_2. \tag{4.16}$$

再把导数传到隐藏层。第 j 个隐藏单元满足

$$\frac{\partial \ell}{\partial h_j} = \delta_2 w_{2j}, \qquad \frac{\partial \ell}{\partial a_j} = \delta_2 w_{2j}\phi'(a_j). \tag{4.17}$$

令 $\boldsymbol{\delta}_1 = \nabla_{\boldsymbol{a}}\ell$，把各坐标放在一起，得到

$$\boldsymbol{\delta}_1 = (\boldsymbol{w}_2\delta_2) \odot \phi'(\boldsymbol{a}). \tag{4.18}$$

符号 $\odot$ 表示逐坐标相乘。最后，由 $a_j = \sum_{k=1}^{d} W_{1,jk}x_k + b_{1j}$，有 $\partial a_j/\partial W_{1,jk} = x_k$，于是

$$\frac{\partial \ell}{\partial W_{1,jk}} = \delta_{1j}x_k, \qquad \nabla_{W_1}\ell = \boldsymbol{\delta}_1\boldsymbol{x}^{\mathsf{T}}, \qquad \nabla_{\boldsymbol{b}_1}\ell = \boldsymbol{\delta}_1. \tag{4.19}$$

外积 $\boldsymbol{\delta}_1\boldsymbol{x}^{\mathsf{T}}$ 的形状为 $m \times d$，与 W_1 一致。其余梯度也与对应参数形状一致。计算从损失向输入方向进行，逐层复用已经得到的导数，这就是反向传播（Backpropagation）。

取一个输入和一个隐藏单元，令 $x = 2$、$y = 1$、$W_1 = w_2 = 1$、$b_1 = b_2 = 0$，使用修正线性单元（Rectified Linear Unit，ReLU）$\phi(a) = \max(0, a)$。前向计算得到 $a = 2$、$h = 2$、$\hat{y} = 2$ 和 $\ell = 0.5$。由于 $a > 0$，$\phi'(a) = 1$。反向计算得到 $\delta_2 = 1$、$\delta_1 = 1$，两个权重的梯度均为 2，两个偏置的梯度均为 1。

若采用学习率 0.1 同时更新所有参数，则 $W_1 = w_2 = 0.8$、$b_1 = b_2 = -0.1$。重新前向计算得到 $\hat{y} = 0.8(0.8 \times 2 - 0.1) - 0.1 = 1.1$，损失为 0.005。这个例子展示了从前向计算、反向求导到参数更新的完整过程；它不意味着任意网络和步长都能降低损失。

4.1.3.3 多层网络怎样复用导数

对具有 L 层的网络，令 $\boldsymbol{h}^{(0)} = \boldsymbol{x}$，第 l 层计算

$$\boldsymbol{a}^{(l)} = W^{(l)}\boldsymbol{h}^{(l-1)} + \boldsymbol{b}^{(l)}, \qquad \boldsymbol{h}^{(l)} = \phi_l(\boldsymbol{a}^{(l)}). \tag{4.20}$$

若第 l 层宽度为 d_l，则 $W^{(l)} \in \mathbb{R}^{d_l \times d_{l-1}}$，$\boldsymbol{a}^{(l)}$、$\boldsymbol{h}^{(l)}$ 和 $\boldsymbol{b}^{(l)}$ 均属于 $\mathbb{R}^{d_l}$。这里假设激活函数逐坐标作用，最终损失为 $\ell(\boldsymbol{h}^{(L)}, y)$。定义 $\boldsymbol{\delta}^{(l)} = \nabla_{\boldsymbol{a}^{(l)}}\ell$，输出层先计算

$$\boldsymbol{\delta}^{(L)} = \nabla_{\boldsymbol{h}^{(L)}}\ell \odot \phi_L'(\boldsymbol{a}^{(L)}). \tag{4.21}$$

随后对 $l = L-1, \dots, 1$ 依次计算

$$\boldsymbol{\delta}^{(l)} = \left((W^{(l+1)})^{\mathsf{T}}\boldsymbol{\delta}^{(l+1)}\right) \odot \phi_l'(\boldsymbol{a}^{(l)}), \tag{4.22}$$

$$\nabla_{W^{(l)}}\ell = \boldsymbol{\delta}^{(l)}(\boldsymbol{h}^{(l-1)})^{\mathsf{T}}, \qquad \nabla_{\boldsymbol{b}^{(l)}}\ell = \boldsymbol{\delta}^{(l)}. \tag{4.23}$$

输出层的参数梯度也使用第二行公式。矩阵转置乘法把下一层各单元的导数贡献加到当前层，再乘当前激活的导数。对于跨坐标耦合的运算，需要使用相应的矩阵导数，不能直接套用逐坐标激活公式。

前向传播需要保存求导所需的输入和中间结果。反向传播按依赖的逆序计算局部导数，并累加分支贡献。这样无需为每个参数重新计算整条导数链。自动微分（Automatic Differentiation，AD）系统根据实际执行的运算记录这些依赖，并按局部求导规则完成累积。神经网络训练通常使用反向模式自动微分，它适合从一个标量损失计算大量参数的梯度。

上述推导在相应运算可微处成立。ReLU 在零点不可微，实际实现通常约定该点的局部导数为零；包含这类运算时，前文的光滑下降保证不能未经检查直接应用。对训练集平均损失，逐样本梯度也取平均，正则项的梯

度另行加入。所有梯度必须在同一组更新前参数下算完，再由优化器更新参数。反向传播解决梯度怎样计算的问题，梯度下降、动量或 Adam 解决怎样使用梯度更新参数的问题。

4.1.4 随机梯度、动量与自适应尺度

设 $J(\theta) = n^{-1}\sum_{i=1}^{n} \ell_i(\theta)$，其中 ℓ_i 是第 i 个样本的损失。大数据集上每步计算完整梯度成本较高。随机梯度下降（Stochastic Gradient Descent，SGD）均匀抽取非空小批量 B_t，计算

$$\hat{\boldsymbol{g}}_t = \frac{1}{|B_t|}\sum_{i\in B_t} \nabla_\theta \ell_i(\theta_t), \qquad \theta_{t+1} = \theta_t - \eta_t \hat{\boldsymbol{g}}_t. \tag{4.24}$$

在固定当前参数、按上述方式抽样时，$\mathbb{E}[\hat{\boldsymbol{g}}_t \mid \theta_t] = \nabla J(\theta_t)$。小批量梯度有噪声，单步目标可能增加，但每步所需样本较少。若目标还含正则项，应加上其梯度。把批平均改为批求和会改变更新尺度，必须相应调整学习率。

如果参数在某些方向来回移动，可以对梯度进行指数加权平均。令 $\boldsymbol{v}_0 = \boldsymbol{0}$，从 $t = 1$ 开始更新：

$$\boldsymbol{v}_t = \beta \boldsymbol{v}_{t-1} + (1-\beta)\hat{\boldsymbol{g}}_t, \tag{4.25}$$

$$\theta_{t+1} = \theta_t - \eta_t \boldsymbol{v}_t. \tag{4.26}$$

这里 $0 \le \beta < 1$，$\hat{\boldsymbol{g}}_t$ 在 θ_t 处计算。持续同向的梯度会被保留，正负交替的梯度会部分抵消。这是动量方法的一种约定。有些实现省略 $(1-\beta)$，对应的有效步长不同。

不同坐标的梯度尺度也可能差异很大。自适应矩估计（Adaptive Moment Estimation，Adam）同时维护梯度与梯度平方的指数平均 [44]：

$$\boldsymbol{m}_t = \beta_1 \boldsymbol{m}_{t-1} + (1-\beta_1)\hat{\boldsymbol{g}}_t, \tag{4.27}$$

$$\boldsymbol{s}_t = \beta_2 \boldsymbol{s}_{t-1} + (1-\beta_2)\hat{\boldsymbol{g}}_t \odot \hat{\boldsymbol{g}}_t, \tag{4.28}$$

$$\hat{\boldsymbol{m}}_t = \boldsymbol{m}_t/(1-\beta_1^t), \qquad \hat{\boldsymbol{s}}_t = \boldsymbol{s}_t/(1-\beta_2^t), \tag{4.29}$$

$$\theta_{t+1} = \theta_t - \eta_t \frac{\hat{\boldsymbol{m}}_t}{\sqrt{\hat{\boldsymbol{s}}_t} + \epsilon}. \tag{4.30}$$

初始状态为 $\boldsymbol{m}_0 = \boldsymbol{s}_0 = \mathbf{0}$，$0 \le \beta_1, \beta_2 < 1$，$\epsilon > 0$ 用于数值稳定。符号 $\odot$ 表示逐坐标相乘，除法和平方根也逐坐标进行。

零初始化使早期平均偏小。例如，恒定梯度 $\boldsymbol{g}$ 对应 $\boldsymbol{m}_t = (1-\beta_1^t)\boldsymbol{g}$，除以 $1-\beta_1^t$ 便恢复原尺度。平方梯度的校正同理。归一化使近期平方梯度较大的坐标使用较小的更新尺度。这里的二阶矩是梯度平方的平均，与描述目标曲率的海森矩阵（Hessian matrix）不同。Adam 仍需要选择学习率和停止规则，其更新不保证每一步目标下降。

4.1.5 启发式搜索求解模型参数

离散规则、结构选择和仿真程序可能无法提供可用梯度。此时可以直接评价候选参数的目标值，再按搜索规则产生新候选。启发式优化适合这类问题，其效果取决于候选表示、搜索规则和计算预算。

下面统一考虑最小化 $J(\theta)$，并要求候选属于可行集合 Ω。算法只需要能够评价候选的目标值。遗传算法通过组合与变异产生新候选，模拟退火通过邻域移动搜索，粒子群则利用多个候选已经找到的较好位置指导移动。

遗传算法。 遗传算法（Genetic Algorithm，GA）同时维护 M 个候选，组成第 t 代种群 $\{\theta_t^{(i)}\}_{i=1}^{M}$。每个候选也称为个体。算法首先选择参数的编码方式：连续参数可以直接编码为实数向量，特征是否被选用可以编码为二进制向量。编码决定交叉和变异怎样进行，因此需要先明确哪些编码对应合法模型。

每代先计算 $J_i = J(\theta_t^{(i)})$，再根据目标值选择父代。选择规则应使较优个体更可能被选中，同时保留其他个体参与搜索的机会。例如，可以将目标值转换为正的选择权重：

$$s_i = \exp\left(-\frac{J_i - J_{\min}}{\tau}\right), \qquad P_i = \frac{s_i}{\sum_{j=1}^{M} s_j}, \qquad J_{\min} = \min_j J_j. \tag{4.31}$$

这里 P_i 是选择第 i 个个体作为父代的概率，$\tau > 0$ 控制选择压力，与目标值使用相同尺度。目标较小的个体具有较大的选择概率。τ 较小时，选择更

集中于少数较优个体；τ 较大时，各个体的概率更接近。这个公式是一种可用选择规则，实际也常采用随机抽取若干个体、选其中最优者的锦标赛选择。

选出两个父代 $\theta^{(a)}$ 和 $\theta^{(b)}$ 后，通过交叉生成子代。对实数编码，一种算术交叉为

$$\widetilde{\theta} = \alpha\theta^{(a)} + (1-\alpha)\theta^{(b)}, \qquad \alpha \sim \mathrm{Uniform}(0,1). \tag{4.32}$$

子代位于两个父代之间。若只进行这种交叉，新候选无法离开已有个体的凸包，因此还需要变异。对 d 维实数参数，可以使用

$$\theta' = \widetilde{\theta} + \sigma \boldsymbol{m} \odot \epsilon, \qquad m_j \sim \mathrm{Bernoulli}(p_{\mathrm{mut}}), \quad \epsilon \sim \mathcal{N}(\mathbf{0}, I). \tag{4.33}$$

这里各坐标的 m_j 独立，p_{mut} 是变异概率，$\sigma > 0$ 是扰动尺度。$m_j = 0$ 时保持该坐标，$m_j = 1$ 时加入随机扰动。若各参数单位不同，应分别设置坐标尺度。交叉与变异产生的候选必须检查约束，必要时修复或重新生成。

例如，从四个特征中选择恰好两个，可以用 $(1,0,1,0)$ 表示选择第一和第三个特征。交换一个已选位置和一个未选位置是合法变异。单点交叉把两个父代在某位置切开，再拼接前后片段，但可能产生选择数量错误的子代，需要修复。二进制编码不能直接使用上述实数交叉和高斯变异。

生成并评价足够多的子代后，组成下一代，并可保留上一代的最优个体，这称为精英保留。在目标评价固定的条件下，它使历代最优目标值不增加，但不保证达到全局最优。种群大小决定每代评价成本，选择压力过强会使个体过早相似，变异过大则可能使搜索难以保留已有结构。遗传算法适用于离散结构、组合规则或混合编码问题，需按评价预算或最优值长期无改进等条件停止。

模拟退火。 模拟退火（Simulated Annealing，SA）维护一个当前候选 θ_t，通过局部修改提出 θ'。只接受改进候选的搜索容易停在局部极小点附近。模拟退火允许以一定概率接受较差候选，使搜索有机会经过目标较高的区域，再找到其他较低区域。

先指定邻域提议规则。例如，无约束连续参数可以采用 $\theta' = \theta_t + \sigma\epsilon$，其中 $\epsilon \sim \mathcal{N}(\mathbf{0}, I)$；固定数量的特征选择可以交换一个已选特征和一个未选特征。对于对称提议，即从 θ_t 提出 θ' 与反向提出的概率相同，令 $\Delta = J(\theta') - J(\theta_t)$，接受概率为

$$a(\theta_t, \theta') = \min\{1, \exp(-\Delta/T_t)\}. \tag{4.34}$$

这里 $T_t > 0$ 是温度，与目标差值使用相同尺度。每次抽取 $u \sim \mathrm{Uniform}(0,1)$，若 $u \le a(\theta_t, \theta')$ 就令 $\theta_{t+1} = \theta'$，否则令 $\theta_{t+1} = \theta_t$。当 $\Delta \le 0$ 时总是接受；当 $\Delta > 0$ 时，目标增加越多，接受概率越小。

固定温度下，这一接受规则可由希望采样的分布 $\pi_T(\theta) \propto \exp(-J(\theta)/T)$ 理解。当该分布可归一化时，对称提议下两个候选的密度比就是 $\exp(-\Delta/T)$。较小温度使概率更集中于目标较小的区域。例如，$\Delta = 2$ 时，$T_t = 2$ 对应接受概率约 0.368，$T_t = 0.5$ 时约 0.018。若提议不对称，维持上述固定温度分布还需要乘以反向与正向提议的概率比，不能直接使用式(4.34)。

搜索开始时设置初温 T_0，随后逐渐降温。常用几何降温：

$$T_k = T_0 \gamma^k, \qquad 0 < \gamma < 1. \tag{4.35}$$

这里 k 表示温度阶段，每个阶段可以进行多次邻域提议。较高温度允许更多非改进移动，较低温度使搜索更偏向改进。初温应结合典型目标差值选择，降温速度应结合评价预算选择。邻域过小可能移动缓慢，过大可能频繁提出很差的候选。

由于算法允许接受较差候选，当前目标值可能上升，应另行保存搜索中找到的最优候选。适当条件和很慢的降温计划下存在渐近全局收敛结论，但常用有限预算的几何降温不提供普遍的全局最优保证。模拟退火适合容易定义合法局部修改的问题，其局限是单个候选可能需要较长时间探索多个区域。

粒子群优化。 粒子群优化（Particle Swarm Optimization，PSO）维护多个连续参数候选，每个候选称为粒子。与遗传算法通过交叉产生子代不同，

粒子群保留各粒子的位置和移动速度，并利用历史较好位置指导下一次移动。它适用于能够直接评价目标、但梯度难以取得的连续参数搜索。

令第 i 个粒子在第 t 轮的位置为 $\theta_t^{(i)} \in \mathbb{R}^d$，速度为 $\boldsymbol{v}_t^{(i)} \in \mathbb{R}^d$。记录该粒子截至当前找到的最优位置 $\boldsymbol{p}_t^{(i)}$，并从所有粒子的历史最优位置中选择群体最优位置 $\boldsymbol{g}_t$：

$$\boldsymbol{p}_t^{(i)} \in \operatorname*{arg\,min}_{\theta \in \{\theta_0^{(i)}, \ldots, \theta_t^{(i)}\}} J(\theta), \qquad \boldsymbol{g}_t \in \operatorname*{arg\,min}_{\theta \in \{\boldsymbol{p}_t^{(1)}, \ldots, \boldsymbol{p}_t^{(M)}\}} J(\theta). \tag{4.36}$$

这里 M 是粒子数量。初始化时先评价各粒子，令 $\boldsymbol{p}_0^{(i)} = \theta_0^{(i)}$，再确定 $\boldsymbol{g}_0$。一种常见更新规则为

$$\boldsymbol{v}_{t+1}^{(i)} = \omega \boldsymbol{v}_t^{(i)} + c_1 \boldsymbol{r}_{1,t}^{(i)} \odot (\boldsymbol{p}_t^{(i)} - \theta_t^{(i)}) + c_2 \boldsymbol{r}_{2,t}^{(i)} \odot (\boldsymbol{g}_t - \theta_t^{(i)}), \tag{4.37}$$

$$\theta_{t+1}^{(i)} = \theta_t^{(i)} + \boldsymbol{v}_{t+1}^{(i)}. \tag{4.38}$$

随机向量 $\boldsymbol{r}_{1,t}^{(i)}$ 和 $\boldsymbol{r}_{2,t}^{(i)}$ 的坐标独立服从 $\mathrm{Uniform}(0,1)$，$\omega \geq 0$ 是惯性权重，$c_1, c_2 \geq 0$ 是引导强度。第一项保留原来的移动方向，第二项把粒子拉向自身历史最优位置，第三项把粒子拉向群体历史最优位置。两个随机向量使不同粒子对相同位置的移动幅度有所差别。

例如，一维粒子当前位置为 2、速度为 0.5，自身历史最优位置为 1，群体历史最优位置为 0。若 $\omega = 0.5$、$c_1 = c_2 = 1$，这次抽到 $r_1 = r_2 = 0.5$，则新速度为 $0.25 - 0.5 - 1 = -1.25$，新位置为 0.75。算法并未计算 $J'(2)$，移动方向由已经评价过的较好位置决定。新位置是否更好，必须重新计算 $J(0.75)$ 才能判断。

每轮移动后，评价新位置。若它优于该粒子的历史最优位置，就更新 $\boldsymbol{p}^{(i)}$；再根据全部历史记录更新 $\boldsymbol{g}$。粒子当前位置的目标可以增加，而保存的群体历史最优目标在固定评价下不会增加。对于箱形约束，可以截断或反射越界位置，并相应处理速度。各参数应使用合理尺度，否则数值范围大的坐标可能主导移动。

惯性或引导强度过大可能造成震荡和越界，所有粒子过早聚集又会降低探索范围。速度上限、局部邻域最优引导或重启部分粒子可以调整搜索

行为，但不能普遍保证全局最优。上述规则针对连续参数，离散问题需要专门的编码和更新方式。粒子数量增加会增加每轮目标评价次数，因此应结合维度和评价成本设置预算。

三种方法都通过目标评价比较候选。遗传算法侧重种群的选择与重组，模拟退火侧重单个候选的邻域移动与温度控制，粒子群侧重历史最优位置对连续移动的引导。比较它们时，应统一可行集合、目标评价方式和总评价预算。目标可微且梯度成本可控时，高维连续模型通常更适合梯度方法。

4.1.6 含隐变量的极大似然：EM 算法

4.1.6.1 为什么完整数据容易求解，观测数据却难求解

确定性参数的概率模型也可能包含未被观测的随机变量，称为隐变量或潜变量（Latent Variables）。例如，高斯混合模型中，我们观察到了样本，却不知道每个样本来自哪个成分。如果成分归属也被观测到，就可以按成分分别估计均值和方差。缺少这部分信息以后，参数估计与成分归属判断相互依赖：需要知道归属才能方便地估计参数，又需要参数才能判断归属。

神经网络中的隐藏层也没有被直接观测，但在普通前馈网络中，给定输入和参数就能确定隐藏层输出。概率隐变量则允许在同一观测条件下具有多种可能取值，计算观测概率时需要将这些可能性按概率汇总。因此，不能直接用一次前向计算得到的中间值替代隐变量的条件分布。

为统一记号，以下用 $\boldsymbol{x}$ 表示全部观测数据，$\boldsymbol{z}$ 表示全部隐变量，θ 仍是固定未知参数。给定联合模型 $p(\boldsymbol{x},\boldsymbol{z}\mid\theta)$，观测数据对数似然为

$$\ell(\theta)=\log p(\boldsymbol{x}\mid\theta)=\log\int p(\boldsymbol{x},\boldsymbol{z}\mid\theta)\,d\boldsymbol{z}. \tag{4.39}$$

离散隐变量时，积分改为求和。这里 ℓ 表示对数似然，与前文的单样本损失按上下文区分。对于条件预测模型，相应关系是 $p(y\mid\boldsymbol{x},\theta)=\int p(y,\boldsymbol{z}\mid\boldsymbol{x},\theta)\,d\boldsymbol{z}$，隐变量的分布可以依赖输入和参数。

极大似然估计要最大化式(4.39)。困难既可能是积分难以计算，也可能是积分或求和外的对数使最大化变得困难。高斯混合模型的求和可以计算，但

对数中的多个成分仍耦合在一起。相比之下，完整数据对数似然 $\log p(\boldsymbol{x}, \boldsymbol{z} \mid \theta)$ 往往能拆成容易处理的项。期望最大化（Expectation-Maximization，EM）算法由此提出一个思路：利用当前参数推断缺失信息，再用这些信息改进参数。下面推导为什么应当对缺失信息取条件期望，以及这种交替计算为什么有效。

4.1.6.2 怎样构造一个能逐步提高的下界

只把隐变量替换为一个最可能取值，会丢掉其他取值的概率，通常不能保证观测似然提高。我们引入一个归一化分布 $q(\boldsymbol{z})$，对所有可能的隐变量取加权平均。暂时不指定 q，先看它能否把难处理的对数积分变成完整数据对数似然的期望。

对数是凹函数。Jensen 不等式说明，对正随机量 U 有 $\log \mathbb{E}[U] \geq \mathbb{E}[\log U]$。在 q 覆盖联合分布有关支撑、所需期望有限的条件下，将积分改写为 q 下的期望：

$$\ell(\theta) = \log \int q(\boldsymbol{z}) \frac{p(\boldsymbol{x}, \boldsymbol{z} \mid \theta)}{q(\boldsymbol{z})} \, d\boldsymbol{z} \tag{4.40}$$

$$= \log \mathbb{E}_q \left[\frac{p(\boldsymbol{x}, \boldsymbol{z} \mid \theta)}{q(\boldsymbol{z})} \right] \tag{4.41}$$

$$\geq \mathbb{E}_q \left[\log \frac{p(\boldsymbol{x}, \boldsymbol{z} \mid \theta)}{q(\boldsymbol{z})} \right] = F(q, \theta). \tag{4.42}$$

这里

$$F(q, \theta) = \mathbb{E}_q[\log p(\boldsymbol{x}, \boldsymbol{z} \mid \theta)] + \mathcal{H}(q), \qquad \mathcal{H}(q) = -\mathbb{E}_q[\log q(\boldsymbol{z})]. \tag{4.43}$$

$\mathcal{H}(q)$ 是熵，连续变量时为微分熵。F 是观测对数似然的下界，也称证据下界（Evidence Lower Bound，ELBO）。固定 q 以后，熵与 θ 无关，最大化这个下界只需要最大化完整数据对数似然的期望。

但任意下界提高，并不意味着原目标提高。例如，一个下界可能从很低的位置上升，仍低于原目标的旧值。要保证原目标不下降，需要让下界在当前参数 $\theta^{(t)}$ 处与原目标相等，然后提高这个下界。

Jensen 不等式在上述比值为常数时取等号，即 $p(\boldsymbol{x}, \boldsymbol{z} \mid \theta^{(t)}) = Cq(\boldsymbol{z})$ 在 q 下几乎处处成立。对两边积分，利用 $\int q = 1$，得到 $C = p(\boldsymbol{x} \mid \theta^{(t)})$。因此，令下界接触当前似然的分布应当是

$$q_t(\boldsymbol{z}) = \frac{p(\boldsymbol{x}, \boldsymbol{z} \mid \theta^{(t)})}{p(\boldsymbol{x} \mid \theta^{(t)})} = p(\boldsymbol{z} \mid \boldsymbol{x}, \theta^{(t)}). \tag{4.44}$$

这就解释了为什么使用当前参数下的隐变量后验：它让构造的下界在当前参数处恰好等于观测对数似然。

4.1.6.3 由下界推导 E 步和 M 步

给定初始参数 $\theta^{(0)}$，E 步先按当前参数计算隐变量后验 q_t，再形成

$$Q(\theta \mid \theta^{(t)}) = \mathbb{E}_{q_t}[\log p(\boldsymbol{x}, \boldsymbol{z} \mid \theta)]. \tag{4.45}$$

期望中的 θ 是接下来要改变的候选参数；分布 q_t 中的 $\theta^{(t)}$ 是固定的旧参数。计算时必须区分这两者。很多模型只需计算有关充分统计量的条件期望，无需显式保存整个后验分布。

M 步固定 q_t，最大化下界。因为 $\mathcal{H}(q_t)$ 与候选参数无关，更新为

$$\theta^{(t+1)} = \arg\max_{\theta} F(q_t, \theta) = \arg\max_{\theta} Q(\theta \mid \theta^{(t)}). \tag{4.46}$$

由此得到 EM 的两个步骤：E 步使下界在旧参数处与原目标相等，M 步利用这个下界求新参数。得到新参数以后，旧 q_t 通常已不再是新参数下的后验，需要重新执行 E 步，再继续更新。

从联合目标 $F(q, \theta)$ 看，EM 是一种交替最大化：固定 θ 时选择精确后验作为 q，固定 q 时更新 θ。每一步只处理一部分未知量，因此可以利用完整数据模型中较容易的计算。M 步可能有闭式解，也可能需要数值优化。E 步则要求后验或有关条件期望能够计算，EM 并不能自动解决所有不可计算的积分。

4.1.6.4 为什么每轮更新不会降低观测似然

先用下界说明单调性。E 步保证 $F(q_t,\theta^{(t)})=\ell(\theta^{(t)})$，M 步保证 $F(q_t,\theta^{(t+1)})\ge F(q_t,\theta^{(t)})$，而下界始终不超过相应似然。因此

$$\ell(\theta^{(t+1)})\ge F(q_t,\theta^{(t+1)})\ge F(q_t,\theta^{(t)})=\ell(\theta^{(t)}). \tag{4.47}$$

这条不等式连接了旧目标值、提高后的下界和新目标值。它保证观测对数似然不下降；若 M 步严格提高 Q，则观测对数似然也严格提高。

还可以直接从条件概率分解看清楚两个变化项。由 $p(\boldsymbol{x},\boldsymbol{z}\mid\theta)=p(\boldsymbol{x}\mid\theta)p(\boldsymbol{z}\mid\boldsymbol{x},\theta)$，取对数并在固定的 q_t 下求期望，得到

$$\ell(\theta)=Q(\theta\mid\theta^{(t)})-A(\theta\mid\theta^{(t)}),\qquad A(\theta\mid\theta^{(t)})=\mathbb{E}_{q_t}[\log p(\boldsymbol{z}\mid\boldsymbol{x},\theta)]. \tag{4.48}$$

$\ell(\theta)$ 与 $\boldsymbol{z}$ 无关，左边的期望仍为自身。这里 A 是后验对数密度的期望，只有在 $\theta=\theta^{(t)}$ 时，才等于 $-\mathcal{H}(q_t)$。

定义 Kullback–Leibler 散度（Kullback–Leibler divergence，KL）为 $\mathrm{KL}(q\|p)=\mathbb{E}_q[\log(q/p)]$。在有关期望有定义时，它非负且通常不对称。于是

$$A(\theta^{(t+1)}\mid\theta^{(t)})-A(\theta^{(t)}\mid\theta^{(t)})=\mathbb{E}_{q_t}\left[\log\frac{p(\boldsymbol{z}\mid\boldsymbol{x},\theta^{(t+1)})}{q_t(\boldsymbol{z})}\right] \tag{4.49}$$

$$=-\mathrm{KL}(q_t\|p(\boldsymbol{z}\mid\boldsymbol{x},\theta^{(t+1)}))\le 0. \tag{4.50}$$

M 步使 Q 不减，而被减去的 A 不增，因此

$$\ell(\theta^{(t+1)})-\ell(\theta^{(t)})=Q(\theta^{(t+1)}\mid\theta^{(t)})-Q(\theta^{(t)}\mid\theta^{(t)})+\mathrm{KL}(q_t\|p(\boldsymbol{z}\mid\boldsymbol{x},\theta^{(t+1)}))\ge 0. \tag{4.51}$$

这个分解说明，新似然的增加来自完整数据期望目标的改进，以及旧隐变量后验与新隐变量后验之间的差异。

对一般 q，同样的代数还给出下界的精确间隙：

$$\ell(\theta)=F(q,\theta)+\mathrm{KL}(q\|p(\boldsymbol{z}\mid\boldsymbol{x},\theta)). \tag{4.52}$$

KL 为零时，下界与似然相等。这个恒等式与 Jensen 推导相互对应，也将引出后面的变分推断。

单调性与收敛是不同结论。如果对数似然有上界，不下降的似然值序列会收敛，但这本身不保证参数序列收敛或达到全局最优。在适当正则条件下，EM 的收敛点可为驻点，初始化仍会影响结果。无约束高斯混合模型可能因成分方差趋近零而出现似然无界，不能直接套用似然有界时的结论。

4.1.6.5 哪些近似仍保留上述保证

若 E 步精确计算后验，而 M 步只使 Q 不下降，不要求达到其最大值，就得到广义 EM（Generalized EM，GEM）。例如，可以在 M 步使用带下降检查的梯度法最小化 $-Q$。上述单调性证明仍成立。

若隐变量后验无法精确计算，则是另一个计算困难。将 q 限制在可处理的分布族内，交替提高 $F(q,\theta)$，得到变分 EM（Variational EM，VEM）。此时 E 步通常不能令 KL 为零，所以提高下界不再自动保证观测似然不下降。用采样估计 E 步期望则得到蒙特卡洛 EM（Monte Carlo EM，MCEM），有限采样误差也可能破坏逐轮单调性。这些方法分别近似分布与期望，不能与只放宽 M 步的广义 EM 混为一谈。

4.1.7 例子：一维高斯混合模型

设独立样本 $x_1,\dots,x_n$ 来自 K 个高斯成分：

$$p(x_i \mid \theta)=\sum_{k=1}^{K}\pi_k\mathcal{N}(x_i \mid \mu_k,\sigma_k^2),\qquad \pi_k\ge 0,\quad \sum_{k=1}^{K}\pi_k=1. \tag{4.53}$$

参数 θ 包含混合权重 π_k、均值 μ_k 和正方差 σ_k^2。隐变量 $z_i=k$ 表示样本来自第 k 个成分。若成分归属已知，每个成分可以分别拟合；归属未知时，用条件概率作为软计数。

E 步由 Bayes 公式计算责任度：

$$r_{ik}=P(z_i=k \mid x_i,\theta^{(t)})=\frac{\pi_k^{(t)}\mathcal{N}(x_i \mid \mu_k^{(t)},(\sigma_k^2)^{(t)})}{\sum_{j=1}^{K}\pi_j^{(t)}\mathcal{N}(x_i \mid \mu_j^{(t)},(\sigma_j^2)^{(t)})}. \tag{4.54}$$

每个样本满足 $\sum_k r_{ik}=1$。若两个成分权重相同、方差均为 1、均值为 0 和 2，则 $x_i=1$ 的责任度各为 1/2，而 $x_i=0$ 属于第一成分的责任度为 $1/(1+e^{-2})\approx 0.881$。

固定责任度，完整数据对数似然的期望为

$$Q=\sum_{i,k} r_{ik}\left[\log\pi_k-\frac{1}{2}\log(2\pi\sigma_k^2)-\frac{(x_i-\mu_k)^2}{2\sigma_k^2}\right]. \tag{4.55}$$

令 $N_k=\sum_i r_{ik}$。在 $N_k>0$ 且更新方差为正时，求导并结合权重和为一的约束，得到 M 步：

$$\pi_k^{(t+1)}=N_k/n, \tag{4.56}$$

$$\mu_k^{(t+1)}=N_k^{-1}\sum_i r_{ik}x_i, \tag{4.57}$$

$$(\sigma_k^2)^{(t+1)}=N_k^{-1}\sum_i r_{ik}(x_i-\mu_k^{(t+1)})^2. \tag{4.58}$$

均值公式来自 $\sum_i r_{ik}(x_i-\mu_k)=0$。方差公式来自对 σ_k^2 求导后得到的 $N_k\sigma_k^2=\sum_i r_{ik}(x_i-\mu_k)^2$。权重约束的拉格朗日乘子给出 $\pi_k=N_k/n$。它们分别是软样本比例、加权均值和加权方差。

反复执行两步，直到观测对数似然的变化小于约定阈值或达到迭代上限。实践中需要处理空成分与方差退化，例如预先限制方差下界，并在这一约束下完成 M 步。多个初始值可以得到不同解，应在相同模型和约束下比较似然。成分数的选择和泛化性能还需要独立的模型评价。

4.2 随机参数模型的求解

以上各节主要讨论固定未知参数的求解，结果通常是一个点估计 $\hat{\theta}$。随机参数模型则用概率分布表达对未知参数 θ 的不确定性。这不要求真实参数在每次观测时重新变化。数据较少时，多个参数取值可能都能解释观测结果；只保留一个参数点，就无法描述这些取值之间的差异及其可信程度。因此，求解需要从参数值扩展到参数分布。

一个模型可以同时包含随机参数和固定未知参数。例如，可以用随机变量表示设备状态，用具有固定未知权重的神经网络表示状态与观测之间的条件分布。前者需要条件分布，后者需要参数估计；两类未知量可以通过交替计算或同一个目标下的联合优化求解。

后验难以精确计算时，变分推断（Variational Inference，VI）选择一个便于计算的分布来近似它，再优化这个分布的参数。这里的优化变量描述的是近似分布，求解结果仍是一个分布。前文的变分 EM 也使用这种思路近似隐变量后验；蒙特卡洛 EM 则用采样估计条件期望。下面先写出参数后验，再分别讨论变分近似与后验采样。

4.2.1 后验分布：数据怎样更新参数的不确定性

设观测数据为 $\mathcal{D}$。先验分布 $p(\theta)$ 表达观察当前数据之前对参数取值的判断；似然 $p(\mathcal{D} \mid \theta)$ 表示给定参数时，模型赋予观测数据的概率或概率密度。观察数据后，贝叶斯公式将二者结合为后验分布（posterior distribution）：

$$p(\theta \mid \mathcal{D}) = \frac{p(\mathcal{D} \mid \theta)p(\theta)}{p(\mathcal{D})}. \tag{4.59}$$

后验回答：在已观察到这些数据的条件下，各种参数取值有多可信？分子把先验权重与数据提供的似然相乘，分母 $p(\mathcal{D})$ 是归一化常数。它由联合分布对参数积分得到：

$$p(\mathcal{D}) = \int p(\mathcal{D}, \theta)\, d\theta = \int p(\mathcal{D} \mid \theta)p(\theta)\, d\theta. \tag{4.60}$$

当参数维度较高，或者似然与先验的形式较复杂时，这个积分通常没有解析形式；即使能够计算它，后验本身以及后验预测中的积分也可能仍然难以直接求出。因此，随机参数模型的核心计算问题，是近似后验分布，或者直接计算关于后验分布的期望。

这产生了两条基本路线。一条是分布近似：选择一个可计算的分布族，用 $q_\phi(\theta)$ 近似 $p(\theta \mid \mathcal{D})$，通过优化确定变分参数 ϕ。另一条是采样近似：构造以后验为目标分布的采样方法，用参数样本近似后验期望。前者给出一

个显式的近似分布，后者未必写出后验的解析表达式，但可以用样本完成预测和其他期望计算。

后验的重要性在于它保留了参数的不确定性。我们可以计算后验均值（或者最大后验估计）作为点估计，也可以计算参数区间的后验概率，说明数据支持的取值范围。预测新标签时，还可以让不同参数按其后验权重共同参与预测：

$$p(y_* \mid \boldsymbol{x}_*, \mathcal{D}) = \int p(y_* \mid \boldsymbol{x}_*, \theta) p(\theta \mid \mathcal{D})\, d\theta. \tag{4.61}$$

其中 $\boldsymbol{x}_*$ 是新输入，y_* 是待预测标签；假设给定输入和参数后，新标签与训练数据条件独立，并将输入作为已知条件。积分把每个参数下的预测按后验密度加权汇总，使参数不确定性进入预测结果。后验较集中时，单点预测可能是合适的近似；后验分散或具有多个峰时，一个参数点可能遗漏其他有较大后验权重的预测。后验是否可信仍取决于先验、似然和数据假设，分布形式本身不保证预测校准。

4.2.2 边际似然：模型整体怎样支持观测数据

式(4.59)的分母由联合分布对参数积分得到：

$$p(\mathcal{D}) = \int p(\mathcal{D}, \theta)\, d\theta = \int p(\mathcal{D} \mid \theta) p(\theta)\, d\theta. \tag{4.62}$$

这个量称为边际似然（marginal likelihood），也称模型证据（model evidence）。这里的“边际”表示通过积分消去参数，只留下观测数据的分布；离散参数时，积分改为求和。它是似然在先验分布下的加权平均，表示在尚未用当前数据更新参数时，模型赋予这些数据的概率或概率密度。给定模型、先验和数据后，边际似然是一个数；后验则是参数取值的分布。

边际似然首先保证后验归一化：将式(4.59)对 θ 积分，分子的积分恰好是 $p(\mathcal{D})$，所以后验积分为 1。在本章中，边际似然只作为后验的归一化常数出现。它的模型比较含义以及模型先验的设定，放在后续贝叶斯学习章节讨论。若模型还含有隐变量，计算边际分布时可能需要同时对隐变量和随机参数积分；这一积分通常也没有解析形式。

4.2.3 分布近似：从贝叶斯公式推导变分目标

面对难以解析计算的后验，可以选择一个归一化、便于计算的分布 $q_\phi(\theta)$，用它近似 $p(\theta \mid \mathcal{D})$。例如，可以选择高斯分布，此时 ϕ 包含均值和协方差参数。变分推断的任务是确定这些参数，使近似分布尽可能接近后验。下面假设 $p(\mathcal{D})$ 正且有限，q_ϕ 在后验为零的区域也为零，且涉及的期望和 KL 散度有限。

从贝叶斯公式出发，取对数并整理，在后验密度为正的地方有

$$\log p(\mathcal{D}) = \log p(\mathcal{D}, \theta) - \log p(\theta \mid \mathcal{D}). \tag{4.63}$$

两边对 $q_\phi(\theta)$ 求期望。左边与 θ 无关，又因为 $\int q_\phi(\theta)\, d\theta = 1$，所以左边仍为 $\log p(\mathcal{D})$：

$$\log p(\mathcal{D}) = \mathbb{E}_{q_\phi}[\log p(\mathcal{D}, \theta)] - \mathbb{E}_{q_\phi}[\log p(\theta \mid \mathcal{D})]. \tag{4.64}$$

在右边加上并减去 $\mathbb{E}_{q_\phi}[\log q_\phi(\theta)]$，再将各项分组，得到

$$\begin{aligned} \log p(\mathcal{D}) &= \mathbb{E}_{q_\phi}[\log p(\mathcal{D}, \theta) - \log q_\phi(\theta)] \\ &\quad + \mathbb{E}_{q_\phi}[\log q_\phi(\theta) - \log p(\theta \mid \mathcal{D})] \\ &= \mathcal{L}(\phi) + \mathrm{KL}(q_\phi \| p(\theta \mid \mathcal{D})). \end{aligned} \tag{4.65}$$

第一项称为证据下界（Evidence Lower Bound，ELBO）：

$$\begin{aligned} \mathcal{L}(\phi) &= \mathbb{E}_{q_\phi}[\log p(\mathcal{D}, \theta) - \log q_\phi(\theta)] \\ &= \mathbb{E}_{q_\phi}[\log p(\mathcal{D} \mid \theta)] - \mathrm{KL}(q_\phi \| p(\theta)). \end{aligned} \tag{4.66}$$

第二项是近似分布与真实后验之间的 KL 散度。它非负，所以 $\mathcal{L}(\phi) \le \log p(\mathcal{D})$，这解释了“下界”的名称。固定模型时，证据与 ϕ 无关，最大化 ELBO 便等价于最小化这个 KL 散度。ELBO 只涉及联合密度和近似分布，优化时无需计算难以求出的归一化积分。

这里的转化并不声称每个 ELBO 都能直接算出。计算后验密度需要知道证据 $p(\mathcal{D})$，而 ELBO 的第一种写法

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi}\left[\log p(\mathcal{D}, \theta) - \log q_\phi(\theta)\right] \tag{4.67}$$

不包含这个未知的归一化常数。只要能够计算给定参数下的联合密度 $p(\mathcal{D}, \theta) = p(\mathcal{D} \mid \theta)p(\theta)$，并且能够计算或估计关于 q_ϕ 的期望，就可以评价或优化 ELBO。是否更容易计算，取决于联合密度、近似分布及其期望的具体形式。

若先验 KL 散度有解析表达式，而对数似然期望难以积分，可以从 q_ϕ 抽取样本 $\theta^{(1)}, \ldots, \theta^{(S)}$，使用

$$\widehat{\mathcal{L}}(\phi) = \frac{1}{S}\sum_{s=1}^{S} \log p(\mathcal{D} \mid \theta^{(s)}) - \mathrm{KL}(q_\phi \| p(\theta)) \tag{4.68}$$

估计 ELBO。若先验 KL 也没有解析形式，则可以使用第一种写法，同时对联合密度和 q_ϕ 的对数密度进行蒙特卡洛估计。若某些项可以直接积分或精确计算，应保留解析计算，以减少采样误差。

得到 ELBO 的数值或无偏（或近似无偏）的梯度估计后，就可以把 ϕ 当作普通优化变量。每轮先从当前的 q_{ϕ_t} 取样，计算 ELBO 或其梯度，再按梯度上升更新：

$$\phi_{t+1} = \phi_t + \alpha_t \widehat{\nabla_\phi \mathcal{L}(\phi_t)}. \tag{4.69}$$

反复迭代，直到目标变化、参数变化或梯度满足停止条件。求解结果是 $q_{\hat{\phi}}(\theta)$，它是对真实后验的近似，而不是后验的解析表达式。后续的后验均值、区间概率和预测，也都使用这个近似分布计算。

ELBO 中的对数似然期望评价近似分布所支持的参数解释数据的程度，先验 KL 项衡量近似分布与先验的差异。即使优化充分，选定的分布族也可能无法表达真实后验的相关性或多个峰，因此结果仍是近似。这里称为确定性近似，是因为最终用一个确定的分布表达式 $q_{\hat{\phi}}$ 表示后验；求解其参数时仍可以使用随机采样和随机梯度。

EM 算法与变分推断使用了相同的下界恒等式。EM 在每次 E 步计算精确隐变量后验，使变分下界与当前参数下的对数似然相等，再更新固定

参数。变分推断将近似分布限制在可处理的族中，下界与对数证据之间通常仍有间隙。这里优化的是分布的参数，求解结果仍是一个分布。

4.2.4 均值场近似怎样计算

均值场（mean-field）近似是变分推断中一种常用的确定性近似。先把参数分成 d 组，记为

$$\theta = (\theta_1, \ldots, \theta_d), \tag{4.70}$$

并假设各组参数在近似后验中相互独立，于是取变分分布为

$$q(\theta) = \prod_{j=1}^{d} q_j(\theta_j). \tag{4.71}$$

其中 $q_j(\theta_j)$ 是只描述第 j 组参数的概率分布，称为一个变分因子；q_{-j} 表示除 q_j 以外其他因子的乘积。为了求解这些因子，可以固定 q_{-j}，只把 q_j 作为变量，最大化 ELBO 关于 q_j 的部分。这里把第 j 个因子看作一个待更新的方向，这种逐个固定其余因子、轮流更新单个因子的做法称为坐标上升变分推断。固定除第 j 个因子以外的 q_{-j}，令 $A_j(\theta_j) = \mathbb{E}_{q_{-j}}[\log p(\mathcal{D}, \theta)]$，ELBO 中依赖 q_j 的部分为

$$\int q_j(\theta_j) A_j(\theta_j)\, d\theta_j - \int q_j(\theta_j) \log q_j(\theta_j)\, d\theta_j. \tag{4.72}$$

在 $\int q_j = 1$ 的约束下，对 q_j 求变分导数，得到 $A_j - \log q_j - 1 + \lambda = 0$。归一化以后，坐标更新为

$$q_j^{\text{new}}(\theta_j) \propto \exp\{\mathbb{E}_{q_{-j}}[\log p(\mathcal{D}, \theta)]\}. \tag{4.73}$$

这要求期望可计算且右端可归一化。逐个更新因子称为坐标上升变分推断。若因子还被限制为指定的参数族，这个不受限的坐标解未必属于该族，可能仍需数值优化。

独立近似降低计算成本，但可能漏掉相关性。例如，真实二维高斯后验协方差为

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \qquad |\rho| < 1. \tag{4.74}$$

取独立高斯近似 $q = \mathcal{N}(\boldsymbol{m}, \mathrm{diag}(v_1, v_2))$，最小化 $\mathrm{KL}(q\|p)$ 对均值的解是真实均值。对方差求导得到 $\frac{1}{2}((\Sigma^{-1})_{jj} - 1/v_j) = 0$，所以 $v_1 = v_2 = 1 - \rho^2$。真实边际方差均为 1，而 $\rho = 0.9$ 时近似方差只有 0.19。该例展示了均值场近似可能低估不确定性的原因。增加 ELBO 表示该目标有所改进，仍需检查分布族能否表达任务所需的相关性、多峰或尾部。

4.2.5 蒙特卡洛变分推断与随机梯度优化

在均值场方法中，如果固定其他因子后，式(4.66)关于某个因子 q_j 的最优解可以直接写出，就能使用上面的坐标上升更新。复杂模型中，这个条件可能不满足：右端的期望难以计算，或者得到的函数难以归一化；即使能得到完整的最优分布，它也可能不属于预先选定的高斯等分布族。此时，不能直接写出 q_j 的更新式，通常改为把近似分布写成 $q_\phi(\theta)$，再用数值优化确定其参数。此时 ELBO 中的期望也可能难以直接积分，可以从当前近似分布 q_ϕ 抽取样本，用样本平均估计 ELBO 或其梯度。这种做法称为蒙特卡洛变分推断（Monte Carlo Variational Inference，MCVI）。待求的仍是近似分布的参数 ϕ，采样为优化提供可计算的估计。

令 $f_\phi(\theta) = \log p(\mathcal{D}, \theta) - \log q_\phi(\theta)$，则 $\mathcal{L}(\phi) = \mathbb{E}_{q_\phi}[f_\phi(\theta)]$。固定当前 ϕ，独立抽取 $\theta^{(s)} \sim q_\phi$，可用 $S^{-1}\sum_{s=1}^{S} f_\phi(\theta^{(s)})$ 估计 ELBO。在可积条件下，这个估计的期望等于真实 ELBO。不过，q_ϕ 本身随 ϕ 变化，计算梯度时也需要考虑采样分布的变化。如果把抽出的 $\theta^{(s)}$ 直接视为与 ϕ 无关的常数再求导，就会遗漏这部分影响。下面介绍两种常见的梯度估计方式。

重参数化梯度 对角高斯近似可以写成

$$\theta = \boldsymbol{\mu}_\phi + \boldsymbol{s}_\phi \odot \epsilon, \qquad \epsilon \sim \mathcal{N}(\mathbf{0}, I), \tag{4.75}$$

其中 $\boldsymbol{s}_\phi$ 逐坐标为正，可用对数尺度参数保证正值。随机性被放入与 ϕ 无关的 ϵ，称为重参数化。抽取 S 个独立样本，令 $\theta^{(s)} = \boldsymbol{\mu}_\phi + \boldsymbol{s}_\phi \odot \epsilon^{(s)}$，可估计

$$\widehat{\mathcal{L}}(\phi) = \frac{1}{S}\sum_{s=1}^{S}[\log p(\mathcal{D}, \theta^{(s)}) - \log q_\phi(\theta^{(s)})]. \tag{4.76}$$

在可微且允许交换求导与期望的条件下，对这个重参数化后的表达式自动微分，可以得到 ELBO 梯度的蒙特卡洛估计。随后进行梯度上升，或最小化负 ELBO。高斯熵或先验 KL 若可解析计算，应直接计算这些项，以减少采样噪声。

得分函数梯度 如果随机变量是离散的，或者难以写出重参数化表达式，可以使用恒等式

$$\nabla_\phi \mathbb{E}_{q_\phi}[f(\theta)] = \mathbb{E}_{q_\phi}\left[f(\theta)\nabla_\phi \log q_\phi(\theta) + \nabla_\phi f(\theta)\right]. \tag{4.77}$$

这个恒等式要求分布的支持集不随 ϕ 变化，并允许交换求导与积分（离散变量时为求和）。其中 $\nabla_\phi \log q_\phi(\theta)$ 称为得分函数。对于 ELBO 中的 f_ϕ，固定生成模型时有 $\nabla_\phi f_\phi = -\nabla_\phi \log q_\phi$，而得分函数的期望为零，因此

$$\nabla_\phi \mathcal{L}(\phi) = \mathbb{E}_{q_\phi}[f_\phi(\theta)\nabla_\phi \log q_\phi(\theta)]. \tag{4.78}$$

用独立样本替换期望，可得梯度估计

$$\widehat{\boldsymbol{g}}(\phi) = \frac{1}{S}\sum_{s=1}^{S}[f_\phi(\theta^{(s)}) - b]\nabla_\phi \log q_\phi(\theta^{(s)}). \tag{4.79}$$

这里 b 是与本次样本无关的基线，例如由以往迭代估计的常数。减去 b 不改变梯度估计的期望，因为 $\mathbb{E}_{q_\phi}[b\nabla_\phi \log q_\phi] = 0$，但合适的基线可以降低方差。在上述条件下，这个估计是无偏的。得分函数方法适用范围较广，方差却可能较大；重参数化梯度在许多可微模型中方差较小，但需要合适的可微采样表达式。

用随机梯度更新变分参数 将蒙特卡洛梯度估计用于优化，便得到随机梯度变分推断。第 t 次迭代从当前 q_{ϕ_t} 重新采样，计算梯度估计 $\widehat{\boldsymbol{g}}_t$，再按步长 α_t 更新：

$$\phi_{t+1} = \phi_t + \alpha_t \widehat{\boldsymbol{g}}_t. \tag{4.80}$$

完整流程是选择分布族、初始化变分参数、采样计算 ELBO 及梯度、更新变分参数，再检查目标变化与数值稳定性。MCVI 描述用蒙特卡洛方法计算变分目标或梯度，随机梯度变分推断描述利用这些梯度估计进行优化。即使使用全部训练数据，从 q_ϕ 采样也会使梯度具有随机性。

如果给定参数后各样本条件独立，大数据下还可以均匀随机抽取小批量 B_t，用下面的量估计全数据的对数似然总和：

$$\widehat{\ell}_{B_t}(\theta) = \frac{n}{|B_t|} \sum_{i \in B_t} \log p(y_i \mid \boldsymbol{x}_i, \theta). \tag{4.81}$$

这里缩放的是数据项，先验项和近似分布的熵项保持原有权重。参数采样和数据抽样是两种不同的随机来源。采样目标有噪声，单次估计增加不表示真实 ELBO 必然增加，优化收敛也仍依赖步长、梯度估计的性质和目标函数。

离散变量通常没有上述直接可微的重参数化，应先检查能否精确求和，或采用适合模型结构的其他梯度估计。最终预测可以从 q_ϕ 抽取参数，平均各次条件预测。这个平均仍包含后验近似误差与有限采样误差。

若模型还包含确定性参数 η，例如表示条件分布的神经网络权重，则联合密度写为 $p_\eta(\mathcal{D}, \theta)$，变分目标也随之写为 $\mathcal{L}(\phi, \eta)$。可以交替更新近似后验的参数 ϕ 和神经网络参数 η，也可以用梯度方法联合更新。在近似后验受限时，优化的是对数边际似然的下界；只有在近似分布等于对应的真实后验时，下界才与对数边际似然相等。

4.2.6 随机性近似：用后验样本计算期望

另一个求解角度是从最终需要计算的量出发。若关注参数均值、区间概率或预测，通常需要的是某个函数 $h(\theta)$ 关于后验的期望：

$$\mathbb{E}[h(\theta) \mid \mathcal{D}] = \int h(\theta) p(\theta \mid \mathcal{D})\, d\theta. \tag{4.82}$$

例如，$h(\theta) = \theta$ 给出后验均值，$h(\theta) = \mathbf{1}_{\{\theta \in A\}}$ 给出参数落在区域 A 内的后验概率。将 $h(\theta)$ 取为条件预测概率或密度，还可以计算式(4.61)中的后验预测。以下要求所求期望存在。

如果能够从后验分布抽取独立样本 $\theta^{(1)}, \ldots, \theta^{(S)}$，就可以用蒙特卡洛平均近似积分：

$$\mathbb{E}[h(\theta) \mid \mathcal{D}] \approx \frac{1}{S} \sum_{s=1}^{S} h(\theta^{(s)}). \tag{4.83}$$

大数定律说明，在可积条件下，随着样本数增加，这个平均趋于目标期望。这样可以用同一批参数样本计算不同函数的期望，无需先写出后验的解析表达式。若样本来自变分分布 q_ϕ，平均对应的是 q_ϕ 下的期望，仍会保留变分近似误差。

难点在于，无法解析计算的后验通常也不能直接进行独立采样。马尔可夫链蒙特卡洛（Markov Chain Monte Carlo，MCMC）通过构造以后验为平稳分布的马尔可夫链来解决这一问题。以 Metropolis–Hastings 算法为例，令未归一化密度 $\widetilde{p}(\theta) = p(\mathcal{D} \mid \theta) p(\theta)$。从当前状态 θ 按提议密度 $r(\theta' \mid \theta)$ 产生候选状态 θ'，以概率

$$\alpha(\theta, \theta') = \min\left\{1, \frac{\widetilde{p}(\theta') r(\theta \mid \theta')}{\widetilde{p}(\theta) r(\theta' \mid \theta)}\right\} \tag{4.84}$$

接受候选状态，否则保留当前状态。后验的归一化常数在比值中相消，因此不必先计算 $p(\mathcal{D})$。这一接受规则使后验满足详细平衡，从而成为链的平稳分布。在适当的不可约性、非周期性等条件下，链能够趋于目标后验，遍历平均可以近似后验期望。

链的样本通常相关，有限运行也可能尚未充分探索后验。实际计算需要检查初始阶段的影响、多条链之间的一致性及有效样本量。增加迭代次数只有在链能够充分探索目标分布时才有意义，不能把迭代数直接当作独立样本数。后验采样用于估计后验期望，也不意味着已经求出了模型比较所需的边际似然。

这里的后验采样称为蒙特卡洛推断，其中 MCMC 是一类常用方法。蒙特卡洛变分推断（Monte Carlo Variational Inference，MCVI）则用采样估计变分目标或其梯度，仍然是在优化近似分布 q_ϕ。两者使用采样的目的不同：前者用以后验为目标的样本近似期望，后者用采样辅助求解变分近似。后续贝叶斯学习章节将进一步讨论这些推断方法。

4.3 选择求解方法时应问的问题

模型求解前，应确认待确定的是固定参数、隐变量的条件分布，还是参数后验。然后检查线性方程、期望或积分能否直接计算，以及目标能否求导。

固定参数有可靠直接解时，可以使用数值线性代数。无直接解且可微时，可以使用梯度方法。无法取得梯度的离散或黑盒问题，可以在计算预算允许时采用启发式搜索。含隐变量的极大似然问题在条件期望可处理时适合 EM。随机参数的后验不可解析时，变分推断将分布近似转化为优化问题。

这些方法的结果具有不同含义。目标下降评价参数搜索，似然提高评价数据在模型下的概率，ELBO 提高评价所选分布族中的近似目标。它们都不能替代下一章的泛化检验。

辅助学习材料

- **Mathematics for Machine Learning**；Deisenroth、Faisal 与 Ong；英文教材。结合线性代数、微积分和连续优化部分阅读最小二乘与梯

度方法。[18]

- **Probabilistic Machine Learning: An Introduction**；Murphy；英文教材。对照混合模型与潜变量推断，理解条件分布在模型求解中的作用。[61]

- **Pattern Recognition and Machine Learning**；Bishop；英文教材。第九章介绍混合模型与 EM，第十章介绍变分推断。[7]

4.4 本章小结

模型求解首先需要明确未知量。固定参数可以通过闭式计算、梯度方法或启发式搜索获得点估计。含隐变量的极大似然估计利用 EM 交替计算条件期望和更新参数。随机参数模型需要后验分布，变分推断通过优化 ELBO 得到可计算的近似。

各方法的保证都有条件。梯度下降的单步保证依赖光滑性与步长，EM 的单调性依赖 E 步和 M 步的计算，变分近似质量受分布族限制。后续统计学习内容将讨论怎样用独立数据检验所得模型能否用于未见样本。

第五章　统计学习理论与模型选择

本章摘要。本章为模型比较提供统计学习视角。先说明假设空间和容量如何影响泛化界，再讨论结构风险、交叉验证、校准、不平衡数据和置信区间。最后把理论约束转成数据泄漏检查，使模型选择从“哪个分数最高”转向“哪个结论在何种不确定性下成立”。

上一章说明训练误差、抽样误差和分布偏移不是一回事，但现实实验还多了一层选择：研究者会试很多窗口、特征和超参数，再报告其中最好的结果。这时需要控制的不再是某个预先固定函数的误差，而是整个选择过程可能带来的乐观偏差。本章以这个区别为出发点，把统计学习的容量约束与实际验证规则连接起来。

试过许多窗口长度以后再挑最高分，相当于又用数据作了一次选择。若仍用同一批数据报告最终成绩，就可能把偶然的好运当成稳定的提升。理论中的复杂度代价说明这种问题为什么会发生，交叉验证帮助安排有限样本的用途，校准和成本分析则帮助把分数变成告警规则。每一种方法都有适用条件，不能替代对新设备的独立检验。

阅读本章前，应能区分训练平均损失与总体风险，并理解一次数据划分为何不能证明所有工况下的表现。第一次阅读可先掌握有限候选集合的联合界和嵌套验证；无限类复杂度推导用于回答连续参数模型如何控制选择偏差，不是实施交叉验证的前置操作。

5.1　假设空间与泛化约束

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

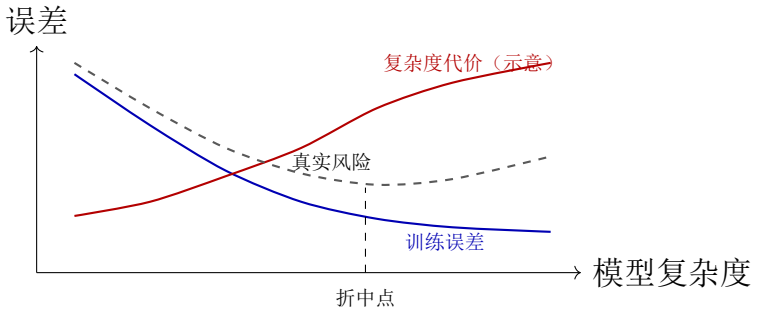


图 5.1: 模型复杂度同时影响拟合误差与估计方差；模型选择的目标是控制真实风险，而不是单独追求训练误差。

图5.1是定性示意，不是风险分解的数值相加，也不保证真实风险总呈 U 形或只有一个最低点。它提醒读者，选模应控制未见样本风险，而非仅追求更低训练误差；理论复杂度上界也不等于实测的估计方差。

假设空间。 学习算法从假设空间 $\mathcal{H}$ 中选择函数。有限训练集只能约束 $\mathcal{H}$ 在观测点上的行为，因此假设空间越丰富，插值训练数据越容易，但泛化分析也越困难。模型容量不能简单等同于参数数量，还与参数化方式、数据几何和优化偏置有关。

读概率界前先确定谁在随机变化。 假设空间 $\mathcal{H}$ 是一组允许的预测函数，而不是数据表。以标量温度 x 为输入，三个预先固定的阈值分类器 $f_c(x) = \mathbb{1}\{x > c\}$、$c \in \{60, 70, 80\}$ 就组成含三个函数的空间。若阈值可以取任意实数，则空间无限，尽管每个函数只有一个参数。

以下 Pr 指重新抽取训练集时的概率，$\epsilon > 0$ 是允许的风险误差，δ 是允许理论保证失败的概率。sup 表示上确界，有限集合时就是最大值；$|\mathcal{H}|$ 是函数个数，log 是自然对数。固定函数的界像保证一个预先选定候选；同时界像保证整张候选名单，随后再看数据选人也仍在名单内。它不是说每个样本的预测误差都小于 ϵ。

统一收敛的直观证明。 对固定函数 f，若损失 $\ell(f(X),Y)\in[0,1]$，Hoeffding 不等式给出

$$\Pr\Big(|R(f)-\hat{R}(f)|>\epsilon\Big)\le 2\exp(-2n\epsilon^2). \tag{5.1}$$

若 $\mathcal{H}$ 是有限集合，对所有 $f\in\mathcal{H}$ 使用联合界可得

$$\Pr\Big(\sup_{f\in\mathcal{H}}|R(f)-\hat{R}(f)|>\epsilon\Big)\le 2|\mathcal{H}|\exp(-2n\epsilon^2). \tag{5.2}$$

这说明样本量需要随假设空间复杂度增加。对无限空间，可用 Vapnik–Chervonenkis (VC) 维、Rademacher 复杂度或覆盖数替代 $|\mathcal{H}|$。

从概率尾界到样本量。 以上 n 个样本必须独立同分布，$\mathcal{H}$ 应预先固定且非空；平方损失无界时不能不加条件地使用式(5.2)。为看到指数项的来源，令 $Z_i=\ell(f(X_i),Y_i)\in[0,1]$。有界变量的指数矩满足 $\mathbb{E}\exp(t(\mathbb{E}Z_i-Z_i))\le\exp(t^2/8)$；独立性使指数矩相乘。Markov 不等式给出

$$\Pr(R-\hat{R}>\epsilon)\le\exp(-tn\epsilon+nt^2/8). \tag{5.3}$$

取 $t=4\epsilon$ 得到单侧 $\exp(-2n\epsilon^2)$，对另一侧重复并相加即得双侧界。联合界不要求各函数的误差独立，因此适用于在同一数据上比较的多个模型。

令式(5.2)右端为 $\delta\in(0,1)$，解得以至少 $1-\delta$ 的概率，对所有 $f\in\mathcal{H}$ 同时成立

$$|R(f)-\hat{R}(f)|\le b_n,\qquad b_n=\sqrt{\frac{\log(2|\mathcal{H}|/\delta)}{2n}}. \tag{5.4}$$

若希望误差不超过 ϵ，充分条件是 $n\ge\log(2|\mathcal{H}|/\delta)/(2\epsilon^2)$。这是一条保守的充分保证，不是对具体任务所需数据量的精确预测。

设 $\hat{f}$ 最小化经验风险，$f^*_{\mathcal{H}}$ 最小化类内真实风险，则在式(5.4)对所有函数同时成立的事件上

$$R(\hat{f})\le\hat{R}(\hat{f})+b_n\le\hat{R}(f^*_{\mathcal{H}})+b_n\le R(f^*_{\mathcal{H}})+2b_n. \tag{5.5}$$

第一步和第三步都需要同时界；只给预先固定 f 的界无法直接代入数据依赖的 $\hat{f}$。若优化仅达到 η 精度，最后再加 η。相对所有可测函数中最优风险的差还包含类外近似误差，故增大 n 不能弥补错误的函数类。

代入数字检验界的含义。 若 $|\mathcal{H}| = 10$、$n = 1000$、$\delta = 0.05$，则 $b_n = \sqrt{\log(400)/2000} \approx 0.055$。经验错误率为 0.08 的所选函数，在同时界成立时真实错误率不超过约 0.135；相对类内最优函数的保证则需 $2b_n \approx 0.110$，不能把这两个误差半径混用。若要求 $b_n \le 0.05$，充分样本数为 $\lceil \log(400)/(2\times 0.05^2) \rceil = 1199$。这些数值较保守，说明“理论能证明”与“实验已经达到”是两种证据。

无限类段落中的 VC 维可先用一维阈值理解：一个点可以任意标为零或一，但两个由小到大排列的点不能得到“一、零”的标记，因此该类的 VC 维为一。Rademacher 随机符号则相当于独立抛硬币生成的正负记号；复杂度询问函数类能在多大程度上追随这种无规律波动。读者可先掌握这两个对象，再阅读它们的上界推导。

结构风险最小化。 经验风险最小化只看训练误差，结构风险最小化在一系列嵌套假设空间中选择复杂度。实际的正则化、树深度限制、网络宽度和数据增强都可视为控制有效复杂度的方法。理论上更强的模型仍可能泛化良好，因为优化算法偏爱某些简单或平滑的解。

复杂度惩罚如何随候选类分配。 对预先指定的每个有限类 $\mathcal{H}_m$，选择正权重 π_m。权重之和为一，并据此分配失败概率：

$$\sum_{m} \pi_m = 1, \qquad \delta_m = \delta \pi_m .$$

再次使用联合界，得到所有类同时有效的偏差界

$$b_m = \sqrt{\frac{\log(2|\mathcal{H}_m|/(\delta\pi_m))}{2n}}. \tag{5.6}$$

若在所有 $m, f \in \mathcal{H}_m$ 中最小化 $\hat{R}(f) + b_m$，则所选模型 $\tilde{f}$ 满足

$$R(\tilde{f}) \le \inf_{m} \inf_{f \in \mathcal{H}_m} \{ R(f) + 2b_m \}. \tag{5.7}$$

推导是先用 $R(\tilde{f}) \le \hat{R}(\tilde{f}) + b_{\tilde{m}}$，再用最小化性质与每个候选比较，最后把候选的经验风险换成真实风险。复杂类要靠真实的拟合改善抵消较大的惩罚，而不是仅靠训练误差获胜。

无限类需要什么替代量。 连续参数类通常有无限多个函数，不能把参数个数代入 $\log|\mathcal{H}|$。二分类的增长函数 $\Pi_{\mathcal{H}}(n)$ 计数在 n 个点上最多能实现多少种二元标记；若 VC 维为 d_{VC}，则 $n \ge d_{\mathrm{VC}} \ge 1$ 时有 $\Pi_{\mathcal{H}}(n) \le (en/d_{\mathrm{VC}})^{d_{\mathrm{VC}}}$。它衡量可区分的标记，而非参数存储量。

另一个视角是随机符号拟合能力。令损失类 $\mathcal{G} = \{(x,y) \mapsto \ell(f(x),y) : f \in \mathcal{H}\}$，独立符号 ϵ_i 等概率为 ± 1，定义

$$\mathfrak{R}_n(\mathcal{G}) = \mathbb{E}_{D,\epsilon} \sup_{g \in \mathcal{G}} \frac{1}{n} \sum_{i} \epsilon_i g(X_i, Y_i). \tag{5.8}$$

这里另记 $Z_i = (X_i, Y_i)$ 为一条样本，而非前面 Hoeffding 推导中的标量损失。引入独立同分布的复制样本 $D' = \{Z_i'\}_{i=1}^{n}$ 后，用 $R(g) = \mathbb{E}_{D'} \hat{R}_{D'}(g)$ 及上确界的凸性，得到

$$\mathbb{E}_D \sup_g (R(g) - \hat{R}_D(g)) \le \mathbb{E}_{D,D'} \sup_g \frac{1}{n} \sum_i (g(Z_i') - g(Z_i)) \tag{5.9}$$

$$\le 2\mathfrak{R}_n(\mathcal{G}). \tag{5.10}$$

第二步利用样本对可交换性插入随机符号，再将两个上确界分开。这解释了“能拟合纯随机波动”为什么意味着更大的乐观风险。若损失在 $[0,1]$ 内，替换一个样本使上确界至多改变 $1/n$，有界差分集中进一步给出以至少 $1-\delta$ 的概率，$\sup_g (R - \hat{R}) \le 2\mathfrak{R}_n(\mathcal{G}) + \sqrt{\log(1/\delta)/(2n)}$。这些结论仍依赖独立抽样和适当可测性，并非对重叠窗口的自动保证。

5.2 模型选择、校准与不平衡

模型选择偏差要求把调参与最终评价分离 [10]。深度网络校准研究则表明，分类正确率与概率可信度需要分别检验，温度缩放是一种后处理基

线 [27]。

模型选择与交叉验证。 若数据近似独立同分布，K 折交叉验证将训练集分为 K 份，轮流使用一份验证、其余训练。时间序列必须使用滚动窗口或前向验证，避免未来信息泄漏。超参数搜索也应嵌套在训练数据内部；否则测试集会逐渐变成隐形训练集。

交叉验证估计的是哪个算法。 设折索引为 $I_1, \dots, I_K$，超参数为 h，$\hat{f}_h^{(-k)}$ 表示只用第 k 折以外的数据完成预处理和训练后的模型。加权交叉验证风险为

$$\widehat{R}_{\mathrm{CV}}(h) = \frac{1}{n} \sum_{k=1}^{K} \sum_{i \in I_k} \ell(\hat{f}_h^{(-k)}(x_i), y_i). \tag{5.11}$$

每个损失的标签没有参与产生该预测，但不同折的训练集重叠，因此这些损失不是独立试验。选 $\hat{h} = \arg\min_h \widehat{R}_{\mathrm{CV}}(h)$ 后，最小分数有选择偏差：对带噪估计 $\hat{r}_h$，总有 $\mathbb{E} \min_h \hat{r}_h \le \min_h \mathbb{E}\hat{r}_h$。搜索越广，越容易挑中有利噪声。

嵌套验证在外层训练集内部完成全部内层选择，再对外层留出样本预测，评估的是“选择加训练”这一完整算法。最后可用所有开发数据重新选择并拟合，但外层分数并非这个最终参数向量的无偏测量。设备切分估计跨设备能力，前向切分估计未来能力；两者对应不同目标，不能由普通随机 K 折替代。

一轮嵌套选择到底留下了什么。 例如有六台开发设备，外层先留下设备 5、6；只在设备 1 至 4 内部比较两个窗口长度，每个内层训练折都重新拟合填补和标准化。选好长度后，用设备 1 至 4 重新训练，最后才预测设备 5、6。外层换组后，内层可能选到不同长度，这正是完整选择算法的表现，而不是执行错误。开发结束后另有独立测试设备时，应冻结最终流程再测试。超参数是训练前需选择的设置（如窗口长度），模型参数则是给定设置后从训练数据估计的数值（如回归系数）。

校准与决策。 分类器输出的分数不一定是概率。校准要求在所有预测为 p 的样本中，正例频率接近 p。可靠性图和 Expected Calibration Error 可用于检查校准。若预测要驱动检修、放行或停机决策，还应定义效用函数 $U(a,y)$，最终选择

$$a^*(x)=\arg\max_a \mathbb{E}_{p(y|x,\mathcal{D})}[U(a,y)]. \tag{5.12}$$

这说明“最准确的分类器”不一定产生“最优的行动”。

不平衡与置信区间。 少数类任务应报告每类召回率、宏平均 F_1 和 Area Under the Precision–Recall Curve (PR-AUC)。重采样、类别权重和阈值调整针对的是不同环节，不能混为一谈。性能估计还需要不确定性，可使用自助法在测试样本上重采样得到指标分布。跨设备评估时，设备级重采样比样本级重采样更能反映真实部署波动。

先读懂混淆矩阵，再读少数类指标。 把故障记为正类，TP、FP、FN 分别为正确告警、错误告警和漏报的数量。召回率为 $\mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$，精确率为 $\mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$，$F_1=2\mathrm{TP}/(2\mathrm{TP}+\mathrm{FP}+\mathrm{FN})$。例如 100 台设备中有 10 台故障，告警 12 台且其中 8 台故障，则召回率为 0.8、精确率为 2/3、$F_1=16/22\approx 0.727$。一直报正常也有 90% 准确率，却漏掉全部故障。若没有真实正例，召回率分母为零；若没有正类预测，精确率分母为零，此时原比值无定义，应说明报告约定，不能默认为性能完美。宏平均是先分别计算各类指标再等权平均，而不是先合并计数。PR 曲线扫描阈值形成精确率与召回率的对应关系；面积还应声明插值或平均精确率等计算约定。

类别权重为何改变概率含义。 令真实条件正例概率为 p，预测为 q，正负类权重为 $a,b>0$。固定输入处的加权交叉熵为 $L(q)=-ap\log q-b(1-p)\log(1-q)$。求导并令其为零，得到

$$-\frac{ap}{q}+\frac{b(1-p)}{1-q}=0,\qquad q^*=\frac{ap}{ap+b(1-p)}. \tag{5.13}$$

所以加权训练的理想输出一般不再是原始分布的 p。若模型恰好达到该最优且权重已知，可反解 $p = bq/[a(1-q)+bq]$；有限样本和错设模型下还需独立校准。重采样同样可能改变类别先验；它不应与只在预测后调整阈值混为一谈。

例如 $p = 0.1, a = 9, b = 1$ 时，理想加权输出为 $q^{*} = 0.5$，并不表示真实故障率升到了 50%；代入反解仍得到 $p = 0.1$。

精确率也直接受基率影响。若正例比例为 π、真正率为 u、假正率为 v，Bayes 公式给出

$$\mathrm{Precision} = \frac{\pi u}{\pi u + (1-\pi)v}. \tag{5.14}$$

即使排序和条件错误率不变，部署正例更稀少时精确率也会下降。跨工况比较精确率–召回率（Precision–Recall，PR）曲线应同时报告基率。

区间与配对比较的抽样单位。 若独立同分布测试单位上的损失 L_i 具有有限方差，令 $\bar{L} = n^{-1}\sum_i L_i$、$s_L^2 = (n-1)^{-1}\sum_i (L_i - \bar{L})^2$（$n > 1$）。$s_L$ 描述单个单位的损失波动，均值的标准误估计 $s_L/\sqrt{n}$ 描述重新抽取测试集时平均损失的波动，两者不能混用。大样本近似区间为 $\bar{L} \pm 1.96 s_L/\sqrt{n}$，其中 1.96 是标准正态分布的 97.5% 分位数，左右尾各留 2.5%。例如 $n = 100, \bar{L} = 4, s_L = 2$ 时，标准误为 0.2，区间为 $[3.608, 4.392]$。这只针对固定模型和既定测试分布，不包括训练随机性；稀有事件或小样本时正态近似可能不良。

比较模型 A、B 时应先在同一测试单位上计算 $d_i = L_{A,i} - L_{B,i}$，再估计 $\bar{d}$ 的区间，因为

$$\mathrm{Var}(L_A - L_B) = \mathrm{Var}(L_A) + \mathrm{Var}(L_B) - 2\,\mathrm{Cov}(L_A, L_B). \tag{5.15}$$

忽略配对会丢失共同设备难度的信息。对 G 台近似独立设备，自助法每次有放回抽取 G 个设备编号，保留所抽设备的全部窗口并重算指标；重复 B 次后取经验分位数作为近似区间。每台等权与每窗口等权是不同的目标，必须在每次重采样中维持原定义。设备数很少、设备之间相关或许多重采样没有正例时，区间本身也不可靠；增加重采样次数不会增加独立设备信息。

置信区间的概率究竟修饰什么。 设固定模型的总体平均损失为 μ，由随机测试数据 D 算出的区间为 $[L(D), U(D)]$。95% 置信区间的目标是 $P_D\{L(D) \le \mu \le U(D)\} \approx 0.95$：重复采集测试集并构造区间，约 95% 的区间覆盖固定的 μ。一次数据已经到手后，不能仅凭这一定义把它读成“μ 有 95% 概率位于当前两端点之间”。后续贝叶斯章节的可信区间则在给定数据和先验后，对未知参数的后验概率作陈述。预测区间又针对一个未来观测，不是总体均值；三者的对象和随机性不同。

自助法不是制造新设备。例如原有设备编号为 (A, B, C)，一次有放回抽样可能为 (C, C, A)，必须把 C 的全部记录按两次抽中计入，而非去重；另一次可能为 (B, A, B)。每次重算相同指标，所得波动近似原实验的抽样波动。只重采样测试设备、不重新训练时，估计的是固定模型的测试不确定性，不包含重训和选模波动。三个设备仅用于演示操作，不足以支撑可靠的 95% 区间。

5.3 从统计结论到实验设置

数据泄漏清单。 常见泄漏包括：用全数据计算标准化参数，把同一设备的相邻窗口分到训练和测试，利用故障发生后的变量预测故障发生前的状态，以及根据测试集反复选择模型。泄漏往往带来异常漂亮的结果，因此每个实验都应记录切分单位、时间边界、预处理拟合范围和标签生成时刻。

从固定函数到数据依赖的模型选择。 Hoeffding 界直接控制固定函数的经验风险偏差，但实际算法会根据数据选择函数。联合界的作用是同时控制整个假设空间，使“先看数据再选模型”仍有可分析的上界。代价是模型空间越复杂，需要更多样本或更强的结构约束。

容量不是参数数量的同义词。 参数数量相同，网络能表达的函数也未必相同。激活函数、连接方式和参数共享决定函数类，优化路径则影响训练最后选到其中哪些函数。例如卷积在不同位置使用同一组权重，注意力允

许相距较远的输入直接交互。分析泛化时，因此还要看函数类、参数范数、分类间隔和算法稳定性，不能仅按参数个数给模型排队。

交叉验证的工程细节。 预处理、特征选择和超参数搜索都必须在每个训练折内部拟合。若先对全体数据做标准化或选择相关特征，再执行交叉验证，验证折的信息已经泄漏。时间序列使用前向验证时，验证窗口必须位于训练窗口之后，必要时在二者之间设置间隔以避免标签窗口重叠。

不平衡、阈值与区间估计。 ROC-AUC 衡量排序能力，PR-AUC 更关注少数正类下的精确率和召回率。阈值改变会改变混淆矩阵，却不改变排序本身。若最终动作依赖阈值，应报告阈值扫描、成本曲线和置信区间。自助法重采样时，设备级任务应按设备重采样；否则同一设备的多个窗口会让区间过窄。

校准的后处理。 温度缩放在校准集上用一个正标量调整 logits（归一化前的类别得分），保持同一样本内部的类别次序，但不保证改善独立测试集的校准；Platt scaling 用逻辑函数映射分数，isotonic regression（保序回归）拟合非递减映射，二者对数据量和函数形状的要求不同。校准模型不能使用测试集反复调参，且分布变化后需要重新检查。对安全告警而言，概率校准和拒识机制常比少数百分点的准确率更重要。

温度缩放的目标与边界。 先冻结基模型及其预处理，再在校准集上保存 logits 并只拟合温度。部署时沿用相同变换；若用校准标签继续更新基模型，这批数据便不再是该模型的独立校准集，需要重新安排划分。对 C 类 logits $z_i \in \mathbb{R}^C$，在独立校准集上令 $T > 0$，定义 $q_{ic}(T) = \exp(z_{ic}/T)/\sum_j \exp(z_{ij}/T)$，最小化

$$L(T) = \sum_i \left[-z_{i,y_i}/T + \log \sum_c \exp(z_{ic}/T) \right]. \tag{5.16}$$

取逆温度 $\beta = 1/T$，则

$$L'(\beta) = \sum_i \left(\sum_c q_{ic} z_{ic} - z_{i,y_i} \right), \tag{5.17}$$

$$L''(\beta) = \sum_i \mathrm{Var}_{c \sim q_i}(z_{ic}) \geq 0. \tag{5.18}$$

求导时使用 $\partial_\beta q_{ic} = q_{ic}(z_{ic} - \sum_j q_{ij} z_{ij})$，故二阶导数正是得分的加权方差。因此这是一个一维凸优化问题（约束 $\beta > 0$）；下确界也可能只在 $\beta \to 0$ 或 $\beta \to \infty$ 时逼近，不能保证存在有限最优温度。正温度保持每个样本内部的类别次序和最大类别；多分类中不同样本的最大概率排序则未必保持，不能据此保证所有排序指标不变。它只能整体调整尖锐程度，无法修复所有类别和工况上的系统偏差。

二分类可靠性图把样本分入 B_m，计算箱内预测均值 $\bar{q}_m$ 和事件比例 $\bar{y}_m$；常用误差为 $\sum_m (|B_m|/N)|\bar{q}_m - \bar{y}_m|$。这是依赖分箱的经验统计量，不是证明条件校准的定理。箱数太少会掩盖局部偏差，太多则产生高方差，应同时报告样本量与可靠性图。

5.4 从统计量到决策

效用与损失只差一个决策方向。 效用 $U(a, y)$ 越大越好，损失 $C(a, y)$ 越小越好，取 $U = -C$ 便得到同一动作。若不检修时故障损失为 100、无故障损失为零；检修固定花费 8 且在这个简化例子中消除该次故障损失，则故障概率为 0.1 时不检修的期望损失为 10，检修为 8，故选检修。这里必须写明检修效果；若只检测而不消除风险，需要把后续动作和残余损失也列入成本，不能直接沿用阈值。

模型输出只是决策系统的一个中间量。若动作集合为 $\mathcal{A}$，效用函数为 $U(a, y)$，最优动作是期望效用最大的动作。不同部门可能面对不同成本，因此同一个概率模型可以配合不同阈值，而不必为每种成本重新训练。这个分离有助于审计模型能力和业务策略各自的变化。

统计学习中的复杂度界与实验估计可结合官方交叉验证文档和重采样教程复习，注意它们服务于不同的不确定性来源。

辅助学习材料

- **Cross-validation: evaluating estimator performance**；作者/平台：scikit-learn Developers；英文；官方文档。阅读 K-fold、group、stratified 与 nested selection 的说明，帮助落实本章的模型选择和泛化估计。在线阅读。

- **Prediction Intervals for Gradient Boosting Regression**;作者/平台：scikit-learn Developers；英文；官方示例。阅读分位数回归、区间覆盖率与调参部分，区分预测区间和参数置信区间；该示例不提供分布无关的覆盖保证。在线阅读。

- **【机器学习】什么是交叉验证？为什么以及如何进行交叉验证?**；知乎；中文解说。区分模型选择与最终泛化估计；标题与主题据必应索引，原页受限。在线阅读。

- **交叉验证方法汇总【附代码】(索引标题节选)**；CSDN；中文博客。比较留一法、K 折与分层划分，另行检查设备分组要求；标题与主题据必应索引，原页受限，完整标题未核实。在线阅读。

- **2022 - 再探宝可梦、数码宝贝分类器—浅谈机器学习原理**；李宏毅；bilibili；中文课程。选看第 23 集，结合本章假设空间与泛化条件讨论分类。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量；已核对目录与计数，未逐帧观看。观看分集。

5.5　本章小结

统计学习提供的是关于数据、模型复杂度和未见样本风险的推理框架。它不能保证某个模型在所有工业分布上有效，却能迫使实验者明确假设空间、验证规则、泄漏风险、不确定性和决策成本。

统一界考虑看过数据以后再选模型的影响，嵌套验证把挑选模型和报告成绩分开，配对比较与设备级区间估计则显示结果会怎样波动。比较平均误差前，要先核对任务、抽样单位和尝试方案的预算是否一致；选择告警阈值时，还要看校准和成本。下一章回到原始记录：如果不知道记录何时可用、标签何时截止、样本来自哪台设备，再严谨的统计计算也无法回答原先的维护问题。

第二部分

贝叶斯机器学习：用概率表达知识与不确定性

前一部分已经规定了输入、标签、时间边界和验收动作，但点预测仍没有说明“这次判断有多可靠”。本部分保持贯穿案例不变，只改变答案的表达方式：先用贝叶斯更新描述有限证据，再比较参数化与非参数化模型如何表达函数不确定性。读者应看到，概率不是给结果加一个置信度装饰，而是改变训练目标、预测输出和维护决策的依据；下一部分将在这些边界上选择更强的表示模型。

第六章　概率图模型

本章摘要。概率图模型用图表示随机变量之间的条件独立关系，用局部分布或势函数构造联合分布。本章从朴素贝叶斯的条件独立假设出发，把已知类别改为隐变量，建立高斯混合模型，再把单个隐变量扩展为状态序列，介绍状态空间模型及其推断。随后从局部归一化的最大熵马尔可夫模型转入全局归一化的条件随机场，解释无向图的分离、团分解和能量表达，最后介绍玻尔兹曼机与受限玻尔兹曼机。各模型的差异落实为边的方向、节点取值、条件独立关系、隐变量安排和分布参数化五个方面。

温度和振动可能共同受到设备状态影响，相邻时刻的状态也可能相关。若直接列出所有变量的联合概率，离散变量的配置数会随变量个数指数增长。概率图模型（Probabilistic Graphical Model，PGM）通过明确哪些依赖需要保留，把联合分布拆成较小的部分 [7, 61]。图给出分布的结构，具体概率还需要由局部分布及其参数确定。

本章以朴素贝叶斯作为简单起点。先把类别视为已知标签，再把它变为需要推断的隐变量，随后让隐状态沿时间连接。接着改变建模目标，直接学习给定观测后的标签分布，并比较局部归一化与全局归一化。最后在无向图中引入二元隐变量，研究怎样通过限制连边获得较容易计算的模型。这是一条逐步改变假设的教学路线，各模型之间的联系将在相应分布上说明。

阅读时要区分随机变量、变量的观测值与模型参数。以下用大写 X, Y, Z 表示随机变量，小写 x, y, z 表示取值，θ 表示参数。$x_{1:T}$ 表示从第一个到第 T 个时刻的观测序列。推断是在参数给定时计算未知变量的分布，学习是用数据估计参数。贝叶斯公式是推断的基本工具，但图模型也可以用最大似然学习参数。

6.1 从朴素贝叶斯理解有向图

6.1.1 类别如何把多个观测联系起来

假设根据温度是否偏高 X_1 和振动是否偏高 X_2，判断设备状态 $Y \in \{0,1\}$，其中 0 为正常，1 为退化。朴素贝叶斯（Naive Bayes，NB）假设：给定类别后，各观测特征条件独立。对 d 个特征，这一假设写成

$$p(x_1,\dots,x_d \mid y)=\prod_{j=1}^{d} p(x_j \mid y), \qquad p(y,x_1,\dots,x_d)=p(y)\prod_{j=1}^{d} p(x_j \mid y). \tag{6.1}$$

这里 $p(y)$ 是类别先验，$p(x_j \mid y)$ 是类别给定时第 j 个特征的分布。二元特征可以使用伯努利分布，连续特征可以使用高斯分布，同一个图也可以同时包含这两类节点。

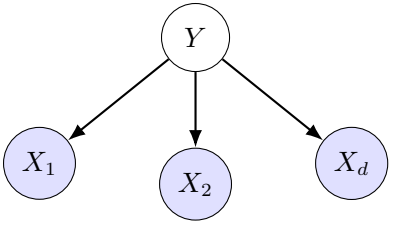


图 6.1： 朴素贝叶斯的有向图。类别是各特征的共同父节点，给定类别后特征条件独立。训练时类别通常已知，预测时需要根据特征推断类别。

图6.1中没有特征间的直接连边。它允许特征通过类别产生边缘相关。例如，设 $p(Y=1)=0.2$，退化时温度和振动各以 0.8 概率偏高，正常时各以 0.1 概率偏高，并采用条件独立假设。则

$$p(X_1=1,X_2=1)=0.2\times 0.8^2+0.8\times 0.1^2=0.136, \tag{6.2}$$

$$p(X_1=1)p(X_2=1)=(0.2\times 0.8+0.8\times 0.1)^2=0.0576. \tag{6.3}$$

两个数不同，说明温度和振动在不知道状态时相关。条件独立只在所给条件下成立。

观察到两个特征都偏高后，贝叶斯公式给出

$$p(Y=1 \mid X_1=1, X_2=1)=\frac{0.2\times 0.8^2}{0.2\times 0.8^2+0.8\times 0.1^2}=\frac{16}{17}. \tag{6.4}$$

分子衡量退化类别对观测的解释，分母对所有类别求和。若给定状态后两个传感器仍有共享噪声，该分解会重复计算相关证据，可能产生过于集中的类别概率。分类效果和概率校准都需要在独立数据上检验。

6.1.2 有向无环图怎样定义分布

朴素贝叶斯是贝叶斯网络（Bayesian Network，BN）的一种简单结构。贝叶斯网络使用有向无环图（Directed Acyclic Graph，DAG）。有向边 $X_i \to X_j$ 把 X_i 列入 X_j 的父节点，无环表示沿箭头无法回到出发节点。

按拓扑顺序排列 m 个变量，使父节点先于子节点出现。概率链式法则给出

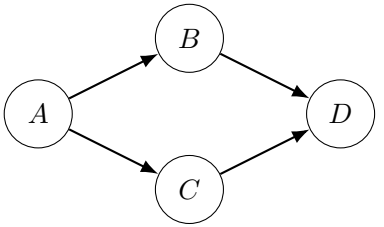
$$p(x_1,\dots,x_m)=\prod_{j=1}^{m} p(x_j \mid x_1,\dots,x_{j-1}). \tag{6.5}$$

再假设给定父节点后，X_j 与其余先前变量条件独立，就得到贝叶斯网络的分解

$$p(x_1,\dots,x_m)=\prod_{j=1}^{m} p(x_j \mid x_{\mathrm{pa}(j)}). \tag{6.6}$$

$\mathrm{pa}(j)$ 表示节点 j 的父节点集合，没有父节点时使用边缘分布。每个因子都对自己的节点归一化，因而整个联合分布归一化。删去条件依赖是建模假设，需要数据或领域知识支持。箭头规定分布如何分解，因果解释还需要额外假设。

图6.2给出一个具体例子。链式法则原本含 $p(c \mid a,b)$ 与 $p(d \mid a,b,c)$，图结构分别将它们简化为 $p(c \mid a)$ 与 $p(d \mid b,c)$。这两处简化对应 $C \perp B \mid A$ 和 $D \perp A \mid (B,C)$。读图时先列出每个节点的父节点，再将对应条件分布相乘。



拓扑顺序：A, B, C, D

父节点：$\mathrm{pa}(D) = \{B, C\}$

$$p(a, b, c, d) = p(a)p(b \mid a)p(c \mid a)p(d \mid b, c)$$

图 6.2: 从有向图读取分解。每个节点贡献一个给定父节点的因子；B, C 共同作为 D 的条件。

6.1.3 用 d-分离判断条件独立

条件独立 $X \perp Y \mid S$ 表示：给定 $S = s$ 后，知道 X 不会改变 Y 的条件分布。离散变量在 $p(s) > 0$ 时满足

$$p(x, y \mid s) = p(x \mid s)p(y \mid s). \tag{6.7}$$

连续变量用条件密度表达相同关系。条件集合 S 可以包含多个变量。仅看两点之间是否有边，无法判断它们是否条件独立，还需要检查连接它们的路径。

d-分离（d-separation）提供从 DAG 读出条件独立关系的规则。检查路径时，先忽略边的方向以寻找路径，再根据箭头在每个中间节点的会合方式判断路径是否阻断。三种基本结构如下。

1. 链 $X \to Z \to Y$ 或 $X \leftarrow Z \leftarrow Y$。中间节点 Z 在条件集合中时，路径被阻断。例如知道当前状态后，更早状态不会经这条链额外影响下一状态。

2. 分叉 $X \leftarrow Z \to Y$。共同父节点 Z 在条件集合中时，路径被阻断。朴素贝叶斯的各特征属于这种情形。

3. 碰撞 $X \to Z \leftarrow Y$。只有当 Z 自身或它的某个后代在条件集合中时，这个中间节点才允许路径通过。后代指从 Z 沿箭头能够到达的节点。

图6.3显示，条件化对碰撞结构与另外两种结构的作用不同。前两类的中间节点称为非碰撞节点。给定条件集合 S，一条路径活跃需要同时满足：

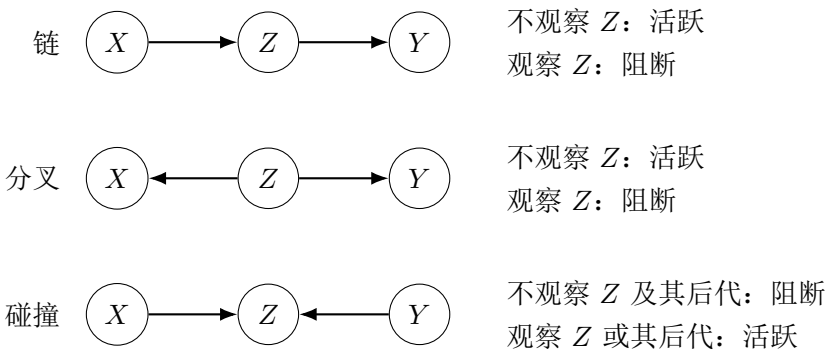


图 6.3: d-分离的三种基本路径结构。这里仅判断所画路径，假定端点不在条件集合中。存在其他路径时，还需逐条检查。

路径上的所有非碰撞中间节点都不在 S 中，每个碰撞中间节点自身或至少一个后代在 S 中。若两个互不相交节点集合 A, B 之间的所有路径都被阻断，就称 A 和 B 被 S d-分离。S 还应与 A, B 不相交。

实际判断时，可以先标记 S 及其祖先，再逐条检查 A 到 B 的路径。某个非碰撞节点属于 S，或者某个碰撞节点不属于 S 且没有后代属于 S，都会阻断该路径。所有路径阻断才能推出 $X_A \perp X_B \mid X_S$。只找到一条阻断路径并不足够。

为什么观察碰撞节点会引入依赖。 令 X, Y 为两个独立二元原因，各以 $1/2$ 概率发生，$Z = 1$ 表示至少一个原因发生。未观察 Z 时，X 与 Y 独立。观察 $Z = 1$ 后，(X, Y) 只可能是 $(1,0), (0,1), (1,1)$ 且等概率，所以 $p(Y = 1 \mid Z = 1) = 2/3$。若又知道 $X = 0$，则 $p(Y = 1 \mid Z = 1, X = 0) = 1$。选择了共同结果以后，两个原因产生依赖。若只观察 Z 的一个有信息的后代，也可能产生这种依赖。

为什么必须检查所有路径。 考虑 $A \to B \to D$ 和 $A \to C \to D$ 组成的菱形 DAG。给定 B 只阻断第一条路径，第二条仍活跃。给定 B, C 才阻断全部路径，从而得到 $A \perp D \mid (B, C)$。d-分离保证该图所分解的所有分布都具有相应独立性。反过来，路径活跃只说明图结构不保证独立，某些特殊参

数仍可能使变量独立。若要由分布中的独立性反推图结构，还需要忠实性等额外条件。

6.2 从已知类别到单个隐变量：高斯混合模型

6.2.1 把类别变成需要推断的变量

若训练数据只有温度和振动，没有状态标签，就无法直接按类别统计 $p(x \mid y)$。可以引入一个未观测的类别变量 $Z \in \{1, \dots, K\}$，用它表示样本属于哪个成分。隐变量（Latent Variable）是模型中的随机变量，未观测的取值需要根据数据推断。它与控制分布形状的参数不同。

若只把朴素贝叶斯的类别隐藏起来，得到的是隐类别模型。再规定每个类别下的连续观测服从高斯分布，才得到高斯混合模型（Gaussian Mixture Model，GMM）：

$$p(Z = k) = \pi_k, \qquad \pi_k \geq 0, \quad \sum_{k=1}^{K} \pi_k = 1, \tag{6.8}$$

$$p(x \mid Z = k) = \mathcal{N}(x; \mu_k, \Sigma_k), \tag{6.9}$$

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x; \mu_k, \Sigma_k). \tag{6.10}$$

其中 $x, \mu_k \in \mathbb{R}^d$，$\Sigma_k \in \mathbb{R}^{d \times d}$ 为正定协方差矩阵。生成一个样本时，先按 π 抽取成分，再从该成分的高斯分布抽取观测。每个样本有自己的 Z_i，各样本在给定共享参数后独立。“单个隐变量”指每个样本只有一个成分指示变量。

若 Σ_k 为对角矩阵，给定成分后各特征独立，与高斯朴素贝叶斯具有相同的星形分解。一般 GMM 允许完整协方差，此时给定 Z 后观测分量仍可能相关。若把整个向量 X 画成一个节点，$Z \to X$ 不会表达向量内部是否独立，必须进一步说明协方差结构。引入隐变量本身不会强制高斯分布或对角协方差。

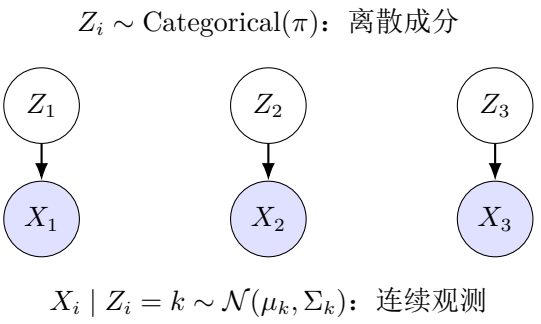


图 6.4: GMM 的图结构，以三个独立样本为例。白色为隐变量，蓝色为观测变量。各样本共享参数 π, μ_k, Σ_k，图中参数视为给定，样本之间没有转移边。

图6.4中，每条 $Z_i \to X_i$ 连接表示 $p(z_i)p(x_i \mid z_i)$。观测密度 $p(x_i)$ 需要对该样本的成分 Z_i 求和。后面建立序列模型时，将在这些成分节点之间加入状态转移边。

6.2.2 后验责任度与 EM 学习

观察到 x_i 后，成分后验为

$$r_{ik} = p(Z_i = k \mid x_i) = \frac{\pi_k \mathcal{N}(x_i; \mu_k, \Sigma_k)}{\sum_{\ell=1}^{K} \pi_\ell \mathcal{N}(x_i; \mu_\ell, \Sigma_\ell)}. \tag{6.11}$$

r_{ik} 称为责任度，表示第 k 个成分对样本 i 的后验权重，各成分责任度之和为一。例如两个成分等权，均值分别为 $0, 2$，方差均为 1。对 $x = 1$，两成分密度相同，责任度各为 $1/2$。对 $x = 2$，第二个成分的责任度为 $1/(1+e^{-2}) \approx 0.881$。这是保留成分不确定性的软分配。

训练要最大化观测对数似然

$$\ell(\theta) = \sum_{i=1}^{n} \log \sum_{k=1}^{K} \pi_k \mathcal{N}(x_i; \mu_k, \Sigma_k). \tag{6.12}$$

求和处于对数内部，使直接求解较困难。期望最大化（Expectation Maximization，EM）先用旧参数计算责任度，再以责任度为权重更新参数。令

$N_k = \sum_i r_{ik}$，则

$$\pi_k^{\text{new}} = N_k/n, \qquad \mu_k^{\text{new}} = \frac{1}{N_k}\sum_i r_{ik}x_i, \tag{6.13}$$

$$\Sigma_k^{\text{new}} = \frac{1}{N_k}\sum_i r_{ik}(x_i-\mu_k^{\text{new}})(x_i-\mu_k^{\text{new}})^{\mathsf{T}}. \tag{6.14}$$

N_k 是期望样本数，可以不是整数。更新对应最大化期望完整数据对数似然。精确 E 步和 M 步保证观测似然不下降，但不能保证全局最优。若 $N_k = 0$，更新无定义。若协方差收缩到零，未约束的高斯混合似然可能无界，因此需要限制协方差、设置下界或使用先验。成分编号可以任意置换，不能自动解释为正常、退化或故障。

6.3 从单个隐变量到状态序列

6.3.1 状态空间模型的结构假设

GMM 没有规定相邻样本的先后关系。若设备状态会持续一段时间，需要为每个时刻设置 Z_t，再用状态转移连接它们。状态空间模型（State-Space Model，SSM）以隐状态序列解释观测序列。常用的一阶形式为

$$p(z_t \mid z_{1:t-1}) = p(z_t \mid z_{t-1}), \tag{6.15}$$

$$p(x_t \mid z_{1:T}, x_{1:t-1}) = p(x_t \mid z_t), \tag{6.16}$$

$$p(z_{1:T}, x_{1:T}) = p(z_1)p(x_1 \mid z_1)\prod_{t=2}^{T} p(z_t \mid z_{t-1})p(x_t \mid z_t). \tag{6.17}$$

第一式是一阶马尔可夫假设，当前状态只需通过上一状态读取过去。第二式是观测条件独立假设，给定状态序列后，各时刻观测独立，每个观测只依赖当前状态。它允许同一时刻的多个传感器采用联合观测分布。

齐次性是另一个假设：转移核 $p(z_t \mid z_{t-1})$ 不随 t 改变。它不由一阶马尔可夫性推出，也不保证状态边缘分布不随时间变化。传感器关系不变时，

还可假设观测分布参数在时间上共享。时变模型仍可以保留相同的链式图，改变的是局部分布参数。

隐状态可以离散，也可以连续。有限离散状态的模型通常称为隐马尔可夫模型。连续状态若满足线性高斯条件，可以用卡尔曼滤波精确推断。非线性或非高斯模型可以考虑粒子滤波近似推断。隐马尔可夫模型是一类模型，卡尔曼滤波和粒子滤波是推断算法，不能仅按名称把它们并列为三种图结构。

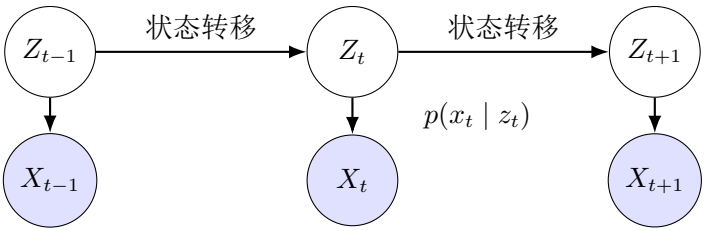


图 6.5: 状态空间模型的局部链结构。白色状态节点可离散或连续，蓝色节点为观测。线性高斯模型和 HMM 具有相同的依赖结构，区别在于节点取值和局部分布。

图6.5中的状态连边是相对于独立 GMM 新增的依赖。图不规定转移是否齐次，也不规定局部分布是否高斯，这些条件需要另行说明。

6.3.2 链结构怎样支持递归推断

过滤（Filtering）计算 $p(z_t \mid x_{1:t})$，只使用截至当前的观测。递推分为预测和更新：

$$p(z_t \mid x_{1:t-1}) = \int p(z_t \mid z_{t-1}) p(z_{t-1} \mid x_{1:t-1})\, dz_{t-1}, \tag{6.18}$$

$$p(z_t \mid x_{1:t}) = \frac{p(x_t \mid z_t) p(z_t \mid x_{1:t-1})}{\int p(x_t \mid u) p(u \mid x_{1:t-1})\, du}. \tag{6.19}$$

第一步将上一时刻的状态不确定性通过转移传播到当前，第二步用新观测重新加权。离散状态把积分改为求和。分母是预测观测密度，必须正且有限。不同过滤算法的区别，在于怎样表示状态分布并完成这两步运算。

6.3.3 线性高斯模型与卡尔曼滤波

设连续状态 $z_t \in \mathbb{R}^q$，观测 $x_t \in \mathbb{R}^d$，线性高斯模型为

$$z_t = F_t z_{t-1} + \eta_t, \qquad x_t = H_t z_t + \varepsilon_t, \quad \eta_t \sim \mathcal{N}(0, Q_t), \quad \varepsilon_t \sim \mathcal{N}(0, R_t). \tag{6.20}$$

$F_t \in \mathbb{R}^{q\times q}$ 描述状态转移，$H_t \in \mathbb{R}^{d\times q}$ 把状态映射为观测，Q_t, R_t 分别描述过程噪声和观测噪声。假设初始状态高斯，各时刻噪声彼此独立且与初始状态独立，R_t 正定。常数矩阵对应时间齐次的常用情形，时变矩阵也可使用以下递推。

若上一过滤分布为 $\mathcal{N}(m_{t-1}, P_{t-1})$，线性变换和独立高斯相加给出预测均值 $m_t^- = F_t m_{t-1}$ 与协方差 $P_t^- = F_t P_{t-1} F_t^{\mathsf{T}} + Q_t$。给定过去观测，状态与当前观测共同服从

$$\begin{bmatrix} z_t \\ x_t \end{bmatrix} \,\Big|\, x_{1:t-1} \sim \mathcal{N}\left(\begin{bmatrix} m_t^- \\ H_t m_t^- \end{bmatrix}, \begin{bmatrix} P_t^- & P_t^- H_t^{\mathsf{T}} \\ H_t P_t^- & H_t P_t^- H_t^{\mathsf{T}} + R_t \end{bmatrix} \right). \tag{6.21}$$

右下块是观测预测协方差，非对角块是状态与观测的交叉协方差。对这个联合高斯分布以当前观测 x_t 条件化，得到卡尔曼滤波（Kalman Filter，KF）[39]：

$$m_t^- = F_t m_{t-1}, \qquad P_t^- = F_t P_{t-1} F_t^{\mathsf{T}} + Q_t, \tag{6.22}$$

$$S_t = H_t P_t^- H_t^{\mathsf{T}} + R_t, \qquad K_t = P_t^- H_t^{\mathsf{T}} S_t^{-1}, \tag{6.23}$$

$$m_t = m_t^- + K_t (x_t - H_t m_t^-), \qquad P_t = P_t^- - K_t S_t K_t^{\mathsf{T}}. \tag{6.24}$$

上标 $-$ 表示接收当前观测之前，S_t 为预测观测误差的协方差，K_t 为卡尔曼增益。均值修正量由观测残差和两类不确定性的相对大小决定。实际计算用线性方程求解代替显式求逆，并使用稳定的协方差更新。

一维例子中，若预测状态均值为 0、方差为 4，观测 $x_t = 3$，$H_t = 1$，观测噪声方差为 1，则 $K_t = 4/5$，更新均值为 2.4，方差为 0.8。较精确的观测使更新更靠近观测。这里高斯分布在预测和更新后保持封闭，因此均

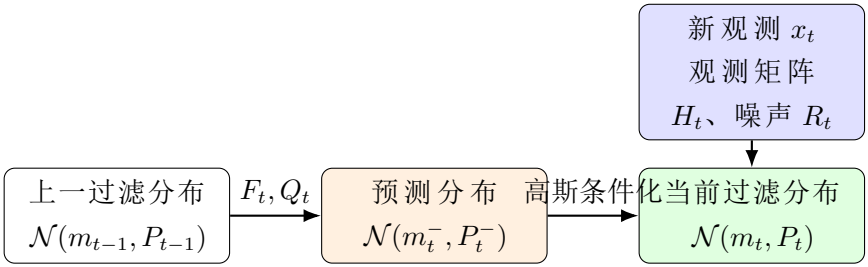


图 6.6: 卡尔曼滤波的计算流程。状态空间图仍如图6.5，这里的方框表示分布与计算步骤，箭头表示计算次序。线性高斯条件使预测与更新后的分布始终保持高斯形式。

值和协方差足以表示精确过滤分布。只有马尔可夫性与观测独立性，还不足以得到这个高斯递推。

图6.6把前面的递推分成两步。预测传播上一分布的均值与协方差，更新使用观测残差修正均值，并减少条件不确定性。

6.3.4 非线性、非高斯模型与粒子滤波

若状态转移或观测关系非线性，或者过滤分布有多个峰，仅传播均值和协方差可能遗漏重要结构。粒子滤波（Particle Filter，PF）用带权样本近似过滤分布：

$$p(z_t \mid x_{1:t}) \approx \sum_{s=1}^{M} w_t^{(s)} \delta_{z_t^{(s)}}(z_t), \qquad w_t^{(s)} \geq 0, \quad \sum_s w_t^{(s)} = 1. \tag{6.25}$$

M 为粒子数，δ_a 表示集中于 a 的单位点质量，每个粒子代表一种可能状态。这个表达是离散测度近似，不要求真实状态离散。

以转移分布为提议的自举粒子滤波，先从 $p(z_t \mid z_{t-1}^{(s)})$ 传播每个粒子，再更新

$$\widetilde{w}_t^{(s)} = w_{t-1}^{(s)} p(x_t \mid z_t^{(s)}), \qquad w_t^{(s)} = \frac{\widetilde{w}_t^{(s)}}{\sum_r \widetilde{w}_t^{(r)}}. \tag{6.26}$$

这是式(6.19)的采样实现。如果先对祖先按旧权重重采样，旧权重已包含在祖先选择中，本步权重只需正比于观测似然。重采样复制高权重粒子并舍

弃低权重粒子，之后权重设为 $1/M$。它缓解权重集中，但也可能减少粒子多样性，不能凭空找回已遗漏的状态区域。

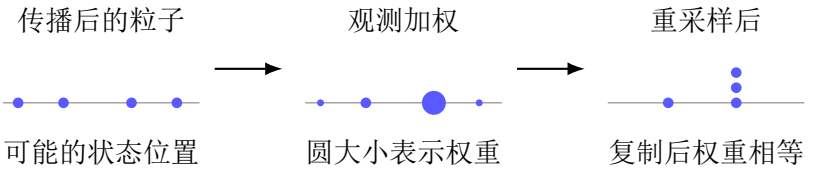


图 6.7: 粒子滤波的一维状态示意。观测似然改变权重；图示一次可能的重采样结果，高权重粒子被复制，低权重粒子可能消失。右侧同位置的三个粒子竖向错开以便显示，实际状态相同。重采样不是每步必须执行的操作。

图6.7用圆的位置表示状态，用大小表示权重。它展示的是分布近似与计算过程，所依据的随机变量图仍是图6.5。

有效粒子数常估计为 $1/\sum_s (w_t^{(s)})^2$，可用于决定何时重采样。粒子数有限会带来采样误差，高维状态下权重退化可能很严重。粒子滤波不要求齐次转移，适用于能够采样转移、评价观测似然并满足相应支持条件的模型。

6.3.5 有限离散状态与隐马尔可夫模型

隐马尔可夫模型（Hidden Markov Model，HMM）把状态空间限制为有限集合。其前向后向、最优路径与参数估计可参照 Rabiner 的教程 [65]。下面将通用过滤递推具体化为有限求和。设 $x_{1:T}$ 为一段设备观测，$z_t \in \{1,\dots,K\}$ 为时刻 t 的隐状态。HMM 采用一阶马尔可夫性和观测条件独立性：

$$p(z_t \mid z_{1:t-1}) = p(z_t \mid z_{t-1}), \tag{6.27}$$

$$p(x_t \mid z_{1:T}, x_{1:t-1}) = p(x_t \mid z_t). \tag{6.28}$$

记初始概率为 π_k，转移概率为 $A_{jk} = p(z_t = k \mid z_{t-1} = j)$，观测密度或概率为 $b_k(x) = p(x \mid z_t = k)$。其中 $\pi \in \mathbb{R}^K$、$A \in \mathbb{R}^{K\times K}$，行索引 j 是出发状态，列索引 k 是到达状态；离散观测的 b_k 为概率，连续观测时为密度。联合分

布分解为

$$p(x_{1:T}, z_{1:T}) = \pi_{z_1} b_{z_1}(x_1) \prod_{t=2}^{T} A_{z_{t-1}, z_t} b_{z_t}(x_t). \tag{6.29}$$

图6.8可以直接读成式(6.29)的联合分布：每个节点贡献一个给定父节点的

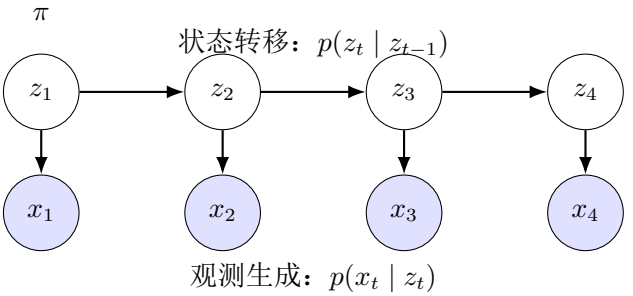


图 6.8: HMM 的有向图结构（以四个时刻为例）。白色圆为隐状态，蓝色圆为已观测变量；横向箭头表示状态转移，向下箭头表示观测生成。箭头表示概率分解关系，不自动代表因果关系。

条件分布，首个状态贡献初始分布。给定 z_t 后，x_t 与其他时刻的变量条件独立；但只给定观测而未固定隐状态时，各时刻观测通常仍然相关。图中的向下箭头是模型定义的生成方向，推断时则可以从观测反过来更新隐状态的概率。

每行转移概率之和为一。多通道观测可以用联合高斯分布或混合分布描述，HMM 并不要求同一时刻的各传感器通道独立。真正受限制的是跨时刻的依赖：一旦给定状态序列，观测之间便被假定条件独立。

以“正常、退化、故障”三个状态为例，转移矩阵可以表达状态持续性。禁止某条转移必须有物理依据，例如只有在明确排除维修过程的运行片段内，才可能限制故障状态不能直接返回正常。无监督学习得到的三个隐状态也不会自动具有这三个语义，需要通过标注、特征分布或专家检查建立对应关系。

过滤、平滑与最优路径。 在线维护需要 $p(z_t \mid x_{1:t})$，称为过滤；事后分析使用 $p(z_t \mid x_{1:T})$，称为平滑。后者利用未来观测，不能直接作为实时告警

的性能。若需要解释整段运行过程，还可以寻找联合概率最大的状态路径。这三个问题的输出不同，即使使用同一个 HMM，也不能混用结果。

直接枚举所有状态路径需要考虑 K^T 种配置。前向算法利用链结构复用公共计算，令 $\alpha_t(k) = p(x_{1:t}, z_t = k)$，则

$$\alpha_1(k) = \pi_k b_k(x_1), \tag{6.30}$$

$$\alpha_t(k) = b_k(x_t) \sum_{j=1}^{K} \alpha_{t-1}(j) A_{jk}, \tag{6.31}$$

$$p(z_t = k \mid x_{1:t}) = \frac{\alpha_t(k)}{\sum_j \alpha_t(j)}. \tag{6.32}$$

最后一时刻的前向量求和即为 $p(x_{1:T})$。每步对 K^2 个状态对计算，总复杂度为 $O(TK^2)$。长序列中概率连乘会下溢，应逐步缩放或在对数域使用 log-sum-exp，并保留缩放因子以恢复序列似然。

后向量 $\beta_t(j) = p(x_{t+1:T} \mid z_t = j)$ 满足

$$\beta_T(j) = 1, \qquad \beta_t(j) = \sum_{k=1}^{K} A_{jk} b_k(x_{t+1}) \beta_{t+1}(k). \tag{6.33}$$

于是平滑概率为 $\gamma_t(k) = \alpha_t(k)\beta_t(k)/p(x_{1:T})$。前向量汇总过去证据，后向量汇总未来证据，这也给出了链式消息传递的具体形式。

Viterbi 算法将前向递推中的求和替换为最大值。在对数域中，

$$\delta_t(k) = \log b_k(x_t) + \max_j \{\delta_{t-1}(j) + \log A_{jk}\}, \qquad \delta_1(k) = \log \pi_k + \log b_k(x_1). \tag{6.34}$$

保存每步最大值对应的前驱，便可从终点回溯路径。逐时刻选择边缘概率最大的状态与 Viterbi 路径通常不同，前者优化逐点分类，后者优化整条路径的联合概率。在存在禁止转移时，逐点选择甚至可能产生不合法路径。

两状态、两时刻的过滤手算。 设状态为正常 N、退化 D，$\pi=(0.8,0.2)$，按 N,D 排列的转移矩阵为

$$A=\begin{bmatrix}0.9 & 0.1\\ 0.2 & 0.8\end{bmatrix},\qquad P(\text{高振动}\mid N)=0.1,\quad P(\text{高振动}\mid D)=0.7. \tag{6.35}$$

首次看到高振动时，$\alpha_1=(0.08,0.14)$，所以退化过滤概率为 $0.14/0.22=7/11$。第二次仍为高振动，先转移再乘观测概率，得到 $\alpha_2(N)=(0.08\times0.9+0.14\times0.2)\times0.1=0.0100$，$\alpha_2(D)=(0.08\times0.1+0.14\times0.8)\times0.7=0.0840$。新的退化概率为 $0.084/0.094\approx0.894$。

若事后回看第一个时刻，$\beta_1(N)=0.9\times0.1+0.1\times0.7=0.16$，$\beta_1(D)=0.2\times0.1+0.8\times0.7=0.58$，所以退化平滑概率为 $0.14\times0.58/0.094\approx0.864$。它不同于当时可算的 $7/11$，因为第二次高振动已经提供了未来证据。此处 $\alpha_t,\beta_t,\gamma_t$ 各有 K 个分量，A 为 $K\times K$ 矩阵，ξ_t 也为 $K\times K$ 相邻状态概率表。

前向后向递推的推导与稳定实现。 固定当前状态 k，对前驱 j 边缘化：

$$p(x_{1:t},z_t=k)=\sum_j p(x_t\mid z_t=k)p(z_t=k\mid z_{t-1}=j)p(x_{1:t-1},z_{t-1}=j) \tag{6.36}$$

$$=b_k(x_t)\sum_j A_{jk}\alpha_{t-1}(j). \tag{6.37}$$

条件独立允许把观测因子提到求和外。相似地，从 z_{t+1} 边缘化得到后向递推；给定 z_t 后过去和未来的观测分离，因此 $\alpha_t(k)\beta_t(k)$ 就是 $p(x_{1:T},z_t=k)$。求和表示保留所有可能路径，Viterbi 的最大值则丢弃每个终点下非最优前缀；链结构保证最优前缀可扩展为最优整段路径。

数值上令 $h_{t-1}(j)=p(z_{t-1}=j\mid x_{1:t-1})$，计算

$$u_t(k)=b_k(x_t)\sum_j h_{t-1}(j)A_{jk},\quad c_t=\sum_k u_t(k),\quad h_t(k)=u_t(k)/c_t. \tag{6.38}$$

第一步用 $u_1(k)=\pi_k b_k(x_1)$。于是 $c_t=p(x_t\mid x_{1:t-1})$ 且 $\log p(x_{1:T})=\sum_t \log c_t$；缩放后的后向递推对应除以 c_{t+1}。精确运算下 $c_t=0$ 表示当前证据不在模型支持内；浮点计算中的零也可能来自观测密度或乘积下溢，应先用对数域区分二者，再检查零转移与观测支持。对数域的 $\log\sum_j e^{a_j}=m+\log\sum_j e^{a_j-m}$（$m=\max_j a_j$ 有限）提供稳定计算；若所有 $a_j=-\infty$，结果直接取 $-\infty$，不能计算 $-\infty-(-\infty)$。

从隐状态推断到参数学习。 隐状态未标注时，Baum–Welch 算法以 Expectation Maximization (EM) 交替估计状态的后验占用和模型参数。E 步计算 $\gamma_t(j)$ 以及相邻状态的后验概率

$$\xi_t(j,k)=\frac{\alpha_t(j)A_{jk}b_k(x_{t+1})\beta_{t+1}(k)}{p(x_{1:T})}. \tag{6.39}$$

对一条序列，M 步的转移更新为

$$A_{jk}^{\text{new}}=\frac{\sum_{t=1}^{T-1}\xi_t(j,k)}{\sum_{t=1}^{T-1}\gamma_t(j)}. \tag{6.40}$$

初始分布更新为 $\pi_k^{\text{new}}=\gamma_1(k)$，观测分布则按 $\gamma_t(k)$ 进行加权估计。多条独立运行序列需要分别推断后再汇总计数，不能把不同设备的尾部与头部连接成一次状态转移。EM 依赖初始化，只保证在精确 E、M 步下不降低训练似然，不能保证找到全局最优参数。

EM 为什么得到期望计数比。 取 $q(z)=p(z\mid x,\theta^{\text{old}})$，由 Jensen 不等式，

$$\log p_\theta(x)\ge \mathbb{E}_q\log p_\theta(x,z)-\mathbb{E}_q\log q(z). \tag{6.41}$$

在旧参数处等号成立；M 步保持 q 固定并提高右端，便不降低观测似然。转移相关部分是 $\sum_{jk}N_{jk}\log A_{jk}$，其中 $N_{jk}=\sum_{t<T}\xi_t(j,k)$。对每行加入约束乘子 $\lambda_j(\sum_k A_{jk}-1)$，一阶条件 $N_{jk}/A_{jk}+\lambda_j=0$ 与行和为一给出 $A_{jk}=N_{jk}/\sum_k N_{jk}$。又因 $\sum_k\xi_t(j,k)=\gamma_t(j)$，便得到前述更新。

若 $x_t \in \mathbb{R}^d$ 且 $b_k = \mathcal{N}(\mu_k, \Sigma_k)$，高斯对数密度的加权一阶条件给出

$$\mu_k^{\text{new}} = \frac{\sum_t \gamma_t(k) x_t}{N_k}, \qquad \Sigma_k^{\text{new}} = \frac{\sum_t \gamma_t(k)(x_t - \mu_k^{\text{new}})(x_t - \mu_k^{\text{new}})^{\mathsf{T}}}{N_k}, \quad N_k = \sum_t \gamma_t(k). \tag{6.42}$$

这里 $\mu_k \in \mathbb{R}^d$、$\Sigma_k \in \mathbb{R}^{d\times d}$。若状态从未被占用，分母为零，参数不可由本轮数据识别；协方差也可能退化，需预先规定先验、协方差结构或数值下界，而非把无定义更新当作成功训练。约束或近似 M 步需要实际检查目标是否改善。

若状态转移已经观测到，可以为 $A_{j,:}$ 设置 Dirichlet 先验，其后验参数等于先验参数加转移计数。状态未知时，转移计数本身也不确定。EM 的期望计数可用于点估计，但将其代入 Dirichlet 分布并不自动得到精确的参数后验，完整贝叶斯学习需要联合处理状态和参数的不确定性。

标准齐次 HMM 的自转移还隐含持续时间假设。若 $A_{kk} < 1$，进入状态 k 后停留 d 步的概率为

$$p(D = d \mid k) = A_{kk}^{d-1}(1 - A_{kk}), \qquad d = 1, 2, \ldots. \tag{6.43}$$

这是一种无记忆的几何分布。若退化持续时间明显集中在某个范围，需要重新检查状态定义或显式建立持续时间模型。若将 HMM 所有转移行设为同一个 π，并令初始分布也为 π，各时刻隐状态就独立同分布。高斯观测下，边缘化各状态便恢复独立样本的 GMM。这个特例说明，从混合模型到序列模型所增加的结构是隐状态之间的依赖。

6.4 从生成模型到局部条件模型：MEMM

6.4.1 为什么直接建模标签的条件分布

HMM 同时描述状态和观测的联合分布。当目标仅是识别状态，而输入包含频谱、载荷变化和重叠窗口特征时，为所有输入建立合适的生成分布可能很困难。条件模型直接学习 $p(z \mid x)$，允许使用相关观测作为输入，无

需假定这些输入彼此独立，也无需为 $p(x)$ 建模。这样处理的是观测特征的使用限制，并没有显式建立观测之间的联合分布。

最大熵马尔可夫模型（Maximum Entropy Markov Model，MEMM）保留标签的有向链，以条件最大熵分类器描述每步转移 [58]：

$$p_\theta(z_t = k \mid z_{t-1} = j, x) = \frac{\exp\{\theta^\top f(j, k, x, t)\}}{\sum_{k'} \exp\{\theta^\top f(j, k', x, t)\}}. \tag{6.44}$$

其中 f 为特征向量，x 表示当前任务允许使用的观测范围。最大熵的名称来自特征期望约束下的条件熵最大化，其解具有上述指数族形式。令 z_0 为固定起始状态，序列条件概率为各步条件概率之积。对于完整标注序列，训练可转化为以真实前驱状态为条件的局部分类；预测时前驱状态未知，仍需进行链上推断。

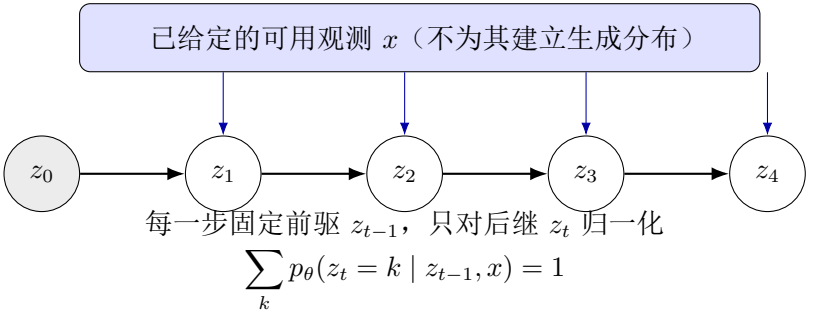


图 6.9： MEMM 的条件有向结构。灰色节点为固定起始状态，观测同时参与各步局部分类；与 HMM 相比，模型不再使用由状态指向观测的生成边。

图6.9中，每个待预测标签的输入来自前驱标签与已给定观测，因此整条路径概率是这些局部条件概率的乘积。顶部的 x 可以包含任务允许的多个时刻和重叠特征，并不意味着在线任务能够读取未来。横向箭头保留了标签顺序依赖，却没有取消每一步各自归一化的限制；这正是后文标签偏置的结构来源。

最大熵为何导出 softmax。 把前驱与可用输入合称上下文 c，令经验上下文权重为 $\hat{p}(c)$，特征 $\phi(c, k) \in \mathbb{R}^p$。在归一化约束 $\sum_k q(k \mid c) = 1$ 及特

征期望约束 $\sum_{c,k}\hat{p}(c)q(k\mid c)\phi(c,k)=\bar{\phi}$ 下，最大化条件熵 $-\sum_{c,k}\hat{p}(c)q(k\mid c)\log q(k\mid c)$。对 $q(k\mid c)$ 求拉格朗日一阶条件得到

$$-\log q(k\mid c)-1+\theta^{\mathsf{T}}\phi(c,k)+\lambda(c)=0. \tag{6.45}$$

指数化后，归一化消去 $\lambda(c)$，即得 $q(k\mid c)=\exp(\theta^{\mathsf{T}}\phi(c,k))/\sum_{k'}\exp(\theta^{\mathsf{T}}\phi(c,k'))$。这要求约束可行；特征完全分离时有限最优权重未必存在，通常以正则化松弛精确矩约束。名称中的熵指这个构造原则，不表示模型输出必须高熵。

MEMM 可以使用相关、重叠的输入特征，不需要描述它们的联合分布，但每个前驱状态都单独归一化，这带来了标签偏置。若某个状态只有一个允许的后继，该转移的条件概率恒为一，无论对应特征得分多低，都不能借助该步降低路径概率。更一般地，后继较少或转移分布较集中的状态可能获得结构性优势。问题来自局部归一化对路径评分的约束，并非简单的类别数量不平衡。

6.5 无向图：分离、团分解与条件随机场

6.5.1 无向图怎样表达条件独立

为了让整条标签路径共同参与归一化，可以用无向图构造条件分布。先讨论一般无向图。无向边不区分父节点和子节点，表达变量之间允许的直接相互作用。给定其他所有变量后，没有直接边的两点在满足图的马尔可夫性质时条件独立。

无向图的分离规则比 d-分离简单。若从节点集合 A 到 B 的每条路径都经过条件集合 S，则 S 分离 A,B，图的全局马尔可夫性质给出

$$X_A\perp X_B\mid X_S. \tag{6.46}$$

这里 A,B,S 两两不相交。实际操作可以删除 S 及其关联边，检查剩余图中 A 与 B 是否仍连通。无向图没有碰撞节点，因此没有“观察碰撞节点反而打开路径”的判断规则。链 $A-B-C$ 中，给定 B 就分离两端。如果另有路径 $A-D-C$，还需要阻断这条路径。

6.5.2 从团与势函数构造联合分布

马尔可夫随机场（Markov Random Field，MRF）用无向图表达上述独立关系。团（Clique）是节点两两相连的集合，极大团是不能再加入其他节点而仍保持两两相连的团。对有限离散变量，严格正的联合分布满足图的全局马尔可夫性质，当且仅当它能按团因子分解。这是 Hammersley–Clifford 定理的常用形式。

选取覆盖所需相互作用的团集合 $\mathcal{C}$，分布写成

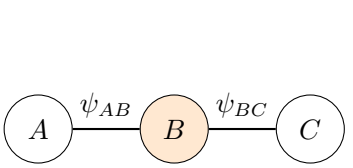
$$p(x)=\frac{1}{Z}\prod_{C\in\mathcal{C}}\psi_C(x_C),\qquad Z=\sum_{x}\prod_{C\in\mathcal{C}}\psi_C(x_C). \tag{6.47}$$

x_C 表示团中变量的取值，势函数（Potential Function）ψ_C 表示这些取值的相容程度，配分函数（Partition Function）Z 对全部配置归一化。势函数无需单独归一化，也不是某个方向的条件概率。连续变量把对应求和改成积分，并要求 $0<Z<\infty$。连续版本的分解定理还需要相应的密度与正则条件。

链 $A-B-C$ 的极大团为 $\{A,B\},\{B,C\}$，可以写成 $p(a,b,c)=\psi_{AB}(a,b)\psi_{BC}(b,c)/Z$。固定 b 后，分子分为关于 a 与 c 的两项，分母也分解成两个和的乘积，因此 $p(a,c\mid b)=p(a\mid b)p(c\mid b)$。这说明团分解如何产生条件独立。

三角形 $A-B-C-A$ 则包含三元极大团。一般需要 $\psi_{ABC}(a,b,c)$，只乘三个二元势会额外限制分布，不能表达所有三元相互作用。若存在零概率配置，按非负势定义分布仍然可行，但不能直接使用依赖严格正性的上述等价定理。以极大团分解时，较小团的势可以吸收到包含它的极大团中，因子表示也不唯一。

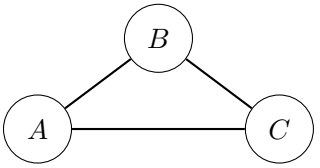
图6.10对照了前面的链与三角形。先找极大团，再给每个团定义势函数，最后对所有变量配置归一化。节点是否被条件化与节点是否属于隐变量，是两个不同问题。



链：两个二元极大团

$p(a,b,c)=\psi_{AB}(a,b)\psi_{BC}(b,c)/Z$

给定 B 分离 A,C



三角形：一个三元极大团

$p(a,b,c)=\psi_{ABC}(a,b,c)/Z$

给定 B 仍有 $A-C$ 直接边

图 6.10: 无向图的分离与团分解。链中的橙色节点表示所给条件；三角形的极大团包含全部三个节点，不能仅凭有三条边就假定只有二元相互作用。两种模型各有自己的配分函数 Z。

6.5.3 从局部归一化改为全局归一化

条件随机场（Conditional Random Field，CRF）对每个给定的观测 x，用无向图描述标签 Z 的条件分布 [48]：

$$p_\theta(z\mid x)=\frac{1}{Z_\theta(x)}\prod_{C\in\mathcal{C}}\psi_C(z_C;x),\qquad Z_\theta(x)=\sum_{z}\prod_{C\in\mathcal{C}}\psi_C(z_C;x). \tag{6.48}$$

x 作为势函数的已知条件，可以包含多个相关观测。CRF 无需对 x 建立生成分布。这里的无向图描述的是给定 x 后的标签关系。

若标签节点构成一条链，就得到线性链条件随机场（Linear-Chain CRF）。标签在训练时通常已观测，预测时未知，因此“线性链”由输出变量的图结构决定，不要求训练标签是隐变量。若训练时也有未观测节点，需要另行边缘化，得到带隐变量的条件模型。

线性链 CRF 仍保留无向链的局部马尔可夫性质：给定 x 和相邻标签后，一个内部标签与其余标签条件独立。它允许势函数依赖位置和整段可用观测，不必使用齐次的生成转移概率。这不等于取消了所有马尔可夫关系。齐次性、图的条件独立性和归一化方式是三个不同问题。

线性链 CRF 把归一化放到整条路径上。定义路径得分

$$F_\theta(z, x) = \sum_{t=1}^{T} \theta^\top f(z_{t-1}, z_t, x, t), \tag{6.49}$$

$$p_\theta(z \mid x) = \frac{\exp F_\theta(z, x)}{Z_\theta(x)}, \tag{6.50}$$

$$Z_\theta(x) = \sum_{z'_{1:T}} \exp F_\theta(z', x). \tag{6.51}$$

图6.11把条件分布写成可逐项检查的乘积：每个方形读取相邻两个标签及

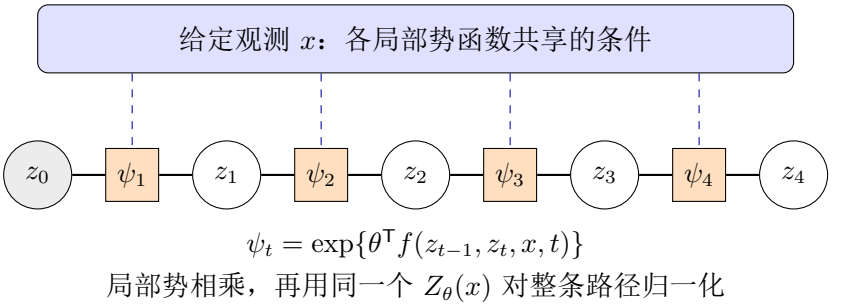


图 6.11: 线性链 CRF 的因子图。圆形表示标签，方形表示相邻标签的势函数；实线无方向，表示变量参与因子。蓝色虚线仅表示势函数依赖已给定观测，不是标签图中的随机变量边或生成箭头。

观测，输出一个非负相容度。固定 z_0 后，第一个因子实际只涉及一个待预测标签。去掉因子节点、将共享因子的标签直接相连，就得到标签的无向链。与 MEMM 不同，ψ_t 不要求对后继标签求和为一，所有因子共同决定路径得分，最后才由一个全局配分函数归一化。

配分函数 $Z_\theta(x)$ 比较所有允许路径的得分。一个只有唯一后继的状态仍然可以获得较低的路径得分，因此消除了 MEMM 局部归一化造成的上述限制。全局归一化不意味着自动解决标注噪声、分布偏移或特征不足。

对一条标注序列 (x, z)，带二次正则的负对数条件似然为

$$\mathcal{L}(\theta) = -F_\theta(z, x) + \log Z_\theta(x) + \frac{\lambda}{2}\|\theta\|_2^2. \tag{6.52}$$

其梯度等于模型期望的特征计数减去真实路径的特征计数，再加 $\lambda\theta$。这个形式解释了训练为何需要边缘概率：只找出当前最优路径不足以计算配分函数的梯度。在线性链、有限状态和相邻标签因子下，前向后向算法可在 $O(TK^2)$ 时间内计算配分函数和边缘概率，Viterbi 则计算最优路径。

两条路径怎样体现全局归一化。　假设只有两条合法路径，得分分别为 0 和 $\log 3$，则未归一化权重为 1 和 3，$Z=4$，路径概率为 $1/4$ 和 $3/4$。若观测证据使第二条路径增加 $\log 2$，它的权重变成 6，概率成为 $6/7$。即使该路径某一步只有一个合法后继，该步得分仍能改变整条路径的权重；MEMM 在那个唯一后继处的局部概率却恒为一。这个小例子只解释归一化的区别，并不是说 CRF 必然取得更高测试准确率。

特征向量 $f(j,k,x,t)\in\mathbb{R}^p$ 可以把“从正常到退化”“当前振动超过阈值”等指示量列成 p 项，$\theta\in\mathbb{R}^p$ 为其权重，内积得到一个标量得分。指数化把任何实得分变成正权重，最后归一化才得到概率。后文神经编码器只是在学习怎样产生这些局部得分，不改变概率必须归一化这一要求。

配分函数、边缘概率与梯度的完整联系。　令 $\psi_t(j,k)=\exp\{\theta^{\mathsf T}f(j,k,x,t)\}$。固定起点 z_0，设置 $a_0(z_0)=1$、其余为零，递推 $a_t(k)=\sum_j a_{t-1}(j)\psi_t(j,k)$，则 $Z=\sum_k a_T(k)$。后向量 $b_T(k)=1$、$b_{t-1}(j)=\sum_k \psi_t(j,k)b_t(k)$ 给出边缘

$$p_\theta(z_{t-1}=j,z_t=k\mid x)=\frac{a_{t-1}(j)\psi_t(j,k)b_t(k)}{Z}. \tag{6.53}$$

这些 a,b 是未归一化消息，不是 HMM 的观测似然参数。定义总特征

$$\Phi(z,x)=\sum_{t} f(z_{t-1},z_t,x,t)\in\mathbb{R}^p. \tag{6.54}$$

直接对有限和求导得

$$\nabla_\theta \log Z=\frac{\sum_z e^{\theta^{\mathsf T}\Phi(z,x)}\Phi(z,x)}{Z}=\mathbb{E}_{p_\theta(z\mid x)}\Phi(z,x), \tag{6.55}$$

$$\nabla_\theta \mathcal{L}=-\Phi(z^{\mathrm{obs}},x)+\sum_{t,j,k} p_\theta(j,k\mid x)f(j,k,x,t)+\lambda\theta. \tag{6.56}$$

再求导得到 $\nabla^2 \mathcal{L} = \mathrm{Cov}_{p_\theta}(\Phi) + \lambda I_p$。因此固定特征的线性 CRF 目标凸，$\lambda > 0$ 时严格凸；若特征由待训练神经网络产生，这一参数凸性便不再成立。禁止路径可赋零势，但至少必须存在一条合法路径，否则 $Z = 0$ 使条件分布无定义。

神经网络可以提供 CRF 的局部观测得分。例如，令 $s_t(k; x)$ 为编码器输出，B_{jk} 为可学习转移得分，则

$$F_\theta(z, x) = \sum_{t=1}^{T} s_t(z_t; x) + \sum_{t=2}^{T} B_{z_{t-1}, z_t}. \tag{6.57}$$

与 HMM 的 A_{jk} 不同，B_{jk} 是未归一化得分，不要求非负或行和为一。Bidirectional Long Short-Term Memory (BiLSTM)–CRF 和 Transformer–CRF 将特征提取交给神经网络，将标签关系交给结构化输出层。双向编码器适合完整记录的离线标注；在线预警必须限制输入和推断范围，或者明确等待未来观测所引入的延迟。即使局部特征只读取过去，对整段序列进行平滑仍可能利用后续证据。

6.5.4 从链到网格：空间相互作用

时间链只是一种邻接关系。在缺陷图像中，每个标签可能有多个邻居。Geman 与 Geman 将 Gibbs 分布和无向图建模用于图像恢复 [25]。沿用式(6.47)的团分解，令 $E(z) = -\sum_C \log \psi_C(z_C)$，便得到能量形式：

$$p(z) = \frac{1}{Z} \prod_{C \in \mathcal{C}} \psi_C(z_C) = \frac{1}{Z} \exp\{-E(z)\}. \tag{6.58}$$

图6.12展示的是一种具体的网格结构。此处 z_{rc} 的两个下标分别表示行和列。局部马尔可夫性质可写为

$$p(z_{22} \mid z_{\setminus 22}) = p(z_{22} \mid z_{12}, z_{21}, z_{23}, z_{32}), \tag{6.59}$$

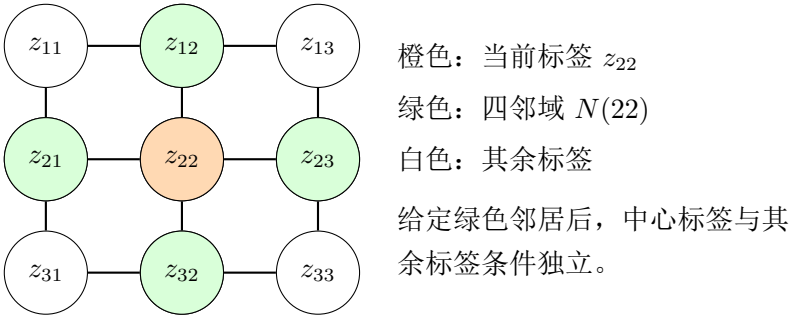


图 6.12: 四邻域网格上的成对 MRF。每个节点对应一个像素或区域标签，每条无向边对应一个二元势；不存在箭头，并不表示各标签独立，而是表示相互作用不采用有向生成分解。

其中 $z_{\setminus 22}$ 表示除中心外的全部标签。对于图示的一元和二元势分解，固定其他标签后，与 z_{22} 无关的因子在条件概率归一化时相消，因而

$$p(z_{22}=k \mid z_{\setminus 22}) = \frac{\psi_{22}(k)\prod_{j\in N(22)}\psi_{22,j}(k,z_j)}{\sum_{k'}\psi_{22}(k')\prod_{j\in N(22)}\psi_{22,j}(k',z_j)}. \tag{6.60}$$

这也解释了 Gibbs 采样为何只需读取当前节点的邻居。不过，局部更新只访问邻域，并不意味着联合分布能够分解成相互独立的节点分布。若这些势还依赖给定图像 x，图中的标签邻接关系保持不变，就得到前面定义的 CRF 在网格上的形式。

团 C 内的节点两两相连，势函数 ψ_C 表达局部相容程度，并不是归一化概率。能量 $E(z)=-\sum_C \log\psi_C(z_C)$ 越低，配置概率越高。配分函数 Z 对全部配置求和，保证总概率为一。若使用零势函数表达硬约束，则不能直接套用依赖严格正性的等价结论。

在给定图像 x 的二元缺陷标注中，可以设置

$$E(z;x)=\sum_{i} U_i(z_i;x)+\lambda\sum_{(i,j)\in\mathcal{E}} w_{ij}(x)\mathbb{1}\{z_i\neq z_j\},\qquad \lambda, w_{ij}(x)\geq 0. \tag{6.61}$$

一元项 U_i 衡量局部像素证据，二元 Potts 项惩罚邻居标签不一致。相邻区域越相似，w_{ij} 可以越大；跨越明显边界时降低权重，可减轻过度平滑。若

直接将分类概率转换成一元负对数得分，这构成条件模型的一种参数化，并不自动成为生成似然。

此时 $p(z \mid x) \propto \exp\{-E(z;x)\}$ 也是一个 CRF。MRF 强调无向马尔可夫依赖，CRF 强调给定观测后的结构化条件分布。每个固定 x 下的 CRF 都按对应无向图分解。线性链 CRF 是其中计算特别方便的一类，二维网格 CRF 通常不能直接沿用链式动态规划。

能量中的平滑项可以移除孤立误报，也可能抹掉真实细裂纹，因此应依据缺陷宽度和边界误差选择强度。一般含环图的精确推断可能十分昂贵，变量消元的复杂度随树宽增长。置信传播在树上精确，在含环图上通常只是近似且不保证收敛。均值场以较简单的分布逼近联合依赖，Gibbs 采样则逐变量更新。对于二元、次模的成对能量，图割可求全局最小能量，但这一结论不能推广到任意多类别势函数或边缘概率计算。

表 6.1： 链式与无向图模型的建模对象和计算边界。

模型	建模对象	归一化方式	关键限制
HMM	联合分布 $p(x,z)$	转移与观测局部归一化	观测假设和状态持续时间需检验
MEMM	条件分布 $p(z \mid x)$	每个前驱状态局部归一化	标签偏置影响路径评分
链式 CRF	条件分布 $p(z \mid x)$	所有标签路径全局归一化	训练需计算模型期望
MRF	无向图上的联合分布	全部配置全局归一化	一般图中配分函数和推断困难

表6.1按建模对象、归一化方式和推断边界比较图模型；应先决定需要联合生成还是条件预测，再判断链式动态规划是否适用。

MRF 的局部更新与均值场。 对固定其他标签 z_{-i}，不包含 i 的能量项在条件概率的分子分母中相消，因此

$$p(z_i = k \mid z_{-i}, x) \propto \exp\left\{ -U_i(k; x) - \lambda \sum_{j:(i,j)\in\mathcal{E}} w_{ij}(x) \mathbb{1}\{k \neq z_j\} \right\}. \tag{6.62}$$

逐点从此分布抽样就是 Gibbs 更新；若改为取最小局部能量，则变为坐标下降，只能保证能量不增而非全局最优。有限状态、适当遍历性和非周期性下 Gibbs 链以目标分布为平稳分布，强耦合时仍可能混合极慢。

若用乘积分布 $q(z) = \prod_i q_i(z_i)$ 近似，最小化 $\mathrm{KL}(q\|p)$ 等价于最小化以下目标：

$$\mathbb{E}_q E + \sum_i \sum_k q_i(k) \log q_i(k). \tag{6.63}$$

固定其他因子并对 q_i 加归一化乘子求导，可得

$$q_i(k) \propto \exp\{-\mathbb{E}_{q_{-i}} E(k, z_{-i}; x)\} \propto \exp\{-U_i(k; x) - \lambda \sum_j w_{ij}(1 - q_j(k))\}. \tag{6.64}$$

这以邻居概率代替确定标签，但忽略联合相关性；逐坐标精确更新改善变分目标，却不保证找到全局最佳近似。二元成对能量可用图割的关键条件是 $V_{ij}(0,0) + V_{ij}(1,1) \le V_{ij}(0,1) + V_{ij}(1,0)$，非负 Potts 项满足它。图割解决最大概率配置，不提供配分函数或后验区间。

两个像素的能量可以全部列完。 设两个相邻标签 $z_1, z_2 \in \{0,1\}$ 没有一元偏好，平滑惩罚为 $\lambda = \log 3$、边权为一。同标签 $(0,0), (1,1)$ 的能量为零、权重为 1，不同标签 $(0,1), (1,0)$ 的能量为 $\log 3$、权重为 $1/3$。配分函数为 $8/3$，因而 $P(0,0) = P(1,1) = 3/8$、$P(0,1) = P(1,0) = 1/8$。未观察邻居时，像素 1 的边缘概率为 $P(z_1 = 0) = 3/8 + 1/8 = 1/2$；已知 $z_2 = 0$ 时，条件概率为 $P(z_1 = 0 \mid z_2 = 0) = (3/8)/(3/8 + 1/8) = 3/4$。两种配置并列最优，并不使单个像素的边缘判断自动偏向零。在邻居为零时，Gibbs 更新以该概率抽零，以 $1/4$ 抽一；若总选择当前条件概率最高的标签，则变成

逐坐标寻找局部最优配置，已经不是从后验抽样。配置概率最高与某像素的边缘概率，是两个不同问题。

把图结构带回维护任务。 假设要从一次运行记录中识别正常、退化与故障阶段，可以先用独立分类器建立逐点基线。若预测频繁跳变，HMM 用转移持续性与观测模型共同解释状态；若观测特征复杂而状态标注充分，MEMM 和 CRF 可直接学习条件边界。若任务转为表面缺陷的空间连通区域，则链结构不再适用，需要结合图像邻接关系定义条件随机场。模型变化由输出依赖决定，而非由名称的新旧决定。

这些比较必须使用相同的可用观测、标签定义和设备划分。逐点准确率之外，还应检查状态切换延迟、阶段持续时间误差和关键故障段漏检。离线平滑结果只能与离线结果比较，在线过滤应另报实际延迟。若由隐状态概率推导未来故障风险，还需要定义故障事件与状态的关系，并验证预测时间窗，不能把“当前处于退化状态”的概率直接解释成“未来二十四小时故障”的概率。

6.6 无向图中的隐变量：玻尔兹曼机与 RBM

6.6.1 能量形式与指数族参数化

前面的无向模型用势函数表达相互作用。对正势函数，取负对数可以把乘积改为能量之和：

$$E_\theta(x) = -\sum_{C} \log \psi_C(x_C), \qquad p_\theta(x) = \frac{\exp\{-E_\theta(x)\}}{Z_\theta}. \tag{6.65}$$

能量是概率权重的参数化，低能量配置具有较高概率。本章把温度常数吸收到参数中，能量因而作为无量纲得分使用。

如果能量关于参数线性，就得到指数族（Exponential Family）的一种常用形式：

$$p_\theta(x) = h(x)\exp\{\theta^{\mathsf{T}} T(x) - A(\theta)\}, \qquad A(\theta) = \log \int h(x) e^{\theta^{\mathsf{T}} T(x)}\, dx. \tag{6.66}$$

$T(x)$ 为充分统计量，θ 为自然参数，$h(x)$ 为与参数无关的基准项，$A(\theta)$ 为对数配分函数。离散变量使用求和。参数必须使归一化量有限。高斯分布、伯努利分布和固定特征的对数线性模型都可写成指数族形式。边的方向决定依赖如何组织，指数族则规定分布怎样参数化，二者不是同一类结构限制。任意参数化的能量模型也不一定是关于所用参数的有限维指数族。

6.6.2 玻尔兹曼机怎样引入隐变量

若只有观测节点，表示复杂的观测联合分布可能需要较多相互作用项。可以在无向图中加入隐节点，让多个观测共享未观测因素。玻尔兹曼机（Boltzmann Machine，BM）是一类具有二元节点和成对相互作用的无向能量模型 [7]。它可以含隐节点，但在任意无向图中加入隐节点并不会自动得到玻尔兹曼机，还需要规定节点取值和能量形式。

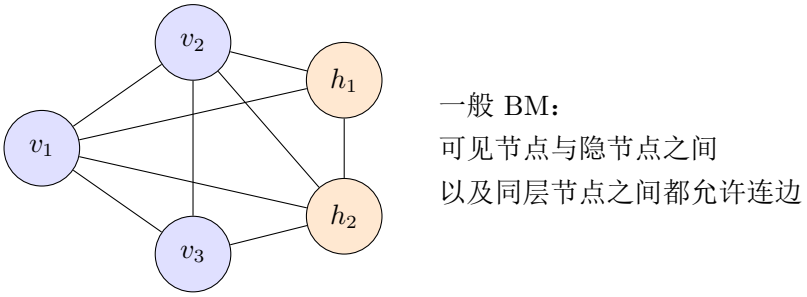


图 6.13: 一般玻尔兹曼机的无向图。节点为二元随机变量，边表示成对相互作用。隐节点之间及同一层可见节点之间的连边，使条件分布通常不再逐节点独立。

图6.13中的边没有方向。它们共同决定能量函数中的相互作用项。RBM 通过删除所有同层边得到后面的二部结构。

将可见变量 $v \in \{0,1\}^d$ 与隐变量 $h \in \{0,1\}^m$ 拼成 $s = (v^\top, h^\top)^\top$。可见表示训练数据中可观测，隐变量表示未直接观测的内部节点。一般二元玻尔兹曼机的能量为

$$E(s) = -\sum_{a} c_a s_a - \sum_{a<b} J_{ab} s_a s_b, \qquad p(s) = \frac{e^{-E(s)}}{\sum_{s'} e^{-E(s')}}. \tag{6.67}$$

c_a 是节点偏置，J_{ab} 是对称相互作用参数，每对节点只计一次。$J_{ab}=0$ 对应缺少该相互作用边。非零参数可以为正或负，分别改变共同取一的相对权重。有限二元配置和有限参数保证配分函数正且有限。

完整变量 s 的分布属于指数族，充分统计量为 s_a 与 $s_a s_b$。若只观察 v，需要求和 $p(v)=\sum_h p(v,h)$。这个边缘分布仍是归一化分布，但通常不再保留关于原参数的简单线性充分统计量形式。一般 BM 允许可见层内部、隐层内部及两层之间连边，隐节点之间的相互作用使 $p(h\mid v)$ 的计算也可能困难。

6.6.3 受限玻尔兹曼机的二部图与能量

受限玻尔兹曼机（Restricted Boltzmann Machine，RBM）删除同一层内的全部连边，只保留可见层与隐层之间的边。这个限制形成二部无向图。它改变了条件独立关系，使给定一层时另一层的节点可以分别计算。

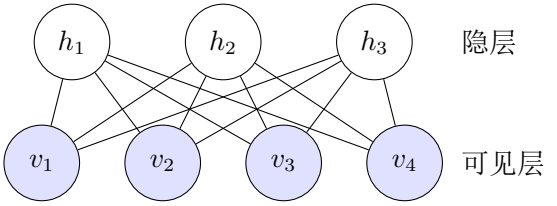


图 6.14: RBM 的二部无向图。图示为全连接的两层结构，也可以删去部分跨层边。每层内部无边，给定另一层后本层节点条件独立。

二元 RBM 沿用 $v\in\{0,1\}^d, h\in\{0,1\}^m$，能量与联合分布为

$$E_\theta(v,h)=-a^{\mathsf T}v-b^{\mathsf T}h-v^{\mathsf T}Wh, \tag{6.68}$$

$$p_\theta(v,h)=\frac{\exp\{a^{\mathsf T}v+b^{\mathsf T}h+v^{\mathsf T}Wh\}}{Z_\theta}, \tag{6.69}$$

$$Z_\theta=\sum_{v\in\{0,1\}^d}\sum_{h\in\{0,1\}^m} e^{-E_\theta(v,h)}. \tag{6.70}$$

$a\in\mathbb{R}^d, b\in\mathbb{R}^m$ 分别为可见和隐节点偏置，$W\in\mathbb{R}^{d\times m}$ 为跨层权重。联合分布的充分统计量是 $v_i, h_j, v_i h_j$。图6.14对应的团至多包含一对跨层节点，因

此能量中没有 $v_i v_{i'}$ 或 $h_j h_{j'}$ 项。

6.6.4 为什么两层的条件分布容易计算

固定 v 后，把所有包含 h 的项按隐节点整理：

$$p(h \mid v) \propto \exp\left\{ \sum_{j=1}^{m} h_j \left(b_j + \sum_i W_{ij} v_i \right) \right\} = \prod_j \exp\{ h_j u_j(v) \}, \tag{6.71}$$

其中 $u_j(v) = b_j + \sum_i W_{ij} v_i$。每个 h_j 只有 $0, 1$ 两个取值，归一化量为 $1 + e^{u_j(v)}$，所以

$$p(h \mid v) = \prod_j p(h_j \mid v), \qquad p(h_j = 1 \mid v) = \sigma\left(b_j + \sum_i W_{ij} v_i \right), \tag{6.72}$$

$$p(v \mid h) = \prod_i p(v_i \mid h), \qquad p(v_i = 1 \mid h) = \sigma\left(a_i + \sum_j W_{ij} h_j \right), \tag{6.73}$$

$\sigma(u) = 1/(1 + e^{-u})$ 为逻辑函数。条件化以后，与待更新层无关的项和全局配分函数都被约掉。也可以直接从图的分离看出：给定全部可见节点就阻断了隐节点之间的所有路径，反向同理。

这种独立性依赖于给定另一层。隐节点未给定时，可见节点仍可能通过共同隐节点相关，因此 RBM 可以描述相关数据。特征表示常取 $\mathbb{E}[h \mid v]$，其第 j 项就是上式的激活概率。它是后验期望，不等于已经观测到的真实物理因素，也不保证每个隐节点都有单一语义。

6.6.5 可见分布与一个可枚举的例子

由于隐节点在给定 v 后独立，可以精确求和消去隐层：

$$\sum_h e^{-E(v,h)} = e^{a^{\mathsf{T}} v} \prod_j \left(1 + e^{b_j + \sum_i W_{ij} v_i} \right), \tag{6.74}$$

$$p(v) = \frac{e^{-\mathcal{F}(v)}}{Z_\theta}, \qquad \mathcal{F}(v) = -a^{\mathsf{T}} v - \sum_j \log\left(1 + e^{b_j + \sum_i W_{ij} v_i} \right). \tag{6.75}$$

$\mathcal{F}(v)$ 称为自由能，已经对隐变量求和。它与固定某个 h 时的联合能量不同。对数中的求和来源于隐节点的两个可能取值。隐层求和容易，并不意味着 $Z_\theta = \sum_v e^{-\mathcal{F}(v)}$ 容易，因为可见配置仍有 2^d 个。

设两个可见节点、一个隐节点，全部偏置为零，两个跨层权重均为 $\log 2$。则

$$\sum_{h=0}^{1} e^{-E(v,h)} = 1 + 2^{v_1+v_2}. \tag{6.76}$$

$(v_1, v_2) = (0,0), (1,0), (0,1), (1,1)$ 的未归一化权重分别为 $2, 3, 3, 5$，配分函数为 13。于是 $p(v_1 = 1, v_2 = 1) = 5/13$，而 $p(v_1 = 1)p(v_2 = 1) = (8/13)^2$，二者不等。图中可见层没有直接边，边缘上仍然相关。给定 $h = 0$ 时，两可见节点独立且取一的概率都是 $1/2$。给定 $h = 1$ 时，它们仍独立，取一的概率都是 $2/3$。

6.6.6 最大似然为什么需要两类期望

训练数据只提供 v。对单个样本求对数似然梯度，利用 $\partial \log Z_\theta / \partial W_{ij} = \mathbb{E}_{p_\theta(v,h)}[v_i h_j]$，得到

$$\frac{\partial \log p_\theta(v)}{\partial W_{ij}} = v_i \, p_\theta(h_j = 1 \mid v) - \mathbb{E}_{p_\theta(v',h')}[v'_i h'_j]. \tag{6.77}$$

第一项固定真实样本，对隐节点后验求平均，称为正相。第二项对当前模型的联合分布求平均，称为负相。梯度提高数据支持的相互作用，同时减去模型已经产生的相互作用。偏置梯度类似，分别比较可见或隐节点的数据期望与模型期望。对多个样本训练时，再对正相作样本平均。

正相可由式(6.73)精确计算。负相通常需要采样：从给定 v 抽取整层 h，再从给定 h 抽取整层 v，交替进行块 Gibbs 采样。在有限二元状态和有限参数下，各条件概率严格位于零与一之间，这条链具有目标联合分布作为平稳分布。但有限步样本未必接近平稳分布，强耦合时混合可能很慢。

对比散度（Contrastive Divergence，CD）从真实样本 $v^{(0)}$ 开始，执行

k 轮交替采样，用所得 $v^{(k)}$ 近似负相，称为 CD-k。常用的权重更新近似为

$$\Delta W_{ij} = \eta \left[v_i^{(0)} p(h_j = 1 \mid v^{(0)}) - v_i^{(k)} p(h_j = 1 \mid v^{(k)}) \right], \tag{6.78}$$

其中 $\eta > 0$ 为学习率，批训练使用这些量的平均。用条件期望替代末端隐节点抽样可减少部分采样噪声。短链通常没有达到平稳分布，所以 CD-k 是有偏的最大似然梯度近似，不保证每一步提高真实似然。持续对比散度（Persistent Contrastive Divergence，PCD）保留链的状态供下一次更新继续使用，也仍需检查混合质量。

6.6.7 连续观测与适用边界

上述伯努利可见节点适合二元特征，不能直接把实数温度代入后仍解释为伯努利观测。固定尺度的高斯–伯努利 RBM 可采用

$$E(v, h) = \sum_{i} \frac{(v_i - a_i)^2}{2 s_i^2} - \sum_{j} b_j h_j - \sum_{i,j} \frac{v_i}{s_i} W_{ij} h_j, \qquad s_i > 0. \tag{6.79}$$

这里 $v \in \mathbb{R}^d$，$h \in \{0,1\}^m$，s_i 是可见节点的尺度。配方后可得

$$p(v_i \mid h) = \mathcal{N}\left(a_i + s_i \sum_{j} W_{ij} h_j, \, s_i^2 \right), \tag{6.80}$$

$$p(h_j = 1 \mid v) = \sigma\left(b_j + \sum_{i} W_{ij} v_i / s_i \right). \tag{6.81}$$

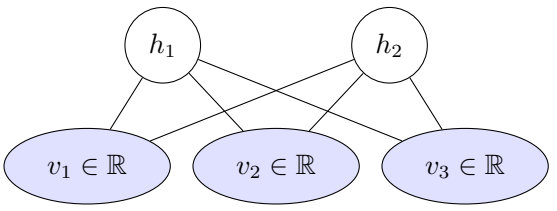


图 6.15: 高斯–伯努利 RBM。椭圆强调连续可见节点，圆形表示二元隐节点。节点取值改变，二部图的条件独立结构保持不变。

图6.15对照二元 RBM 显示了连续可见节点的变化。这个变体保留二部图及两层条件独立性，改变的是可见节点的取值与条件分布。二次项保证固定正尺度下连续积分有限。连续特征需处理尺度差异，也需验证高斯条件观测假设。

RBM 可以用于学习特征、补全缺失变量和生成样本。缺失值补全时固定已观测节点，更新缺失节点和隐节点，不能把固定观测也重新生成后当作原证据。重构误差小并不保证似然高、样本覆盖充分或异常检测有效。RBM 的主要计算收益是两层条件分布容易求解，联合归一化与长期采样仍可能困难。

6.7 用五个方面比较概率图模型

前面的模型通过改变具体假设得到不同分解。比较时应逐项问清以下问题。

1. **边的方向。**有向图用父节点条件分布构造联合分布，无向图用团势构造联合或条件分布。因子图则另外画出因子节点，展示局部计算所需的分解，可以表示这两类模型。

2. **节点的取值。**节点可以离散、连续或混合。GMM 使用离散成分与连续观测，HMM 使用有限状态，线性高斯 SSM 使用连续状态。节点类型影响求和或积分的计算，但不能单独决定图的方向。

3. **条件独立关系。**有向图使用 d-分离，无向图使用路径分离。缺边表达在相应条件下被排除的直接依赖，不保证边缘独立。向量节点还需说明内部协方差或分解假设。

4. **隐变量安排。**隐变量可能是每个样本的成分、随时间连接的状态，或 RBM 中的多个二元特征。引入隐变量通常需要边缘化，也可能使观测在边缘上相关。参数不确定性是另一层问题，不应与状态未知混淆。

5. **分布参数化。**指数族用固定统计量和自然参数表达概率。高斯局部分布、MEMM 的 softmax、固定特征 CRF 和 BM 联合分布均有相关指数族表达。它不决定有向或无向，也不保证配分函数容易计算。

表 6.2: 主要图模型的结构、节点与推断对象。

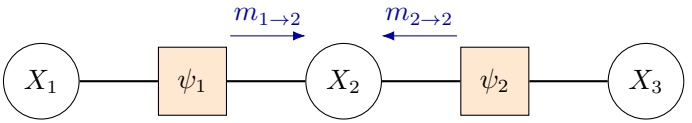
模型	图与节点	主要假设	参数给定后的计算
朴素贝叶斯	有向星形,节点可混合	给定类别后特征独立	类别后验的有限求和
GMM	离散成分、连续观测	给定成分后观测高斯	成分责任度与混合密度
HMM	有向链,有限状态	一阶状态转移、观测条件独立	前向后向与最优路径
线性高斯 SSM	有向链,连续状态	线性关系、独立高斯噪声	卡尔曼过滤的均值与协方差
MEMM	条件有向链	每个前驱下局部归一化	标签路径概率与链式推断
线性链 CRF	条件无向链	相邻标签势、全局归一化	配分函数、边缘与最优路径
RBM	无向二部图	层内无边，跨层成对能量	条件分布精确，联合期望常需采样

表6.2中的模型与推断算法需要分别选择。同一个 SSM 可以使用不同的近似过滤方法，图结构相同也可以使用不同的局部分布。结构学习、参数学习和变量推断也是不同任务。本章主要假定图结构已选定，再讨论参数学习与变量推断。

6.7.1 因子图与消息传递的共同计算方式

将分布写成 $p(x) \propto \prod_a \psi_a(x_a)$ 后，可以用因子图连接变量节点和因子节点。它表达变量参与哪个局部因子。HMM 的条件分布也可以当作因子画入因子图，这不改变原来的联合分布。

图6.16中的消息方向是计算安排，不改变原分布的结构。在树形因子图



$$p(x_1, x_2, x_3) \propto \psi_1(x_1, x_2)\psi_2(x_2, x_3)$$

图 6.16: 树形因子图及向 X_2 汇总的消息。圆形是变量，方形是因子；黑色边只表示变量参与因子，蓝色箭头表示计算消息的方向。两侧分支先对 X_1, X_3 求和，消息相乘并归一化后得到 X_2 的边缘分布。

上，边缘化可以利用乘法对加法的分配律逐分支计算。令 $N(i)$ 为变量 i 相邻的因子集合，$N(a)$ 为因子 a 涉及的变量集合，消息递推为

$$m_{i\to a}(x_i) = \prod_{b\in N(i)\setminus\{a\}} m_{b\to i}(x_i), \tag{6.82}$$

$$m_{a\to i}(x_i) = \sum_{x_{N(a)\setminus\{i\}}} \psi_a(x_a) \prod_{j\in N(a)\setminus\{i\}} m_{j\to a}(x_j). \tag{6.83}$$

消息汇总一个分支对连接变量的权重，不必归一化为概率。叶子向内、再向外计算后，$p(x_i) \propto \prod_{a\in N(i)} m_{a\to i}(x_i)$，最后归一化。连续变量需要积分。HMM 和线性链 CRF 的前向后向就是这种分支消元的具体形式。把求和改为最大值并保存索引，可以恢复最优配置，但这时不再计算边缘概率。

有环图不能直接套用树上的精确性结论。RBM 虽然两层条件分布容易计算，跨层连边仍可形成环。一般图精确消元的代价取决于中间因子的大小，常用树宽描述，因此节点数和局部条件分布的简单程度都不足以判断整体推断难度。

6.7.2 图模型与贝叶斯参数学习的区别

在本章的前向后向、卡尔曼递推和 RBM 条件分布中，参数都暂时视为给定。若还要表达有限数据造成的参数未知，可以在已有图模型外加入参数先验。上一部分线性回归中使用过的贝叶斯公式仍然成立：

$$p(\theta \mid \mathcal{D}) \propto p(\mathcal{D} \mid \theta)p(\theta), \qquad p(y_* \mid x_*, \mathcal{D}) = \int p(y_* \mid x_*, \theta)p(\theta \mid \mathcal{D})\, d\theta. \tag{6.84}$$

第二式假设给定 x_*, θ 后，新目标与训练数据条件独立，且 x_* 不需要额外更新参数后验。状态求和处理未知状态，参数积分处理未知参数。贝叶斯网络的名称只规定有向分解形式，不要求参数一定采用贝叶斯学习。

补充阅读：参数不确定性与预测检验

下面的内容讨论参数后验及预测检验，作为图模型主线之外的补充。首次阅读可先理解前面的图结构与 RBM 算例，再按需要阅读。这里的参数积分与隐状态边缘化应分别理解。

不确定性的分解与校准。 预测方差可用全概率方差公式分解：

$$\mathrm{Var}(y_* \mid x_*, \mathcal{D}) = \mathbb{E}_{p(\theta\mid\mathcal{D})}[\mathrm{Var}(y_* \mid x_*, \theta)] + \mathrm{Var}_{p(\theta\mid\mathcal{D})}[\mathbb{E}(y_* \mid x_*, \theta)]. \tag{6.85}$$

式(6.85)右端的第一项主要对应观测噪声，第二项对应参数不确定性。模型给出的区间还必须经过覆盖率检查：预测百分之九十区间不应只在训练分布内覆盖百分之六十的真实值。对于工业决策，区间宽度与错误成本同样重要。

全方差公式的推导与估计。 省略给定的 $x_*, \mathcal{D}$，记 $m_\theta = \mathbb{E}[Y_* \mid \theta]$、$m = \mathbb{E}_\theta m_\theta$，则 $Y_* - m = (Y_* - m_\theta) + (m_\theta - m)$。平方后取期望，交叉项为零，因为 $\mathbb{E}[Y_* - m_\theta \mid \theta] = 0$，从而得到全方差公式。这个分解是在指定模型内的，不包含模型类别错设所遗漏的不确定性。

若有 S 个参数样本，并能计算条件均值 m_s 及方差 v_s，令 $\bar{m} = S^{-1}\sum_s m_s$，则经验混合分布的精确方差为

$$\hat{v} = \frac{1}{S}\sum_{s} v_s + \frac{1}{S}\sum_{s} (m_s - \bar{m})^2. \tag{6.86}$$

若目的是无偏估计独立后验样本的均值间方差，第二项可改用 $S-1$ 分母，但这时不再是该有限混合的精确方差。回归区间需从完整预测混合求分位

数，不能仅对 m_s 取分位数后声称覆盖有噪声观测。对于重尾或多峰预测，$\bar{m} \pm 1.96\sqrt{\bar{v}}$ 也不一定是 95% 区间。

参数抽样与观测抽样要分两层。 设两个等权参数样本对应的条件预测分别为

$$Y_* \mid \theta^{(1)} \sim \mathcal{N}(0, 1), \qquad Y_* \mid \theta^{(2)} \sim \mathcal{N}(2, 1).$$

这里省略共同给定的输入和数据。混合均值为 1，平均条件方差为 1，条件均值的方差也为 1，总预测方差为 2。仅保存两个条件均值 $(0, 2)$ 会遗漏观测噪声。

生成预测样本时应先选择参数样本，再从对应的条件观测分布抽 Y_*；生成参数可信区间则只对参数样本取分位数。把抽样次数由 100 增至 10000，只会使这些分位数估计更稳定，并不等于增加了 9900 次真实设备试验。

贝叶斯方法的常见误用。 使用贝叶斯模型时，可以从结果倒查计算过程。先检查报告的概率与实际发生频率是否相符，再检查陌生工况下模型是否仍然过度自信。后验方差只反映当前模型表达的未知量，模型没有考虑到的故障机制可能根本不会使它增大。先验也应写明来源和尺度；如果近似算法尚未稳定，计算误差甚至可能大于想要估计的参数不确定性。

预测分布的蒙特卡洛近似。 当后验积分无法解析计算时，可从后验得到 S 个样本 $\theta^{(s)}$，使用

$$p(y_* \mid x_*, \mathcal{D}) \approx \frac{1}{S} \sum_{s=1}^{S} p(y_* \mid x_*, \theta^{(s)}). \tag{6.87}$$

注意先平均概率再取最大类别；平均 logits 或平均类别标签一般不等价。对回归，可由每个参数样本产生一条预测，再计算总方差和分位数区间。S 太小会造成蒙特卡洛噪声，样本相关时有效样本量还会进一步下降。

采样诊断。 马尔可夫链蒙特卡洛（Markov Chain Monte Carlo，MCMC）通过具有目标平稳分布的相关样本链近似期望。有效样本量（Effective Sample Size，ESS）衡量某个估计量的采样效率，与粒子滤波中依据归一化权重计算的有效粒子数具有不同定义。链的轨迹图可以检查是否进入稳定区域，自相关函数衡量样本冗余，有效样本量近似为

$$ESS \approx \frac{S}{1 + 2\sum_{k \geq 1} \rho_k}. \tag{6.88}$$

多条不同初始状态的链还应比较 $\hat{R}$ 等收敛指标。若链只在后验的一个模式附近游走，表面上的稳定并不代表全局混合良好。工业高维模型通常更偏向近似推断，但这不意味着可以跳过近似质量和预测覆盖率检查。

Effective Sample Size (ESS) 是针对哪个估计量。 对平稳链上的标量 $h(\theta^{(s)})$，设其方差为 v_h、滞后相关为 ρ_k，展开样本均值的协方差和得

$$\mathrm{Var}\left(\frac{1}{S}\sum_{s} h(\theta^{(s)})\right) = \frac{v_h}{S}\left[1 + 2\sum_{k=1}^{S-1}(1 - k/S)\rho_k\right]. \tag{6.89}$$

当相关可求和且链足够长时，匹配独立样本均值的方差便得到前述 ESS。不同参数、尾部概率和维护成本函数有不同的自相关，因此不存在适用于所有结论的单一 ESS。短链直接相加所有经验相关会很不稳定，需截断或稳定的谱估计；尚未进入平稳区或未跨模式时，这个局部诊断不能证明准确性。

先验敏感性分析。 先验选择应通过敏感性分析验证。对故障率、噪声尺度或参数收缩强度使用几组合理先验，比较后验预测和决策是否稳定。若结果对先验极其敏感，说明数据不足、模型可识别性弱，或先验承担了过多结论。此时应增加数据、改进测量或明确报告先验依赖，而不是只选择产生最好结果的先验。

校准、覆盖率与风险。 预测区间覆盖率和区间宽度需要同时观察。过宽的区间容易达到覆盖率，却可能没有决策价值；过窄的区间看似精确，却会造成过度自信。对分类概率，可按置信度分箱比较预测概率和经验事件率；对回归区间，可按设备、工况和预测提前量分层检查。校准应在独立验证数据上完成，并在部署漂移后持续监测。

小样本故障率的后验决策。 某设备在新工况下运行 20 次，观察到 2 次异常。若采用 $\mathrm{Beta}(1,9)$ 先验，则后验为 $\mathrm{Beta}(3,27)$，后验均值为 0.1。直接使用样本比例得到的估计也是 0.1，但二者对未来风险的表达不同：后验还包含小样本造成的宽区间。若把“安排人工复检”的成本记为 C_I，把一次漏检损失记为 C_M，则当后验异常概率满足

$$p(\text{异常} \mid \mathcal{D})C_M > C_I \tag{6.90}$$

时才应触发复检。这里假定复检及随后的处理能消除所计漏检损失，且只产生固定成本 C_I。例如 $C_M = 100, C_I = 12$ 时，后验概率 0.1 对应不复检损失 10，小于 12，故不复检；若复检不完美，应重新列出残余损失。这样，概率输出通过成本函数转化为动作，而不是凭经验固定一个看似通用的阈值。

该例还说明先验不是隐藏的常数。若先验改为 $\mathrm{Beta}(1,1)$，后验均值变为 $3/22$；两种结果的差异提示当前数据不足以完全决定风险。工程报告应同时给出先验、后验和决策阈值，使不同团队可以复核结论。

回归预测区间的覆盖实验。 假设模型对每台设备给出正态观测预测分布，其均值为 μ_i、标准差为 σ_i，则名义 95% 预测区间为 $[\mu_i - 1.96\sigma_i, \mu_i + 1.96\sigma_i]$。在验证集上统计真实值落入区间的比例，并分别按设备、环境温度和预测提前量分组。若整体覆盖率为 0.94，但高温工况只有 0.71，则总体数字掩盖了局部失效。可以在独立校准集上估计分位数修正因子，再在另一段时间上复验，避免把校准集上的偶然波动误认为改进。

区间宽度也应进入报告。两个模型可能具有相同覆盖率，但一个区间宽得无法指导维护，另一个区间更窄且只在少数工况失效。因而应联合绘制覆盖率、平均区间宽度和漏覆盖成本，并说明校准是否使用了未来数据。

后验预测检查的操作步骤。 用于拟合后验的真实数据也参与了这项检查，因此它不是独立测试集上的泛化评价。复制数据只是模型内的模拟结果，不能作为新设备证据再次更新同一后验。后验预测检查不是把训练数据重新拟合一次，而是从后验参数样本生成复制数据 $\tilde{y}$，比较 $\tilde{y}$ 与真实数据的统计量。例如可比较均值、方差、极值数量、故障持续时间和相邻残差相关性。若模型能匹配均值却无法产生真实的长尾，说明其似然假设不适合风险评估。工业案例中，检查统计量应优先选择与维护动作相关的量，而不是只选择容易展示的总体误差。

本章核心内容可结合下面的图模型课程和 RBM 实现文档学习。参数后验教程用于补充阅读，不能替代条件独立、分解与隐变量推断的学习。

辅助学习材料

- **Probabilistic Graphical Models**；作者/平台：Stanford University CS228；英文；课程讲义与课程资源。重点学习 Bayesian networks、Markov networks、因子分解和推断主题，帮助理解本章的 HMM、MRF、消息传递与条件独立。课程主页。

- **Bayesian Regression - Introduction (Part 1)**；作者/平台：Pyro 社区；英文；官方教程。阅读模型与先验、变分推断和后验预测部分，将点估计与参数不确定性作对照。在线阅读。

- **BernoulliRBM**；scikit-learn；英文；模型接口文档。对照二元可见层与隐层的定义、参数矩阵形状以及持续对比散度训练，区分隐藏特征的条件均值与随机采样。接口文档。

- **Deep Learning：概率模型与配分函数相关章节**；Ian Goodfellow、Yoshua Bengio、Aaron Courville；英文；作者公开的在线教材。结合本章 RBM 自由能与似然梯度，学习能量模型中的归一化和采样计算。书籍网站。

本章小结。 概率图模型把变量、条件独立关系与分布分解联系起来。有向图以父节点条件分布相乘，用 d-分离判断图保证的独立性。无向图以团势相乘，通过一个配分函数归一化，用路径分离判断条件独立。图规定允许哪些依赖，局部分布和参数决定具体概率。

朴素贝叶斯假设给定类别后特征独立。隐藏类别并采用高斯观测得到 GMM，将成分变量沿时间连接得到状态空间模型。有限离散状态可用 HMM 前向后向推断，线性高斯状态可用卡尔曼滤波，较一般的状态分布可用粒子滤波近似。MEMM 直接学习标签条件分布，允许相关输入，但局部归一化会产生标签偏置。CRF 使用全局归一化，线性链 CRF 保留相邻标签的无向马尔可夫关系。

BM 在二元无向图中使用成对能量并可包含隐变量，完整变量的联合分布属于指数族。RBM 进一步删除层内连边，使两层的条件分布可以分别计算，但边缘依赖、全局配分函数和模型期望仍需处理。边的方向、节点取值、条件独立关系、隐变量安排和指数族参数化，是比较这些模型的五个方面，不能相互替代。

下一章转向参数化与非参数化模型。这里已经用图结构规定多个变量如何共同分布，后面将研究如何直接规定多个输入位置的函数值共同服从高斯分布。高斯条件化仍是计算工具，改变的是被建模的对象与相关结构。

第七章　参数化与非参数化模型

本章摘要。本章比较两种表达函数复杂度的方式：参数化模型用有限维参数概括规律，非参数化模型则通过核、邻域或函数分布保留更灵活的形状。高斯过程和核方法贯穿全文，用来说明先验结构、计算代价和小样本性能之间的权衡，并承接上一章的联合分布、相关结构与条件推断。

上一章通过图结构规定变量之间的条件独立关系，并用局部分布或势函数构造联合分布。本章把建模对象转向输入与输出之间的函数关系。可以先用有限个回归系数描述函数，也可以直接规定不同输入处函数值如何共同分布，再根据观测计算预测。参数化与非参数化模型的区别，涉及函数如何表示以及模型复杂度如何随数据变化。

假设要根据转速预测温升，可以先找转速相近的历史记录取平均，这就是近邻方法的直观起点。核方法用相似程度决定记录之间怎样相互影响，高斯过程进一步描述可能的函数及其概率。方法越灵活，越需要考虑样本是否足够、计算是否承受得起。还要分清一个预测数值和一整个预测分布：两个方法给出相同的平均温升，并不意味着它们对预测有同样的把握。

本章默认读者理解样本平均、协方差以及上一章的后验预测。可先用近邻例子理解“让附近样本参与预测”，再用单观测 GP 例子核对均值与方差；函数空间和对偶推导用于解释算法形式，不是动手计算这两个例子的先修门槛。

7.1　两个概念

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

参数化模型用固定维度参数描述分布，例如线性回归 $y = \boldsymbol{w}^{\mathsf{T}} x + b + \varepsilon$。无论样本数如何增加，参数维度仍由输入维度和模型设计决定。非参数化模型不预先固定同样意义上的有限参数维度，而允许模型复杂度随数据增长，例如 k 近邻、高斯过程和 Dirichlet 过程模型。

近邻回归：由局部常数假设得到估计。 设 $x_i \in \mathbb{R}^d$、$Y_i = f^*(x_i) + \varepsilon_i$，给定输入后噪声独立、均值为零且方差为 σ^2。固定查询 x，按预先规定距离选出 k 个近邻集合 $N_k(x)$。若假设该邻域内函数近似常数 c，最小化 $\sum_{i \in N_k(x)} (Y_i - c)^2$ 的一阶条件为 $2\sum_i (c - Y_i) = 0$，所以

$$\hat{f}_k(x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i. \tag{7.1}$$

给定训练输入，条件偏差为 $k^{-1}\sum_{i \in N_k(x)} f^*(x_i) - f^*(x)$，条件方差为 σ^2/k。若 f^* 为 L_f-Lipschitz 函数，近邻最远距离为 $r_k(x)$，则

$$|\operatorname{Bias}(x)| \le L_f r_k(x), \qquad \mathbb{E}[(\hat{f}_k(x) - f^*(x))^2 \mid X] \le L_f^2 r_k(x)^2 + \sigma^2/k. \tag{7.2}$$

增大 k 降低噪声方差，却扩大邻域偏差。若局部密度为正且规则，典型半径量级为 $(k/n)^{1/d}$，平衡两项得到 k 约为 $n^{2/(d+2)}$、均方误差量级约为 $n^{-2/(d+2)}$；这是基于光滑与密度条件的局部量级论证，而非对任何数据的保证。维度越高，邻域收缩越慢，这就是距离方法的维数困难。分类近邻则平均类别指示以估计局部类别概率。

一致性通常要求 $k \to \infty$ 且 $k/n \to 0$，并附加分布与正则条件；固定 k 一般保留不可消失的方差。距离尺度、无关特征和跨工况混合都可能破坏局部相似假设。朴素查询需约 $O(nd)$ 距离计算，快速索引在高维也可能失效。

近邻手算与“非参数”的含义。 历史输入为 $(0, 1, 3)$，对应温升为 $(2, 4, 8)$，查询 $x = 1.2$，按绝对距离找两个邻居，距离依次为 $1.2, 0.2, 1.8$，因此预测为 $(4+2)/2 = 3$；三个邻居都用则为 $14/3$。k 是控制平滑程度的超参数，储

存的训练样本仍参与预测，所以“非参数”绝不是“没有需要设置或保存的数值”。多维距离还受单位影响：转速与温度相加求距离前，必须明确尺度或领域距离，不能把数值大的单位误当成更重要的变量。

图7.1把上述三个样本放回输入轴。邻居按横向输入距离选择，再对选中样本的纵向输出取平均。扩大到三个邻居时，输入范围扩大，预测也从 3 变为 14/3。

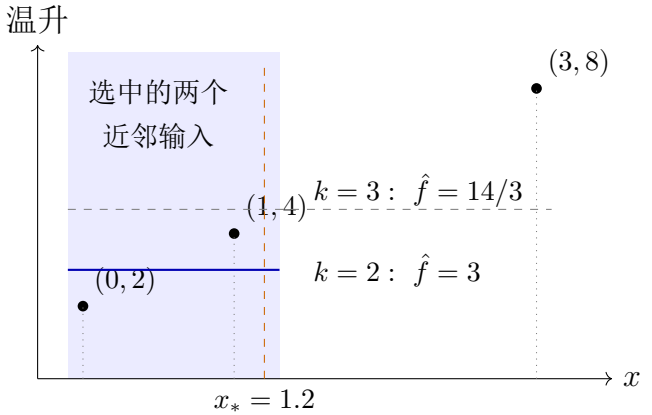


图 7.1： 近邻回归的教学算例。浅色区域标出两个选中邻居的输入位置，竖虚线为查询输入，水平线为本次查询的预测值，不表示整个输入范围上的拟合曲线。输入与温升沿用正文的教学数值。

Lipschitz 条件 $|f^*(x) - f^*(x')| \le L_f \|x - x'\|$ 表示输入靠近时真实均值不会任意跳变。偏差上界来自对邻居逐个应用该条件再取平均，方差 σ^2/k 则来自 k 个独立噪声平均。若邻居来自同一条高度相关轨迹，后一个计算需加入协方差；不能仅增加窗口数量就宣称方差按 $1/k$ 下降。

高斯过程示例。 高斯过程（Gaussian process, GP）直接在函数空间上定义先验：任意有限输入集合对应的函数值服从联合高斯分布，记为 $f \sim \mathcal{GP}(m, k)$。给定训练输入 X 和观测 $y = f(X) + \varepsilon$，其中 $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$，新点 x_* 的后验均值为

$$\mu_* = m(x_*) + k_*^{\mathsf{T}} (K + \sigma^2 I)^{-1} (y - m(X)), \tag{7.3}$$

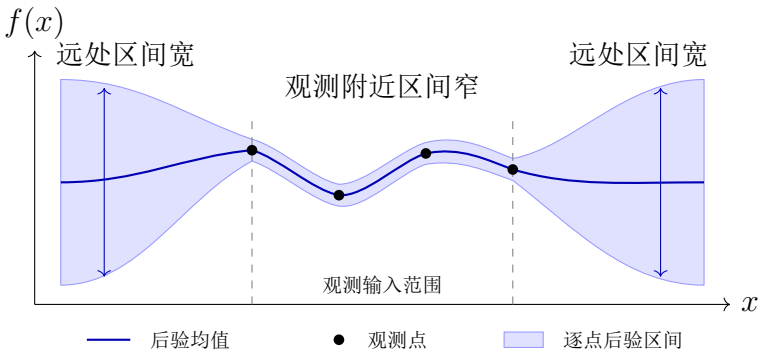


图 7.2: 高斯过程不确定性示意：观测附近的后验区间较窄，远离观测后逐渐变宽。

后验方差为

$$\sigma_*^2 = k(x_*, x_*) - k_*^{\mathsf{T}}(K + \sigma^2 I)^{-1} k_*. \tag{7.4}$$

这里 X 的 n 行分别为训练输入的转置，$y \in \mathbb{R}^n$ 为观测列向量，m 为先验均值函数，$m(X) = [m(x_1), \dots, m(x_n)]^{\mathsf{T}}$，$K_{ij} = k(x_i, x_j)$，$k_* = [k(x_1, x_*), \dots, k(x_n, x_*)]^{\mathsf{T}}$。噪声与潜在函数独立。式(7.4)针对潜在函数值 $f(x_*)$；若预测含独立同方差噪声的新观测，还需加上 σ^2。核函数 k 表达“相似输入应有相似函数值”的先验。远离训练样本时，预测方差通常增大，这提供了自然的不确定性信号。

图7.2是相关性随输入距离衰减时的定性示意，并非某组数据的数值拟合结果。黑点集中在两条虚线之间，蓝线表示后验均值，浅蓝色区域表示潜在函数值的逐点后验区间：观测附近较窄，两侧远离观测后逐渐变宽。区间宽度取决于后验标准差，而不是均值曲线的高低。例如，逐点 95% 后验区间为 $\mu_* \pm 1.96\sigma_*$；当 $k_* \to 0$ 时，式(7.4)中的方差缩减项趋于零，区间宽度回到先验所决定的水平，而非无限增大。这里的图示针对相关性随距离衰减的核，不能推广到所有核。

GP 后验不是另一个需要记忆的公式。 设 $C = K + \sigma^2 I_n$，训练中心化观测 $r = y - m(X)$，新点中心化函数值 $g_* = f(x_*) - m(x_*)$。GP 定义和独立

高斯噪声给出

$$\begin{bmatrix} r \\ g_* \end{bmatrix} \sim \mathcal{N}\left(0, \begin{bmatrix} C & k_* \\ k_*^{\mathsf{T}} & k_{**} \end{bmatrix}\right), \qquad k_{**} = k(x_*, x_*). \tag{7.5}$$

构造残差 $u = g_* - k_*^{\mathsf{T}} C^{-1} r$，直接计算 $\mathrm{Cov}(u, r) = k_*^{\mathsf{T}} - k_*^{\mathsf{T}} C^{-1} C = 0$。联合高斯中不相关意味着独立，且

$$\mathrm{Var}(u) = k_{**} - k_*^{\mathsf{T}} C^{-1} k_*. \tag{7.6}$$

因此给定 r 时 u 仍为同一零均值高斯，恢复先验均值便得到式(7.3)与式(7.4)。这个证明同时说明减去的项为何非负：C 正定时 $k_*^{\mathsf{T}} C^{-1} k_* \geq 0$；整个条件方差非负则由联合协方差的半正定性保证。

对 m 个新点，$K_{X*} \in \mathbb{R}^{n\times m}$、$K_{**} \in \mathbb{R}^{m\times m}$，后验协方差为 $K_{**} - K_{X*}^{\mathsf{T}} C^{-1} K_{X*}$。各点之间通常相关，不能把多个边际区间当作整条曲线的同时置信带。若核超参数固定，此协方差只依赖输入而不依赖观测值；异常的 y 不会自动增大方差。

$\sigma^2 > 0$ 使半正定 K 对应的 C 正定；无噪声且有重复输入时需处理奇异性。只有当远处 k_* 趋近零时，后验才回到先验均值和先验方差；周期核等结构可能在距离很远时仍高度相关。因此“远离数据更不确定”是常见核下的行为，而非 GP 定义本身的普适结论。

只有一个观测时，GP 公式就是分数运算。 取零均值先验，一个训练观测 $y = 2$，训练点与新点的先验方差都为 1，交叉协方差 $k_* = 0.5$，噪声方差 $\sigma^2 = 0.25$。此时 $C = 1.25$，后验均值为 $0.5 \times 2/1.25 = 0.8$，潜在函数方差为 $1 - 0.5^2/1.25 = 0.8$；新观测方差还要加噪声，得到 1.05。输入与训练点完全不相关时 $k_* = 0$，预测就回到均值 0、函数方差 1 的先验，而不是断言温升必为零。

在训练点本身预测，交叉协方差变为 1，后验均值为 1.6 而非观测值 2，函数方差为 0.2 而非零：因为观测可能带噪声，不必完全通过观测点。区间半宽取标准差而非方差，例如前一个新点的逐点 95% 可信区间为 $0.8 \pm 1.96\sqrt{0.8}$。这依赖当前核和噪声假设，也不是整条函数同时位于区间带内的 95% 保证。

7.2 核方法、函数空间与计算边界

支持向量机展示了核函数如何把线性判别推广到非线性空间，稀疏高斯过程则以诱导变量降低函数后验近似的计算成本 [16, 86]。核化与贝叶斯函数建模可以共享工具，但优化目标和不确定性含义不同。

联系而非对立。 参数化和非参数化并不是“现代”和“传统”的划分。神经网络是有限参数模型，但宽网络和核方法之间存在理论联系；贝叶斯神经网络在有限参数空间上保留后验；核方法则把参数学习转化为函数空间中的推断。真正的选择依据是数据量、计算资源、先验结构、预测任务和对不确定性的要求。

说明 7.1. *当数据量很少而风险可解释性重要时，结构清晰的参数化概率模型往往更合适；当关系复杂且数据充足时，深度参数化模型可以提供更强的表示能力。两者都必须通过验证数据和任务指标检验。*

参数模型中的先验结构。 参数化并不意味着没有先验。线性模型假设输入与输出的关系可由有限维方向表达；多项式模型增加曲率；状态空间模型把时间依赖写入转移方程。参数越少通常越容易估计，但若结构假设错误，偏差会成为主要误差来源。选择参数化模型就是选择哪些变化被认为值得显式表达。

核方法的函数空间视角。 核函数 $k(x, x')$ 定义了输入相似性。核岭回归的预测可以写成训练样本核函数的线性组合：

$$f(x) = \sum_{i=1}^{n} \alpha_i k(x_i, x). \tag{7.7}$$

核技巧把高维特征映射隐含在内积中，但训练通常需要处理 $n \times n$ 核矩阵，样本规模增大时计算和存储成为瓶颈。稀疏近似、随机特征和诱导点（inducing points）可以降低这一代价。下文的 Gram 矩阵就是有限输入两两核值组成的矩阵 K；“核矩阵”与“Gram 矩阵”在此指同一对象。

什么相似性可以成为核。 合法实值核必须对称，并对任意有限输入和 $a \in \mathbb{R}^n$ 满足 $\sum_{ij} a_i a_j k(x_i, x_j) \geq 0$，即 Gram 矩阵半正定。若 $k(x, x') = \phi(x)^{\mathsf{T}}\phi(x')$，该二次式等于 $\|\sum_i a_i \phi(x_i)\|^2$，因此自动满足条件；任意手写距离的负值却不一定是合法核。

平方指数核 $k(x, x') = s_f^2 \exp[-\frac{1}{2}\sum_j (x_j - x'_j)^2/\ell_j^2]$ 用 $\ell_j > 0$ 控制各维相关长度，$s_f^2 > 0$ 控制函数幅度。长度很大意味着该维变化难以使函数改变，长度很小则允许快速波动。例如一维中两点相距 ℓ 时，核值为 $s_f^2 e^{-1/2}$；相距 2ℓ 时为 $s_f^2 e^{-2}$，长度尺度不是超过后相关性突然归零的硬阈值。核的非负加权和仍为核，可组合平滑、线性或周期结构，但组合之前应确定各分量对应什么物理变化。

图7.3将长度尺度的作用画成核响应。固定第一个输入，横轴表示两个输入的距离，纵轴表示相对核值。同样的输入距离在不同长度尺度下会对应不同的相关强度，因此长度尺度改变了模型如何共享样本信息。

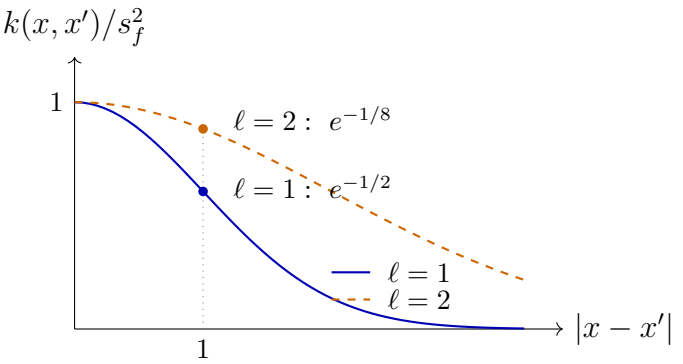


图 7.3: 一维平方指数核的数值曲线。距离与长度尺度使用同一输入单位。较大的长度尺度使相关性随距离下降得更慢，曲线没有硬截断点。

核岭回归的表示与系数求解。 在核对应的再生核 Hilbert 空间 $\mathcal{H}_k$ 中，再生性质为

$$f(x_i) = \langle f, k(x_i, \cdot)\rangle. \tag{7.8}$$

考虑 $\lambda>0$ 时的目标

$$J(f)=\frac{1}{2n}\sum_{i}(y_i-f(x_i))^2+\frac{\lambda}{2}\|f\|_{\mathcal{H}_k}^2. \tag{7.9}$$

把 f 正交分解为训练核函数张成空间中的 $f_{\parallel}$ 与 $f_{\perp}$。再生性质给出 $f_{\perp}(x_i)=0$，故去掉 $f_{\perp}$ 不改变训练拟合，却将范数平方减少 $\|f_{\perp}\|^2$。最优解必可写为 $f(\cdot)=\sum_i \alpha_i k(x_i,\cdot)$，这就是此处表示结论的推导。

代入后 $J(\alpha)=\|y-K\alpha\|^2/(2n)+\lambda\alpha^{\mathsf{T}}K\alpha/2$，梯度条件为 $K[(K+n\lambda I)\alpha-y]=0$。可选稳定解

$$\alpha=(K+n\lambda I_n)^{-1}y. \tag{7.10}$$

若 K 奇异，不能在梯度式中随意约去 K；但式(7.10)的解仍有效，系数的零空间差异表示同一个函数。正则化保证函数解唯一。零均值 GP 在 $\sigma^2=n\lambda$ 时与核岭回归均值相同，但核岭目标本身不定义观测噪声或预测方差，不能直接把两者的不确定性等同。

再生核空间先读作带长度规则的函数集合。 $\mathcal{H}_k$ 的元素是函数，内积 $\langle f,g\rangle$ 衡量函数之间的关系，范数 $\|f\|_{\mathcal{H}_k}$ 衡量核规定的函数复杂度，而不是简单把有限训练点的预测平方求和。$k(x_i,\cdot)$ 表示固定第一个输入、把第二个输入留给查询的函数；再生性质使“在 x_i 求值”转成一次内积。$f_{\perp}$ 与所有训练核函数正交，所以它在训练点为零，却可能在别处改变预测；正则化删掉的是没有训练拟合收益的额外部分。

继续使用单观测 $y=2,K=[1]$，取 $n\lambda=0.25$，核岭系数为 $\alpha=2/1.25=1.6$，新点核值为 0.5 时预测为 0.8，与前面的 GP 均值一致。$\alpha\in\mathbb{R}^n$ 每个分量对应一条训练记录，既不是类别概率，也不是输入的 d 维回归系数。核岭计算到这里就结束；还要报告方差，则必须另有概率或区间构造依据。

从有限参数高斯先验得到核。 令 $f(x)=\phi(x)^{\mathsf{T}}w$，$\phi(x)\in\mathbb{R}^p$、$w\sim\mathcal{N}(0,S)$。任意有限函数值均为高斯线性变换，协方差为 $k(x,x')=\phi(x)^{\mathsf{T}}S\phi(x')$。令

$\Phi \in \mathbb{R}^{n\times p}$，则参数后验给出的均值与函数空间表达相等：

$$(S^{-1}+\sigma^{-2}\Phi^{\mathsf{T}}\Phi)^{-1}\sigma^{-2}\Phi^{\mathsf{T}} = S\Phi^{\mathsf{T}}(\Phi S\Phi^{\mathsf{T}}+\sigma^{2}I)^{-1}. \tag{7.11}$$

在 S 正定时，左右两边同乘左侧精度矩阵即可验证恒等式。它说明有限秩核 GP 也可有固定有限参数表示；所谓非参数性主要针对可随样本扩展的无限秩函数类，而不是“出现核就绝无有限参数”。

核支持向量机的对偶来源。 对 $y_i \in \{-1,1\}$，软间隔分类在特征空间中求

$$\min_{w,b,\xi}\ \tfrac{1}{2}\|w\|^2 + C\sum_{i}\xi_i, \quad y_i(\langle w,\phi(x_i)\rangle + b) \ge 1-\xi_i, \quad \xi_i \ge 0. \tag{7.12}$$

给两组不等式加入乘子 $\alpha_i,\mu_i \ge 0$。此处 $\alpha \in \mathbb{R}^n$ 是 SVM 约束乘子，不是前面核岭回归中可取任意实数的展开系数；两个模型只是沿用同一常见符号。对 w,b,ξ_i 的驻点条件分别为 $w=\sum_i \alpha_i y_i \phi(x_i)$、$\sum_i \alpha_i y_i = 0$、$C-\alpha_i-\mu_i=0$。代回拉格朗日函数得

$$\max_{0\le\alpha_i\le C,\ \sum_i \alpha_i y_i = 0} \sum_{i}\alpha_i - \frac{1}{2}\sum_{ij}\alpha_i\alpha_j y_i y_j k(x_i,x_j). \tag{7.13}$$

凸性和可行条件使对偶可用于求解；预测得分为 $\sum_i \alpha_i y_i k(x_i,x)+b$。若 $0<\alpha_i<C$，互补松弛给出对应样本位于间隔边界，可用于计算 b。若没有 $0<\alpha_i<C$ 的样本，不能用该等式硬求 b；应由 $\alpha_i=0$ 时 $y_i f(x_i)\ge 1$、$\alpha_i=C$ 时 $y_i f(x_i)\le 1$ 所给出的上下界选择可行 b，并检查数值容差。非零系数对应支持向量。间隔得分不是故障概率，仍须单独校准；核矩阵半正定则是凸优化性质的重要前提。

支持向量机中的松弛变量与成本参数。 ξ_i 允许第 i 个点违反单位间隔约束。取 $C>0$ 时，最优解不会无故增大松弛量，故 $\xi_i=\max\{0,1-y_i f(x_i)\}$。在这个最小松弛约定下，$\xi_i=0$ 表示满足间隔，$0<\xi_i<1$ 表示分类正确但离边界太近，$\xi_i=1$ 表示位于判别边界，$\xi_i>1$ 才对应得分落在错误一

侧。任意尚未优化的可行松弛量可能更大，不能直接用它判断分类对错。增大 C 会更重地处罚违反间隔；这与核岭中增大 λ 加强平滑不是同一个方向的调节。乘子 α_i 是约束在最优解处的权重，互补松弛说明未触及约束的点可以有零权重，这就是只保留支持向量仍能计算判别函数的原因。这里 $f(x)>0$ 选择正类，不代表 $f(x)$ 是 $[0,1]$ 内的概率。

高斯过程的边际似然。 高斯过程不仅给出预测均值，还能通过边际似然选择核参数和噪声尺度：

$$\log p(y\mid X)=-\frac{1}{2}(y-m(X))^{\mathsf{T}}K_y^{-1}(y-m(X))-\frac{1}{2}\log|K_y|-\frac{n}{2}\log(2\pi). \tag{7.14}$$

其中 $K_y=K+\sigma^2 I$，$|K_y|$ 表示行列式；$m\equiv 0$ 时得到零均值先验的简式。二次型衡量残差相对协方差的大小，行列式项来自高斯密度的归一化；两项共同形成拟合与分布扩散程度的折中，不能把第二项单独当作通用的复杂度排序。边际化所体现的这种 Occam 效应与上一章的模型证据相连，矩阵分解成本通常为 $O(n^3)$。

边际似然的积分、导数与数值实现。 由 $f_X\sim\mathcal{N}(m_X,K)$ 及 $y=f_X+\varepsilon$，独立高斯相加后 $y\sim\mathcal{N}(m_X,C)$，$C=K+\sigma^2 I$；把这个 n 维高斯密度取对数就得到式(7.14)。这一步已经积分掉函数值，并不是将最优函数值代入似然。

设超参数为 η，$r=y-m_X$、$a=C^{-1}r$。利用 $d\log|C|=\operatorname{tr}(C^{-1}dC)$ 和 $dC^{-1}=-C^{-1}(dC)C^{-1}$，逐项微分得到

$$\frac{\partial\log p(y\mid X)}{\partial\eta}=\frac{1}{2}\operatorname{tr}\left[(aa^{\mathsf{T}}-C^{-1})\frac{\partial C}{\partial\eta}\right]+\left(\frac{\partial m_X}{\partial\eta}\right)^{\mathsf{T}}a. \tag{7.15}$$

核长度、幅度和噪声可据此优化，正尺度通常取对数参数化。目标不保证凸，应检查多起点和边界。将超参数估计后固定属于经验贝叶斯，预测区间未包含超参数不确定性；充分贝叶斯做法还要对其后验积分。

数值上分解 $C = LL^{\mathsf{T}}$，解 $Lv = r$、$L^{\mathsf{T}}a = v$，可计算 $r^{\mathsf{T}}C^{-1}r = v^{\mathsf{T}}v$ 及 $\log|C| = 2\sum_i \log L_{ii}$。预测时解 $Lu = k_*$，方差为 $k_{**} - u^{\mathsf{T}}u$，无需存储逆矩阵。浮点误差可能出现极小负方差，需结合残差和条件数诊断；不能把显著负值简单截断后忽略错误。训练分解为 $O(n^3)$ 时间、$O(n^2)$ 存储，单点方差通常需 $O(n^2)$ 求解。

训练完成后，应保存训练侧预处理参数、训练输入、均值与核配置、噪声尺度、Cholesky 因子 L 及解向量 a。新点只应用已保存的预处理并计算交叉核，再求均值与方差；不能在每批查询上重新拟合标准化。若加入新观测或更换核参数，则需更新相应分解与解向量，不能混用旧缓存。

行列式项不是独立的万能复杂度标尺。 若 $C = U\,\mathrm{diag}(c_j)U^{\mathsf{T}}$，中心化边际负对数似然为 $\frac{1}{2}\sum_j[(u_j^{\mathsf{T}}r)^2/c_j + \log c_j] + \frac{n}{2}\log(2\pi)$。增大某方向方差会减小残差惩罚，却增加归一化代价，两项共同决定折中。不能脱离数据与核谱，把行列式项简单解释成参数越多就惩罚越大。

非参数模型的计算边界。 非参数模型可以表达复杂结构，却不代表复杂度无限且没有代价。kNN 的查询成本随样本数增加；核方法受核矩阵限制；高斯过程的后验更新需要处理越来越大的协方差矩阵。实际部署常用近似推断、原型压缩、局部模型或分层采样。

诱导变量如何降低代价。 选 $m \ll n$ 个诱导输入 Z，令 $u = f(Z) \in \mathbb{R}^m$。为简化取零均值，$K_{uu} \in \mathbb{R}^{m\times m}$ 可逆，$K_{Xu} \in \mathbb{R}^{n\times m}$。高斯条件公式给出

$$p(f_X \mid u) = \mathcal{N}(K_{Xu}K_{uu}^{-1}u,\; K - Q), \qquad Q = K_{Xu}K_{uu}^{-1}K_{uX}. \tag{7.16}$$

这里 $K - Q$ 是诱导变量未解释的条件协方差，不能只因为使用低秩表示就断言它为零。取近似联合 $q(f_X, u) = p(f_X \mid u)q(u)$，ELBO 化为 $\mathbb{E}_q \log p(y \mid f_X) - \mathrm{KL}(q(u)\|p(u))$。对高斯噪声，先在 $p(f_X \mid u)$ 下取期望，得到

$$\mathbb{E}[\log p(y \mid f_X) \mid u] = \log\mathcal{N}(y \mid K_{Xu}K_{uu}^{-1}u, \sigma^2 I) - \frac{\mathrm{tr}(K - Q)}{2\sigma^2}. \tag{7.17}$$

再对自由 $q(u)$ 优化，利用 $\sup_q\{\mathbb{E}_q \log h(u) - \mathrm{KL}(q\|p)\} = \log \int h(u)p(u)\,du$，可得

$$\mathcal{L} = \log \mathcal{N}(y \mid 0, Q + \sigma^2 I) - \frac{\mathrm{tr}(K - Q)}{2\sigma^2}. \tag{7.18}$$

迹修正惩罚遗漏的函数变异，因此这不是随意用 Q 替换 K 的精确模型。借助低秩恒等式主要成本可降至 $O(nm^2 + m^3)$、存储 $O(nm)$；诱导点过少或位置不当会遗漏局部故障结构。$m = n$、诱导输入等于训练输入且矩阵适定时，$Q = K$ 恢复精确训练证据。

诱导点不是额外测量点。 Z 是人为选择的代表输入位置，$u = f(Z)$ 仍未知，需要由 $q(u)$ 描述；不是在这些位置真的测到了新温升。m 表示诱导点个数，不再表示均值函数 $m(x)$。矩阵 Q 表达经这些代表位置传递的相关性，$\mathrm{tr}(K - Q)$ 为未解释的各训练点条件方差之和，迹就是矩阵对角线元素相加。因而更多计算上的代表点可以改善近似，却不能增加真实观测证据。上一章的 ELBO 在这里仍是对数证据下界，固定近似结构的后验区间也仍需独立检查覆盖。

随机特征的另一路近似。 对适当的平稳正定核，写 $k(x, x') = s_f^2 \mathbb{E}_\omega \cos(\omega^\mathsf{T}(x - x'))$，其中 $s_f^2 = k(x, x) > 0$。独立采样 ω_j 和 $b_j \sim \mathrm{Uniform}(0, 2\pi)$，设 $\phi_j(x) = s_f\sqrt{2/m}\cos(\omega_j^\mathsf{T} x + b_j)$。积化和差给出 $2\mathbb{E}_b[\cos(u+b)\cos(v+b)] = \cos(u-v)$，因为含 $2b$ 的余弦在整周期上的平均为零；再对频率和 m 项取期望，得到 $\mathbb{E}[\phi(x)^\mathsf{T}\phi(x')] = k(x, x')$。这把核问题变成 m 维线性问题，但有限 m 引入随机近似误差；适用的频率分布由核决定，不能对任意相似性随意采样。

参数化与非参数化的混合。 这些方法也可以组合使用。例如先用神经网络把振动窗口压成低维特征，再用 GP 预测并给出模型内的不确定性。这里若把编码器固定，GP 的区间通常不会自动包含编码器本身的不确定性。另一些任务只需在冻结特征上重新训练线性头，或用状态空间先验约束序列预测。组合前要说明每部分负责什么、哪些误差仍未计入，不能因为接上概率模型就认为整个系统已经校准。

模型选择案例。 小样本温度预测可以从线性回归、核岭回归和高斯过程开始，比较留出设备上的误差、区间覆盖率、训练时间和增量更新成本。若数据规模扩大且输入包含图像或长序列，再考虑深度模型。这个顺序能够先验证任务是否可预测，再决定是否需要更复杂的表示学习。

下列材料可用于对照近邻、支持向量机与高斯过程回归的实现；普通近邻方法不需要先构造核矩阵。

辅助学习材料

- **Support Vector Machines**；作者/平台：scikit-learn Developers；英文；官方文档。重点阅读 linear/nonlinear kernels、C、epsilon 和 dual formulation 小节，帮助理解本章的 RKHS、核岭和 SVM 对偶。在线阅读。

- **Gaussian Processes**；作者/平台：scikit-learn Developers；英文；官方文档。重点阅读 GP regression、kernels、noise level 和 predictive uncertainty，帮助理解核函数、协方差矩阵与不确定性。在线阅读。

- **高斯过程回归：推导，实现和理解**；知乎；中文解说。对照核矩阵与条件高斯分布，检查预测均值和方差；标题与主题据必应索引，原页受限。在线阅读。

- **高斯过程回归 (Gaussian Processes Regression, GPR) 简介**；CSDN；中文博客。先复算少量观测点的预测，再区分潜在函数与含噪观测的区间；标题与主题据必应索引，原页受限。在线阅读。

- **03-KNN 算法**；黑马程序员；bilibili；中文课程分集。选看《黑马程序员 3 天快速入门 python 机器学习》第 21 集，对照本章近邻方法的距离、邻居数和非参数性质，比较标准化前后的邻域；该分集不替代高斯过程推导。2026 年 10 月 4 日公开元数据所列整套课程累计播

放 1,793,918 次（不是本分集计数）；已核对目录与计数，未逐帧观看。观看分集。

本章小结。 参数化模型以明确结构换取估计效率和解释性，非参数化模型以更灵活的函数空间换取计算成本。二者不是互斥阵营，关键是让模型复杂度、数据量、先验知识和不确定性需求相互匹配。

从局部常数的近邻估计，到再生核空间的正则解，再到高斯联合分布的条件化，本章展示了三种共享样本信息的机制。核规定哪些输入相关，正则或先验规定允许多大变化，近似方法规定在预算内保留哪些变化；任何一个环节都可能成为偏差来源。相同预测均值不意味着相同概率解释，较宽函数空间也不意味着在未覆盖工况下必然诚实地表达不确定性。

到这里，我们已经从参数分布走到了函数分布。下一章把读数按时间排好：平均温度相同，持续升温和持续降温却可能需要不同处理。序列网络、状态空间模型和时间核各有办法利用这种顺序。比较时继续检查它们如何表达依赖、需要多少计算，以及给出的不确定性究竟针对潜在规律还是未来读数。

第三部分

深度学习模型

本部分从维护流程中尚未解决的问题出发。统计特征遗漏演化过程时，需要序列表示；风险分数不能指出缺陷位置时，需要视觉定位；检测结果不足以确定复检步骤时，需要检索有效规程；单路证据含糊时，需要跨模态对齐；真实故障覆盖不足时，才讨论生成数据。后续章节沿用第??章的信息可用性原则，但分别定义预测、定位、问答和合成的验收对象，不能用一种任务的高分证明另一种任务也有效。

第八章　序列建模模型

本章摘要。序列模型根据有顺序的历史观测形成表示，再由任务头预测未来数值或事件。异常检测还需要将已到达的观测与正常模式比较。本章先固定这几类任务的信息边界，再围绕“怎样利用历史”讲解代表模型：RNN 与 LSTM 逐步更新记忆，时间卷积网络组合固定范围的历史，Transformer 按内容读取历史，PatchTST 与 iTransformer 分别说明时间片和变量标记的组织，Mamba 用输入依赖的状态更新处理长序列。随后将这些表示接到多步预测、概率预测和异常评分上，说明输出如何训练、如何评价以及何时能够触发告警；最后介绍先在大量序列上预训练、再直接用于新设备的时序基础模型。

设每分钟记录一次温度、转速和振动。过去一小时的平均温度相同，可能对应稳定运行，也可能对应持续升温后骤降。平均值没有保留这些变化的顺序，而未来温度和异常判断可能都依赖这一顺序。序列模型的共同工作，就是把有顺序的观测变成对当前任务有用的表示。

本章以设备监测为例，先用未来温度预测走通输入、表示和输出，再说明同一类表示如何用于异常检测与未来故障预测。模型部分围绕历史信息的处理方式展开。逐步压缩历史带来记忆与训练问题，固定时间范围的卷积提供另一种计算方式，注意力允许重新读取远处的记录，选择性状态更新则控制长历史的计算和存储成本。它们是不同约束下的选择，不构成必然逐级升级的关系。时序基础模型改变的则是模型的获得方式：先在大量序列上预训练，再直接用于新设备。

8.1 先固定任务与可用的历史

8.1.1 预测未来与识别当前异常

设 $x_t \in \mathbb{R}^p$ 为时刻 t 已经取得的 p 个观测，长度为 T 的输入窗口为 $X_t = (x_{t-T+1}, \dots, x_t)$。温度预测根据这个窗口估计未来 H 分钟的温度 $(y_{t+1}, \dots, y_{t+H})$。故障预测估计未来指定时间段内发生故障的概率，标签是按这一时间段定义的零一事件。剩余寿命预测估计距失效还剩多久。它们可以使用同一类序列编码器，但输出含义与标签不同。

异常检测判断已经到达的观测是否偏离正常模式。例如，在 $t-1$ 时预测温度 $\hat{y}_{t|t-1}$，等 y_t 到达后才计算误差。这个误差可以提示当前异常，但不等于未来故障概率；若要用它提前预警，必须另外验证异常与后续故障之间的关系。

8.1.2 共享表示与不同的输出头

把序列变成向量或向量序列的网络主体称为**序列编码器**，把表示转成指定预测的部分称为**任务头**。窗口预测可写为

$$r_t = f_\theta(X_t), \qquad \hat{y}_{t+1:t+H} = g_\phi(r_t). \tag{8.1}$$

r_t 是中间表示，θ 与 ϕ 分别为编码器和任务头参数。数值预测头输出未来温度，事件预测头输出故障概率。不同任务头可以使用同类编码器，但训练目标不同时，编码器会学到不同参数。

图8.1区分编码、输出和事后比较三种操作。实线计算在时刻 $t-1$ 完成，虚线在新观测到达后才形成残差。未来故障头须用事件标签训练，不能通过给残差改名获得。

例如，四分钟的三个传感器组成 4×3 输入，八台设备构成一批时为 $8 \times 4 \times 3$；预测未来两分钟温度时，每个样本的标签是长度为二的向量。训练时用记录下来的未来标签计算损失，预测时只能读取当前已取得的窗口。未来转速只有来自已知排程时，才能作为外生输入提前进入模型。

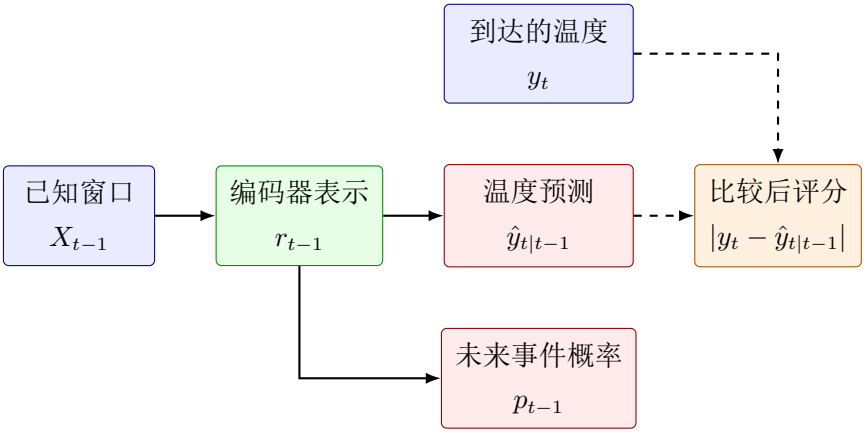


图 8.1： 相同类别的历史编码方法可以服务于不同任务。实线是截至 $t-1$ 的预测计算，虚线是 t 时刻观测到达后的异常评分。各任务可分别训练，也可在有相应标签时联合训练。

8.2 RNN 与 LSTM：把历史逐步写入记忆

8.2.1 RNN 的状态怎样形成预测

当数据持续到达时，可以每读一个观测就更新一个固定宽度的状态，无需每次重新计算完整窗口。循环神经网络（Recurrent Neural Network，RNN）将这一规则写为

$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b), \qquad \hat{y}_{t+1} = w^{\mathsf{T}} h_t + b_y. \tag{8.2}$$

设 $h_t \in \mathbb{R}^m$，则 $W_x \in \mathbb{R}^{m\times p}$、$W_h \in \mathbb{R}^{m\times m}$、$b, w \in \mathbb{R}^m$，$b_y$ 为标量。W_x 处理当前输入，W_h 处理旧状态，同一组参数在各时刻重复使用。tanh 逐分量施加非线性。状态是内部计算的一组数，不是另一个传感器，也不是自动获得的状态概率分布。

图8.2中，纵向箭头读入当前观测，横向箭头传递过去的状态。若 $m=2$，每一步都把三个新观测与两个旧状态数变成两个新状态数；初始状态可以为零，也可以学习得到。

状态宽度不随历史增长，但过去的信息必须经过连续更新才能影响当前输出。早期的单次冲击可能被后续状态覆盖，训练时也难以获得有效梯

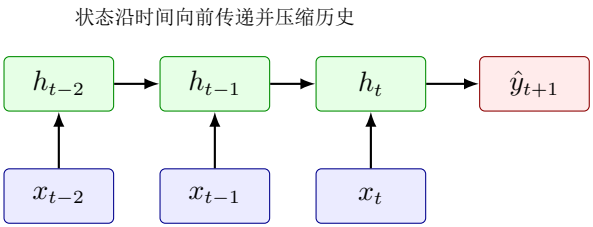


图 8.2：递归序列模型把历史压缩为状态；状态维度和更新机制决定哪些信息能够持续保留。

度。下面先看门控如何改变更新，再用梯度路径说明它解决了什么困难。

8.2.2 LSTM：分开控制保留、写入与读出

长短期记忆网络（Long Short-Term Memory，LSTM）在状态更新中增加门控与单独的细胞状态[1]。下面采用含遗忘门的常见版本；遗忘门是后续引入的机制，并非 1997 年原始结构已经具有的门。它让网络分别控制旧内容的保留和新内容的写入：

$$i_t = \sigma(W_i x_t + U_i h_{t-1}), \qquad f_t = \sigma(W_f x_t + U_f h_{t-1}), \tag{8.3}$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1}), \qquad \tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1}), \tag{8.4}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \qquad h_t = o_t \odot \tanh(c_t). \tag{8.5}$$

这里 $\sigma(a) = 1/(1+e^{-a})$ 把数压到零与一之间，tanh 把数压到 $(-1,1)$，$\odot$ 表示对应分量相乘，不是矩阵乘法。$x_t \in \mathbb{R}^p$，各门与 $c_t, h_t \in \mathbb{R}^m$，因此各 W 为 $m \times p$、各 U 为 $m \times m$，可训练偏置省略未写。输入门 i_t 决定写多少候选内容，遗忘门 f_t 决定留多少旧内容，输出门 o_t 决定公开多少记忆；细胞状态 c_t 是存储通道，h_t 是供下一步和任务头使用的表示。

可先手算一个分量：若 $c_{t-1} = 2, f_t = 0.9, i_t = 0.2, \tilde{c}_t = 0.5, o_t = 1/2$，则 $c_t = 0.9 \times 2 + 0.2 \times 0.5 = 1.9$，$h_t = \tanh(1.9)/2 \approx 0.478$。候选值受限不代

[1]来源：Hochreiter 与 Schmidhuber，*Long Short-Term Memory*，1997；Gers 等，*Learning to Forget: Continual Prediction with LSTM*，2000。

表累积记忆也限于 $[-1,1]$。门值由网络根据当前输入和旧状态算出，不是人为判定“重要”后再开门。

门控的必要性可以从训练梯度理解。对简单 RNN，隐藏状态对早期状态的导数包含

$$\frac{\partial h_T}{\partial h_t^{\top}} = J_T J_{T-1} \cdots J_{t+1}, \qquad J_s = \operatorname{diag}\left(1 - \tanh^2(a_s)\right) W_h. \tag{8.6}$$

这里 $a_s = W_h h_{s-1} + W_x x_s + b$。Jacobian（雅可比矩阵）的第 (i,j) 项为输出第 i 分量对输入第 j 分量的偏导；矩阵因子按式中次序相乘，不可交换，反向传播列梯度时使用其转置。以标量为例：若每步因子都是 0.9，回传 50 步后只剩 $0.9^{50} \approx 0.005$；若都是 1.1，则增至 $1.1^{50} \approx 117$。矩阵情形下，若乘积中的最大奇异值长期小于一，梯度趋向零；若大于一，梯度可能爆炸。梯度裁剪在 $g \neq 0$ 时把 g 替换为 $g \min(1, \tau/\|g\|)$，其中阈值 $\tau > 0$；$g = 0$ 时直接保留零，避免除零。它可以控制爆炸，但不能修复长期消失。LSTM 的细胞状态通过门 f_t 保留一条近似加法路径，使信息保存时间由门值控制。

非线性导数 $1 - \tanh^2(a_s)$ 在饱和区域接近零，因此仅控制循环权重的尺度仍不足以保证长期梯度。对于长数据流，可以每 K 步截断计算图以控制训练内存，前向状态仍可携带更早的信息，但早期输入不能通过被截断的路径直接贡献梯度。窗口长度与截断长度因而是不同的实验变量。实现截断时，应保留状态数值但切断它与上一计算图的梯度连接；切断梯度不等于把状态清零。若下一批已换设备或不再时间连续，则应按样本边界重置，不能沿用上一批状态。

从单步导数到跨时间反向传播。 沿用式(8.2)的维度，令总损失为 $\mathcal{L} = \sum_{t=1}^{T} \ell_t(h_t)$，用列向量 $g_t = \nabla_{h_t} \mathcal{L}$ 表示包含所有后续损失的梯度。链式法则

逐步给出

$$g_T = \nabla_{h_T} \ell_T, \tag{8.7}$$

$$g_t = \nabla_{h_t} \ell_t + J_{t+1}^{\mathsf{T}} g_{t+1}, \tag{8.8}$$

$$g_t = \sum_{s=t}^{T} (J_s J_{s-1} \cdots J_{t+1})^{\mathsf{T}} \nabla_{h_s} \ell_s, \tag{8.9}$$

其中 $s = t$ 时空乘积为 I。再令 $\delta_t = \operatorname{diag}(1 - h_t \odot h_t) g_t$，共享权重的梯度不是某一步的梯度，而是所有出现位置的累加：

$$\nabla_{W_h} \mathcal{L} = \sum_{t=1}^{T} \delta_t h_{t-1}^{\mathsf{T}}, \qquad \nabla_{W_x} \mathcal{L} = \sum_{t=1}^{T} \delta_t x_t^{\mathsf{T}}. \tag{8.10}$$

由矩阵范数的次乘性，$\|J_s \cdots J_{t+1}\|_2 \le \prod_{r=t+1}^{s} \|J_r\|_2$。若每项至多为 $\rho < 1$，远期损失传回的上界按 ρ^{s-t} 衰减；若上界大于一，仅意味着可能放大，不能据此断言实际梯度必然爆炸，因为奇异方向会随时间改变。

固定门值时，沿 LSTM 细胞状态的直接路径有

$$\left. \frac{\partial c_T}{\partial c_t^{\mathsf{T}}} \right|_{\text{直接路径}} = \operatorname{diag}\left(\prod_{s=t+1}^{T} f_s \right). \tag{8.11}$$

乘积按元素计算。若某维遗忘门近似恒为 $f \in (0,1)$，经过 k 步保留 f^k，衰减到初值的 e^{-1} 倍所需步数为 $-1/\log f$。例如 $f = 0.9$ 时这一时间尺度约为 9.49 步，$f = 0.99$ 时约为 99.50 步；它是衰减到约 36.8% 的时间，不是到零的时间。这解释了门值与记忆时间尺度的关系，但不是完整 Jacobian：门还通过 h_{t-1} 依赖早期状态，其他路径仍会放大或衰减梯度。门控改善可训练性，不保证无限记忆。

8.2.3 GRU：用较少门控更新状态

门控循环单元（Gated Recurrent Unit，GRU）使用更新门和重置门

$$z_t = \sigma(W_z x_t + U_z h_{t-1}), \tag{8.12}$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1}), \tag{8.13}$$

$$\tilde{h}_t = \tanh(W_h x_t + U_h(r_t \odot h_{t-1})), \tag{8.14}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t. \tag{8.15}$$

这里沿用 LSTM 的写法：W 作用于当前输入，U 作用于旧状态；W_h 的下标指候选状态，与式(8.2)不同；r_t 在此表示重置门。重置门决定计算候选状态时参考多少旧状态；更新门接近零时保留旧状态，接近一时写入候选状态。GRU 没有单独的细胞状态和输出门，保留与写入由同一个更新门成对控制，所以参数更少，控制也更粗。

8.3 时间卷积网络：在固定范围内组合历史

8.3.1 因果卷积怎样保留顺序

递归状态按时间逐步计算。若每次输入都是一段完整窗口，也可以同时计算窗口中各位置的局部特征。时间卷积网络（Temporal Convolutional Network，TCN）沿时间轴使用因果卷积，并通过多层空洞卷积扩大可见范围。因果卷积在位置 t 只读取当前和过去，单层可写为

$$z_t = \rho\left(b + \sum_{j=0}^{k-1} W_j x_{t-jd}\right). \tag{8.16}$$

k 为卷积核宽度，d 为正整数空洞率，W_j 把输入通道映射到输出通道，ρ 为逐分量激活函数。边界以零补齐并只在左侧补值。$d = 1$ 读取连续位置，$d = 2$ 每隔一个位置读取一次。各相对位置有各自权重，所以交换两个时间点通常会改变结果。

以标量输入为例，令 $k=2, d=2, W_0=1, W_1=-1, b=0$，暂不使用非线性，则 $z_t = x_t - x_{t-2}$。温度序列 $(20, 21, 22)$ 在第三个位置给出 2，交换为 $(22, 21, 20)$ 后给出 -2。两段的均值相同，卷积提取的变化方向不同。多通道卷积可以同时组合温度、转速与振动，实际权重由预测损失学习。

8.3.2 空洞卷积怎样扩大感受野

设每层步幅为一、核宽为 k，第 ℓ 层空洞率为 d_ℓ，则 L 层输出能依赖的最早位置与当前位置之间跨度为

$$R = 1 + (k-1)\sum_{\ell=1}^{L} d_\ell. \tag{8.17}$$

R 是感受野跨度，不自动保证跨度内每个位置都被覆盖。取 $k=2$、$d_\ell = 2^{\ell-1}$ 时，路径可组合这些二进制偏移，覆盖最近 2^L 个位置：三层空洞率 $1, 2, 4$ 给出 $R = 1 + (1+2+4) = 8$，正好覆盖八步历史。若每个残差块有两层同空洞率卷积，计算感受野时须将两层都计入。

图8.3把三层的局部读取展开：最终节点先取相隔四步的两个表示，每个表示再取相隔两步的两个表示，底层则读取相邻输入。

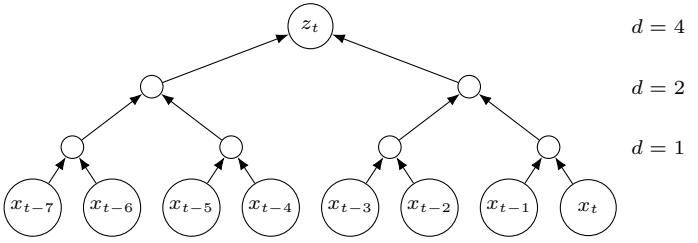


图 8.3: 核宽为二的三层因果空洞卷积中，当前位置输出读取最近八步的路径。箭头表示特征参与下一层计算，只展开与 z_t 相关的节点。

TCN 常用残差块，将卷积变换结果与输入相加。图8.4展开一个含两层同空洞率卷积的残差块：每层卷积配合权重归一化、ReLU 与随机失活，右侧捷径在需要匹配通道时使用 1×1 卷积。图中信息自下向上传递，$\hat{z}^{(i-1)}$ 与 $\hat{z}^{(i)}$ 是相邻层的特征序列，不是本章预测任务中的未来标签。

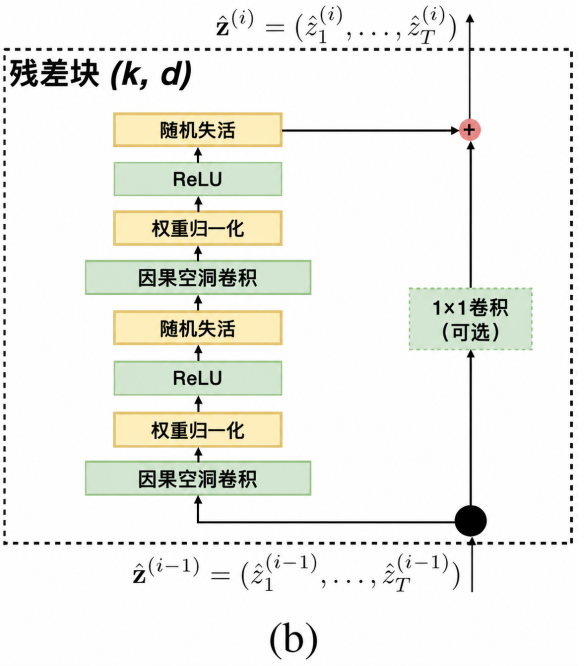


图 8.4： TCN 残差块[2]

增加层数或空洞率可以扩大历史范围，但超出感受野的信息仍无法影响当前输出。训练时各位置可并行计算，流式运行时可缓存各层所需的过去特征。TCN 适合有明确局部时间尺度的预测，不能仅凭扩大跨度保证保留短冲击或远期周期。下面讨论另一种做法：保留历史表示，在预测需要时重新读取。

8.4 Transformer：按内容重新读取历史

8.4.1 查询、键和值怎样完成一次读取

递归模型把全部历史压入有限维状态，需要重新访问某次冲击或某段工况时，这种压缩可能成为瓶颈。注意力改为按当前查询读取历史表示，其

[2]来源：Bai 等，*An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling*，2018。

缩放点积形式为[3]

$$\text{Attention}(Q,K,V)=\text{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}\right)V. \tag{8.18}$$

直接访问缩短了远距离位置之间的信息路径，代价是标准全局注意力的计算量随序列长度呈二次增长。Transformer 把多头注意力、位置编码、前馈网络、残差连接和归一化组合起来。因此，从 GRU 转向 Transformer 是以保存和访问历史的成本换取更灵活的信息选择，而非无条件提高预测能力。

图8.5区分历史键用于匹配、历史值用于输出的两条路径；当前查询通过归一化权重决定读取哪些历史内容。

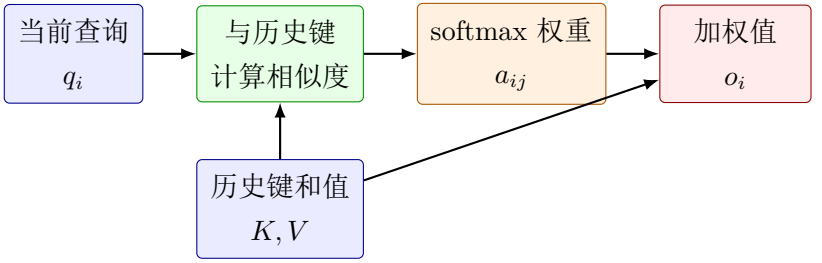


图 8.5： 注意力把“压缩全部历史”改为“按查询重新读取历史”，代价是保存和计算位置间的相互作用。

注意力的逐位置解释。 对于第 i 个查询，注意力权重为

$$a_{ij}=\frac{\exp(q_i^{\mathsf{T}}k_j/\sqrt{d_k})}{\sum_{r=1}^{T}\exp(q_i^{\mathsf{T}}k_r/\sqrt{d_k})},\qquad o_i=\sum_j a_{ij}v_j. \tag{8.19}$$

因此每个输出是值向量的加权平均。多头注意力使用多组投影，在不同的特征子空间分别读取历史；训练不保证每个头都具有可命名的分工。

一次可以手算的读取。 把一个采样点或一个时间片转换成向量后，该向量也称为一个 token，即模型处理的一个序列单元。对当前查询，假设两个

[3]来源：Vaswani 等，*Attention Is All You Need*，2017。

可见历史位置的缩放得分为 $0, \log 3$，则 softmax 先取指数得到 $1, 3$，再除以总和得到 $1/4, 3/4$。若对应的标量值为 $10, 20$，输出就是 17.5，而不是直接复制得分最大的 20。键用于算权重，值用于形成输出，所以两者可以有不同维度。若第二个位置实际来自未来，必须在归一化前屏蔽它，此时权重成为 $1, 0$，输出为 10。

缩放、归一化与访问成本的推导。 采用逐行存放位置表示的约定。各矩阵形状为

$$X \in \mathbb{R}^{T\times d}, \quad W_Q, W_K \in \mathbb{R}^{d\times d_k}, \quad W_V \in \mathbb{R}^{d\times d_v}, \tag{8.20}$$

因此 $Q, K \in \mathbb{R}^{T\times d_k}$、$V \in \mathbb{R}^{T\times d_v}$。为理解缩放，暂设 q_i, k_j 的坐标彼此独立、均值为零、方差为一，则

$$\mathbb{E}(q_i^{\mathsf{T}} k_j) = 0, \qquad \mathrm{Var}(q_i^{\mathsf{T}} k_j) = \sum_{r=1}^{d_k} \mathrm{Var}(q_{ir} k_{jr}) = d_k. \tag{8.21}$$

因此除以 $\sqrt{d_k}$ 使得分方差约为一，避免维度增加时 softmax 过早饱和。这是初始化尺度的解释，不是对训练后相关特征的严格分布假设。记缩放得分为 s_{ij}，由商法则得到

$$\frac{\partial a_{ij}}{\partial s_{ir}} = a_{ij}(\mathbf{1}_{j=r} - a_{ir}). \tag{8.22}$$

当一个权重已接近一时，其余权重及大量导数接近零，模型便难以调整访问对象。softmax 使 $a_{ij} \geq 0$ 且 $\sum_j a_{ij} = 1$，单头输出因而位于值向量的凸包内；但后续投影、残差和前馈变换不受这个凸包约束。

计算 QK^{T} 需 $O(T^2 d_k)$ 次标量运算，计算 AV 需 $O(T^2 d_v)$；显式保存分数需 $O(T^2)$ 空间。若无位置编码、无遮罩，令 P 为位置置换矩阵，则 $Q' = PQ, K' = PK, V' = PV$，有 $A' = PAP^{\mathsf{T}}$ 及 $O' = PO$。这叫置换等变，而不是输出不随置换变化；网络本身无法从内容之外识别先后顺序。位置编码正是为补足这一点而加入的结构；因果遮罩的首要作用是限定可读取的范围，见下文。

位置编码与因果遮罩。 由于前述置换等变性，要表达明确的先后或时间距离，需加入位置信息。正弦位置编码使用不同频率的正余弦函数；可学习位置嵌入直接为每个位置分配向量。因果遮罩令 $j > i$ 的注意力得分为 $-\infty$，从而保证第 i 个位置只能使用 1 到 i 的信息。解码时的 Key–Value (KV) cache 保存已经计算的键和值，使每次生成新 token 不必重复计算全部历史。

8.4.2 Transformer 编码块怎样接到预测头

设窗口投影与位置编码后的表示为 $Z \in \mathbb{R}^{T\times d}$。一个前置归一化编码块可写为

$$U = Z + \mathrm{MHA}(\mathrm{LN}(Z)), \tag{8.23}$$

$$Z' = U + \mathrm{FFN}(\mathrm{LN}(U)), \tag{8.24}$$

$$\mathrm{FFN}(u) = W_2\rho(W_1u + b_1) + b_2. \tag{8.25}$$

LN 是层归一化，MHA 是多头注意力（Multi-Head Attention），FFN 是逐位置前馈网络（Feed-Forward Network）。最后一式按列向量写，$W_1 \in \mathbb{R}^{d_f\times d}$、$W_2 \in \mathbb{R}^{d\times d_f}$，$d_f$ 为中间宽度。多头先各自读取历史，再拼接并投影回 d 维，以便残差相加；前馈网络对每个位置分别做同样的非线性加工，残差把子层的输入直接加回输出。批大小为 B、头数为 n_h 时，注意力分数张量的形状为 $B \times n_h \times T \times T$，最后两维随窗口长度平方增长，是长序列的显存瓶颈。

预测未来两分钟温度时，可以取最后一个位置的 d 维表示，接 $2 \times d$ 的线性投影得到两个提前量的输出。窗口编码时所有输入都已在 t 取得，窗口内部的双向注意力不会读取 t 以后的观测；若同时训练各位置的在线预测，则须使用因果遮罩，否则早期位置会读到它预测时尚未取得的内容。

Transformer 的编码器处理输入序列，解码器读取编码器表示并自回归地产生输出。图8.6展示完整结构[4]，其中编码器–解码器注意力的查询来自

[4]来源：Vaswani 等，*Attention Is All You Need*，2017。

解码器，键和值来自编码器输出。“加法与归一化”先完成残差相加，再做层归一化，与本节公式的前置归一化顺序不同。前述时间序列预测采用编码器加预测头，不需要默认加入自回归解码器。

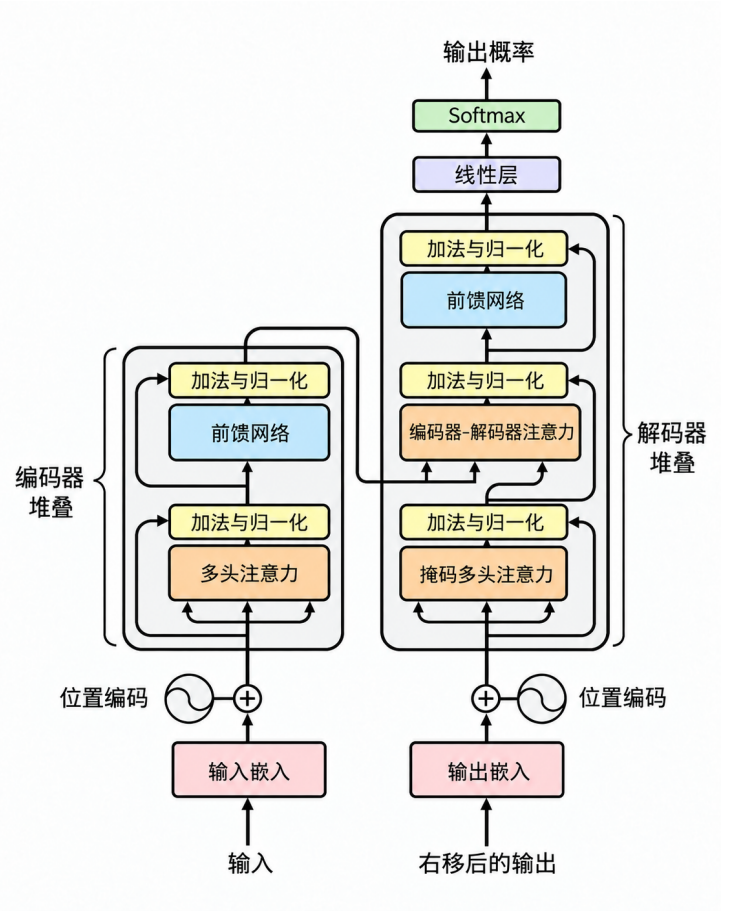


图 8.6: Transformer 编码器与解码器[4]

8.4.3 非平稳性与位置表示

趋势、季节性、工况切换和传感器老化会使 $p(x_{t+1} \mid x_{\le t})$ 随时间变化。差分、归一化、分解和时间特征可以减少非平稳性，也可能删除故障前的有用趋势；检验未来性能时，应采用滚动验证而非随机交叉验证。模型更

新还应区分概念漂移与测量系统改变。

位置编码的选择。 绝对位置编码把位置直接加到 token 表示中，简单但长度外推能力有限；相对位置编码直接描述 token 间距离，更适合长度变化；旋转位置编码通过二维旋转改变查询和键，使点积携带相对位置信息。选择时要同时考虑训练长度与部署长度。

8.4.4 PatchTST：把局部时间片作为读取单位

逐采样点注意力的成本随窗口长度平方增长。PatchTST（Patch Time Series Transformer）把每个传感器通道的连续片段投影成一个序列单元，再对片段做注意力[5]。例如，一百二十个采样点按长度十、步幅十切分，得到十二个片段。单通道片段 $p_j \in \mathbb{R}^{10}$ 通过 $e_j = W_p p_j + b_p$ 映射为 d 维，其中 $W_p \in \mathbb{R}^{d\times 10}$，再加入位置信息。十二个单元的注意力分数矩阵为 12×12，小于逐点处理的 120×120。

原始 PatchTST 采用通道独立设计：各通道分别形成片段序列，共享编码器和预测头参数，注意力不直接交换不同传感器的信息。预测单个温度通道时，这种共享可以利用不同通道的训练样本规律；但若预测必须依赖转速与负载的联动，还需另行设计跨通道融合或选用联合编码模型。片段越长，越可能抹去短冲击。

图8.7上方将多变量序列按通道拆开、送入共享骨干，再把各通道预测拼回多变量输出；左下经实例归一化、切片、投影与编码输出未来序列；右下用被遮蔽片段的重建做自监督预训练，其重建输出不等于未来预测。

[5] 来源：Nie 等，*A Time Series is Worth 64 Words: Long-term Forecasting with Transformers*，2023。

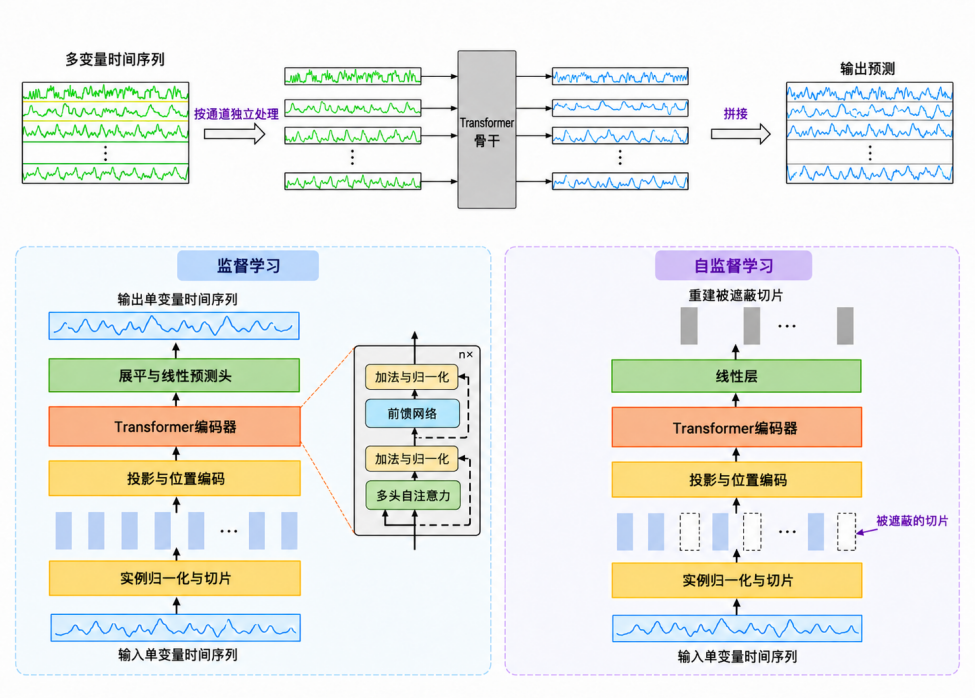


图 8.7： PatchTST 预测与预训练[6]

8.4.5 iTransformer：以变量标记表达传感器关系

与 PatchTST 沿时间轴形成片段标记不同，iTransformer 将每个变量的整个回看窗口嵌入为一个变量标记，再在变量标记之间做注意力[7]。对 p 个变量、长度为 T 的窗口，得到 p 个 d 维标记，单头注意力的分数矩阵因而为 $p \times p$。时间位置由窗口嵌入中的参数区分，注意力直接交换变量之间的信息，逐变量应用的前馈网络继续加工各变量表示。

图8.8上方按时间步形成标记，下方是 iTransformer 的变量标记：每个变量保留一个标记位置，其内容已通过注意力融合其他变量的信息。图中

[6]来源：Nie 等，*A Time Series is Worth 64 Words: Long-term Forecasting with Transformers*，2023。

[7]来源：Liu 等，*iTransformer: Inverted Transformers Are Effective for Time Series Forecasting*，2024。

的“反转”指标记组织维度的变化，不是把时间顺序倒置。

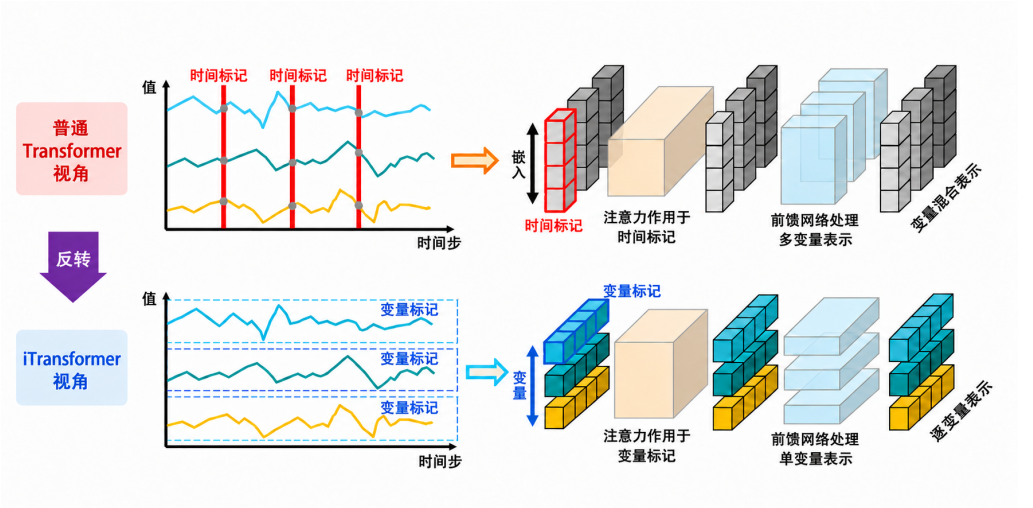


图 8.8: 时间标记与变量标记[7]

8.5 状态空间与 Mamba：选择性地保留长历史

8.5.1 状态转移不自动等于概率估计

状态空间模型（State Space Model，SSM）将状态演化和观测生成分开。先用线性高斯模型说明“状态表示”与“状态不确定性”的区别[8]：

$$h_t = Ah_{t-1} + Bu_t + \eta_t, \qquad \eta_t \sim \mathcal{N}(0, Q), \tag{8.26}$$

$$x_t = Ch_t + \varepsilon_t, \qquad \varepsilon_t \sim \mathcal{N}(0, R). \tag{8.27}$$

这里 u_t 为已知控制量，Q 与 R 分别为状态噪声和观测噪声协方差。卡尔曼滤波（Kalman Filter）在状态均值之外传播协方差；确定性的 RNN 或 Mamba 层只计算一组状态数，不自动获得这种概率解释。

滤波只用截至 t 的观测估计 h_t；平滑还会用到 t 以后的观测，在线任务不能使用。下面给出滤波推导作为概率状态的对照，随后转回可训练序

[8]来源：Kalman，*A New Approach to Linear Filtering and Prediction Problems*，1960。

列层。

卡尔曼滤波的两步更新。 在线线性高斯状态空间模型中，预测步骤为

$$\hat{h}_{t|t-1} = A\hat{h}_{t-1|t-1} + Bu_t, \tag{8.28}$$

$$P_{t|t-1} = AP_{t-1|t-1}A^{\mathsf{T}} + Q. \tag{8.29}$$

观测到 x_t 后，计算创新 $r_t = x_t - C\hat{h}_{t|t-1}$（新观测减去预测观测的残差，并非技术创新）和增益

$$K_t = P_{t|t-1}C^{\mathsf{T}}(CP_{t|t-1}C^{\mathsf{T}} + R)^{-1}, \tag{8.30}$$

再更新 $\hat{h}_{t|t} = \hat{h}_{t|t-1} + K_t r_t$。创新序列可以用于检测模型失配：若其长期偏离零或自相关显著，说明转移、噪声或传感器模型需要重新估计。

把滤波更新算成一个温度例子。 设当前温度的预测均值为 20，预测方差 $P^- = 4$，传感器噪声方差 $R = 1$，且 $C = 1$。读到 22 后，创新是 $22 - 20 = 2$，增益为 $4/(4+1) = 0.8$，修正均值为 21.6，修正方差为 $(1-0.8)4 = 0.8$。修正均值也可写成 $0.2 \times 20 + 0.8 \times 22$，即以 $1-K$ 与 K 为权重对预测值和观测值加权平均，方差较小的一方权重较大。若传感器更不可靠，$R = 16$，增益降为 0.2，均值只移到 20.4。方差的单位是温度单位的平方，衡量的是估计的不确定性。滤波中的“更新”是在固定系统参数下修正状态分布，与神经网络训练时更新权重不是同一操作。

由高斯条件化推导滤波增益。 设 $h_t \in \mathbb{R}^m, x_t \in \mathbb{R}^p, u_t \in \mathbb{R}^q$，则 $A \in \mathbb{R}^{m\times m}, B \in \mathbb{R}^{m\times q}, C \in \mathbb{R}^{p\times m}$；$Q, P \in \mathbb{R}^{m\times m}$，$R \in \mathbb{R}^{p\times p}$。假设转移噪声与观测噪声均为零均值、彼此独立、跨时间独立，并与先前状态独立。记预测均值和协方差为 m^-, P^-。线性变换的均值与协方差规则先给出前述预测步骤，再给出联合分布

$$\begin{bmatrix} h_t \\ x_t \end{bmatrix} \,\Big|\, x_{<t} \sim \mathcal{N}\left(\begin{bmatrix} m^- \\ Cm^- \end{bmatrix}, \begin{bmatrix} P^- & P^-C^{\mathsf{T}} \\ CP^- & CP^-C^{\mathsf{T}} + R \end{bmatrix} \right). \tag{8.31}$$

为看清条件化的来源，令 $e = h_t - m^-$、$r = x_t - Cm^-$、$S = CP^-C^\top + R$，并写出修正后的误差 $e^+ = e - Kr$。要求它与已经利用的创新不相关，有

$$\mathrm{Cov}(e - Kr, r) = P^-C^\top - KS = 0, \qquad K = P^-C^\top S^{-1}. \tag{8.32}$$

联合高斯使不相关等价于独立，因此 $\mathbb{E}(h_t \mid x_t, x_{<t}) = m^- + Kr$，且后验协方差为

$$P^+ = P^- - P^-C^\top S^{-1}CP^- \tag{8.33}$$

$$= (I - KC)P^-(I - KC)^\top + KRK^\top. \tag{8.34}$$

式(8.34)称为 Joseph 形式，更适合在有限精度计算中保持对称性和半正定性。这里要求 S 可逆，实际实现应解线性方程而非显式求逆。若 $p = m = 1, C = 1$，则 $K = P^-/(P^- + R)$：观测越噪，修正越小；状态预测越不确定，越相信新观测。在线性高斯且参数正确时，$r^\top S^{-1} r$ 服从自由度为 p 的卡方分布；用它设阈值仍需检查噪声、参数估计与重复告警假设，不能直接把名义尾概率当成事件级误报率。

8.5.2 从固定状态空间到 Mamba 的选择性记忆

本节沿用状态转移的语言，但把 SSM 用作可训练的确定性序列层：它输出表示，不携带协方差或预测区间。先说明固定线性系统为何能形成长记忆，再解释 Mamba 如何根据输入选择写入、保留和读取的信息；以下只讨论原始 Mamba。

连续动力学怎样成为离散记忆。 以 τ 表示连续时间，t 仍表示离散位置。设状态 $h(\tau) \in \mathbb{R}^m$、输入 $u(\tau) \in \mathbb{R}^q$、层输出 $v(\tau) \in \mathbb{R}^r$，连续系统为

$$\frac{dh(\tau)}{d\tau} = A_c h(\tau) + B_c u(\tau), \qquad v(\tau) = Ch(\tau) + Du(\tau). \tag{8.35}$$

其中 $A_c \in \mathbb{R}^{m\times m}$、$B_c \in \mathbb{R}^{m\times q}$、$C \in \mathbb{R}^{r\times m}$、$D \in \mathbb{R}^{r\times q}$ 均不随位置变化，D 为输入到输出的直接通路。这里 u_t 是由观测 x_t 提取的输入特征，不限于前

文滤波模型中的控制量；v_t 是中间表示，不与任务标签 y_t 混用。式(8.35)是线性时不变（Linear Time-Invariant，LTI）系统。

在长度为 $\Delta > 0$ 的每个区间内保持输入不变，即零阶保持，积分因子法给出

$$h_t = \bar{A}h_{t-1} + \bar{B}u_t, \qquad v_t = Ch_t + Du_t, \tag{8.36}$$

$$\bar{A} = \exp(\Delta A_c), \qquad \bar{B} = \int_0^{\Delta} \exp(sA_c)B_c\, ds. \tag{8.37}$$

只有 A_c 可逆时，才可把式(8.37)的积分写为 $A_c^{-1}(\bar{A} - I)B_c$；积分形式始终有效。反复代入式(8.36)可得

$$v_t = C\bar{A}^t h_0 + \sum_{j=1}^{t} C\bar{A}^{t-j}\bar{B}u_j + Du_t. \tag{8.38}$$

式(8.38)表明，固定线性系统既可递推，也可使用只依赖时间差的卷积核 $G_k = C\bar{A}^k\bar{B}$ 计算。S4 通过结构化参数高效表示和计算长核；卷积实现的复杂度取决于具体算法，不能将其一概说成严格线性。若 A_c 的特征值实部为负，则 $\bar{A}$ 的特征值模小于一，长期记忆衰减，但非正规矩阵仍可能短期放大扰动。固定核对同一时间差使用相同权重，不能仅因某次冲击内容重要就改变记忆规则，这正是选择性更新要解决的限制。

输入依赖的步长、写入与读取。 为明确维度，先看一个标量输入通道 $u_t \in \mathbb{R}$，其状态 $h_t \in \mathbb{R}^m$。令 $\xi_t \in \mathbb{R}^d$ 为当前位置经过因果局部处理后的特征，定义

$$\Delta_t = \mathrm{softplus}(w_\Delta^{\mathsf{T}}\xi_t + b_\Delta) > 0, \tag{8.39}$$

$$B_t = W_B\xi_t \in \mathbb{R}^m, \qquad C_t = W_C\xi_t \in \mathbb{R}^m, \qquad A_c = \mathrm{diag}(-\exp(a_1), \ldots, -\exp(a_m)).$$

这里 $w_\Delta \in \mathbb{R}^d$、$W_B, W_C \in \mathbb{R}^{m\times d}$ 以及 a_i 是训练得到、推理时共享的参数；$\mathrm{softplus}(s) = \log(1 + e^s)$。式(8.39)是便于推导的单通道参数化，实际模块

可用低秩投影产生各通道步长，并在通道间共享部分 B_t, C_t。输入依赖的是 Δ_t, B_t, C_t，不是所有参数；尤其 A_c 和直接通路系数 D 不必随输入变化。

逐步冻结这些系数，精确零阶保持对应

$$\bar{A}_t = \exp(\Delta_t A_c), \qquad \bar{B}_t^{\mathrm{ZOH}} = \int_0^{\Delta_t} \exp(sA_c) B_t \, ds, \tag{8.40}$$

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t u_t, \qquad v_t = C_t^{\mathsf{T}} h_t + D u_t. \tag{8.41}$$

式(8.41)中的 $\bar{B}_t$ 必须与所选离散化一致。原始 Mamba 的官方选择性扫描实现对输入项采用 $\bar{B}_t = \Delta_t B_t$，同时保留 $\bar{A}_t = \exp(\Delta_t A_c)$；它并非直接使用式(8.40)的精确输入积分。两者在 $\|\Delta_t A_c\|$ 较小时一阶相符，不能将简化输入项写成精确零阶保持的恒等式。

对第 i 个状态分量，保留系数为 $\exp(-\Delta_t \exp(a_i))$。较小的 Δ_t 使旧状态较少衰减，较大的 Δ_t 使更新更快；B_t 控制写入方向和强度，C_t 控制当前读出。步长因此是学习到的记忆时间尺度，不等于传感器的物理采样间隔；能否真正保留短时冲击，仍取决于训练目标与数据，须通过事件级验证检查。

尽管式(8.41)对给定系数下的旧状态仍是线性的，系数本身依赖输入，整个输入到输出映射已不是 LTI 系统。历史输入的权重同时依赖其后的选择，不能再用式(8.38)中那个固定的时间差卷积核替代。

先手算两步，再理解扫描。 取单维 $h_0 = 0$，第一步 $F_1 = 0.5, b_1 = 2$，第二步 $F_2 = 0.8, b_2 = 1$。依次递推得到 $h_1 = 2, h_2 = 0.8 \times 2 + 1 = 2.6$。合并成一步则是 $h_2 = (0.8 \times 0.5)h_0 + (0.8 \times 2 + 1) = 0.4h_0 + 2.6$。第三步既可先与第二步合并，也可后接到前两步的结果上，答案相同；交换前两步却得到 $0.5 \times 1 + 2 = 2.5$，说明顺序不能交换。这里的 b_t 是已经计算好的写入量，不是神经网络所有层都共用的固定偏置。

离散化也可以手算：取 $A_c = -1, B_t = 1, u_t = 2, h_{t-1} = 0, \Delta_t = \log 2$，则保留系数为 $1/2$。精确积分的输入系数为 $1 - e^{-\Delta_t} = 1/2$，得到 $h_t = 1$；简化输入系数为 Δ_t，得到 $h_t = 2\log 2 \approx 1.386$。这不是计算错误，而是两

种离散化在步长不小时确实不同。学习参数可以适应所用实现，但不能因此把两种公式称为相等。

为何能递推推理，也能并行训练。 记 $F_t = \bar{A}_t$、$b_t = \bar{B}_t u_t$，每步状态更新都是仿射映射 $h \mapsto F_t h + b_t$。定义按时间先后合并两个映射的运算

$$(F_2, b_2) \star (F_1, b_1) = (F_2 F_1,\ F_2 b_1 + b_2). \tag{8.42}$$

函数复合的结合性使式(8.42)满足结合律，单位元为 $(I, 0)$；它通常不满足交换律，不能打乱时间顺序。对前缀 $(F_t, b_t) \star \cdots \star (F_1, b_1)$ 做并行扫描，即可得到所有 h_t。由于选择参数由输入特征而非尚未求得的 h_{t-1} 生成，训练时可先并行计算各位置系数，再合并前缀；这与一般非线性 RNN 的顺序状态依赖不同。理想并行前缀算法具有 $O(\log T)$ 深度，但总工作量仍随 T 增长；实际硬件上的分块、访存和同步决定实际延迟，不能据此宣称运行时间只随 $\log T$ 增长。

从选择性 SSM 到 Mamba 模块。 原始 Mamba 模块中，输入先经线性投影分成内容分支与门控分支；内容分支经过短核因果深度卷积（每个通道分别沿时间使用短核）和 SiLU 激活 $\mathrm{SiLU}(a) = a\sigma(a)$，再进入选择性 SSM；扫描结果与门控分支的 SiLU 输出逐元素相乘，经输出投影后接入残差路径。短卷积负责局部混合，SSM 负责长历史压缩；流式部署须同时维护 SSM 状态和短卷积缓存，输出还要接任务头才能成为预测。

图8.9中信息自下向上传递：绿色投影形成两个分支，浅蓝色模块处理序列，圆圈表示激活或逐元素乘法。原图的 σ 在此处均指 SiLU，而非前文门控公式中的 sigmoid；堆叠时使用的归一化与外部残差连接没有画出。

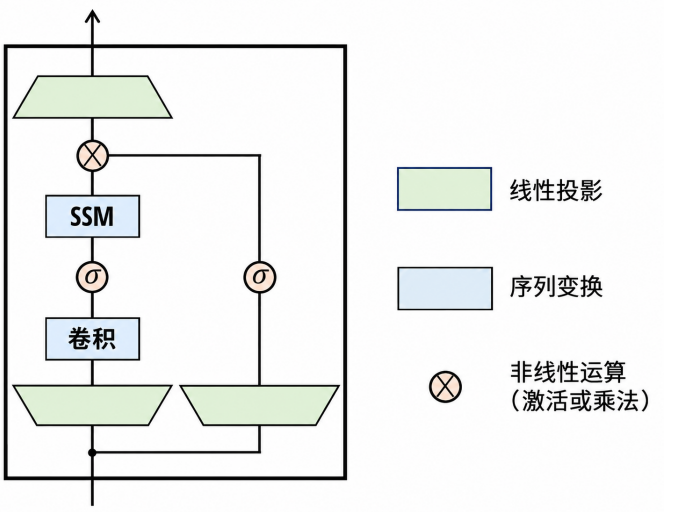


图 8.9: Mamba 模块[9]

与 Transformer 的计算和记忆取舍。 设层内通道数为 d，每通道状态维度为 m。对角转移下，选择性扫描部分的总工作量为 $O(Tdm)$，流式状态占用为 $O(dm)$，与已处理历史长度无关；通道投影另需 $O(Td^2)$，训练时也仍要存储或重算随序列长度增长的激活。标准全局注意力的交互计算为 $O(T^2d)$，自回归 KV 缓存随历史增长到 $O(Td)$。因此 Mamba 在长数据流与受限缓存下有结构性优势；Transformer 则能按当前查询重新访问具体历史位置，而压缩进有限状态的信息一旦丢失，Mamba 无法回读原记录。短序列、精确事件检索或缺少优化扫描内核时，不能预设 Mamba 更准确或更快。

工业实例：保留冲击还是保留工况。 沿用轴承案例，可将因果振动片段特征、当前温度、转速、负载、缺失掩码与实际时间间隔组成 x_t，经投影和局部卷积形成 ξ_t。稳定工况中，一部分状态维度可学习较慢衰减以积累磨

[9]来源：Gu 与 Dao，*Mamba: Linear-Time Sequence Modeling with Selective State Spaces*，2023，2024 年修订。

损趋势；负载切换时，选择机制可调整写入，避免把正常升温直接解释为退化；稀疏冲击是否进入长期记忆则由故障目标约束。这只是机制解释，不是已经观察到的实验结果，更不能把某个门值当作物理故障原因。比较 GRU、Transformer 与 Mamba 时，应固定设备划分、时间边界、预测提前量和参数预算，消融输入依赖的 Δ_t, B_t, C_t，检查收益来自选择机制还是局部卷积与额外容量；除轨迹误差外，还应报告短冲击召回、事件级误报、流式延迟和峰值显存。每台设备独立维护状态；跨设备拼接、长缺失后的恢复和模型更新必须按预定规则重置或预热，训练时也要模拟这些边界，式(8.41)中的长记忆才与上线时真正可用的历史一致。

8.6 把历史表示接到预测与异常任务

8.6.1 直接多步预测与递归预测

前面的模型都先形成表示，由输出头决定预测什么。直接多步预测用 $\hat{y}_{t+1:t+H} = W r_t + b$ 一次生成 H 个未来值，其中 $W \in \mathbb{R}^{H\times d}$、$r_t \in \mathbb{R}^d$。可用

$$\mathcal{L}_{\text{point}} = \frac{1}{NH}\sum_{n=1}^{N}\sum_{h=1}^{H}(\hat{y}_{t_n+h} - y_{t_n+h})^2 \tag{8.43}$$

训练，N 为训练窗口数，t_n 为第 n 个窗口终点。各提前量共享表示，但使用不同的投影行。平方损失对应条件均值估计：固定历史后，$\mathbb{E}[(Y-a)^2]$ 对 a 的导数为 $-2\mathbb{E}(Y-a)$，令其为零即得 $a = \mathbb{E}(Y)$，因此单凭点预测给不出区间。

递归预测每次只预测一步，再把预测值反馈给下一步。以标量温度为例，$\hat{y}_{t+1} = F_\theta(y_{t-T+1:t})$，第二步将窗口移为 $(y_{t-T+2}, \dots, y_t, \hat{y}_{t+1})$。训练时用真实历史作为递归输入称为教师强制（Teacher Forcing），部署时却要面对自己的预测误差，因此必须按实际部署的反馈方式评价多步结果。

为说明误差如何传播，暂设真实状态 $x_{t+1} = f_*(x_t) + \eta_{t+1}$，递归预测 $\hat{x}_{t+h} = f_\theta(\hat{x}_{t+h-1})$ 且 $\hat{x}_t = x_t$。在所考察区域假设 $\|f_\theta(a) - f_\theta(b)\| \le L\|a-b\|$、

$\|f_\theta(x) - f_*(x)\| \le \delta$、$\|\eta_t\| \le \epsilon$。插入并减去 $f_\theta(x_{t+h-1})$，得到

$$e_h = \|\hat{x}_{t+h} - x_{t+h}\| \le L e_{h-1} + \delta + \epsilon, \tag{8.44}$$

$$e_h \le (\delta + \epsilon) \sum_{j=0}^{h-1} L^j. \tag{8.45}$$

$L = 1$ 时上界随 h 线性增长，$L > 1$ 时可能更快放大，$L < 1$ 时此上界有界。这是有界噪声条件下的推导，高斯噪声不能直接套用统一确定性 ϵ。直接输出避免反馈自身误差，但仍受表示能力和未来不可预测性限制。

8.6.2 概率输出怎样表达未来的不确定性

若每个提前量输出 $0.1, 0.5, 0.9$ 三个分位数，未来两分钟的输出形状为 2×3。其中中位数描述条件分布的中间位置，上下分位数给出名义覆盖率为 80% 的区间。分位数损失（Pinball Loss）为

$$\ell_\tau(y, a) = \max\{\tau(y - a), (\tau - 1)(y - a)\}, \qquad 0 < \tau < 1. \tag{8.46}$$

y 为实际未来值，a 为对应分位数预测。取 $\tau = 0.9, y = 10$，预测 8 的损失为 1.8，预测 12 为 0.2，因此高分位数更重罚低估。

固定历史，令未来标量的条件分布函数为 F。在期望损失有限且 F 连续时，

$$R(a) = (1 - \tau) \int_{-\infty}^{a} (a - y)\, dF(y) + \tau \int_{a}^{\infty} (y - a)\, dF(y), \tag{8.47}$$

$$R'(a) = (1 - \tau)F(a) - \tau(1 - F(a)) = F(a) - \tau. \tag{8.48}$$

最优点满足 $F(a) = \tau$，有原子质量时以次梯度条件 $F(a^-) \le \tau \le F(a)$ 代替。训练后须逐提前量检查覆盖率和区间宽度，过宽的区间虽然容易覆盖，却可能没有使用价值；完整分布预测还可以用连续排序概率得分评价。独立分位数可能交叉，模型失配与漂移也会改变覆盖率。各时刻分别覆盖不等于整条轨迹同时覆盖。

未来故障概率使用另一种输出。令 $c_t \in \{0,1\}$ 表示 $(t, t+H]$ 内是否发生指定故障，输出 $p_t = \sigma(w^{\mathsf{T}} r_t + b)$，可用二元交叉熵 $-c_t \log p_t - (1-c_t)\log(1-p_t)$ 训练。它的标签是未来事件，不能用当前异常分数直接替代。概率输出仍需检查校准，少数故障事件不能仅用准确率评价。

8.6.3 异常评分：把新观测与正常模式比较

预测残差检测可预测模式的偏离。若预测头还输出正常数据的条件分布，则可用负对数似然评分。例如单通道正态预测 $\mathcal{N}(\mu_t, \sigma_t^2)$ 在读到 y_t 后给出

$$s_t^{\mathrm{NLL}} = \frac{(y_t - \mu_t)^2}{2\sigma_t^2} + \log \sigma_t + \tfrac{1}{2}\log(2\pi), \qquad \sigma_t > 0. \tag{8.49}$$

μ_t, σ_t 须在读到 y_t 之前生成，传感器单位保持固定。相同误差在正常波动小的工况下得分更高。方差估计失真也会改变异常排序，因此需要独立的正常和异常验证数据。

还可以训练窗口重构模型，把编码器表示经解码器还原为 $\tilde{X}_t$，以重构误差衡量偏离；它判断的是已经到达的窗口。若训练集中混入异常或模型容量过大，异常样本也可能被重构得很好，低重构误差不能保证正常。本章以预测残差为主要算例，所有异常分数都需要验证其与实际事件的关系。

8.6.4 时间边界与工业验证

滚动预测的完整设置。 设传感器每分钟采样一次，用过去 $T = 120$ 步预测未来 $H = 30$ 步。相邻窗口高度重叠，随机切分会把几乎相同的片段分到训练和测试两侧；应按时间块或设备划分，块之间留出间隔，同一故障事件不能同时出现在训练和测试中。评价时分别计算 $h = 1, 5, 15, 30$ 的误差，并报告故障前提前量、告警持续时间和每台设备每天的误报数，这些量直接决定维护工作量。

从预测到异常告警。 轨迹预测误差只有在真实观测到达后才能计算，不能用未来误差触发当前预警。设 $\hat{x}_{t|t-h}$ 及 $\hat{\sigma}_{t|t-h}$ 是在 $t-h$ 时刻对 t 的预测和标准差。对一个传感器通道，时刻 t 可计算的标准化残差为

$$s_t = \max_{1\le h\le H} \frac{|x_t - \hat{x}_{t|t-h}|}{\hat{\sigma}_{t|t-h} + \epsilon}. \tag{8.50}$$

其中 $\epsilon > 0$ 与标准差使用相同单位。取绝对值并对多个提前量取最大值后，不能直接套用标准正态阈值，应在验证集上定阈值；为避免瞬时噪声触发告警，还可以要求连续 m 个窗口超限，或在事件级别合并相邻告警。阈值和 m 只能在验证数据上根据漏报成本、误报预算和最小提前量确定；测试集只用于一次性报告，不能在看到故障时间后反复调整规则。

传感器掉线时，应用缺失掩码标明哪些值没有测到，而不是直接填零制造突变；若沿用上次读数，还应限制最多沿用多久。长时间缺失应触发数据质量告警，并按预定规则暂停判断或转人工处理，以免把通信故障误报成设备故障。

8.7 时序基础模型：先在大量序列上预训练

前面各节的模型都用本设备或同类设备的数据训练。时序基础模型先在大量公开序列和合成序列上预训练，再把新设备的历史窗口直接交给它，输出未来数值或分位数。不更新参数就对新序列作预测，称为零样本（zero-shot）预测；也可以再用本设备数据少量微调。零样本不等于不用数据，模型仍要从输入窗口读出这台设备的水平、趋势和周期。

8.7.1 把数值离散成词元：Chronos

Chronos 把序列值变成离散符号，直接沿用语言模型的结构和训练方法[10]。设历史窗口为 $x_1, \dots, x_C$，先用平均绝对值缩放（即图中的均值缩放），

[10] 来源：Ansari 等，*Chronos: Learning the Language of Time Series*，2024。

再把缩放后的值归入事先划好的箱：

$$s = \frac{1}{C}\sum_{i=1}^{C}|x_i|, \qquad \tilde{x}_i = \frac{x_i}{s}, \qquad z_i = q(\tilde{x}_i), \qquad \hat{x} = s\, c_z. \tag{8.51}$$

q 返回 $\tilde{x}_i$ 所在箱的编号，箱中心 $c_1 < \cdots < c_B$ 均匀分布在 $[-15, 15]$ 上，$\hat{x}$ 是还原后的数值。每个箱编号称为一个词元（token），词表共有 4096 个词元。缩放只除以 s 而不减去均值，零值仍映射为零。

模型主体是 T5 编码器–解码器，用交叉熵逐个预测未来词元，相当于用分类完成回归；交叉熵并不知道相邻箱的数值相近，这种远近关系只能从数据中学到。推理时逐个采样词元再还原为数值，重复采样得到多条未来轨迹，由它们估计各提前量的分位数。预训练语料包括多个领域的公开数据和合成序列，训练时的历史长度为 512。

手算一次缩放与量化。 设历史温度为 $(20, 21, 22, 21)$，则 $s = 21$，缩放后约为 $(0.952, 1, 1.048, 1)$。若箱中心相隔 0.05，0.952 归入中心为 0.95 的箱，乘回 s 后还原为 19.95；量化误差不超过半个箱宽乘以 s，即 0.525。实际模型约四千个箱覆盖 $[-15, 15]$，$s = 21$ 时原始单位下相邻箱约相隔 0.15。超过历史平均绝对值十五倍的未来值无法表示，强趋势序列因此受限；原始 Chronos 也只做单变量预测。图8.10依次画出缩放与量化、语言模型训练，以及推理时的采样与还原。

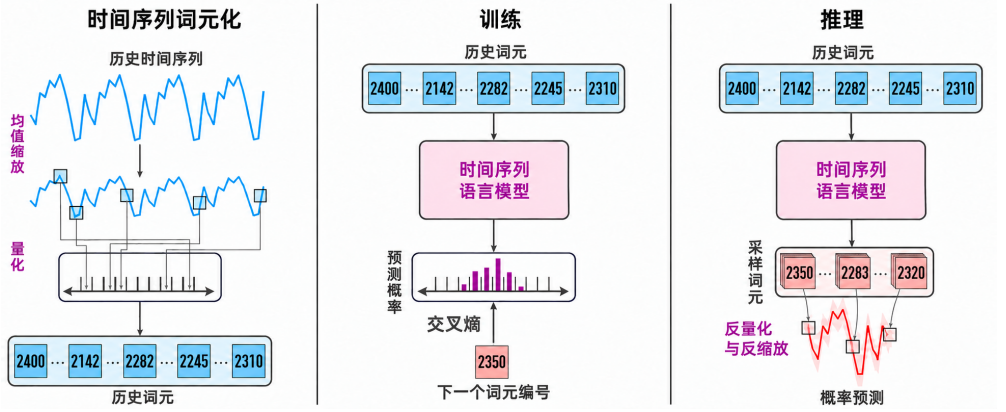


图 8.10: Chronos 预训练与推理流程[11]

8.7.2 片段解码、多变量与其他预训练目标

TimesFM 是只含解码器的 Transformer[12]：历史序列切成长度为 32 的输入片段，经因果注意力后，每个位置输出紧随其后的 128 个值；原始模型最多读取 512 个历史点。输出片段比输入片段长，是直接预测与递归预测的折中：预测 256 点只需解码两次；若输出也取 32 点，就要解码八次，其间七次把自己的预测当作输入，误差反馈更多。原论文的模型只输出点预测。

Moirai[13]把多变量序列展平成一条序列，用注意力偏置区分变量，输出几种分布的混合。Chronos-2[14]交替做时间注意力和组注意力，可以把一台设备的多个传感器，或目标序列与它的协变量（如本章开头的计划转速）放在同一组，输出 21 个分位数。MOMENT[15]以遮住部分片段再重建为预训练目标，重建误差可以直接作异常分数，对应第8.6.3节的窗口重构评分。

[11] 来源：Ansari 等，*Chronos: Learning the Language of Time Series*，2024。
[12] 来源：Das 等，*A decoder-only foundation model for time-series forecasting*，2024。
[13] 来源：Woo 等，*Unified Training of Universal Time Series Forecasting Transformers*，2024。
[14] 来源：Ansari 等，*Chronos-2: From Univariate to Universal Forecasting*，2025。
[15] 来源：Goswami 等，*MOMENT: A Family of Open Time-series Foundation Models*，2024。

8.7.3 零样本预测怎样接入设备监测

零样本省去的是训练，不是验证。按分钟采样时，512 点只覆盖约 8.5 小时，看不到日周期；重采样为 5 分钟可覆盖约 42.7 小时，但会削弱短时冲击。预训练语料可能已包含常用公开基准，零样本结论只能来自未参与预训练的数据；本设备数据仍按第8.6.4节划分时间块，并与持久性预测、在本设备数据上训练的模型和微调后的基础模型比较。用于异常检测时，若窗口内已有缓慢发展的退化，预测会随之漂移，残差反而较小；预测区间也不是设备正常范围的定义，告警阈值仍须在本设备的验证数据上确定。

8.8 回到设备监测：怎样验证历史表示有用

基线与消融。 持久性预测 $\hat{x}_{t+h} = x_t$ 是许多连续传感器任务的强基线，有周期的过程还应比较季节性复制。深度模型不能稳定超过这些基线时，应先检查窗口构造、目标定义和数据泄漏，而不是立即增加层数；消融实验可以依次去掉时间特征、缺失掩码、注意力或多步损失，判断性能来自结构还是额外的参数量。

时间间隔与特征的可用性。 不等间隔的事件序列应显式输入时间间隔 Δt，而不是把事件编号当作时间步。多个传感器之间存在同步采集、控制回路和滞后影响，注意力权重或相关性都不能直接解释为因果关系，因为共同工况变量会同时改变多个通道。若预测目标是控制动作，还应区分可用的外生变量、动作之后才产生的变量和部署时不可获得的维修记录；每个特征在预测时刻是否已经可得，应按时间戳审计。

概率预测的评价。 评价概率预测时既要检查尖锐性，也要检查校准：过宽的预测分布可能轻易覆盖真实值，却没有调度价值。对多步预测，应分别评估每个提前量，并观察区间是否随着预测跨度合理变宽；若预测分布出现不合理的收缩，通常意味着模型忽略了过程噪声或训练目标过度追求

均值误差。

以下材料分别对应递归状态、注意力和选择性状态空间，可在完成相关算例后阅读。

辅助学习材料

- **CS224N: Natural Language Processing with Deep Learning**；作者/平台：Stanford University；英文；课程讲义与视频。重点看 self-attention 与 Transformers。课程主页。
- **NLP From Scratch: Classifying Names with a Character-Level RNN**；作者/平台：Sean Robertson / PyTorch；英文；代码教程。观察隐藏状态如何逐字符更新。在线阅读。
- **The Illustrated Transformer**；作者/平台：Jay Alammar / 作者博客；英文；图解教程。对照查询、键、值与多头注意力。在线阅读。
- **A Visual Guide to Mamba and State Space Models**；作者/平台：Maarten Grootendorst / 作者博客；英文；图解教程。配合第8.5.2节阅读。在线阅读。
- **Mamba**；作者/平台：state-spaces / GitHub 官方项目文档；英文；实现与使用说明。部署前核对接口与加速内核要求。使用文档。

本章小结。 序列建模先确定截至当前可取得的观测，再选择历史表示方法：RNN 逐步更新状态，LSTM 与 GRU 用门控控制保留和写入，TCN 用因果空洞卷积组合固定感受野，Transformer 按查询重新读取历史，PatchTST 与 iTransformer 分别以片段和变量为读取单位，Mamba 让输入控制状态更新并支持并行扫描。没有一种结构对所有任务都更合适。

表示之后，未来轨迹使用数值或分位数头，未来故障使用事件概率头，当前异常则比较已到达的观测与正常模式。概率状态滤波、确定性隐状态

和概率预测头具有不同含义。多步预测要按实际反馈策略评价，异常告警要按观测到达时间计算。时序基础模型可以零样本给出预测和区间，但仍要在本设备数据上按同样的边界和指标验证。

振动曲线可以提示设备发生了变化，但通常不能指出表面裂纹在哪里。下一章转向图像，用卷积、区域匹配和像素分割寻找缺陷位置。

第九章　视觉模型

本章摘要。本章围绕图像中的缺陷识别展开：图像分类判断是否存在缺陷，目标检测给出缺陷的位置，图像分割描出缺陷的边界。先以卷积网络和 ResNet 解释如何从像素形成类别判断，再以 ViT 解释图像区域之间的注意力交互，并说明分类正确为何不等于局部特征对齐。随后以 Faster R-CNN 和 U-Net 分别讲解框级定位与像素级预测，并由它们的局限引出单阶段检测、多尺度特征和实例分割。缺陷样本稀少时，再用 DINOv2 系列的冻结图像块特征与少量正常样本逐块比较，做少样本异常检测。每个模型都沿输入、计算、输出和训练目标展开，最后回到细小缺陷、标注不足与跨相机验证这些典型问题。

风险预警告诉维护人员何时需要关注设备，却不能指出缺陷位于哪里。本章转向巡检图像和表面质检，所用的图像级、框级或像素级标签都与未来故障标签不同；拆检后才能获得的照片可以支持离线诊断，却不能直接作为拆检前预警的输入。同样一组深浅像素，排列成细长的连续区域时可能表示裂纹，散布在表面时却可能只是纹理；模型既要识别这些空间关系，也要按任务要求保留位置。本章始终以表面质检为例，逐步回答三个问题：图中有没有裂纹，裂纹在哪里，哪些像素属于裂纹。

9.1　先确定任务：类别、位置还是边界

图像分类为整幅图给出类别，例如“正常”“裂纹”“划痕”，模型输出各类得分或概率。若裂纹与划痕可以同时出现，就需要为各类别分别标注是否存在，并使用多标签输出。分类适合工件筛查，但类别概率不能直接提供裂纹坐标。

目标检测为图中每个目标输出类别和矩形框，适合寻找多个缺陷、统

计数量和指引复检位置。图像分割为每个像素给出标签，适合描述不规则边界和计算缺陷面积；语义分割只区分像素类别，实例分割还区分不同目标，同类的两条裂纹需要不同的实例编号。像素长度和面积要换算为物理尺寸，还需要相机标定或已知尺度。

三类任务分别需要图像级标签、框标注和像素标注，标签粒度决定了能直接训练什么输出：只有“有无裂纹”的标签时，不能直接计算逐像素分割损失。缺陷样本少到难以训练这些任务时，还可以只用少量正常样本建立参照，把偏离参照的位置报为异常，见第9.6节。

这些任务通常共享一个提取图像特征的网络主体，称为**骨干网络**；骨干之后的**任务头**将特征转成类别、框或掩码。卷积神经网络（Convolutional Neural Network，CNN）与视觉 Transformer（Vision Transformer，ViT）是两种常用的视觉骨干。下面先通过分类走通从像素到预测的过程，再解释定位任务为何需要改变这个过程。图9.1中，分类可以汇总位置，检测与分

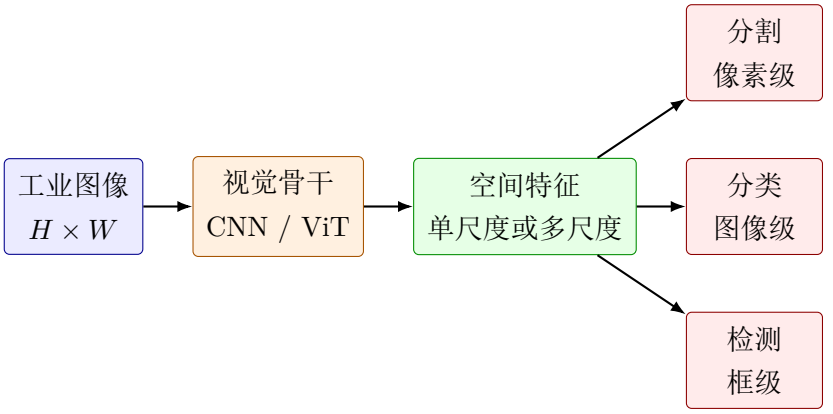


图 9.1：视觉系统先由卷积或 Transformer 骨干提取表示，再按标签粒度输出分类、检测或分割结果。

割则要继续使用空间对应关系；原始 ViT 通常只输出单一尺度的图像块表示。

9.2 图像分类：从局部卷积到 ResNet

9.2.1 卷积如何从像素中提取特征

设彩色图像为 $X \in \mathbb{R}^{H\times W\times C_{\text{in}}}$，其中 H, W 为像素高度和宽度，$C_{\text{in}}=3$ 时三个输入通道分别表示红、绿、蓝；隐藏层的通道表示学习到的特征，不再对应颜色。张量可以理解成带多个索引的数表，本章采用高、宽、通道的轴顺序。

若把图像直接展平后送入全连接层，每个位置都拥有独立权重，却没有利用“同一种局部形状可能出现在不同位置”这一规律。卷积用一个小窗口读取局部像素，并在整幅图上重复使用同一组权重。不同卷积核响应不同的局部变化，训练决定哪些响应对识别缺陷有用。

一个窗口怎样变成一个输出。 取单通道窗口 $\left[\begin{smallmatrix}1&2\\3&4\end{smallmatrix}\right]$ 与核 $\left[\begin{smallmatrix}1&0\\0&-1\end{smallmatrix}\right]$，偏置为零，则对应输出为 $1\times1+2\times0+3\times0-4\times1=-3$。核移到右边后仍使用这四个权重，只更换被读取的像素。若随后使用整流线性单元（Rectified Linear Unit，ReLU），即 $\max(0,z)$，这一响应变为零。实际的核权重由训练学到，示例核只用于理解计算。

步幅是相邻窗口起点移动的像素数，填充是在图像边缘补值，空洞率是核内相邻采样点的间隔。例如 $5\times5\times3$ 输入经过 3×3 核、步幅一、无填充、四个输出通道，得到 $3\times3\times4$，含 $3\times3\times3\times4+4=112$ 个参数。每个输出通道都汇总三个输入通道，并不是分别对红绿蓝得到三个互不交流的答案。

卷积的索引、参数与等变性。 设输入 $X\in\mathbb{R}^{H\times W\times C_{\text{in}}}$，方形核大小 k，输出通道数 C_{out}，步幅 s、填充 p、空洞率 d_a。采用从零开始的空间索引，有

$$Z_{i,j,c}=b_c+\sum_{u,v=0}^{k-1}\sum_{a=1}^{C_{\text{in}}}K_{u,v,a,c}X_{si-p+d_au,\,sj-p+d_av,\,a}, \tag{9.1}$$

越界输入按指定规则填充。这个深度学习中惯称的卷积实际采用互相关索引；若使用数学卷积，只需翻转核。沿高度方向，为使最下端采样不超过填充后的输入，需满足 $si + d_a(k-1) \le H + 2p - 1$，因此

$$H_{\text{out}} = \left\lfloor \frac{H + 2p - d_a(k-1) - 1}{s} \right\rfloor + 1, \tag{9.2}$$

宽度同理。参数量为 $k^2 C_{\text{in}} C_{\text{out}} + C_{\text{out}}$，与图像面积无关；不共享的局部连接则须为每个输出位置另存一组权重。

在无限网格或忽略边界、$s = 1$ 时，令 $(T_\delta X)_{i,j} = X_{i-\delta_1, j-\delta_2}$，直接代入求和式得 $K * (T_\delta X) = T_\delta (K * X)$。这就是平移等变性，而不是平移后输出保持不变。步幅 $s > 1$ 时通常仅保留对 s 整数倍平移的对应关系，边界填充还会引入额外差异。图像分类可以通过汇聚追求不变性，定位任务却应保留位置随输入一起移动的关系。

9.2.2 多层卷积如何形成整幅图的判断

单个小窗口只能看到裂纹的一部分。把卷积与非线性激活连续堆叠后，后层可以组合前层的局部响应，例如把多个方向一致的边缘组合为较长的结构。网络常用步幅大于一的卷积或池化降低空间分辨率，这个过程称为下采样；它减少计算量，也可能让细裂纹与背景混在一起。

一个深层位置在输入中能够访问的范围称为**理论感受野**。令 r_l 表示第 l 层的感受野宽度，j_l 表示该层相邻位置在原图中的间隔。以 $r_0 = j_0 = 1$ 开始，对于核大小 k_l、步幅 s_l 且不使用空洞采样的层，有

$$r_l = r_{l-1} + (k_l - 1) j_{l-1}, \qquad j_l = s_l j_{l-1}. \tag{9.3}$$

新增的 $k_l - 1$ 个间隔，每个跨越 j_{l-1} 个输入像素。三层 3×3 卷积的步幅依次为 $1, 2, 1$ 时，(r_l, j_l) 依次为 $(3,1), (5,2), (9,2)$。第三层每个内点理论上访问九像素宽的区域，相邻输出却只相隔两像素。这个范围不表示每个像素贡献相同，边界处还可能读到填充值。

设最后一层特征为 $F \in \mathbb{R}^{H' \times W' \times D}$，其中 D 为通道数。分类可以先对每个通道作全局平均，再进行线性分类：

$$v_c = \frac{1}{H'W'} \sum_{i=1}^{H'} \sum_{j=1}^{W'} F_{i,j,c}, \qquad z = Uv + b, \qquad p_k = \frac{e^{z_k}}{\sum_{a=1}^{K} e^{z_a}}. \tag{9.4}$$

这里 K 为互斥类别数，$v \in \mathbb{R}^D$ 为整图表示，$U \in \mathbb{R}^{K \times D}$ 与 $b \in \mathbb{R}^K$ 为分类头参数，z_k 是类别 k 的实数得分，p_k 是模型给出的类别概率。若真实类别为 y，单幅图的交叉熵损失为 $-\log p_y = -z_y + \log \sum_{a=1}^{K} e^{z_a}$，对各得分求导得

$$\frac{\partial(-\log p_y)}{\partial z_k} = p_k - \mathbf{1}_{k=y}.$$

例如三类概率为 $(0.7, 0.2, 0.1)$ 而真实类别为第二类时，梯度为 $(0.7, -0.8, 0.1)$：沿负梯度方向更新会增大真实类别的得分，并按各自概率减小其余类别的得分。这一梯度再经反向传播调整分类头和卷积核，使特征对区分类别有用。

全局平均把各位置汇总为一个向量，适合回答“有没有裂纹”，却舍弃了直接读取位置的接口；检测与分割必须在汇总之前保留空间特征。

9.2.3 ResNet：网络加深以后怎样训练

增加层数能让模型组合更大范围的局部信息，但普通深层网络可能比浅层网络具有更高的训练误差。连训练集都拟合得更差，就不能只用过拟合解释：更长的连续变换使优化更困难，深层网络也不容易自行学出“保持已有表示不变”的操作。

残差网络（Residual Network，ResNet）将一个块的输出写为[1]

$$h_{l+1} = h_l + F_l(h_l). \tag{9.5}$$

h_l 是输入特征，F_l 是由卷积、归一化和激活组成的残差分支。这里先省略相加后的激活，以分析加法节点的梯度；原始 ResNet 在相加后还施加 ReLU，

[1] 来源：He 等，*Deep Residual Learning for Image Recognition*，2016。

完整块的导数还须乘入该激活的导数。若期望映射为 $H(h_l)$，残差分支要学习的就是差值 $H(h_l)-h_l$；已有表示已经合用时，分支输出接近零即可在加法节点保留输入。图9.2展示了分支与捷径如何在同一位置相加。

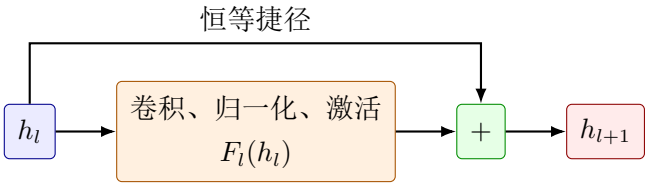


图 9.2: 同尺寸残差块的计算路径。捷径传递输入，分支学习修正量，二者逐元素相加。图中省略了具体实现可能在相加后使用的激活。

残差梯度不再只有单一路径。 设各层 $h_l \in \mathbb{R}^d$，且残差分支 $F_l : \mathbb{R}^d \to \mathbb{R}^d$ 可微。令 $J_l = \partial F_l / \partial h_l^{\mathsf{T}}$，则

$$\frac{\partial h_{l+1}}{\partial h_l^{\mathsf{T}}} = I + J_l, \tag{9.6}$$

$$\nabla_{h_l}\mathcal{L} = (I + J_l)^{\mathsf{T}} \nabla_{h_{l+1}}\mathcal{L}. \tag{9.7}$$

连续两个块的前向 Jacobian 为 $(I+J_{l+1})(I+J_l) = I + J_l + J_{l+1} + J_{l+1}J_l$，包含不经过任何残差分支的恒等项、经过一个分支的项和经过两个分支的项。相比普通网络只有 $J_{l+1}J_l$，残差结构允许梯度走较短路径。以标量为例：设每个分支的导数都是 0.1，普通网络把 10 层的导数连乘得 $0.1^{10} = 10^{-10}$，残差网络每层导数为 $1+0.1$，连乘约为 2.6，梯度量级不随层数增加而迅速衰减。若 $\|J_l\|_2 \le \epsilon < 1$，则对任意向量 v 有

$$(1-\epsilon)\|v\|_2 \le \|(I+J_l)v\|_2 \le (1+\epsilon)\|v\|_2. \tag{9.8}$$

小残差分支使单块接近恒等，但多块的上下界仍相乘，所以残差不是绝不消失或爆炸的定理。改变通道或空间尺寸时，要把捷径替换为投影 $S_l h_l$，导数变为 $S_l + J_l$，此时也不再有字面上的恒等路径。

相加要求尺寸一致。 若残差输入和分支输出都是 $8 \times 8 \times 16$，逐元素相加后仍是 $8 \times 8 \times 16$。若残差分支改变空间尺寸或通道数，捷径也要用步幅卷积等投影变换得到相同尺寸。后文 U-Net 将使用通道拼接，同样两组特征拼接后为 $8 \times 8 \times 32$，两种连接的输出维度和计算含义不同。

9.2.4 从基本块到瓶颈块与轻量卷积

ResNet-18 和 ResNet-34 主要使用由两个 3×3 卷积构成的基本残差块。ResNet-50 等更深的版本使用瓶颈块：先以 1×1 卷积减少通道，在较窄的表示上做 3×3 卷积，再以 1×1 卷积恢复通道。1×1 卷积只混合同一位置的不同通道，瓶颈设计把较昂贵的空间卷积放在较少通道上，使加深网络的计算代价更可控。

图9.3左侧基本块维持 64 通道，右侧瓶颈块先将 256 通道压到 64，再恢复为 256。方框内依次标出核大小与输出通道数，弧线是恒等捷径。两种块均在相加后施加 ReLU，属于原始版本；该图没有单列卷积配套的批归一化。

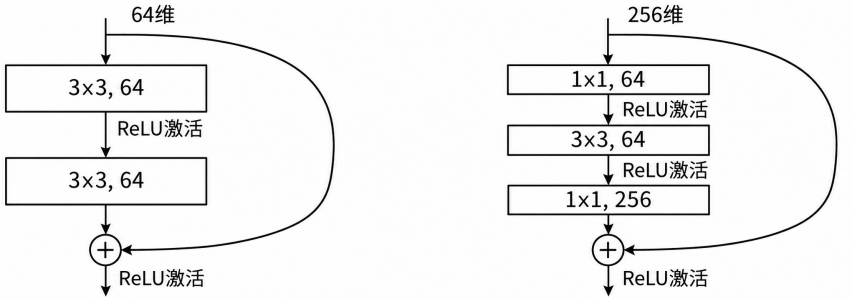


图 9.3: ResNet 残差块[2]

若相机侧计算资源更紧，MobileNet 一类轻量网络使用深度可分离卷积：先逐通道做空间卷积，再用 1×1 卷积混合通道。忽略偏置，标准卷积每个位置约需 $k^2 C_{\text{in}} C_{\text{out}}$ 次乘加，拆分后为 $k^2 C_{\text{in}} + C_{\text{in}} C_{\text{out}}$，二者比值为 $1/C_{\text{out}} + 1/k^2$；$k = 3$、$C_{\text{out}} = 64$ 时约为 0.13，乘加数降到约八分之一。节

[2]来源：He 等，*Deep Residual Learning for Image Recognition*，2016。

省来自对空间与通道混合方式的限制，表达能力也随之改变，实际延迟还要在目标设备上测量。

这些设计都没有取消局部卷积的约束。若判断一个局部缺陷必须参考远处的部件，能否让区域之间直接交换信息？

9.3 ViT：用注意力联系不同图像区域

9.3.1 从图像块到类别预测

卷积通过逐层组合扩大观察范围。视觉 Transformer 将图像划分为一组图像块（patch），把每个块编码为一个向量单元（token，下文称标记），再通过自注意力更新这些向量[3]。它仍可用于整图分类，改变的是骨干内部组织空间信息的方法。

设输入为 $H \times W \times C$，每块大小为 $P \times P$，且 H, W 均可被 P 整除。共有 $N = HW/P^2$ 个块。第 i 块展平为列向量 $x_i \in \mathbb{R}^{P^2C}$，线性投影为

$$z_i = Ex_i + e_i^{\text{pos}}, \qquad E \in \mathbb{R}^{d \times P^2C}. \tag{9.9}$$

$z_i \in \mathbb{R}^d$ 为块表示，$e_i^{\text{pos}} \in \mathbb{R}^d$ 为位置嵌入。投影权重在各块之间共享，位置嵌入标明块来自哪里；没有位置信息时，普通自注意力本身不区分相同图像块在网格中的排列。

一幅 $32 \times 32 \times 3$ 图像按 8×8 划块，得到 16 个块，每块包含 192 个数。投影到 $d = 64$ 后，按行放置这些向量得到 $Z \in \mathbb{R}^{16 \times 64}$。对单头注意力，令 $W_Q, W_K, W_V \in \mathbb{R}^{64 \times 64}$，计算

$$Q = ZW_Q, \quad K = ZW_K, \quad V = ZW_V, \qquad A = \operatorname{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{64}}\right), \quad O = AV. \tag{9.10}$$

Q, K, V 分别称为查询、键和值，$A \in \mathbb{R}^{16 \times 16}$ 沿每一行归一化。A_{ij} 决定更新第 i 块时读取第 j 块值向量的权重，输出 O 仍为 16×64。每个块因此

[3] 来源：Dosovitskiy 等，*An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*，2021。

可以在同一层读取任意其他块的信息；权重由当前表示计算，不等于人工给定的空间邻接关系。

原始 ViT 在块序列前加入一个可学习的分类标记，此时本例共有 17 个位置。经过多层带残差连接的注意力与逐位置前馈网络后，取分类标记的最终表示送入分类头，用图像标签计算交叉熵；也可以改用块表示的平均值作分类。用于检测或分割时，则要保留图像块与原网格的对应关系，另外设计空间输出头。

图9.4中 0∗ 是额外学习的分类标记，不由图像块投影得到；其余标记由图像块投影并加入位置嵌入形成。右侧是重复堆叠的前置归一化编码块，分类头读取分类标记的最终表示。图中只画出九个图像块，与前述十六块算例的数量不同，计算规则一致。

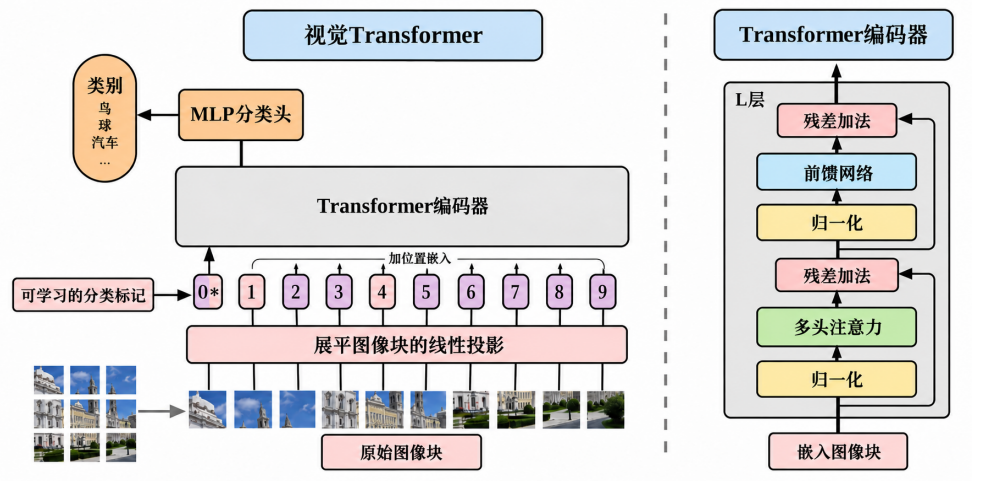


图 9.4: ViT 分类结构[4]

[4]来源：Dosovitskiy 等，*An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*，2021。

9.3.2 空间特征为何会出现伪影：从 Register 到惰性聚合

图像级分类监督只要求分类标记给出整图类别，并不直接约束每个图像块都保留准确的局部语义。在一些视觉 Transformer 中，低信息背景区域会出现范数很大的异常标记，在中间层承担存储或传递全局信息的作用。Registers 论文在输入序列中加入额外的可学习标记，给这种内部计算提供专门位置，输出时丢弃它们，只保留分类标记和图像块表示[5]。可将输入写成

$$Z_{\text{in}} = [z_{\text{CLS}}, z_1, \ldots, z_N, r_1, \ldots, r_R]^{\top} \in \mathbb{R}^{(1+N+R)\times d}, \tag{9.11}$$

其中每一行对应一个标记，R 为寄存标记数。寄存标记不对应原图上的固定位置，在训练中与模型共同学习。图9.5中蓝色为图像块标记、黑色为分类标记、黄色为寄存标记，顶部两个括号分别标出保留和丢弃的输出；图中寄存标记的编号沿用原论文写到 N，对应式(9.11)中的 R 个寄存标记。

后续研究认为，减少高范数标记并不必然消除空间语义错位：全局注意力和粗粒度的图像级监督可能使背景图像块成为表达全局语义的捷径，导致分类正确而局部特征与目标位置对齐较差[6]。工业质检因此要用缺陷框、掩码等定位指标检查，注意力图只能提供诊断线索。

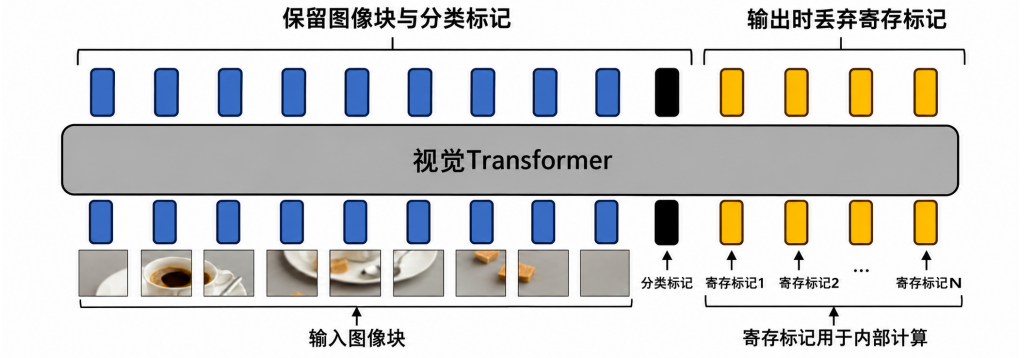


图 9.5： ViT 的寄存标记[7]

[5]来源：Darcet 等，*Vision Transformers Need Registers*，2024。

[6]来源：Shi 等，*Vision Transformers Need More Than Registers*，2026。

[7]来源：Darcet 等，*Vision Transformers Need Registers*，2024。

9.3.3 为什么引入窗口注意力与层级表示

全局注意力显式形成 $N \times N$ 的得分矩阵，主要交互计算量为 $O(N^2 d)$。若高、宽都加倍而块大小不变，块数增加到四倍，注意力得分数量增加到十六倍。细缺陷需要较高分辨率，全局交互的成本因此成为直接限制。

Swin Transformer 将注意力限制在局部窗口内，并在相邻层之间移动窗口划分：前一层位于窗口边缘的两个块，下一层可以进入同一窗口，跨窗口信息由此逐层传递。若每个窗口含 $M \times M$ 个单元且可整分，则有 N/M^2 个窗口，交互计算量为

$$O\left(\frac{N}{M^2}(M^2)^2 d\right) = O(NM^2 d). \tag{9.12}$$

固定 M 时，这部分成本随 N 线性增加，代价是单层只能读取窗口内信息。Swin 还逐级合并相邻单元，得到不同空间尺度的特征，供检测与分割使用；合并降低成本，也可能损失局部细节。

图9.6用红框标出局部注意力窗口，灰色小格表示图像块。第 $l+1$ 层改变窗口边界，使原先分属两个窗口的块能够在新窗口内交互；移动的是分组边界，不是把图像内容平移。

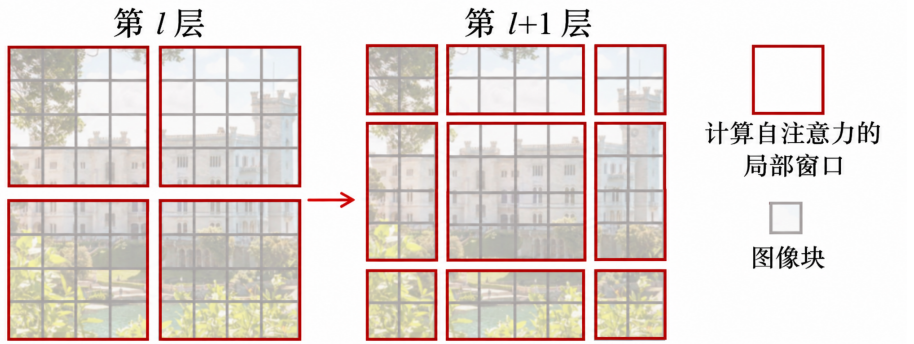


图 9.6: Swin 窗口注意力[8]

[8]来源：Liu 等，*Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*，2021。

卷积把局部性和权重共享直接写入结构；原始 ViT 的这类约束较弱，通常更依赖预训练规模和训练策略，实际比较应控制输入分辨率、预训练数据和微调预算。无论哪种骨干，输入缩放或块投影已经丢失的信息都不能被自动补回。块投影在 $d < P^2C$ 时不可能保留所有输入变化，但这不意味着小于块的缺陷一定不可见，结果取决于投影保留了什么以及标签要求模型识别什么。

9.4 目标检测：以 Faster R-CNN 解释框级定位

9.4.1 为什么先提议区域，再分类和修正位置

分类器每图输出一组类别概率，检测器却需要输出数量不固定的一组目标：一张图可能没有缺陷，也可能有多条裂纹。若把分类器在所有可能的矩形上重复运行，不仅计算量大，相邻矩形还会反复读取相同像素。

Faster R-CNN 沿用区域卷积神经网络（Region-based Convolutional Neural Network，R-CNN）的区域识别思路，把主要计算集中在共享骨干中，分两阶段工作：区域提议网络（Region Proposal Network，RPN）在共享特征上为预置参考框预测“目标还是背景”以及坐标偏移，筛选出候选区域；第二阶段对候选区域提取固定大小的特征，输出具体类别和进一步修正的框。候选区域也可能只包含背景，因此第二阶段仍需背景类。

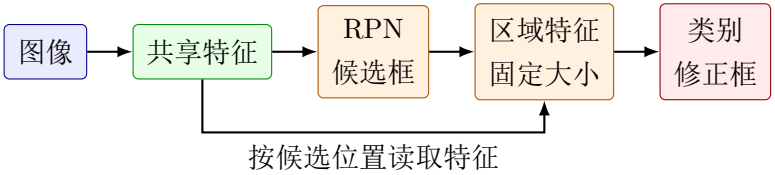


图 9.7: Faster R-CNN 的两阶段计算。区域提议给出在哪里读取，共享特征提供读取内容，第二阶段进行区域分类与框修正。

图9.7中的区域特征来自整图共享特征，不必为每个候选重新运行骨干。

原始 Faster R-CNN 用感兴趣区域（Region of Interest，RoI）池化把大小不同的区域转成固定大小的特征，其坐标量化会影响精细对齐，后文 Mask R-CNN 的 RoIAlign 用插值采样减轻这一问题。

9.4.2 框怎样匹配标签并参与训练

锚框（anchor）是在特征位置预置的参考矩形，不是真实标注。若一幅图有 100 个候选、两类缺陷，含背景类的简化检测头输出 100×3 的类别得分和 100×4 的类别无关框偏移。训练先把候选与标注匹配，得到“这是背景还是哪类缺陷”及正样本的坐标目标，再计算损失；不同检测器的输出格式可能不同。

图9.8展开 RPN 在一个特征位置的计算：滑动窗口形成中间表示，两个分支分别输出 k 个锚框的 $2k$ 个目标 / 背景得分与 $4k$ 个框回归量；右侧矩形是不同尺度和宽高比的锚框，并非筛选后的检测结果。图中的 256 维对应原论文 ZF 骨干，采用 VGG 时中间表示为 512 维。

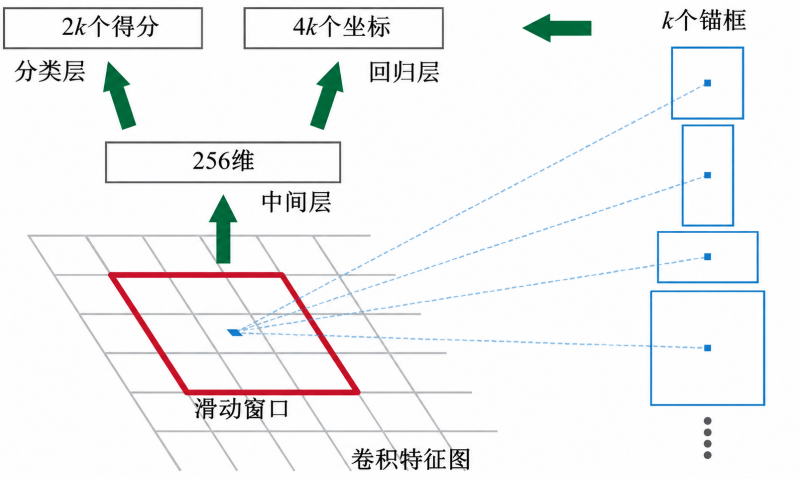


图 9.8： RPN 区域提议[9]

[9]来源：Ren 等，*Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*，2015。

参考框或候选框与真实标注匹配时，常用的几何依据是交并比（Intersection over Union，IoU）。两个框 A, B 的交并比为

$$\mathrm{IoU}(A,B)=\frac{|A\cap B|}{|A\cup B|}. \tag{9.13}$$

这里 $|\cdot|$ 表示面积，IoU 取值为 $[0,1]$。匹配到目标的候选是正样本，背景候选是负样本，阈值之间的候选还可以按协议忽略。RPN 的类别目标是目标或背景，第二阶段则区分具体缺陷类别。下面用第二阶段的简化目标解释分类与定位如何一起学习，完整训练还包括 RPN 的提议损失。

从几何框到可训练的回归目标。 设参考框中心及宽高为 (a_x,a_y,a_w,a_h)，真实框为 (g_x,g_y,g_w,g_h)，宽高均严格为正且使用同一像素坐标系。相同相对位置误差在大框中对应更大的像素位移。为减小回归目标对框尺寸的依赖，定义无量纲目标

$$t_x^*=\frac{g_x-a_x}{a_w},\quad t_y^*=\frac{g_y-a_y}{a_h},\quad t_w^*=\log\frac{g_w}{a_w},\quad t_h^*=\log\frac{g_h}{a_h}. \tag{9.14}$$

网络输出 $t\in\mathbb{R}^4$ 后，以 $b_x=a_x+a_wt_x, b_y=a_y+a_ht_y, b_w=a_we^{t_w}, b_h=a_he^{t_h}$ 解码。中心相对化降低尺度依赖，对数宽高保证解码尺寸为正；但 $\partial b_w/\partial t_w=b_w$，极端输出仍可能带来不稳定。

对匹配到真实框的正样本，常用残差 $e=t-t^*$ 的分段损失

$$\rho_\beta(e)=\begin{cases}e^2/(2\beta), & |e|<\beta,\\ |e|-\beta/2, & |e|\ge\beta,\end{cases}\qquad \beta>0. \tag{9.15}$$

在接点 $e=\pm\beta$，两段函数值均为 $\beta/2$，两侧导数也分别相等，所以此处分段不妨碍一阶求导。其导数在小误差处为 e/β，大误差处为 $\mathrm{sign}(e)$，兼顾局部平滑与异常残差的有界影响。完整损失可写为

$$\mathcal{L}=\frac{1}{N_{\mathrm{cls}}}\sum_i \ell_{\mathrm{cls}}(p_i,y_i)+\frac{\lambda}{\max(1,N_+)}\sum_{i:y_i>0}\sum_{j\in\{x,y,w,h\}}\rho_\beta(t_{ij}-t_{ij}^*). \tag{9.16}$$

这里 p_i 是候选 i 的类别概率向量，$y_i = 0$ 表示背景、$y_i > 0$ 表示缺陷类别；$N_{\text{cls}} > 0$ 为参与分类计分的候选数，N_+ 为正样本数，$\lambda \geq 0$ 控制定位项权重。背景样本没有真实框回归目标；分类与定位的归一化方式必须报告，否则相同 λ 可能代表不同梯度比例。

IoU 直接比较几何重叠。设两个边长为 a 的正方形仅水平错位 $\delta \in [0, a)$，则交集为 $a(a-\delta)$，并集为 $a(a+\delta)$，所以 $\text{IoU} = (a-\delta)/(a+\delta)$，在 $\delta = 0$ 右侧的导数为 $-2/a$。这说明同样一个像素的偏移对小框更加苛刻。不相交框的普通 IoU 为零，在保持不相交的区域内不给出靠近方向，因此实际定位还会结合参数回归或加入外接框、中心距离等项。

9.4.3 推理怎样得到数量不固定的检测结果

推理时没有真实框可以匹配。模型先根据参考框解码预测偏移，再按类别分数筛掉低分框。多个候选可能指向同一条裂纹，因此还需要消除重复结果。非极大值抑制（Non-Maximum Suppression，NMS）通常逐类进行：先保留最高分框，再删除与它的 IoU 超过阈值的其他框，对剩余候选重复这一过程。例如三个裂纹框的得分为 $0.9, 0.8, 0.6$，后两个框与第一个框的 IoU 分别为 0.7 和 0.1；阈值取 0.5 时，保留 0.9 的框、删去 0.8 的框，0.6 的框与它几乎不重叠，得以保留。最终框数由图像和阈值共同决定；两个紧邻的真实缺陷也可能互相抑制。

检测评价同样需要空间匹配。先按置信度排序，同类预测框在给定 IoU 阈值下与真实框一对一匹配，未匹配预测计为误报，未匹配真实框计为漏检。平均精度（Average Precision，AP）汇总精确率与召回率的关系，平均精度均值（mean Average Precision，mAP）再按指定类别或 IoU 阈值取平均；不同协议的 mAP 不能直接比较。小框对偏移敏感，应另外报告不同缺陷尺寸下的召回。

9.4.4 从两阶段到单阶段：省去逐候选识别

YOLO（You Only Look Once）代表的单阶段检测直接从整图特征的多个位置预测类别与坐标，不再为每个候选运行第二阶段识别头，适合吞吐量要求高的任务。早期 YOLO 由网格单元预测框、目标置信度和类别，密集目标和尺度变化较难处理；后续版本改进了多尺度输出与预测头，有的使用锚框，有的不用，使用时应按具体版本核对输出和正样本分配。

单阶段检测会面对大量背景位置。许多背景已经容易识别，却仍可能在总损失中占据较大比例。RetinaNet 用焦点损失（focal loss）降低易样本权重：

$$\mathcal{L}_{\text{focal}} = -\alpha_t (1 - p_t)^{\gamma} \log p_t. \tag{9.17}$$

二分类时，p_t 是对真实标签的预测概率，即正样本取 p，负样本取 $1-p$。α_t 为类别权重，$\gamma \geq 0$ 控制降权强度。例如 $\gamma = 2$ 时，$p_t = 0.99$ 的易样本权重为 0.0001，$p_t = 0.5$ 的样本权重为 0.25。这改变了不同难度样本对训练的相对影响，标注错误也可能因此获得较大权重。

焦点损失怎样改变梯度。 对正类样本设 logit 为 z、$p = \sigma(z)$，则 $\ell = -\alpha(1-p)^{\gamma}\log p$。不能只把交叉熵梯度乘以 $(1-p)^{\gamma}$，因为这个权重本身依赖参数。乘积法则给出

$$\frac{d\ell}{dz} = \alpha\gamma p(1-p)^{\gamma}\log p - \alpha(1-p)^{\gamma+1}. \tag{9.18}$$

令 $p = 1-\varepsilon$ 并利用 $\log(1-\varepsilon) \approx -\varepsilon$，得梯度约为 $-\alpha(\gamma+1)\varepsilon^{\gamma+1}$；普通交叉熵则约为 $-\alpha\varepsilon$。所以易样本梯度以更高阶衰减，困难样本占据更大的相对权重。但标注错误往往也是困难样本，焦点损失不具备自动甄别错误标签的能力，也不能保证输出概率仍然校准。

9.4.5 FPN：让不同大小的缺陷使用不同尺度的特征

小裂纹需要较密的空间采样，大范围表面损伤则需要较广的上下文；只在最深层特征上检测，可能已经失去小缺陷的位置。特征金字塔网络（Fea-

ture Pyramid Network，FPN）在骨干不同层的特征之间建立自顶向下的信息路径。

设骨干特征 C_l 的分辨率随层级 l 增加而降低。先用 1×1 卷积 L_l 统一通道数，再从最高层开始融合：

$$\widetilde{P}_L = L_L(C_L), \qquad \widetilde{P}_l = L_l(C_l) + \mathrm{Up}(\widetilde{P}_{l+1}). \tag{9.19}$$

Up 将高层特征上采样到 C_l 的空间大小，两个分支通道相同后逐元素相加，通常再用 3×3 卷积处理融合结果，得到检测使用的 P_l。高层提供较广的语义信息，横向连接提供较密的空间信息，不同大小的目标可分配到不同层级上预测。FPN 可以接入两阶段或单阶段检测器，它改变特征来源，不规定最终输出格式。

图9.9中，左侧是骨干的自底向上路径，右侧是产生多尺度预测特征的自顶向下路径。下方放大框对应式(9.19)中的一次融合：高层特征上采样两倍，横向特征经过 1×1 卷积，二者相加；融合后的 3×3 卷积没有单列。

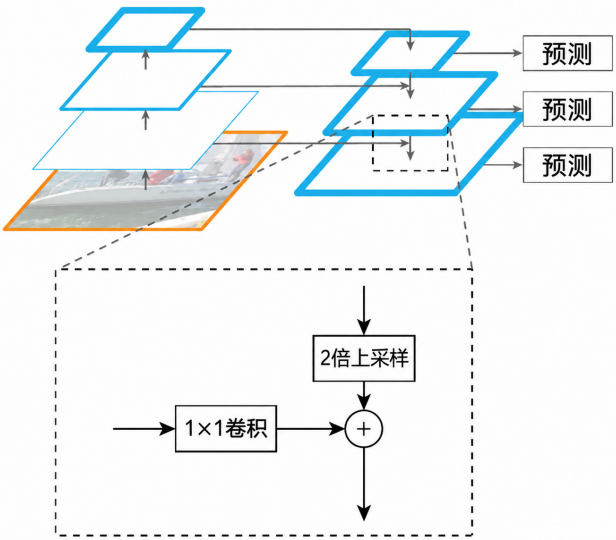


图 9.9： FPN 多尺度特征融合[10]

[10]来源：Lin 等，*Feature Pyramid Networks for Object Detection*，2017。

上采样只是把数表放大。FPN 能利用的细节来自仍保留这些信息的横向分支；若缺陷在所有分支中都已丢失，融合不能把它恢复。这个限制同样存在于像素级分割中。

9.5 图像分割：以 U-Net 解释像素级预测

9.5.1 为什么解码器需要编码器的细节

矩形框可以圈出裂纹，却同时包含很多正常背景，不能直接用于测量裂纹面积。分割将预测目标改为与图像对应的像素标签；对细长裂纹，模型既要判断局部变化是否属于裂纹，又要保持其边界与连续性。

U-Net 是具有编码器与解码器的卷积网络[11]。编码器逐级下采样，形成越来越粗的空间特征；解码器逐级上采样，将表示恢复到输出网格。只把最深层特征放大时，精细位置难以确定，因此 U-Net 还把编码器同尺度特征传给解码器。图9.10展示了这一计算关系。

例如，把 $8 \times 8 \times 64$ 深层特征上采样并调整为 $16 \times 16 \times 32$，与编码器的 $16 \times 16 \times 32$ 特征按通道拼接，得到 $16 \times 16 \times 64$，再通过卷积产生 $16 \times 16 \times 32$ 解码特征。拼接保留两组特征供后续学习使用，和 ResNet 的逐元素相加不同。图中为了保持尺寸使用了填充，原始 U-Net 的无填充卷积需要裁切编码特征后再拼接。

图9.11给出原始 U-Net 的完整尺寸关系：蓝色箭头表示 3×3 无填充卷积与 ReLU，每次使高、宽各减少二；红色箭头下采样，绿色箭头上卷积，灰色箭头复制并裁剪编码特征。输入为 572×572，输出为 388×388 的两类分割得分图，尚不是阈值化后的二值掩码。

[11] 来源：Ronneberger 等，*U-Net: Convolutional Networks for Biomedical Image Segmentation*，2015。

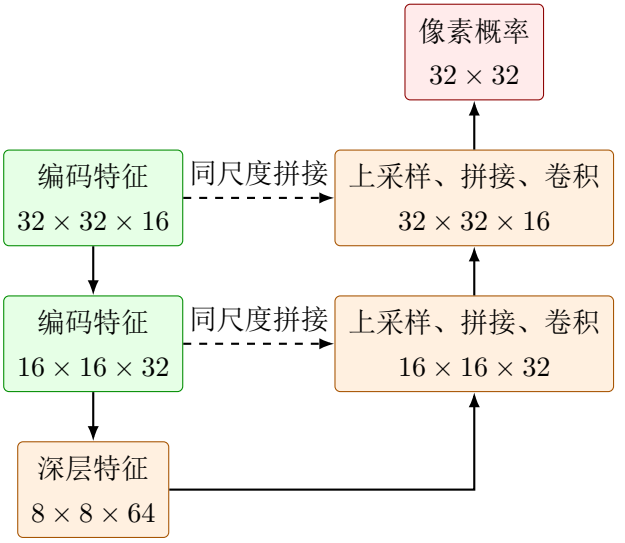


图 9.10: 采用尺寸保持卷积的简化 U-Net。实线表示下采样或解码计算，虚线把编码特征送到同尺度解码层。尺寸为教学设置，未逐层复现原论文配置。

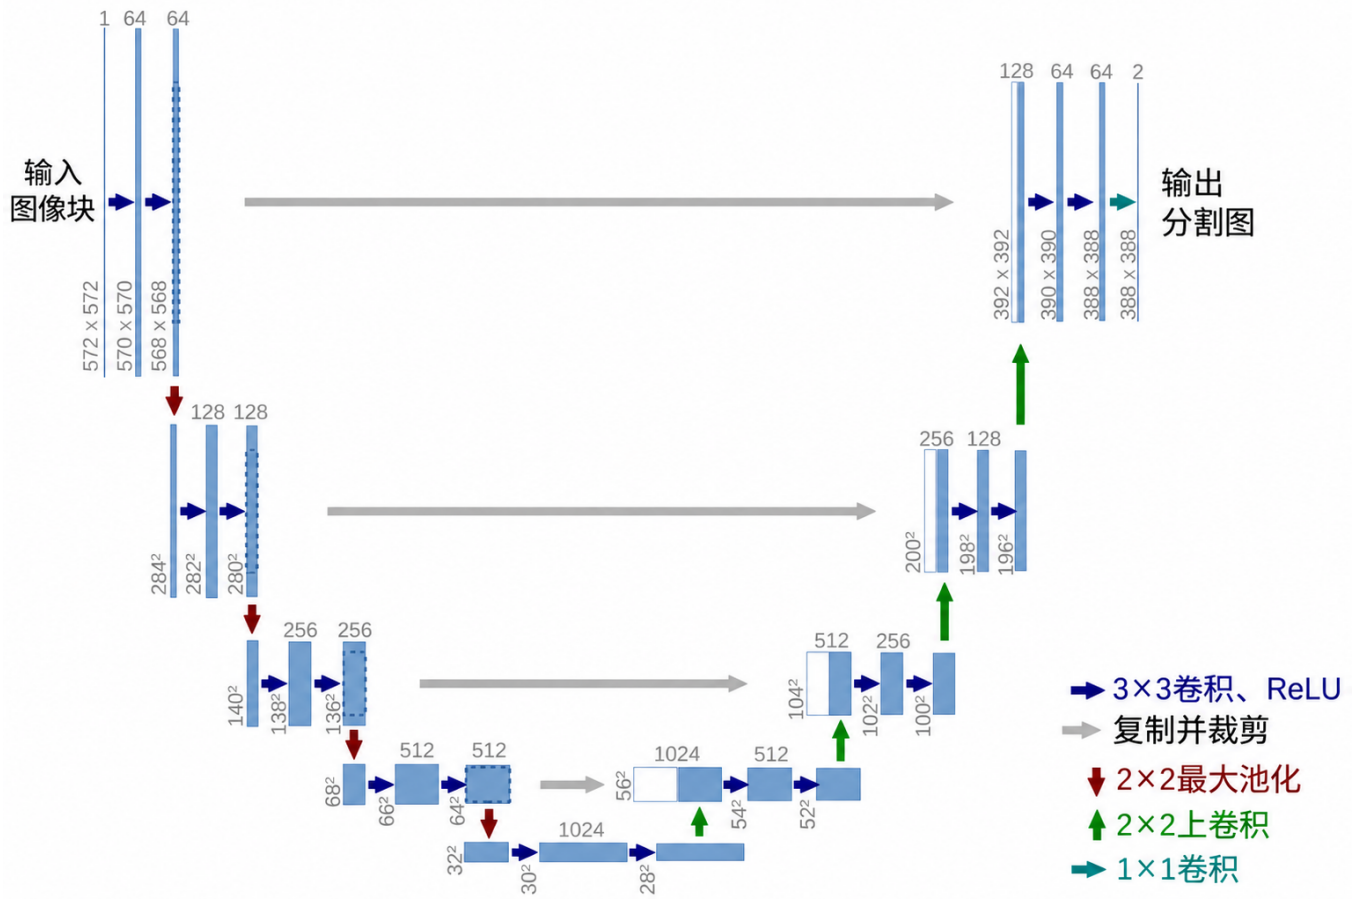


图 9.11: U-Net 编码器与解码器[12]

[12]来源：Ronneberger 等，*U-Net: Convolutional Networks for Biomedical Image Segmentation*，2015。

同尺度连接使解码器可以同时读取细节与上下文，但也可能带入背景纹理；它提供了使用信息的路径，是否正确使用仍由训练决定。

9.5.2 从概率图到掩码与训练损失

以一张 32×32 图像的二值分割为例，模型输出 32×32 个 logit，即尚未转成概率的实数得分，经 sigmoid 成为同形状概率图，训练时与同形状的零一标签比较，推理时才按验证集确定的阈值变成硬掩码。多类互斥分割通常输出 $32 \times 32 \times K$，在每个像素的 K 个类别上归一化，而不是在整幅图的全部像素上做一次 softmax。

四个像素的真实掩码为 $(1,1,0,0)$，预测硬掩码为 $(1,0,1,0)$，则交集为一、并集为三，IoU 为 $1/3$，Dice 为 $2/(2+2) = 1/2$。训练中的软 Dice 用概率代替硬预测，以便求导；阈值化通常不参与这条训练梯度。

像素似然、Dice 与稀疏前景。 设一幅图含 n 个像素，二值标签 $y_i \in \{0,1\}$，模型输出 $p_i = \sigma(z_i)$，其中 $\sigma(z) = 1/(1+e^{-z})$ 为 sigmoid 函数。将每个像素的标签建模为伯努利分布，在给定图像后采用乘积形式得到似然。取负对数并按像素数平均，得到二值交叉熵（Binary Cross Entropy，BCE）：

$$p(y \mid X) = \prod_{i=1}^{n} p_i^{y_i} (1-p_i)^{1-y_i}, \tag{9.20}$$

$$\mathcal{L}_{\mathrm{BCE}} = -\frac{1}{n} \sum_i [y_i \log p_i + (1-y_i) \log(1-p_i)], \tag{9.21}$$

$$\frac{\partial \mathcal{L}_{\mathrm{BCE}}}{\partial z_i} = \frac{p_i - y_i}{n}. \tag{9.22}$$

这个似然分解不表示真实裂纹像素相互独立，而是输出头采用的近似。前景极少时，大量背景项会主导平均损失。Dice 从集合重叠出发：硬掩码的 $D = 2|A \cap B|/(|A| + |B|)$，将预测指示函数换成概率便得到软 Dice 损失：

$$\mathcal{L}_{\mathrm{Dice}} = 1 - \frac{2 \sum_i p_i y_i + \epsilon}{\sum_i p_i + \sum_i y_i + \epsilon}. \tag{9.23}$$

其中 $\epsilon > 0$ 是固定的小平滑常数，用于避免空掩码时分母为零，求导时不随 p_i 变化。记 $N = 2\sum_i p_i y_i + \epsilon$、$D_0 = \sum_i p_i + \sum_i y_i + \epsilon$，则

$$\frac{\partial \mathcal{L}_{\text{Dice}}}{\partial p_j} = \frac{N - 2y_j D_0}{D_0^2}, \qquad \frac{\partial \mathcal{L}_{\text{Dice}}}{\partial z_j} = \frac{N - 2y_j D_0}{D_0^2} p_j(1 - p_j). \tag{9.24}$$

一个像素的梯度依赖全图预测总量，体现其区域级归一化，而不是各像素独立计分。对无前景图，$N = \epsilon$，当预测面积较大时惩罚梯度可能很小；可结合 BCE 并明确空掩码的评价约定。Dice 也不是概率校准目标，因此不应把优化后的 p_i 未经验证就解释为可靠风险概率。

硬掩码下，令 $J = \text{IoU}$，由 $|A| + |B| = |A \cup B| + |A \cap B|$ 得到 $D = 2J/(1 + J)$。同一对掩码的两个指标单调对应，但先对图像平均再作非线性变换不等价；软 Dice 与阈值后二值 IoU 更不能直接替换。边界和拓扑验收正是补充这些面积指标遗漏的信息。

9.5.3 U-Net 的改进与 Mask R-CNN 的实例输出

U-Net++ 在横向连接路径中增加卷积与中间融合，使解码器逐步组合不同深度的表示，代价是更多计算和存储。DeepLab 系列则用空洞卷积在不继续下采样的情况下扩大上下文：空洞率为二的 3×3 核覆盖五像素宽的范围，仍只有九个空间采样点；在式(9.3)中将增量改为 $d_l(k_l - 1)j_{l-1}$，即可计算空洞率 d_l 的感受野。空洞空间金字塔池化（Atrous Spatial Pyramid Pooling，ASPP）并行使用不同空洞率，组合不同范围的上下文。稀疏采样不等于观察了覆盖范围内的全部细节，边界仍要依赖足够密的特征。这些改进是否改善边界，都要用相同数据与评价协议检验。

语义掩码中，同类相邻目标仍可能连在一起。若要分别统计每个缺陷的面积，可以使用 Mask R-CNN[13]：它在 Faster R-CNN 中增加一个与分类和框回归并行的掩码分支，用 RoIAlign 按候选框位置在共享特征上插值采样，为每个正候选预测固定网格的掩码，推理时再映射回该框在原图中的

[13] 来源：He 等，*Mask R-CNN*，2017。

位置。它依赖检测结果，漏掉的候选不会被掩码分支补回，较粗的区域网格也会限制细边界。

9.6 少样本异常检测：用 DINOv2 特征比较正常图像块

9.6.1 只有少量正常样本时要回答什么

分类、检测和分割都需要缺陷样本，而新产线或低缺陷率工序常常只有少量正常件，缺陷种类也难以穷举。异常检测只用正常样本建立参照：测试时给整幅图一个异常得分，并为每个位置给出偏离程度，后者称为异常图；得分超过阈值的图送去复检，异常图指出可疑位置。每类产品只提供 k 张正常参考图（如 $k = 1, 2, 4$）时，称为少样本（few-shot）异常检测。异常得分衡量的是与参照的差异，不是缺陷概率；异常图高亮的位置也未必都是缺陷。

9.6.2 DINOv2 系列：无标签预训练的图像块特征

要让逐块比较可靠，图像块特征应当对同一部位稳定、对异常变化敏感。DINOv2 是不使用人工标签训练的 ViT[14]：教师网络取学生网络参数的指数滑动平均，两者看到同一幅图的不同裁剪；学生既要让分类标记的输出与教师一致，也要在被遮住的图像块位置预测教师给出的图像块表示。训练后，不同图像中相同部位的图像块特征彼此相近。本节只把冻结的 DINOv2 当作特征提取器，训练目标留到预训练章展开。它的普通版本有第9.3.2节所说的高范数伪影，官方也提供了带寄存标记的版本；后续的 DINOv3 进一步扩大了模型与数据[15]。

设冻结的骨干把图像 x 变成 N 个图像块特征 $f_1(x), \ldots, f_N(x) \in \mathbb{R}^D$。

[14] 来源：Oquab 等，*DINOv2: Learning Robust Visual Features without Supervision*，2024。

[15] 来源：Siméoni 等，*DINOv3*，2025。

ViT-S/14 的图像块边长为 14 像素、$D = 384$，输入为 448×448 时有 $(448/14)^2 = 1024$ 个图像块。

9.6.3 以最近邻距离给图像块打分

AnomalyDINO 直接比较这些图像块特征，不训练任何参数[16]。先把 k 张正常参考图的全部图像块特征放入记忆库

$$\mathcal{M} = \{f_j(x^{(r)}) : r = 1, \dots, k;\ j = 1, \dots, N\}, \tag{9.25}$$

再对测试图的每个图像块求到记忆库的最近余弦距离，并取距离最大的 1% 图像块的平均值作为整图得分：

$$d_j = \min_{m \in \mathcal{M}} \left(1 - \frac{f_j(x)^{\mathsf{T}} m}{\|f_j(x)\|_2 \, \|m\|_2}\right), \qquad s(x) = \frac{1}{|\mathcal{T}|} \sum_{j \in \mathcal{T}} d_j, \tag{9.26}$$

其中 $\mathcal{T}$ 是 d_j 最大的 $\lceil 0.01N \rceil$ 个图像块。把 $d_1, \dots, d_N$ 排回图像块网格，经上采样和平滑便得到异常图。参考图默认加入旋转增强，物体类图像还会先去掉背景，图9.12中把两者标为可选步骤。“正常图像块记忆库加最近邻距离”的思路此前已用于 PatchCore[17]；AnomalyDINO 表明，换用 DINOv2 特征后，少到一张参考图也能工作。

手算两个图像块的距离。 设记忆库只有 $m_1 = (1, 0)$ 与 $m_2 = (0.8, 0.6)$ 两个单位向量。测试图像块 $a = (0.6, 0.8)$ 与它们的余弦相似度为 0.6 和 0.96，距离为 0.4 和 0.04，取最小值得 $d_a = 0.04$，说明 a 接近某个正常部位。图像块 $b = (-0.6, 0.8)$ 的相似度为 -0.6 和 0，距离为 1.6 和 1，于是 $d_b = 1$。若整图有 200 个图像块，$\mathcal{T}$ 只含 2 个；最大的两个距离为 1 和 0.6 时，$s = 0.8$。只要少数图像块明显偏离，整图得分就会升高，这对小缺陷有利；平均两个最大值又能减弱单个噪声图像块的影响。最近邻取最小值，意味着测试块

[16] 来源：Damm 等，*AnomalyDINO: Boosting Patch-based Few-shot Anomaly Detection with DINOv2*，2025。

[17] 来源：Roth 等，*Towards Total Recall in Industrial Anomaly Detection*，2022。

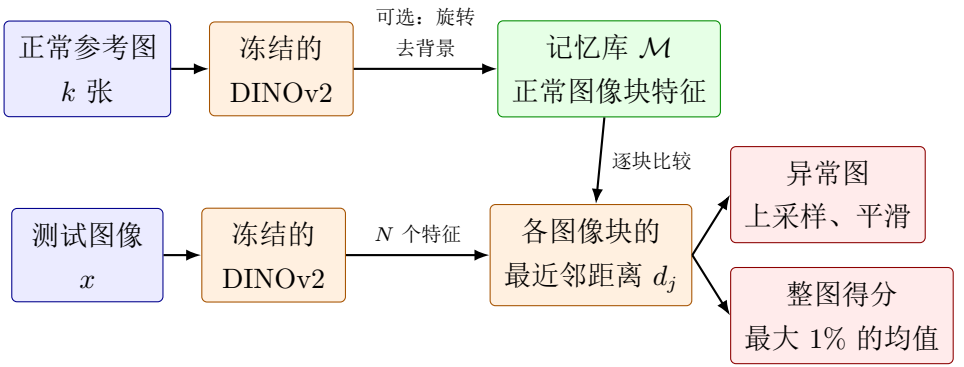


图 9.12：基于图像块最近邻的少样本异常检测。上行用少量正常参考图建立记忆库，下行求测试图每个图像块到记忆库的最近距离；骨干只提取特征，参数不更新。

只要与任一正常块相似就不会被报出，因此记忆库应覆盖正常件允许出现的各种外观。逐块比较的计算量随记忆库规模增长：448×448 输入、$k = 4$ 时，每张测试图需计算 $1024 \times 4096 \approx 4.2 \times 10^6$ 个余弦相似度，可写成一次矩阵乘法。

9.6.4 适用边界与验证

最近邻比较只能发现“与参考图不同”的外观。参考图太少时，光照、位置、批次纹理等正常变化也会被报为异常，应补充覆盖这些变化的参考图或先做对位。旋转增强假定旋转后的正常件仍然正常；若方向本身就是检验内容，如零件装反，就不能使用。去背景也可能把物体的一部分误当作背景。尺寸下限取决于图像块大小和输入分辨率：把 2048 像素宽的原图缩放到 448 像素时，每个图像块对应原图约 64×64 像素，宽 10 像素的裂纹只剩约 2 像素，提高分辨率又会增加计算。缺件、错装等逻辑异常逐块看可能都正常，需要整体比较。部署阈值须在验证集上确定；异常不等于缺陷，最终仍要按第9.7.2节的做法用独立数据检验。

9.7 回到质检任务：模型能解决什么，怎样验证

9.7.1 细小缺陷与有限标注

分类、检测和分割的错误要分别检查。若分类正确而检测漏掉细裂纹，应先看裂纹是否在缩放或下采样时消失，再检查候选分配与筛选；如果框已经正确而掩码边缘断裂，则应检查解码分辨率、像素标签与掩码阈值。换一个更深的骨干不一定解决这些不同来源的问题。

标注不足时，可以使用在其他图像上预训练的骨干。冻结骨干、只训练最终线性分类层，称为线性探测：骨干每图输出 128 维向量时，三类分类头只有 $3 \times 128 + 3 = 387$ 个参数；全量微调还会更新骨干。检测和分割则必须训练各自的空间任务头；若预训练没有保留所需纹理，仅更新分类头可能不足。不用人工类别标签的预训练（如第9.6节的 DINOv2）将在预训练章展开，图文对齐放到多模态章讨论。

数据增强也要服从任务：几何变换必须同步作用于图像、框和掩码，离散类别掩码缩放通常采用最近邻插值；若裁剪删掉全部裂纹，图像级标签也要相应检查；若颜色是缺陷的依据，过强的颜色扰动会破坏标签。增强需要模拟允许出现的变化，不能随意要求模型忽略任务所需信息。

9.7.2 用独立数据检查类别、位置和边界

设生产线上有四台相机。可以用前三台相机的早期批次训练、后期批次验证，完整留出第四台相机测试设备迁移。来自同一工件的近重复帧应放在同一集合，避免模型在测试时再次看到几乎相同的图。阈值、输入分辨率与后处理规则在验证集确定，固定测试集只用于最终评价。若要区分相机变化与时间变化的影响，还需要分别固定其中一个因素进行测试。

分类除准确率外，还应报告缺陷召回和正常图误报。例如十个真实缺陷中找对八个，另误报两个，精确率为 $8/(8+2) = 0.8$，召回率为 $8/10 = 0.8$。检测须先完成前述类别与空间匹配，再统计这些数量；分类热力图可以帮助检查模型是否依赖批次标记，却不能替代经过框标注训练与评价的检测

结果。分割还要在 IoU、Dice 等面积重叠之外检查连通性和边界距离：细裂纹少量断裂只改变很少像素，却影响长度估计。面积过滤等后处理也可能删除真实小缺陷，应纳入完整预测流程一起评价；标注边缘本身模糊时，可保留多名标注者的分歧，避免把标注不确定性全部归因于模型。

置信度也需要单独验证：在大量被报为 0.8 缺陷概率的图像中，实际缺陷比例接近 80%，才支持这一概率解释；新相机与光照变化可能破坏这种对应。无法自动判定的图像可以转人工复核，同时报告自动覆盖率：例如一百张图自动处理八十张、其中两张错误，覆盖率为 80%，已处理样本错误率为 $2/80 = 2.5\%$。最后应在目标设备上测量包含预处理与后处理的延迟，并记录相机、批次、标注版本和所用模型，使漏检可以追溯到具体环节。

以下材料按本章顺序排列，可在完成相关算例后阅读或实践。

辅助学习材料

- **Convolutional Neural Networks (CNNs / ConvNets)**（Stanford CS231n，英文笔记）。复习卷积层、输出尺寸与参数共享。在线阅读。
- **ResNet 网络讲解**（中文视频）。区分恒等捷径与改变尺寸的投影捷径。观看讲解。
- **Vision Transformer 网络讲解**（中文视频）。看图像如何切成 patch 并投影为 token。观看讲解。
- **区域卷积神经网络（R-CNN）系列**（《动手学深度学习》，中文教程）。先读 Fast R-CNN 与 RoI pooling，再读引入 RPN 的 Faster R-CNN。在线阅读。
- **YOLO 系列网络讲解 (V1~V3)**（中文视频）。比较网格、锚框与多尺度输出。观看讲解。
- **U-Net 网络讲解**（中文视频）。沿编码器、解码器与同尺度拼接追踪

分辨率。观看讲解。上述四个模型视频均可从作者课程目录查到配套代码。

- **TorchVision Object Detection Finetuning Tutorial**（PyTorch 官方，英文实践）。跟随 Mask R-CNN 微调流程，核对框、标签和掩码格式。在线阅读。

本章小结。 本章从同一幅质检图像的三种输出展开。分类把空间特征汇聚成类别判断，ResNet 用残差路径改善深层卷积网络的优化，ViT 用图像块注意力联系不同区域；寄存标记为内部计算提供额外位置，但分类正确并不保证局部特征与缺陷对齐。

要求位置时，Faster R-CNN 用共享特征、区域提议和区域识别输出检测框，单阶段检测省去逐候选识别，FPN 让不同大小的缺陷有合适的预测层级；要求边界时，U-Net 用解码器与同尺度连接输出像素标签，Mask R-CNN 进一步区分每个目标。缺陷样本稀少时，冻结的 DINOv2 图像块特征可以与少量正常样本逐块比较，给出整图得分与异常图；它衡量的是偏离正常参照的程度，仍需用缺陷样本验证。框匹配、像素损失和最终评价各自回答不同问题，不能用一个训练分数代表全部任务效果。

找到裂纹后，还需要结合设备关系、有效规程和维修记录判断如何处理，后续章节将分别讨论。视觉模型给出的类别、坐标和掩码应保留拍摄条件、尺度和模型版本，便于他人核对。

第十章　语言大模型

本章摘要。本章沿着“文本如何变成可预测的序列”这条主线介绍语言大模型。先讲 token、表示和 Transformer，再解释预训练、缩放、监督微调、参数高效适配和解码，最后讨论检索增强、工具调用、评测与风险。这样可以把模型能力、外部知识和系统行为区分开来。

在贯穿案例中，本章不让语言模型直接替代故障预测器，而是处理设备手册、维修记录和告警上下文这类离散证据。它改变的是“如何检索、组织和调用知识”，而不是把事后记录伪装成预测时刻可用的信息；任何维修建议都必须回到原始证据、权限和人工确认。视觉章节把缺陷落实为空间位置和边界，上一章进一步利用设备连接与共同工序关系组织观测。但维护判断还需要回答“这个型号允许多大偏差”“哪一版条款适用于当前设备”。这些知识并不天然存在于像素或传感器轨迹中，而分散在带条件、例外和有效期的文档里。本章研究的不是让语言流畅性覆盖证据缺口，而是把文本概率模型、外部知识访问和受约束的系统行为分开建模，再考察它们怎样协同。

可以把本章的方法分开理解：预训练学习文本怎样接续，微调和偏好学习调整回答方式，检索则为这次回答找来相关资料。三者不能互相替代。模型即使把句子续得很顺，也可能记错规程；回答即使受人欢迎，也可能漏掉适用条件；放入整本手册，也不保证它读到了关键条款。下面通过似然梯度、低秩更新和偏好概率解释训练，再检查生成答案能否追溯到当前有效的原文。

10.1 Token、表示与语言建模

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

本章的自注意力结构以 Transformer 为基础 [89]。Bidirectional Encoder Representations from Transformers (BERT) 的双向掩码预训练与自回归语言模型采用不同的信息可见性，因而需要分别理解表示与生成目标 [19, 8]。分词器（tokenizer）先按固定规则把文本转换为词元（token）编号。词元可以是字、词的一部分、标点或字节片段，不一定是完整词。为便于手算，假设一个教学词表把“温度升高”切成“温度”“升高”两个词元，编号为 $3, 7$；真实切分取决于所用分词器。编号只用于查表，7 不是比 3“语义更大”。嵌入就是从可训练矩阵中取出相应行，把离散编号变成稠密向量。

若一批有两段文本，补齐后各四个词元，则编号张量为 2×4；嵌入宽度取八，查表后是 $2 \times 4 \times 8$；词表有十项，输出得分为 $2 \times 4 \times 10$。最后一维表示十个候选词元，不是十个独立答案。logit 是 softmax 之前的实数打分，可正可负；softmax 把一组得分转换成和为一的概率。语言模型学习

$$p_\theta(x_{1:T}) = \prod_{t=1}^{T} p_\theta(x_t \mid x_{<t}), \tag{10.1}$$

训练目标是最小化负对数似然。Transformer 中的 token 表示由词嵌入、位置编码和多层注意力变换得到。

初读可先复习条件概率、对数和矩阵乘法，再按“词元编号—嵌入—词表得分—下一个词元”追踪数据。最大似然的推导解释为什么用交叉熵训练；LoRA 和 DPO 的推导分别解释如何限制参数更新、如何利用偏好，不是开始使用检索问答前必须先实现的三个训练阶段。

一段文本怎样产生训练标签。 沿用两个词元的例子，输入为“起始符、温度、升高”，目标为“温度、升高、结束符”。第一位置只能看起始符，第二位置能看起始符与“温度”，第三位置能看此前全部输入。因此一次前向计算

虽有三个目标，每个目标仍只能依据其前缀。若三个正确目标的概率分别为 $1/2, 1/4, 1/2$，整段含终止符的概率为 $1/16$，平均负对数似然为 $\log 16/3$，困惑度为 $16^{1/3} \approx 2.52$。计算使用自然对数。

生成时没有“升高”这个真实标签可以提前喂入。模型先选一个词元，将其加入输入，再预测下一个，直至结束符或长度上限。训练时输入真实前缀称为教师强制；生成时使用自己生成的前缀，错误因此可能影响后续内容。两者都调用同一个参数化网络，区别在于输入从哪里来以及是否更新参数。

链式分解如何变成可计算的训练目标。 设词表大小为 V_{voc}，$x_t \in \{1, \dots, V_{\text{voc}}\}$，嵌入矩阵 $E \in \mathbb{R}^{V_{\text{voc}} \times d}$。由联合概率的乘法公式，反复展开 $p(x_{1:T}) = p(x_{1:T-1})p(x_T \mid x_{<T})$ 即可得到式(10.1)；这不要求 token 独立。以起始符（BOS）提供第一个位置的条件，以结束符（EOS）学习何时停止，才构成包括长度的序列分布。设因果网络对前缀 $x_{<t}$ 产生 $h_t \in \mathbb{R}^d$，输出矩阵 $U \in \mathbb{R}^{V_{\text{voc}} \times d}$，则

$$z_t = U h_t + b, \qquad p_{t,j} = \frac{e^{z_{t,j}}}{\sum_{k=1}^{V_{\text{voc}}} e^{z_{t,k}}}, \tag{10.2}$$

$$\ell_t = -\log p_{t,x_t} = -z_{t,x_t} + \log \sum_{k} e^{z_{t,k}}, \tag{10.3}$$

$$\frac{\partial \ell_t}{\partial z_{t,j}} = p_{t,j} - \mathbf{1}_{j=x_t}. \tag{10.4}$$

若把这一位置的 logit 当作独立变量做梯度下降，真实 token 的 logit 增加，其余 logit 减小，真实 token 的概率随之上升。共享网络参数的一步更新还受其他位置梯度影响，不能据此保证每个样本的真实 token 概率都上升。对隐藏状态的梯度为

$$\frac{\partial \ell_t}{\partial h_t} = U^{\mathsf{T}}(p_t - e_{x_t}), \tag{10.5}$$

其中 $p_t, e_{x_t} \in \mathbb{R}^{V_{\text{voc}}}$，$e_{x_t}$ 仅在真实词元编号处为一，其余为零；$\mathbf{1}_{j=x_t}$ 是该条件成立时取一、否则取零的指示量。所得梯度为 d 维，再经网络反传。数值实现用 $\log \sum_k e^{z_k} = m + \log \sum_k e^{z_k - m}$，其中 $m = \max_k z_k$，避免指数溢出。

训练时可一次输入整段右移后的真实 token，并用因果遮罩并行计算所有位置；第 t 个输出的目标必须是尚未作为该位置可见输入的 x_t，否则会退化成复制任务。填充位置不计损失，指令微调还可只对回答位置计损失。注意力遮罩控制能读取哪些位置，损失掩码控制哪些输出计分，二者不能互换；不计提示损失仍可允许回答读取提示。部分模型接口内部完成标签移位，传入前须核对契约，避免手动移位后再被内部移位。归一化应按实际计分 token 数而非填充后的矩阵大小进行。训练并行并不改变生成时必须逐步追加未知 token 的事实。

固定同一个输入前缀 c，设真实条件分布为 $q(\cdot \mid c)$，则期望交叉熵分解为

$$-\sum_j q_j \log p_j = -\sum_j q_j \log q_j + \mathrm{KL}(q\|p). \tag{10.6}$$

第一个熵项与参数无关，最大似然因此在可表达范围内逼近训练分布，而不是直接优化事实核查。若训练分布本身含有过时或错误陈述，降低这项损失反而可能提高相应陈述的概率。这是外部证据管理不能被预训练规模替代的数学原因。

Tokenizer 在有限词表下平衡覆盖率与序列长度。词表过小会产生较长序列，词表过大则增加嵌入参数，并使部分低频 token 缺少训练。设备编号、故障码和单位可能被切成多个片段，因此语言模型是否能正确复制这些字符串，需要单独检验。标准注意力的计算量随序列长度呈二次增长，比较上下文成本时也应记录 token 数，而非只比较字符数。

自注意力由输入 H 生成查询、键和值：

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V, \qquad A = \mathrm{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}} + M\right), \tag{10.7}$$

其中 d_k 为键的维度。自回归模型令 $M_{ij} = -\infty$（当 $j > i$），其余位置为零，使当前位置不能读取后续 token。多头注意力以不同投影组合上下文，前馈网络进一步变换表示，残差连接和归一化控制深层计算。各个头可能学到不同关系，但不能预先认定某个头必然负责特定语义。

对单条长为 T 的序列，$H \in \mathbb{R}^{T\times d}$，$W_Q, W_K \in \mathbb{R}^{d\times d_k}$，$W_V \in \mathbb{R}^{d\times d_v}$，所以 $A \in \mathbb{R}^{T\times T}$，注意力读取结果为 $AV \in \mathbb{R}^{T\times d_v}$。softmax 沿每一行可见位置计算。查询用于提出当前读取需求，键用于匹配位置，值是实际读出的内容。例如一行可见得分为 $0, \log 3$，权重便为 $1/4, 3/4$；不是从两个位置中硬选一个。位置编码说明内容出现在哪里，前馈网络在各位置独立使用相同参数加工表示，多头结果经拼接和投影恢复宽度 d 后才能与原输入相加。

预归一化将归一化放在子层之前，保留较直接的残差梯度路径；后归一化改变了残差输出的尺度。因而 Transformer 是一组可以组合的结构选择，而非唯一固定的网络。理解注意力方向后，才能区分双向表示学习与因果生成的任务边界。

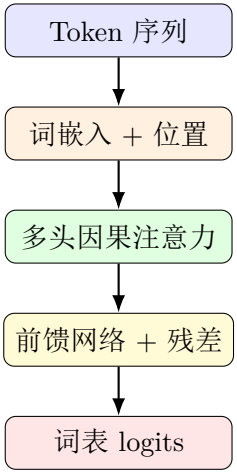


图 10.1: 自回归语言模型的基本计算链条。

图10.1从离散 token 追踪到词表 logits，说明嵌入、因果注意力和前馈变换如何共同产生下一词元的打分，而非直接检索一条既存答案。

10.2 预训练、对齐与推理

图10.2的反馈箭头表示选定 token 被追加到上下文；这使后续分布依赖先前生成结果，也解释了训练并行与推理逐步执行的区别。指令微调和

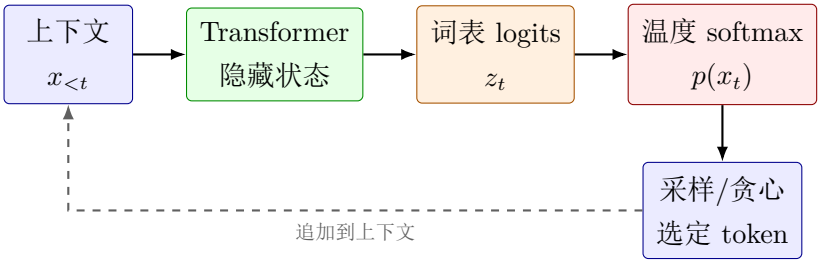


图 10.2: 自回归解码的单步迭代：模型先形成词表分布，再把选中的 token 反馈给下一步。

人类反馈训练的典型路线可参照 InstructGPT，直接偏好优化则把偏好学习转写为对语言模型的优化目标 [63, 67]。LoRA 的低秩参数更新有独立的结构假设 [36]，不应与对齐目标混为一谈。语言模型的主要分歧来自预训练任务和注意力方向，而不只是参数规模。BERT 属于 encoder-only 架构，通过双向注意力和 masked language modeling 学习上下文表示，适合分类、序列标注和检索重排序；Generative Pretrained Transformer (GPT)、LLaMA 等 decoder-only 模型使用因果掩码，只根据前文预测下一个 token，天然适合连续生成和工具调用；Text-to-Text Transfer Transformer (T5) 属于 encoder–decoder 架构，把分类、摘要、问答等任务统一写成文本到文本的条件生成。工业系统应依据输出形式选择架构：需要字段分类时，可先用 BERT 类编码器接固定类别的分类头，并在验证集上校准；能否校准良好仍取决于数据和目标，而非架构名称；需要长文本生成时，GPT/LLaMA 类模型更直接；需要输入输出长度差异明显的转换任务时，T5 类结构可减少提示工程依赖。

编码器（encoder）把已有输入变成表示，解码器（decoder）在这里指按条件逐步产生输出的模块，并非把压缩文件原样还原。BERT 可根据“温度［遮蔽］，请复检”的左右文恢复被遮蔽词，做分类时再接任务头；GPT 只能根据左侧前缀接续；T5 先完整编码输入，再由因果解码器读取编码表示生成输出。BERT 的双向不是偷看分类答案，只要整段输入在决策时已可取得便合理；但不能把未来维修记录放入在线预警输入。MoE 则主要替换部分前馈计算，它可以与这些注意力方向组合，不是第四种互斥的文本

可见性。

decoder-only 模型对整段序列优化

$$\mathcal{L}_{\mathrm{CLM}} = -\sum_{t=1}^{T} \log p_\theta(x_t \mid x_{<t}), \tag{10.8}$$

而 BERT 的掩码目标只在被遮蔽位置计算损失。两者的训练信号不同，因此不能仅用参数量推断迁移效果。对于设备手册和维修记录，可以先用 encoder 模型做语义检索和事件分类，再用 decoder 模型生成带证据引用的维修建议；这种组合通常比让一个生成模型独立完成所有步骤更容易审计。

当模型容量继续增加时，稀疏混合专家（Mixture-of-Experts, MoE）用路由器为每个 token 选择少数专家：

$$y = \sum_{e \in \mathcal{S}(x)} g_e(x) E_e(x), \qquad |\mathcal{S}(x)| \ll N_{\mathrm{exp}}. \tag{10.9}$$

这里 N_{exp} 是专家总数，$\mathcal{S}(x)$ 是路由器为当前词元表示 x 选中的专家索引集合，$E_e(x)$ 为第 e 个专家的输出，$g_e(x)$ 为相应路由权重；各专家输出须同维才能加权相加。专家是可训练子网络，并非人工专家；N_{exp} 也不是前文的嵌入矩阵 E。Switch Transformer 采用近似 top-1 路由，降低每个 token 的激活计算；更复杂的 top-2 路由能够提高容量利用，但需要处理专家负载不均和通信开销。MoE 的“总参数量”不等于“单次推理成本”，工业部署必须分别报告总存储、激活参数、路由丢弃率和跨卡通信。

表 10.1： 语言模型架构与工业任务匹配

架构路线	训练与注意力方向	优势	工业任务和风险
BERT 类 encoder-only	双向掩码建模	表示稳定、分类和检索高效	事件分类、实体抽取、重排序；不直接生成长文本
GPT/LLaMA 类 decoder-only	因果下一 token 预测	生成、对话和工具调用自然	报告草拟、脚本生成；需防幻觉和提示注入
T5 类 encoder–decoder	条件文本到文本	输入输出长度灵活、任务统一	摘要、规范化和文本转换；部署链路更复杂
MoE 语言模型	路由器选择少数专家	总容量大而激活成本可控	多领域共享；需监控负载和通信

表10.1将注意力方向和训练任务与工业输出要求对应，提示读者把分类检索、连续生成和条件转换分开选型，并单独核算 MoE 的通信成本。

预训练目标与困惑度。 语言模型的平均负对数似然为

$$\mathcal{L}_{LM} = -\frac{1}{T}\sum_{t=1}^{T}\log p_\theta(x_t \mid x_{<t}). \tag{10.10}$$

困惑度定义为 $\mathrm{PPL} = \exp(\mathcal{L}_{LM})$，可以理解为模型在每个位置面对的有效候选数。困惑度适合比较相同 tokenization 和数据分布下的语言模型，但不能单独代表事实性、帮助性或工业任务质量。

缩放、数据质量与模型容量。 模型参数量、训练 token 数和计算预算共同影响性能，但增加规模并不能弥补重复、污染或错误数据。高质量语料需要去重、过滤个人信息、识别模板化文本，并建立训练数据与评测数据的隔离。对于工业语料，还需处理机密信息、专有术语和时间有效性。

近重复文本可能降低训练损失，却不增加新的知识覆盖。若训练语料包含评测问题或答案模板，较低困惑度也不能证明迁移能力。固定计算预算下，应同时记录参数规模、有效 token 数、序列长度、训练步数和去重比例。工业语料还需要保存来源、许可和生效时间，使旧版本规程始终与适用设备绑定。

预训练提供语言分布的基础，监督微调则用示范答案塑造任务行为。上下文学习只改变当前输入条件，不更新参数。偏好优化进一步利用同一提示下的优选与非优选答案调整输出。Reinforcement Learning from Human Feedback (RLHF) 通常训练奖励模型并优化带参考策略约束的目标，Direct Preference Optimization (DPO) 则直接学习相对于参考模型的回答概率比。参考模型提供约束基准，但不保证事实性或原有能力完全保留，仍需独立评价。

监督微调与参数高效适配。 全量微调更新所有参数，成本随模型规模增长。LoRA 在权重更新上使用低秩分解

$$W' = W + \frac{\alpha}{r}BA, \qquad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k). \tag{10.11}$$

它只训练 A, B，便于为不同设备、部门或任务保存轻量适配器。参数高效方法降低存储成本，但多个适配器之间可能产生干扰，需要明确版本和适用域。

对一个 $d \times k$ 矩阵，全量更新需要 dk 个参数，LoRA 仅需 $r(d+k)$ 个，参数节省比例为

$$1 - \frac{r(d+k)}{dk}. \tag{10.12}$$

低秩约束限制更新所在的方向，秩过小可能无法表达目标域变化。因此应同时比较任务效果、可训练参数、训练显存及适配器合并后的推理成本，而不是只比较保存文件的大小。

区分训练目标、可训练参数与当前提示。 监督微调（Supervised Fine-Tuning，SFT）需要“问题、示范回答”对，以示范词元为目标；DPO 需要同一问题下优选与非优选回答对，以相对偏好为目标；LoRA 只规定哪些参数能变化，可以用于不同训练目标。给提示附上两个示例属于上下文学习，只改变本次前向计算，不会自动把示例写进权重。将三者都称为“教模型”容易混淆数据需求和成本。

取 $d = k = 4, r = 1, \alpha = 1$，完整权重有 16 个数，LoRA 的 A, B 共有八个数。令 $A = (1,0,0,0)$、$B = (1,2,0,0)^{\mathsf{T}}$、$x = (3,4,5,6)^{\mathsf{T}}$，则 $Ax = 3$，附加输出 $BAx = (3,6,0,0)^{\mathsf{T}}$。它只通过一个中间标量改变四维输出，说明“低秩”限制的是更新方向，而不是把原模型的全部知识压成一个数。推理时基座和已训练适配器通常都固定，不再利用真实答案反向传播。

低秩更新的前向与反向计算。 对单个线性层，令输入 $x \in \mathbb{R}^k$、输出 $y \in \mathbb{R}^d$、冻结权重 $W \in \mathbb{R}^{d \times k}$，并记 $s = \alpha/r$。LoRA 并非先构造完整更新再相乘，而可按

$$v = Ax \in \mathbb{R}^r, \qquad y = Wx + sBv \tag{10.13}$$

计算。若上游梯度为 $g = \nabla_y \mathcal{L} \in \mathbb{R}^d$，由微分 $d\mathcal{L} = g^{\mathsf{T}} dy$ 逐项整理得

$$\nabla_B \mathcal{L} = s\, g(Ax)^{\mathsf{T}}, \tag{10.14}$$

$$\nabla_A \mathcal{L} = s\, B^{\mathsf{T}} g\, x^{\mathsf{T}}, \tag{10.15}$$

$$\nabla_x \mathcal{L} = W^{\mathsf{T}} g + s A^{\mathsf{T}} B^{\mathsf{T}} g. \tag{10.16}$$

即使 W 冻结，反向传播仍可能需要穿过它，且前向激活仍需存储，所以可训练参数减少不等于训练显存按同一比例减少。常用 A 随机初始化、$B = 0$，使初始模型严格等于基座；第一步 $\nabla_A = 0$ 而 ∇_B 一般不为零，随后 B 变化才使 A 获得梯度。若两者都初始化为零，两组梯度都为零，会阻断学习。

矩阵的秩是其线性独立列的最大数量，可理解为能独立改变输出的方向数；更新满足 $\operatorname{rank}(BA) \le r$。若理想全量更新 ΔW_* 的奇异值为 $\sigma_1 \ge \cdots \ge \sigma_s$，其最佳秩 r 的 Frobenius 范数近似误差为 $\sum_{j>r} \sigma_j^2$ 的平方根。这解释了低秩假设依赖任务变化是否集中在少数方向，但不意味着实际非凸训练一定找到这个近似。部署时可把 sBA 合并进 W 以消除额外分支，前提是适配器固定且数值格式兼容；动态切换适配器、量化权重与合并精度则需另外验证。

从偏好概率到直接偏好优化。 设提示为 q，完整回答为 y，策略为 $\pi_\theta(y \mid q)$，冻结参考策略为 π_{ref}。假设参考策略在所比较回答上概率为正，先考虑给定 q 的 KL 正则目标

$$\max_{\pi} \left\{ \sum_{y} \pi(y \mid q) r(q, y) - \beta \sum_{y} \pi(y \mid q) \log \frac{\pi(y \mid q)}{\pi_{\mathrm{ref}}(y \mid q)} \right\}, \qquad \beta > 0. \tag{10.17}$$

用乘子 λ 约束 $\sum_y \pi(y \mid q) = 1$，对每个 $\pi(y \mid q)$ 求导，得到

$$r(q, y) - \beta \left(\log \frac{\pi(y \mid q)}{\pi_{\mathrm{ref}}(y \mid q)} + 1 \right) + \lambda = 0. \tag{10.18}$$

还需归一化常数 $Z(q) = \sum_y \pi_{\mathrm{ref}}(y \mid q) e^{r(q,y)/\beta}$ 有限；例如回答空间有限且奖励有限时满足这一条件。归一化后，最优策略为 $\pi^*(y \mid q) = \pi_{\mathrm{ref}}(y \mid$

$q)e^{r(q,y)/\beta}/Z(q)$，即

$$r(q,y)=\beta\log\frac{\pi^*(y\mid q)}{\pi_{\mathrm{ref}}(y\mid q)}+\beta\log Z(q). \tag{10.19}$$

再假设偏好符合 Bradley–Terry 模型，优选回答 y^+ 胜过 y^- 的概率为 $\sigma(r(q,y^+)-r(q,y^-))$。同一提示的 $\log Z(q)$ 相消，用 π_θ 参数化最优策略便得到

$$a_\theta=\beta\left[\log\frac{\pi_\theta(y^+\mid q)}{\pi_{\mathrm{ref}}(y^+\mid q)}-\log\frac{\pi_\theta(y^-\mid q)}{\pi_{\mathrm{ref}}(y^-\mid q)}\right], \tag{10.20}$$

$$\mathcal{L}_{\mathrm{DPO}}=-\mathbb{E}_{(q,y^+,y^-)}\log\sigma(a_\theta), \tag{10.21}$$

$$\nabla_\theta\ell_{\mathrm{DPO}}=-\beta\sigma(-a_\theta)[\nabla_\theta\log\pi_\theta(y^+\mid q)-\nabla_\theta\log\pi_\theta(y^-\mid q)]. \tag{10.22}$$

回答的对数概率是其 token 条件对数概率之和，提示本身不计入回答似然。这个目标提高相对于参考模型的偏好差，并非单独保证优选回答的绝对概率上升。偏好噪声、回答长度偏差、策略表达能力和有限离线数据都会破坏理想推导的前提；若标注者偏好自信但错误的答案，目标本身不会自动发现错误。KL 约束与偏好数据因而不能替代事实和规程验收。

偏好目标的一个数值检查。 设参考模型对两个完整回答的概率分别为 $0.2,0.2$，当前模型为 $0.4,0.1$，其他回答占剩余概率。取 $\beta=1$，则 $a_\theta=\log(0.4/0.2)-\log(0.1/0.2)=\log 4$，模型隐含的优选胜出概率为 $\sigma(\log 4)=0.8$，这对样本损失为 $-\log 0.8$。若当前模型等于参考模型，隐含胜率是 0.5、损失为 $\log 2$。这里的胜率描述偏好模型，不是优选答案事实正确的概率；冻结参考模型是固定比较基准，也不是提供实时事实核验。

解码与生成控制。 贪心解码每次选择最大概率 token，束搜索维护多个候选序列，温度采样使用

$$p_{\tau_{\mathrm{dec}}}(x_t=j\mid x_{<t})=\frac{\exp(z_{t,j}/\tau_{\mathrm{dec}})}{\sum_{k=1}^{V_{\mathrm{voc}}}\exp(z_{t,k}/\tau_{\mathrm{dec}})}. \tag{10.23}$$

这里 $z_t \in \mathbb{R}^{V_{\text{voc}}}$ 为当前词表 logits，V_{voc} 为词表大小，j 为候选词元编号，$\tau_{\text{dec}} > 0$ 为解码温度，与序列长度 T 区分。温度越高，分布越平坦。top-k 保留概率最大的 k 个候选；核采样（nucleus sampling，也称 top-p）保留按概率降序累加首次达到阈值 p 的最小前缀，再归一化。例如概率为 $0.6, 0.25, 0.15$ 时，top-2 与 top-0.8 都保留前两个，变为 $0.6/0.85, 0.25/0.85$；这里 p 是累计质量门槛，不是只保留单个概率超过 0.8 的词元。事实问答和工具调用通常需要低随机性与结构化输出，创意生成则可以接受更高多样性。

温度、序列概率与缓存的边界。 固定当前 logits，两个 token 的概率比满足

$$\log \frac{p_\tau(j)}{p_\tau(k)} = \frac{z_j - z_k}{\tau}. \tag{10.24}$$

由式(10.24)可知，$\tau \to 0^+$ 时概率集中到最大 logit 集合，$\tau \to \infty$ 时在有限词表上趋于均匀。令 $\mathcal{H}(\tau) = -\sum_j p_\tau(j) \log p_\tau(j)$，利用 $\mathcal{H} = \log Z - \mathbb{E}_{p_\tau}[z]/\tau$ 及 $d\mathbb{E}[z]/d\tau = -\operatorname{Var}_{p_\tau}(z)/\tau^2$，得到

$$\frac{d\mathcal{H}}{d\tau} = \frac{\operatorname{Var}_{p_\tau}(z)}{\tau^3} \geq 0. \tag{10.25}$$

温度增加确实增加这个固定前缀下的分布熵，但不保证生成事实更多样或更正确，因为后续前缀也随采样改变。top-k 或 top-p 先选择集合 S 再按 $p'(j) = p(j)\mathbf{1}_{j\in S}/\sum_{r\in S} p(r)$ 归一化，已经改变原始模型分布。

贪心逐步取最大条件概率，也不等于最大化完整序列概率。例如第一步两条路径概率为 $0.6, 0.4$，第二步各自最优续接概率为 $0.5, 0.9$，两条最优完整路径概率分别为 $0.30, 0.36$；贪心会错过第二条。束搜索只保留有限候选，也不能保证全局最优，长度处理和终止规则还会改变比较方式。

设批大小为 B、层数为 L、缓存长度为 T、键值头数为 H_{kv}、每头维度为 d_h，每元素占 b 字节，则仅键和值缓存占用约为

$$M_{\text{KV}} = 2BLTH_{\text{kv}}d_h b. \tag{10.26}$$

例如 $B = 1, L = 2, T = 1024, H_{\text{kv}} = 4, d_h = 64, b = 2$ 时，缓存为 2097152 字节，即 2 MiB；这还没有计入模型权重、当前激活和框架开销。单个新查

询仍需与 T 个历史键比较，标准全局注意力的新 token 成本仍随上下文线性增加，连续生成的累计注意力计算仍可能呈二次增长。缓存节省的是旧键值投影和旧位置的重复计算，并不把任意长上下文变成常数成本。不同键值头共享方案还会改变缓存与表达能力的折中。

生成时只新增一个 token，KV cache 保存已计算的历史键和值以减少重复计算，但缓存占用随上下文增长。缓存管理还需保证会话隔离与敏感内容清理。量化可以降低内存开销，却应在故障码、数值、单位和工具参数上单独验证。低温度和缓存优化只改变生成行为与资源消耗，不能补足模型缺少的有效规程，因此还需要外部检索。

10.3 检索、工具与安全边界

检索增强生成将外部检索证据与生成模型结合，Retrieval-Augmented Generation (RAG) 的原始工作给出了知识密集任务中的代表性实现 [50]。工业手册检索还需要额外约束版本、生效时间和权限，这些属于本书的应用规则，不能由生成模型自身保证。

检索增强生成。 给定查询 q，检索器返回文档 D_q，生成器计算 $p(y \mid q, D_q)$。系统误差可分为召回错误、排序错误、上下文理解错误和生成错误。评估时应分别测量检索召回率、引用是否支持答案、答案完整性和拒答质量。检索系统不能把不存在的证据变成可靠事实。

从一个问题走完检索链。 假设问题指定了设备型号和当前日期。离线先把手册切为保留标题、版本和页码的片段，用文档编码器将每段映射为 d 维向量并存入索引；在线把问题映射为同维向量，在权限与生效时间允许的片段中检索候选。双编码器分别编码问题和片段，便于缓存；交叉编码器（cross-encoder）把问题与某个候选共同输入再打分，更适合少量候选重排，不能直接复用独立文档向量。

若返回两段，一段有适用条件但没有处理步骤，另一段有步骤但属于

已失效版本，不能因为两段都“相似”就拼成可执行结论。应继续找完整有效证据或拒答。普通 RAG 查询通常既不更新生成器权重，也不更新检索器权重，只改变送进上下文的文字；文档更新后需同步更新索引，若编码器版本改变还需重建对应表示。检索片段中的词元也占上下文长度，更多片段可能挤掉关键条件。

检索得分、训练目标与证据边缘化。 设查询编码器 f_ϕ 与文档编码器 g_ϕ 输出 $\mathbb{R}^d$ 中的非零向量，归一化后得分为 $s_\phi(q,d) = f_\phi(q)^\top g_\phi(d)$。给定一个相关文档 d^+ 和候选集合 $\mathcal{C}$，对比检索损失为

$$P_\phi(d \mid q, \mathcal{C}) = \frac{\exp(s_\phi(q,d)/\tau_r)}{\sum_{d' \in \mathcal{C}} \exp(s_\phi(q,d')/\tau_r)}, \tag{10.27}$$

$$\ell_{\mathrm{ret}} = -\log P_\phi(d^+ \mid q, \mathcal{C}), \qquad \tau_r > 0, \tag{10.28}$$

$$\frac{\partial \ell_{\mathrm{ret}}}{\partial s_\phi(q,d)} = \frac{P_\phi(d \mid q, \mathcal{C}) - \mathbf{1}_{d=d^+}}{\tau_r}. \tag{10.29}$$

若把候选得分视为独立变量，式(10.29)的下降方向提高正例得分、降低负例得分；实际共享编码器还会汇总不同样本的梯度，不保证每对向量距离都按此方向变化。所得概率仅相对于候选集合归一化，不是文档支持答案的校准概率。同型号不同版本尤其适合作为需要区分的候选，却必须避免把另一份同样有效的证据错误标成负例。权限和有效期先定义可搜索集合 $\mathcal{D}(q)$，相似度排序只在这个集合内进行。

为理解检索和生成怎样组合，可把相关文档 d 视为潜变量，写出简化的单文档边缘化模型

$$p(y \mid q) = \sum_{d \in \mathcal{D}(q)} p_\phi(d \mid q)\, p_\theta(y \mid q, d). \tag{10.30}$$

实际仅取 top-K 集合 S_K。令 $Z_K = \sum_{d \in S_K} p_\phi(d \mid q)$，截断并重新归一化的分布为

$$p_K(y \mid q) = \frac{1}{Z_K} \sum_{d \in S_K} p_\phi(d \mid q)\, p_\theta(y \mid q, d). \tag{10.31}$$

若 $0 < Z_K < 1$，完整分布满足 $p(y \mid q) = Z_K p_K(y \mid q) + (1 - Z_K) p_{\text{tail}}(y \mid q)$，故两者对任意回答事件的概率差不超过 $1 - Z_K$。这个界解释了截断遗漏的影响，但工业向量得分通常没有给出真实全库后验，因此不能从 top-K 分数直接宣称已知 Z_K。此外，将多个片段拼接到一个提示里与上述单文档混合并不等价，跨段落推理还需要联合证据。

令 E 表示检索上下文包含足够有效证据，A 表示答案正确。全概率公式给出

$$P(A) = P(E)P(A \mid E) + P(E^{\text{c}})P(A \mid E^{\text{c}}). \tag{10.32}$$

证据缺失时模型可能凭已有知识答对，所以一般不能声称正确率必然低于检索召回；但若验收事件要求“正确且由当前有效证据支持”，则它是 E 的子事件，其概率必不超过 $P(E)$。这正是分别评价召回、答案正确性和引用支持率的理由。增加 K 可能提高召回，也可能加入冲突或噪声，需要固定上下文预算作分层验证。

工业知识问答应把 RAG 拆成可独立验收的流水线。离线阶段按照设备、部件、工况和有效时间切分手册，保留章节标题、表格关系、版本号和页码；切块时不能把“警告条件”和“处理步骤”拆到互不相邻的向量中。检索阶段可以先用 Best Matching 25 (BM25) 召回精确故障码，再用向量检索补充语义相近描述，最后由 cross-encoder 重排序。生成阶段要求模型输出答案、证据片段、文档版本和不确定性状态；当证据覆盖不足时，应拒答或请求更多设备上下文。

评估集需要按问题类型分层：直接查表、跨段落组合、版本冲突、过期规程、未登录故障码和恶意提示。对每个问题分别记录检索召回、证据支持率、答案正确率、引用准确率和拒答质量。一个语言模型即使在开放问答上流畅，也可能在版本冲突时选择了旧规程；因此文档有效期和权限过滤必须作为检索条件，而不是依赖生成模型自行判断。

工具返回值不是模型自己算出的事实。 例如回答设备记录查询时，模型先产生包含工具名、设备编号和时间范围的请求；外部程序检查格式与权

限后才执行查询，将结果作为新的上下文返回，模型再据此组织文字。请求格式合法不等于设备编号存在，更不等于查询已成功。超时、空结果或版本冲突应作为显式状态传回，不能让模型把未返回的数据补成“合理数值”。这一过程是推理中的外部交互，不会因为调用一次数据库就自动更新模型权重。

工具调用与评测。 工具调用把模型输出限制为结构化参数，再由外部程序执行查询、计算或控制动作。工业系统应采用白名单工具、参数校验、权限隔离和人工确认。评测集需要覆盖正常任务、边界输入、对抗提示、过时知识和工具失败。困惑度与任务准确率并不等价，LoRA 的参数量优势也必须结合任务迁移效果和推理开销评价。

幻觉、提示注入与安全边界。 幻觉不仅是“模型说错话”，还包括引用不存在、混淆设备型号、把条件性建议表达成确定事实。系统应允许模型在证据不足时拒答，并显示证据覆盖范围。提示注入则利用文档或用户输入改变系统指令；因此检索文本必须被视为不可信数据，工具调用必须通过结构化参数、权限检查和资源范围限制。

大模型评测矩阵。 工业评测应至少包含四个轴：语言能力、任务正确性、证据忠实度和系统可靠性。语言能力可测困惑度或结构化遵循；任务正确性应使用专家标注或可验证程序；证据忠实度检查答案是否被文档支持；系统可靠性则记录延迟、成本、拒答、超时和工具失败。每个轴都应按设备型号、工况、输入长度和缺失信息分层报告。

以下材料沿“因果语言建模—示范微调—低秩适配—偏好学习—外部知识”组织，不再重复通用 Transformer 入门。官方网页访问不稳定时，可从相应项目的公开文档源文件核对示例；接口版本应以实际安装环境为准。

辅助学习材料

- **Causal language modeling**（Hugging Face，英文教程）。跟随文本分块、标签构造、训练与生成，核对“Token、表示与语言建模”中的下一 token 目标及“预训练目标与困惑度”。示例是在已有模型上继续训练，不是从零预训练大模型的完整配方。在线阅读。

- **SFT Trainer**（Hugging Face TRL，英文教程）。重点读指令数据格式、标签右移、只对回答计损失与指令微调示例，把本章“监督微调与参数高效适配”落实为训练样本与损失掩码；再比较仅回答计分和整段文本计分的差别。在线阅读。

- **PEFT：在低资源硬件上对十亿规模模型进行参数高效微调**（Hugging Face，中文博客）。阅读 LoRA 配置、可训练参数统计和适配器保存 / 加载示例，对照本章低秩更新的前向与反向计算，区分冻结基座和训练适配器。文中低精度训练示例不等于 QLoRA 的完整说明，也不意味着显存与参数按同一比例减少。在线阅读。

- **ChatGPT 背后的“功臣”——RLHF 技术详解**（Hugging Face，中文图解博客）。按预训练、奖励模型与强化学习微调三步读图，识别偏好数据和参考策略各自的作用，再与本章 DPO 推导比较：DPO 直接优化相对回答概率，并非照搬奖励模型加策略优化的训练流程。在线阅读。

- **一文彻底搞懂大模型 - RAG（检索、增强、生成）**（CSDN，中文博客）。阅读知识库构建、向量检索、排序与上下文融合流程，对照本章“检索增强生成”，把召回错误与生成错误分开检查；图示便于理解管线，但“增强”不保证事实正确，仍须执行本章的版本、权限和引用支持率验收。在线阅读。

- **吴恩达 x OpenAI 的 Prompt Engineering 课程专业翻译版**（中英双语字幕视频，Datawhale 教程收录）。选看迭代提示、文本总结与

聊天机器人示例，练习把维修记录转成受约束的输出，对照本章生成控制与任务评测；提示只改变输入条件，不是 SFT，也不能替代上面的训练材料。观看课程，中文配套教程提供示例。名称、字幕说明和链接已核对教程目录；视频页访问受限，未逐帧观看，未核实播放量。

本章小结。 语言大模型的能力来自 token 表示、因果建模、规模化训练和对齐过程的共同作用，但这些环节优化的对象不同。最大似然逼近语料分布，LoRA 限制可更新的方向，偏好优化调整相对回答倾向，温度与截断改变解码分布，检索则改变当前能够引用的证据。把这些数学对象区分开来，才能判断某项改进究竟降低了什么误差，而不是把更流畅、更受偏好和更可信混为一谈。

工业应用的关键不在于把模型接入界面，而在于建立数据版本、检索证据、工具权限、输出校验和持续评测组成的控制链。本章沿用型号、生效时间和预测时刻的信息边界，使文字答案始终能返回原始来源。对于故障码、量值和复检条件，正确复制与精确引用往往比措辞自然更重要；证据不足时的拒答也是系统输出的一部分。

文字还需要与现场记录对应。“此处裂纹”指图中的哪个区域？“升温后异响”对应哪一段传感器记录？下一章讨论怎样配对、对齐和融合这些输入。即使放进共同的表示空间，时间戳、坐标和记录质量也要保留；几路观测有矛盾时，应指出矛盾并核查，不能靠一段流畅的描述把它们掩盖过去。

第十一章　多模态模型

本章摘要。本章从图文检索、零样本分类和图像问答的输入输出出发，深入解释三个代表性模型。CLIP 用双塔编码器和对称对比损失学习图文匹配。BLIP-2 用查询变换器从视觉特征中提取信息，连接冻结的语言模型进行条件生成。LLaVA 将视觉表示接入语言上下文，通过视觉指令微调学习按问题回答。各模型的结构、训练目标和推理过程分别展开，最后讨论它们在工业迁移中怎样验证。

视觉章节说明了如何从图像预测类别、框和像素边界。上一章说明了语言模型如何根据前文生成后续词元。现在给出一张巡检照片和问题“表面有什么异常”，还需要让语言模型取得照片中的信息。给出一句“有细长裂纹的工件”，则可能只需要从图库中找出相关照片。这两项任务都使用图像和文本，但输出形式与训练数据不同。

本章以图像与文本为主。先解释怎样比较二者，再解释怎样让图像成为语言生成的条件，最后解释怎样根据不同指令组织回答。阅读时需要用到内积、矩阵乘法、softmax、交叉熵和反向传播。视觉块表示与语言词元沿用前两章的定义。向量默认是列向量，将多个表示排成矩阵时，每行存放一个向量的转置。

11.1　先确定任务：寻找匹配还是生成回答

模态（modality）是信息的表现形式，例如图像、文本、音频和传感器序列。多模态模型处理两种或更多形式的输入，或者在不同形式之间建立对应。输入形式增加后，仍要先确定输出是什么。

图文检索与零样本分类。 图文检索可以输入一句描述，输出按相关程度排序的图像，也可以输入一张图像，输出相关文本。模型需要给候选组合打分。它不必逐词生成描述。零样本分类则把候选类别写成文本，例如“正常表面的照片”“有裂纹的表面的照片”“有划痕的表面的照片”，再选出与图像最匹配的类别描述。这要求图像表示与文本表示能在同一空间比较。

图像描述与视觉问答。 图像描述输入照片，输出一段概括内容的文字。视觉问答还输入问题，例如“裂纹大致位于左侧还是右侧”，输出针对该问题的回答。同一照片面对不同问题，需要使用不同信息。训练数据因此需要目标描述或问题与示范回答，仅有图文配对索引不足以规定怎样回答。

视觉指令跟随。 用户还可能要求“只列出可见异常，不判断成因”或“按部件、现象、待确认信息三个字段回答”。模型既要读取图像，也要按指令选择内容和格式。视觉指令微调用这样的示范教模型响应请求。模型能回答位置问题，不等于具有经过验证的检测或分割能力。定位仍需按视觉章节的框或像素标注验收。

接下来选择 CLIP、BLIP-2 和 LLaVA 作为里程碑模型。这是一条解释能力差异的顺序，各模型拥有各自的训练方案。CLIP 学习匹配分数，BLIP-2 建立视觉条件生成路径，LLaVA 进一步学习视觉指令响应。本章中的图文“对齐”指表示与配对关系的对应，与上一章通过指令或偏好调整回答行为的含义需要区分。

本章末的辅助学习材料按三个模型组织，可在完成相应算例后对照阅读。

11.2 CLIP：把图像和文本变成可比较的表示

11.2.1 双塔为什么适合检索

图文对比预训练（Contrastive Language–Image Pre-training，CLIP）用大量配对图像和文本学习共同表示空间 [66]。训练文本可以是对图像内容的自然语言描述，无需先把所有内容限制成一套固定类别。共同空间要求两路输出可以用同一种内积比较，不要求像素和文字具有相同的原始格式。

设一个训练批次有 N 对样本 (v_i, t_i)，其中 v_i 是第 i 幅图像，t_i 是其配对文本，$i = 1, \ldots, N$。视觉编码器 f_v 和文本编码器 f_t 各自处理输入，连同投影层输出 d 维表示：

$$u_i^v = f_v(v_i) \in \mathbb{R}^d, \qquad u_i^t = f_t(t_i) \in \mathbb{R}^d. \tag{11.1}$$

这里 d 是共同空间的宽度。视觉分支可以用卷积网络或视觉 Transformer，文本分支处理词元序列。两路编码器在计算单个表示时不读取另一模态，这种结构称为双塔。

若直接用未归一化向量的内积，向量长度也会影响分数。CLIP 将非零输出除以欧氏长度，得到单位向量：

$$z_i^v = \frac{u_i^v}{\|u_i^v\|_2}, \qquad z_i^t = \frac{u_i^t}{\|u_i^t\|_2}. \tag{11.2}$$

$z_i^v, z_i^t \in \mathbb{R}^d$ 均有单位范数。式(11.2)要求原向量非零。归一化后，内积等于两向量夹角的余弦，取值在 $[-1, 1]$ 之间。方向越接近，分数越高。模型通过训练学习这些方向，因此相近方向是否对应相关内容，要由配对数据和验证结果判断。

将所有图像表示按行排成 $Z_v \in \mathbb{R}^{N\times d}$，文本表示排成 $Z_t \in \mathbb{R}^{N\times d}$。全批次的得分为

$$S = \frac{Z_v Z_t^{\mathsf{T}}}{\tau} \in \mathbb{R}^{N\times N}, \qquad S_{ij} = \frac{(z_i^v)^{\mathsf{T}} z_j^t}{\tau}. \tag{11.3}$$

$\tau > 0$ 是温度参数，控制得分差异进入 softmax 后的尺度，原始 CLIP 在训练中学习其对应尺度。S 的行编号是图像，列编号是文本。N 对观测产生

N^2 个组合，只有对角位置是按当前索引给定的配对。这里 S 已经除以温度，后续损失不再重复除以 τ。

图11.1以两对样本展示双塔如何形成得分表。两个编码器先独立产生单位表示，随后计算全部内积。方框标出的是训练目标位置，行归一化和列归一化分别解决两个检索方向的问题。

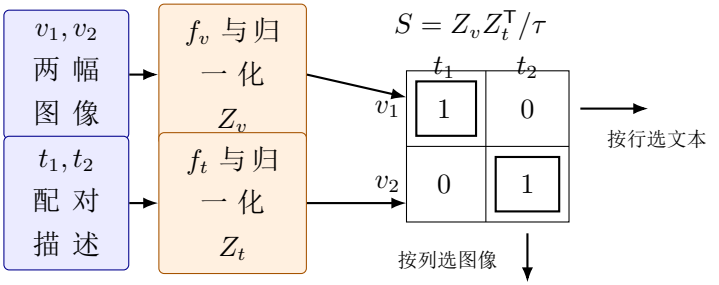


图 11.1: 两对样本的 CLIP 计算。箭头表示表示计算或归一化方向，方框标出给定配对。表中数值采用正文的二维单位向量与 $\tau = 1$，不代表实际模型的实验结果。

11.2.2 对称对比损失怎样使用配对索引

固定图像 i，可以把第 i 行的 N 个文本得分变成候选概率：

$$P_{v\to t}(j \mid i) = \frac{e^{S_{ij}}}{\sum_{k=1}^{N} e^{S_{ik}}}. \tag{11.4}$$

j, k 都是文本候选编号。softmax 沿行计算，各概率非负且和为一。当前批次指定文本 i 为目标，因此用负对数概率惩罚模型没有选中它的程度。对所有图像取平均，得到图到文损失。

反过来，固定文本 i，模型需要在所有图像中选出图像 i。此时沿第 i 列归一化：

$$P_{t\to v}(j \mid i) = \frac{e^{S_{ji}}}{\sum_{k=1}^{N} e^{S_{ki}}}. \tag{11.5}$$

这里 j, k 变成图像候选编号。两方向使用相同的得分表，但候选轴不同。分

别写出两项，再平均，就得到 CLIP 的对称对比损失：

$$\mathcal{L}_{v\to t} = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{e^{S_{ii}}}{\sum_{j=1}^{N}e^{S_{ij}}}, \tag{11.6}$$

$$\mathcal{L}_{t\to v} = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{e^{S_{ii}}}{\sum_{j=1}^{N}e^{S_{ji}}}, \tag{11.7}$$

$$\mathcal{L}_{\text{CLIP}} = \frac{1}{2}(\mathcal{L}_{v\to t} + \mathcal{L}_{t\to v}). \tag{11.8}$$

这些量是当前训练批次的经验损失，使用自然对数。目标索引来自图文配对，正样本指配对组合，负样本指被用作不匹配候选的其他组合，与“正常”“故障”的业务类别无关。图文必须同步重排，或者同步更新目标索引，否则对角目标就不再正确。

为了看清参数为何会变化，固定图像 i，记单行损失为 $\ell_i = -\log P_{v\to t}(i \mid i)$。展开对数并对一个得分求导：

$$\ell_i = -S_{ii} + \log\sum_{k=1}^{N} e^{S_{ik}}, \tag{11.9}$$

$$\frac{\partial \ell_i}{\partial S_{ij}} = P_{v\to t}(j \mid i) - \mathbf{1}_{j=i}. \tag{11.10}$$

$\mathbf{1}_{j=i}$ 在 $j=i$ 时为一，其他情况为零。若得分可独立调整，梯度下降会提高目标得分、降低其余得分。实际得分共享编码器参数，一次更新汇总所有行列的梯度，不能保证每个组合都单独按这个方向变化。

11.2.3 两对样本：从内积算到损失

取 $N=2, d=2$，设两幅图像的单位表示依次为 $(1,0)^{\mathsf{T}}$、$(0,1)^{\mathsf{T}}$，两段配对文本也取这两个向量。取 $\tau=1$，则

$$Z_v = Z_t = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \qquad S = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}. \tag{11.11}$$

四个组合中，配对内积为一，交叉组合内积为零。对第一幅图像，两个候选文本的概率为

$$P_{v\to t}(1 \mid 1) = \frac{e}{e+1} \approx 0.731, \qquad P_{v\to t}(2 \mid 1) = \frac{1}{e+1} \approx 0.269. \tag{11.12}$$

第二行以及两列的正确配对概率相同。因此两方向平均损失都约为 $-\log 0.731 = 0.313$，对称损失也约为 0.313。两个方向已经分开，softmax 仍不会在有限得分下输出概率一。

保持表示不变，仅把 τ 改为 0.5，对角得分变为二，正确配对概率变为 $e^2/(e^2+1) \approx 0.881$，损失约为 0.127。损失下降来自尺度改变，图文方向并未改善。温度因而不能脱离表示和任务指标单独评价。固定得分差时，小温度使概率更集中，也放大相似度梯度的尺度。它与上一章生成时调整词表分布的解码温度作用于不同对象。

若 $N = 1$ 且没有额外负样本，分子分母完全相同，两项损失都恒为零，无法提供对比分数梯度。较大的批次增加候选，但候选未必真的不匹配。例如两幅图都显示裂纹，两段文本都写“有裂纹的表面”，非对角组合也可能合理。这类实际匹配却被当成负例的组合称为假负例（false negative）。若数据存在多重匹配，应检查配对规则，并考虑将多个合理目标共同计入监督。

11.2.4 训练之后怎样检索与分类

训练时，配对文本提供监督，损失通过编码器和投影层更新参数。推理时参数固定，不再需要正确配对索引。文本检索图像可以先缓存图库的单位图像向量，再编码输入描述，按内积排序。图像检索文本则缓存候选文本向量。双塔使这两种缓存都可行，更新编码器后需重新生成对应索引。

零样本分类把类别名称放入描述模板。设有 C 个互斥候选类别，类别 c 的描述为 t_c，单位文本向量为 z_c^t。新图像的单位向量为 z^v，决策写为

$$a_c = (z^v)^{\mathsf{T}} z_c^t, \qquad \hat{y} = \operatorname*{arg\,max}_{c \in \{1,\dots,C\}} a_c. \tag{11.13}$$

$a_c \in [-1, 1]$ 是类别相似度，$\hat{y}$ 是选出的类别编号。正温度缩放不改变排序。这里“零样本”表示在这种迁移设置下，没有使用目标任务的标注图像训练类别预测器，模型仍经历过图文预训练。若随后用目标域标签选择提示或调节阈值，应报告这部分监督，不能继续把整个流程称为严格零样本。

对类别得分做 softmax，可以得到相对于这 C 类的归一化数值，但它不自动等于类别正确的校准概率。照片也可能含有候选之外的缺陷，或者同时出现裂纹和划痕。前者需要拒识检验，后者需要多标签任务定义。描述模板与候选集合都会改变结果。

CLIP 将整幅图像和整段文本各汇成一个向量，适合大规模匹配。整图相似度难以直接表达“左边的零件挡住右边的裂纹”这样的细粒度关系，也不提供逐词生成路径。要解释照片或回答问题，需要继续把视觉信息送入语言模型。

11.3 BLIP-2：用少量查询连接视觉与语言

11.3.1 为什么需要一个可训练的连接模块

已有视觉编码器能产生区域特征，已有语言大模型能生成文字，但两者的表示宽度和训练任务不同。把视觉数表直接当成文本嵌入，没有理由让语言模型理解。若将两个大模型从头联合训练，更新参数和训练资源又会明显增加。

第二代视觉语言预训练模型 BLIP-2（Bootstrapping Language-Image Pre-training，第二代）用一个较小的查询变换器（Querying Transformer，Q-Former）连接冻结的视觉编码器和语言模型 [51]。冻结指训练时不更新指定权重。Q-Former 先学习从图像中提取与文本有关的信息，再学习把这些信息作为语言模型可以利用的条件输入。

设视觉编码器输出 $H_v \in \mathbb{R}^{n_v \times d_v}$，其中 n_v 是视觉位置数，d_v 是每个位置的特征宽度。沿用视觉章节的理解，这些位置可对应图像块，但特征已受编码器上下文影响，并非每行只含一个独立局部区域的信息。

Q-Former 使用 m 个可学习查询，初始查询矩阵为 $Q_0 \in \mathbb{R}^{m\times d_q}$。$d_q$ 是查询宽度，m 由结构设定。查询是训练得到的向量，不是 m 句人工问题，也没有预先规定每个查询负责哪种物体。原始 BLIP-2 使用固定数量的查询，下面取较小数值说明计算。

11.3.2 查询通过交叉注意力读取哪些信息

查询先在自身之间进行自注意力交互，再通过交叉注意力（cross-attention）读取视觉特征。与视觉章节的自注意力相比，这里查询和键值来自不同的序列。令某层查询状态为 $H_q \in \mathbb{R}^{m\times d_q}$。单头交叉读取可写为

$$Q = H_q W_Q \in \mathbb{R}^{m\times d_k}, \tag{11.14}$$

$$K = H_v W_K \in \mathbb{R}^{n_v\times d_k}, \tag{11.15}$$

$$V = H_v W_V \in \mathbb{R}^{n_v\times d_a}, \tag{11.16}$$

$$A = \operatorname{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}\right), \qquad O = AV. \tag{11.17}$$

$W_Q \in \mathbb{R}^{d_q\times d_k}$、$W_K \in \mathbb{R}^{d_v\times d_k}$、$W_V \in \mathbb{R}^{d_v\times d_a}$ 为可训练投影。d_k 是查询与键的共同宽度，d_a 是值的宽度。$A \in \mathbb{R}^{m\times n_v}$ 逐行沿视觉位置归一化，$O \in \mathbb{R}^{m\times d_a}$ 保留查询行数。$\sqrt{d_k}$ 用于控制内积尺度，在各维独立且单位方差的简化条件下，未缩放内积的方差随 d_k 增长。

第 a 个查询读取结果为 $O_{a,:} = \sum_{b=1}^{n_v} A_{ab} V_{b,:}$。$a$ 是查询编号，b 是视觉位置编号，$A_{ab} \geq 0$ 且 $\sum_b A_{ab} = 1$。不同查询可以从相同视觉特征读取不同组合。实际 Q-Former 使用多头注意力、输出投影、残差和前馈层，式(11.17)只展开其中一次读取。多头结果需投影回 d_q 宽度，才能与原查询状态做残差相加。

两个查询读取三个位置的手算。 取 $m=2, n_v=3, d_k=1, d_a=1$。用以下查询和键构造明确的示意得分：

$$Q=\begin{bmatrix}1\\-1\end{bmatrix},\qquad K=\begin{bmatrix}\log 2\\0\\0\end{bmatrix},\qquad V=\begin{bmatrix}2\\4\\10\end{bmatrix}. \tag{11.18}$$

V 的三个标量是教学特征值，没有像素或毫米单位。第一行得分为 $(\log 2, 0, 0)$，softmax 权重为 $(1/2, 1/4, 1/4)$。第二行得分为 $(-\log 2, 0, 0)$，权重为 $(1/5, 2/5, 2/5)$。于是

$$A=\begin{bmatrix}1/2 & 1/4 & 1/4\\1/5 & 2/5 & 2/5\end{bmatrix},\qquad O=\begin{bmatrix}4.5\\6\end{bmatrix}. \tag{11.19}$$

第一个结果为 $2/2+4/4+10/4=4.5$，第二个为 $2/5+8/5+20/5=6$。输出有两行，与查询数一致，不能当成三个视觉位置的标签。若另一组查询与键产生权重 $(0.1, 0.2, 0.7)$，读取结果就会变为 $0.1\times 2+0.2\times 4+0.7\times 10=8$。这个变化说明读取结果依赖查询与视觉特征共同形成的权重。

图11.2画出本次计算的两个输入轴。每个查询连接三个值，边旁数字表示读取权重。它们是模型计算中的加权系数，不提供真实缺陷位置或因果解释。

11.3.3 两阶段训练分别解决什么问题

第一阶段：从图像提取与文本有关的表示。 这一阶段冻结视觉编码器，训练 Q-Former，还没有接入冻结的语言大模型。Q-Former 除查询路径外还有文本路径，两者共享部分 Transformer 参数，利用不同注意力掩码定义任务。原始方法共同使用图文对比、图文匹配和以图像为条件的文本生成三个目标。

图文对比要求查询输出与配对文本表示能匹配。原始方法比较文本表示与多个查询表示，并使用其中最大的相似度形成图文对比得分。此任务限制查询与文本路径直接互读，避免仅复制配对文本就得到好分数。图文

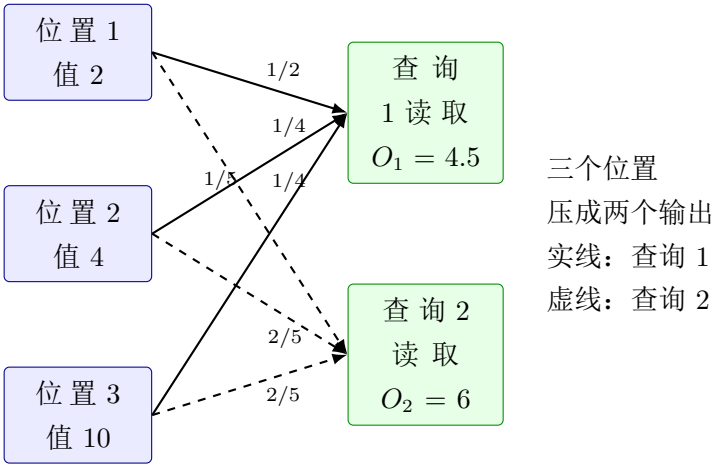


图 11.2: 单头交叉注意力的数值读取。箭头表示值信息进入查询输出，实线和虚线区分两个查询的读取路径。权重由正文给定的查询与键计算，输出行数由查询数决定。

匹配则让查询和文本交互，判断这组图文是否匹配，学习更细的联合关系。图像条件文本生成让文本位置读取查询输出，同时只能读取此前文本，以下一词元为目标。它要求查询携带有助于描述图像的信息。

三项目标分别约束独立表示的可比较性、联合图文的匹配判断和视觉条件下的文本预测。第一阶段的生成由 Q-Former 的文本路径承担，不能与第二阶段接入语言大模型的生成混为同一步。不同掩码改变了哪些信息可见，监督目标仍由配对关系或真实文本确定。

第二阶段：让冻结语言模型利用视觉条件。 保留冻结视觉编码器，接入冻结语言模型，训练 Q-Former 和连接投影。记 Q-Former 的最终查询输出为 $H_Q \in \mathbb{R}^{m\times d_q}$。线性投影得到

$$B = H_Q W_P \in \mathbb{R}^{m\times d_{\mathrm{lm}}}, \qquad W_P \in \mathbb{R}^{d_q\times d_{\mathrm{lm}}}. \tag{11.20}$$

d_{lm} 是语言模型嵌入宽度，B 包含 m 个连续视觉条件向量。这里省略可选偏置。这些向量常称为软视觉前缀，它们占据输入位置，却不需要先变成词表中的离散编号。BLIP-2 可连接不同语言模型结构，下面选解码器式语言模型说明前缀计算。

给定图像 v、文本提示 q 和目标回答 $y_{1:T}$，条件概率和单样本训练损失为

$$p(y_{1:T} \mid v, q) = \prod_{t=1}^{T} p(y_t \mid B(v), q, y_{<t}), \tag{11.21}$$

$$\ell_{\text{gen}} = -\frac{1}{T} \sum_{t=1}^{T} \log p(y_t \mid B(v), q, y_{<t}). \tag{11.22}$$

$B(v)$ 表示由该图像计算的视觉前缀，q 是已知提示，$y_{<t}$ 是第 t 个目标词元之前的真实回答。$T \geq 1$ 是计分回答词元数，可包含结束符，填充不计分。y_t 取自语言模型词表。所有概率由带因果掩码的语言模型计算，回答位置可以读取视觉前缀、提示和此前回答。训练集目标由各样本的损失平均得到。

这沿用上一章的下一词元预测。图文对比损失在有限候选间选择配对，式(11.22)在每一步的词表中预测目标词元。二者的候选、标签和输出都不同。生成损失降低只说明示范文字的预测改善，不直接证明每句话得到图像支持。

冻结权重时，梯度在哪里停止。 冻结语言模型参数 θ_{lm} 后，仍要计算它对视觉前缀的导数。令可训练连接部分的参数为 ϕ，链式法则为

$$\nabla_{\phi} \ell_{\text{gen}} = \left(\frac{\partial B}{\partial \phi} \right)^{\top} \nabla_{B} \ell_{\text{gen}}. \tag{11.23}$$

此处将 B 展平理解为向量，雅可比矩阵 $\partial B / \partial \phi$ 把连接参数变化映射到视觉前缀变化。$\nabla_{B} \ell_{\text{gen}}$ 来自穿过语言模型计算的反向传播。语言模型权重不执行更新，输入导数仍需保留。若在语言模型输入处切断梯度，连接模块就无法从回答损失学习。视觉编码器的权重也不更新，在本方案中其输出可以作为不求导的特征输入交给 Q-Former。

所以冻结减少的是需要更新的权重及相应优化器状态，冻结语言模型仍需前向计算，也通常仍需为输入梯度保存或重算内部激活。训练成本不能仅按可训练参数比例估计。

11.3.4 查询压缩带来什么收益与限制

取一个教学设置，视觉特征为64×128，使用八个查询，查询宽度 $d_q = 32$，语言宽度 $d_{\text{lm}} = 256$。Q-Former 输出 8×32，连接投影为 32×256，视觉前缀为 8×256。原有 64 个视觉位置压成八个语言输入位置。原始模型的配置不同，这些数值只用于追踪维度。

固定查询数可以控制送入语言模型的视觉序列长度，但 Q-Former 仍要读取 64 个视觉位置。压缩不能保证保留全部小缺陷、文字和空间关系。若视觉编码器在输入缩放时已丢失裂纹像素，连接模块没有原始证据可供恢复。增加查询数可能提高信息容量，也增加计算，需要在相同数据和预算下检验。

推理时不给真实回答，也不更新参数。先计算图像特征、查询输出和视觉前缀，再给提示，例如“描述可见表面”，逐词生成文字。若接入的是以描述训练为主的模型，面对复杂格式指令或多轮问题可能表现不足。视觉条件可用与指令响应熟练是两项不同要求，下一节用 LLaVA 解释后一项怎样训练。

11.4 LLaVA：让视觉表示参与指令回答

11.4.1 从线性投影到语言上下文

大型语言与视觉助手（Large Language and Vision Assistant，LLaVA）通过视觉指令微调，把预训练视觉编码器与语言模型连接起来 [55]。原始 LLaVA 用线性投影连接二者，没有使用 Q-Former 的查询压缩结构。图像描述用于初步连接，随后用包含问题、指令和示范回答的数据训练对话响应。

设视觉编码器仍输出 $H_v \in \mathbb{R}^{n_v \times d_v}$。原始线性连接可写为

$$B_v = H_v W_C \in \mathbb{R}^{n_v \times d_{\text{lm}}}, \qquad W_C \in \mathbb{R}^{d_v \times d_{\text{lm}}}. \tag{11.24}$$

B_v 的每行是送入语言模型的一个视觉词元表示，这些连续向量没有普通文

字的词元编号。投影改变宽度，保留 n_v 行。沿用 64×128 的教学视觉特征，投影矩阵为 128×256，得到 64×256。与 BLIP-2 的八个查询前缀相比，这里直接接入 64 个位置。

后续常用的 LLaVA 版本将线性连接改为多层感知机（Multilayer Perceptron，MLP）。例如逐位置的两层连接可写为

$$B_v = \sigma(H_v W_1) W_2, \tag{11.25}$$

$W_1 \in \mathbb{R}^{d_v \times d_h}$、$W_2 \in \mathbb{R}^{d_h \times d_{\mathrm{lm}}}$，$d_h$ 为连接器隐藏宽度，σ 是逐元素非线性激活，这里省略偏置。它能学习更灵活的逐位置变换，行数仍为 n_v，不会自动产生查询压缩。该式用于说明后续变体，原始论文的连接器应按式(11.24)理解。

将视觉向量与提示的文字嵌入沿序列方向拼接。若提示 q 有 n_q 个词元，文字嵌入为 $E(q) \in \mathbb{R}^{n_q \times d_{\mathrm{lm}}}$，一个简化上下文为

$$X_{\mathrm{ctx}} = \begin{bmatrix} B_v \\ E(q) \end{bmatrix} \in \mathbb{R}^{(n_v + n_q) \times d_{\mathrm{lm}}}. \tag{11.26}$$

X_{ctx} 包含视觉位置和文字位置，宽度统一为 d_{lm}。实际对话还含角色与分隔标记，图像向量在图像占位位置插入。视觉与文本不按坐标相加，语言模型通过后续注意力读取它们。

图11.3用三个视觉位置和两个提示位置画出序列。生成第一个回答词元时，它可以读取全部已知视觉与提示位置。训练时即使将整段真实回答同时送入网络，因果掩码仍禁止该位置读取自己的目标和后续回答。

11.4.2 两阶段训练怎样改变回答能力

第一阶段：学习视觉与语言的连接。 原始 LLaVA 冻结视觉编码器和语言模型，只训练线性投影。样本提供图像和配对描述，以描述的下一词元为目标。模型必须通过连接后的视觉向量提高真实描述的概率，才能让视觉输出进入语言模型可利用的输入范围。这一阶段更新少量参数，但同样需要保留通过冻结语言模型回到投影的输入梯度。

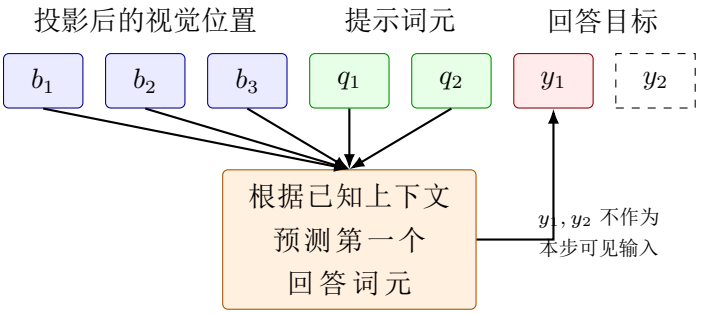


图 11.3： 视觉指令回答的上下文与目标。b_1, b_2, b_3 表示三行投影视觉向量，q_1, q_2 表示简化提示词元。箭头表示本步可读取的信息和预测输出。y_2 的虚线框表示未来目标，图中省略角色标记和内部注意力层。

第二阶段：学习按视觉指令回答。 继续冻结视觉编码器，训练连接层和语言模型。样本包含图像、用户问题或指令以及示范回答，可含多轮对话。回答损失使用式(11.22)的形式，将视觉条件 $B(v)$ 替换为 $B_v(v)$。计分位置来自助手回答，问题、角色标记和视觉前缀作为条件。损失掩码决定哪些位置计分，因果注意力掩码决定哪些位置可读取，两者作用不同。

原始工作利用语言模型根据图像描述与框等已有文本标注辅助构造视觉指令数据。这样的示范扩大了问答形式，但内容质量仍受标注覆盖和生成误差影响。若示范把没有证据的成因写成肯定结论，下一词元训练也会鼓励类似表达。指令微调学习示范中的响应方式，不直接给出事实正确性保证。

这与 BLIP-2 的两阶段训练有明确差异。BLIP-2 第一阶段训练查询提取，第二阶段连接冻结语言模型。原始 LLaVA 第一阶段训练投影，第二阶段同时调整语言模型来适应视觉指令。后续使用参数高效微调或不同冻结策略时，应单独说明实际更新范围。

11.4.3 同一张图为何能产生不同回答

考虑一张教学照片，人工标注确认其右侧有一条细长裂纹。输入“描述这张照片”时，示范可以要求概括可见物体和异常。输入“只回答是否

有裂纹”时，示范可以只输出“有”。输入“按现象和待确认信息回答，不推测成因”时，示范可以输出“现象：右侧可见细长裂纹。待确认：裂纹深度和形成原因”。这些是教学输出示例，不是模型实测结果。

三次输入使用相同视觉特征，不同提示改变语言上下文和后续条件概率。参数在推理期间固定。训练时真实回答前缀由数据提供，生成时则依次选词元、追加到上下文，再预测下一词元。若首句把划痕误写成裂纹，后续回答可能继续围绕这项错误组织解释。

幻觉（hallucination）在这里指生成了图像或已有证据不支持的内容。例如照片只显示表面，模型却给出“裂纹深度为两毫米”，既缺少深度观测，也缺少毫米尺度的依据。降低解码随机性不能补足这些输入。含有“不确定”示范可以训练相应行为，仍需验证模型是否在证据不足时实际使用它。

LLaVA 直接保留更多视觉位置，可能减少查询压缩造成的信息损失，但语言上下文更长。标准全局注意力对总序列长度的交互开销呈二次增长。保留位置也不保证细裂纹识别或准确定位，输入分辨率、特征提取、位置表示和监督粒度仍决定可用证据。注意力图不能直接替代真实框或像素标签。

11.4.4 用相同维度比较 BLIP-2 与 LLaVA

两种连接都从 H_v 出发，最终提供 d_{lm} 宽的语言输入。BLIP-2 先让查询读取视觉特征，输出行数由 m 控制。原始 LLaVA 逐行线性投影，输出行数仍为 n_v。前者在语言模型前压缩位置，后者将更多位置交给语言模型继续处理。

表11.1按相同维度总结已经解释的差异。可训练参数少、上下文短和任务效果好是不同结论，需要分别检查。

表 11.1: BLIP-2 与原始 LLaVA 的连接和训练差异

比较项	BLIP-2	原始 LLaVA
视觉连接	查询交叉读取，再投影	对每个视觉位置线性投影
语言输入	m 个查询前缀	n_v 个投影视觉位置
第一阶段	冻结视觉编码器，训练查询与文本路径	冻结视觉与语言模型，训练投影
第二阶段	视觉与语言模型均冻结，训练查询和投影	视觉编码器冻结，训练投影和语言模型
主要收益	控制视觉前缀长度，减少大模型权重更新	连接直接，通过指令数据调整响应方式
主要限制	查询压缩可能丢失细节	视觉位置多，语言上下文成本较高

11.5 典型应用怎样验证

11.5.1 先按输出形式选择评价对象

图文检索应检查相关候选是否进入前 k 个结果。k 是预先指定的返回数量，相关性由人工配对或任务标注确定。若一条描述对应多幅图像，应在评价中保留多重相关关系。训练批次的配对概率与全图库的检索效果不同，不能用低对比损失替代留出图库验证。

零样本分类应固定候选类别和提示模板，再在未用于选择提示的标注图像上统计准确率、各类召回和误报。细裂纹、反光、不同相机和类别之外的输入需分别检查。若使用目标域标签训练分类头，这就是有监督迁移，应与原来的零样本设置分开报告。

图像描述与视觉问答需要核对内容。可以把回答拆成可检验陈述，例如“有裂纹”“在右侧”“深度两毫米”，逐项检查图像或外部资料是否支持。还要统计应答覆盖：该回答是否遗漏了任务要求的可见现象。语言流畅度、示范词元损失和事实正确率分别评价不同对象。

视觉指令跟随还要检查格式和限制是否遵守。例如要求不推测成因时，

即使类别判断正确，添加未经证实的故障成因也不满足任务。位置回答则另用框、像素标注或约定的位置类别验收。模型名称和注意力可视化不能替代这些标签。

11.5.2 工业迁移：从巡检照片到报告草稿

考虑一个范围有限的应用：检索相似巡检照片，筛查表面缺陷，再草拟可见现象报告。CLIP 可先按描述检索图库或比较候选缺陷类别。需要文字描述时，可以评估 BLIP-2。需要用户指定字段或多轮追问时，可以评估 LLaVA。它们承担不同输出，不要求为了流程完整而全部部署。

验证集与测试集应按设备、生产批次或事件隔离。同一工件的近重复照片不能跨越训练与测试，提示、阈值和微调方案也不能在测试集上挑选。迁移时比较已有视觉分类器、CLIP 零样本结果和目标域微调结果，保持数据划分与标注定义一致，再记录可训练参数、视觉位置数和生成延迟。这样才能分辨收益来自新增监督、结构差异还是更多计算。

外部文字也要明确来源。有效手册可以支持报告中的规程说明，模型仍需按上一章的检索方式确认版本和适用条件。维修结论可以成为事后监督，预测时尚未形成的结论不能放进输入。沿用原有时间例子：10:00 诊断时，09:59:58 拍摄但 10:00:03 才到达的照片不可用。10:30 确认的类别可以作为历史样本标签，不能回填成 10:00 已知信息。

若额外接入振动或工艺曲线，需要为该联合任务提供对应数据和标签，图文预训练本身不建立传感器理解能力。假设一百个事件中图像分类答对八十个、振动分类答对七十五个，两个数不能推出融合会答对九十个。要逐事件比较错误是否互补，再与单模态和简单组合基线比较。照片缺失、模糊或两路信息冲突时还应分别测试，证据不足允许请求复检。

所有数值算例和问答示例用于解释机制，均不代表已完成的工业实验。报告草稿应保留图像来源与待确认信息，最终结论由独立证据和任务验收决定。

本章小结

CLIP 用配对索引训练两个独立编码器，在单位表示的共同空间中形成图文得分。对称损失同时训练图到文和文到图选择，推理只需编码和排序。它适合检索与零样本分类，缺少直接生成回答的路径。

BLIP-2 让少量可学习查询通过交叉注意力读取视觉特征，再将查询输出投影为语言模型的条件。其两阶段训练先学习视觉语言表示，再连接冻结语言模型。冻结权重保留了输入梯度，查询压缩则引入信息容量与上下文成本的折中。

LLaVA 将视觉位置投影到语言嵌入宽度，通过描述数据学习连接，再通过视觉指令数据调整连接层和语言模型。原始线性投影与后续 MLP 需要区分。它可以根据问题组织回答，回答是否忠于图像、是否准确定位仍要独立验证。

本章的生成是在已知图像条件下产生文字。下一章转向图像、波形等数据的生成，研究怎样从随机变量或噪声出发构造新样本，并检查所学分布与真实数据的关系。

辅助学习材料

- **CLIP 原始论文** [66]。对照双塔结构、批内对称损失和零样本分类，先重算本章两对样本，再查看论文中的真实配置与评价设置。
- **BLIP-2 原始论文** [51]。重点读 Q-Former、第一阶段三个目标的注意力掩码，以及第二阶段连接不同语言模型的方式。将论文中实际的查询数与本章教学维度区分。
- **Visual Instruction Tuning**[55]。对照原始线性连接、两阶段冻结范围和视觉指令数据构造。后续代码配置中的 MLP 不应反推成原始模型结构。
- **Contrastive Representation Learning**（Lilian Weng，英文教程）。复

习对比目标、温度与负样本选择，对照 CLIP 损失和假负例讨论。在线阅读。

- **Natural language image search with a Dual Encoder**（Keras，英文代码教程）。追踪双编码器、投影和检索计算。示例与 CLIP 的具体训练配置不同，运行前核对依赖版本。在线阅读。

第十二章　深度生成模型

本章摘要。本章围绕一个问题展开：如何让模型生成符合数据规律、又能用于具体任务的新样本？先区分采样、补全、去噪和条件生成，再以变分自编码器（VAE）、生成对抗网络（GAN）和扩散模型为里程碑，说明它们的生成机制、训练目标和典型失效方式。最后讨论任务选择、样本验证和工业使用边界。

生成模型不能替真实观测，也不能凭空证明罕见故障确实存在。它可以在数据稀缺时产生候选样本，补全缺失观测，或在给定工况下模拟可能的退化轨迹。合成数据是否有用，要在未参与训练和模型选择的真实数据上检验。

12.1　生成任务与概率建模目标

12.1.1　先确定要生成什么

假设 $x \in \mathbb{R}^D$ 是一个振动窗口，c 是转速、负载或故障类别等条件。深度生成模型常完成四类任务：

1. **无条件采样**：从学习到的分布中产生新的 x，例如模拟正常振动窗口。
2. **条件生成**：给定 c 产生 x，例如在指定转速下生成可能的波形。条件通常允许多个结果，不要求给定条件后输出唯一样本。
3. **补全与去噪**：给定部分观测、带噪观测或掩码，生成与已知信息一致的完整结果。
4. **表示学习**：把高维样本压缩为较低维的潜变量，供可视化、聚类或下游预测使用。

这些任务的共同对象是分布。若模型学习 $p_\theta(x)$，就可以从该分布采样；若学习 $p_\theta(x \mid c)$，就可以在条件 c 下采样。训练集是有限观测，不等于真实分布 p_{data}。连续变量的 $p_\theta(x)$ 是密度，某个区域的概率需要对密度积分。把所有样本都替换成均值，只能描述平均位置，不能再现波动、相关性和少数模式。

生成目标与判别目标不同。判别模型通常学习 $p(y \mid x)$ 或直接学习决策边界，生成模型还要描述 x 本身的变化。生成模型的训练损失也不自动等于任务评价指标。重构误差较小，不代表裂纹位置正确；样本看起来逼真，也不代表它覆盖了真实故障类型。

12.1.2 潜变量把随机性变成可采样结构

潜变量 z 是模型引入、但数据中没有直接观测的变量。一个常见生成方向是

$$z \sim p(z), \qquad x \sim p_\theta(x \mid z).$$

先抽取简单先验中的 z，再由解码器把它变成样本 x。例如，若 $z \sim \mathcal{N}(0,1)$ 且 $x \mid z \sim \mathcal{N}((z, 2z)^{\mathsf{T}}, \sigma_x^2 I)$，两个观测分量会因共享 z 而相关。观察到 x 后反推 z，对应后验 $p_\theta(z \mid x)$。

普通自编码器只要求编码器和解码器互相重构。它没有规定新样本应该从编码空间的哪里抽取。变分自编码器把潜变量先验、概率解码器和近似后验放在同一个目标中，从而得到可采样的表示。

12.2 VAE：用潜变量获得稳定采样

12.2.1 为什么需要变分近似

变分自编码器（Variational Autoencoder，VAE）用潜变量模型表示联合分布：

$$p_\theta(x, z) = p(z)p_\theta(x \mid z). \tag{12.1}$$

给定 x 后，真实后验满足

$$p_\theta(z \mid x) = \frac{p_\theta(x \mid z)p(z)}{p_\theta(x)}, \qquad p_\theta(x) = \int p_\theta(x \mid z)p(z)\,\mathrm{d}z.$$

分母通常无法解析计算。VAE 用编码器给出的 $q_\phi(z \mid x)$ 近似该后验，并最大化证据下界（Evidence Lower Bound，ELBO）：

$$\mathcal{L}(x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x \mid z)] - \mathrm{KL}(q_\phi(z \mid x)\|p(z)). \tag{12.2}$$

第一项要求抽到的 z 能够重构 x。第二项要求不同样本使用的潜变量仍接近先验，以便生成时直接从 $p(z)$ 抽样。

由 Jensen 不等式，

$$\log p_\theta(x) = \log \int q_\phi(z \mid x)\frac{p_\theta(x,z)}{q_\phi(z \mid x)}\,\mathrm{d}z \tag{12.3}$$

$$\geq \mathbb{E}_{q_\phi}[\log p_\theta(x,z) - \log q_\phi(z \mid x)] = \mathcal{L}(x). \tag{12.4}$$

更精确的关系是

$$\log p_\theta(x) - \mathcal{L}(x) = \mathrm{KL}\big(q_\phi(z \mid x)\|p_\theta(z \mid x)\big) \geq 0. \tag{12.5}$$

这里的两个 KL 项用途不同。式(12.2)中的 KL 比较近似后验与先验，最后一个等式中的 KL 衡量后验近似误差。KL 散度非负但通常不对称，也不是欧氏距离。

12.2.2 如何训练和采样

常用的近似后验为

$$q_\phi(z \mid x) = \mathcal{N}\big(\mu_\phi(x), \mathrm{diag}(\sigma_\phi^2(x))\big).$$

直接抽样会阻断对编码器参数的普通反向传播。重参数化把随机性移到与参数无关的 ϵ：

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I_d). \tag{12.6}$$

因此固定一次 ϵ 时，梯度可以通过 z 传回编码器。训练阶段给定 x，从 $q_\phi(z \mid x)$ 抽样并计算重构项。生成阶段没有 x，改为从 $p(z)$ 抽样，再交给解码器 $p_\theta(x \mid z)$。

若解码器采用 $p_\theta(x \mid z) = \mathcal{N}(\mu_\theta(z), \sigma_x^2 I)$，则

$$-\log p_\theta(x \mid z) = \frac{1}{2\sigma_x^2}\|x - \mu_\theta(z)\|_2^2 + \frac{D}{2}\log(2\pi\sigma_x^2).$$

所以均方重构项隐含了条件独立、同方差高斯噪声假设。它不一定适合少数但重要的冲击或裂纹像素。

当 q_ϕ 是对角高斯、$p(z) = \mathcal{N}(0, I)$ 时，KL 项为

$$\mathrm{KL}(q\|p) = \frac{1}{2}\sum_{j=1}^{d}(\mu_j^2 + \sigma_j^2 - \log\sigma_j^2 - 1).$$

例如一维情况下 $\mu = 1, \sigma = 1$ 时，KL 为 0.5。$\mu = 0, \sigma = 1$ 时 KL 为零，但这只说明两个分布相同，不说明重构准确。

12.2.3 VAE 的变体与典型问题

VAE 的主要折中是重构准确性与潜变量规整性。KL 权重过强时，编码器可能令 $q_\phi(z \mid x)$ 接近先验，潜变量几乎不再携带输入信息，这称为后验坍缩。KL annealing 逐渐增加 KL 权重，free bits 在小 KL 区间内减弱惩罚。它们改变优化折中，却不保证潜变量对应可解释的物理因素。

条件 VAE 将条件加入编码器和解码器，学习 $p_\theta(x \mid z, c)$。它适合需要连续潜在表示和条件采样的任务。VAE 往往生成较平滑的结果，因为重构目标会偏向条件平均。若细节和少数模式重要，应检查模式覆盖，而不能只增加潜变量维度。

12.3 GAN：追求逼真样本的对抗训练

12.3.1 判别器如何提供训练信号

生成对抗网络（Generative Adversarial Network，GAN）把采样器和判别器分开。生成器 $G:\mathbb{R}^d\to\mathbb{R}^D$ 把噪声 z 变成 $G(z)$，判别器 $D:\mathbb{R}^D\to(0,1)$ 估计输入来自真实数据的概率。训练时交替更新：判别器区分真实样本与合成样本，生成器则使合成样本更难被判别。采样时只需要生成器。

原始 GAN 目标为

$$\min_G \max_D \ \mathbb{E}_{x\sim p_{\text{data}}}\log D(x)+\mathbb{E}_{z\sim p(z)}\log(1-D(G(z))). \tag{12.7}$$

固定生成分布 p_g 时，逐点最优判别器为

$$D^*(x)=\frac{p_{\text{data}}(x)}{p_{\text{data}}(x)+p_g(x)}.$$

代回式(12.7)，理想情况下目标与

$$\mathrm{JSD}(p_{\text{data}}\|p_g)$$

相关，分布相同时达到最优。这个结论依赖判别器足够强、训练达到平衡以及分布可比较。有限数据和不充分优化会破坏这些条件。

12.3.2 逼真与覆盖为何会冲突

GAN 不需要显式计算 $p_g(x)$，因此可以把容量用于生成清晰样本。它的困难来自两个网络的交替博弈。判别器过强时，生成器获得的梯度可能饱和。不同噪声被映射到相似样本时，称为模式坍塌。生成结果可能很逼真，却遗漏罕见故障或某些工况。条件 GAN 可以把类别、工况或部分观测输入生成器和判别器，但条件一致性仍需单独验证。

GAN 适合采样速度要求高、且有足够样本支持目标分布的任务。它不提供像 VAE 那样直接的后验编码，也不直接给出可比较的显式似然。训练稳定性、模式覆盖和条件满足率应与样本质量一起报告。

12.4 扩散模型：逐步去噪成为当前主线

12.4.1 从一次生成改为多步恢复

扩散模型把困难的生成映射分成许多局部去噪任务。前向过程逐步破坏真实样本，反向网络学习在每个噪声尺度恢复结构。设 $x_0 \sim p_{\text{data}}$，$t = 1, \dots, T$，并令 $0 < \beta_t < 1$：

$$q(x_t \mid x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I). \tag{12.8}$$

记 $\alpha_t = 1 - \beta_t$、$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$，可直接得到

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, \qquad \epsilon \sim \mathcal{N}(0, I). \tag{12.9}$$

这里 t 是人为设定的噪声步，不是设备运行时间。训练时随机选 t 和 ϵ，所以不必真的执行完整的前向链。

例如 $x_0 = 2$、$\bar{\alpha}_t = 0.64$ 且 $\epsilon = 1$ 时，$x_t = 0.8 \times 2 + 0.6 \times 1 = 2.2$。网络看到 x_t 和 t，不知道 x_0。它要学习的是在给定噪声状态下最有用的恢复方向。

12.4.2 噪声预测与反向采样

噪声预测网络记为 $\epsilon_\theta(x_t, t)$，常用训练目标为

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right]. \tag{12.10}$$

平方损失的最优函数是条件均值：

$$\epsilon_\theta^*(x_t, t) = \mathbb{E}[\epsilon \mid x_t, t].$$

由式(12.9)，可以得到干净样本估计

$$\widehat{x}_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

当 $\bar{\alpha}_t$ 很小时，噪声预测误差会被放大。这说明高噪声阶段影响采样稳定性。

采样从 $x_T \sim \mathcal{N}(0, I)$ 开始，再按 $t = T, T-1, \ldots, 1$ 反向计算。以去噪扩散概率模型（Denoising Diffusion Probabilistic Model，DDPM）的一种参数化为例，

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right), \tag{12.11}$$

$$x_{t-1} = \mu_\theta(x_t, t) + \sqrt{\widetilde{\beta}_t}\, \zeta_t, \tag{12.12}$$

其中 $\zeta_t \sim \mathcal{N}(0, I)$ 是反向步骤重新抽取的噪声。多步随机性使模型能够表达多个可能结果。一次计算 $\widehat{x}_0$ 不等于执行完整反向采样。

完整的变分目标包含前向后验与反向转移之间的 KL 项。常用的噪声均方误差是经过参数化和权重处理后的简化目标，不能与完整变分目标逐项等同。噪声预测、x_0 预测和速度预测改变梯度尺度与采样表现，但共享逐步去噪框架。

12.4.3 条件控制与扩散模型的变体

给定条件 c 时，网络写成 $\epsilon_\theta(x_t, t, c)$。无分类器引导让同一网络同时学习有条件和无条件预测，并组合为

$$\widehat{\epsilon} = \epsilon_\theta(x_t, t, \varnothing) + w \left[\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \varnothing) \right]. \tag{12.13}$$

w 越大，条件方向通常越强，但多样性可能下降并产生伪影。边缘、深度、掩码或几何信息也可以作为条件输入。条件输入不自动保证物理可行性。

去噪扩散隐式模型（Denoising Diffusion Implicit Model，DDIM）使用不同的反向轨迹减少采样步数。潜空间扩散先把数据压缩到潜空间，再在潜空间进行扩散，降低高分辨率任务的计算量。这些变体改变采样速度或计算位置，没有消除条件一致性和压缩损失的验证要求。

12.5 任务选择与验证边界

VAE、GAN 和扩散模型解决的是不同的计算折中。需要连续潜变量、补全或稳定编码时，VAE 的后验结构较直接。需要快速采样且主要关注视觉或波形逼真度时，可以考虑 GAN，但必须检查模式坍塌。需要复杂条件控制、较好的覆盖性和高质量样本时，扩散模型通常更合适，但采样成本较高。若任务要求显式似然、可逆映射或异常分数，还需要单独评估其他密度建模方法，不能从上述模型的采样质量推断得到。

工业应用至少要检查四类性质：

1. **真实性**：边缘分布、相关性、频谱或缺陷几何是否接近真实数据。
2. **覆盖性**：不同设备、工况和故障类型是否都出现，而不是重复少数模板。
3. **条件与物理一致性**：生成结果是否符合输入条件、守恒关系、边界条件和状态转移约束。
4. **下游价值**：加入合成数据后，独立真实测试集上的召回、误报和校准是否改善。

约束可以加入生成损失，例如

$$\mathcal{L} = \mathcal{L}_{\text{gen}} + \lambda_{\text{phys}} \mathbb{E}[\|r(x, c)\|_2^2], \tag{12.14}$$

其中 r 是物理残差。惩罚过弱会产生不可行样本，过强则可能损害分布覆盖。应分别报告真实性、多样性和约束违反率。

生成数据还可能记住训练集中的罕见记录，或改变真实故障的先验比例。测试集必须保持真实、独立，并且不能参与生成模型训练或选择。评价时应与“只用真实数据”的基线比较，匹配训练预算，并在不同随机种子、设备和故障类型上重复。生成样本的数量增加、训练损失下降或单张图片更清晰，都不能单独证明下游收益。

辅助学习材料

- **What are Diffusion Models?**；作者/平台：Lilian Weng；英文技术教程。可对照前向加噪、反向去噪、条件引导和潜空间扩散。在线阅读。
- **From Autoencoder to Beta-VAE**；作者/平台：Lilian Weng；英文技术教程。可对照 VAE、ELBO 和重参数化。在线阅读。
- **第六节 2021–生成式对抗网络**；作者/平台：李宏毅；中文课程。可对照 GAN 的生成器、判别器和训练过程。观看分集。

本章小结。 生成任务首先要明确输出分布和条件。VAE 通过潜变量和 ELBO 获得可采样表示，GAN 通过判别器追求逼真但容易训练不稳定和模式坍塌，扩散模型通过多步去噪处理复杂分布并提供条件控制。模型选择不能只看样本外观。真实性、覆盖性、条件与物理一致性，以及独立真实数据上的下游结果共同决定生成模型是否适用。

第十三章　物理信息神经网络与风场重建

本章摘要。激光雷达只能测到少量位置、特定方向上的风速，我们却希望知道一片区域中的风怎样变化。物理信息神经网络（Physics-Informed Neural Network，PINN）把测量数据和流体方程一起用于训练，为这一问题提供了一种求解方法。本章先通过手算例子说明训练过程，介绍 PINN 的通用框架与正、逆问题，再讨论雷达观测、风场方程和损失函数，结合具体论文理解风场重建，最后介绍训练与模型的优化方向。

想象风机前方有一片随时间变化的风场。激光雷达沿几条波束测量风速，得到的是分散的读数。而风机控制和风场分析希望知道区域内各处的速度和方向。根据这些有限读数补出连续风场，就是本章要讨论的任务。

如果只按测量值做插值，结果主要取决于测点的位置和插值规则。流体力学还提供了另一类信息：相邻位置、相邻时刻的速度应当遵循质量守恒和动量变化规律。PINN 用神经网络表示风场，同时用数据和方程来调整这个网络 [41, 69]。

本章以二维风场为主，先把方法的计算过程讲清楚。这里的二维风场指某个平面内的两个速度分量，记为 $u(x, y, t)$ 和 $v(x, y, t)$。学会这个例子后，再把空间坐标和速度分量扩展到三维，会更容易理解。

13.1 先用一个小例子理解 PINN

13.1.1 网络表示的是一个可以查询的函数

先把要求解的未知函数记为 q。如果它只有一个自变量 x，就可以让网络接收 x，输出这个位置的函数值：

$$q_\theta(x) = F_\theta(x). \tag{13.1}$$

下标 θ 表示网络中需要学习的权重和偏置。训练就是调整这些参数，使网络表示的函数接近我们要求的解。训练完成后，给定一个 x，就能查询对应的 $q_\theta(x)$。

如果未知函数还随时间变化，输入就增加时间 t。如果要同时求解几个物理量，输出就增加相应分量。先从一个只有 x 的例子开始，便于看清方程怎样参与训练。

13.1.2 把方程变成可以计算的误差

先暂时离开风场，考虑一个只有一个自变量的方程：

$$q'(x) + q(x) = 0, \qquad q(0) = 1, \qquad 0 \le x \le 1. \tag{13.2}$$

这个方程的解是 $q(x) = e^{-x}$。这里假设我们还不知道解，想通过训练找到它。

为方便手算，先用一条直线 $q_{a,b}(x) = ax + b$ 近似这个函数，a, b 就是待学习参数。它对坐标的导数是 $q'_{a,b} = a$。把直线代入方程左侧，得到

$$r(x) = q'_{a,b}(x) + q_{a,b}(x) = a + ax + b.$$

这个 $r(x)$ 叫作**方程残差**，表示当前函数与方程要求的差距。我们希望它在区间内尽量接近零。

先选 $x=0,1$ 两个位置检查方程，再检查 $q(0)=1$ 这个条件。将误差平方后相加，得到损失函数

$$\mathcal{L}(a,b)=\frac{1}{2}\left[(a+b)^2+(2a+b)^2\right]+(b-1)^2. \tag{13.3}$$

前面两项检查方程，最后一项检查 $x=0$ 处的函数值。像 $x=0,1$ 这样用来计算方程残差的位置，称为**配点**。选择配点只需要坐标，这些位置不必有真实函数值标签。

从 $a=0,b=1$ 开始，当前函数是 $q(x)=1$。它在 $x=0$ 处满足给定条件，但两个位置的方程残差都是 1，总损失为 1。此时

$$\frac{\partial\mathcal{L}}{\partial a}=3,\qquad \frac{\partial\mathcal{L}}{\partial b}=2.$$

取学习率 0.1，沿减小损失的方向更新一次：

$$a\leftarrow 0-0.1\times 3=-0.3,\qquad b\leftarrow 1-0.1\times 2=0.8.$$

新函数为 $q(x)=-0.3x+0.8$。两个位置的残差变为 0.5 和 0.2，总损失下降到

$$\frac{1}{2}(0.5^2+0.2^2)+(0.8-1)^2=0.185.$$

这就完成了一次训练：先计算函数和导数，再算残差与损失，最后更新参数。实际 PINN 用多层神经网络代替这条直线，重复同样的过程，逐渐得到更合适的函数。

13.1.3 两次求导分别在做什么

上面的计算中出现了两种导数。对坐标 x 求导，得到 $q'(x)$，用来检查方程。对参数 a,b 求导，得到损失的下降方向，用来更新模型。风场 PINN 也是这样：先计算速度对位置、时间的导数，再计算损失对网络参数的导数。

自动微分就是由程序按照链式法则完成这些求导。只要网络的计算过程由可求导的运算组成，就可以从输出追踪到输入，计算 $\partial_x u$、$\partial_t u$ 等量。

可以先把它理解为训练框架提供的一套求导工具，后续实现时再学习具体接口。

13.1.4 同一套流程可以用于哪些问题

手算例子中的关键步骤是：用一个可学习函数表示未知量，把它代入方程形成残差，再结合已知条件计算损失、更新参数。PINN 的通用性就体现在这套流程可以用于不同的方程和物理系统 [69, 93]。

换一个任务时，先回答三个问题：**输入哪些坐标，输出哪些未知量，用什么方程检查它们？**表13.1列出几个例子。稳态问题可以只输入空间坐标，随时间演化的问题则加入 t。输出既可以是一个温度，也可以是多个速度分量和压力。

表 13.1: 不同任务中的 PINN 输入、输出与方程。这里以一维传热、波动和二维流动为例。

任务	输入	输出	用于训练的方程
本章手算例子	x	q	$q' + q = 0$
一维热传导	(x, t)	温度 T	$\partial_t T - \kappa \partial_{xx} T = 0$
一维波动	(x, t)	位移 s	$\partial_{tt} s - c^2 \partial_{xx} s = 0$
二维风场	(x, y, t)	u, v, π	连续性与动量方程

例如，把未知量换成温度 $T(x, t)$，建立网络 $T_\theta = F_\theta(x, t)$，再按热传导方程计算

$$r_T(x, t) = \partial_t T_\theta - \kappa \partial_{xx} T_\theta. \tag{13.4}$$

κ 是热扩散系数。这里的 r_T 与手算例子的 $r = q' + q$ 承担相同作用，都是检查当前函数与方程要求的差距。热传导中还可以给出初始温度、两端的温度或热流条件，把这些条件也写成误差项。

更一般地，可以用 $\mathcal{N}[q; \mu] = 0$ 概括要满足的方程。其中，$\mathcal{N}$ 表示方程中的求导和组合运算，μ 表示方程参数，例如热扩散系数 κ 或波速 c。确定任务后，就按相应方程构造残差，结合已知条件和可用观测形成损失。神经

网络表示函数、自动微分计算导数、优化器更新参数的基本过程保持一致。

13.1.5 正问题、逆问题与本章的风场重建

正问题：已知模型与条件，求物理场。 例如已知材料的热扩散系数、初始温度和两端条件，希望求出之后各处的温度。训练时使用给定方程和这些条件，在内部配点上检查残差，最后查询网络得到温度分布。这类任务称为正问题。

逆问题：利用观测，推断未知场或参数。 例如已经测到少量位置的温度，希望估计材料的热扩散系数。可以将 κ 与网络权重一起作为待学习参数，用测量误差和方程残差共同训练。观测来自哪里、测到了什么，就通过相应的观测关系写入损失 [69]。

本章关心的是另一类逆问题：从少量雷达读数恢复未测位置的速度场。网络以时空坐标为输入，一种常见的输出形式是

$$(u_\theta, v_\theta, \pi_\theta) = F_\theta(x, y, t). \tag{13.5}$$

u, v 是两个速度分量，$\pi = p/\rho$ 是压力除以空气密度得到的量。压力与速度变化通过动量方程联系，因此也可以作为网络需要学习的未知场。测量数据通过训练时的误差参与学习，训练后的网络则可以在整个区域内查询。

从这里开始，我们把通用框架中的未知函数换成风场，依次弄清雷达测到了什么、流体方程怎样写、两类信息怎样一起训练网络。

13.2 激光雷达给了我们什么数据

13.2.1 径向速度是风速在波束方向上的投影

二维速度记为 $\mathbf{u} = (u, v)^\top$。设一条波束与 x 轴的夹角为 α，方向向量是 $\mathbf{e} = (\cos\alpha, \sin\alpha)^\top$，理想点测量可写成

$$y_{\mathrm{LOS}} = \mathbf{e}^\top \mathbf{u} = u\cos\alpha + v\sin\alpha. \tag{13.6}$$

LOS 是 line of sight 的缩写，表示视线方向。测量值也称径向速度。

例如某处的速度为 $(u, v) = (3, 4)\,\mathrm{m/s}$。沿 x 方向的波束测到 $3\,\mathrm{m/s}$，沿 y 方向的波束测到 $4\,\mathrm{m/s}$，而风速大小为 $\sqrt{3^2 + 4^2} = 5\,\mathrm{m/s}$。建立数据损失时，要先把网络预测的速度投影到波束方向，再与仪器读数比较。

若同一位置、同一时刻有两个不平行方向的测量，就能联立两个投影关系求解 u, v。实际扫描中的不同波束通常经过不同位置，此时可以借助流体方程把分散的观测联系起来。后面的论文案例展示的就是这种做法。

13.2.2 一条训练样本包含哪些信息

一条二维雷达观测可以整理为

$$(x_m, y_m, t_m, \alpha_m, y_m^{\mathrm{LOS}}).$$

它依次记录测点位置、测量时间、波束方向和径向速度。训练时，将 (x_m, y_m, t_m) 送进网络得到 u_θ, v_θ，再用 α_m 计算预测的径向速度。

可以把投影计算统一写成 $\widehat{y}_m = \mathcal{H}_m[\mathbf{u}_\theta]$。符号 $\mathcal{H}_m$ 叫作**观测算子**，可以理解为“把预测风场转换成第 m 条仪器读数的计算规则”。对于式(13.6)，它就是一次投影。

实际雷达的一个距离门会覆盖一定长度，测量过程还可能包含时间平均。需要描述这些效应时，可以在若干位置和时刻查询网络，再加权求和：

$$\widehat{y}_m = \sum_{a=1}^{A_m} \omega_{ma}\, \mathbf{e}_{ma}^{\top} \mathbf{u}_\theta(\mathbf{x}_{ma}, t_{ma}), \qquad \sum_{a=1}^{A_m} \omega_{ma} = 1. \tag{13.7}$$

A_m 是求和使用的点数，ω_{ma} 是权重。第一次学习时，可以先掌握点投影，再根据仪器的距离门设置扩展这一步 [76]。

数据整理时，先统一坐标轴、角度定义、速度正负号和时间单位。例如仪器方位角可能从北方向起算，而模型中的角度从 x 轴起算，转换后才能使用同一条投影公式。

13.3 用流体方程描述风速怎样变化

13.3.1 连续性方程：检查局部的流入和流出

先考虑恒密度、不可压缩的二维流动，其连续性方程为

$$\frac{\partial u}{\partial x}+\frac{\partial v}{\partial y}=0. \tag{13.8}$$

可以在风场中想象一个很小的方框。空气从方框的一边进入，从另一边流出。在密度近似不变的情况下，各边流量需要平衡。式(13.8)表达的就是这种局部平衡。

其中 $\partial_x u$ 描述 u 沿 x 方向的变化率，$\partial_y v$ 描述 v 沿 y 方向的变化率。将网络预测代入方程左侧，得到连续性残差

$$r_c=\partial_x u_\theta+\partial_y v_\theta.$$

训练时让 r_c 接近零，就在推动预测风场满足这一平衡关系。

13.3.2 动量方程：联系速度变化、压力和黏性

连续性方程回答的是“空气的流入和流出怎样平衡”。接下来还要回答：**空气为什么会加速、减速或改变方向？**这就需要动量方程。

先把一小团空气想成一个正在运动的物体。牛顿第二定律告诉我们，物体受到合力就会产生加速度。对空气也是如此：周围的压力和黏性作用会改变它的速度。把牛顿第二定律用于流体，并除以这团空气的质量，就得到“加速度等于单位质量所受的合力”这样的关系。

在本章恒密度、不可压缩的二维模型中，暂不加入重力等体积力，Navier–Stokes 动量方程可以展开为

$$\partial_t u+u\partial_x u+v\partial_y u=-\partial_x \pi+\nu(\partial_{xx}u+\partial_{yy}u), \tag{13.9}$$

$$\partial_t v+u\partial_x v+v\partial_y v=-\partial_y \pi+\nu(\partial_{xx}v+\partial_{yy}v). \tag{13.10}$$

这里 ν 是运动黏度，单位为 m^2/s。$\pi = p/\rho$，p 是压力，ρ 是空气密度。两行方程分别描述 x、y 方向的运动。先读第一行，可以把它概括为

$$\underbrace{\partial_t u + u\partial_x u + v\partial_y u}_{\text{跟着空气团看到的加速度}} = \underbrace{-\partial_x \pi}_{\text{压力作用}} + \underbrace{\nu(\partial_{xx} u + \partial_{yy} u)}_{\text{黏性作用}}.$$

等号两边的单位都是 $\mathrm{m/s}^2$。下面逐步说明这三个部分。

左边：为什么加速度要写成三项？ $u(x, y, t)$ 描述每个位置、每个时刻的 x 方向速度。其中 $\partial_t u$ 表示固定位置的速度随时间变化有多快，$\partial_x u$ 和 $\partial_y u$ 则表示同一时刻不同位置之间的速度差异。前者像把风速仪固定在一点，连续记录读数。后两者像在不同位置放置风速仪，比较同一时刻的读数。

如果跟着一团空气移动，就要同时考虑时间和位置的变化。在很短的 Δt 内，它沿 x 方向移动约 $u\Delta t$，沿 y 方向移动约 $v\Delta t$。因此，它的 x 方向速度变化可以近似写成

$$\Delta u \approx \partial_t u\, \Delta t + \partial_x u\, (u\Delta t) + \partial_y u\, (v\Delta t).$$

两边除以 Δt，再让时间间隔趋近于零，就得到第一行左侧的三个加速度项。它们合起来称为 u 的**物质导数**，常记为 Du/Dt。其中 $u\partial_x u + v\partial_y u$ 称为**对流项**，记录空气移动到新位置时，空间速度差异带来的变化。

图13.1展示了一种容易混淆的情形：各个固定位置的风速都不随时间变化，但越往右风速越大。固定的风速仪读数不变，沿流动方向移动的空气团却会逐渐变快。例如，在某一点 $u = 4\,\mathrm{m/s}$、$\partial_x u = 0.05\,\mathrm{s}^{-1}$，仅 $u\partial_x u$ 这一项就贡献了 $0.2\,\mathrm{m/s}^2$ 的加速度。这解释了为什么只用 $\partial_t u$ 还不足以描述空气团的加速度。

右边第一项：压力差怎样推动空气？ 可以想象这团空气的左、右两侧都受到周围空气的挤压。如果左侧压力较高、右侧较低，向右的推动就更强，空气会获得向右的加速度。此时压力沿 x 方向下降，$\partial_x p < 0$，所以 $-\partial_x \pi > 0$，正好表示向右的作用。除以密度，是把单位体积的压力作用换成单位质量对应的加速度。

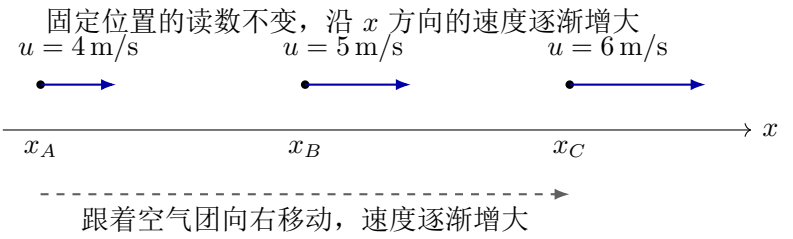


图 13.1： 固定位置的变化与跟随空气团的变化。实线箭头表示同一时刻各处的 x 方向速度，黑点标出测量位置。虚线箭头表示空气团的移动方向，数字为教学示例。

右边第二项：黏性为什么与速度的二阶导数有关？ 相邻空气层的速度不同时，会通过黏性作用交换动量。较快的空气层会带动较慢的层，自己也会受到减速作用，整体效果是使速度差异逐渐变得平缓。ν 表示这种动量扩散的强弱。

二阶导数 $\partial_{xx}u + \partial_{yy}u$ 描述速度分布在两个方向上的弯曲程度。例如，只看沿 y 方向的速度剖面，在一个局部速度峰顶附近，$\partial_{yy}u < 0$，黏性项倾向于降低这个峰值。在局部低谷附近，$\partial_{yy}u > 0$，它则倾向于抬高低谷。这样就能把“平滑速度差异”与公式中的二阶导数联系起来。

第二行按同样的方式理解：跟着空气团观察 y 方向速度 v 的变化，右边由 y 方向的压力差和黏性作用提供加速度。**连续性方程检查流量平衡，两个动量方程检查速度变化与受力是否匹配。**这三条方程共同构成本章用于训练风场的物理关系。

和手算例子一样，把所有项移到左边，就能得到两个动量残差：

$$r_u = \partial_t u_\theta + u_\theta \partial_x u_\theta + v_\theta \partial_y u_\theta + \partial_x \pi_\theta - \nu(\partial_{xx} u_\theta + \partial_{yy} u_\theta), \tag{13.11}$$

$$r_v = \partial_t v_\theta + u_\theta \partial_x v_\theta + v_\theta \partial_y v_\theta + \partial_y \pi_\theta - \nu(\partial_{xx} v_\theta + \partial_{yy} v_\theta). \tag{13.12}$$

三种残差都可以在区域内部的配点上计算。观测点负责告诉网络“这里测到了多少”，配点则负责检查“这里的变化是否符合方程”。

13.3.3 初值、边界与尺度

初始条件描述开始时刻的状态，例如 $t=0$ 时的速度分布。**边界条件**描述区域边缘的状态，例如入口风速或地表条件。在实际重建中，先整理能获得的入口、初始场等信息，再把它们写成相应误差项。论文案例采用的具体损失会在第13.5节说明。

风场中的坐标可能是几百米，时间是几十秒，速度是几米每秒。训练前通常先选择长度尺度 L_0 和速度尺度 U_0，把各变量换成相对大小：

$$x^*=\frac{x}{L_0},\quad y^*=\frac{y}{L_0},\quad t^*=\frac{tU_0}{L_0},\qquad u^*=\frac{u}{U_0},\quad v^*=\frac{v}{U_0},\quad \pi^*=\frac{\pi}{U_0^2}. \tag{13.13}$$

这一步称为**无量纲化**。例如 $U_0=10\,\mathrm{m/s}$ 时，$u=3\,\mathrm{m/s}$ 变成 $u^*=0.3$。训练时预测和观测使用同一套尺度，输出结果时再换回米、秒和米每秒。

换成无量纲坐标后，方程中的黏度系数变为 $1/\mathrm{Re}$，其中 $\mathrm{Re}=U_0L_0/\nu$ 是雷诺数。它由所选尺度和黏度共同确定。实现时可直接对无量纲坐标求导，使用无量纲方程计算残差。

本章的二维模型用于学习基本流程。三维重建时，网络输入扩展为 (x,y,z,t)，速度增加 w 分量，连续性方程相应增加 $\partial_z w$。若研究时间平均风场，还需要考虑湍流脉动对平均流动的影响，常通过湍流模型来描述。后续深入流体建模时再展开这一部分。

13.4 把数据和方程放进同一次训练

13.4.1 两条计算路径汇入一个损失

图13.2展示了风场 PINN 的主要计算过程。网络先根据坐标给出速度和压力，然后分别计算径向速度误差与方程残差，最后合成损失来更新同一组网络参数。

为了计算二阶导数，网络通常选用平滑激活函数，如 tanh。第一次实现时，可以先从普通全连接网络开始，把观测投影和方程残差这两条路径

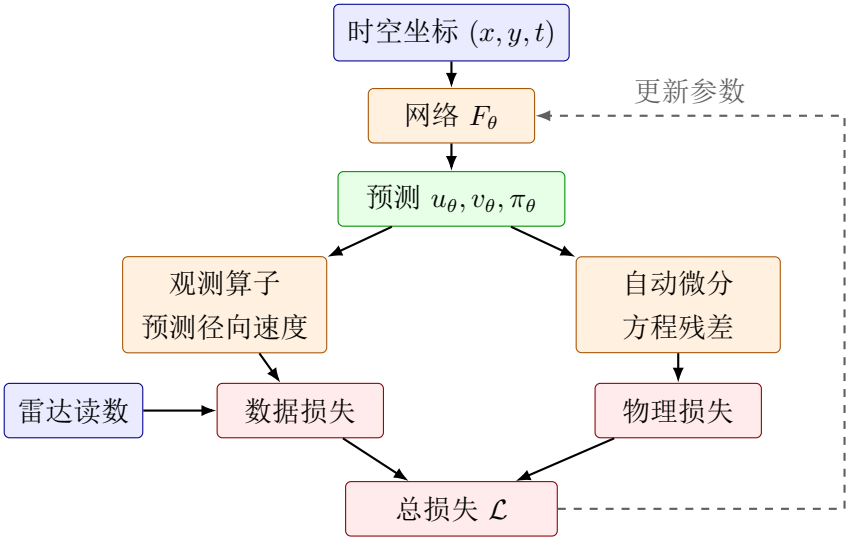


图 13.2: 风场 PINN 的计算路径。实线表示预测量和误差的计算，虚线表示根据总损失更新网络参数。可用的初值、边界信息也可形成损失项，一起加入总损失。

分别检查清楚。

13.4.2 数据损失检查预测与测量是否接近

在第 m 条观测的位置查询网络，用观测算子计算 $\widehat{y}_m$，再与实测径向速度 y_m 比较。若以 U_0 缩放速度，数据损失可写成

$$\mathcal{L}_d = \frac{1}{N_d} \sum_{m=1}^{N_d} \left(\frac{\widehat{y}_m - y_m}{U_0} \right)^2 . \tag{13.14}$$

N_d 是观测条数，平均平方误差越小，预测读数与实际读数越接近。例如实测值是 $3\,\mathrm{m/s}$、预测值是 $2.8\,\mathrm{m/s}$，两者先在相同单位下相减，再除以速度尺度。

13.4.3 物理损失检查预测是否符合方程

用 $\overline{r}_c, \overline{r}_u, \overline{r}_v$ 表示无量纲方程残差。在 N_f 个配点上计算

$$\mathcal{L}_f = \frac{1}{N_f} \sum_{j=1}^{N_f} \left[\overline{r}_c(\boldsymbol{\xi}_j)^2 + \overline{r}_u(\boldsymbol{\xi}_j)^2 + \overline{r}_v(\boldsymbol{\xi}_j)^2 \right], \tag{13.15}$$

其中 $\boldsymbol{\xi}_j = (x_j^*, y_j^*, t_j^*)$ 是一个配点。这里与手算例子的做法相同，只是从一条方程扩展到了连续性和两个动量方程。

如果从有量纲残差出发，也可以用 $\overline{r}_c = (L_0/U_0) r_c$、$\overline{r}_u = (L_0/U_0^2) r_u$ 和 $\overline{r}_v = (L_0/U_0^2) r_v$ 得到相同的尺度处理。

若已知边界或初始状态，还可以计算边界损失 $\mathcal{L}_b$ 和初值损失 $\mathcal{L}_i$。一个常见的总损失为

$$\mathcal{L} = \lambda_d \mathcal{L}_d + \lambda_f \mathcal{L}_f + \lambda_b \mathcal{L}_b + \lambda_i \mathcal{L}_i. \tag{13.16}$$

各个 λ 是权重，用来调整训练对不同误差的重视程度。先把各项缩放到合适的量级，再观察数据误差和方程残差怎样下降，会更容易判断权重是否合适。

13.4.4 一次训练和一张风场图怎样得到

训练通常从随机网络参数开始。每一步抽取观测点和配点，分别计算两类误差，用 Adam 等优化器更新参数，然后重复。训练过程中分别查看各项损失，能帮助定位投影、求导或尺度处理中的问题。

例如想画 $t = 50\,\mathrm{s}$ 时的风场，就把这个时刻与网格上的各个 (x_i, y_i) 组合起来，逐点或成批送入网络。得到 u_i, v_i 后，计算风速大小 $V_i = \sqrt{u_i^2 + v_i^2}$，用颜色展示，同时用箭头表示速度方向。这样就从一组稀疏读数得到了可查看的空间分布。

检查效果时，既看训练误差，也与留出的观测或参考风场比较。数据损失回答“雷达读数是否拟合得好”，参考风场对比则帮助我们查看未测区域和各个速度分量的重建效果。

Algorithm 1 从稀疏雷达观测训练风场 PINN

Require: 测点坐标、时间、波束方向、径向速度，以及选定的流体方程

统一坐标与单位，对坐标和速度做无量纲化
建立网络，在重建区域内准备配点
for 每一步训练 **do**
    从观测中取一批样本，计算预测的径向速度和数据损失
    从配点中取一批坐标，自动微分计算方程残差和物理损失
    加入可用的边界、初值误差，计算总损失
    根据总损失更新网络参数
end for
固定一个查询时刻，在空间网格上查询网络
恢复物理单位，绘制速度分量、风速大小或风向

13.5 论文案例：两束激光雷达怎样重建风机前方的风场

13.5.1 先看任务、测点与参考风场

Zhang 和 Zhao 在 2021 年的研究中，将 PINN 用于风机前方的时空风场重建 [96]。他们关注轮毂高度处的水平面，希望从两束激光雷达的径向速度，得到整个平面内的顺风速度 u 和横风速度 v。

图13.3摘录了论文的测量布置。图 A 中，安装在风机上的雷达向上游发出两束激光，夹角为 30°，每束相对中心方向偏转 15°。叉号表示测点，蓝色区域是希望恢复风场的平面。图 B 是左右波束在不同测点得到的径向风速时间序列。训练数据是这些分散位置上的曲线，重建目标是整片区域随时间变化的速度分布。

研究使用 SOWFA 大涡模拟生成风场：先模拟三维大气边界层，再取轮毂高度处的二维切片作为参考。从两束波束经过的位置提取速度，投影后得到模拟雷达读数。训练时使用这些径向读数，完整切片用于对比重建

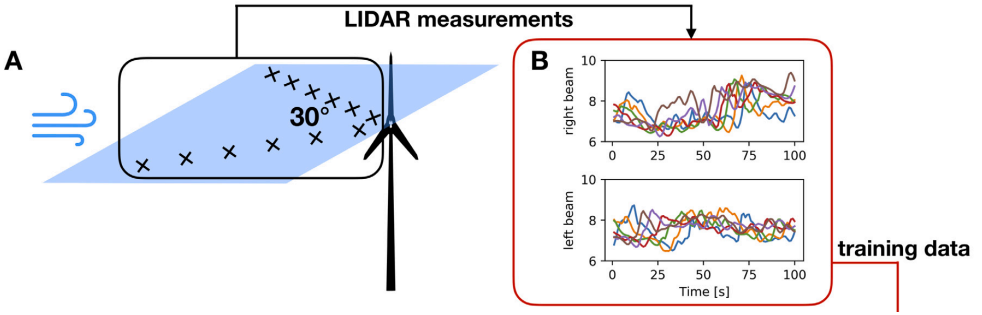


图 13.3: 双波束激光雷达的测量布置与径向速度记录。A 为测量几何，B 为各测点的时间序列。摘自 Zhang 和 Zhao[96] 原文图 1(A、B)，保留原图标注。

结果。这种数据组织使我们既有稀疏观测，也有可逐点比较的参考风场。

论文中用于重建的区域为 $x \in [-240, 0]\,\mathrm{m}$、$y \in [-60, 60]\,\mathrm{m}$，时间窗为 0 到 100 s。表13.2列出了基准算例的主要设置。

表 13.2: 论文基准算例的主要设置，整理自原文第 2.3、3.2 节与表 2[96]。

项目	设置
平均来流与湍流强度	8 m/s，自由来流湍流强度 6%
雷达波束	两束，半夹角 15°，测量范围 220 m
空间与时间采样	每束 11 个测点，相邻测点相距 20 m，每秒测量一次
基准测量噪声	不添加噪声
网络	含输入、输出在内共 12 层，隐藏层宽度 128，tanh 激活
优化器与学习率	Adam，10^{-4}
每步训练样本	物理配点 1000 个，左右波束观测各 1100 条

这里的“1100 条观测”统计的是位置与时间的组合。每束只有 11 个空间测点，但连续测量后，每个测点都会形成一条时间序列。论文还在 $81 \times 41 \times 101$ 的时空网格上准备配点坐标，每一步从中抽取一批来计算方程残差。

13.5.2 网络为什么先输出流函数和压力

这个案例的基础网络输出**流函数** ψ 和压力，再通过求导得到速度。为沿用本章符号，将论文的无量纲压力 p 记为 π，把网络写成

$$(\psi_\theta, \pi_\theta) = F_\theta(x, y, t). \tag{13.17}$$

本小节及后续案例公式中的坐标、时间和输出均已无量纲化。论文选择风机直径 D 作为长度尺度、平均来流速度 U_∞ 作为速度尺度，时间尺度就是 D/U_∞。

流函数可以看成一个用于生成速度的辅助函数。按照论文原文式 (3)，由它计算

$$u_\theta = \frac{\partial \psi_\theta}{\partial y}, \qquad v_\theta = -\frac{\partial \psi_\theta}{\partial x}. \tag{13.18}$$

这样做的好处是，连续性方程会自动满足：

$$\partial_x u_\theta + \partial_y v_\theta = \partial_x \partial_y \psi_\theta - \partial_y \partial_x \psi_\theta = 0.$$

例如取 $\psi = 2y$，就得到均匀速度 $u = 2, v = 0$。再把 ψ 换成可以学习的复杂函数，就能表示随空间、时间变化的速度分布，同时保留上述连续性关系。

图13.4摘录了论文的网络结构。灰色 DNN1 表示基础网络，输出 ψ, p。绿色 DNN2 通过自动微分得到 u, v，再通过 f_1, f_2 得到左右波束的径向速度。粉色 DNN3 进一步计算动量方程残差。图中的三个 DNN 名称对应同一组可训练参数在不同计算步骤中的用法，训练时一起更新。

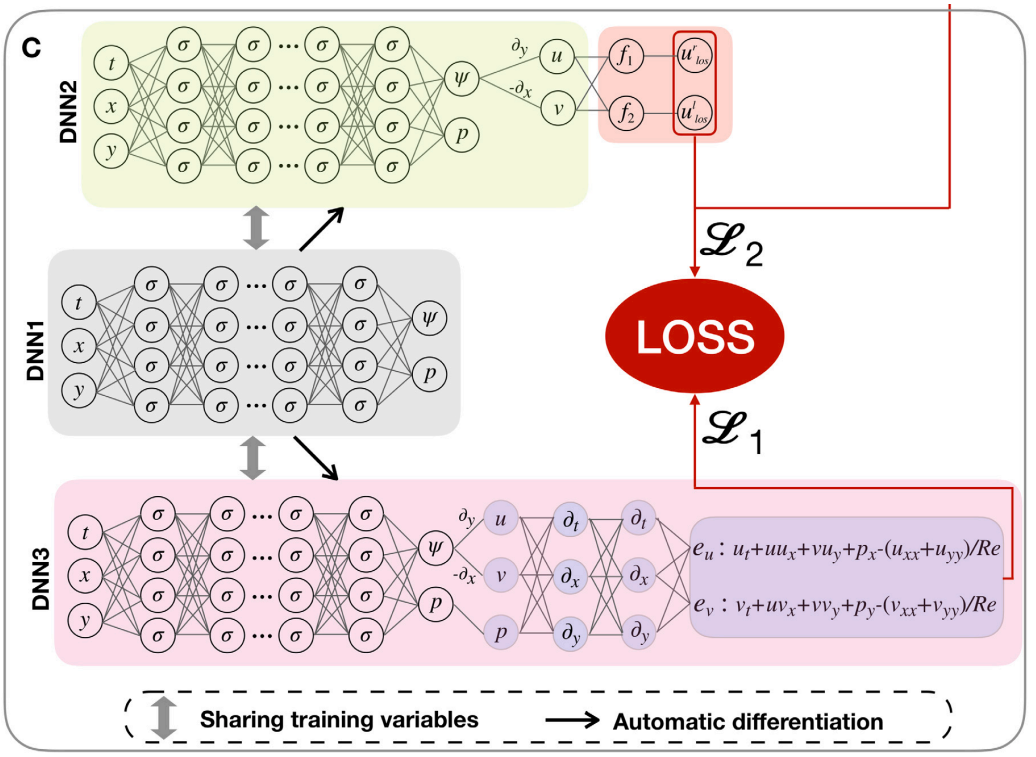


图 13.4: 论文中的网络及损失计算。$\mathcal{L}_1$ 来自方程残差，$\mathcal{L}_2$ 来自径向观测误差，两者共同训练基础网络。原图用 p 表示无量纲压力，对应本章的 π。摘自 Zhang 和 Zhao[96] 原文图 1(C)。

13.5.3 两束观测怎样参与损失计算

网络得到 u, v 后，先按波束方向计算径向速度。沿用论文的左右波束与符号约定，原文式 (5)–(6) 为

$$f_r(u, v) = u\cos 15^\circ - v\sin 15^\circ, \tag{13.19}$$

$$f_l(u, v) = u\cos(-15^\circ) - v\sin(-15^\circ). \tag{13.20}$$

右波束使用 f_r，左波束使用 f_l。例如在右波束某个位置查询得到 $u = 1, v = 0.1$，预测径向速度约为 $1 \times 0.966 - 0.1 \times 0.259 = 0.940$，再与该位置的无量纲测量值比较。

记右、左波束实测值分别为 $y_{r,i}$ 和 $y_{l,i}$，对应预测值为 $\widehat{y}_{r,i}$ 和 $\widehat{y}_{l,i}$。论文的数据损失是左右两组平均平方误差相加：

$$\mathcal{L}_2 = \frac{1}{N_r}\sum_{i=1}^{N_r}(\widehat{y}_{r,i}-y_{r,i})^2 + \frac{1}{N_l}\sum_{i=1}^{N_l}(\widehat{y}_{l,i}-y_{l,i})^2. \tag{13.21}$$

N_r, N_l 是本次训练取出的两组观测条数。每个预测值都在其对应的测点位置和测量时刻计算。

物理部分使用二维无量纲动量方程。按照原文式 (9)–(10)，两个残差为

$$e_u = \partial_t u + u\partial_x u + v\partial_y u + \partial_x \pi - \frac{1}{\mathrm{Re}}(\partial_{xx}u + \partial_{yy}u), \tag{13.22}$$

$$e_v = \partial_t v + u\partial_x v + v\partial_y v + \partial_y \pi - \frac{1}{\mathrm{Re}}(\partial_{xx}v + \partial_{yy}v). \tag{13.23}$$

其中 $\mathrm{Re} = U_\infty D/\nu$。在 N_{NS} 个配点上取残差平方的平均，得到

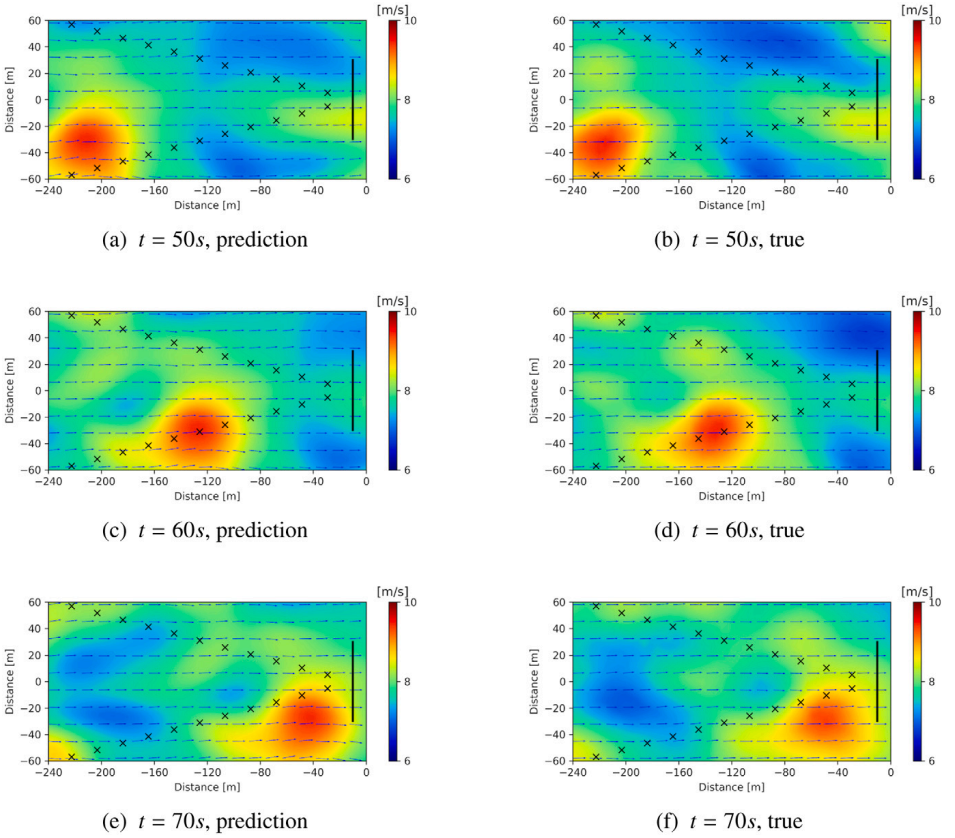
$$\mathcal{L}_1 = \frac{1}{N_{\mathrm{NS}}}\sum_{j=1}^{N_{\mathrm{NS}}}\left[e_u(\boldsymbol{\xi}_j)^2 + e_v(\boldsymbol{\xi}_j)^2\right]. \tag{13.24}$$

论文最后采用 $\mathcal{L} = \mathcal{L}_1 + \mathcal{L}_2$ 训练网络。流函数构造已经满足连续性，所以物理损失中只列出两个动量残差。原文这一训练设置采用上述两类损失，没有另外列出初值损失和边界损失。

把这一过程连起来看：一批坐标经过网络得到 ψ, π，求导得到 u, v。接着，在观测点计算径向误差，在配点计算动量残差。将两类误差相加，再更新同一组参数。训练使用的风速标签来自两束波束，压力和流函数由训练过程一同确定。

13.5.4 从风场图片看重建效果

训练完成后，固定时刻，在 81×41 个空间网格点上查询 u, v，即可得到一张风场图。图13.5给出基准算例的结果：左列是网络重建，右列是 SOWFA 参考切片，三行分别对应 50、60 和 70 s。



(a) $t = 50s$, prediction　(b) $t = 50s$, true

(c) $t = 60s$, prediction　(d) $t = 60s$, true

(e) $t = 70s$, prediction　(f) $t = 70s$, true

图 13.5: 基准算例的重建与参考风场。左列为 PINN 结果，右列为 SOWFA 参考值，从上到下为 50、60、70 s。颜色表示风速大小，箭头表示速度方向，叉号表示雷达测点。摘自 Zhang 和 Zhao[96] 原文图 3。

看这张图时，可以先找红黄色的高速区域。它在 50 s 时位于区域左侧，60 s 时移到中部，70 s 时到达风机附近。左列与右列呈现出相近的移动过程，说明重建结果抓住了这团高速来流的位置和输运过程。再看箭头，可以比较两个结果中的局部风向。

除了看图，论文还逐时刻计算全场风速误差，再对时间取平均。将风

速大小记为 $V=\sqrt{u^2+v^2}$，对应原文式 (14) 的指标为

$$\varepsilon_V=\frac{1}{N_t}\sum_{k=1}^{N_t}\sqrt{\frac{1}{N_s}\sum_{i=1}^{N_s}\left(\widehat{V}_{i,k}-V_{i,k}^{\mathrm{ref}}\right)^2}. \tag{13.25}$$

先在一个时刻，对 N_s 个空间位置求均方根误差，再把 N_t 个时刻的结果取平均。这就是论文中的 MRMSE。本例 $N_s=81\times 41=3321$，指标采用 100 个时刻。风向使用同样的计算顺序。

基准算例的风速大小 MRMSE 为 0.198 m/s，风向 MRMSE 为 2.77°。表13.3还整理了几个改变观测条件的结果，便于读者看到测量质量和测点数量怎样影响重建。

表 13.3: 部分算例的全场重建误差，整理自 Zhang 和 Zhao[96] 原文表 3。各行采用同一 MRMSE 计算方式。

测量或来流设置	风速误差（m/s）	风向误差（°）
基准：无噪声，每束 11 个测点	0.198	2.77
径向速度加均匀噪声 $[-0.1,0.1]$ m/s	0.387	3.73
空间采样变稀:每束 6 个测点,间隔 40 m	0.212	2.85
时间采样变稀：每 2 s 测量一次	0.222	2.66
来流相对雷达中心方向偏转 20°	0.281	2.46

加入噪声后，风速误差有所增加。减少空间测点后，模型仍重建出了主要风场结构。学习这个案例时，可以把注意力放在这种联系上：输入数据发生了什么变化，重建图中的结构和误差数值又怎样变化。

13.5.5 从重建时间窗走向短时预测

前面的对比发生在 0 到 100 s 的测量时间窗内。论文还把查询时间延伸到 115 s，用额外 15 秒的 SOWFA 结果检验短时预测。

图13.6给出风机位置附近三个横向位置的风速曲线。黑色实线为参考值，红色虚线为网络预测，横轴延伸到 115 s。读图时可分别观察 100 s 之

前的重建段，以及之后的短时外推段，比较峰值、低谷和变化趋势的对应情况。

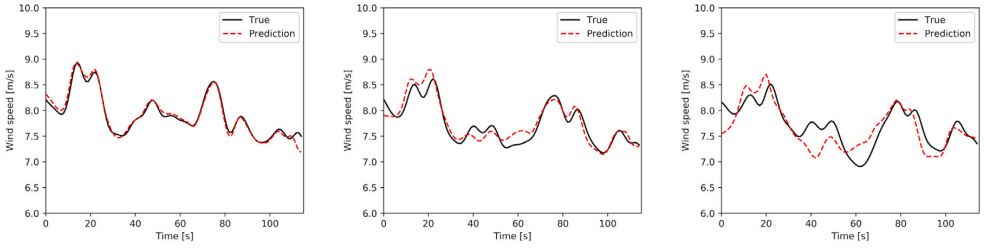


图 13.6: 三个横向位置的风速时间序列。横向坐标依次为 $y = 0$、15、30 m。黑色实线为参考值，红色虚线为预测值。曲线包含 100 到 115 s 的未来时间外推。摘自 Zhang 和 Zhao[96] 原文图 5。

这个案例把 PINN 的基本想法落到了具体计算上：用坐标网络表示风场，用流函数构造满足连续性方程的速度分布，用投影连接雷达读数，用动量残差联系未测位置，最后在网格和时间轴上查询结果。回到自己的研究时，可以沿着同一顺序整理测量几何、方程、训练数据和结果对比。

13.6 PINN 的优化方向

前面的案例给出了一个完整的 PINN：用网络表示风场，再用观测误差和方程残差训练它。真正动手后，还会遇到一些具体问题。例如，数据误差下降很快，方程残差却迟迟不降。有时平均风速已经接近参考值，局部变化仍显得过于平滑。也可能短时间内重建较好，时间窗一拉长，结果就变差。本节围绕这些现象，介绍怎样调整训练方法和网络结构。

Krishnapriyan 等的研究帮助我们理解训练困难从哪里来 [47]。Wang 等整理了尺度处理、网络设计和训练策略方面的实用方法 [93]。Jagtap 和 Karniadakis 提出的 XPINNs 则把一个大问题拆成多个相互连接的子问题 [38]。下面先从容易检查的设置开始，再介绍更深入的改进。

13.6.1 先看清训练卡在哪里

一个网络要同时拟合雷达读数、满足连续性和动量方程，还可能需要匹配入口与初始状态。这几项任务使用同一组参数，但各自提出的调整要求会有所不同。因此，查看训练过程时，可以先把总损失拆开看。

例如，若 $\mathcal{L}_d$ 持续下降而 $\mathcal{L}_f$ 几乎不变，就需要检查方程残差的尺度和权重。若两项都下降，而高速区域仍被预测得很模糊，可以继续检查配点分布与网络表达细节的能力。把问题定位到某一类现象后，再选择对应方法，调整会更有针对性。

Krishnapriyan 等在对流、反应和反应扩散方程上发现，增大方程中的某些系数后，原先能够训练好的 PINN 会变得难以优化。其原因与损失函数的形状有关：可以把参数训练想成在起伏的地形上寻找低点，方程项会改变这片地形，使下降过程更难进行。论文通过改变训练方式，在相同网络结构下得到了更好的结果 [47]。这为我们提供了一个很实际的起点：先检查训练安排，再决定是否增加网络规模。

13.6.2 统一变量尺度，并把配点放到合适的位置

先处理尺度。 第13.3节已经介绍了无量纲化。它在优化中的作用，可以理解为让网络在相近的数值范围内处理坐标、时间、速度和压力。例如，用 $L_0 = 240\,\mathrm{m}$、$U_0 = 8\,\mathrm{m/s}$ 作为一组教学尺度，则 $x = -120\,\mathrm{m}$ 对应 $x^* = -0.5$，$t = 30\,\mathrm{s}$ 对应 $t^* = 1$，$u = 8\,\mathrm{m/s}$ 对应 $u^* = 1$。这些量更便于放进同一个网络。

实际操作时，要把同一套尺度同时用于观测投影、方程残差和结果恢复。如果另外把网络输入坐标映射到 $[-1, 1]$，求导计算也应包含这次坐标变换。Wang 等把无量纲化放在训练流程的第一步，并在 Stokes 流动算例中比较了它对训练结果的影响 [93]。

让配点覆盖整个重建区域。 配点决定了网络在哪些位置接受方程检查。对于稀疏雷达重建，观测集中在几条波束上，物理配点则可以覆盖波束之间

和波束之外的区域。这样，方程信息就能进入整个待重建区域。

一种容易实现的做法是每一步随机抽取一批配点，或每隔若干步重新采样，使网络不断在新的位置接受检查。Wang 等将随机采样纳入了训练流程 [93]。如果局部剪切较强，还可以进一步使用**残差自适应采样**：先在一批候选点上计算残差，找出较大的位置，再给这些区域增加配点。保留一部分均匀分布的点，可以同时照顾整体区域与局部细节。

在风场问题中，这一策略可以按“全域采样、查看残差分布、局部加密、继续训练”的顺序实施。增加的是方程检查位置，所需输入仍然只是坐标和时间。

13.6.3 平衡数据损失和物理损失

即使变量已经无量纲化，不同损失对参数更新的影响仍可能相差很大。这里要关注的是**损失对参数的梯度**，也就是每项损失在多大程度上推动网络调整。某项损失的梯度长期占主导时，训练就会更多地围绕这项任务进行。

Wang 等介绍了一种基于梯度大小的自适应加权方法 [93]。用 q 表示数据、物理、边界或初值等某一项损失，先计算

$$g_q = \|\nabla_\theta \mathcal{L}_q\|_2, \qquad \widehat{\lambda}_q = \frac{\sum_j g_j}{g_q}. \tag{13.26}$$

$\nabla_\theta \mathcal{L}_q$ 是该项损失对全部网络参数的梯度，g_q 表示它的整体大小。梯度较小的项会获得较大的权重，使各项对参数更新的推动幅度更接近。

例如只有数据和物理两项时，若 $g_d = 0.01$、$g_f = 1$，按上式得到 $\widehat{\lambda}_d = 101$、$\widehat{\lambda}_f = 1.01$。加权后的梯度大小均为 1.01。这个例子说明，权重是在协调各项任务参与训练的程度。

为使权重变化平滑，可以采用移动平均：

$$\lambda_q^{\text{new}} = \alpha \lambda_q^{\text{old}} + (1-\alpha)\widehat{\lambda}_q. \tag{13.27}$$

α 越大，越多地保留原来的权重。Wang 等给出 $\alpha = 0.9$、每 1000 步更新一

次权重的默认设置 [93]。权重定期重算，在当前一步更新网络参数时，将它们作为固定系数使用。

对于风场重建，可以先分别记录 $\mathcal{L}_d$、连续性残差和两个动量残差。若某一项长期下降缓慢，再比较梯度大小，决定按“数据与物理”两组加权，还是把不同方程进一步分开加权。这样，调节权重就有了可观察的依据。

13.6.4 采用课程训练，让任务由易到难

课程训练的想法很接近学习过程：先完成较容易的任务，再利用已经学到的参数处理更难的任务。每个阶段都以上一阶段的网络为起点，逐步接近最终问题。

Krishnapriyan 等以一维对流方程为例：

$$\partial_t q + \beta \partial_x q = 0. \tag{13.28}$$

q 是随时间平移的一个场，β 控制它的平移速度。论文先在较小的 β 下训练，再逐步增大到目标值。原文表 1 中，$\beta = 30$ 时，常规训练的相对误差为 8.97×10^{-1}，课程训练为 2.02×10^{-2}[47]。这个例子直观地说明，训练顺序本身就能影响最后学到的结果。

Wang 等也介绍了类似做法：求解较高雷诺数的流动时，先训练较低雷诺数的模型，再把结果用于目标雷诺数下的训练 [93]。前一阶段提供一个较好的起点，后一阶段继续拟合目标方程。

把“由易到难”的思路用于风场重建，可以设计分阶段训练：先让网络学到主要来流和观测变化，再逐步增强动量方程约束，最后在目标权重和全部观测上继续训练。如果采用改变方程参数的课程，各阶段也要明确当前使用的参数，最后回到目标方程。这样就能把每一阶段的训练任务说清楚。

13.6.5 缩短单次时间跨度，并按时间顺序学习

时间分窗：每次重建一小段。 假设有 0 到 100 s 的雷达数据，可以把它划成五个 20 s 窗口。先训练第一个窗口，得到 $t = 20\,\mathrm{s}$ 的场，再把这一末态作为下一个窗口的初始状态，同时使用下一窗口内的雷达观测继续重建。网络参数也可以沿用前一窗口的训练结果。

这就是 Krishnapriyan 等讨论的序列式学习思路：将一次学习整个时空区域，改成沿时间逐段推进 [47]。Wang 等也将时间推进用于长时间动力系统的训练 [93]。对风场而言，每个网络只需处理一段较短时间内的变化，窗口之间再通过末态与初值连接。

因果加权：在一个窗口内先学好较早的时刻。 时间分窗以后，每个窗口内部仍包含许多时刻。因果加权进一步调整这些时刻的学习顺序。较早时间段的残差还很大时，先把训练重点放在前面。等前面的残差下降后，再逐步提高后面时间段的权重。

按照 Wang 等的写法，将当前窗口划成 M 个有先后顺序的小段，用 $\mathcal{L}_f^{(k)}$ 表示第 k 段的物理损失，定义

$$w_1 = 1, \qquad w_k = \exp\left(-\varepsilon \sum_{j=1}^{k-1} \mathcal{L}_f^{(j)}\right), \quad k = 2, \dots, M, \tag{13.29}$$

$$\mathcal{L}_{f,\mathrm{causal}} = \frac{1}{M} \sum_{k=1}^{M} w_k \mathcal{L}_f^{(k)}. \tag{13.30}$$

$\varepsilon > 0$ 控制这种先后顺序的强弱。前面各段的累计残差越大，后面段的 w_k 越小。前面的残差下降后，后面的权重就逐渐接近 1。更新网络参数时，同样把当前计算出的 w_k 作为固定系数 [93]。

例如取 $\varepsilon = 1$，若前两段物理损失都是 1，三段权重约为 $(1, 0.37, 0.14)$。当前两段损失都降到 0.1 时，权重变为 $(1, 0.90, 0.82)$。这些教学数值展示了训练重点怎样逐渐向后展开。

图13.7把两种做法放在一起。上面是不同时间窗口之间传递末态，下面

是同一个网络内部按时间段调整物理损失权重。它们可以结合使用：先把长记录分窗，再在每个窗口内进行因果加权。

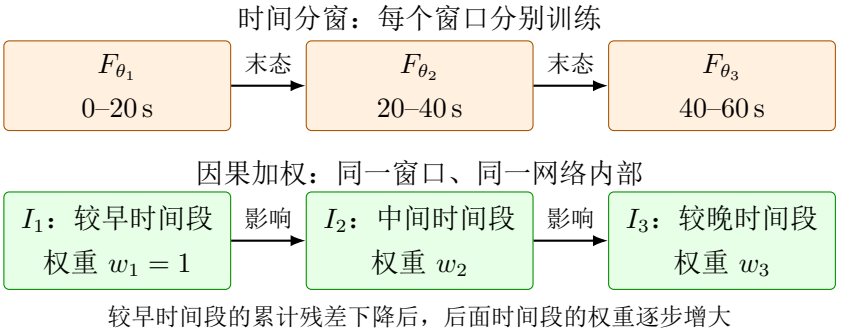


图 13.7：时间分窗与因果加权的教学示意。上排箭头表示前一窗口的末态用于下一窗口的初值。下排箭头表示较早时间段的残差参与后面权重的计算，见式(13.30)。图中窗口长度用于举例。

13.6.6 改进网络对局部细节的表达

风场往往同时包含缓慢变化的背景来流和变化较快的局部结构。普通全连接网络在训练中倾向于先学到平滑、变化缓慢的部分，这种现象称为**频谱偏置**。它可以帮助我们理解一种常见结果：平均风速已经比较接近，局部峰值和剪切变化却仍被抹平。Wang 等从以下几方面改进网络 [93]。

傅里叶特征：给坐标增加不同频率的表示。 在坐标进入网络前，先把它转换为一组正弦和余弦特征：

$$\gamma(\boldsymbol{\xi}) = \begin{bmatrix} \cos(B\boldsymbol{\xi}) \\ \sin(B\boldsymbol{\xi}) \end{bmatrix}. \tag{13.31}$$

$\boldsymbol{\xi}$ 是无量纲时空坐标，B 是一组控制频率的系数。随机傅里叶特征通常从高斯分布采样这些系数，再在训练中固定它们。以一个空间坐标为例，$\sin(2\pi x^*)$ 在单位区间内变化一周，$\sin(10\pi x^*)$ 则变化五周。将这些特征交给网络，相当于提供不同快慢的变化模式，让它更容易组合出局部细节。

频率范围需要与希望重建的空间、时间尺度相配合。在风场中，可以比较加入特征前后，高速区边缘、横向剪切和速度时间曲线是否更清晰。这里增加的是坐标的表示方式，网络的输出仍然是本章使用的速度、压力或流函数。

随机权重分解：调整参数的组织方式。 Wang 等还介绍了随机权重分解（RWF）。对于一层网络的权重矩阵，可以写成

$$W = \operatorname{diag}(\exp(\mathbf{a}))V. \tag{13.32}$$

$\mathbf{a}$ 为每个神经元提供一个可学习的缩放量，V 给出其余权重。先按普通方法初始化 W，再选取 $\mathbf{a}$ 并据此得到 V，使分解后的初始矩阵与原来的 W 一致。训练时更新 $\mathbf{a}, V$。这种改法保留了全连接层的计算形式，同时改变参数的更新过程，使不同神经元可以形成不同的调整幅度。

改进连接方式，并利用已知物理结构。 Wang 等讨论的 modified MLP 用两个编码器提取输入特征，再在各隐藏层中组合这些特征，使输入信息能反复参与中间层计算。它提供了普通全连接网络之外的另一种结构选择 [93]。

物理关系也可以直接参与输出设计。第13.5节的流函数就是一个例子：网络输出 ψ，再由求导得到 u, v，从而把连续性方程放进速度的构造过程。若问题具有已知的周期边界，还可以通过周期性的正弦、余弦输入来表达这种边界关系。这样的结构设计能减少需要单独学习的约束。

13.6.7 用 XPINNs 把大区域拆成相互连接的子区域

当重建区域变大，或区域内不同位置的变化程度差别明显时，可以让多个局部网络分工。Jagtap 和 Karniadakis 提出的 XPINNs 将空间或时空区域划成若干子区域，每个区域使用一个网络，再通过界面条件把结果连接起来 [38]。

图13.8沿用前面案例的矩形区域，示意在 $x = -120\,\mathrm{m}$ 处划分。左侧由

F_{θ_1} 表示，右侧由 F_{θ_2} 表示。各自使用区域内的观测和配点训练，共同边界 Γ 上的点则同时送入两个网络，比较两侧的结果。

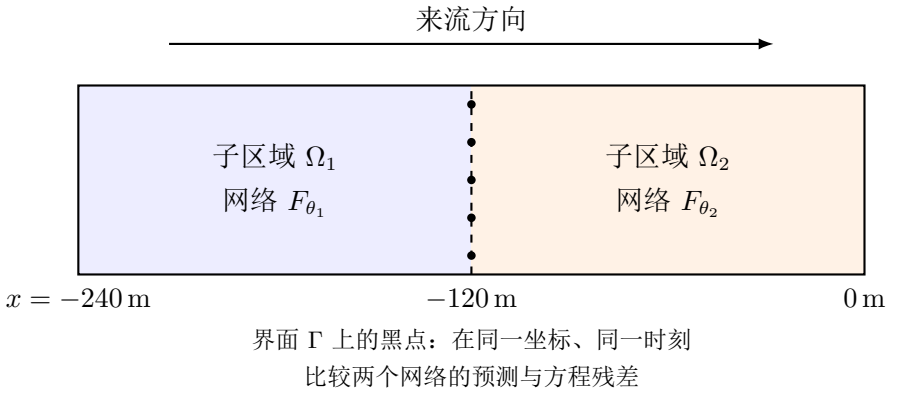


图 13.8: 风场区域分解的教学示意。虚线为两个子区域的界面，黑点为界面约束的计算位置，箭头表示来流方向。这里的划分用于解释 XPINNs 的计算方法。

界面上主要处理两件事：**两侧给出相衔接的场值，两侧的方程残差也保持一致**。沿用本章的无量纲变量，记第 k 个局部网络的预测为 $\mathbf{z}_k = (u_k, v_k, \pi_k)^\top$，残差为 $\mathbf{R}_k = (\overline{r}_{c,k}, \overline{r}_{u,k}, \overline{r}_{v,k})^\top$。

先在界面点上计算两侧预测的平均值

$$\overline{\mathbf{z}} = \frac{\mathbf{z}_1 + \mathbf{z}_2}{2}.$$

按 XPINNs 的界面构造思路，让每一侧接近这个共同值：

$$\mathcal{L}_{\Gamma,z} = \frac{1}{N_\Gamma} \sum_{i=1}^{N_\Gamma} \left[\|\mathbf{z}_1(\boldsymbol{\xi}_i) - \overline{\mathbf{z}}(\boldsymbol{\xi}_i)\|_2^2 + \|\mathbf{z}_2(\boldsymbol{\xi}_i) - \overline{\mathbf{z}}(\boldsymbol{\xi}_i)\|_2^2 \right]. \tag{13.33}$$

同时，比较同一界面点上的残差：

$$\mathcal{L}_{\Gamma,R} = \frac{1}{N_\Gamma} \sum_{i=1}^{N_\Gamma} \|\mathbf{R}_1(\boldsymbol{\xi}_i) - \mathbf{R}_2(\boldsymbol{\xi}_i)\|_2^2. \tag{13.34}$$

N_Γ 是界面点数，$\boldsymbol{\xi}_i$ 记录其坐标和时间。第一项帮助两块预测衔接，第二项协调界面处的方程计算。它们与各子区域原有的数据损失、物理损失一起参与训练。具体方程需要时，还可以加入通量等界面条件 [38]。

XPINNs 的另一个特点是不同区域可以采用不同配置。变化平缓的区域可以用较小的网络，局部变化较强的区域可以增加网络容量和配点。多个子网络还可以分配到不同计算设备上训练，这样计算资源就能按区域需要分配。

空间分解与时间分窗也有不同侧重：前者让不同空间区域的网络通过界面共同训练，后者沿时间把前一窗口的末态传给后一窗口。XPINNs 的划分可以同时涉及空间和时间，因此能够容纳更灵活的时空子区域。

13.6.8 在风场重建中怎样安排这些改进

表13.4将训练现象与可以优先尝试的方法对应起来。先观察哪一部分学得不好，再选择改进方式，实验过程会更清楚。

表 13.4: 风场 PINN 中常见的训练现象与改进思路。这里给出方法选择的教学对应关系。

观察到的现象	可以优先检查或尝试	主要调整对象
各项损失量级相差很大	无量纲化、残差缩放	变量与方程的数值尺度
观测拟合较好，方程项下降缓慢	梯度监测、自适应加权	各项损失参与更新的程度
局部高速区或剪切被抹平	局部增加配点、傅里叶特征	检查位置与细节表达
短窗口较好，长窗口变差	时间分窗、因果加权	单次任务跨度与时间顺序
目标方程从随机初始化开始很难训练	课程训练、沿用较易任务的参数	训练起点与难度安排
区域很大，不同位置复杂程度不同	XPINNs、局部网络与配点配置	空间分工与界面连接

开始实现时，可以采用如下顺序：

1. 先固定一套基础网络，检查坐标、投影和方程实现，统一变量尺度，记录每项损失。

2. 使用随机配点和 Adam 训练。学习率可以逐步衰减，让训练前期较快调整、后期细化。Wang 等的训练采用 Adam 与指数衰减学习率 [93]。

3. 根据结果加入一种有针对性的改进，例如自适应权重或傅里叶特征，并比较相同观测条件下的重建图、留出数据误差和训练耗时。

4. 当时间跨度或区域规模成为主要困难时，再引入分窗、因果加权或 XPINNs，继续检查窗口交界或子区域界面附近的结果。

还可以沿另外两条方向继续扩展方法。其一是改变方程的表达方式，例如弱形式 PINN 先对方程积分，再形成训练误差，适当的分部积分能够减少直接计算高阶导数的需求 [42]。其二是把未知物理参数与风场一起学习，例如估计所选模型中的黏度参数。贝叶斯 PINN 则进一步用概率分布表达参数和预测的不确定程度 [94]。这些扩展可以与前面的训练优化方法结合，用于不同的风场重建任务。

本章小结。 PINN 的训练同时利用测量值和方程：测量值约束已测位置的预测，方程约束风场在空间与时间中的变化。实现时，先明确网络的输入和输出，再写观测投影、计算方程残差，把它们合成损失。训练完成后，在指定网格和时刻查询网络，就能得到风速分量、风速大小与风向。论文中的双波束案例把这些步骤串在了一起，也展示了从时间窗内的重建到短时外推的使用过程。在此基础上，还可以从变量尺度、损失平衡、时间安排、网络结构和区域分解等方面改善训练。

第四部分

从学习方式看数据智能场景

前面各章主要讨论如何用给定数据学习预测器。本部分进一步讨论数据与知识如何被组织：预训练构建可复用的表示，迁移学习处理源域与目标域，持续学习处理按时间到达的变化，主动学习决定哪些样本值得标注，联邦学习处理分散的数据所有权，流形学习利用样本几何，元学习利用任务经验。七章分别给出问题假设、关键算法、变体与工业评价边界，不能用其中一种方法的收益替代另一种设定的验证。

第十四章　预训练：构建可复用的数据表示

本章摘要。预训练通过先行学习任务获得可复用的参数或表示。本章从数据与目标的关系出发，解释监督预训练、掩码与生成式学习、对比学习、无负样本自蒸馏及领域继续预训练。工业振动信号案例用于说明如何选择增强与遮蔽方式，以及如何区分预训练损失下降、表示改善和下游收益。

前面的模型章节回答序列、图像和文本应如何表示，上一章进一步让物理方程参与学习：当标签不足时，已知规律可以约束候选解。然而，不是所有设备都有足够准确的控制方程，许多可利用的知识只隐含在历史观测中。本章由此转向另一条路线：在目标故障标签不足时，能否先利用历史数据学习可复用结构，再用有限标签建立预测器？预训练的价值在于可复用性，其监督信号可以来自人工标签，也可以来自数据本身。它不等同于无监督学习，更不要求模型一定具有很大规模。

理解这条路线，需要区分三个并不等价的问题：辅助任务能否被完成，表示是否保留了任务需要的信息，有限标签能否把这些信息转成可靠判断。重构波形可以依靠平滑性，对比学习可以依靠设备身份，而故障诊断可能恰恰需要低能量的短时冲击。因此，本章不以罗列预训练模型为主线，而是逐步追问学习信号要求模型保留什么、丢弃什么：先由似然与重构解释预测目标，再由正负样本关系解释不变性，最后分析不使用负样本时如何避免所有表示趋同。贯穿这些方法的观点是，预训练目标是一种关于有用结构的假设，必须由独立的下游任务检验。

读完本章，可以按三个问题检查自己的方案：哪些历史记录允许参与训练，遮住的部分是否太容易猜中，模型是否把不同输入都编码成了相近

的结果。例如波形补得很平滑，却丢掉短时冲击，就未必有利于故障诊断。下一章继续讨论拿到预训练参数以后，哪些可以保留，哪些需要用新设备的数据重新调整。

14.1 预训练学到了什么

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

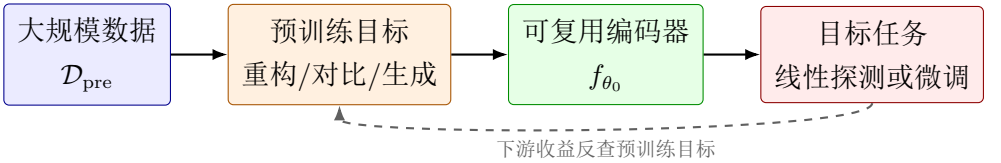


图 14.1：预训练的价值由下游任务检验：辅助目标下降并不自动意味着故障相关信息被保留。

图14.1把无标签预训练与下游评估连成反馈路径，强调辅助任务学到的表示须通过独立故障任务检验，而不能只用预训练损失验收。反馈只允许使用训练与验证任务：若根据测试集表现反复改变预训练目标，该测试集就参与了模型选择，不能再充当最终独立证据。阅读下面的目标函数，只需先掌握小批次训练、交叉熵和反向传播。与从零训练相比，本章多了一个先行任务：用什么训练信号产生可复用参数？先辨认每个目标的输入和答案来自哪里，再判断学到的特征能否帮助有限标签任务。

表示、编码器和头分别是什么。 表示是从原始输入计算出的特征向量，而不是人工故障标签。例如一个窗口含 $C = 3$ 个通道、每通道 $L = 100$ 个采样值，可展平为 $x \in \mathbb{R}^{300}$，编码器 $f_\theta : \mathbb{R}^{300} \to \mathbb{R}^{32}$ 把它变成 32 维表示。重构头 $g_\phi : \mathbb{R}^{32} \to \mathbb{R}^{300}$ 把表示映射回波形；下游三分类头则把同一表示映射到 3 个类别分数，经 softmax 变成概率。头是为特定目标服务的末端模块，骨干或编码器负责提取共享特征。不同任务的头输出尺寸不同，所以预训练结束时常需替换它，而非直接把重构波形当成故障概率。

在线性探测中，固定 $h = f_{\theta_0}(x) \in \mathbb{R}^{32}$，只学习 $W \in \mathbb{R}^{3\times 32}$、$b \in \mathbb{R}^3$，计算类别分数 $a = Wh + b$ 和概率 $\mathrm{softmax}(a)$。这里“线性”指分数对表示 h 是仿射的，不是对原始波形一定线性，也不是把 softmax 删除。若表示已丢掉故障冲击，再训练这样的头不能恢复被删信息；全量微调则允许编码器重新学习，但需要更多目标证据控制过拟合。

“预训练”描述先学习可复用参数的阶段，“自监督”描述标签如何由数据本身构造，“迁移学习”描述把已有知识用于目标问题的做法。它们不互斥：用掩码恢复历史波形是自监督预训练，把得到的编码器用于新设备故障分类是迁移，训练新分类头或更新编码器则是具体适配操作。监督预训练也能用于迁移，迁移也不必使用单独设计的自监督阶段。

设预训练数据为 $\mathcal{D}_{\mathrm{pre}}$，编码器为 f_θ，与预训练目标配套的预测头为 g_ϕ。一般训练形式为

$$(\theta_0, \phi_0) = \arg\min_{\theta,\phi} \mathbb{E}_{x\sim\mathcal{D}_{\mathrm{pre}}} \mathbb{E}_{\omega\sim P_\omega} \ell_{\mathrm{pre}}\big(g_\phi(f_\theta(v_\omega(x))), s_\omega(x)\big). \tag{14.1}$$

式中 $\arg\min$ 表示寻找使平均损失尽量小的参数，外层期望平均不同记录，内层期望平均同一记录的随机处理方式，实际通常以一个小批次近似。下标 0 表示交付下游任务的预训练参数，并非所有参数取零。监督版本的外层抽样应读作 $(x, y) \sim \mathcal{D}_{\mathrm{pre}}$，此时目标 s_ω 取该记录的人工标签 y；不能只凭输入 x 凭空得到人工标签。

其中 ω 控制裁剪、遮蔽或目标构造，$v_\omega(x)$ 为模型输入，$s_\omega(x)$ 为学习目标。监督分类时目标来自人工标签，自监督任务则由样本结构构造目标，例如被遮蔽的片段或同一样本的另一视图。预训练完成后可保留编码器、丢弃辅助头，再接入目标任务头 h_ψ。

若冻结 θ_0 只训练线性 h_ψ，检验的是该表示中的线性可分信息；全量微调则同时检验初始化能否支持适应。两者可能产生不同排序。模型也可能保留了设备编号和工况，却没有保留故障机理，因此预训练损失不能直接用作表示质量指标。下一章讨论微调、参数高效适配与域对齐，本章重点是初始化产生之前的学习过程。

预训练数据不一定与下游任务同分布。通用图像表示可能提供边缘和纹理结构，但工业细裂纹要求保留更细的空间信息；自然语言模型能够学习句法，却未必知道某台设备的有效规程。数据规模、任务相关性和目标设计共同决定迁移潜力，增加其中一项不能保证补偿另一项的缺失。

14.2 监督预训练与重建式目标

监督预训练利用较大源数据集的标签训练骨干，例如图像分类网络中的交叉熵目标 [31]：

$$\mathcal{L}_{\mathrm{sup}} = -\frac{1}{N}\sum_{i=1}^{N} \log p_{\theta,\phi}(y_i \mid x_i). \tag{14.2}$$

随后保留骨干并替换分类头。源标签可以来自其他设备或相关任务，但其类别定义决定了哪些差异受到强调。只以设备类别预训练，可能更容易区分传感器安装位置而不是早期故障。弱标签和伪标签能扩大覆盖，却需要单独处理标签噪声，不能把它们等同于准确人工标注。

自编码器从压缩表示重构输入，去噪自编码器则从受扰动输入 $\widetilde{x}$ 恢复原始 x[90]：

$$\mathcal{L}_{\mathrm{denoise}} = \mathbb{E}_{x\sim\mathcal{D}_{\mathrm{pre}}}\mathbb{E}_{\widetilde{x}\sim q(\cdot\mid x)}\|g_{\phi}(f_{\theta}(\widetilde{x})) - x\|_2^2. \tag{14.3}$$

扰动机制决定模型需要恢复什么。噪声过小可能只要求近似恒等映射，噪声过大可能使恢复目标含糊。重构均方误差倾向于优先解释高能量成分，低幅值但诊断价值较高的冲击不一定受到足够重视。频谱或多尺度损失可以改变关注点，但要明确引入的频段先验，避免利用测试故障选择损失。

14.2.1 从条件似然理解重构为何产生平滑结果

把一个窗口展平为 $x \in \mathbb{R}^{D}$，令 $u = \widetilde{x}$ 表示受扰动观测，编码器输出 $f_{\theta}(u) \in \mathbb{R}^{d}$，解码器输出 $m_{\theta,\phi}(u) \in \mathbb{R}^{D}$。若建模假设为

$$p_{\theta,\phi}(x \mid u) = \mathcal{N}\!\left(x; m_{\theta,\phi}(u), \sigma^2 I_D\right), \tag{14.4}$$

则单个样本的负对数似然是

$$-\log p(x \mid u) = \frac{D}{2}\log(2\pi\sigma^2) + \frac{1}{2\sigma^2}\|x - m_{\theta,\phi}(u)\|_2^2. \tag{14.5}$$

只有在 σ^2 固定时，最大似然才等价于普通均方误差最小化；若同时学习方差，就不能丢弃对数方差项。不同通道单位差异很大时，采用对角协方差 Σ 会得到 $(x-m)^\top \Sigma^{-1}(x-m)$，即按噪声尺度加权的误差。这样的权重表达的是可靠性或尺度假设，不能任意解释为故障重要性。

进一步令 $m^*(u) = \mathbb{E}[X \mid U = u]$，对任意候选重构 a 展开平方：

$$\mathbb{E}[\|X - a\|^2 \mid u] = \mathbb{E}[\|X - m^* + m^* - a\|^2 \mid u] \tag{14.6}$$

$$= \mathbb{E}[\|X - m^*\|^2 \mid u] + \|m^* - a\|^2. \tag{14.7}$$

式(14.7)中交叉项消失，是因为 $\mathbb{E}[X - m^* \mid u] = 0$。因此无限容量、总体风险最优的平方误差预测器输出条件均值。假如遮蔽区的冲击可能出现在两个不同位置，条件均值可能在两处各产生半个冲击，虽然平均误差最小，却不是任何一次真实波形。这不是单纯增加网络容量就能解决的问题；需要缩短遮蔽区、加入可靠上下文，或用能表达多峰条件分布的预测头。

用两个等可能的真实片段 $(2,0)$ 与 $(0,2)$ 可检查条件均值结论。预测 $(1,1)$ 时，两种情况的平方误差都为 2；固定预测 $(2,0)$ 时，误差分别为 0 和 8，平均为 4。因此均值确实赢得平方损失，却把一个完整冲击拆成两个半冲击。重构指标和故障语义之间的差异由此可见。

14.2.2 遮蔽任务与因果预测的边界

掩码建模只显示部分输入，并预测被遮蔽区域。令 M 为目标位置集合、V 为可见位置集合，可写为

$$\mathcal{L}_{\text{mask}} = \mathbb{E}_{x,M}\frac{1}{|M|}\sum_{j\in M}\ell\big(\widehat{x}_j(x_V, M), x_j\big). \tag{14.8}$$

离散词元通常采用交叉熵，连续图像块或信号片段可采用重构误差。BERT 使用掩码语言建模，MAE 则以可见图像块训练编码器，并由轻量解码器重

构被遮蔽块 [19, 29]。MAE 的编码器只处理可见块，减少了高遮蔽率下的编码开销；解码器仍需接收位置信息与遮蔽标记。不能仅按遮蔽比例推断所有架构都具有相同节省。

这里假定输入由 L 个元素或片段组成，每个连续片段 $x_j \in \mathbb{R}^p$，$M \subset \{1, \dots, L\}$ 非空，V 为其补集；解码器需为每个 $j \in M$ 输出同维预测。若采用逐位置条件分布 $q_{\theta,\phi}(x_j \mid x_V, M)$，掩码损失就是条件负对数似然之和。逐位置相加相当于用条件独立输出头拟合各位置的边缘分布，不表示真实被遮蔽片段给定可见输入后必然独立；若要生成相互协调的一整段，还需联合或自回归解码器。$1/|M|$ 避免遮蔽更多位置时仅因项数增加而提高损失，但它不会消除不同遮蔽难度带来的梯度差异。

离散监督分类和掩码词元分类共享交叉熵结构。令真实条件分布为 $r(k \mid u)$、预测为 $p(k \mid u)$，则 $-\sum_k r_k \log p_k = H(r) + \mathrm{KL}(r\|p)$。固定输入条件下，总体最优预测应匹配 r；有限标签训练以单个类别指示向量代替未知 r。因此监督预训练强调源标签可区分的信息，掩码训练强调由上下文可预测的信息，二者都没有数学理由自动保留与自身目标无关的下游细节。

例如 $x = (1, 2, 3, 4)$，遮蔽集合 $M = \{2, 3\}$，输入只显示位置 $1, 4$ 及其数值。若模型对遮蔽位置输出 $(2.5, 2.5)$，则按本节平方误差约定，损失为 $[(2.5-2)^2 + (2.5-3)^2]/2 = 0.25$；可见位置不参与这次目标平均。监督值来自原始完整记录，但不能先把完整记录编码后才遮蔽目标，否则模型已经看过答案。连续片段含 p 个数时，单位置损失可用平方范数，是否再除以 p 也应统一。

独立随机点遮蔽可能被局部平滑插值轻易解决。时间序列可使用连续片段遮蔽、跨通道遮蔽或多尺度遮蔽，以迫使模型利用更长上下文。遮蔽过长又可能使目标不可预测，网络只能输出条件平均。应根据信号周期、传感器耦合与任务时间尺度选择策略，并检查模型是否只是复制相邻样本。

自回归预训练预测给定过去的下一个元素，目标为

$$\mathcal{L}_{\mathrm{AR}} = -\mathbb{E}_x \sum_{j=1}^{L} \log p_\theta(x_j \mid x_{<j}). \tag{14.9}$$

该目标来自联合分布的链式分解 $p_\theta(x_1, \dots, x_L) = \prod_{j=1}^{L} p_\theta(x_j \mid x_{<j})$；取负对数将连乘转为求和，不要求序列元素相互独立。训练时使用真实前缀计算条件似然，而生成时使用模型已生成的前缀，两者输入分布可能不同。对总体数据分布 P，期望负对数似然等于 $H(P) + \mathrm{KL}(P \| P_\theta)$；模型族足够表达且优化达到总体最优时，才有匹配数据分布的解释。有限数据、有限上下文或模型失配下，即便整体似然改善，稀有故障的条件概率也可能仍很差。对文本这是下一词元预测，对连续信号需要明确预测分布或回归损失。双向掩码表示可以利用目标位置两侧上下文，自回归表示受因果边界约束。在线故障预测若采用窗口表示，应保证窗口中没有预测时刻之后的数据，不能因任务名称为自监督就忽略时间泄漏。

14.3 对比学习：哪些样本应当接近

对比学习用正样本对定义应保留的一致性，用负样本提供区分信号。A Simple Framework for Contrastive Learning of Visual Representations (SimCLR) 对一个批次中的每个样本独立增强两次，经编码器与投影头得到归一化表示 z_i[12]。对锚点 i 及其正样本 j，损失为

$$\ell_{i,j} = -\log \frac{\exp(z_i^\top z_j / \tau)}{\sum_{k \neq i} \exp(z_i^\top z_k / \tau)}, \qquad \tau > 0. \tag{14.10}$$

含 $B > 1$ 个原始样本的批次产生 $2B$ 个视图；若 $B = 1$，只有正候选，损失恒为零，无法提供这里的对比信号。分母含一个正样本和 $2B - 2$ 个负样本，训练对两个方向求平均。投影头使对比目标作用于专门的空间，下游任务常使用投影前的编码器表示。温度 τ 改变相似度差异对梯度的影响，较小温度强调难区分样本，也可能放大假负样本的影响。

“视图”就是同一条记录经不同允许处理得到的输入，正样本不是“正常设备”，负样本也不是“故障设备”，而是当前配对任务中匹配与不匹配的候选。例如 $B=2$，某锚点有一个正候选和两个负候选，若与三者的相似度分别为 $1,0,0$ 且 $\tau=1$，则正候选概率为 $e/(e+2)\approx 0.576$，损失约 0.551。若三者都同样相似，则概率为 $1/3$、损失为 $\log 3\approx 1.099$。这说明对比训练不是单独提高正相似度，而是提高它相对于其他候选的辨识度。

把对比损失展开为一个分类问题。 设投影前表示为 $h_i\in\mathbb{R}^d$，投影后归一化向量为 $z_i\in\mathbb{R}^m$，$\|z_i\|_2=1$。固定锚点 i 时，其余 $2B-1$ 个视图构成候选集合。令 $s_{ik}=z_i^{\top}z_k$ 及

$$q_{ik}=\frac{e^{s_{ik}/\tau}}{\sum_{l\neq i}e^{s_{il}/\tau}}. \tag{14.11}$$

任务就是从候选中识别真正配对的视图 j。把 $\ell_{i,j}=-s_{ij}/\tau+\log\sum_{k\neq i}e^{s_{ik}/\tau}$ 逐项求导，有

$$\frac{\partial \ell_{i,j}}{\partial s_{ik}}=\frac{1}{\tau}(q_{ik}-\mathbf{1}[k=j]),\qquad \nabla_{z_i}\ell_{i,j}=\frac{1}{\tau}\left(\sum_{k\neq i}q_{ik}z_k-z_j\right). \tag{14.12}$$

这里第二式暂把其他向量视为常量；完整批次梯度还包含 z_i 作为别的锚点的候选时收到的梯度。下降方向拉近正样本并远离概率加权的候选均值，而非均匀排斥每个负样本。若未归一化投影为 $u_i\neq 0$，还需乘归一化雅可比 $(I-z_iz_i^{\top})/\|u_i\|_2$，不能把单位球面上的变量当成任意自由向量。零向量不能直接归一化；实现中若用小常数保护分母，保护区间内的导数也应按实际公式计算。

这个推导解释了温度的两个作用：显式的 $1/\tau$ 改变梯度尺度，softmax 又把权重集中到最相似候选。因此减小温度不只是“加大学习率”。当一个高相似负样本实际属于同类故障时，它会得到很大的排斥权重。另一方面，若所有 z 完全相等，则 $q_{ik}=1/(2B-1)$，损失为 $\log(2B-1)$，没有完成配对识别；但对称构型仍可能有退化驻点，不能仅从负样本存在推断优化必然成功。

大批次可以提供更多负样本，但增加内存成本。Momentum Contrast (MoCo) 使用键队列复用近期表示，并用动量编码器降低队列中新旧表示的不一致 [30]。若查询编码器参数为 θ_q、键编码器参数为 θ_k，则

$$\theta_k \leftarrow \mu\theta_k + (1-\mu)\theta_q, \qquad 0 \le \mu < 1. \tag{14.13}$$

查询分支通过梯度更新，键分支按指数移动平均更新，当前键入队并移除最旧键。队列增大并不总有益：分布变化较快时，陈旧键可能形成不合适的比较对象。

正样本定义比损失名称更重要。图像颜色扰动可以弱化照明差异，但在变色故障中颜色本身就是标签信息。振动信号的强幅值归一化可能删除故障严重度，时间伸缩可能改变与转速相关的频率结构。只有在目标任务对某种变化确实不敏感时，才应训练这种不变性。状态变化对应的敏感方向应保留，而不是一律压缩。

同一故障的两个不同记录可能被当作负样本，造成假负样本排斥。监督对比学习利用已有类别标签为一个锚点构造多个正样本 [43]，但其适用范围由标签覆盖决定。工业采样还应控制设备和批次：若一个批次中每台设备只出现一种工况，模型可能靠设备身份完成对比任务，而非学习可迁移的状态表示。

跨模态对比预训练将同步波形、图像或文本对齐。CLIP 使用图像与文本的双向批次对比目标 [66]，其思想可以扩展到工业配对数据，但工单时间不一定等于故障发生时间，粗糙配对会引入错误正样本。跨模态目标学到的是给定配对规则下的关联，不会自动建立因果对应。

14.4 无负样本学习与表示坍缩

如果只令两个增强视图的表示接近，所有输入都映射到同一个常量也能使距离为零，这称为表示坍缩。Bootstrap Your Own Latent (BYOL) 通过在线编码器、预测头和移动平均目标编码器构成不对称训练 [26]。用 sg 表示停止梯度，归一化后的预测与目标分别为 $\bar{q}_\theta$ 和 $\bar{z}_\xi$，则一个方向的损失

为

$$\ell_{\mathrm{BYOL}} = \left\| \overline{q}_\theta(v_1) - \mathrm{sg}\big(\overline{z}_\xi(v_2)\big) \right\|_2^2, \qquad \xi \leftarrow \mu\xi + (1-\mu)\theta. \tag{14.14}$$

实际训练交换视图后再平均。这里 θ 和 ξ 表示两分支中对应编码与投影模块的参数，在线预测头单独通过梯度更新。停止梯度和移动平均控制目标变化，并不使任意网络与任意数据增强都自动免于坍缩。

Simple Siamese (SimSiam) 去掉移动平均目标更新，使用共享编码器、预测头和停止梯度构造更简洁的孪生学习 [14]。Self-Distillation with No Labels (DINO) 则让学生匹配教师在不同裁剪视图上的概率输出，并以移动平均教师、输出中心化和温度锐化调节目标分布 [9]。这些方法的教师通常来自学生训练轨迹，而不是额外人工标签，因此属于自蒸馏。训练中要检查特征方差、有效秩和样本间距离，不能只看两个分支越来越一致。

另一类方法直接约束表示统计量。VICReg 组合视图一致性、各维方差下限和非对角协方差惩罚 [3]：

$$\mathcal{L} = \lambda_s \mathcal{L}_{\mathrm{inv}} + \lambda_v \mathcal{L}_{\mathrm{var}} + \lambda_c \mathcal{L}_{\mathrm{cov}}. \tag{14.15}$$

对中心化批次表示 $Z \in \mathbb{R}^{B\times d}$，协方差为 $C = Z^\top Z/(B-1)$，协方差项惩罚 C 的非对角元素平方，方差项则惩罚标准差低于给定阈值的维度。两项通常分别作用于两个视图分支。它以显式统计约束抑制常量表示和维度冗余，但小批次统计不稳定，低相关性也不保证所有维度都具有诊断意义。

停止梯度和统计约束究竟改变了什么。 对单位向量 q, z，$\|q - z\|^2 = 2 - 2q^\top z$，所以 BYOL 的距离最小化也在最大化方向一致性。若目标 z 停止梯度，单次更新只改变在线分支，而目标编码器通过移动平均间接改变。把动量递推展开，得到

$$\xi_t = \mu^t \xi_0 + (1-\mu)\sum_{s=1}^{t} \mu^{t-s}\theta_s. \tag{14.16}$$

教师因此是历史学生的指数加权组合：较大的 μ 平滑噪声，也增加对新分布的响应延迟。停止梯度不是修改距离的数值，而是修改计算图的导数路

径；它与预测头、归一化和优化共同作用，单独的常量映射依然能让一致性项为零。

为了明确 VICReg 如何额外排斥这个解，令未中心化批次表示为 $Z^{(a)} \in \mathbb{R}^{B\times d}$、$a \in \{1,2\}$，$B > 1$，中心化后协方差为 $C^{(a)}$。一组明确的损失约定是

$$\mathcal{L}_{\text{inv}} = \frac{1}{B}\sum_{i=1}^{B} \|z_i^{(1)} - z_i^{(2)}\|_2^2, \tag{14.17}$$

$$\mathcal{L}_{\text{var}} = \frac{1}{2d}\sum_{a=1}^{2}\sum_{j=1}^{d} \max\{0, \gamma - \sqrt{C_{jj}^{(a)} + \epsilon}\}, \tag{14.18}$$

$$\mathcal{L}_{\text{cov}} = \frac{1}{2d}\sum_{a=1}^{2}\sum_{j\neq k} (C_{jk}^{(a)})^2. \tag{14.19}$$

这里 $\gamma > \sqrt{\epsilon} > 0$ 规定标准差下限。常量表示使一致性和协方差项都为零，却令每一维方差惩罚严格为正；所有维度复制同一个变化信号能够通过方差检查，却会产生很大的非对角协方差。这说明两种统计惩罚分别针对无变化和重复编码，缺一不可。不过 $\operatorname{rank}(C) \le \min(d, B-1)$，当 $d > B-1$ 时不可能在一个批次内同时达到全维正方差与严格零非对角协方差。损失权重是在这些目标间折中，而不是保证有限批次出现理想白化表示。

可把停止梯度先看成标量操作：$L = (a - \operatorname{sg}(b))^2$ 在 $a = 1, b = 2$ 时值为 1，对 a 的导数为 -2，而沿被停止的目标路径对 b 的导数为零。若移去 sg，数值仍为 1，但对 b 的导数变为 2。教师不是“知道真相”的专家，只是提供当前更新暂不追赶的目标。比如教师参数 $\xi = 0$、学生对应参数 $\theta = 1$、$\mu = 0.9$ 时，移动平均把教师更新到 0.1，不是立刻复制成 1。

无负样本方法避免了显式的负样本队列或大规模两两比较，却仍依赖增强、架构和优化。对比、蒸馏与重建可以组合，但新增目标会引入权重与梯度冲突。应先验证单一目标，再判断组合是否保留了不同的有效信息，而不是因目标数量增加就推断表示更通用。

14.5 数据组织与领域继续预训练

预训练数据应登记来源、设备、时间、工况和使用许可。没有标签不等于可以随意使用：历史记录可能含有机密信息，也可能已经包含后续测试期的数据。对连续波形，应先按设备或时间段划分，再切窗口；否则同一段波形的重叠片段会落入不同集合，让表示看起来比实际更好。归一化统计和滤波参数也只能用规则允许的数据估计。

领域继续预训练在已有参数上使用领域数据延续学习。领域自适应预训练与任务相关语料预训练在语言任务中已有系统研究 [28]。对工业波形，相应思路是在通用信号表示上使用目标设备族的历史无标签数据，但应区分部署前可用历史与未来测试期数据。使用无标签测试输入属于不同的信息使用规则，不能悄悄并入普通归纳评估。

只使用狭窄领域数据继续训练可能遗忘通用能力，也可能过拟合设备身份。可比较较小学习率、较短训练、混合原始数据或限制可训练参数等策略。若采用数据混合，可令来源 s 以概率 q_s 被采样，$\sum_s q_s = 1$。按样本量取 q_s 使大来源占主导，均衡来源则会重复小数据集；两者改变了优化分布，需要记录而不能仅报告总样本数。

例如两个来源分别有 900 和 100 个窗口，按样本量抽取对应 $q_1 = 0.9, q_2 = 0.1$；均衡来源则取 $q_1 = q_2 = 0.5$。若总共抽取 1000 次，后一种策略平均各抽 500 次，小来源的单个窗口会被重复使用得更多，但并未产生 500 条独立信息。采样比例需要围绕目标设备群确定，不能只以损失更低为由过度重复容易的来源。

固定算力预算下，模型规模、有效样本量、输入长度和训练步数存在取舍。遮蔽率改变任务难度和部分架构的计算量，队列长度改变负样本覆盖，继续训练改变历史知识的保留。比较时应记录实际处理样本或词元数、去重比例、训练时间与峰值显存。跨领域缩放规律不能直接当作当前工业数据的性能承诺。

预训练产物应同时保存模型、输入规范、数据来源和训练截止时间。投影头是否保留、归一化层统计是否更新、通道顺序如何定义，都会影响复

用结果。所谓冻结编码器还应说明是否固定归一化运行统计，否则无参数梯度更新也可能改变模型行为。预训练模型版本应与适用设备和数据使用规则绑定。

14.6 工业振动信号的完整学习任务设置

考虑利用多个设备的历史振动记录预训练编码器，再以有限故障标签进行诊断。首先限定预测对象：窗口状态分类、未来故障预测和故障严重度回归需要保留的信息不同。本例以窗口状态分类为教学任务，输入为窗口内多通道波形及允许获得的运行条件，不假定已有实验结果。

按设备划分预训练与下游评估范围，再按连续记录或运行批次组织窗口。跨设备泛化试验中，测试设备的无标签记录也不进入预训练；若研究目标设备无标签适应，则另设一组明确允许该信息的规则。故障状态标签只能来自可核查记录，不能将未标注窗口全部视为正常。

掩码方案可将波形分成连续片段，只向编码器显示可见片段，再预测被遮蔽片段。对比方案可使用不改变窗口状态的裁剪和经过幅值校准的小噪声，增强幅度在训练与验证范围内选择。若裁剪可能移除唯一故障冲击，两视图便不再可靠共享状态，应限制裁剪或改用其他目标。转速变化明显时，可以在明确的工况条件下比较，避免把转速差异一律当作应消除的干扰。

对照应包括随机初始化、适用的监督预训练，以及在相同数据范围下的代表性自监督目标。线性探测与全量微调分别报告，至少在多个标签预算下绘制学习曲线，比较每类故障召回、宏平均指标、误报及校准。若使用同一个预训练模型服务多个任务，可另外报告摊销成本，但不能把预训练计算完全隐藏。

消融应保持数据和计算条件尽量一致。例如固定编码器比较随机点遮蔽与连续片段遮蔽，检验收益是否来自更长上下文；固定增强比较是否使用投影头，检验下游表示与训练目标空间的区别；固定预训练样本量比较

Algorithm 2 工业信号预训练与下游表示评价

Require: 按设备和时间划分的数据、预训练目标、有限下游标签

固定允许使用的数据、窗口边界、归一化与增强规则
初始化编码器及预训练辅助头
for 每个预训练批次 **do**
    按设备和工况采样窗口，生成掩码或增强视图
    计算选定的重建、对比或自蒸馏损失
    更新在线参数，并按算法更新教师或队列
    监测目标损失、表示方差和不同来源的训练贡献
end for
在固定标签子集上训练线性探测头，并单独进行微调对照
用验证集选择配置，冻结选择后在独立测试集上评价

来源混合，检验模型是否依赖某个设备族。注意单纯匹配训练轮数不一定匹配算力，尤其是不同遮蔽编码和对比批次设置之间。

预训练损失下降但线性探测不改善，可能说明任务主要学到了插值或身份线索。线性探测改善而微调收益消失，则需检查标签量、适应策略和优化预算。某些设备收益明显、另一些退化时，应报告子群差异，而非只用平均分掩盖负迁移。表示可视化只提供诊断线索，不能代替独立分类或预测评价。

监督预训练、自监督目标和表示坍缩可结合下面的教程复习，分别关注训练目标与对比/非对比表示学习。

辅助学习材料

- **Self-Supervised Representation Learning**；作者/平台：Lilian Weng；英文；技术教程。重点阅读 pretext tasks、上下文预测和 Contrastive Predictive Coding，帮助理解本章的重建、对比目标和表示质量。在线阅读。

- **Transfer Learning for Computer Vision**；作者/平台：PyTorch 官方教程；英文；代码教程。重点看 pretrained weights、fine-tuning、feature extraction 和 augmentation，帮助理解本章从通用预训练到领域继续训练的实验边界。在线阅读。

- **通俗易懂讲 AI–自监督学习**；知乎；中文解说。区分预训练辅助目标与下游目标，比较遮蔽、重建和对比学习；标题与主题据必应索引，原页受限。在线阅读。

- **【深度学习】自监督学习详解（self-supervised learning）**；CSDN；中文博客。阅读对比学习和生成学习的入门说明，表示质量仍须由独立下游任务评价；已读取公开页面引言与方法概述。在线阅读。

- **2021 - 自监督式学习 (二) -BERT 简介**；李宏毅；bilibili；中文课程。选看第 72 集，以语言遮蔽预训练为例对照本章自监督目标。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量；已核对目录与计数，未逐帧观看。观看分集。

本章小结。 预训练的设计由三件事共同决定：哪些数据可以使用、什么变化应当保持一致、什么信息必须保留。监督目标利用已有标签，掩码与生成目标恢复缺失或后续内容，对比目标定义样本关系，自蒸馏和统计约束抑制表示退化。这些目标的数学结构对应不同偏好：平方误差输出条件均值，对比交叉熵放大难区分候选的作用，停止梯度改变优化路径，方差与协方差项分别约束常量坍缩和维度重复。理解这些偏好，比记住某个模型名称更有助于判断故障信息会不会被保留。

判断预训练是否有用，要在独立任务上给出相同标签预算，再比较线性探测或微调后的结果。报告中应写清用了哪些历史数据，怎样增强或遮蔽，表示有没有退化，以及故障识别究竟改善多少。辅助损失下降只能说明辅助任务学得更好。下一章接着检查这些表示换到新设备后是否仍适用，并讨论重加权、表示对齐、参数适配和负迁移。

第十五章　迁移学习

本章摘要。迁移学习利用已有数据、表示或参数降低目标任务的学习成本。本章先区分任务变化与分布偏移，再从风险重加权、表示对齐和参数适配推导主要算法，最后讨论测试时适配与负迁移。选择依据是哪些假设仍成立，而不是预训练模型有多大。

上一章把大量历史观测压缩成一个可复用的编码器，但“可复用”只是潜力，不是新设备上的性能承诺。旧相机学到的边缘结构可能仍然有用，照明统计可能需要更新，而不同产品的缺陷定义甚至可能不再相同。本章因此从参数初始化走向目标风险：不是询问源模型有多强，而是询问源数据中的哪些关系在目标环境中仍成立。

这里存在三种不同的干预。若预测关系不变而采样频率改变，可重加权样本；若不同观测方式背后存在共享语义，可尝试对齐表示；若目标任务需要新的决策规则，则必须更新分类头或部分骨干。三种干预对应不同假设，不能把它们看成可互换的技巧。本章先推导风险如何从源分布转换到目标分布，再解释统计对齐与域对抗到底消除了什么差异，随后讨论有限标签与计算预算下的参数适配，并用负迁移说明这些方法的边界。

假设两台相机的图像颜色变得更接近了，还要检查裂纹和正常纹理是否仍能区分。对齐指标下降，只说明某种分布差异缩小，不能直接说明目标设备上的故障更容易识别。章末再考虑连续更新：用新设备数据改好模型后，旧设备上的故障还能不能识别？下一章的持续学习就从这里开始。

15.1 源域知识与目标域风险

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

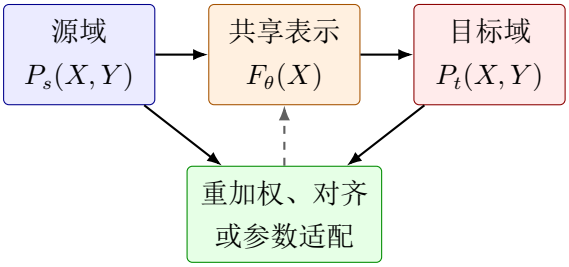


图 15.1: 迁移学习的核心是把源域知识送入目标域，同时检验哪些分布或任务假设仍然成立。

图15.1将源域知识、适配过程和目标域评价分开；共享参数并不意味着分布相同，目标域验证必须检验迁移后是否降低了实际风险。设源域与目标域联合分布分别为 $P_s(X,Y)$ 与 $P_t(X,Y)$，目标是降低 $R_t(f)=\mathbb{E}_{P_t}\ell(f(X),Y)$。迁移学习允许域或任务发生变化，领域自适应通常保持预测任务并处理域差异，领域泛化则要求在训练时未见的域上工作 [64]。新相机质检可保持缺陷类别不变，跨产品迁移却可能改变标签空间；二者不能使用同一适配规则。

读到风险与密度比时，可先把期望看成按出现概率加权的平均损失；后文的两工况例子先用有限个数说明这个平均如何改变，再推广到积分。使用迁移方法前还要列明手头有什么：源标签、预训练参数、目标无标签输入和目标标签是四种不同资源，不能默认全部可用。

这里的“域”是数据产生环境及其分布，不只是文件夹名称；“任务”包括要预测什么和怎样计算错误。X 是输入，Y 是目标标签，$f(X)$ 是预测，ℓ 把单次错误变成一个数，风险 R_t 是目标环境中这些错误的期望。例如零一损失在判对时为 0、判错时为 1，风险就是错误率；若使用交叉熵，风险衡量的还包括预测概率的好坏，不能直接当成错误率。联合分布 $P(X,Y)$ 同时描述输入和标签；边缘分布 $P(X)$ 忽略标签；条件分布 $P(Y\mid X)$ 描述

给定输入后的标签规则。

预训练与迁移的分工也由此明确：前者产生一组参数，后者要证明使用这些参数或源数据确实降低了目标风险。即使无需更新参数、直接复用源模型，也是一种需要目标评价的复用方式；微调只是迁移的一种手段。

协变量偏移假定 $P_s(Y \mid X) = P_t(Y \mid X)$ 而输入边缘分布变化；标签偏移假定 $P_s(X \mid Y) = P_t(X \mid Y)$ 而类别比例变化；概念变化则涉及预测关系本身。实际数据可能同时存在多种变化。仅观察无标签目标输入通常无法确定标签机制是否改变，因此无监督适配不能替代目标标签审核。

15.2 实例重加权与分布对齐

重要性加权。 在协变量偏移且目标分布支撑被源分布覆盖时，目标风险可写为

$$R_t(f) = \mathbb{E}_{P_s}\left[w(X)\ell(f(X), Y)\right], \qquad w(x) = \frac{p_t(x)}{p_s(x)}. \tag{15.1}$$

先用源、目标输入估计密度比，再最小化加权源域损失。核均值匹配直接使加权源域特征均值接近目标均值，避免分别估计高维密度 [37]。若用域分类器估计比值，必须校正训练时源、目标样本的先验比例。大权重会使少数样本主导梯度，截断权重可以降低方差但引入偏差。有效样本量 $(\sum_i w_i)^2 / \sum_i w_i^2$ 可用于判断加权是否退化。

先用两个工况手算权重。 设输入只有低速、高速两种工况，源比例为 $(0.8, 0.2)$，目标比例为 $(0.4, 0.6)$，并假定同一工况中的预测关系不变。两组权重分别为 $0.4/0.8 = 0.5$ 和 $0.6/0.2 = 3$。若某模型两组平均损失为 $0.1, 0.5$，源风险为 $0.8\times0.1+0.2\times0.5 = 0.18$，目标风险为 $0.4\times0.1+0.6\times0.5 = 0.34$。加权源风险 $0.8 \times 0.5 \times 0.1 + 0.2 \times 3 \times 0.5 = 0.34$ 恰好一致。权重不是把高速样本改成新样本，而是增加它们对平均损失和梯度的贡献。若源数据完全没有高速工况，分母为零，重加权就无法替代采集数据。

风险恒等式、密度比估计与方差。 以离散标签和连续输入为例，协变量偏移要求对目标几乎处处的 x，两域条件分布相同，且 $p_t(x) > 0$ 时 $p_s(x) > 0$。于是

$$R_t(f) = \int \sum_y \ell(f(x), y) p_t(y \mid x) p_t(x)\, \mathrm{d}x \tag{15.2}$$

$$= \int \sum_y \ell(f(x), y) p_s(y \mid x) p_s(x) \frac{p_t(x)}{p_s(x)}\, \mathrm{d}x. \tag{15.3}$$

式(15.3)才是可从源标签估计的量。支撑覆盖不是技术性装饰：源域从未出现的输入区域没有标签项可重用，任何有限权重都不能补上这部分风险。

令域指示 $D = 1$ 表示目标，域分类器训练混合中的先验为 π_t 与 $\pi_s = 1 - \pi_t$，其校准输出为 $q(x) = P(D = 1 \mid x)$。由贝叶斯公式

$$\frac{q(x)}{1 - q(x)} = \frac{\pi_t p_t(x)}{\pi_s p_s(x)}, \qquad w(x) = \frac{\pi_s}{\pi_t} \frac{q(x)}{1 - q(x)}. \tag{15.4}$$

若训练时人为平衡两域，先验就是该平衡采样的比例，而不是原始数据库大小的比例。q 接近 1 使估计非常不稳定；高域分类准确率此时可能表明重叠不足，而不是重加权更可靠。

对独立源样本，使用真实权重的估计 $\widehat{R} = n_s^{-1} \sum_i w_i \ell_i$ 在可积时无偏；有限方差时其方差为 $\mathrm{Var}_s(w\ell)/n_s$。若截断为 $\bar{w} = \min(w, c)$，且 $0 \le \ell \le L_{\max}$，则

$$0 \le R_t - \mathbb{E}_s[\bar{w}\ell] = \mathbb{E}_s[(w - c)_+ \ell] \le L_{\max} \mathbb{E}_s[(w - c)_+]. \tag{15.5}$$

这显式展示了截断的偏差来源。自归一化估计 $\sum_i w_i \ell_i / \sum_i w_i$ 也通常具有有限样本偏差，但可改善数值稳定性。有效样本量来自归一化权重 $\alpha_i = w_i / \sum_j w_j$ 的 $1/\sum_i \alpha_i^2$：全部相等时为 n_s，一个样本几乎占全重时接近 1；它是权重集中的诊断量，不是所有损失下精确的独立样本数。

标签偏移下，权重改为类别先验比 $p_t(y)/p_s(y)$。这个结论来自 $p_t(x, y) = p_s(x \mid y) p_t(y) = p_s(x, y) p_t(y)/p_s(y)$，要求目标出现的类别在源域具有正概率。若希望从无标签目标数据估计先验，可先固定一个分类器，定义源验证

集上的混淆矩阵 $C_{ky} = P_s(\widehat{Y} = k \mid Y = y)$。标签偏移意味着该矩阵在目标域不变，目标预测类别频率 $\mu_k = P_t(\widehat{Y} = k)$ 满足 $\mu = C\pi_t$，其中 $\pi_t \in \mathbb{R}^K$ 是目标类别先验。可在 $\pi_t \geq 0$、$\mathbf{1}^\top \pi_t = 1$ 约束下拟合这个线性关系。矩阵列若近似相同，分类器不能区分类别，先验反演便病态；若 $P(X \mid Y)$ 也改变，则关系本身失效。它不能直接与协变量偏移权重互换。若目标域出现源域从未包含的故障，仅靠重加权不能产生缺失的类别证据。

标签偏移可手算为另一种情形：两个真实类别上的混淆矩阵为 $C = \begin{bmatrix} 0.9 & 0.2 \\ 0.1 & 0.8 \end{bmatrix}$，每列对应一个真实类别，每列和为 1。若目标预测频率为 $\mu = (0.55, 0.45)^\top$，写真实类别比例为 $(a, 1-a)^\top$，第一行给出 $0.55 = 0.9a + 0.2(1-a)$，故 $a = 0.5$。这个反演只有在目标域仍保留这些类条件识别率时成立，不能把预测频率直接当成真实类别频率。

Maximum Mean Discrepancy (MMD) 与 Correlation Alignment (CORAL)。 深度适配网络在特征 $z = F_\theta(x)$ 上同时优化源域监督损失和域差异 [56]：

$$\mathcal{L} = \mathcal{L}_s + \lambda \left\| \frac{1}{n_s} \sum_i \varphi(z_i^s) - \frac{1}{n_t} \sum_j \varphi(z_j^t) \right\|_{\mathcal{H}}^2 . \tag{15.6}$$

核技巧将平方范数展开为源源、目标目标和源目标三组核值，无需显式构造 φ。训练时从两域抽取批次，计算分类与对齐损失，再共同更新编码器。核带宽决定比较的尺度，多核 MMD 组合不同带宽以减少对单一尺度的依赖。

φ 把表示映射到用于比较分布的特征空间 $\mathcal{H}$，核函数 $k(u, v)$ 直接计算该空间中的内积，因此不必真的存储可能无限维的 $\varphi(u)$。例如线性核 $k(u, v) = u^\top v$ 就是在原特征空间比较均值；高斯核 $k(u, v) = \exp(-\|u - v\|^2/(2b^2))$ 用带宽 $b > 0$ 控制多远的两个样本仍被视为相似。MMD 是最大均值差异，CORAL 是相关性对齐；本节给出的 CORAL 实际比较协方差矩阵，而不是逐个样本配对。

核均值差的实际计算。 设 $k(u,v)=\langle\varphi(u),\varphi(v)\rangle_{\mathcal{H}}$ 为正定核，$z\in\mathbb{R}^d$。将式(15.6)中的平方范数按 $\|a-b\|^2=\langle a,a\rangle+\langle b,b\rangle-2\langle a,b\rangle$ 展开，得到

$$\widehat{\mathrm{MMD}}_b^2=\frac{1}{n_s^2}\sum_{i,i'}k(z_i^s,z_{i'}^s)+\frac{1}{n_t^2}\sum_{j,j'}k(z_j^t,z_{j'}^t) \tag{15.7}$$

$$-\frac{2}{n_sn_t}\sum_{i,j}k(z_i^s,z_j^t). \tag{15.8}$$

这是含对角项的非负、有偏估计。若两域样本分别独立同分布且 $n_s,n_t>1$，去掉前两项中相同下标的配对，并将分母换为 $n_s(n_s-1)$ 和 $n_t(n_t-1)$，可得到总体平方 MMD 的无偏估计；后者有限样本下可能为负，不能误认为程序必定出错。采用特征核（characteristic kernel）时，核均值能够唯一确定其适用分布类中的分布，因此总体 MMD 为零可以识别分布相同；这里不是泛指作用于特征的任意核，线性核就只检查均值相同。无论采用哪种核，比较对象都是 $P_s(Z)$ 与 $P_t(Z)$，并没有自动检查 $P_s(Y\mid Z)$ 与 $P_t(Y\mid Z)$。

CORAL 对齐二阶统计量 [83]：

$$\mathcal{L}_{\mathrm{CORAL}}=\frac{1}{4d^2}\|C_s-C_t\|_F^2, \tag{15.9}$$

其中 C_s,C_t 为 d 维表示的批次协方差。具体地，把样本按行写成 $Z_s\in\mathbb{R}^{n_s\times d}$，令 $H_s=I_{n_s}-\mathbf{1}\mathbf{1}^{\top}/n_s$，则 $C_s=Z_s^{\top}H_sZ_s/(n_s-1)$，目标域同理。由于 C_s-C_t 对称，矩阵微分给出

$$\nabla_{Z_s}\mathcal{L}_{\mathrm{CORAL}}=\frac{H_sZ_s(C_s-C_t)}{d^2(n_s-1)}. \tag{15.10}$$

可见梯度来自中心化表示与协方差差异的乘积，源、目标均值本身不在该损失中；如果还需均值对齐，应另行添加对应项。$n_s=1$ 时样本协方差未定义，小批次下秩至多为 n_s-1，也解释了协方差估计为何依赖批次组织。它计算直接，但小批次协方差不稳定，而且二阶一致不代表类别条件分布一致。MMD 与 CORAL 都可能把不同类别拉近；存在目标标签时应检查类条件结构，使用伪标签时则需控制错误对齐的累积。

一维源表示 $(-1,1)$ 与目标表示 $(-2,2)$ 的均值都为零，线性核 MMD 因而为零；样本方差却分别为 2 与 8，CORAL 损失为 $(2-8)^2/4=9$。相反，把 $(-1,1)$ 整体平移为 $(4,6)$ 后，方差不变，CORAL 为零，均值差却为 5。这两个手算例子解释了为何均值、协方差检查互不替代，更不能替代标签语义检查。$\|A\|_F^2$ 就是矩阵所有元素的平方和。

域对抗适配。 Domain-Adversarial Neural Network (DANN) 用域判别器 D 识别表示来自哪一个域 [24]。若域损失为交叉熵，目标写为

$$\min_{F,C}\max_{D}\ \mathcal{L}_s(C(F(x_s)),y_s)-\lambda\mathcal{L}_d(D(F(x)),d). \tag{15.11}$$

域判别器最小化自己的交叉熵，编码器通过梯度反转最大化该损失，同时维持源域分类能力。实现时不能将两个模块都沿同一符号更新。域准确率接近随机只是对齐的诊断信号，并非目标分类正确的证据；特征全部坍缩也可使域不可区分。

域不可区分为何不是语义正确。 为了看清目标的符号，采用等域权重的域损失

$$\mathcal{L}_d=-\mathbb{E}_s\log(1-D(Z))-\mathbb{E}_t\log D(Z). \tag{15.12}$$

固定编码器，在具有特征密度且 $p_s(z)+p_t(z)>0$ 的点逐点最小化，得到

$$D^*(z)=\frac{p_t(z)}{p_s(z)+p_t(z)}.$$

两域密度都为零的点不贡献损失；仅一方密度为零时，最优值在边界，严格取值于 $(0,1)$ 的判别器只能趋近它。下式的最小值按允许边界输出的理想判别器理解。代回可得

$$\min_D\mathcal{L}_d=\log 4-2\,\mathrm{JS}(P_s^Z\|P_t^Z), \tag{15.13}$$

其中 $\mathrm{JS}(P\|Q)=\frac{1}{2}\mathrm{KL}(P\|M)+\frac{1}{2}\mathrm{KL}(Q\|M)$，$M=(P+Q)/2$。因此在判别器充分优化这一理想条件下，编码器最大化域损失相当于减小特征边缘

分布差异。若实现中再把两域损失除以 2，常数和系数也相应减半，方向不变。

但令两域特征都均匀取 $-1,+1$，源域标签满足 $Y=\mathbf{1}[Z=1]$，目标域却满足 $Y=\mathbf{1}[Z=-1]$。两域特征分布完全相同，任何域判别器都只能猜测，而源分类器在目标域全部判错。这个反例说明真正需要的是可共享的预测关系，而不只是看不出设备来源。二分类的零一风险可用理论形式

$$R_t(h)\le R_s(h)+\tfrac{1}{2}d_{\mathcal{H}\Delta\mathcal{H}}(P_s^X,P_t^X)+\lambda^*,\qquad \lambda^*=\min_{h\in\mathcal{H}}(R_s(h)+R_t(h)) \tag{15.14}$$

理解这一点：差异量定义为 $2\sup_{h,h'\in\mathcal{H}}|P_s(h\neq h')-P_t(h\neq h')|$，检查假设对在两域的分歧概率；$\lambda^*$ 则表达同一分类器同时做好两个域的可能性。这是总体风险界，有限样本估计还需要复杂度误差项；域对抗损失也不等于这个差异量的精确值。对齐可以降低某种域差异，却不能从无标签输入中证明 λ^* 很小。

条件对齐将类别预测纳入域判别输入，以区分同一域中的不同语义。多源适配对不同源域分别估计可信度，避免样本最多的源主导目标；部分域适配需降低源域独有类别的权重，开放集适配则必须识别目标域未知类别。这些变体改变的是标签空间假设，不能只通过调大域对齐系数实现。

15.3 预训练、微调与参数高效适配

第十四章讨论如何从预训练数据构造可复用表示，本节转向已有表示如何适应目标任务。预训练提供初始化，但目标任务仍决定哪些层需要改变。线性探测冻结编码器只训练头，可检验原表示是否已具有判别性；逐层解冻先调整高层，再判断低层滤波是否需要变化；全量微调自由度最大，也更容易在少量目标样本上过拟合。比较时应固定目标标签量、预训练来源与超参数搜索预算。

Adapter 在冻结骨干中插入低维瓶颈。对输入表示 h，一个残差适配器可写为 $h'=h+W_{up}\sigma(W_{down}h)$，只训练新增参数 [34]。LoRA 则令权重更新 $\Delta W=BA$，以秩 r 限制更新自由度 [36]。二者都降低每个目标域的存

储开销，但低秩不意味着任何域变化都能被表达。提示学习优化输入或中间层的提示向量，适合保持基础模型不变的条件化使用；其可迁移性仍取决于基础模型是否理解目标语义。

低秩更新的维度、梯度与容量。 令冻结的线性层为 $W_0 \in \mathbb{R}^{d_{out}\times d_{in}}$，输入 $x \in \mathbb{R}^{d_{in}}$。LoRA 使用 $A \in \mathbb{R}^{r\times d_{in}}$、$B \in \mathbb{R}^{d_{out}\times r}$ 及尺度 $s = \alpha/r$，输出为

$$y = (W_0 + sBA)x. \tag{15.15}$$

可训练参数数目为 $r(d_{out} + d_{in})$，更新秩不超过 r。记 $W_{eff} = W_0 + sBA$，则 $G = \partial\mathcal{L}/\partial W_{eff} \in \mathbb{R}^{d_{out}\times d_{in}}$，矩阵链式法则给出

$$\nabla_B\mathcal{L} = sGA^\top, \qquad \nabla_A\mathcal{L} = sB^\top G. \tag{15.16}$$

这解释了常见的随机初始化 A、零初始化 B：初始 $BA = 0$ 保证原输出不变，同时 B 可以收到非零梯度；若两者都初始化为零，则两条梯度都为零，低秩分支无法启动。假如理想全量更新 ΔW^* 的奇异值为 $\sigma_1 \geq \sigma_2 \geq \cdots$，最佳秩 r 矩阵近似的平方 Frobenius 误差为 $\sum_{j>r}\sigma_j^2$。因此低秩适配隐含的是有用更新可被少数方向近似，而非原权重本身低秩；该矩阵逼近结论也不等于网络任务风险的误差界。

对 Adapter，若 $h \in \mathbb{R}^d$、瓶颈宽度为 r，则 $W_{down} \in \mathbb{R}^{r\times d}$、$W_{up} \in \mathbb{R}^{d\times r}$，忽略偏置时有 $2dr$ 个参数。它的非线性瓶颈通常不能像单个线性 LoRA 更新那样直接合并进原权重。选择应同时看可表达变化、路由和推理限制，而不只看参数比率。

可用一个小矩阵检查低秩的含义。令 $d_{in} = d_{out} = 2, r = 1, s = 1$，$A = [1\ \ 2]$、$B = [3\ \ 4]^\top$，则 $BA = \begin{bmatrix} 3 & 6 \\ 4 & 8 \end{bmatrix}$；对 $x = (1,0)^\top$，新增输出为 $(3,4)^\top$。两列彼此成比例，所以只有一个独立更新方向。这个极小例中参数数目仍为 4，并不省参数；若原层为 100×100 且 $r = 2$，才从 10000 个参数降为 400 个。实际省参数需要 $r(d_{out} + d_{in}) < d_{out}d_{in}$，低秩的名字本身不是节省保证。

参数量、训练显存与推理开销应分别报告。冻结权重仍可能需要存储用于反向传播的激活；多个 Adapter 需要路由规则，LoRA 合并则需要确认目标域选择是否明确。不能把参数高效方法自动视为持续学习算法：若所有域共享并反复覆盖同一个低秩更新，仍会遗忘旧域。

15.4 测试时适配与负迁移

测试时适配只使用部署输入调整有限参数。Tent 最小化预测熵，并在其设定下更新归一化层仿射参数 [92]：

$$\min_{\eta} \frac{1}{|B|} \sum_{x \in B} \left[-\sum_{k} p_\eta(k \mid x) \log p_\eta(k \mid x) \right]. \tag{15.17}$$

先保留训练好的模型，按部署批次计算熵，再对允许更新的参数执行梯度步。低熵可能是正确判断，也可能是错误自信。类别极不平衡、批次很小或流中含未知故障时，熵最小化可能将预测推向单一类别。逐批重置与持续累积更新是不同规则，必须明确是否保留适配状态。

用二分类数值理解熵：$p = (0.5, 0.5)$ 时 $H = \log 2 \approx 0.693$，$p = (0.9, 0.1)$ 时 $H \approx 0.325$，确定预测时熵趋于零。若真实类别恰是第二类，后一个预测虽然熵更低，却错得更自信。因此无标签目标衡量的是预测集中程度，不是准确率。

部署评估还要规定信息到达顺序。严格在线的“先预测、后更新”先用当前模型记录本批结果，再利用本批无标签输入更新供后续批次使用；“先适配、后预测”允许本批输入参与自身预测前的更新，是另一种协议，不能混报。两种协议都不得访问未来批次或测试标签；重置频率、步数和学习率应由先前验证数据确定，而不是查看测试准确率后调整。

熵下降为什么会强化错误。 令类别 logits 为 $a \in \mathbb{R}^K$、$p = \mathrm{softmax}(a)$。由 $\partial p_k / \partial a_j = p_k(\mathbf{1}[k = j] - p_j)$，可逐项得到

$$\frac{\partial H(p)}{\partial a_j} = -p_j(\log p_j + H(p)). \tag{15.18}$$

二分类时令 $p=\sigma(a)$，则 $\mathrm{d}H/\mathrm{d}a=p(1-p)\log((1-p)/p)$。若 $p>1/2$，梯度下降会继续增大 a 和 p；若 $p<1/2$ 则进一步压低 p。没有标签参与时，这个更新没有能力识别当前偏向是否正确，只会强化已有偏向。熵适配因而依赖初始预测大体可信、低密度区域适合作决策边界等额外条件。应限制步数和漂移幅度，保留重置机制，并使用独立监测数据检验校准与少数类召回；这些操作降低风险，但仍不能构成无标签正确性保证。

负迁移指相对于合适的无迁移基线，使用源知识反而提高目标风险。应比较从零训练、线性探测、全量微调和轻量适配，并绘制随目标标签量变化的学习曲线。领域自适应理论中的分布差异项之外，还存在源、目标任务能否被同一假设同时解释的误差项 [6]；只减小域差异并不足够。

换了新相机后，先查清楚是亮度、镜头和噪声变了，还是“什么算缺陷”的定义变了。前一类问题可以先试归一化适配和线性探测；后一类问题需要重新核对标签。若规则允许，可以用新相机的无标签图像做适配，但测试标签只能留到最终评价。报告各类缺陷召回、未知输入拒识、校准、训练成本和发生负迁移的设备组。若还要长期维护旧相机能力，就需要下一章的持续学习机制。

迁移学习中的分布偏移、对齐与参数适配可用以下材料复习，分别覆盖数据变换和模型复用。

辅助学习材料

- **Transfer Learning**；作者/平台：Stanford CS231n；英文；课程笔记。阅读固定特征提取、微调以及数据规模和领域相似性对应的选择建议，理解迁移范围与过拟合风险。在线阅读。

- **Transfer Learning for Computer Vision Tutorial**；作者/平台：Sasank Chilamkurthy / PyTorch；英文；代码教程。比较微调整个网络与冻结特征提取器两种训练流程，核对训练参数范围和验证步骤；该教程不是 LoRA 实现。在线阅读。

- **什么是迁移学习（Transfer Learning）?**；知乎；中文解说。比较冻结特征与微调，记录可训练参数；标题与主题据必应索引，原页受限。在线阅读。

- **迁移学习 (Transfer Learning) 概述及代码实现**；CSDN；中文博客。对照源域与目标域划分，用无迁移基线识别负迁移；标题与主题据必应索引，原页受限。在线阅读。

- **第十一节 2021 - 概述领域自适应 (Domain Adaptation)**；李宏毅；bilibili；中文课程。选看第 110 集，对照本章分布差异与适应条件。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量；已核对目录与计数，未逐帧观看。观看分集。

本章小结。 迁移学习依次回答源知识是否相关、分布差异能否被估计、哪些参数应更新。重加权改变样本贡献，成立前提是正确的偏移假设和支撑覆盖；分布对齐改变表示，却必须额外保护类别语义；微调和低秩适配改变预测器，其容量与标签预算应匹配。测试时熵下降进一步说明，没有标签的自洽改进可能只是错误自信。所有路线都需要目标域证据与无迁移基线，不能以对齐损失下降代替目标风险下降。

实际选方法时，先核对新旧数据的标签含义是否相同，再看目标设备有多少标签、能否使用它的无标签记录，最后选择足够解决问题的适配办法。如果系统仍需服务旧相机，更新后就要一起复测；新相机得分提高、旧相机却明显退步，不能算整个更新任务已经完成。下一章据此讨论持续学习：数据不断到来时，怎样学习新情况、保留旧能力，并控制存储和计算开销。

第十六章　持续学习

本章摘要。持续学习把更新过程放到时间轴上，同时约束新知识获取、旧知识保持和资源增长。本章从增量设置出发，推导回放、梯度约束、参数正则和知识蒸馏，再比较隔离与扩展方法。评价对象是整个学习轨迹，而非最后一个任务。

上一章研究如何借助源知识降低一个目标域的风险。实际系统却往往没有永久不变的“最终目标域”：新相机、新工况和新故障按时间到达，上一轮的目标域很快又成为需要保护的历史域。如果每次适应都只考核最新数据，系统可能一边发布更好的新版本，一边失去识别旧故障的能力。本章将学习对象从一个最终模型改为一串带资源约束的更新过程；因此，读者要问的不是“最后一次训练是否收敛”，而是“沿时间轴是否持续服务所有仍需服务的分布”。

持续学习并非要求所有参数永远不变，而是要求区分有益的知识修正与不必要的历史破坏。旧数据能否保留、推理时是否知道任务身份、类别是否持续增加，会直接改变可用算法和评价标准。本章先说明回放如何近似历史风险，再从损失的局部变化推出梯度约束，从后验近似推出参数重要性惩罚，并解释蒸馏和参数隔离分别保留了什么。它们共同处理稳定性与可塑性的张力，但保护对象并不相同：样本风险、局部方向、参数邻域和可调用模块不能互相替代。

每次更新以后，都要重新测一遍仍需服务的旧设备，记录哪些故障开始漏检。只看最后一个阶段的总分，会看不到中途丢失的能力。另一个实际困难是，新到的记录往往还没有标签，专家不可能逐条检查。下一章的主动学习讨论怎样挑选优先标注的记录，再把得到的标签交给更新算法。

16.1 数据流、任务边界与遗忘

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

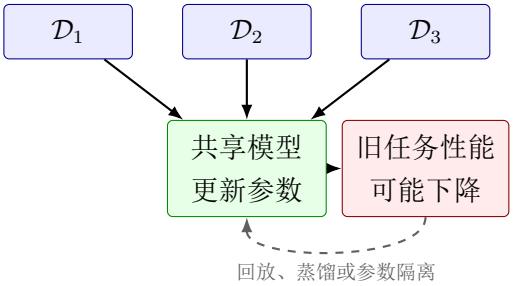


图 16.1: 持续学习沿数据流更新模型；新任务的可塑性与旧任务的稳定性形成直接张力。

图16.1沿任务流展示更新过程，并将旧知识保持与新任务适应并列；评价更新效果时须同时检查历史任务和当前任务，不能只看新数据损失。设数据依次到达 $\mathcal{D}_1, \ldots, \mathcal{D}_T$，学习第 t 阶段时通常无法完整访问历史数据。直接在新数据上继续优化会改变共享参数，旧分布风险可能增加，这就是灾难性遗忘的典型表现。持续学习的核心矛盾是可塑性与稳定性，而非单纯限制更新幅度 [17]。

任务增量通常在推理时提供任务身份，可选择相应输出头；类增量要求在已出现的所有类别中统一预测，测试时不提供任务身份；域增量通常保持标签空间而改变输入分布。类增量训练可以有已知阶段边界，不能把它与无边界数据流混为一谈。任务无关的在线持续学习进一步要求算法自行处理连续到达的数据，标签还可能延迟。

先分清一条样本、一个任务和一个阶段。 例如一台电机连续记录振动，把一段互不重叠的时间窗提取成 $x \in \mathbb{R}^d$，复检给出标签 $y \in \{1, \ldots, K\}$，这一对 (x, y) 才是一条有标签样本。设备是产生记录的物理对象；任务是规定输入、标签含义和评价分布的预测问题；阶段 t 是允许更新的时间区间。

一个阶段可以有多台设备，一台设备也可以经历多个阶段，三种编号不能混用。本章参数写作 $\theta \in \mathbb{R}^p$，模型输出 K 类概率，损失 $\ell_\theta(x, y)$ 是一个标量，例如真实类别概率为 0.8 时交叉熵为 $-\log 0.8$。梯度是损失对 p 个参数的偏导数组成的向量，更新 $\theta \leftarrow \theta - \eta \nabla_\theta \ell$ 才是实际改变模型的步骤。

为什么学新任务会影响旧任务。 用只有一个参数的例子，旧损失为 $(\theta-1)^2/2$、新损失为 $(\theta+1)^2/2$。旧任务训练到 $\theta = 1$ 后，新损失梯度为 2；步长 $\eta = 1/2$ 使参数变为 0，新损失从 2 降为 $1/2$，旧损失却从 0 升为 $1/2$。两个任务争用同一个参数，因而只优化当前损失不足以保留历史能力。真实网络不一定如此直接冲突，但也没有自动保存旧功能的机制。若标签定义本身被纠正，则旧测试标准也应按预定规则重审，不能把坚持错误旧标签当作成功保持。

16.2 经验回放与梯度约束

有限缓存如何近似历史风险。 经验回放保存大小为 M 的缓存 $\mathcal{B}$，每次从当前数据与缓存分别采样：

$$\mathcal{L}_t = \frac{1}{|B_t|} \sum_{(x,y)\in B_t} \ell_\theta(x, y) + \lambda \frac{1}{|B_m|} \sum_{(x,y)\in B_m} \ell_\theta(x, y). \tag{16.1}$$

先混合计算梯度并更新模型，再按既定策略更新缓存。蓄水池采样在观察到第 $n > M$ 个样本时，以 M/n 概率将其放入缓存，并均匀替换一个槽位，使历史每个样本有相同保留概率。类别均衡缓存则改变采样目标，保障少数类但不再保持原始频率。iCaRL 使用代表样本与蒸馏维护类增量表示，并以类均值进行预测 [72]。

把回放公式执行一次。 $\mathcal{B}$ 是跨轮保存的缓存，$B_m \subseteq \mathcal{B}$ 是本次抽取的旧样本小批，B_t 是当前小批；这里的竖线表示集合大小（样本数），不是向量范数。若当前两条损失为 $0.2, 0.6$，回放两条为 $0.1, 0.3$，且 $\lambda = 2$，目标值为

$0.4 + 2 \times 0.2 = 0.8$。更新时对这个加权和求导，不是把损失值直接从参数上减去。第一次还没有旧缓存时只计算当前项，不能除以 $|B_m| = 0$。容量 $M = 2$、已见两条记录时，第三条以 $2/3$ 概率入选，入选后在两个槽位中各以 $1/2$ 概率替换；所以每条旧记录被替换的概率为 $1/3$。这说明随机替换与每次总删最旧记录是不同算法。

缓存无偏性与风险权重不是同一件事。 设此前共观察到 n 个样本且缓存容量为 $1 \le M \le n$；$M = 0$ 表示停用回放，不计算缓存均值。蓄水池采样的等概率性质可由归纳法证明：第 n 个新样本的入选概率是 M/n；任一旧样本在 $n-1$ 时刻位于缓存的概率为 $M/(n-1)$，本轮被替换的条件概率为 $(M/n)(1/M) = 1/n$。所以它本轮后仍在缓存的概率为

$$\frac{M}{n-1}\left(1 - \frac{1}{n}\right) = \frac{M}{n}. \tag{16.2}$$

初始 $n = M$ 时所有样本都被保留，归纳因此成立。对固定参数 θ，缓存平均损失对采样随机性取期望等于历史经验平均损失：

$$\mathbb{E}_{\mathcal{B}}\left[\frac{1}{M}\sum_{i\in\mathcal{B}} \ell_\theta(x_i, y_i)\right] = \frac{1}{M}\sum_{i=1}^{n} \frac{M}{n}\ell_\theta(x_i, y_i) = \frac{1}{n}\sum_{i=1}^{n} \ell_\theta(x_i, y_i). \tag{16.3}$$

这是固定函数的抽样性质，不表示在同一缓存上反复优化后，所选模型的缓存分数仍是无偏泛化估计；模型会适应缓存，所以还需要固定的历史测试集。

此外，式(16.1)的训练目标除以 $1+\lambda$ 后对应新数据权重 $1/(1+\lambda)$ 与历史权重 $\lambda/(1+\lambda)$。若真要拟合所有已见样本的等权经验风险，当前阶段有 n_t 个样本、历史有 n_{old} 个样本时，应取 $\lambda = n_{old}/n_t$，并确保两侧批次各自代表相应经验分布。整体除以 $1+\lambda$ 不改变极小点，却会把梯度缩小同样倍数；对于无额外梯度变换的普通梯度下降，归一化后把学习率相应放大才能保持同一步更新；带自适应缩放、梯度裁剪或独立权重衰减的优化器不能直接套用这一等价关系。固定 λ 实际是在规定新旧风险的政策权重，而

不是自动复现全历史训练。对逐渐变化的设备，近期分布优先也许更合理，但必须说明这是主动选择的目标。

缓存按样本数公平并不等于按字节公平：原图、压缩特征与 logits 占用不同。特征回放节省空间，却依赖编码器版本兼容；生成回放用生成器代替原样本，但生成器本身也会遗忘，偏差可能逐阶段累积 [81]。保存合成样本也不能自动免除隐私审计。

梯度情景记忆（Gradient Episodic Memory，GEM）与 A-GEM。 GEM 将当前梯度 g 投影为与旧任务梯度 g_k 不冲突的 $\tilde{g}$[57]：

$$\min_{\tilde{g}} \frac{1}{2}\|\tilde{g}-g\|_2^2, \qquad \tilde{g}^{\top} g_k \geq 0 \quad \text{对所有旧任务} k. \tag{16.4}$$

因为梯度下降的旧损失一阶变化约为 $-\eta g_k^{\top}\tilde{g}$，该约束限制局部增损，而非保证有限步后的旧风险不升。A-GEM 用回放批次的平均参考梯度 g_r 替代全部约束 [11]。若 $g^{\top} g_r < 0$ 且 $\|g_r\| > 0$，投影为

$$\tilde{g} = g - \frac{g^{\top} g_r}{\|g_r\|_2^2} g_r; \tag{16.5}$$

否则保留原梯度。图16.2以二维情形展示这一投影过程。A-GEM 降低了计算开销，但只约束平均回放方向，少数旧任务仍可能受损。

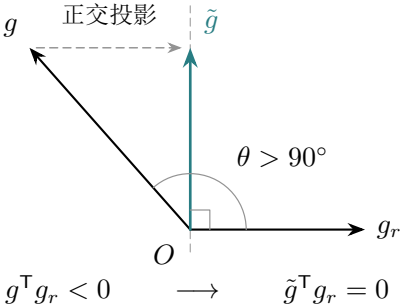


图 16.2: A-GEM 的二维梯度投影示意。当 $g^{\top} g_r < 0$ 时，将 g 正交投影到垂直于 g_r 的边界上，得到满足 $\tilde{g}^{\top} g_r = 0$ 的投影梯度。

从约束优化推出投影及其步长限制。 令参数维度为 p，$g, g_r, \tilde{g} \in \mathbb{R}^p$。单个约束的拉格朗日函数为

$$\mathcal{J}(\tilde{g}, \alpha) = \tfrac{1}{2}\|\tilde{g} - g\|^2 - \alpha g_r^\top \tilde{g}, \qquad \alpha \geq 0. \tag{16.6}$$

驻点条件给出 $\tilde{g} = g + \alpha g_r$。当 $g^\top g_r \geq 0$ 时约束已满足，$\alpha = 0$；否则最优点位于边界 $g_r^\top \tilde{g} = 0$，故 $\alpha = -g_r^\top g / \|g_r\|^2$，代回即得 A-GEM 公式。若 $g_r = 0$，该一阶约束没有信息，不应执行除法。对于 K_{old} 个旧任务，把梯度写成矩阵 $G = [g_1, \ldots, g_{K_{\text{old}}}] \in \mathbb{R}^{p \times K_{\text{old}}}$；这里旧任务数不同于类别数 K。此时 $\alpha \in \mathbb{R}^{K_{\text{old}}}$ 为逐任务的非负乘子向量，同样有 $\tilde{g} = g + G\alpha$，对偶问题成为

$$\min_{\alpha \geq 0} \ \tfrac{1}{2}\alpha^\top G^\top G \alpha + \alpha^\top G^\top g. \tag{16.7}$$

这把高维参数空间中的投影转换为以旧任务数为变量数的二次规划，但需要计算和保存参考梯度。

即使投影精确，有限步长仍可能增加旧损失。若旧损失梯度为 L_k-Lipschitz，则

$$\mathcal{L}_k(\theta - \eta\tilde{g}) \leq \mathcal{L}_k(\theta) - \eta g_k^\top \tilde{g} + \tfrac{1}{2} L_k \eta^2 \|\tilde{g}\|^2. \tag{16.8}$$

约束仅保证一次项不为正；当内积恰好为零时，二次项仍允许增损。当内积严格为正且梯度确实来自该损失时，$\eta \leq 2 g_k^\top \tilde{g} / (L_k \|\tilde{g}\|^2)$ 才给出这个上界下的非增条件。实际使用的是小缓存梯度，既有抽样误差又有曲率误差，因此仍须检查历史风险。若优化器再对投影梯度施加动量或自适应预条件，实际更新方向也可能不再满足约束；约束应针对实际步向量解释。

手算一次梯度投影。 取 $g = (-1, 2)^\mathsf{T}$、$g_r = (1, 0)^\mathsf{T}$，内积为 -1。原始下降步为 $-\eta g = (\eta, -2\eta)^\mathsf{T}$，旧损失的一阶变化为 $+\eta$，所以发生冲突。投影后 $\tilde{g} = (-1, 2)^\mathsf{T} - (-1)(1, 0)^\mathsf{T} = (0, 2)^\mathsf{T}$，内积变为零，只去掉冲突分量。注意算法投影的是梯度，执行时仍要取负号；把约束误写成梯度内积小于零，会恰好鼓励旧损失上升。

16.3 参数重要性与知识蒸馏

Elastic Weight Consolidation (EWC) 及其在线变体。 EWC 将旧任务后验在最优参数附近近似为对角二次项 [45]：

$$\mathcal{L}_t(\theta) = \mathcal{L}_{new}(\theta) + \frac{\lambda}{2}\sum_j F_j(\theta_j - \theta_j^*)^2, \quad F_j \approx \frac{1}{N}\sum_n [\partial_{\theta_j} \log p_{\theta^*}(y_n \mid x_n)]^2. \tag{16.9}$$

先训练旧阶段、保存 θ^* 并估计 F，再在新阶段加入惩罚。经验 Fisher 使用观测标签，和对模型预测分布取期望的 Fisher 并不完全相同。对角近似忽略参数耦合，旧任务局部曲率也未必能描述大范围更新风险。在线变体将历史重要性按衰减系数累积为一个统计量，控制内存，但衰减速度决定更早知识被保留多少。

从贝叶斯递推到对角二次保护。 若给定参数后各阶段数据条件独立，后验满足

$$p(\theta \mid \mathcal{D}_{1:t}) \propto p(\mathcal{D}_t \mid \theta) p(\theta \mid \mathcal{D}_{1:t-1}). \tag{16.10}$$

对旧后验的负对数 $V(\theta)$ 在局部极小点 θ^* 二阶展开，若梯度为零，有

$$V(\theta) \approx V(\theta^*) + \tfrac{1}{2}(\theta - \theta^*)^\top H (\theta - \theta^*), \qquad H = \nabla^2 V(\theta^*). \tag{16.11}$$

这里 $H \in \mathbb{R}^{p\times p}$，完整存储需要 $O(p^2)$。EWC 用似然 Fisher 的对角近似作为局部精度信息，忽略参数间相关性后只需 $O(p)$ 存储。模型 Fisher 的定义为

$$F = \mathbb{E}_X \mathbb{E}_{Y\sim p_{\theta^*}(\cdot\mid X)}[s(X,Y)s(X,Y)^\top], \qquad s = \nabla_\theta \log p_{\theta^*}(Y \mid X). \tag{16.12}$$

在可交换微分和积分等正则条件下，模型分布内的 Fisher 等于负对数似然 Hessian 的期望；把模型标签换为观测标签得到的是经验 Fisher，不必等于实际损失 Hessian。若新损失采用样本平均而旧后验来自样本似然之和，还要计入样本量尺度；实践中的 λ 同时承担尺度转换与保持强度调节，不能把任意 λ 都当作精确贝叶斯更新。

二次惩罚对第 j 个参数的梯度为 $\lambda F_j(\theta_j-\theta_j^*)$。在单个坐标上，若新目标局部为 $\frac{1}{2}a(\theta_j-b)^2$，$a>0$，则合并后的极小点为

$$\theta_j^{new}=\frac{ab+\lambda F_j\theta_j^*}{a+\lambda F_j}. \tag{16.13}$$

这明确展示了折中：新证据曲率 a 越强，参数越靠近 b；旧重要性越强，越靠近 θ_j^*。但两个参数可能需要协同移动才能不改变旧函数，对角惩罚看不到这种安全方向。在线累积 $\bar{F}_t=\rho\bar{F}_{t-1}+F_t$ 还应同时说明锚点如何重置；把多阶段局部曲率压缩到最新锚点，是进一步近似，不等于保留所有历史后验。

Synaptic Intelligence 沿训练轨迹累计参数更新对损失下降的贡献，再按总位移归一化估计重要性 [95]。例如令一次参数增量为 $\Delta\theta_j^{(s)}$、更新前梯度为 $g_j^{(s)}$，可累计 $\omega_j=\sum_s -g_j^{(s)}\Delta\theta_j^{(s)}$，再以 $\Omega_j=\max(0,\omega_j)/((\theta_j^{end}-\theta_j^{start})^2+\epsilon)$ 作为非负重要性的一种实现约定。分子来自一阶损失下降的逐坐标贡献，分母避免仅因坐标位移较大就给出高重要性；$\epsilon>0$ 防止小位移导致数值爆炸。噪声、动量和坐标间耦合会使逐坐标贡献不稳定，因此需记录截断与累积约定。它与 EWC 的区别是使用优化路径而非阶段末的 Fisher。两者都可能在任务冲突较强时过度限制可塑性，因此要同时报告新任务学习不足与旧任务遗忘。

参数重要性可以怎样直观核算。 在上面的一维折中式中，取 $a=1,b=-1,\theta_j^*=1,\lambda F_j=3$，新最优参数为 $(-1+3)/4=1/2$，处于新旧偏好之间。F_j 大不是说参数数值大，而是旧预测对该坐标变化敏感；即使 $\theta_j^*=0$ 也可能很重要。$\lambda F_j=0$ 时完全服从新目标，趋于无穷时近乎冻结，这两端分别可能遗忘旧任务和学不会新任务。Synaptic Intelligence 中若梯度为 2、本次位移为 -0.1，一阶下降贡献为 $-2(-0.1)=0.2$；它记录的是沿路径的贡献，与只在末点计算的 Fisher 不是同一统计量。

输出蒸馏与特征保持。 Learning without Forgetting 保存旧模型输出，在新数据上约束新模型 [54]：

$$\mathcal{L} = \mathcal{L}_{new} + \lambda \tau^2 \mathbb{E}_x \, \mathrm{KL}(p_{old}^{(\tau)}(\cdot \mid x) \| p_\theta^{(\tau)}(\cdot \mid x)). \tag{16.14}$$

温度 τ 软化类别概率，旧教师应停止梯度更新。蒸馏只能约束所观察输入上的行为；若新输入不覆盖旧分布，保持这些输出不保证保持旧任务。类增量场景还需统一输出空间并处理新旧类别的偏置。特征蒸馏可约束中间表示，但应明确对齐层、距离和容量，否则会阻碍必要的表示变化。

蒸馏温度、梯度缩放与类增量缺口。 令旧教师与新学生在相同 K 个旧类别上的 logits 分别为 $u, v \in \mathbb{R}^K$，$p_k = \mathrm{softmax}(u/\tau)_k$、$q_k = \mathrm{softmax}(v/\tau)_k$。停止教师梯度后，$\mathrm{KL}(p\|q) = \sum_k p_k \log p_k - \sum_k p_k \log q_k$ 中的第一项为常数，所以

$$\frac{\partial \, \mathrm{KL}(p\|q)}{\partial v_j} = \frac{q_j - p_j}{\tau}, \qquad \frac{\partial [\tau^2 \, \mathrm{KL}(p\|q)]}{\partial v_j} = \tau (q_j - p_j). \tag{16.15}$$

较高温度下，令 $\bar{u} = K^{-1} \sum_k u_k$、$\bar{v}$ 同理，有 $p_k \approx K^{-1} + (u_k - \bar{u})/(K\tau)$，故 $q_k - p_k$ 本身约为 $1/\tau$ 量级。乘 τ^2 使高温近似下的梯度尺度不至于随温度平方衰减，主要约束中心化 logits 的相对差异；它不是对所有温度都精确保持梯度范数。

类增量时必须说明 softmax 的归一化范围。如果只在旧类别上归一化，蒸馏保存旧类之间的相对关系，却不控制它们与新类之间的整体偏移；如果在全部类别归一化并把教师对新类概率设为零，就会额外压低新类概率，可能与新任务监督冲突。回放样本、分类校准和权重调节可以缓解，但不能省略这个输出空间选择。

特征保持也有明确几何假设：若教师特征 $h_o \in \mathbb{R}^{d_o}$、学生特征 $h_n \in \mathbb{R}^{d_n}$ 维度不同，应通过映射 $P \in \mathbb{R}^{d_o \times d_n}$ 再比较 $\|P h_n - h_o\|^2$，或比较关系结构；直接相减没有定义。可训练的 P 可能吸收一部分变化，过强的逐点保持则会限制新任务需要的表示重组。

蒸馏保留的是答案分布，不是参数副本。 logit 指 softmax 之前的实数得分，并非概率；对 $u = (2, 0)$，温度 1 下概率约为 $(0.881, 0.119)$，温度 2 下约为 $(0.731, 0.269)$，次要类别更容易被看见。实际一步先用冻结教师对同一批输入算概率，再用学生算概率，组合监督损失与蒸馏损失后仅更新学生。这里 $\mathrm{KL}(p\|q) = \sum_k p_k \log(p_k/q_k)$ 衡量两分布差异，不是两个类别标签的距离。教师若把新故障误判为正常，照搬其输出也会保留错误，因此蒸馏必须与新标签监督共同权衡。

16.4 参数隔离、扩展与混合策略

Progressive Networks 为新任务增加网络列，并通过横向连接复用旧表示，旧参数冻结以避免直接覆盖 [75]。代价是参数随任务增长，并依赖任务路由。掩码方法为不同任务选择不同参数子集，容量耗尽后仍需要压缩或扩展。Adapter 和 LoRA 可以成为隔离模块，但只有旧模块被冻结且路由可靠时，才提供对应的保持机制。

冻结模块只有在它实际被调用时才保护输出。设路由器为 $r(x)$、旧任务 i 的固定专家为 f_i，最终预测为 $f_{r(x)}(x)$。对零一损失，记错误路由概率为 ϵ_r，旧专家单独使用时风险为 R_i，则由事件的并集界有 $R_{system,i} \le \epsilon_r + R_i$。即使 R_i 完全不变，路由错误也足以损坏系统性能；若另有共享归一化统计或公共前处理被更新，冻结专家权重甚至不保证 f_i 这一函数不变。增加 T 个每个含 P_0 参数的专家通常需 $O(TP_0)$ 存储，隔离是在保持与资源之间交换，不是免费消除遗忘。

回放、蒸馏和隔离并不互斥。可用小缓存维持真实旧分布，用蒸馏保留相对类别信息，再通过新模块吸收变化。比较混合算法时必须同时限制缓存、模型参数、教师副本与训练计算，避免用更大资源获得的收益被误认为算法优势。

如何选择并调用被隔离的模块。 输出头是把共享特征变成类别得分的最后一段网络；掩码是与参数同形状的零一开关，决定某任务使用哪些参数；

路由器是决定调用哪个头或专家的规则。若生产系统已提供相机型号，可以按该元数据路由；若测试不提供任务身份，就必须从输入估计路由，不能用真实标签代选正确专家。Adapter 是插入主干的小型可训练模块，LoRA 以低秩矩阵乘积表示权重增量；二者只是节约任务专用参数的方式，仍须冻结对应旧路径以及其前处理。选择混合策略时应先问能否存旧数据、能否知道任务身份、最多能增加多少参数，再确定保护对象，而不是默认把所有方法相加就最好。

16.5 评价矩阵与工业更新规则

定义 $A_{t,i}$ 为学习完阶段 t 后在任务 i 固定测试集上的性能，行对应学习时间，列对应测试任务。最终平均性能和平均遗忘为

$$\mathrm{ACC} = \frac{1}{T}\sum_{i=1}^{T} A_{T,i}, \qquad F = \frac{1}{T-1}\sum_{i=1}^{T-1}\left(\max_{i\le t<T} A_{t,i} - A_{T,i}\right). \tag{16.16}$$

遗忘量可以为负，表示最终性能超过此前最佳值；若采用截断为零的定义，应显式声明。后向迁移为

$$\mathrm{BWT} = \frac{1}{T-1}\sum_{i=1}^{T-1}(A_{T,i} - A_{i,i}). \tag{16.17}$$

前向迁移可比较学习任务 i 之前的 $A_{i-1,i}$ 与未迁移基线，但仅在输出空间与任务可访问性允许该测试时有意义 [57]。类增量应同时测试所有已见类别，不能利用真实任务身份缩小候选集合。

这些指标中的 A 默认越大越好，例如准确率或召回；若填入损失，需要相应反转差分方向。遗忘与后向迁移并不相反等价：若某旧任务初学得分为 0.70，中期最高为 0.90，最终为 0.80，它的后向迁移为 $+0.10$，但从历史最佳计算的遗忘仍为 0.10。数值仅为解释定义的教学例。只报告最终平均性能可能同时掩盖某旧域崩溃与某新域改善，因此应保留完整矩阵、最差子群指标和新阶段初学性能；没有学会旧任务的模型也可能表现为“几乎不遗忘”。当 $T = 1$ 时，含 $T-1$ 分母的指标不定义。

从完整矩阵读出最终指标。 例如三阶段的下三角成绩可逐行写为

$$
\begin{aligned}
(A_{1,1}) &= (0.8),\\
(A_{2,1}, A_{2,2}) &= (0.7, 0.9),\\
(A_{3,1}, A_{3,2}, A_{3,3}) &= (0.6, 0.85, 0.9).
\end{aligned}
$$

未学任务的格子留空而非填零。最终平均性能为

$$
\mathrm{ACC} = \frac{0.6 + 0.85 + 0.9}{3} \approx 0.783.
$$

前两任务遗忘分别为 $0.8 - 0.6 = 0.2$ 和 $0.9 - 0.85 = 0.05$，平均为 0.125，后向迁移为 -0.125。这里两者恰好互为相反数，是因为旧任务历史最佳都在初学时取得，不是一般规律。0.2 表示二十个百分点的绝对下降，不是相对下降百分之二十。

新相机按周接入时，应提前为每台相机固定测试集，每次更新后都在这些集合上填写评价矩阵。缓存不能混入测试样本，超参数也不能看到未来阶段的结果后反复修改。线上流程应先用当前模型预测，等工单或复检标签到达后再学习，并记录标签延迟、漂移响应时间、每阶段训练时长和累计存储。旧相机或安全关键缺陷一旦超过风险阈值，应回滚到已验收版本，而不是自动覆盖生产模型。

以下教程与讲解可用于复习持续学习设置，并组织回放、模块保存和遗忘评价实验。

辅助学习材料

- **Avalanche: an End-to-End Library for Continual Learning**；作者/平台：ContinualAI；英文；开源框架教程。重点阅读 scenarios、benchmarks、replay plugins 和 continual evaluation，帮助把本章的任务流、缓存、类增量与遗忘矩阵转成可重复实验。在线文档。

- **Saving and Loading Models**；作者/平台：PyTorch 官方教程；英文；代码教程。重点看 checkpoint、optimizer state 与模型版本保存，帮助组织本章的回放、蒸馏和参数隔离对照。在线阅读。

- **持续学习/终身学习/增量学习基础知识**；知乎；中文解说。区分任务增量、类增量与数据流设定；标题与主题据必应索引，原页受限。在线阅读。

- **持续学习（Continual Learning）：让 AI 像人类一样终身成长**；CSDN；中文博客。比较回放与参数约束，同时检查旧任务遗忘和新任务学习；标题与主题据必应索引，原页受限。在线阅读。

- **2021 - 机器終身学习（二）- 灾难性遗忘（Catastrophic Forgetting)**；李宏毅；bilibili；中文课程。选看第 132 集，对照本章序贯训练中的遗忘问题。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量；已核对目录与计数，未逐帧观看。观看分集。

本章小结。 回放重建历史风险，梯度约束限制局部干扰，参数正则保存重要方向，蒸馏保存所观察输入上的函数行为，隔离减少共享参数冲突。这些保护机制各有缺口：缓存未必覆盖稀有旧故障，一阶约束不控制有限步长曲率，对角重要性忽略参数耦合，新输入上的蒸馏不保证旧输入行为，冻结模块还依赖正确路由。没有一种方法能够脱离任务身份、历史访问和资源预算单独比较。

持续学习要逐阶段记录新旧任务的成绩。先列出仍需识别的设备和故障，再选择保留历史样本、约束重要参数，或保存独立模块。同时检查新任务是否学会：完全不更新当然不会因更新而遗忘，但也可能一直学不会新故障。现场还会受标注速度限制。回放与正则化解决拿到标签以后怎样更新，下一章的主动学习则决定有限的专家时间先花在哪些记录上。

第十七章　主动学习

本章摘要。主动学习在有限标注预算下选择最有价值的查询。本章从候选池与标注者的交互规则出发，比较不确定性、委员会分歧、预期模型变化和批量多样性，再讨论成本、噪声与流式查询。核心不是找到最难的样本，而是使下一次标注改善部署风险。

上一章讨论在新数据到来后如何更新而不遗忘，但这通常默认训练所需标签能够取得。工业现场中，更稀缺的资源可能是能够判断裂纹性质、核对工单因果或识别异常波形的专家时间。面对成千上万条未标注记录，更新算法之前还有一个决策：先看哪一条，为什么值得看，得到答案后能够改变什么？本章把这种决策本身纳入学习过程：标注预算是有限资源，查询规则的目标是降低部署风险，而不是让训练集看起来更大。

主动学习不是把最难样本交给专家，而是在当前信息和预算下选择预期有用的观测。模型拿不准可能源于知识不足，也可能源于输入本身无法判读；两个都很有价值的单点放在同一批次中，也可能提供重复信息。因此，本章依次区分预测不确定性与可减少的不确定性，推导标签带来的信息增益和预期风险变化，再用几何覆盖与梯度表示处理批量冗余，最后把费用、标注错误和抽样偏差纳入查询与标注流程。

获取函数给记录排出的次序，只是在估计先标哪一条可能更有帮助。它的分数再高，也要通过实际标注和重新训练来检验。比较方法时应给它们相同的总预算，并计入专家核对、返工和等待时间，再看哪一种更快减少漏报与误报。如果记录分散在不能交换原始数据的工厂中，还需要安排各处怎样共同训练，这就是下一章联邦学习的问题。

17.1 查询规则与标注预算

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

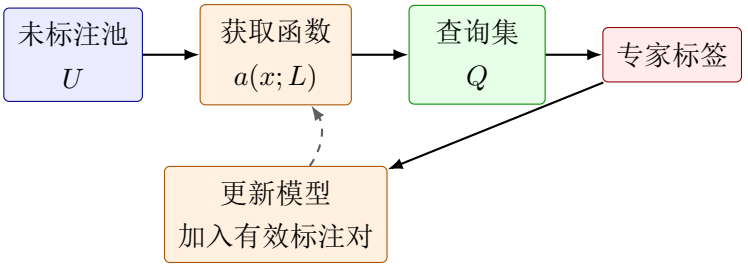


图 17.1: 池式主动学习在每轮用获取函数分配有限标注预算，再用新标签更新模型和下一轮查询。

图17.1的反馈路径说明查询与训练相互影响：获取函数选择待标注样本，新标签改变模型，也改变下一轮的查询分布。设已标注集为 L，未标注池为 U，标注成本为 $c(x)$，总预算为 B。每轮训练模型，按获取函数 $a(x;L)$ 选择查询集 $Q \subset U$，获取标签后更新 $L \leftarrow L \cup \{(x,y) : x \in Q\}$、$U \leftarrow U \setminus Q$。查询满足 $\sum_{x \in Q} c(x) \le B_{remaining}$。获取函数（acquisition function）是对未来收益的近似，不是测试集上的真实增益 [79]。

池式主动学习可比较整个 U；流式方法只能对到达样本决定查询或跳过；查询合成允许模型构造新输入，但工业中未必存在可由专家可靠判读的合成波形。无论采用哪种设定，测试集都不属于候选池。初始化标签过少时，模型置信度尚不可靠，因此随机或分层覆盖的种子集十分重要。

一次查询究竟买到了什么。 一张巡检图像或一段振动窗口是输入 $x \in \mathbb{R}^d$，故障类别 $y \in \{1,\dots,K\}$ 是标签；未标注不是没有输入，而是没有可供训练的可靠 y。设备是输入的来源，不是一个类别，也不是一次查询。任务是要解决的诊断问题；本章可以始终只有一个任务，却进行很多轮查询。L 存样本对，U 只存输入，Q 在送标注时也只含输入；因此 $|L|$ 计已返回的有效标签，而不计待处理记录。若初始 $|L|=4, |U|=10$，本轮查询两条并都

得到有效标签，则下一轮为 $|L| = 6, |U| = 8$；标签尚未返回的记录应标为待处理，避免重复派单。拒标仍可能消耗费用，但不能伪造标签加入 L。

区分训练、选择和验收。 训练把 L 变成参数 θ；获取函数把每个候选变成标量分数；专家查询才产生真实标签；重新训练后独立测试才衡量收益。获取分数不是标签，也不能直接当作训练目标。预算单位应先固定，例如专家分钟数：剩余 10 分钟、每条 3 分钟时最多查询三条，而不是十条。停止条件可以是预算用完或预先规定的验证收益不足，不能反复看最终测试集来决定何时停止。

17.2 不确定性、委员会与贝叶斯查询

最小置信度、间隔与熵。 设模型类别概率按大小排列为 $p_{(1)}(x) \geq p_{(2)}(x)$。常见获取函数为

$$a_{LC}(x) = 1 - p_{(1)}(x), \qquad a_{margin}(x) = -(p_{(1)}(x) - p_{(2)}(x)), \tag{17.1}$$

$$a_H(x) = -\sum_k p_k(x) \log p_k(x). \tag{17.2}$$

三者均选择得分较大的样本。最小置信度只看最大类别，间隔看前两类竞争，熵考虑全部概率。多分类下它们并不等价。Lewis 与 Gale 的不确定性采样工作展示了基于当前分类器选择标注对象的基本思想 [49]。

何时这些分数等价，何时不等价。 对二分类，记 $p = P(Y = 1 \mid x)$，则最小置信度为 $\min(p, 1-p)$，负间隔为 $-|2p-1|$，熵为 $h(p) = -p\log p - (1-p)\log(1-p)$。在 $0 < p < 1/2$ 时，$h'(p) = \log((1-p)/p) > 0$，三者都随 p 靠近 $1/2$ 而增加，故产生相同排序。多分类没有这个结论。例如两个候选概率为 $(0.50, 0.49, 0.01)$ 与 $(0.50, 0.25, 0.25)$，最小置信度相同，间隔优先选前者，熵却优先选后者；前者突出两类决策竞争，后者突出整体分散程度。这里及下文取自然对数，约定 $0 \log 0 = 0$。

边界附近可能有可学习样本，也可能是永久模糊的记录、传感器损坏或标签定义冲突。反复查询后一类样本会消耗预算却不减少模型不确定性。应按设备与工况审计获取分数，并检查模型校准，而不是默认低置信度必有高信息价值。

分数的数值和含义。 二分类候选甲预测为 $(0.9, 0.1)$，乙为 $(0.5, 0.5)$，则最小置信度分别为 $0.1, 0.5$，负间隔为 $-0.8, 0$，熵约为 $0.325, 0.693$，三种规则都优先乙。负间隔越接近零越不确定，不能因为它有负号而改成选最小值。熵 $H(p)$ 就是按概率加权的意外程度 $-\log p_k$；这里的自然对数使单位为 nat，换成以 2 为底只改变单位和统一缩放，不改变单点排序。预测概率来自当前模型而非真实频率；自信但错误的模型可能永远不主动查询甲。

委员会查询（Query-by-Committee）。 委员会方法训练多个与当前数据相容的预测器，选择其分歧最大的样本 [80]。若有 M 个成员，类别投票比例为 $v_k(x)$，投票熵为 $-\sum_k v_k \log v_k$。也可用成员概率分布到平均预测的 KL 散度。Bootstrap、不同初始化或后验样本可形成委员会，但高度相关的成员会低估分歧，毫无约束的弱模型则可能制造无效分歧。

Bayesian Active Learning by Disagreement (BALD) 与联合批量查询。 BALD 选择标签与模型参数间条件互信息最大的输入 [35]：

$$a_{BALD}(x) = H\big[\mathbb{E}_{p(\theta|L)} p(y \mid x, \theta)\big] - \mathbb{E}_{p(\theta|L)} H[p(y \mid x, \theta)]. \tag{17.3}$$

第一项是总体预测熵，第二项扣除各模型自身仍有的不确定性。用 M 次后验近似采样计算类别概率、先平均再取熵，并减去逐次熵的平均。它试图区分认知不确定性与数据歧义，但效果取决于后验近似。Monte Carlo (MC) dropout 是一种近似手段，不是精确贝叶斯采样 [23]。

先把两种平均分开计算。 两个模型分别输出 $(0.9, 0.1)$ 和 $(0.1, 0.9)$。先平均概率得到 $(0.5, 0.5)$，熵为 0.693；各自先算熵再平均得到 0.325，相减为

0.368。若两个模型都输出 $(0.5, 0.5)$，相减为零。前者是模型意见相左，标签可能帮助选择模型；后者是每个模型自身都模糊。贝叶斯后验 $p(\theta \mid L)$ 表示看到 L 以后对参数的分布，$\mathbb{E}_{p(\theta \mid L)}$ 指对不同可能参数求平均，而非对候选样本求平均。认知不确定性指可望随证据减少的参数分歧，数据歧义指给定解释后仍可能出现多个标签；这种分解始终依赖所选模型，不能当作对现实噪声来源的直接测量。

从后验信息增益推出 BALD。 固定已标注集 L 和候选 x，把参数 Θ 看成后验随机变量、标签 Y 看成尚未观测的离散变量。理想查询的信息价值是观察标签后后验改变多少：

$$I(Y; \Theta \mid x, L) = \mathbb{E}_{Y \mid x, L} \, \mathrm{KL}(p(\theta \mid L, x, Y) \| p(\theta \mid L)) \tag{17.4}$$

$$= \mathbb{E}_{\Theta \mid L} \sum_{y} p(y \mid x, \Theta) \log \frac{p(y \mid x, \Theta)}{p(y \mid x, L)} \tag{17.5}$$

$$= H[p(y \mid x, L)] - \mathbb{E}_{\Theta \mid L} H[p(y \mid x, \Theta)]. \tag{17.6}$$

从式(17.4)到式(17.5)使用贝叶斯公式 $p(\theta \mid L, x, y)/p(\theta \mid L) = p(y \mid x, \theta)/p(y \mid x, L)$，这里采用条件预测模型并将候选 x 作为固定设计。互信息非负且至多为 $\log K$，其中 K 为类别数，因为条件熵非负且 K 类熵至多为 $\log K$。

取 M 个后验近似样本，令 $p^{(m)} \in \mathbb{R}^K$ 为其预测、$\bar{p} = M^{-1} \sum_m p^{(m)}$，则估计为

$$\widehat{I} = H(\bar{p}) - \frac{1}{M} \sum_{m} H(p^{(m)}) = \frac{1}{M} \sum_{m} \mathrm{KL}(p^{(m)} \| \bar{p}). \tag{17.7}$$

最后一个等式也说明概率委员会分歧与 BALD 的联系，但普通随机初始化委员会未必代表后验。二分类中，若每个模型都输出 $(1/2, 1/2)$，预测熵为 $\log 2$ 而互信息为零：再看标签未必能解决输入本身歧义。若一半模型输出 $(1, 0)$、另一半输出 $(0, 1)$，平均预测同样为 $(1/2, 1/2)$，但每个模型熵为零，互信息达到 $\log 2$：标签可以区分两组假设。这是两种不确定性的理想示例，不保证近似后验能在真实数据中正确区分它们。

逐点取 BALD 前若干名可能选出几乎相同的相邻窗口。BatchBALD 对一批标签与参数的联合互信息进行近似优化，考虑查询间冗余 [46]。批量规模增加使联合计算更困难，因此应报告候选池大小、后验采样次数和获取时间。

对查询批次 $Q=\{x_1,\dots,x_b\}$，若给定参数后标签条件独立，联合信息增益可写为

$$I(Y_Q;\Theta\mid L)=H(Y_Q\mid L)-\sum_{j=1}^{b}\mathbb{E}_{\Theta\mid L}H(Y_j\mid x_j,\Theta). \tag{17.8}$$

不能把第一项换成单点熵之和，因为对参数积分后各标签往往相关。两点时，条件独立假设给出 $I(Y_1,Y_2;\Theta)=I(Y_1;\Theta)+I(Y_2;\Theta)-I(Y_1;Y_2)$，省略的条件均为固定输入与 L。这正是冗余扣除：两条记录若几乎回答同一个参数问题，单点相加会重复计算收益。联合标签空间有 K^b 种配置，直接枚举随批量指数增长，所以近似采样和贪心批量构造是计算折中，而不是改变查询目标。

17.3 预期风险、梯度变化与多样性

预期误差减少。 理想查询希望标注后风险下降。由于未知 y，可按当前预测枚举候选标签并模拟更新 [74]：

$$a_{EER}(x)=\widehat{R}(\theta)-\sum_{y}p_\theta(y\mid x)\widehat{R}(\theta_{L\cup\{(x,y)\}}). \tag{17.9}$$

风险代理只能在训练侧保留集或规定的无标签代理上计算，不能使用最终测试标签。每个候选、每个标签都重训代价很高，可用少量梯度步近似，但近似可能误判长期收益。若当前模型给真实类别极低概率，预期收益也可能被低估。

怎样模拟还没拿到的标签。 假设某候选当前预测两类概率为 $0.75,0.25$，当前代理风险为 0.20。分别暂设标签为第一类和第二类，复制模型后独立模

拟更新，得到代理风险 $0.16, 0.24$，则期望更新后风险为 $0.75 \times 0.16 + 0.25 \times 0.24 = 0.18$，获取分数为 0.02。这两个假想标签都不能写入正式训练集；真正查询后只用专家返回的标签更新。风险代理是训练侧可计算的近似风险，不是预知未来测试误差的工具。若没有代表性验证标签，必须说明无标签代理如何定义，不能把高置信度直接等同于低真实风险。

一次梯度更新能否预测风险收益。 令 $\theta \in \mathbb{R}^p$，候选标签为 y 时的梯度为 $g_y(x) = \nabla_\theta \ell(x, y)$，模拟一步 $\theta'_y = \theta - \eta g_y$。若风险代理 $\widehat{R}$ 二阶可微，在当前参数处梯度为 r、Hessian 为 H，则

$$\widehat{R}(\theta) - \widehat{R}(\theta'_y) \approx \eta r^\top g_y - \frac{\eta^2}{2} g_y^\top H g_y. \tag{17.10}$$

所以有效更新取决于方向对齐和曲率，并非只取决于 $\|g_y\|$。若代理风险在当前模型处已近驻点，一阶项很小，大梯度甚至可能主要增加二阶风险。

还有一个容易忽略的抵消现象。对交叉熵 $\ell = -\log p_\theta(y \mid x)$，若用同一个当前模型对未知标签求平均，则

$$\sum_y p_\theta(y \mid x) g_y(x) = -\sum_y \nabla_\theta p_\theta(y \mid x) = -\nabla_\theta 1 = 0. \tag{17.11}$$

这里先对每个假想标签的损失求梯度，再用当前概率加权；不是对 $\sum_y p_\theta(y \mid x)\ell(x, y)$ 整体求导，后者还会对概率权重求导。因此简单的一步、固定代理风险、一阶近似组合会给所有候选零平均收益；它不是完整 Expected Error Reduction (EER) 的替代。完整重训会改变最优解、后验或风险估计，高阶项也不会一般消失。这个结果解释了为什么预期梯度长度使用范数的平均，而不是平均梯度的范数，二者由三角不等式并不相同。

预期梯度长度以 $\sum_y p_\theta(y \mid x)\|\nabla_\theta \ell(x, y)\|$ 估计模型变化。较大梯度说明会产生较大更新，却不保证更新方向有益，异常值可能占据排名前列。

Core-set 与 BADGE。 BADGE 的英文全称为 Batch Active Learning by Diverse Gradient Embeddings，即利用多样化梯度嵌入进行批量主动学

习。Core-set 在表示空间选择覆盖候选池的样本 [78]：

$$\min_{Q\subseteq U:|Q|=b}\ \max_{x\in U}\ \min_{z\in L_X\cup Q}\ \|f(x)-f(z)\|_2. \tag{17.12}$$

这里 $L_X=\{x:(x,y)\in L\}$ 为已标注集的输入集合，b 为本轮查询数，f 为当前特征编码器。这样距离比较的两端都是输入，而不是将带标签样本对与输入混合。常用贪心近似每次选离已选中心最远的点，并更新所有候选的最近距离。它鼓励覆盖，但若表示由背景或设备身份主导，就会覆盖无关差异；极端离群点也可能被优先选择。

覆盖半径为什么有意义，又为什么不够。 记当前已选中心集合为 S，所有候选到中心的最近距离为 $d_S(x)$。贪心最远点步骤选择 $x^*=\arg\max_x d_S(x)$，随后仅需更新 $d_{S\cup\{x^*\}}(x)=\min\{d_S(x),\|f(x)-f(x^*)\|\}$，而不必每轮重新比较所有中心。在固定度量、等成本、中心从候选中选取的离散覆盖问题中，最远点策略有经典的两倍半径近似解释：若最终半径超过最优半径的两倍，依次选出的点和最终最远点必须彼此相距超过该值；但最优的 b 个新增半径球无法容纳 $b+1$ 个这样的点，因为同一球内任意两点的距离至多为两倍半径。已有固定中心时，这些点也不可能由已有中心在最优半径内覆盖，故相同计数逻辑仍成立。

这个结论只保证几何覆盖。若条件期望损失 $\bar{\ell}(z)=\mathbb{E}[\ell\mid Z=z]$ 在表示空间是 L_ℓ-Lipschitz，其中 $L_\ell\ge 0$ 是常数而非已标注集 L，则 $|\bar{\ell}(z)-\bar{\ell}(z_c)|\le L_\ell\|z-z_c\|$，覆盖半径 r 才能被解释为至多 $L_\ell r$ 的局部损失差异控制；但故障边界可能不平滑，表示可能遗漏关键变量，而且一个中心标签不等于精确的条件期望损失。因此几何近似保证不能直接改写为标注后分类风险保证。

BADGE 将不确定性与多样性放到最后一层的梯度表示中 [2]。先取预测概率最大的类别为伪标签，再计算各类别的梯度块：

$$\hat{y}=\arg\max_k p_k(x),\qquad g_k(x)=(p_k(x)-\mathbf{1}[k=\hat{y}])h(x), \tag{17.13}$$

其中 $h(x)$ 是分类头输入。拼接各类梯度后，用类似 k-means++ 的距离采样选择一批点。梯度长度反映当前预测的不确定性，梯度方向帮助减少冗余。该方法不需要候选真实标签，但依赖伪标签与当前表示质量。

从覆盖与梯度各算一个小例子。 在一维表示上，已标注中心为 0，候选为 $1, 2, 8, 9$，预算为两条。最远点法先选 9，最近中心距离更新为 $1, 2, 1, 0$，再选 2，而不是继续选靠近 9 的 8；这就是批量多样性的作用。若 9 只是坏传感器的读数，则覆盖仍可能浪费一次查询，故离群审核不能省略。BADGE 中若 $h = (1, 2)^{\mathsf{T}}$、$p = (0.6, 0.4)$，伪标签为第一类，两个梯度块为 $(-0.4, -0.8)^{\mathsf{T}}$ 和 $(0.4, 0.8)^{\mathsf{T}}$，拼成四维向量。伪标签仅用于算选择特征，不表示已经获得专家标签。

梯度嵌入为何同时包含置信度与方向。 令线性分类头 $W \in \mathbb{R}^{K \times d_h}$、特征 $h(x) \in \mathbb{R}^{d_h}$，其中 d_h 是编码后的特征数，不必等于输入维数 d；logits 为 $Wh \in \mathbb{R}^K$，概率为 $p \in \mathbb{R}^K$。对标签 y，交叉熵梯度为

$$\nabla_W \ell = (p - e_y) h^\top \in \mathbb{R}^{K \times d_h}, \tag{17.14}$$

其中 $e_y \in \mathbb{R}^K$ 为第 y 个标准基向量。逐行展平这张矩阵得到 Kd_h 维嵌入，便得到式(17.13)中的 g_k。其范数满足

$$\|g(x)\|_2^2 = \|p - e_{\hat{y}}\|_2^2 \|h(x)\|_2^2. \tag{17.15}$$

若预测接近某个确定类别，第一个因子接近零；若多个类别竞争，则残差通常更大。但第二个因子也会影响长度，所以不能把它当作纯粹的概率不确定性。两个样本的梯度内积为 $(p - e_{\hat{y}})^\top (p' - e_{\hat{y}'})\, h^\top h'$：类别竞争结构与特征相似性共同决定方向。

一种可复现的初始化约定是先选梯度范数最大的候选作为首中心，并列时按固定种子的随机规则选择。随后类似 k-means++，在已有中心集合 S 下，以 $D(x)^2 / \sum_{u \in U \setminus S} D(u)^2$ 从未选候选中抽取新中心，其中 $D(x) = \min_{z \in S} \|g(x) - g(z)\|$。每选一条即更新最近距离，直到达到本轮预算。这既

避免单纯选取最大梯度的一簇近重复样本，又保留随机探索。若所有剩余距离为零，可在未选候选中均匀无放回抽样，不能除以零或重复选择同一条。它是在梯度空间中寻找代表性，并不保证伪标签正确或最终风险最小。

17.4 成本、噪声与工业流式变体

等成本预算下按获取分数排序即可形成简单策略；成本差异明显时，对非负收益分数且 $c(x) > 0$ 的情形，可用 $a(x)/c(x)$ 作启发式，或直接求带预算约束的批量选择。前面的负间隔不能未经处理就按此解释为收益：例如固定加一个常数虽不改变单点排序，却会改变除以不同成本后的排序，所以需先明确收益代理的零点与尺度。比值排序不是一般情况下的最优解。长工单、复杂图像与短波形的标注时间不同，应使用专家分钟数或费用，而不只用样本数比较。

若先把收益近似为可加的 $a_i \geq 0$，批量选择就是 $\max_{q_i \in \{0,1\}} \sum_i q_i a_i$，约束 $\sum_i q_i c_i \leq B$。比值排序解的是可分割背包的思想，而样本标签不可分割。例如预算为 10，一个候选成本 6、收益 12，另外两个各成本 5、收益 9；按比值会先选第一个而得到 12，选后两个却得到 18。数值只是算法反例，不是实验结果。实际批量收益还因冗余不满足可加性，故应把多样性和成本联合考虑。

多标注者场景还需选择由谁标注，并允许“不确定”或“无法判读”。对高风险少数故障可配置双人复核；对重复分歧应先修改标签定义。密度加权可以降低孤立噪声的优先级，但也可能排斥真正罕见的新故障，因此应保留随机探索和新颖性审核预算。

流式方法可在 $a(x_t) > \tau_t$ 时查询，并根据剩余预算调整阈值。漂移后旧阈值可能失效，不能仅依赖过去的分数分布。持续学习决定如何更新模型，主动学习决定获取哪些标签，二者可联合但应分别消融。查询高不确定样本产生选择偏差，性能监测仍需要独立的代表性抽样，不能直接用已查询数据的准确率估计上线风险。

查询偏差与代表性监测。 设一个固定候选总体有 N 个样本，$S_i \in \{0,1\}$ 表示是否被查询，已知边际入选概率为 $\pi_i > 0$。对预先固定的评估器，若损失为 ℓ_i，则逆概率估计

$$\widehat{R}_{IPW} = \frac{1}{N}\sum_{i=1}^{N} \frac{S_i \ell_i}{\pi_i}, \qquad \mathbb{E}[\widehat{R}_{IPW}] = \frac{1}{N}\sum_{i=1}^{N} \ell_i \tag{17.16}$$

利用的是 $\mathbb{E}S_i = \pi_i$。查询越少的区域权重越大，故方差可能很高；确定性只选最高分时，未入选样本 $\pi_i = 0$，无法作此修正。自适应多轮查询的条件概率还依赖历史，最终入选概率不能随意替换为某轮的查询概率；同一批查询标签又参与训练时，固定评估器的无偏论证也不再直接适用。

一个可操作的补充是将部分预算留给概率探索：每轮候选数为 $|U|$ 时，按 $q_t(x) = (1-\epsilon)q_{a,t}(x) + \epsilon/|U|$ 查询，$0 < \epsilon \le 1$，并记录当轮概率与历史状态。这保证当轮每个候选有非零机会，却不自动保证精确最终风险估计。最清晰的验收仍是保留不参与获取排序和训练的代表性监测样本，其成本应计入整体标注预算，而不是被当作免费信息。

标注噪声还会改变信息价值。若标注者 a 的混淆矩阵为 $T^{(a)}_{ky} = P(\widetilde{Y} = k \mid Y = y, a)$，并假定给定真实标签后错误与 x, θ 无关，则观测标签预测为 $p(\widetilde{y} = k \mid x, \theta, a) = \sum_y T^{(a)}_{ky} p(y \mid x, \theta)$。查询信息增益应针对实际收到的 $\widetilde{Y}$ 计算，而非假设完美的 Y。矩阵本身未知、错误随图像质量变化或多人错误相关时，需要审核样本和更细模型；简单多数投票不能消除共同误判。

查询偏差与标注噪声的小例子。 某记录以 $\pi_i = 1/4$ 概率被查询，则它被查询时在逆概率求和中贡献 $4\ell_i$，未查询时贡献零，期望仍为 ℓ_i；除以总体数 N 后才是平均风险贡献。这不允许在 $\pi_i = 0$ 时补权重，也不意味着一次抽样结果一定接近真实平均。对于二分类标注者，若每类都有 0.1 概率被误标为另一类，则 $T = \left(\begin{smallmatrix} 0.9 & 0.1 \\ 0.1 & 0.9 \end{smallmatrix}\right)$，列对应真标签且每列和为一。模型真标签概率为 $(0.8, 0.2)^{\mathsf{T}}$ 时，收到标签的预测为 $T(0.8, 0.2)^{\mathsf{T}} = (0.74, 0.26)^{\mathsf{T}}$，并非原概率。应把标注质量也纳入查询价值，不能只增加重复标注数量。

17.5 算法流程与验收

在巡检图像标注中，可以先按设备划分候选池和固定测试集，再从训练池取一批共同的初始样本。每轮用相同训练预算更新模型，给候选图像打获取分数，去掉连续拍摄的近重复图像后送专家标注，同时记录标签、耗时、费用和拒标原因。新标签加入训练集后再开始下一轮，不能把本轮查询结果提前用于本轮的分数计算。

比较随机、分层随机、不确定性和一种多样性方法，绘制真实测试召回随累计标注成本的曲线。重复不同种子集与查询随机种子，同时报告获取耗时、训练耗时、少数故障覆盖和失败查询比例。主动学习只有在同等总成本下提高真实风险表现时才有价值；节省标签却需要无法承受的反复重训，并非完整收益。

主动学习的获取函数、批量多样性和预算评价可用以下材料复习，分别对应算法直觉和工程实验。

辅助学习材料

- **Active Learning**；作者/平台：Small-Text；英文；官方教程。阅读 Components 和池式主动学习流程，理解初始化、查询策略、人工标注与停止准则如何组成迭代过程。在线阅读。

- **Validation curves: plotting scores to evaluate models**；作者/平台：scikit-learn Developers；英文；官方示例文档。重点看训练集大小、验证曲线和重复评估，帮助把本章的累计标注预算、风险曲线与独立测试集评价落到实验设计。在线阅读。

- **通俗易懂讲 AI–主动学习**；知乎；中文解说。沿查询、标注与更新循环理解预算分配；标题与主题据必应索引，原页受限。在线阅读。

- **用大白话讲主动学习（Active Learning）**；CSDN；中文博客。比较

不确定性和样本多样性，评价必须使用独立测试集；标题与主题据必应索引，原页受限。在线阅读。

- **主动学习 (Active Learning, AL) 的步骤、代码流程讲解及实战**；上传者：来包番茄沙司；bilibili；中文技术讲解。对照本章查询策略、不确定性度量与标注循环，检查每轮预算；评价仍使用独立测试集，不以查询样本上的准确率作为停止依据。2026 年 10 月 4 日公开元数据播放 14,386 次，高于本次另一直接相关入门候选的 1,501 次；已核对公开流程简介、标题和计数，未逐帧观看。观看视频。

本章小结。 主动学习把标签视为需要分配的资源。不确定性寻找尚未确定的判断，BALD 进一步区分模型间分歧与单模型仍有的歧义，联合信息增益扣除批量冗余，预期风险方法直接考虑更新后的收益，而几何覆盖与梯度嵌入提供较便宜的批量代理。它们各自近似不同对象，因此获取得分不能跨方法直接解释为真实收益；大梯度不一定有益，高熵不一定可学，远距离也不一定对应新故障。

模型会判断错，专家也可能标错，同一批查询还可能重复，所以选样策略必须连同费用一起检验。上线效果应在独立且有代表性的数据上估计，不能只用主动挑出的难例测试。与持续学习结合时，可以分别替换选样方法和更新方法，查清收益来自哪里。如果多个工厂无法汇集原始记录，还要安排本地计算、更新通信与聚合。下一章讨论这种联邦协作；标签缺失、选择偏差和历史遗忘仍需各自处理。

第十八章　联邦学习

本章摘要。本章把“数据不能集中”作为约束，重新审视训练、通信、隐私和公平性。先定义联邦优化与非独立同分布，再分析 Federated Averaging (FedAvg)、本地更新、差分隐私、安全聚合和个性化方法，最后回到系统延迟、参与方差异和攻击面。联邦学习解决的是数据协作边界，不会自动解决统计偏差。

上一章主动学习讨论把有限标注预算花在哪些样本上，隐含的问题是所选样本能否进入同一个学习流程。本章进一步撤去数据可集中这一便利条件：不同工厂或设备群既可能具有不同工况，也可能不能把原始记录汇集到同一处。故障预测目标没有改变，改变的是谁持有数据、谁计算梯度，以及谁能够观察更新。

假设几家工厂不能交换原始记录，但希望一起改进故障模型。首先要决定大工厂是否因样本多而占更大权重，再看各厂独立训练多步以后，更新为什么可能朝不同方向走。通信中断、设备掉线和更新中泄露的信息，也都要考虑。本章从加权经验风险推导 FedAvg，再解释近端项、控制变量和个性化方法。评价时既看平均成绩，也看表现最差的工厂，并记录通信成本和隐私预算。原始数据留在本地，并不自动保证上传的更新安全；本章因此同时追踪统计目标、通信过程和可观察信息，而不把“分散存储”误当成隐私结论。

18.1　问题定义

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

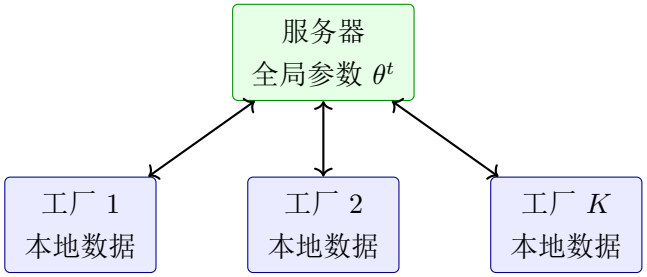


图 18.1: 联邦学习的基本循环。原始数据留在客户端，服务器只接收模型参数或更新。

图18.1区分本地数据路径与服务器聚合路径；客户端在原始记录上训练，服务器通过汇总更新协调模型，而不是集中收集训练样本。FedAvg 通过客户端本地更新与服务器加权聚合实现分散训练 [60]。Federated Proximal Optimization (FedProx) 加入近端约束，Stochastic Controlled Averaging for Federated Learning (SCAFFOLD) 使用控制变量校正客户端漂移 [52, 40]；它们改变优化机制，并不单独提供隐私保证。联邦学习在多个客户端保留本地数据，仅交换模型更新。客户端（client）k 有目标 $F_k(\theta)$ 和权重 p_k，服务器（server）协调全局目标为

$$\min_{\theta} F(\theta) = \sum_{k=1}^{K} p_k F_k(\theta). \tag{18.1}$$

FedAvg 在每轮下发全局参数，客户端执行若干步本地 SGD，再按样本量聚合：

$$\theta^{t+1} = \sum_{k=1}^{K} p_k \theta_k^{t+1}. \tag{18.2}$$

客户端不是一条样本。 一条样本 (x_{ki}, y_{ki}) 可以是一段振动窗口及其故障标签，i 编号记录，k 编号持有这些记录并能执行本地训练的客户端。一家工厂可以作为一个客户端并管理多台物理设备，也可以按设备群拆成多个客户端；划分必须与权限、通信和评价一致。任务是预测故障的规则，各客户端可以共同执行同一任务，不能把客户端数直接当成类别数或任务数。

本章讨论各方具有相容输入与模型结构的横向联邦设定；同一对象的不同特征分散在不同机构的纵向联邦需要另行设计样本对齐和计算流程，不能直接平均本章的参数。

模型参数 $\theta \in \mathbb{R}^d$ 是所有可训练权重按固定顺序排成的向量，此处 d 是参数数而非传感器通道数。F_k 是客户端平均损失，p_k 是其全局权重；上标 t 表示通信轮次而非幂次。所有客户端必须从同一个版本开始，且同一参数坐标和类别编号含义一致，参数逐坐标平均才有定义。SGD 即随机梯度下降：从本地数据抽小批算梯度，再减去步长乘梯度，不必每步遍历全部记录。

18.1.1 权重、抽样与集中式基线

设参数 $\theta \in \mathbb{R}^d$，客户端 k 持有 n_k 个样本，且

$$F_k(\theta) = \frac{1}{n_k} \sum_{i=1}^{n_k} \ell(\theta; x_{ki}, y_{ki}), \qquad p_k \geq 0, \quad \sum_k p_k = 1. \tag{18.3}$$

取 $p_k = n_k / \sum_j n_j$ 得到所有样本等权的经验风险；取 $p_k = 1/K$ 得到所有工厂等权的风险。二者不是实现上的可互换选项：一家拥有大量正常记录的大工厂，在第一种目标中可能压过数据稀少但故障代价高的小工厂。权重应先由业务目标定义，而不是由方便上传的数据量事后决定。

若所有客户端参与、从同一参数出发且以共同步长 η 只做一步全梯度下降，则

$$\sum_k p_k(\theta^t - \eta \nabla F_k(\theta^t)) = \theta^t - \eta \sum_k p_k \nabla F_k(\theta^t) \tag{18.4}$$

$$= \theta^t - \eta \nabla F(\theta^t). \tag{18.5}$$

式(18.5)表明，这个特例与集中式全梯度更新严格相同。若使用随机梯度 g_k，需要条件无偏性 $\mathbb{E}[g_k \mid \theta^t] = \nabla F_k(\theta^t)$ 才有期望意义上的相同；模型中的随机状态、归一化统计量等还应采用相容的处理方式。

部分参与使权重问题更复杂。令 $I_k^t \in \{0,1\}$ 表示是否参与，已知参与概率 $\pi_k > 0$，则在更新与抽样条件相容时，

$$\widehat{g}^t = \sum_k I_k^t \frac{p_k}{\pi_k} g_k^t, \qquad \mathbb{E}[\widehat{g}^t \mid \theta^t] = \nabla F(\theta^t). \tag{18.6}$$

式(18.6)中的期望等式来自 $\mathbb{E}[I_k^t] = \pi_k$。这种逆概率校正不要求各客户端独立入选，但小 π_k 会放大方差。常用的参与集合内重新归一化权重是随机比值，通常不能声称对原目标严格无偏。如果网络故障与设备状态相关，又没有可靠参与概率，仅靠增加训练轮数不能恢复缺失工厂的代表性。

手算一轮聚合和一种掉线后果。 两客户端分别有 1 条和 3 条样本，按样本量取权重 $1/4, 3/4$。从标量参数 $\theta^t = 0$ 出发，本地梯度分别为 $2, -2$，步长 0.1，一步后参数为 $-0.2, 0.2$，服务器得到标量参数 $\theta^{t+1} = 0.1$；这里的数字是参数值，不是客户端编号。直接算全局梯度 $(1/4)2 + (3/4)(-2) = -1$ 也得到 $0 - 0.1(-1) = 0.1$。若改为客户端等权，结果为 0，这不是算错，而是目标变了。若本轮只有第一客户端上线并把其权重归一成 1，结果为 -0.2；掉线改变了被代表的人群，不能把此次更新称为原全局梯度。

上传差分 $u_k = \theta_{k,E}^t - \theta^t$ 与上传完整参数在全参与且权重和为一时等价：服务器执行 $\theta^{t+1} = \theta^t + \sum_k p_k u_k$。一个轮次包含选择、下发、本地计算、上传、聚合；$E$ 表示本地梯度步数，不自动等于遍历数据的轮数。一遍数据含多个小批时，一个本地 epoch 就有多步，比较通信与计算时要分别记录。

18.2 联邦优化、隐私与系统约束

非独立同分布与通信。 当 $P_k(X, Y)$ 不同，本地更新方向可能冲突，客户端数量、参与率和本地步数会影响收敛。通信压缩、个性化联邦学习和聚类联邦学习分别处理带宽、客户端差异和多群体结构。服务器不能直接看到原始数据，但更新仍可能泄露信息，因此需要安全聚合、差分隐私或加密协议。这里的协议指参与方之间明确规定的消息交换和计算步骤。

训练完成后，共享完整模型的客户端可直接对新输入做前向预测，不需要每预测一次就重新聚合。个性化模型还须加载该客户端自己的预测头及预处理状态，并核对它们与共享编码器的版本；新客户端没有本地头时，应先执行约定的适应流程。

评价与边界。 联邦系统应报告全局性能、最差客户端性能、通信轮数、隐私预算与掉线鲁棒性。联邦学习解决的是数据不能集中这一约束，并不会自动解决标签偏差、恶意客户端或模型公平性问题。

表 18.1: 联邦学习方法的约束匹配

方法	主要修正对象	额外代价	适用边界
FedAvg	基本全局聚合	本地漂移未被显式校正	分布接近、通信受限的基线
FedProx	客户端更新偏离	近端系数和局部适应之间需调节	非 Independent and Identically Distributed (IID) 与算力异构
SCAFFOLD	系统性梯度漂移	控制变量存储和同步	客户端长期参与、通信可承受
个性化联邦	客户端条件差异	共享层与本地层的划分	工厂、设备或人群差异明显
安全聚合与 Differential Privacy (DP)	更新可见性和样本影响	密码学开销或噪声导致效用下降	需要隐私保证的跨组织协作

表18.1将联邦方法与数据异质性、通信及个性化约束对应；比较方法时须先确定主要瓶颈，不能仅按聚合后平均精度选型。

FedAvg 的本地更新。 客户端 k 从全局参数 θ^t 开始执行 E 步本地更新：

$$\theta^t_{k,e+1} = \theta^t_{k,e} - \eta \nabla F_k(\theta^t_{k,e}), \qquad \theta^t_{k,0} = \theta^t. \tag{18.7}$$

服务器聚合 $\theta^{t+1} = \sum_k p_k \theta^t_{k,E}$。当各客户端数据同分布且目标函数平滑时，增加本地步数可减少通信；非 IID 情况下，本地漂移会使聚合方向偏离全局梯度。

从本地多步展开看漂移来源。 先考虑全参与、确定性梯度与共同步长，以免将抽样噪声和漂移混在一起。把 E 步递推求和可得

$$\theta^{t+1}-\theta^{t}=-\eta\sum_{k}p_k\sum_{e=0}^{E-1}\nabla F_k(\theta_{k,e}^{t}) \tag{18.8}$$

$$=-\eta E\nabla F(\theta^{t})-\eta R_t, \tag{18.9}$$

$$R_t=\sum_{k}p_k\sum_{e=0}^{E-1}[\nabla F_k(\theta_{k,e}^{t})-\nabla F_k(\theta^{t})]. \tag{18.10}$$

这里 $R_t\in\mathbb{R}^d$ 就是相对于固定起点梯度的累计偏离。假设各 F_k 梯度为 L-Lipschitz，且本轮轨迹上 $\|\nabla F_k\|\le G$，由三角不等式有

$$\|\theta_{k,e}^{t}-\theta^{t}\|\le \eta eG,\qquad \|R_t\|\le L\eta G\frac{E(E-1)}{2}. \tag{18.11}$$

于是参数误差上界为 $L\eta^2GE(E-1)/2$。这不是完整收敛定理，也未区分同分布曲率与异质性；它明确说明：少通信带来的多步本地训练会累积偏离，而不是无代价地模拟集中式梯度。

异质性可用 $\zeta^2(\theta)=\sum_k p_k\|\nabla F_k(\theta)-\nabla F(\theta)\|^2$ 描述。全局最优点上 $\nabla F=0$ 并不要求各 $\nabla F_k=0$，因此本地继续优化仍可能把参数拉向不同方向。一个可直接核算的例子是 $F_k(\theta)=a_k(\theta-b_k)^2/2$，其中 $\theta\in\mathbb{R}$、$a_k>0$。递推给出

$$\theta_{k,E}=b_k+(1-\eta a_k)^{E}(\theta^{t}-b_k). \tag{18.12}$$

当 $|1-\eta a_k|<1$ 且 $E\to\infty$，聚合趋于 $\sum_k p_k b_k$，但全局最优点是 $\sum_k p_k a_k b_k/\sum_k p_k a_k$。除特殊情形外二者不同；本地模型各自训练得更充分，不代表全局模型更接近目标最优点。

把漂移例子代入数字。 取两客户端等权，$a_1=1,b_1=0,a_2=3,b_2=2$，即第二客户端的损失曲线更陡。各自充分训练后参数分别为 $0,2$，平均为 1；全局最优却是 $(0{+}6)/(1{+}3)=1.5$。在 $\theta=1$ 处，全局梯度为 $[1{+}3(1{-}2)]/2=-1$，并未达到驻点。非 IID 意为不同客户端的记录不服从同一个联合分布，例

如故障比例、输入条件或标签含义有差异；它与本地训练时间不同的系统异构不是同一个概念。即使没有异质性，多步梯度也在移动后的点求值，通常不等于把起点梯度重复 E 遍。

隐私的三个层次。 数据不上传不等于隐私完好。更新可能通过梯度反演暴露样本特征，恶意客户端可能投毒，服务器也可能推断客户端属性。安全聚合保护服务器免于看到单个更新；差分隐私在更新上加入噪声，提供形式化的 (ϵ, δ) 保证；鲁棒聚合则针对异常更新，但不能自动提供隐私。

个性化联邦学习。 全局模型适合共享规律，个性化模型允许客户端保留本地参数：

$$\theta_k = \theta_{shared} + \theta_{k,local}. \tag{18.13}$$

共享层、个性化头、元学习初始化和客户端聚类是常见路线。工业设备差异很大时，追求一个平均最优模型可能不如学习一组有结构的个性化模型。

个性化目标为什么需要耦合。 仅写 $\theta_k = \theta_{shared} + \theta_{k,local}$ 还没有定义算法，因为给共享参数加一个向量、给每个本地参数减去同一向量不会改变预测。一个明确的软共享目标是

$$\min_{\theta,\{v_k\}} \sum_k p_k \left[F_k(v_k) + \frac{\lambda}{2}\|v_k - \theta\|^2 \right], \quad \theta, v_k \in \mathbb{R}^d, \quad \lambda > 0. \tag{18.14}$$

固定 θ，各客户端独立优化其正则化风险；固定 v_k，对 θ 求导得到 $\lambda \sum_k p_k(\theta - v_k) = 0$，故 $\theta = \sum_k p_k v_k$。这一交替过程把共享信息理解为各个性化参数的参照，而不是强迫它们完全相同。λ 很大时接近共享模型，很小时接近独立训练，但数据少的客户端可能因此过拟合。这里的 v_k 是长期保留的个性化模型，与 FedProx 中每轮重置的局部变量不同。

若不同工厂的输出标签或传感器结构并不相同，可令共享编码器为 f_θ、本地头为 h_{ψ_k}，优化 $\sum_k p_k F_k(\theta, \psi_k)$。此时只能聚合语义和维度一致的共享参数，不能把不同类别顺序的分类头逐坐标平均。对从未参与的新工厂，还必须规定支持样本和本地适应步骤；这个问题将在元学习章进一步展开。

通信和系统约束。 量化、稀疏化、低秩更新和客户端选择降低通信量。实际系统还面对带宽波动、设备掉线、异构算力和更新延迟。实验应记录每轮参与客户端数、有效样本量、字节数、端侧训练时间和掉线率，而不能只报告最终准确率。

压缩误差与误差反馈。 设待上传差分 $u_k \in \mathbb{R}^d$，压缩器 Q 可返回量化值或稀疏向量。若 $\mathbb{E}[Q(u) \mid u] = u$ 且 $\mathbb{E}\|Q(u) - u\|^2 \le \omega \|u\|^2$，压缩不改变条件均值，却增加更新方差；确定性的最大幅度稀疏化通常不满足无偏性。误差反馈保存残差 r_k^t，令

$$s_k^t = Q(u_k^t + r_k^t), \qquad r_k^{t+1} = u_k^t + r_k^t - s_k^t. \tag{18.15}$$

由此 $s_k^t = u_k^t + r_k^t - r_k^{t+1}$，对轮次求和后中间残差相消：$\sum_{t=0}^{T-1} s_k^t = \sum_{t=0}^{T-1} u_k^t + r_k^0 - r_k^T$。它解释了为何未发送信息可以延后补偿，但残差有界及收敛仍需压缩器和目标的额外条件。长期掉线、状态丢失或模型版本变化都可能破坏这种补偿；稀疏上传还要计入索引字节，不能只数非零数值。

压缩发送的是近似更新，残差不能丢。 取二维更新 $u = (0.6, 0.4)^{\mathsf{T}}$，只保留绝对值最大的一个坐标，首次发送 $(0.6, 0)^{\mathsf{T}}$，残差为 $(0, 0.4)^{\mathsf{T}}$。下一次相同更新先加残差，得到 $(0.6, 0.8)^{\mathsf{T}}$，发送 $(0, 0.8)^{\mathsf{T}}$，新残差为 $(0.6, 0)^{\mathsf{T}}$。累计发送加最终残差恰等于累计原更新 $(1.2, 0.8)^{\mathsf{T}}$。这说明信息可以延后发送，但不保证每一轮的模型与未压缩模型相同。个性化模型还需保存本地头，控制变量方法需保存 c_k，所以通信减少与状态内存增加应一起核算。

18.3 联邦诊断案例与验收

将不同工厂作为客户端，训练共享的故障表征和个性化的告警头。一轮 FedAvg 与集中式梯度下降的差异来自本地多步更新和客户端数据权重；安全聚合只能隐藏单个更新，不能防止模型投毒，因此验收还应约束最差客户端性能、异常更新比例和通信失败后的恢复行为。

一轮联邦训练的完整过程。 服务器首先选择客户端子集并发送当前模型。客户端在本地数据上训练若干步，计算更新后上传参数或差分；服务器按样本量或其他权重聚合，再将新模型发送给下一轮。这个过程的关键不是“把 SGD 分散执行”这么简单，而是每轮参与者、数据量、本地步数和网络状态都会改变优化轨迹。

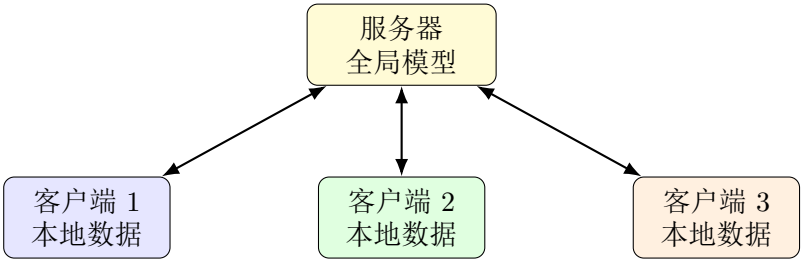


图 18.2: 联邦学习的服务器–客户端循环；原始数据留在客户端，但更新仍需保护。

图18.2展开一轮下发、本地训练和回传聚合的关系；客户端计算与通信构成不同成本，且回传更新本身仍可能包含敏感信息。

客户端漂移与 FedProx。 非 IID 数据下，本地目标的最优方向可能不同。客户端执行过多本地步数后，更新会远离全局模型，聚合后产生客户端漂移。FedProx 在本地目标中加入近端项：

$$\min_{\theta} F_k(\theta) + \frac{\mu}{2}\|\theta - \theta^t\|_2^2. \tag{18.16}$$

近端系数限制本地模型偏离服务器模型的幅度，适合数据和算力差异较大的系统，但过大的 μ 会降低本地适应能力。

对该目标求梯度，本地第 e 步为

$$\theta_{k,e+1} = \theta_{k,e} - \eta[\nabla F_k(\theta_{k,e}) + \mu(\theta_{k,e} - \theta^t)]. \tag{18.17}$$

起点 $\theta_{k,0} = \theta^t$ 处近端梯度为零，所以第一步与 FedAvg 相同；它主要约束之后的偏离。对二次目标 $F_k(v) = \frac{1}{2}(v - b_k)^{\mathsf{T}} A_k (v - b_k)$，其中 $A_k \in \mathbb{R}^{d\times d}$ 对

称半正定、$\mu>0$，驻点方程为 $(A_k+\mu I)v=A_kb_k+\mu\theta^t$，从而

$$v-\theta^t=-(A_k+\mu I)^{-1}\nabla F_k(\theta^t). \tag{18.18}$$

沿 A_k 的特征方向，位移被 $1/(a+\mu)$ 缩放，展示了近端项如何抑制偏离。对非凸神经网络，近端项不自动使目标凸；若 Hessian 特征值下界为 $-\rho$，只有 $\mu>\rho$ 才足以使该区域的正则化 Hessian 正定。实际内层通常仅近似求解，应同时报告本地停止准则，而非默认获得精确极小点。

近端项不是直接把更新裁短。 取 $F_k(v)=(v-2)^2/2$、服务器起点 0、$\mu=3$，正则化驻点满足 $(v-2)+3v=0$，所以 $v=0.5$ 而非本地独立最优 2。它改变了整个本地目标；每步都受到返回起点的力，但并非强制要求位移小于某固定半径。若 $\eta=0.1$，第一步仍为 0.2，第二步梯度为 $(0.2-2)+3(0.2)=-1.2$，更新至 0.32。这个例子也说明有限步结果不等于精确近端解。

控制变量与 SCAFFOLD。 SCAFFOLD 为服务器和客户端维护控制变量，用于估计并校正本地更新中的系统性偏差。其思想是把“客户端自身的梯度偏移”和“当前模型真正的全局下降方向”区分开。该类方法通常以额外状态和通信为代价改善非 IID 收敛，实验时必须报告控制变量的存储和同步开销。

具体地，设 $c,c_k\in\mathbb{R}^d$ 分别估计全局和本地梯度方向，本地更新改为

$$v_{k,e+1}=v_{k,e}-\eta(g_k(v_{k,e})-c_k+c),\qquad v_{k,0}=\theta^t. \tag{18.19}$$

若在同一参考点 $c_k=\nabla F_k(\theta^t)$、$c=\sum_k p_kc_k$，则第一步修正方向的条件期望恰为 $\nabla F(\theta^t)$，不再随客户端改变。后续各本地点不同，校正并不意味着始终拥有精确全局梯度。一种固定 E,η 的控制变量更新为

$$c_k^{new}=c_k-c+\frac{\theta^t-v_{k,E}}{E\eta}=\frac{1}{E}\sum_{e=0}^{E-1}g_k(v_{k,e}). \tag{18.20}$$

第二个等号由本地递推求和得到，说明新控制变量代表本轮沿轨迹的平均梯度。若维护加权关系 $c=\sum_k p_kc_k$，服务器应更新 $c^{new}=c+\sum_{k\in S_t}p_k(c_k^{new}-$

c_k)，未参与者保留旧状态。经典均匀客户端设定取 $p_k = 1/K$；不同权重、服务器步长和参与方案需要配套实现，不能混用聚合规则。陈旧控制变量以及额外的 d 维上传，是该方法的实际代价。

控制变量为什么有减有加。 若客户端当前梯度为 5，保存的本地方向估计为 $c_k = 4$，全局方向估计为 $c = 1$，修正后是 $5 - 4 + 1 = 2$。减去 4 是在扣除本地系统偏移，加上 1 是在补回共享参考方向，不是把梯度都强制为零。若当前梯度仍恰为 4，则得到 1；若本地分布已经改变，陈旧的 4 也可能校正过头，所以状态要随参与更新并与模型版本对应。

差分隐私与隐私预算。 必须先指定保护单位。样本级邻接表示训练集仅相差一条记录；客户端级邻接表示相差一个客户端的全部贡献。单样本梯度裁剪通常用于样本级保护，不能直接称为客户端级保护。随机机制 M 满足 (ϵ, δ) 差分隐私，是指任意相邻数据集 D, D' 和可测输出事件 A 都有

$$\Pr[M(D) \in A] \le e^{\epsilon} \Pr[M(D') \in A] + \delta. \tag{18.21}$$

它约束观察结果因一单位数据变化而改变的程度，不是“攻击一定失败”的概率声明。

以客户端级发布为例，先把每个上传向量 $u_k \in \mathbb{R}^d$ 裁剪为

$$\bar{u}_k = u_k \min\{1, C/\|u_k\|_2\}, \qquad M = \frac{1}{m}\left(\sum_k \bar{u}_k + \xi\right), \quad \xi \sim \mathcal{N}(0, \sigma^2 C^2 I_d), \tag{18.22}$$

其中零向量保持为零，m 是固定公开归一化常数，缺席贡献以零计。加入或删除一个客户端时，和的 ℓ_2 敏感度至多为 C；替换一个客户端时由三角不等式得到 $2C$。因此两种邻接定义不可使用相同敏感度而不作说明。对一次发布、加入删除邻接、$0 < \epsilon < 1$，经典高斯机制的一个充分条件是 $\sigma \ge \sqrt{2\log(1.25/\delta)}/\epsilon$；该式是保守校准条件，不是多轮训练的最终预算。

除以 m 后，敏感度与噪声标准差同时缩小，不能据此声称隐私自动增强。裁剪把过大更新的影响截断，也引入偏差；噪声期望为零，但其平均

平方范数为 $d\sigma^2C^2/m^2$，高维、少参与者时可能明显损害效用。若服务器先看到未扰动单个更新，再在总和上加噪声，则保证针对发布结果的观察者，而不保护客户端免受该服务器观察；必须明确可信聚合者，或使用安全聚合与按约定步骤进行的分布式噪声生成。

对于自适应的 T 轮发布，基本组合给出 $\epsilon_{tot} \le \sum_t \epsilon_t$、$\delta_{tot} \le \sum_t \delta_t$。实际可用更紧的隐私会计，但需声明抽样方式、采样率、噪声乘子、邻接定义和会计方法。抽样放大结论依赖抽样独立性及可见信息，不能对按故障分数挑选客户端的过程直接套用均匀抽样公式。

用二维向量理解裁剪、噪声和保护单位。 若上传 $u = (3, 4)^{\mathsf{T}}$，长度为 5，阈值 $C = 2$，裁剪后为 $(1.2, 1.6)^{\mathsf{T}}$，方向不变而长度变为 2；小于阈值的向量不变。噪声不是每次固定加同一个数，而是按声明分布独立生成新的随机向量，再按发布机制聚合。ϵ 控制相邻数据发布概率比的容许变化，δ 是概率不等式的松弛量，二者都不是准确率。保护一条窗口与保护整家工厂的所有窗口差别很大，应先回答要隐藏哪一种贡献，再选择裁剪与会计方式。

安全聚合与攻击面。 安全聚合使服务器只能看到聚合结果，不能直接读取单个客户端更新，但它不能防止恶意客户端上传投毒或后门更新。鲁棒聚合可以按坐标中位数、截断均值或相似性筛除异常，却可能误伤来自真实少数群体的正常更新。安全性需要从服务器、客户端、通信通道和模型输出四个方面分别分析。

安全聚合为何能只显露总和。 下面只用代数说明掩码抵消，不把它当作可直接部署的完整密码协议。设更新经约定量化后为有限域 $\mathbb{F}_q^d$ 上的向量 u_k，每对客户端共享随机掩码 r_{kj}，并约定 $r_{jk} = -r_{kj}$。客户端发送

$$\widetilde{u}_k = u_k + \sum_{j \neq k} r_{kj}, \qquad \sum_k \widetilde{u}_k = \sum_k u_k + \sum_{k<j} (r_{kj} + r_{jk}) = \sum_k u_k. \tag{18.23}$$

掩码在总和中抵消，单个带掩码消息却不直接等于原更新。实际协议还需要认证、密钥协商、门限恢复及串谋假设；若某客户端掉线，它对应的掩码未必成对抵消，需要恢复机制，且不能同时恢复足以解开其原始贡献的全部秘密。量化范围和模数还要防止解码溢出。

服务器得到总和仍可能通过参与集合差分或很小的聚合组推断贡献，因此还需最小聚合规模、查询限制及必要的差分隐私。另一个根本冲突是：坐标中位数不是总和的函数，服务器若只能获得总和，就不能直接执行基于单个更新的筛选。安全聚合与鲁棒聚合必须联合设计，而不是把两个算法名称并列便认为两项保证同时成立。

掉线、异构与公平性。 慢客户端会拖延同步，掉线客户端可能造成样本代表性变化；按样本量加权又可能让大客户端压过小群体。评价时应报告平均性能、最差客户端、不同客户端规模区间和掉线条件下的性能。对于工业多工厂系统，公平性不仅是统计指标，也关系到不同工厂是否都能获得足够的故障检测能力。

在多工厂轴承诊断中，可把工厂、产线或设备群定义为客户端。首先固定一个不参与训练的跨工厂测试集，并在每轮记录参与客户端、样本量、本地步数、上传字节数和训练时长。随后构造三种非 IID 情形：不同工厂故障比例不同、不同工厂只观测部分类别、不同工厂的相机或传感器分布不同。FedAvg、FedProx、SCAFFOLD 和个性化头应使用相同总通信预算比较，同时报告全局平均、宏平均、最差工厂和各类故障召回。

隐私验收不能只检查原始文件是否离开工厂。应分别测试更新反演、成员推断、恶意客户端投毒和服务器串谋；对差分隐私记录每轮裁剪、噪声和累计 (ϵ, δ)，对安全聚合记录阈值、掉线恢复和密钥失效行为。若加入噪声后小工厂的少数故障召回显著下降，平均准确率可能仍然稳定，但系统已经产生了不公平的风险分配，因此最差客户端和少数类指标必须进入停止条件。

以下框架教程、隐私指南与入门讲解可用于复习联邦训练流程及其保

证边界。

辅助学习材料

- **Quickstart PyTorch**；作者/平台：Flower；英文；官方框架教程。阅读 ClientApp、ServerApp、FedAvg 与本地模拟流程，观察数据分区、轮次聚合和客户端评估。在线阅读。
- **TensorFlow Privacy：隐私保护指南**；作者/平台：TensorFlow；中文；官方指南。阅读 DP-SGD 的介绍，理解限制单个样本影响的动机及其与联邦学习用户级隐私的区别；隐私预算还需结合本章的会计分析。在线阅读。
- **详解联邦学习 Federated Learning**；知乎；中文解说。画出本地训练与服务器聚合流程，检查客户端权重；标题与主题据必应索引，原页受限。在线阅读。
- **终于有人把联邦学习讲明白了**；CSDN；中文博客。对照非独立同分布和通信约束；数据不出本地不等于已经满足隐私保证；标题与主题据必应索引，原页受限。在线阅读。
- **《联邦学习技术介绍、应用和 FATE 开源框架》第 1 课！了解一下 AI 的新风口?**；上传者：FedAI 联邦学习；bilibili；中文课程。对照本章联邦协作流程与应用边界，区分框架实现和隐私保证；旧课程的软件接口以当前官方文档为准。2026 年 10 月 4 日公开元数据播放 12,741 次，高于本次异步联邦教程候选的 6,701 次；已核对公开课程简介、标题和计数，未逐帧观看。观看视频。

本章小结。 联邦学习要求数据留在各工厂，但这不会替我们决定应该最小化哪一种风险。所有工厂各做一步、再按样本聚合时，FedAvg 可还原集中式梯度；每个工厂本地走多步后，各自停在不同位置，聚合方向就会产生

偏差。FedProx 用近端项限制本地模型离开全局模型太远，SCAFFOLD 用控制变量修正客户端漂移，个性化方法则允许不同工厂保留不同的预测头。它们解决的不是同一个优化问题，不能只按通信轮数或平均准确率排顺序。

隐私与可靠性同样必须拆开：安全聚合限制单个更新的可见性，差分隐私限制单个保护单位对发布分布的影响，鲁棒聚合处理异常贡献。有效系统还要在掉线、少数故障和最差工厂上通过验收。本章的基本立场不是尽可能多地分散计算，而是在可说明的统计目标、信任边界与资源预算之间选择可执行的协作方式。

能够共同训练以后，还要检查怎样衡量样本相似性。高维读数距离近，可能只是温度量纲较大，不一定代表故障相似。下一章的流形学习研究局部邻近关系能否反映转速、负载等少量变化因素。理解这些关系，也有助于判断联邦学习中所谓相似工厂究竟是工况相似，还是仅仅表示中的数值接近。

第十九章　流形学习

本章摘要。流形学习假定高维观测由少量连续因素控制。本章从线性子空间基线出发，分别推导保持测地距离、局部重构和图平滑的算法，再讨论 t-distributed Stochastic Neighbor Embedding (t-SNE)、Uniform Manifold Approximation and Projection (UMAP) 与流形正则化。低维图形只是一种表示，不能直接证明故障类别可分。

上一章解决了数据分散时如何协同训练，却没有保证传递给模型的距离和表示本身合理。相同故障在不同转速下可能相距很远，不同故障也可能因传感器尺度相似而靠得很近。本章把问题从“数据在哪里”转向“数据之间什么关系应被保留”：如果观测的高维变化主要由少量连续因素驱动，能否在低维坐标中保留对判断有用的结构？

把许多传感器读数画到平面上，可以有不同的画法。PCA 尽量保留线性重构能力，Isometric Mapping (Isomap，等距映射) 保留沿邻域图行走的测地距离，Locally Linear Embedding (LLE) 保留局部重构关系，谱方法关注图上的平滑变化；概率可视化更重视谁与谁相邻，并不保证远处两点的距离准确。本章分别推导这些目标。看图时还要问：聚在一起的是同一种故障，还是同一种转速？换一台设备后，这种表示是否仍有助于识别故障？本章的几何目标只有在服务这个预测问题时才有意义，漂亮的二维图不是终点。

19.1　几何假设与邻域构造

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

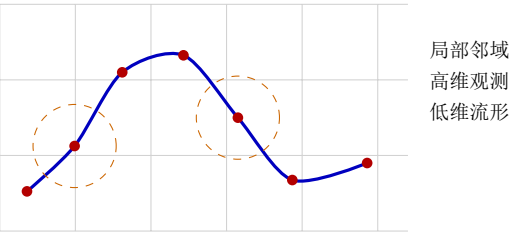


图 19.1: 流形学习把高维观测看作嵌入空间中的低维结构；邻域大小决定局部几何是否可靠。

图19.1用曲线上的邻域说明局部距离与整体嵌入形状的区别；邻域过大会跨越不同局部区域，过小则可能使几何估计缺乏样本支持。设 $x = g(z) + \epsilon \in \mathbb{R}^d$，$z \in \mathbb{R}^r$ 且 $r \ll d$，g 在局部光滑。目标可以是恢复坐标、保持邻域或改善预测，这三者不是同一个优化问题。不同载荷、转速和传感器尺度会改变距离；先按训练数据确定标准化和度量，再构造 k 近邻或半径邻域图。

邻域太小会使图断裂，太大会跨越流形折叠形成捷径。互为近邻与并集近邻的连通性不同，应记录图的连通分量和边长分布。故障突变可能跨越不连续机制，不能因为原始欧氏距离近就强迫标签平滑。

低维并不等于只留下少数传感器。 每个 $x_i \in \mathbb{R}^d$ 是一条记录的 d 个特征，n 条记录堆成矩阵 X，行是样本、列是特征。设备是记录来源；任务是用这些记录作何种预测，不是矩阵的一行。潜在变量 $z \in \mathbb{R}^r$ 是少量连续因素，$\epsilon \in \mathbb{R}^d$ 是观测扰动，$g : \mathbb{R}^r \to \mathbb{R}^d$ 把因素变成观测。比如 $x = (\cos z, \sin z)$ 有两个读数，却只由一个角度控制；这是局部一维圆周，不能靠删掉其中一个读数无歧义地表示整圈。流形是局部像低维平面一样可用坐标描述的集合，通常不要求整体是平面。实际算法只能依据有限且有噪声的点猜测这种结构。

构图时每个样本是一节点，近邻之间连边；边长通常是距离，边权也可以是随距离减小而增大的相似度，二者不能混淆。k 近邻是为每点找最近的 k 个其他点；有向近邻关系不必对称，双方都选中才连边是交集规则，任一

方选中就连边是并集规则。标准化例如把温度减去训练均值再除以训练标准差，避免温度的数值尺度压过振动；零标准差通道需要删除或另作约定。

19.2 线性基线与测地距离

PCA 与核 PCA。 对中心化数据矩阵 $X \in \mathbb{R}^{n\times d}$，PCA 求

$$\min_{V^{\mathsf{T}}V=I} \|X - XVV^{\mathsf{T}}\|_F^2, \tag{19.1}$$

其解由 $X^{\mathsf{T}}X$ 的主特征向量组成。坐标为 $Z = XV$，截断奇异值分解可避免显式构造大协方差矩阵。高方差方向不一定携带故障信息，低方差异常可能被截断。核 PCA 在核矩阵上中心化后求特征向量，允许非线性表示，但需要选择核与处理新样本映射 [77]。

PCA 的重构推导与尺度选择。 令 $V \in \mathbb{R}^{d\times r}$ 列正交，$P = VV^{\mathsf{T}}$ 满足 $P^2 = P = P^{\mathsf{T}}$。因此

$$\|X - XP\|_F^2 = \operatorname{tr}[(I-P)X^{\mathsf{T}}X(I-P)] \tag{19.2}$$

$$= \operatorname{tr}(X^{\mathsf{T}}X) - \operatorname{tr}(V^{\mathsf{T}}X^{\mathsf{T}}XV). \tag{19.3}$$

第二行利用迹的循环性质 $\operatorname{tr}(AB)=\operatorname{tr}(BA)$ 以及 $(I-P)^2 = I-P$，将两侧投影合并。最小化重构误差等价于最大化最后的迹。设 $X^{\mathsf{T}}X = U\Lambda U^{\mathsf{T}}$，特征值降序排列，把 V 展开到 U 基底后，每个特征方向的被保留权重介于 0 与 1，且总和为 r；最大值于是为前 r 个特征值之和。若 $X = U_X\Sigma V_X^{\mathsf{T}}$，坐标为 $XV_{X,r} = U_{X,r}\Sigma_r$，最小误差为被舍弃奇异值平方之和。这也说明为何投影坐标有 r 列，而不是把样本特征向量直接当作载荷矩阵。

中心化均值和标准差仅由训练数据估计。若只中心化，新样本坐标为 $z = V^{\mathsf{T}}(x-\bar{x})$；若训练时还做了标准化，则先令 $\widetilde{x}_j = (x_j - \bar{x}_j)/s_j$，再用在标准化训练数据上求得的载荷计算 $z = V^{\mathsf{T}}\widetilde{x}$，不能遗漏除以训练标准差 s_j 的步骤。只中心化的 PCA 偏重数值方差大的传感器，标准化后的 PCA 则

赋予低方差传感器更大相对权重；二者都不是天然正确。重特征值对应的基底可以旋转，不能把单条主轴的符号或方向变化解释成物理机制变化。

PCA 的每个矩阵各做什么。 $V \in \mathbb{R}^{d\times r}$ 的列是保留方向，$Z = XV \in \mathbb{R}^{n\times r}$ 是每条记录的新坐标，$ZV^{\mathsf{T}} \in \mathbb{R}^{n\times d}$ 把它们重构回原特征数。$\|A\|_F^2$ 指矩阵所有元素平方之和，$\operatorname{tr}(A)$ 是方阵对角线之和；特征向量 v 满足 $Av = \lambda v$，表示该方向只被矩阵缩放而不改变方向。取三条已中心化记录 $(-1,0),(0,0),(1,0)$，则 $X^{\mathsf{T}}X = \operatorname{diag}(2,0)$，选 $r = 1$ 时 $V = (1,0)^{\mathsf{T}}$，得到坐标 $(-1,0,1)^{\mathsf{T}}$，重构误差为零。若新点为 $(0,1)$，投影却为 0，第二个方向的异常完全丢失；训练重构好并不保证保留所有未来故障。

核 PCA 的特征空间与新样本坐标。 设正半定核 $k(x,x') = \langle\varphi(x),\varphi(x')\rangle$，$K_{ij} = k(x_i,x_j)$，$K \in \mathbb{R}^{n\times n}$。特征空间中心化对应 $K_c = HKH$，其中 $H = I - \mathbf{1}\mathbf{1}^{\mathsf{T}}/n$。若 $K_c v_j = \lambda_j v_j$、$\|v_j\| = 1$ 且 $\lambda_j > 0$，则单位主轴为

$$w_j = \frac{1}{\sqrt{\lambda_j}}\sum_i (v_j)_i[\varphi(x_i) - \bar{\varphi}], \qquad z_{ij} = \sqrt{\lambda_j}(v_j)_i. \tag{19.4}$$

归一化来自 $\|w_j\|^2 = v_j^{\mathsf{T}}K_c v_j/\lambda_j = 1$。对新样本 x，先形成交叉核向量

$$(k_c(x))_i = k(x_i,x) - \frac{1}{n}\sum_a k(x_a,x) - \frac{1}{n}\sum_b K_{ib} + \frac{1}{n^2}\sum_{a,b} K_{ab}, \tag{19.5}$$

再计算 $z_j(x) = v_j^{\mathsf{T}}k_c(x)/\sqrt{\lambda_j}$。新点必须使用训练均值，不能单独重新中心化。极小特征值会放大数值误差，核宽度会改变整个几何；核空间中的好重构也不等于可以唯一还原原始传感器读数。

Isomap。 Isomap 用邻域图最短路径距离 D_{ij} 近似测地距离，再执行经典多维尺度分析 [85]：

$$H = I - \frac{1}{n}\mathbf{1}\mathbf{1}^{\mathsf{T}}, \qquad B = -\frac{1}{2}HD^{\circ 2}H, \qquad Z = U_r\Lambda_r^{1/2}. \tag{19.6}$$

$D^{\circ 2}$ 表示逐元素平方，U_r, Λ_r 取正的主特征对。算法依次构图、计算最短路径、双中心化和谱分解。图断裂时路径距离无穷，不能直接进入 Multidimensional Scaling (MDS)；跨流形捷径则会系统性缩短距离。负特征值提示估计距离不能完全对应欧氏嵌入，不应直接对其开平方。

沿图走与直接穿过去的差别。 设三点为 $A=(0,0), B=(1,0), C=(1,1)$，图只连 A–B 和 B–C，边长都为 1。图上 $D_{AC}=2$，而原空间直线距离是 $\sqrt{2}$；Isomap 使用前者，因为假设允许的局部移动必须沿图边。如果这三点其实来自平面而非折线路径，稀疏图会高估距离，说明图距离只是估计，不自动等于真实测地距离。反过来，误加一条跨折叠短边会低估距离。把距离矩阵变成坐标时，$H \in \mathbb{R}^{n\times n}$ 执行去均值，$B \in \mathbb{R}^{n\times n}$ 存样本两两内积，$U_r \in \mathbb{R}^{n\times r}$ 是样本侧特征向量，与 PCA 的特征侧载荷 V 维度不同。

双中心化为什么把距离变成内积。 暂设 D_{ij} 确实来自中心化坐标 $Z \in \mathbb{R}^{n\times r}$，即 $Z^{\mathsf{T}}\mathbf{1}=0$。令 $B=ZZ^{\mathsf{T}}$、$b_i = B_{ii}$，平方距离展开为

$$D_{ij}^2 = B_{ii} + B_{jj} - 2B_{ij}, \qquad D^{\circ 2} = b\mathbf{1}^{\mathsf{T}} + \mathbf{1}b^{\mathsf{T}} - 2B. \tag{19.7}$$

由于 $H\mathbf{1}=0$ 且 $HBH=B$，左右乘 H 便得到 $B=-HD^{\circ 2}H/2$。因此谱分解不是无来由的步骤，而是在从距离反求坐标内积。若 B 半正定，保留前 r 个正特征对得到 $Z=U_r\Lambda_r^{1/2}$；坐标只确定到正交旋转，中心化则固定了平移自由度。

图最短路径得到的距离未必能精确嵌入欧氏空间。截断谱解最小化的是秩约束下的 Gram 矩阵误差 $\|B-ZZ^{\mathsf{T}}\|_F^2$，不是一般意义下的 $\sum_{ij}(D_{ij}-\|z_i-z_j\|)^2$。即便图构造正确，球面等具有内在曲率的流形也不能被无失真地摊平成同维欧氏平面。Isomap 尤其依赖采样足够密、邻域不跨越折叠以及测地结构近似可展平；“存在低维流形”本身还不足以保证成功。

经典实现需要存储 $n\times n$ 距离矩阵。Landmark 变体仅用部分代表点近似全局几何，降低计算和存储，但代表点必须覆盖各工况；选择失衡会遗漏少数状态。

19.3 局部重构与谱嵌入

LLE。 局部线性嵌入先固定每个样本的邻居，求局部重构权重 [73]：

$$\min_{W} \sum_{i} \Big\| x_i - \sum_{j \in \mathcal{N}_i} W_{ij} x_j \Big\|_2^2, \qquad \sum_{j} W_{ij} = 1. \tag{19.8}$$

和为一的约束使权重对整体平移不变。邻域协方差奇异时需加小的对角正则。固定 W 后，再求

$$\min_{Z} \operatorname{tr}\!\big(Z^{\top} (I - W)^{\top} (I - W) Z\big), \qquad Z^{\top}\mathbf{1} = 0, \quad Z^{\top} Z = I. \tag{19.9}$$

取 $(I-W)^{\top}(I-W)$ 最小非平凡特征值对应向量。第一步保留局部重构关系，第二步避免坐标全部坍缩。噪声、采样密度变化或过大的邻域会破坏局部线性假设。Hessian LLE 与局部切空间对齐等变体改变局部几何估计，并非仅更换一个可视化参数 [20, 97]。

LLE 的两个约束优化如何求解。 对点 i 设邻居数为 m_i，把差向量组成 $A_i = [x_j - x_i]_{j \in \mathcal{N}_i} \in \mathbb{R}^{d \times m_i}$，局部权重 $w_i \in \mathbb{R}^{m_i}$。利用 $\mathbf{1}^{\top} w_i = 1$，重构误差化为 $\|A_i w_i\|^2 = w_i^{\top} C_i w_i$，其中 $C_i = A_i^{\top} A_i$。拉格朗日函数取

$$\mathcal{J}(w_i, \nu) = w_i^{\top} C_i w_i - 2\nu (\mathbf{1}^{\top} w_i - 1). \tag{19.10}$$

驻点满足 $C_i w_i = \nu \mathbf{1}$，故当 C_i 可逆时

$$w_i = \frac{C_i^{-1}\mathbf{1}}{\mathbf{1}^{\top} C_i^{-1} \mathbf{1}}. \tag{19.11}$$

实现应求解线性系统而非显式求逆。若邻居近似落在低维切平面，C_i 很容易奇异，可用 $C_i + \gamma I$、$\gamma > 0$ 替代。正则化提高稳定性，但同时改变重构关系。权重允许为负，LLE 的权重矩阵不是随机游走概率矩阵。

第二步设 $M = (I-W)^{\top}(I-W) \in \mathbb{R}^{n \times n}$。因 $W\mathbf{1} = \mathbf{1}$，有 $M\mathbf{1} = 0$，不加约束时 $Z = 0$ 就是平凡最优解。约束 $Z^{\top} Z = I$ 固定尺度、$Z^{\top}\mathbf{1} = 0$ 排除

常数方向；Rayleigh 商最小化给出其余最小特征值对应向量。若零空间不止一维，还需诊断连通分量或重构退化，不能机械删除一个特征向量就结束。

对新点可以在训练点中求同样的和为一重构权重，并令 $z(x)=\sum_j w_j(x)z_j$。这是一种已声明的邻域插值规则，不是重新求解训练谱问题。它在已覆盖的局部区域有意义，但无法可靠外推到新工况形成的流形分支。

局部重构不是按邻居投票。 在一维上，点 1 由邻居 $0,2$ 重构，权重 $1/2,1/2$ 使 $1=(1/2)0+(1/2)2$。若全体加 10，仍有 $11=(1/2)10+(1/2)12$，这就是权重和为一的平移不变性。点 3 若只能用邻居 $0,2$ 重构，则权重为 $-1/2,3/2$，和仍为一；负权重不是概率，也不能拿去做随机游走。嵌入的第二步寻找新的 $z_i\in\mathbb{R}^r$，让同一组权重仍尽量重构它们，不是在新空间重新随意选权重。由于小邻域可能重构得过于精确，零误差本身不足以证明全局坐标可靠。

拉普拉斯特征映射。 取对称非负邻接权 W_{ij}，例如邻域内的高斯核权重；令 $D_{ii}=\sum_j W_{ij}$、$L=D-W$。拉普拉斯特征映射最小化 [4]

$$\frac{1}{2}\sum_{i,j}W_{ij}\|z_i-z_j\|_2^2=\operatorname{tr}(Z^{\mathsf{T}}LZ),\qquad Z^{\mathsf{T}}DZ=I. \tag{19.12}$$

排除常数方向后求 $Lv=\lambda Dv$。图断裂会产生多个零特征值，因此非平凡方向的选择必须结合连通性。归一化拉普拉斯使用 $D^{-1/2}LD^{-1/2}$，对孤立节点需单独处理，避免除零。

从边上的差异到广义特征值。 本段 $W\in\mathbb{R}^{n\times n}$ 是对称非负相似度，区别于上一方法允许负值的重构权重；本段的 D 是度矩阵，不是 Isomap 的距离矩阵。对单列坐标 $v\in\mathbb{R}^n$ 逐项展开，有

$$\frac{1}{2}\sum_{i,j}W_{ij}(v_i-v_j)^2=\sum_i D_{ii}v_i^2-\sum_{i,j}W_{ij}v_iv_j \tag{19.13}$$

$$=v^{\mathsf{T}}(D-W)v\geq 0. \tag{19.14}$$

在 $v^{\mathsf T}Dv=1$ 下求驻点，$\nabla_v[v^{\mathsf T}Lv-\lambda(v^{\mathsf T}Dv-1)]=0$ 给出 $Lv=\lambda Dv$。还需 $v^{\mathsf T}D\mathbf{1}=0$ 排除常数方向。令 $u=D^{1/2}v$ 就转成对称问题 $D^{-1/2}LD^{-1/2}u=\lambda u$。低特征值表示沿强连接边缓慢变化，因而可能分开弱连接的设备群，但并不保证这些群等于故障类别。图密度、核带宽和正常工况的采样数量都可能决定这些方向。

图平滑可以在三个节点上手算。　三节点链 1–2–3，两条边权为 1，则度为 $(1,2,1)$，

$$L=\begin{pmatrix}1&-1&0\\-1&2&-1\\0&-1&1\end{pmatrix},\qquad v^{\mathsf T}Lv=(v_1-v_2)^2+(v_2-v_3)^2. \tag{19.15}$$

$v=(0,1,2)^{\mathsf T}$ 的能量为 2，$v=(0,2,0)^{\mathsf T}$ 的能量为 8，因此后者在边上变化更剧烈。所有节点取同一个值则能量为零，所以必须排除常数并固定尺度，否则求最平滑坐标只会得到重合的点。这里没有使用故障标签，故最平滑方向未必是分类最有用方向。

扩散坐标与扩散距离。　Diffusion Maps 将邻接权归一化为随机游走转移矩阵，以特征值的时间次幂缩放坐标 [15]。设图连通、各度 $d_i>0$，$P=D^{-1}W$，则 P_{ij} 表示一步从 i 到 j 的概率，平稳分布为 $\pi_i=d_i/\sum_a d_a$。对称性给出细致平衡 $\pi_iP_{ij}=\pi_jP_{ji}$，故可选右特征函数 ψ_ℓ，满足 $\sum_i \pi_i\psi_\ell(i)\psi_m(i)=\mathbf{1}[\ell=m]$。第一项为 $\lambda_0=1,\psi_0=1$。

走 t 步后的两行概率分布之差定义扩散距离：

$$D_t^2(i,j)=\sum_{a}\frac{[P^t_{ia}-P^t_{ja}]^2}{\pi_a} \tag{19.16}$$

$$=\sum_{\ell\ge 1}\lambda_\ell^{2t}[\psi_\ell(i)-\psi_\ell(j)]^2. \tag{19.17}$$

第二式由 $P^t_{ia}=\pi_a\sum_\ell \lambda_\ell^t\psi_\ell(i)\psi_\ell(a)$ 代入，并用加权正交性消去交叉项得到。因此坐标 $\Psi_t(i)=(\lambda_1^t\psi_1(i),\dots,\lambda_r^t\psi_r(i))$ 的欧氏距离近似扩散距离，截断误

差正是未保留项之和。它衡量的是多个路径共同形成的可达性，而非一条最短路径。

时间 t 越大，$|\lambda_\ell| < 1$ 的方向衰减越强；短时间强调局部邻域，较长时间突出缓慢变化的结构，过长则使所有点近乎重合。二部图可能出现 -1 特征值和周期振荡，可采用懒惰随机游走 $(I+P)/2$ 消除周期性。采样密度校正改变几何与密度的相对影响，应按任务解释，不能只选最美观的嵌入。

扩散为什么比较整行概率。 在前面的三节点链中，从端点 1 出发一步必到 2，从端点 3 出发一步也必到 2，所以两行转移概率都为 $(0,1,0)$，一步扩散距离为零，尽管两端的最短路径距离为 2。扩散关心后续能到哪里，不保证每个原节点都可区分；这种对称结构会合并具有相同扩散行为的点。若使用懒惰随机游走，两端还有留在自身的概率，就能改变这一现象。选时间尺度和转移规则因此是在选择保留什么关系，而非无关紧要的绘图选项。

19.4 概率邻域可视化

t-SNE。 t-SNE 在原空间构造对称邻域概率 p_{ij}，在低维空间使用重尾分布 [87]：

$$q_{ij} = \frac{(1+\|z_i - z_j\|^2)^{-1}}{\sum_{a\neq b}(1+\|z_a - z_b\|^2)^{-1}}, \qquad \min_{Z} \sum_{i\neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}. \tag{19.18}$$

原空间高斯带宽逐点调整，使条件分布熵对应指定 perplexity。重尾低维分布缓解拥挤问题，KL 方向更重视保留高概率邻居。优化非凸，不同初始化、perplexity 和学习率可能改变结果。图中簇间空隙、面积和距离不能直接解释为真实故障严重度。

t-SNE 的概率、熵与梯度。 先在高维空间定义条件邻域概率：

$$p_{j|i} = \frac{\exp\!\big(-\|x_i - x_j\|^2/(2\sigma_i^2)\big)}{\sum_{a\neq i}\exp\!\big(-\|x_i - x_a\|^2/(2\sigma_i^2)\big)}, \qquad j \neq i, \quad p_{i|i} = 0. \tag{19.19}$$

带宽 σ_i 按 $\exp[-\sum_j p_{j|i}\log p_{j|i}]$ 等于给定 perplexity 调整；它描述有效邻居数而不是类别数。再令 $p_{ij}=(p_{j|i}+p_{i|j})/(2n)$，便有 $\sum_{i\neq j}p_{ij}=1$。

令 $a_{ij}=(1+\|z_i-z_j\|^2)^{-1}$、$A=\sum_{a\neq b}a_{ab}$。去掉不含 Z 的常数，目标为

$$C=-\sum_{i\neq j}p_{ij}\log a_{ij}+\log A. \tag{19.20}$$

式(19.20)右端的第一项鼓励原空间高概率邻居靠近，第二项因归一化耦合所有点而产生排斥。利用 $\nabla_{z_i}\log a_{ij}=-2a_{ij}(z_i-z_j)$，并计入有序点对的两个方向，可得

$$\nabla_{z_i}C=4\sum_{j\neq i}(p_{ij}-q_{ij})\frac{z_i-z_j}{1+\|z_i-z_j\|^2}. \tag{19.21}$$

当 $p_{ij}>q_{ij}$ 时，该点对对下降方向的贡献是吸引，反之为排斥；总更新还叠加其他点的作用，不能据单个差值保证这对点本步实际靠近或远离。重尾使较远点仍能产生排斥，缓解把高维邻域挤到二维的拥挤问题，但不会恢复真实全局距离。平移、旋转不改变目标，初始化和优化路径却可能改变局部极小值；因此多次结果中稳定的邻域比某次图上的簇间距离更值得解释。

可视化概率不是分类概率。 $p_{j|i}$ 表示给定样本 i 时把 j 视为邻居的相对权重，不是 j 属于某故障的概率。若一个点的两个邻居等概率，熵为 $\log 2$，perplexity 为 $\exp(\log 2)=2$；若有四个等概率邻居，则为 4。这帮助解释有效邻居数，但不表示算法一定只连这么多条边。t-SNE 的 q_{ij} 在所有有序点对上归一化，UMAP 的 q_{ij} 则是单条边的连接强度，通常不要求全部边强度相加为一；两处使用相同字母不意味着概率空间相同。

UMAP。 UMAP 用局部距离尺度构造模糊邻域图，再优化低维边连接强度 [59]。设原图权重为 w_{ij}，低维相似度为 $q_{ij}=(1+a\|z_i-z_j\|^{2b})^{-1}$，其图交叉熵包含

$$-\sum_{i<j}\left[w_{ij}\log q_{ij}+(1-w_{ij})\log(1-q_{ij})\right], \tag{19.22}$$

其中与 Z 无关的常数省略。实际实现用边采样与负采样近似优化，不能把采样目标不加区分地当成全对全精确计算。邻居数控制局部与较大尺度结构的折中，最小距离参数影响低维点的紧密程度，不是分类间隔的直接估计。

UMAP 的局部尺度与吸引排斥。 一种典型有向邻域强度在邻居上定义为

$$s_{j|i} = \exp\left[-\frac{\max\{0, d(x_i, x_j) - \rho_i\}}{\sigma_i}\right], \tag{19.23}$$

非邻居取零。其中 ρ_i 给出局部连接距离，$\sigma_i > 0$ 调节有效邻域规模。以模糊并集对称化得到

$$w_{ij} = s_{j|i} + s_{i|j} - s_{j|i}s_{i|j}, \tag{19.24}$$

从而即便只有一侧视对方为近邻，也可能保留该边。这与对条件概率取平均不是同一构图过程。

令 $r = \|z_i - z_j\| > 0$、$q = (1 + ar^{2b})^{-1}$，$a, b > 0$。单对损失 $\ell = -w \log q - (1 - w)\log(1 - q)$ 对距离的导数为

$$\frac{dq}{dr} = -\frac{2b}{r}q(1 - q), \qquad \frac{d\ell}{dr} = \frac{2b}{r}(w - q), \qquad \nabla_{z_i}\ell = \frac{2b(w - q)}{r^2}(z_i - z_j). \tag{19.25}$$

推导式(19.25)只需先对 q 求导，再乘 dq/dr。当 $w > q$ 时下降方向拉近点对，当 $w < q$ 时推远点对；$r = 0$ 附近需数值稳定处理。该式描述全对全理想目标，实际边采样和负采样的频率会改变有效权重，没有对应重要性校正时不能把随机更新称为该目标的严格无偏梯度。a, b 控制低维相似度曲线，因而紧簇大小部分来自人为设定，不是原始数据中的物理尺寸。

参数化嵌入学习显式映射，便于处理新数据；普通谱嵌入与非参数可视化通常需要邻域插值、Nyström 扩展或重新拟合。全数据联合嵌入属于传导式设定，不能据此声称对未见设备具备归纳泛化能力。

19.5 流形正则与工业验证

流形正则将未标注样本几何引入监督学习 [5]：

$$\mathcal{L}(f)=\frac{1}{n_l}\sum_{i=1}^{n_l}\ell(f(x_i),y_i)+\lambda_A\|f\|_{\mathcal{H}}^2+\lambda_I\boldsymbol{f}^{\mathsf{T}}L\boldsymbol{f},\tag{19.26}$$

其中 $\boldsymbol{f}$ 为全部训练侧样本的预测向量。最后一项鼓励邻近样本预测平滑；若邻域跨越真实类别边界，它会损害少数故障。类别条件图可以利用已知标签约束邻接，但不能使用测试标签构图。

图上的平滑如何影响一个未知标签。 沿三节点链，若两端预测固定为 0 和 1，中间无标签，则图能量为 $f_2^2+(f_2-1)^2$，导数 $4f_2-2=0$ 给出 $f_2=1/2$。这是沿邻域插值，不是发现中间点的真实类别；若第一条边跨越故障突变，这种平均会有害。一般式中的 $\boldsymbol{f}\in\mathbb{R}^n$ 先按标量回归理解，多类预测需对各类分量求图惩罚或使用矩阵迹。$\|f\|_{\mathcal{H}}^2$ 约束核函数空间中的复杂度，$\boldsymbol{f}^{\mathsf{T}}L\boldsymbol{f}$ 约束训练点之间的变化，两种约束的对象不同，不能只保留后者就认为未标注孤立区域也能得到唯一答案。

平方损失下把函数问题化为线性系统。 设训练侧共 n 个样本，其中 n_l 个有标签，取平方损失并假设 $\lambda_A>0$。核展开 $f(x)=\sum_{j=1}^{n}a_jk(x_j,x)$ 足以表达最优解：任何与这些核截面正交的函数在训练点上取零，不改变经验损失和图项，却只会增加 Reproducing Kernel Hilbert Space (RKHS) 范数。因此令 $a\in\mathbb{R}^n$、$\boldsymbol{f}=Ka$，$J\in\mathbb{R}^{n\times n}$ 为有标签位置为 1 的对角选择矩阵，y 在无标签位置补零，目标化为

$$\mathcal{L}(a)=\frac{1}{n_l}(Ka-y)^{\mathsf{T}}J(Ka-y)+\lambda_Aa^{\mathsf{T}}Ka+\lambda_Ia^{\mathsf{T}}KLKa.\tag{19.27}$$

对 a 求导并除以 2，得到

$$\left(\frac{1}{n_l}KJK+\lambda_AK+\lambda_IKLK\right)a=\frac{1}{n_l}KJy.\tag{19.28}$$

该系统的矩阵对称半正定。若 K 正定，$\lambda_A > 0$ 保证唯一系数解；若 K 奇异，不能直接消去 K，可在其非零特征子空间求解，系数虽可能不唯一，所表达的训练函数仍可相同。预测新点时使用核展开，不需要把测试标签或测试点加入训练图。

为理解图项的作用，也可暂时直接优化节点预测 $f \in \mathbb{R}^n$。在 $\frac{1}{2}(f-y)^{\mathsf{T}}J(f-y)+\frac{\gamma}{2}f^{\mathsf{T}}Lf$ 中，驻点满足 $(J+\gamma L)f = Jy$。对无标签节点 i，有 $d_i f_i = \sum_j W_{ij} f_j$，即预测等于邻居的加权平均。若一个连通分量完全没有标签，其常数水平无法由此确定；若正常与故障之间有错误强边，平滑会把真实突变抹掉。几何提供的是可检验的先验，而不是无标签数据自动携带正确标签的保证。

对多工况振动数据，先统一转速、负载和通道量纲，再比较 PCA、Isomap 和图嵌入。随后改变邻居数、距离定义和随机种子，检查哪些邻近关系始终稳定。在归纳评估下，图构造和参数选择只能用训练侧数据；新设备上线时，要按事先写好的映射规则处理，不能把测试样本重新放回图中。若预先声明传导式评估，可联合使用无标签测试输入，但不得使用测试标签，也不能把结果称为逐个新点的归纳性能。除了邻域保持、重构误差或谱诊断，还要报告未见设备的故障召回、误报和计算成本。二维图看起来更整齐，却让异常召回下降时，它就不适合这个业务。

以下文档与讲解可用于比较降维目标，并检查低维图形的解释边界。

辅助学习材料

- **Manifold learning**；作者/平台：scikit-learn Developers；英文；官方文档。重点阅读 Isomap、LLE、Spectral Embedding、t-SNE 与 MDS 小节，帮助逐一对应本章的测地距离、局部重构、图平滑和概率邻域。在线阅读。

- **Basic UMAP Parameters**；作者/平台：UMAP-learn；英文；官方教程。比较 n_neighbors、min_dist、n_components 和 metric 的示

例，理解局部与全局结构、嵌入紧密度和距离选择。在线阅读。

- **【机器学习】数据降维（Dimensionality Reduction）**；知乎；中文解说。先建立 PCA 基线，再比较邻域和距离保持目标；标题与主题据必应索引，原页受限。在线阅读。

- **降维算法总结（超全！附代码）**；CSDN；中文博客。核对降维的目标与新样本映射；二维可视化不能直接证明类别结构或部署泛化；标题与主题据必应索引，原页受限。在线阅读。

- **(选修)To Learn More - Unsupervised Learning - Neighbor Embedding**；李宏毅；bilibili；中文课程。选看第 93 集，对照本章邻域嵌入与可视化限制。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量；已核对目录与计数，未逐帧观看。观看分集。

本章小结。 本章从同一批高维观测得到了不同的数学对象：PCA 的正交投影、核 PCA 的特征空间内积、Isomap 的测地距离、LLE 的局部重构权重、谱方法的图平滑与扩散距离，以及 t-SNE、UMAP 的邻域强度。每一种谱分解或梯度优化都服务于一个明确目标；它们不能因最终都画出二维点图而互相替代。

流形假设真正有用的地方，是把局部连续变化与有限样本下的学习联系起来；真正危险的地方，是把错误距离、采样密度或跨类别边界的邻接当成真实结构。工业验证因此要同时检查图连通性、邻域稳定性、新点映射和故障指标。低维图形提供可探索的线索，而不是类别存在性、因果关系或部署泛化的证明。

本章利用样本之间的邻近关系，下一章则利用做过多个任务的经验。例如已经在多台设备上练习过少样本诊断，能否让下一台设备只需少量标签就完成适应？流形学习要检查样本邻近是否有意义，元学习则要检查以往

任务的共同规律是否适用于新任务。换了故障定义或设备机理以后，两种方法的原有假设都可能需要重审。

第二十章　元学习

本章摘要。元学习在一组任务上优化学习过程，使新任务能够用少量数据完成适应。本章从支持集、查询集和任务分布出发，分别推导度量方法、梯度初始化与学习优化器，再比较一阶近似、隐式梯度和概率变体。少样本只是常见应用，任务级泛化才是评价核心。

上一章利用样本几何学习表示，但即使表示合理，新设备仍可能只有极少标注数据。普通迁移学习先学一个模型再微调；元学习更进一步，把“看到少量样本之后如何学习”本身作为训练对象。这里被共享的不是所有任务的同一个最优参数，而是比较规则、初始化、更新器或先验，使不同任务能够以较低代价形成各自的预测器。

可以把每台新设备的适应过程看成一次练习：支持集是允许先看的少量已标注记录，查询集用来检查适应后的效果。训练时重复经历多个任务，才学出共享的元参数。下面先介绍不更新全部参数的度量方法，再用链式法则推导 Model-Agnostic Meta-Learning (MAML) 及其近似，最后讨论学习优化器和概率适应。作为全书最后一章，这里仍要回到最初的检查：测试任务是否真的没见过，查询标签是否参与了适应？这些条件不成立，少样本高分也不能说明模型会适应新任务；评价的对象必须是“用支持集适应后，在未见查询样本上的表现”。

20.1　任务分布与双层目标

本章末的“辅助学习材料”列出与核心方法对应的讲解和实践入口，可在阅读相关推导后，按所列小节对照学习。

图20.1将支持集上的任务内适应与查询集上的外层更新分开；查询误差

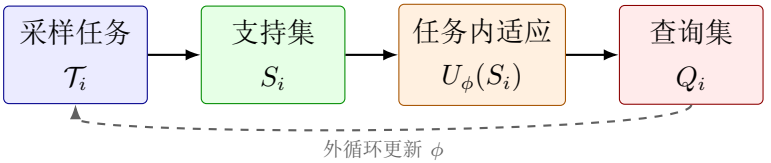


图 20.1：元学习的双层结构：支持集用于适应，查询集评价适应后的模型并更新元参数。

衡量的是适应后的泛化，而不是支持集拟合程度。任务 $\mathcal{T} \sim p(\mathcal{T})$ 包含支持集 S 与查询集 Q。支持集用于任务内适应，查询集用于评价适应结果。这里的“查询”不同于主动学习中向专家请求标签：Q 是适应后要预测的样本集合，元测试时不能把其标签补入支持集。设适应算子为 $U_\phi(S)$，元目标为

$$\min_{\phi} \mathbb{E}_{\mathcal{T}} \left[\mathcal{L}_Q(U_\phi(S)) \right]. \tag{20.1}$$

元参数可以是编码器、初始化、更新规则或概率先验 [33]。元训练查询集提供外循环梯度，元测试查询标签则只能用于最终评价。把所有任务样本混合做监督训练是多任务或预训练基线，不等同于上述适应后目标。

N-way K-shot 表示每个任务有 N 个类别、每类 K 个支持样本；shot 只计支持集，不计查询集。闭集分类中的 1-way 只需输出唯一类别，不能作为有意义的分类难度；单类故障检测需要另设正常参考、未知类别和拒识阈值。工业任务应按设备、批次或工况定义，并明确新任务的类别是否与元训练重合。

样本、设备、任务与 episode 的具体对应。 一段振动窗口及其故障标签是样本 (x, y)，电机是物理设备；任务则是一个有明确类别和数据分布的预测问题，例如在设备甲上区分正常与磨损。客户端是联邦计算中的数据持有者，本章不要求客户端存在，也不要求设备之间交换模型。一次 episode 是从任务分布中抽出一个任务并组织支持、查询的一次练习，不是一条样本。若在设备甲上做 2-way 2-shot，支持集有正常两条、磨损两条，共四条；查询集可以另有每类三条，共六条，shot 不限制查询数。同一设备可形成

多个 episode，但它们共享来源，不能被当作多个独立设备来夸大统计证据。

元训练先用支持标签适应，再用查询标签改进共享规则；元测试先固定已学到的共享规则，只用新任务支持标签适应，最后才揭示查询标签计分。度量方法的 $U_\phi(S)$ 可以输出原型和编码器组成的预测器状态，不一定输出与 ϕ 等长的网络权重。$\mathcal{L}_S$ 和 $\mathcal{L}_Q$ 分别是在对应集合上平均的标量损失，内循环是任务内改变状态，外循环是跨任务改变共享参数，两个循环优化的对象不同。

为什么必须在任务内划分支持与查询。 令元参数 $\phi \in \mathbb{R}^p$，适应后参数 $U_\phi(S) \in \mathbb{R}^d$；两者维度未必相同。训练批包含 B 个任务时，经验元目标为

$$\widehat{R}(\phi) = \frac{1}{B}\sum_{i=1}^{B} \frac{1}{|Q_i|} \sum_{(x,y)\in Q_i} \ell(f_{U_\phi(S_i)}(x), y). \tag{20.2}$$

先在每个查询集内平均、再在任务间平均，表达的是任务等权风险；把所有查询样本直接汇总则偏向查询集更大的任务。两者都可以定义，但必须与部署时抽到任务的分布对应。在任务独立同分布且支持查询按声明机制抽样时，该经验目标估计适应后的期望风险。高度相关的窗口不是独立任务，任务数量不能用窗口数量替代。

若把支持集也作为外循环评价集，目标会偏向快速记住已见样本，而不是快速泛化到任务内的新样本。相反，元训练查询标签用于更新 ϕ 是算法本身所需，并非泄漏；真正禁止的是利用元测试查询标签选择初始化、步数、阈值或检查点。对于时间序列，支持与查询的时间关系也属于任务分布：训练时用随机窗口构造任务，部署时却要求从过去适应未来，会改变元目标所对应的条件分布。

20.2 度量与关系方法

Matching Networks 与原型网络。 Matching Networks 根据查询与支持样本的相似度对支持标签加权 [91]：

$$p(y \mid x, S) = \sum_{i \in S} a(x, x_i) \mathbf{1}[y_i = y], \quad a(x, x_i) = \frac{\exp s(f(x), g(x_i))}{\sum_{j \in S} \exp s(f(x), g(x_j))}. \tag{20.3}$$

适应主要表现为改变支持集，而非更新全部网络参数。支持样本增加会提高推理成本，噪声支持样本可能直接传播错误标签。

若查询编码 $h = f(x) \in \mathbb{R}^r$、支持编码 $e_i = g(x_i) \in \mathbb{R}^r$，可取 $s(h, e_i) = -\|h - e_i\|^2/\tau$，$\tau > 0$。对类别 k，Matching Networks 等价于

$$p(y = k \mid x, S) = \frac{\sum_{i: y_i = k} \exp[-\|h - e_i\|^2/\tau]}{\sum_{j} \exp[-\|h - e_j\|^2/\tau]}. \tag{20.4}$$

它可以看作嵌入空间中的核加权投票：当 $\tau \to 0$ 且最近点唯一时接近最近邻，当 $\tau \to \infty$ 时接近支持集类别频率。于是支持集不平衡会隐含改变类别先验，不能把“多放几个正常样本”视为不影响预测规则的改动。训练查询交叉熵时，梯度同时改变查询和支持编码器，使适用于任务的近邻关系被反复强化；若相似度本身受新工况干扰，少量错误近邻就可能主导结果。

原型网络以类均值压缩支持集 [82]：

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_\phi(x_i), \qquad p(y = k \mid x, S) = \frac{\exp[-d(f_\phi(x), c_k)/\tau]}{\sum_j \exp[-d(f_\phi(x), c_j)/\tau]}. \tag{20.5}$$

每个 episode 先编码支持集并计算原型，再计算查询交叉熵，最后反向更新共享编码器。类均值与平方欧氏距离配合有明确几何意义，换用任意距离不保证均值仍是最佳代表。温度 τ 影响概率尖锐程度，应在元验证任务选择。

手算一次原型适应与预测。 假设编码器已把支持样本映到一维，第一类为 $0, 2$，第二类为 $4, 6$。计算均值得到 $c_1 = 1, c_2 = 5$；新查询编码 $h = 2$ 到

两中心的平方距离为 $1,9$。取 $\tau=2$，第一类概率为 $e^{-1/2}/(e^{-1/2}+e^{-9/2})=1/(1+e^{-4})\approx 0.982$。看到支持集以后只重算原型就已经发生任务适应，无须先对编码器做梯度下降。若改把距离 $|h-c_k|$ 而非平方距离代入，概率与相应概率假设都会改变；因此实现必须说明 d 是哪一种距离。支持集中每类至少有一个样本，否则类均值分母为零。

均值原型、概率模型与反向传播。 设每个编码 $h_i=f_\phi(x_i)\in\mathbb{R}^r$，类别 k 的原型解决 $\min_c \sum_{i\in S_k}\|h_i-c\|^2$。展开并求导得到 $2|S_k|c-2\sum_i h_i=0$，故最优解正是均值 c_k。若再假设 $h\mid y=k\sim\mathcal{N}(c_k,\sigma^2 I_r)$ 且各类先验相同，贝叶斯公式给出平方欧氏原型的 softmax，温度 $\tau=2\sigma^2$。先验不同则需在 logit 中加 $\log\pi_k$。因此均值和距离的配合隐含了单峰、近似同尺度类别分布；同类多工况形成多个分支时，均值可能落在没有真实样本的位置。

对查询真标签 y，令 $\ell=-\log p_y$、$h=f_\phi(x)$。平方欧氏距离下

$$\frac{\partial \ell}{\partial h}=\frac{2}{\tau}\left(\sum_k p_k c_k-c_y\right),\qquad \frac{\partial \ell}{\partial c_k}=\frac{2}{\tau}(p_k-\mathbf{1}[k=y])(h-c_k). \tag{20.6}$$

这来自交叉熵对 logit 的导数 $p_k-\mathbf{1}[k=y]$ 以及 $\partial[-\|h-c_k\|^2/\tau]/\partial h=-2(h-c_k)/\tau$；对类别求和时，含 h 的项因 $\sum_k(p_k-\mathbf{1}[k=y])=0$ 而抵消。固定原型、直接更新查询编码时，负梯度方向为 $c_y-\sum_k p_k c_k$，即真类原型相对于概率加权原型的位置；它不保证每步都缩短到真类原型的欧氏距离。实际编码器更新还会同时改变支持与查询编码。又因 $\partial c_k/\partial h_i=I_r/|S_k|$，查询误差会通过原型回传到每个支持编码，不能在元训练中默认将原型从计算图分离。推理时则只需计算支持原型和新查询距离。若支持噪声独立且协方差为 Σ_k，均值方差为 $\Sigma_k/|S_k|$；相关窗口会降低这种方差缩减收益，说明 shot 数必须按真正独立证据理解。

多原型变体用多个中心表示同类不同工况，但需要估计中心数和分配规则；类不平衡变体应避免支持样本数量被隐含当作类别先验。Relation Networks 用可学习关系模块替代固定距离 [84]，表达能力增加，同时也更易记住训练任务的比较模式。传导式变体联合利用无标签查询集结构，须

与逐查询归纳预测分开比较。

可学习关系与无标签查询的边界。 关系模块可以取 $r_\psi([h;c_k])\in\mathbb{R}$，其中拼接输入为 $2r$ 维，令 $p_k=\mathrm{softmax}_k(r_\psi([h;c_k]))$，再用查询交叉熵训练 ϕ,ψ。此时 $\partial\ell/\partial r_k=p_k-\mathbf{1}[k=y]$，随后通过关系网络传回编码器。关系分数不一定对称，也不必满足三角不等式，所以它是任务比较函数而非严格距离；灵活性提高的同时失去了固定度量的一些约束。

若允许一次看到整个无标签查询批，可用软分配 $r_{jk}\propto\exp[-\|h_j-c_k\|^2/\tau]$，再以 $c_k^{new}=(\sum_{i\in S_k}h_i+\sum_{j\in Q}r_{jk}h_j)/(|S_k|+\sum_{j\in Q}r_{jk})$ 更新中心。它类似固定各向同性尺度混合模型的一次软聚类更新，不需要查询标签，但确实使用了查询分布。未知类、类别不平衡或初始原型错误可能形成自我强化，因此必须与逐查询预测分开报告，也不能在只到达一个样本的部署流程中假定整批查询可见。

20.3 梯度初始化与一阶变体

MAML 的内外循环。 MAML 学习适于快速更新的初始化 θ[21]。单步内循环与外循环为

$$\theta_i'=\theta-\alpha\nabla_\theta\mathcal{L}_{S_i}(\theta),\qquad \theta\leftarrow\theta-\beta\sum_i\nabla_\theta\mathcal{L}_{Q_i}(\theta_i'). \tag{20.7}$$

先采样多个任务，各自从同一初始化开始适应，再汇总查询梯度；不能让任务 $i+1$ 直接继承任务 i 的适应结果。上式对任务求和，固定批量 B 时可把平均因子 $1/B$ 并入外循环学习率；若要保持前述任务等权平均目标且批量大小变化，应显式除以 B。链式法则给出

$$\nabla_\theta\mathcal{L}_{Q_i}(\theta_i')=(I-\alpha H_{S_i})^{\top}\nabla_{\theta_i'}\mathcal{L}_{Q_i}(\theta_i'). \tag{20.8}$$

这里 i 索引本批任务，$\alpha,\beta>0$ 分别为内、外循环学习率，$H_{S_i}=\nabla_\theta^2\mathcal{L}_{S_i}(\theta)$ 是在当前初始化处求值的 Hessian，I 与参数维数相同。实现通常使用 Hessian–

向量积，无需显式存储整个 Hessian，但多步内循环仍增加计算图与显存。适应步数、内循环学习率和是否更新归一化统计量都属于算法设定。

一维数值看清为什么要再乘一次导数。 取初始化 $\theta = 0$、支持损失 $(\theta - 2)^2/2$、内步长 $\alpha = 1/2$。支持梯度为 -2，适应后 $\theta' = 1$。若查询损失为 $(\theta' - 3)^2/2$，查询梯度对 θ' 是 -2，而 $\partial\theta'/\partial\theta = 1 - \alpha = 1/2$，故对初始化的元梯度为 -1。外步长 $\beta = 0.1$ 把共享初始化更新至 0.1，不是把它替换为本任务的 1，也不是直接使用 -2 更新。查询标签参与元训练的这一步是合法的，元测试则不能执行这一步。Hessian 是损失的二阶偏导矩阵，用来描述梯度如何随参数改变；Jacobian 是向量映射的一阶偏导矩阵，用来把适应后参数的变化追溯到初始化。

多步链式法则与曲率直觉。 设 $\theta_{i,0} = \theta \in \mathbb{R}^d$，第 s 步 $\theta_{i,s+1} = \theta_{i,s} - \alpha\nabla\mathcal{L}_{S_i}(\theta_{i,s})$。记 $H_{i,s} \in \mathbb{R}^{d\times d}$ 为该步 Hessian、$A_{i,s} = I - \alpha H_{i,s}$，则

$$\frac{\partial\theta_{i,m}}{\partial\theta} = A_{i,m-1}\cdots A_{i,0}, \qquad \nabla_\theta\mathcal{L}_{Q_i}(\theta_{i,m}) = A_{i,0}^{\mathsf{T}}\cdots A_{i,m-1}^{\mathsf{T}} g_{Q_i}. \tag{20.9}$$

矩阵一般不可交换，顺序不能倒置。反向实现从查询梯度 $v_m = g_{Q_i}$ 出发，逐步计算 $v_s = v_{s+1} - \alpha H_{i,s}^{\mathsf{T}} v_{s+1}$。对固定向量 v，$Hv = \nabla_\theta[(\nabla_\theta\mathcal{L})^{\mathsf{T}} v]$，所以无须建立 $d\times d$ 矩阵。但仍需保存或重算各步状态，而且内循环梯度必须保留可微路径；把更新后的参数无条件分离会改变算法。

用一维任务 $\mathcal{L}_S(\theta) = a(\theta - b)^2/2$、$\mathcal{L}_Q(v) = c(v - b)^2/2$ 说明曲率作用，其中 $a, c > 0$。一步适应后 $\theta' - b = (1 - \alpha a)(\theta - b)$，外层损失及其梯度为

$$\mathcal{L}_Q(\theta') = \frac{c}{2}(1 - \alpha a)^2(\theta - b)^2, \qquad \frac{d\mathcal{L}_Q(\theta')}{d\theta} = c(1 - \alpha a)^2(\theta - b). \tag{20.10}$$

元目标评价的是适应后误差，而非原点误差。若支持曲率 a 允许一步恰好到达 b，该任务对初始化的梯度可以为零；若步长使 $|1 - \alpha a| > 1$，适应反而放大误差。这说明“容易微调”的初始化必须和步长、任务曲率共同讨论。实际支持与查询目标不同，有限支持样本产生的曲率还可能是噪声，不能把该示例的理想一步解推广到真实网络。

First-Order Model-Agnostic Meta-Learning (FOMAML) 忽略内循环 Jacobian 中的 Hessian 项，以降低开销；它是梯度近似，不是与 MAML 完全等价的目标。Reptile 在单任务上执行多步更新得到 θ_i'，再令 [62]

$$\theta \leftarrow \theta + \epsilon(\theta_i' - \theta). \tag{20.11}$$

式(20.11)不显式对查询损失求二阶梯度，多步任务内更新使算法偏向能在同一任务不同批次间泛化的初始化。一步更新时与多任务梯度训练的关系更接近，因此步数不是无关的实现细节。

一阶近似到底舍弃了什么。 单步时 FOMAML 使用 g_Q 代替 $(I-\alpha H_S)^\top g_Q$，故误差为 $\alpha H_S^\top g_Q$，若 $\|H_S\| \le L$ 则范数不超过 $\alpha L\|g_Q\|$。小步长且曲率受控时这种近似较合理；多步情况下误差来自一串 Jacobian 的省略，不能只凭单步界判断。前述一维例中，FOMAML 给出 $c(1-\alpha a)(\theta-b)$，而真梯度多一个 $1-\alpha a$ 因子，过大步长甚至会使两者方向相反。

对 Reptile，考虑同一任务上两个小批次损失，初始点处梯度为 g_1, g_2、第二批 Hessian 为 H_2。两步内更新用 Taylor 展开得到

$$\theta_1 = \theta - \alpha g_1, \tag{20.12}$$

$$\begin{aligned}\theta_2 &= \theta_1 - \alpha \nabla \mathcal{L}_2(\theta_1) \\ &= \theta - \alpha(g_1 + g_2) + \alpha^2 H_2 g_1 + O(\alpha^3).\end{aligned} \tag{20.13}$$

因此 Reptile 的位移除平均梯度项外，还含跨批次相互作用。由梯度内积的求导关系

$$\nabla(g_1^\top g_2) = H_1 g_2 + H_2 g_1,$$

可知，若批次交换对称，二阶位移在期望上与提高同任务梯度一致性有关。这只是光滑、小步长下的局部解释，不是 Reptile 与 MAML 完全等价的证明。只有一步时没有该项，更新退化为任务采样下的普通梯度训练。

Meta-SGD、Almost No Inner Loop (ANIL) 与隐式梯度。 Meta-SGD 同时学习初始化和逐参数更新尺度 α，内循环写为 $\theta_i' = \theta - \alpha \odot \nabla \mathcal{L}_{S_i}$[53]。更新尺度可改变方向和幅度，但也增加元参数与过拟合风险。ANIL 仅在内循环更新任务头，编码器由外循环训练 [68]；它检验快速适应是否主要依赖可复用表示，而非整个网络都必须变化。

对 Meta-SGD，$\alpha \in \mathbb{R}^d$ 也是元参数。令 $g_S = \nabla \mathcal{L}_S(\theta)$、$g_Q = \nabla \mathcal{L}_Q(\theta')$，链式法则给出

$$\nabla_\alpha \mathcal{L}_Q = -g_S \odot g_Q, \qquad \nabla_\theta \mathcal{L}_Q = [I - \operatorname{diag}(\alpha) H_S]^{\mathsf{T}} g_Q. \tag{20.14}$$

当同一坐标的支持与查询梯度一致时，外循环倾向增大该坐标更新幅度；不一致时倾向减小。允许负尺度还可翻转方向，但这不再是传统的正学习率下降法，应监控任务外的稳定性。

对 ANIL，令参数为编码器 ω 与任务头 w，仅更新 $w' = w - \alpha \nabla_w \mathcal{L}_S(\omega, w)$。编码器的外层梯度仍为

$$\nabla_\omega \mathcal{L}_Q(\omega, w') = \partial_\omega \mathcal{L}_Q + \left(\frac{\partial w'}{\partial \omega}\right)^{\mathsf{T}} \nabla_{w'} \mathcal{L}_Q, \qquad \frac{\partial w'}{\partial \omega} = -\alpha \frac{\partial (\nabla_w \mathcal{L}_S)}{\partial \omega}. \tag{20.15}$$

所以“内循环不更新编码器”不等于“外循环冻结编码器”，也不自动消除混合二阶导数；若额外舍弃该项，还应声明采用了一阶近似。

iMAML 在任务内目标加入到初始化的近端项 [70]：

$$\theta_i^* = \arg\min_{\vartheta} \left[\mathcal{L}_{S_i}(\vartheta) + \frac{\lambda}{2} \|\vartheta - \theta\|^2 \right]. \tag{20.16}$$

在局部可微、驻点充分求解且相关矩阵可逆时，隐式微分给出

$$\frac{\partial \theta_i^*}{\partial \theta} = \lambda (H_{S_i} + \lambda I)^{-1}. \tag{20.17}$$

此处 $\lambda > 0$，$H_{S_i} = \nabla_\vartheta^2 \mathcal{L}_{S_i}(\vartheta)|_{\vartheta = \theta_i^*}$ 改在内层解处求值，不能沿用前面初始化处的数值。通过迭代解线性系统获得向量积，可避免保存全部内循环轨迹；代价转为内层求解和线性系统精度。它不是任意少量梯度步下都成立的精确替代。

隐式微分的驻点方程与数值误差。 令 $G(v,\theta)=\nabla\mathcal{L}_S(v)+\lambda(v-\theta)$。内层解满足 $G(\theta^*,\theta)=0$，对初始化求全导数得到

$$(H_S+\lambda I)\frac{\partial\theta^*}{\partial\theta}-\lambda I=0. \tag{20.18}$$

若 $A=H_S+\lambda I$ 可逆，就得到式(20.17)。对不直接依赖初始化的查询损失，先解 $A^{\mathsf{T}}v=g_Q$，再返回 λv 作为元梯度。若 A 对称正定可用共轭梯度法，并以 Hessian–向量积执行矩阵作用；单纯可逆但不定时，不能无条件使用正定系统的收敛保证。

若线性求解的残差为 $r=g_Q-A^{\mathsf{T}}\widetilde{v}$，则 $\|\widetilde{v}-v\|\le\|A^{-\mathsf{T}}\|\|r\|$。小残差在病态系统中仍可能对应大误差；内层未达到驻点还会引入另一项偏差。对凸二次支持损失的特征方向 $a\ge0$，初始化敏感度为 $\lambda/(a+\lambda)$：证据曲率强的方向更由支持集决定，曲率弱的方向更依赖初始化。λ 很大时稳定但适应受限，过小时可能病态，非凸情况下还可能切换局部解分支。隐式方法省去的是展开轨迹，而不是内层求解本身。

隐式解与一步适应不是同一个答案。 取支持损失 $(v-2)^2/2$、初始化 $\theta=0$、$\lambda=1$。内层驻点由 $(v-2)+(v-0)=0$ 得到 $v^*=1$，一般初始化下 $v^*=(2+\theta)/2$，所以对初始化的导数为 $1/2$。若查询损失为 $(v-3)^2/2$，在 $v^*=1$ 时 $g_Q=-2$，解 $(1+1)w=-2$ 得 $w=-1$，返回 $\lambda w=-1$。如果只走一次步长 0.1 的内更新，得到 $v=0.2$，它并非上述驻点，不能直接套用隐式导数当成该一步程序的精确梯度。

20.4 学习更新规则与概率适应

学习优化器将梯度与历史状态输入参数化更新器：

$$h_{r+1}=g_\phi(h_r,\nabla\mathcal{L}_S),\qquad \theta_{r+1}=\theta_r+u_\phi(h_{r+1}). \tag{20.19}$$

外循环根据优化后的损失训练 ϕ[1]。相比学习一个初始化，这一路线学习整个更新行为，但展开步数、参数尺度和网络结构变化会造成新的分布偏

移。

学习优化器与直接学参数的区别。 普通 SGD 规定更新器 $u = -\eta g$，给定梯度 $g = 2$ 和步长 0.1 就移动 -0.2。学习优化器把这个计算规则本身参数化；例如简单特例 $u_\phi(g) = -\phi g$ 中，ϕ 是跨任务学出的步长，而 θ 仍是本任务要优化的模型参数。历史状态 h_r 可以记住前几步梯度，类似动量，但不是输入样本的隐藏标签。训练它时必须检查经过多步后的查询损失，不能仅奖励第一步下降；过大更新可能第一步有效、随后发散。

学习优化器的状态展开。 设 $\theta_r \in \mathbb{R}^d$、隐藏状态 $h_r \in \mathbb{R}^m$，合并状态 $s_r = (\theta_r, h_r) \in \mathbb{R}^{d+m}$，则上述更新可以写为 $s_{r+1} = T_\phi(s_r; S)$。对 $\phi \in \mathbb{R}^p$，定义 $J_r = \partial s_r / \partial \phi \in \mathbb{R}^{(d+m)\times p}$；状态转移的 Jacobian 为 $(d+m)\times(d+m)$ 矩阵，故下面的乘积仍与 J_r 同形。若初始状态与 ϕ 无关，有

$$J_0 = 0, \qquad J_{r+1} = \frac{\partial T_\phi}{\partial s_r} J_r + \frac{\partial T_\phi}{\partial \phi}, \qquad \nabla_\phi \mathcal{L}_Q(\theta_R) = J_R^{\mathsf{T}} \nabla_{s_R} \mathcal{L}_Q. \tag{20.20}$$

若初始化也可学习，则 J_0 应包含相应导数。由于状态转移使用 $\nabla \mathcal{L}_S(\theta_r)$，第一项通常含 Hessian；对输入梯度停止求导可降低开销，但会改变元梯度。反复相乘的状态 Jacobian 还会产生梯度消失或爆炸，截断反向传播因此是一种有偏近似，而非免费计算技巧。

逐坐标共享更新器可让同一个小网络应用于不同维度参数，然而梯度尺度、层结构、训练时长仍可能超出元训练范围。训练只展开十步的优化器不能凭短期损失下降就保证运行一千步稳定。验证时应报告完整轨迹、不同展开长度及普通 SGD、Adam 在相同计算预算下的结果。

概率元学习不只输出单个适应参数，而是在少量证据下保留多个合理任务解释。Probabilistic Model-Agnostic Meta-Learning (PLATIPUS) 等方法学习初始化的不确定性，并通过任务内更新得到预测分布 [22]。模型平均可表达任务歧义，但需要检查近似后验、采样成本与校准；支持样本少并不保证任何概率方法都能正确估计不确定性。

层次先验如何产生少样本适应。 一个可明确计算的概率元学习模型是 $\theta_i \sim p_\phi(\theta_i)$、$S_i \sim p(S_i \mid \theta_i)$。任务内适应对应

$$p_\phi(\theta_i \mid S_i) = \frac{p(S_i \mid \theta_i) p_\phi(\theta_i)}{\int p(S_i \mid v) p_\phi(v)\, dv}, \qquad p(y \mid x, S_i) = \int p(y \mid x, \theta_i) p_\phi(\theta_i \mid S_i)\, d\theta_i. \tag{20.21}$$

元训练可最大化支持条件下查询数据的预测概率，从而学习使新任务容易适应的先验。这是层次贝叶斯的基本解释，不意味着所有概率元学习算法都使用相同后验或目标。

以线性高斯任务为例，$\theta_i \in \mathbb{R}^d$、$X_S \in \mathbb{R}^{m \times d}$、$y_S \in \mathbb{R}^m$，设 $y_S \mid \theta_i \sim \mathcal{N}(X_S \theta_i, \sigma^2 I)$，先验 $\theta_i \sim \mathcal{N}(\mu, \Lambda^{-1})$、$\Lambda \succ 0$。负对数后验中依赖 θ_i 的部分为

$$\frac{1}{2\sigma^2} \| y_S - X_S \theta_i \|^2 + \frac{1}{2} (\theta_i - \mu)^\top \Lambda (\theta_i - \mu). \tag{20.22}$$

展开二次项并配方得到

$$\Sigma_S = (\Lambda + \sigma^{-2} X_S^\top X_S)^{-1}, \qquad m_S = \Sigma_S (\Lambda \mu + \sigma^{-2} X_S^\top y_S). \tag{20.23}$$

因此新输入 $x \in \mathbb{R}^d$ 的预测分布为 $\mathcal{N}(x^\top m_S, \sigma^2 + x^\top \Sigma_S x)$。第一项方差来自观测噪声，第二项来自任务参数不确定性。样本未覆盖的方向主要保留先验，样本充分的方向更多服从似然，给出了“借助任务经验”的精确含义。先验均值及精度可由多个训练任务学习，但若新设备机制不在训练任务覆盖范围内，强先验也可能造成自信错误。

把概率适应缩成一次加权平均。 令 $d = 1$，先验均值 $\mu = 0$、精度 $\Lambda = 1$，一条支持观测满足 $x = 1, y = 2$ 且 $\sigma^2 = 1$。后验方差为 $\Sigma_S = (1 + 1)^{-1} = 1/2$，后验均值为 $m_S = (1/2)(0 + 2) = 1$，介于先验的 0 与样本偏好的 2 之间。下一条 $x = 1$ 的预测方差为 $1 + 1/2 = 1.5$，其中 1 是观测噪声，$1/2$ 是参数尚不确定。精度是方差的倒数，精度大表示先验更集中而不是更不确定。若相同噪声模型下增加独立支持观测，参数方差可下降，但观测噪声不会因此归零；重复复制同一记录不算独立证据。

非共轭模型常以 $q_\psi(\theta \mid S)$ 近似后验，由 Jensen 不等式有

$$\log p_\phi(S) \geq \mathbb{E}_{q_\psi} \log p(S \mid \theta) - \mathrm{KL}(q_\psi(\theta \mid S) \| p_\phi(\theta)). \tag{20.24}$$

这个证据下界解释了数据拟合与接近共享先验的权衡；若元目标是条件查询预测，还需相应的外层训练，不能把优化支持集下界自动当作优化查询泛化。近似分布过于简单或采样不足会低估多种任务解释，因而概率输出仍须用覆盖率和校准检验。

记忆增强方法把任务内观测写入可寻址状态，以读取记忆完成预测。它与参数梯度适应的主要区别是任务状态的保存位置。元测试时应重置任务记忆，防止跨任务残留信息改变规则；持续学习的回放缓存则有意跨阶段保留，两者不能因都称为“记忆”而沿用同一重置规则。对于序列任务，还必须保证读取的记忆均早于当前预测时刻。

记忆读取也是一种适应算子。 令任务记忆键 $k_j \in \mathbb{R}^r$、值 $v_j \in \mathbb{R}^q$，查询键 $k(x) \in \mathbb{R}^r$。一个基本读取形式是

$$a_j(x) = \frac{\exp(k(x)^\top k_j / \sqrt{r})}{\sum_b \exp(k(x)^\top k_b / \sqrt{r})}, \qquad o(x) = \sum_j a_j(x) v_j. \tag{20.25}$$

若值存标签编码，这与软近邻分类相联系；若值存任务历史状态，则输出还依赖写入与遗忘规则。分母使权重和为一，读取向量位于值向量的凸包内；要产生凸包外的复杂响应，还需后续预测网络。记忆容量有限、错误标签写入和相似键冲突都会限制适应。尤其在顺序标注规则中，当前样本标签必须在本次预测之后才能写入，否则模型学到的是读取答案而非预测。

一次读取的可核算结果。 若两条记忆的键与查询相似度相同，softmax 权重各为 $1/2$，存储的标签值为 $v_1 = (1,0)^\top$、$v_2 = (0,1)^\top$，则读出 $o = (1/2, 1/2)^\top$，表示证据打平而非已确定类别。若先把当前查询真标签写入记忆再读取，模型可能轻易拿到答案，所以写入时序本身就是评价规则的一部分。切换到另一任务时既要重置任务记忆，也要重置任务内优化器的状态，除非明确研究允许跨任务保留状态的另一种设定。

20.5 跨设备快速适应的完整设置

在轴承诊断中，可以把“正常”和一种故障组成 2-way 任务；只有确实有五类可靠标签时，才定义 5-way 任务。应按设备划分元训练、元验证和元测试，同一条原始记录的相邻窗口不能一边进入支持集、一边进入查询集。元测试时，支持集只能用于预先规定的适应步骤，查询集再用来评价不同时间和工况下的表现。类别不够就修改任务设计，不能复制标签来凑 way 数。

任务内标签要与预测头同步。 若某 episode 的两个类为正常与磨损，可以临时编码为 $0,1$；下一 episode 换成裂纹与松动时也可以编码为 $0,1$，但该任务的支持集、查询集和输出头必须使用同一映射。这些编号只表示本任务的类别位置，不能据其相同就认为两任务故障含义相同。基于固定头的梯度方法通常还要求任务输出维度相容，跨 way 数测试需另行规定头的构造，而不是直接沿用不匹配的参数。

每个 episode 的步骤是抽取任务与类别、划分支持查询、重置初始化或任务状态、执行内循环、在查询上计算损失；只有元训练阶段反向更新共享元参数。比较原型网络、MAML、一阶方法与普通预训练微调时，应匹配支持样本、预训练数据和适应计算预算。预训练基线很强时，元学习的额外收益需要单独验证 [13]。

评价以任务而非高度相关的窗口为统计单元，报告平均性能、任务间区间、失败任务比例、适应前后增益、校准与延迟。改变支持集大小、标签噪声和目标设备类型，检查元训练任务分布之外的退化。不能用同一设备随机切片上的高准确率证明快速跨设备适应。

以下课程、实现文档与入门讲解可用于复习任务划分、度量方法和可微适应。

辅助学习材料

- **CS330: Deep Multi-Task and Meta Learning**；作者/平台：Stanford University；英文；课程讲义、作业与项目。重点阅读 meta-learning、few-shot learning、MAML、metric learning 和 task distribution，帮助理解支持集/查询集与双层目标。课程主页。

- **higher documentation: Top-Level Functions**；作者/平台：Facebook Research / higher；英文；API 教程文档。阅读 innerloop_ctx 的 copy_initial_weights 与 track_higher_grads 参数，核对可微内循环、快速权重及 MAML 的梯度路径。在线阅读。

- **一文入门元学习（Meta-Learning）（附代码）**；知乎；中文解说。明确任务划分、支持集与查询集，比较度量学习和梯度初始化；标题与主题据必应索引，原页受限。在线阅读。

- **通俗讲解元学习（Meta-Learning）**；CSDN；中文博客。对照内外层更新，检查测试任务是否泄漏到元训练；标题与主题据必应索引，原页受限。在线阅读。

- **第十五节 2021 - 元学习 Meta Learning (一) - 元学习和机器学习一样也是三個步骤**；李宏毅；bilibili；中文课程。选看第 135 集，对照本章跨任务训练与快速适应。2026 年 10 月 4 日官方公开元数据显示整套课程累计播放约 299.5 万，并非本分集播放量；已核对目录与计数，未逐帧观看。观看分集。

本章小结。 元学习把一个预测器的训练问题改写为适应过程的训练问题。度量方法通过支持集重建比较规则，原型网络把平方距离下的类均值作为任务状态；MAML 通过内外循环链式法则学习初始化，一阶方法以梯度近似换取计算效率，隐式方法则以驻点方程替代轨迹展开。学习优化器和记忆方法把适应放在更新规则或显式状态中，概率方法进一步保留少量证据

下的多种任务解释。这些路线的共同目标都是适应后的查询风险，而不是仅把支持样本拟合得更好。

本章最重要的限制同样位于任务层面：训练任务的共同性未必能延续到新设备，过强先验、错误近邻和不稳定更新都可能放大偏差。只有设备级隔离、合法的支持查询划分、匹配的适应预算以及强预训练基线，才能说明元学习带来了真实收益。对同一设备重复切窗，或者利用元测试查询表现调参，都会改变原本宣称的学习问题。

全书从怎样定义样本和损失开始，经过优化、概率推断和深度模型，最后讨论了不同的数据组织与学习方式。回到设备现场，仍应先问手上有什么记录、要提前作出什么判断，再选择模型和训练办法，最后检查误差、不确定性与运行成本。接下来的结语把这些检查整理为五个问题。开始新任务时，把记录来源、可用时间和评价方法写清楚，比先选一个热门模型更有帮助。

结语：如何开始一个工业数据智能问题

面对新的工业任务，先写下五件事：现在能看到哪些变量，要提前多久给出什么判断，线上什么时候拿得到每条记录，设备和工况会怎样变化，以及漏报、误报各会带来什么代价。例如要预测未来二十四小时内的故障，就必须同时写清标签确认时间、预测窗口和允许的告警延迟。五件事没有写清之前，模型结构的比较缺少明确依据。

回看全书，第一部分把实际问题写成数据、假设空间、损失和风险之间的关系，并说明训练误差为什么不能代替部署表现；第二部分把未知量纳入概率推理，区分参数估计、预测分布与决策所需的不确定性；第三部分根据时间、空间、语言、跨模态关系和物理规律组织模型；第四部分进一步改变数据到达、知识迁移、标注获取和协作学习的方式。这条顺序反映了一个基本判断：先明确需要保留的结构与需要承担的错误，再选择模型，而不是从某个热门模型反推问题。

数学推导使这种选择具有可检查的依据。最小二乘的正规方程揭示了可辨识性与数值条件的重要性，概率模型的似然揭示了损失函数背后的观测假设，泛化分析揭示了样本数量与复杂度之间的约束，梯度与近似推断揭示了可计算性所付出的代价。深度网络并没有取消这些问题；它只是把表示和参数空间扩展得更大。迁移、联邦或元学习也没有自动消除分布变化，而是为利用已有知识增加了新的结构假设。公式的价值因此不在于显得复杂，而在于让假设、推理和限制能够被逐项追问。

真正开始一个项目时，可以先固定预测时刻和标签窗口，建立按设备与时间隔离的评估集，再实现可解释的简单基线。只有在误差分析指出明确瓶颈之后，才引入更丰富的表示、不确定性估计或新的学习方式。每次修改都应留下可复核的比较：使用了哪些新增信息，改变了什么假设，改善了

哪类错误，增加了多少计算与维护成本。在本文的维护案例中，风险预测、缺陷定位和规程问答最终都必须回到同一件事：现有证据是否足以支持下一步维护动作；若不足，系统应请求复检或补充观测，而不是用更肯定的输出掩盖知识的缺口。

因此，学完本书并不意味着为每种工业任务记住一个标准答案，而是形成一套可以反复使用的工作方式：把问题写清楚，把推导做完整，把近似讲明白，把证据与结论对应起来，并在环境变化后重新检验。能够说明一个方法何时不应使用，与能够实现它同样重要。

参考文献

[1] Marcin Andrychowicz et al. Learning to learn by gradient descent by gradient descent. In *Advances in Neural Information Processing Systems*, 2016.

[2] Jordan T. Ash, Chicheng Zhang, Akshay Krishnamurthy, John Langford, and Alekh Agarwal. Deep batch active learning by diverse, uncertain gradient lower bounds. In *International Conference on Learning Representations*, 2020.

[3] Adrien Bardes, Jean Ponce, and Yann LeCun. VICReg: Variance-invariance-covariance regularization for self-supervised learning. In *International Conference on Learning Representations*, 2022.

[4] Mikhail Belkin and Partha Niyogi. Laplacian eigenmaps for dimensionality reduction and data representation. *Neural Computation*, 15(6):1373–1396, 2003.

[5] Mikhail Belkin, Partha Niyogi, and Vikas Sindhwani. Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. *Journal of Machine Learning Research*, 7:2399–2434, 2006.

[6] Shai Ben-David, John Blitzer, Koby Crammer, Alex Kulesza, Fernando Pereira, and Jennifer Wortman Vaughan. A theory of learning from different domains. *Machine Learning*, 79:151–175, 2010.

[7] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

[8] Tom B. Brown et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, 2020.

[9] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *IEEE/CVF International Conference on Computer Vision*, 2021.

[10] Gavin C. Cawley and Nicola L. C. Talbot. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11:2079–2107, 2010.

[11] Arslan Chaudhry, Marc'Aurelio Ranzato, Marcus Rohrbach, and Mohamed Elhoseiny. Efficient lifelong learning with A-GEM. In *International Conference on Learning Representations*, 2019.

[12] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International Conference on Machine Learning*, 2020.

[13] Wei-Yu Chen, Yen-Cheng Liu, Zsolt Kira, Yu-Chiang Frank Wang, and Jia-Bin Huang. A closer look at few-shot classification. In *International Conference on Learning Representations*, 2019.

[14] Xinlei Chen and Kaiming He. Exploring simple siamese representation learning. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.

[15] Ronald R. Coifman and Stéphane Lafon. Diffusion maps. *Applied and Computational Harmonic Analysis*, 21(1):5–30, 2006.

[16] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20:273–297, 1995.

[17] Matthias De Lange et al. A continual learning survey: Defying forgetting in classification tasks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(7):3366–3385, 2022.

[18] Marc Peter Deisenroth, A. Aldo Faisal, and Cheng Soon Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020.

[19] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2019.

[20] David L. Donoho and Carrie Grimes. Hessian eigenmaps: Locally linear embedding techniques for high-dimensional data. *Proceedings of the National Academy of Sciences*, 100(10):5591–5596, 2003.

[21] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. *International Conference on Machine Learning*, 2017.

[22] Chelsea Finn, Kelvin Xu, and Sergey Levine. Probabilistic model-agnostic meta-learning. In *Advances in Neural Information Processing Systems*, 2018.

[23] Yarin Gal, Riashat Islam, and Zoubin Ghahramani. Deep bayesian active learning with image data. In *International Conference on Machine Learning*, 2017.

[24] Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, and Victor Lem-

pitsky. Domain-adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59):1–35, 2016.

[25] Stuart Geman and Donald Geman. Stochastic relaxation, gibbs distributions, and the bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-6(6):721–741, 1984.

[26] Jean-Bastien Grill et al. Bootstrap your own latent: A new approach to self-supervised learning. In *Advances in Neural Information Processing Systems*, 2020.

[27] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning*, 2017.

[28] Suchin Gururangan, Ana Marasović, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey, and Noah A. Smith. Don't stop pretraining: Adapt language models to domains and tasks. In *Annual Meeting of the Association for Computational Linguistics*, 2020.

[29] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.

[30] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020.

[31] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.

[32] Arthur E. Hoerl and Robert W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.

[33] Timothy Hospedales, Antreas Antoniou, Paul Micaelli, and Amos Storkey. Meta-learning in neural networks: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(9):5149–5169, 2022.

[34] Neil Houlsby et al. Parameter-efficient transfer learning for NLP. In *International Conference on Machine Learning*, 2019.

[35] Neil Houlsby, Ferenc Huszár, Zoubin Ghahramani, and Máté Lengyel. Bayesian active learning for classification and preference learning. *arXiv preprint arXiv:1112.5745*, 2011.

[36] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.

[37] Jiayuan Huang, Alexander J. Smola, Arthur Gretton, Karsten M. Borgwardt, and Bernhard Sch"olkopf. Correcting sample selection bias by unlabeled data. In *Advances in Neural Information Processing Systems*, 2007.

[38] Ameya D. Jagtap and George Em Karniadakis. Extended physics-informed neural networks (XPINNs): A generalized space-time domain decomposition based deep learning framework for nonlinear par-

tial differential equations. *Communications in Computational Physics*, 28(5):2002–2041, 2020.

[39] Rudolf E. Kalman. A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1):35–45, 1960.

[40] Sai Praneeth Karimireddy, Satyen Kale, Mehryar Mohri, Sashank Reddi, Sebastian Stich, and Ananda Theertha Suresh. SCAFFOLD: Stochastic controlled averaging for federated learning. In *International Conference on Machine Learning*, 2020.

[41] George Em Karniadakis, Ioannis G. Kevrekidis, Lu Lu, Paris Perdikaris, Sifan Wang, and Liu Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3:422–440, 2021.

[42] Ehsan Kharazmi, Zhongqiang Zhang, and George Em Karniadakis. hp-VPINNs: Variational physics-informed neural networks with domain decomposition. *Computer Methods in Applied Mechanics and Engineering*, 374:113547, 2021.

[43] Prannay Khosla et al. Supervised contrastive learning. In *Advances in Neural Information Processing Systems*, 2020.

[44] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.

[45] James Kirkpatrick et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.

[46] Andreas Kirsch, Joost van Amersfoort, and Yarin Gal. BatchBALD: Efficient and diverse batch acquisition for deep bayesian active learning. In *Advances in Neural Information Processing Systems*, 2019.

[47] Aditi Krishnapriyan, Amir Gholami, Shandian Zhe, Robert Kirby, and Michael W. Mahoney. Characterizing possible failure modes in physics-informed neural networks. In *Advances in Neural Information Processing Systems*, 2021.

[48] John Lafferty, Andrew McCallum, and Fernando Pereira. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. In *International Conference on Machine Learning*, 2001.

[49] David D. Lewis and William A. Gale. A sequential algorithm for training text classifiers. In *ACM SIGIR Conference on Research and Development in Information Retrieval*, 1994.

[50] Patrick Lewis et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, 2020.

[51] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International Conference on Machine Learning*, 2023.

[52] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, and Virginia Smith. Federated optimization in heterogeneous networks. In *Proceedings of Machine Learning and Systems*, 2020.

[53] Zhenguo Li, Fengwei Zhou, Fei Chen, and Hang Li. Meta-SGD: Learning to learn quickly for few-shot learning. *arXiv preprint arXiv:1707.09835*, 2017.

[54] Zhizhong Li and Derek Hoiem. Learning without forgetting. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 40(12):2935–2947, 2018.

[55] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems*, 2023.

[56] Mingsheng Long, Yue Cao, Jianmin Wang, and Michael I. Jordan. Learning transferable features with deep adaptation networks. In *International Conference on Machine Learning*, 2015.

[57] David Lopez-Paz and Marc'Aurelio Ranzato. Gradient episodic memory for continual learning. In *Advances in Neural Information Processing Systems*, 2017.

[58] Andrew McCallum, Dayne Freitag, and Fernando C. N. Pereira. Maximum entropy markov models for information extraction and segmentation. In *International Conference on Machine Learning*, 2000.

[59] Leland McInnes, John Healy, and James Melville. UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*, 2018.

[60] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Aguera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *International Conference on Artificial Intelligence and Statistics*, 2017.

[61] Kevin P. Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, 2022.

[62] Alex Nichol, Joshua Achiam, and John Schulman. On first-order meta-learning algorithms. *arXiv preprint arXiv:1803.02999*, 2018.

[63] Long Ouyang et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, 2022.

[64] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2010.

[65] Lawrence R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2):257–286, 1989.

[66] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, 2021.

[67] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. In *Advances in Neural Information Processing Systems*, 2023.

[68] Aniruddh Raghu, Maithra Raghu, Samy Bengio, and Oriol Vinyals. Rapid learning or feature reuse? towards understanding the effective-

ness of MAML. In *International Conference on Learning Representations*, 2020.

[69] Maziar Raissi, Paris Perdikaris, and George Em Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.

[70] Aravind Rajeswaran, Chelsea Finn, Sham M. Kakade, and Sergey Levine. Meta-learning with implicit gradients. In *Advances in Neural Information Processing Systems*, 2019.

[71] Carl Edward Rasmussen and Christopher K. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.

[72] Sylvestre-Alvise Rebuffi, Alexander Kolesnikov, Georg Sperl, and Christoph H. Lampert. iCaRL: Incremental classifier and representation learning. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.

[73] Sam T. Roweis and Lawrence K. Saul. Nonlinear dimensionality reduction by locally linear embedding. *Science*, 290(5500):2323–2326, 2000.

[74] Nicholas Roy and Andrew McCallum. Toward optimal active learning through sampling estimation of error reduction. In *International Conference on Machine Learning*, 2001.

[75] Andrei A. Rusu et al. Progressive neural networks. *arXiv preprint arXiv:1606.04671*, 2016.

[76] Ameya Sathe and Jakob Mann. A review of turbulence measurements using ground-based wind lidars. *Atmospheric Measurement Techniques*, 6:3147–3167, 2013.

[77] Bernhard Schölkopf, Alexander Smola, and Klaus-Robert Müller. Nonlinear component analysis as a kernel eigenvalue problem. *Neural Computation*, 10(5):1299–1319, 1998.

[78] Ozan Sener and Silvio Savarese. Active learning for convolutional neural networks: A core-set approach. In *International Conference on Learning Representations*, 2018.

[79] Burr Settles. Active learning literature survey. Technical Report 1648, University of Wisconsin–Madison, 2009.

[80] H. Sebastian Seung, Manfred Opper, and Haim Sompolinsky. Query by committee. In *Workshop on Computational Learning Theory*, 1992.

[81] Hanul Shin, Jung Kwon Lee, Jaehong Kim, and Jiwon Kim. Continual learning with deep generative replay. In *Advances in Neural Information Processing Systems*, 2017.

[82] Jake Snell, Kevin Swersky, and Richard Zemel. Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, 2017.

[83] Baochen Sun and Kate Saenko. Deep CORAL: Correlation alignment for deep domain adaptation. In *European Conference on Computer Vision Workshops*, 2016.

[84] Flood Sung, Yongxin Yang, Li Zhang, Tao Xiang, Philip H. S. Torr, and Timothy M. Hospedales. Learning to compare: Relation network for few-shot learning. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2018.

[85] Joshua B. Tenenbaum, Vin de Silva, and John C. Langford. A global geometric framework for nonlinear dimensionality reduction. *Science*, 290(5500):2319–2323, 2000.

[86] Michalis Titsias. Variational learning of inducing variables in sparse gaussian processes. In *International Conference on Artificial Intelligence and Statistics*, 2009.

[87] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.

[88] Vladimir N. Vapnik and Alexey Ya. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and Its Applications*, 16(2):264–280, 1971.

[89] Ashish Vaswani et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.

[90] Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. Extracting and composing robust features with denoising autoencoders. In *International Conference on Machine Learning*, 2008.

[91] Oriol Vinyals, Charles Blundell, Timothy Lillicrap, Daan Wierstra, and Koray Kavukcuoglu. Matching networks for one shot learning. In *Advances in Neural Information Processing Systems*, 2016.

[92] Dequan Wang, Evan Shelhamer, Shaoteng Liu, Bruno Olshausen, and Trevor Darrell. Tent: Fully test-time adaptation by entropy minimization. In *International Conference on Learning Representations*, 2021.

[93] Sifan Wang, Shyam Sankaran, Hanwen Wang, and Paris Perdikaris. An expert's guide to training physics-informed neural networks, 2023. arXiv:2308.08468v1.

[94] Liu Yang, Xuhui Meng, and George Em Karniadakis. B-PINNs: Bayesian physics-informed neural networks for forward and inverse PDE problems with noisy data. *Journal of Computational Physics*, 425:109913, 2021.

[95] Friedemann Zenke, Ben Poole, and Surya Ganguli. Continual learning through synaptic intelligence. In *International Conference on Machine Learning*, 2017.

[96] Jincheng Zhang and Xiaowei Zhao. Spatiotemporal wind field prediction based on physics-informed deep learning and LIDAR measurements. *Applied Energy*, 288:116641, 2021.

[97] Zhenyue Zhang and Hongyuan Zha. Principal manifolds and nonlinear dimensionality reduction via tangent space alignment. *SIAM Journal on Scientific Computing*, 26(1):313–338, 2004.